Université Mohammed Premier
Faculté des Sciences Oujda
Département de Mathématiques

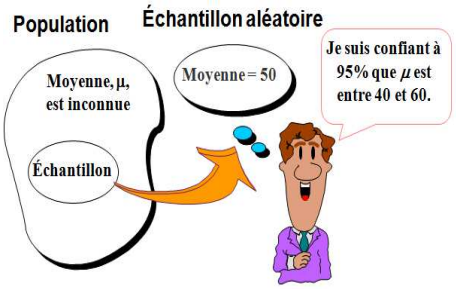
COURS ET EXERCICES

BIOSTATISTIQUE

Enseignant : SGHIR AISSA
sghir.aissa@gmail.com

Filière : BCG-BIO-S3

Année universitaire :
2025-2026





Faire des erreurs n'est pas mal. Ce n'est pas mal du tout. Les erreurs sont la conséquence inévitable d'avoir fait quelque chose de nouveau. Elles sont une manifestation de l'apprentissage et de l'exploration. Sans elles, nous n'aurions aucune originalité.

Table des matières

1 Statistique descriptive **5**
- 1.1 Introduction . . . 5
- 1.2 Statistique descriptive univariée . . . 6
  - 1.2.1 Vocabulaires . . . 6
  - 1.2.2 Paramètres de position . . . 12
  - 1.2.3 Paramètres de dispersion . . . 15
  - 1.2.4 Utilisation d'une calculatrice de type Casio . . . 16
- 1.3 Statistique descriptive bivariée . . . 18
  - 1.3.1 Deux variables qualitatives . . . 18
  - 1.3.2 Une variable quantitative et une variable qualitative . . . 19
  - 1.3.3 Deux variables quantitatives . . . 19
  - 1.3.4 Utilisation d'une calculatrice de type Casio . . . 23
- 1.4 Exercices . . . 25

2 Notion de probabilités et variables aléatoires **27**
- 2.1 Vocabulaires . . . 27
- 2.2 Notion de probabilités . . . 28
- 2.3 Notion de variables aléatoires . . . 29
  - 2.3.1 Variables aléatoires discrètes . . . 30
  - 2.3.2 Variables aléatoires continues . . . 30
- 2.4 Exercices . . . 33

3 Échantillonnage et estimation **35**
- 3.1 Échantillonnage . . . 35
  - 3.1.1 Introduction . . . 35
  - 3.1.2 Distribution d'échantillonnage de la moyenne . . . 37
  - 3.1.3 Distribution d'échantillonnage de la proportion . . . 39
  - 3.1.4 Distribution d'échantillonnage de la variance . . . 40
- 3.2 Estimation . . . 40
  - 3.2.1 Estimation ponctuelle . . . 40
  - 3.2.2 Estimation par intervalle de confiance . . . 41
- 3.3 Exercices . . . 44

4 Tests d'hypothèses **46**
4.1 Introduction 46
4.2 Tests de conformité 46
4.2.1 Test de conformité de la proportion à une référence 46
4.2.2 Test de conformité de la moyenne à une référence 47
4.2.3 Test de conformité de la variance à une référence 48
4.3 Test d'indépendance du khi-deux entre deux variables qualitatives 49
4.4 Tests d'homogénéité dans le cas des échantillons indépendants 50
4.4.1 Test de comparaison de deux proportions 50
4.4.2 Test de comparaison de deux variances 50
4.4.3 Test de comparaison de deux moyennes 52
4.5 Test de normalité: test de Shapiro et Wilk 54
4.6 Exercices 55
4.7 Exercices de révisions 58
4.8 Examen (session normale 2016-2017) 61
4.9 Examen (session de rattrapage 2016-2017) 63
4.10 Examen (session normale 2017-2018) 65
4.11 Examen (session de rattrapage 2017-2018) 67
4.12 Références 68

Chapitre 1

Statistique descriptive

1.1 Introduction

Dans chaque expérience, un manager est conduit à prendre des décisions pour gérer ses résultats. Leur pertinence dépend de la qualité de l'information recueillie, de son analyse et de sa capacité à transformer l'information en action. Dans cet exemple et dans d'autres domaines, (biologie, géologie, physique, chimie, finance, ...), les managers doivent pouvoir disposer d'outils performants d'aide à la décision: la statistique s'inscrit dans cette perspective et dont la définition est la suivante:

La statistique est un ensemble de méthodes scientifiques dont l'objectif est d'analyser, structurer et modéliser des informations numériques.

Les méthodes statistiques peuvent être classés en deux groupes:

1) La Statistique descriptive regroupe les méthodes dont l'objectif principal est la description des données étudiées. Cette description des données se fait à travers leur représentation graphique, et le calcul de résumés numériques. Dans cette optique, on ne fait pas appel à des outils de type probabiliste.

- **Statistique descriptive univariée:** étude de la population selon une seule variable.
- **Statistique descriptive bivariée:** étude des corrélations et relations éventuelles entre deux variables de la même population.
- **Statistique descriptive multivariée:** étude des relations éventuelles entre plusieurs variables de la même population.

2) La statistique inférentielle. Ce terme regroupe les méthodes dont l'objectif principal est de préciser un phénomène sur une population globale, à partir de son observation sur une partie restreinte (échantillon) de cette population. Ce passage ne se fait que moyennant des hypothèses de type probabiliste.
NB: La statistique descriptive précède en général la statistique inférentielle dans une démarche de traitement de données: les deux aspects de la statistique se complètent bien plus qu'ils ne s'opposent.

1.2 Statistique descriptive univariée

1.2.1 Vocabulaires

- **Population:** ensemble des individus objets de l'étude.
  (Étudiants, entreprises, plantes, animaux, produits,...)
- **Échantillon:** sous-ensemble issu de la population.
  (Une classe, une ville, hommes, femmes,...)
- **Unité statistique:** chaque individu.
  (Un étudiant, une plante, un homme, une femme,...)
- **Variable:** caractère ou propriété mesuré sur chaque individu notée X,Y,...
  (Note, taille, poids, sex, âge, couleur, mesure,...)
- **Modalités:** les valeurs possibles de la variable.
- **Série statistique:** suite des valeurs prises par une variable X notées $x_1, x_2, x_3, ...$
- **Variable quantitative:** les modalités sont mesurables ou repérables.
  - **Variable quantitative discrète:** l'ensemble des modalités est fini ou dénombrable. (Note, taille, poids, âge, mesure,...)
  - **Variable quantitative continue:** l'ensemble des modalités est un intervalle fini ou infini. ($[8; 20[$, $[0; +\infty[$, $\mathbb{R}$,...)
- **Variable qualitative:** les modalités ne sont pas mesurables.
  - **Variable qualitative nominale:** les modalités ne peuvent pas être ordonnées. (sex, couleur,...)
  - **Variable qualitative ordinale:** les modalités peuvent être ordonnées. (taille d'un vêtement: XXL, XL, L, M, S).
- **Effectif totale n:** le nombre de toutes les valeurs prises par la variable.
- **Effectif n_i:** nombre d'apparitions de la valeur x_i dans la population ou dans l'échantillon.

$$\sum_{i=1}^{J} n_i = n_1 + n_2 + ... + n_J = n.$$

- **Fréquence f_i associée à la valeur x_i**

$$\begin{cases} f_i = \frac{n_i}{n}, \\ \sum\limits_{i=1}^{J} f_i = f_1 + f_2 + ... + f_J = 1. \end{cases}$$

- **Pourcentage p_i associé à la valeur x_i**

$$\begin{cases} p_i = 100 \times f_i \ \%, \\ \sum\limits_{i=1}^{J} p_i = p_1 + p_2 + ... + p_J = 100 \ \%. \end{cases}$$

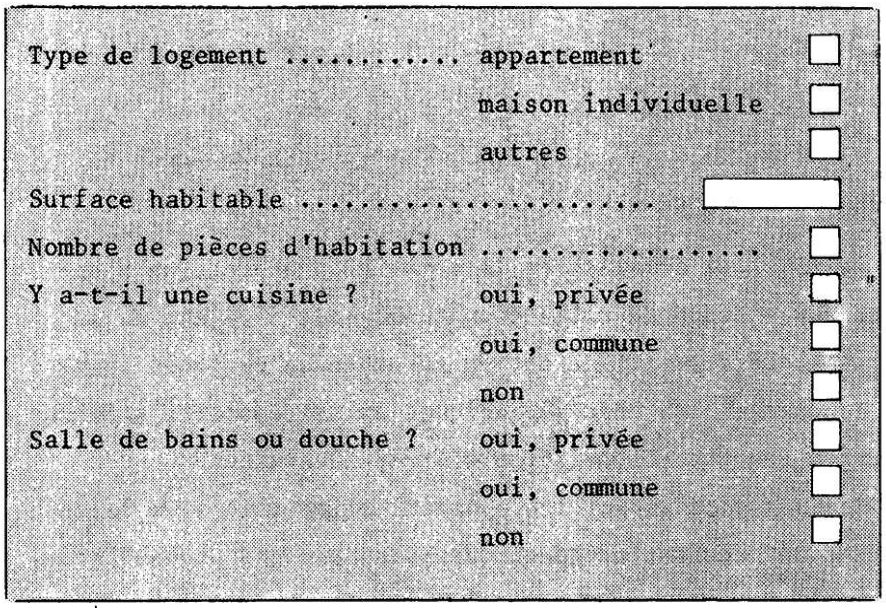
- **Effectif cumulé** N_i

$$\begin{cases} N_1 = n_1, \\ N_2 = n_1 + n_2, \\ N_3 = n_1 + n_2 + n_3, \\ ..... \\ N_J = n_1 + n_2 + ... + n_J = n. \end{cases}$$

- **Fréquence cumulée** F_i

$$\begin{cases} F_1 = f_1, \\ F_2 = f_1 + f_2, \\ F_3 = f_1 + f_2 + f_3, \\ ..... \\ F_J = f_1 + f_2 + ... + f_J = 1. \end{cases}$$

Remarque
Avant de citer les exemples de cette section, nous présentons un exemple d'un modèle de questionnaire pour la collection des informations dans la population.



Exemples:
•Variable qualitative nominale
On note C : célibataire, M : marié, V : veuf, D : divorcé. On s'intéresse à la variable X=(état-civil) sur une population de $n = 20$ personnes. Considérons la série statistique suivante :

M D M C C M C C C M C M V M V D C C M C

Tableau statistique

x_i	n_i	f_i	$p_i\%$	N_i	F_i
C	9	0.45	45	9	0.45
M	7	0.35	35	16	0.75
V	2	0.10	10	18	0.85
D	2	0.10	10	**20**	**1**

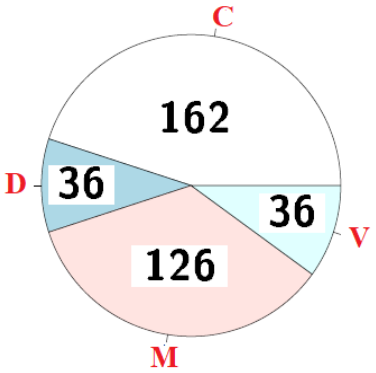
Par exemple: le nombre d'apparition de la valeur $x_2 = M$ dans la série statistique est $n_2 = 7$, sa fréquence est $f_2 = \frac{n_2}{n} = \frac{7}{20} = 0.35$, son pourcentage $p_2 = 100 \times f_2 = 100 \times 0.35 = 35\ \%$, l'effectif cumulé $N_2 = n_1 + n_2 = 9 + 7 = 16$ et la fréquence cumulée $F_2 = f_1 + f_2 = 0.45 + 0.35 = 0.75$.

Diagramme en secteurs

Le tableau statistique d'une variable qualitative est représenté par le diagramme en secteurs formés par les degrés obtenus comme suit:

x_i	$p_i\ \%$	$d_i = p_i \times 3.6\ ^\circ$
C	45	162
M	35	126
V	10	36
D	10	36

FIGURE 1.1 – Diagramme en secteurs



•Variable qualitative ordinale

On interroge une population de $n = 50$ personnes sur leur dernier diplôme obtenu. On note: Sd : Sans diplôme, P : Primaire, Se : Secondaire, Su : Supérieur non-universitaire et U : Universitaire.

Sd Sd Sd Sd P P P P P P P P P P P Se Se Su
Se Se Se Se Se Se Se Se Se Se Se Se Su Su Su
Su Su Su Su U U U U U U U U U U U U Su

FIGURE 1.2 – Diagramme en secteurs

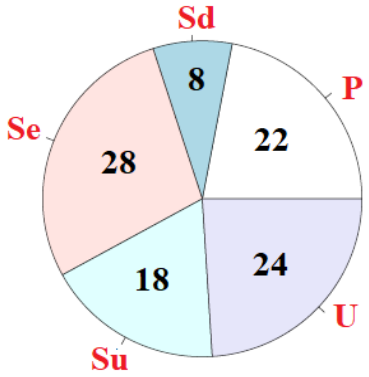


Tableau statistique

x_i	n_i	N_i	f_i	p_i	F_i
Sd	4	4	0.08	8	0.08
P	11	15	0.22	22	0.30
Se	14	29	0.28	28	0.58
Su	9	38	0.18	18	0.76
U	12	**50**	0.24	24	**1**

•Variable quantitative discrète

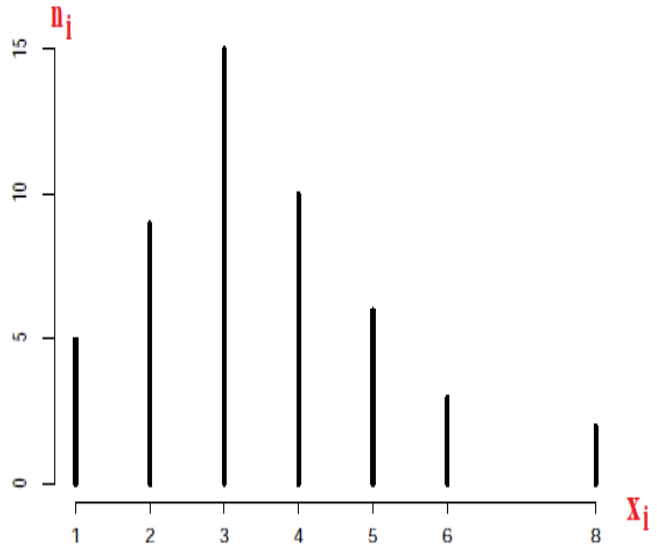
Un quartier est composé d'une population de 50 ménages, et la variable X représente le nombre de personnes par ménage. Les valeurs de la variable sont:

1	1	1	1	1	2	2	2	2	2
2	2	2	2	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	4
4	4	4	4	4	4	4	4	4	5
5	5	5	5	5	6	6	6	8	8

Tableau statistique

x_i	n_i	N_i	f_i	F_i
1	5	5	0.10	0.10
2	9	14	0.18	0.28
3	15	29	0.30	0.58
4	10	39	0.20	0.78
5	6	45	0.12	0.90
6	3	48	0.06	0.96
8	2	**50**	0.04	**1**

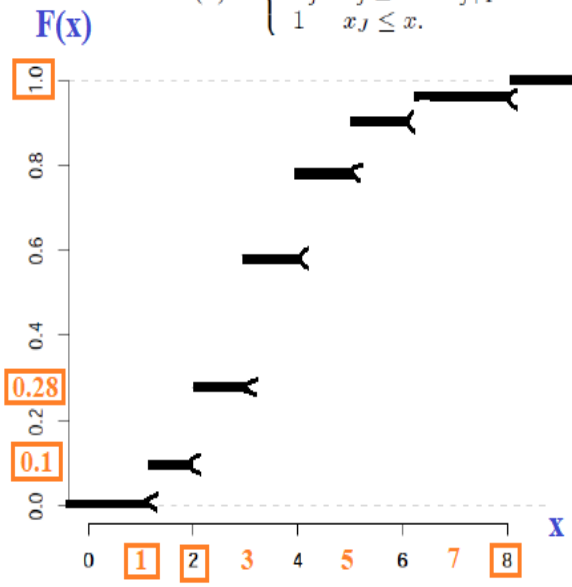
FIGURE 1.3 – Diagramme en bâtonnets des effectifs



Fonction de répartition

Les fréquences cumulées sont représentées au moyen de la fonction de répartition. Cette fonction est définie de $\mathbb{R}$ dans $[0, 1]$ et vaut:

$$F(x) = \begin{cases} 0 & x < x_1 \\ F_j & x_j \leq x < x_{j+1} \\ 1 & x_J \leq x. \end{cases}$$



x_i	F_i
1	0.10
2	0.28
3	0.58
4	0.78
5	0.90
6	0.96
8	1

• **Variable quantitative continue**

Très souvent, la prise en compte de toute les valeurs observées ne permet pas de donner une interprétation simple des résultats et conduit à des calculs inutiles. On peut souvent se contenter de regarder des regroupements en classes.

Exemple:

On mesure la variable X=taille en centimètre d'une population de 50 élèves d'une classe.

152	152	152	153	153
154	154	154	155	155
156	156	156	156	156
157	157	157	158	158
159	159	160	160	160
161	160	160	161	162
162	162	163	164	164
164	164	165	166	167
168	168	168	169	169
170	171	171	171	171

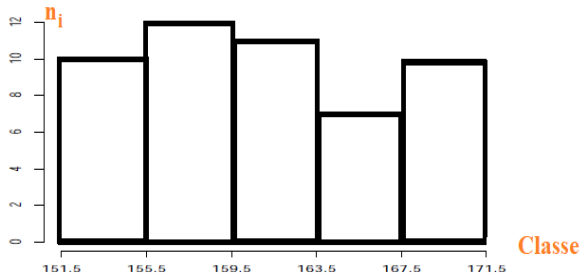
Tableau statistique

Pour construire le tableau statistique, il faut procéder à des regroupements en classes (intervalles) de même amplitude. En règle générale, on choisit au moins cinq classes, sinon on utilise par exemple la règle de Sturge: le nombre de classes est $J = 1+(3.3\times log_{10}(n))$. La longeur de chaque classe est $l = \dfrac{x_{\max} - x_{\min}}{J}$. Par exemple pour $J = 5$, on prend $l \simeq 4$.

classe	n_i	N_i	f_i	F_i
[151.5; 155.5[	10	10	0.20	0.20
[155.5; 159.5[	12	22	0.24	0.44
[159.5; 163.5[	11	33	0.22	0.66
[163.5; 167.5[	7	40	0.14	0.80
[167.5; 171.5[	10	**50**	0.20	**1**

Histogramme des effectifs

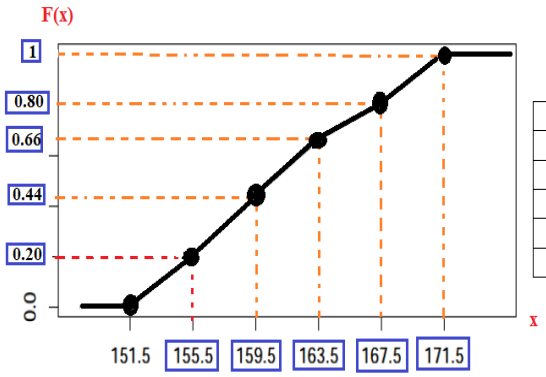
FIGURE 1.4 – Histogramme des effectifs



Fonction de répartition
Si $[c_j^-; c_j^+[$ désigne la classe j, on note, de manière générale:

- c_j^- la borne inférieure de la classe j,
- c_j^+ la borne supérieure de la classe j,
- $c_j = (c_j^+ + c_j^-)/2$ le centre de la classe j,
- $a_j = c_j^+ - c_j^-$ l'amplitude de la classe j,
- n_j l'effectif de la classe j,
- N_j l'effectif cumulé de la classe j,
- f_j la fréquence de la classe j,
- F_j la fréquence cumulée de la classe j.

$$F(x) = \begin{cases} 0 & x < c_1^- \\ F_{j-1} + \frac{f_j}{c_j^+ - c_j^-}(x - c_j^-) & c_j^- \leq x < c_j^+ \\ 1 & c_J^+ \leq x \end{cases}$$



classe	F_i
[151.5 ; 155.5[	0.20
[155.5 ; 159.5[	0.44
[159.5 ; 163.5[	0.66
[163.5 ; 167.5[	0.80
[167.5 ; 171.5[	1

1.2.2 Paramètres de position

• **Le mode**
Le mode est la valeur x_i correspondant à l'effectif (ou fréquence) le plus élevé.
Exemple:

x_i	n_i	f_i
C	9	0.45
M	7	0.35
V	2	0.10
D	2	0.10

le mode est $x_1 = C$: célibataire correspondant à l'effectif $n_1 = 9$.

Remarques
– Le mode peut être calculé pour tous les types de variable, quantitative et qualitative.
– Le mode n'est pas nécessairement unique.
– Quand une variable continue est découpée en classes, on parle de classe modale.

• **La moyenne**
La moyenne $\bar{x}$ ne peut être définie que sur une variable quantitative.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + ... + x_n}{n}.$$

La moyenne peut être calculée à partir des valeurs distinctes et des effectifs.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{J} n_i \times x_i = \frac{(n_1 \times x_1) + ... + (n_J \times x_J)}{n}.$$

Exemple:
Les nombres d'enfants de 8 familles sont les suivants $0, 0, 1, 1, 1, 2, 3, 4$. La moyenne est

$$\bar{x} = \frac{0+0+1+1+1+2+3+4}{8} = 1.5.$$

On peut aussi faire

$$\bar{x} = \frac{(2\times 0)+(3\times 1)+(1\times 2)+(1\times 3)+(1\times 4)}{8} = 1.5.$$

• **La médiane**
Cas d'une variable quantitative discrète
La médiane, notée M_e ou $x_{\frac{1}{2}}$, est une valeur centrale de la série statistique qui la partage en deux groupes de même effectifs. Elle est obtenue de la manière suivante:
– On trie la série statistique par ordre croissant des valeurs observées:
Par exemple, avec la série observée:

$$3 \quad 2 \quad 1 \quad 0 \quad 0 \quad 1 \quad 2,$$

on obtient:

$$0 \quad 0 \quad 1 \quad \mathbf{1} \quad 2 \quad 2 \quad 3.$$

– $n = 7$ est impair, alors la médiane est la valeur du rang $(n+1)/2 = 4$. Donc $x_{\frac{1}{2}} = 1$.
– Si n est pair, alors la médiane est la moyenne des deux valeurs de rang $n/2$ et $(n/2)+1$.
Par exemple pour $n = 8$, si on a:

$$0 \quad 0 \quad 1 \quad \mathbf{1} \quad \mathbf{2} \quad 2 \quad 3 \quad 4$$

alors

$$x_{\frac{1}{2}} = \frac{1+2}{2} = 1.5.$$

Cas d'une variable quantitative continue

De manière générale, on définira la médiane comme étant la valeur (abscisse) correspondant à la fréquence cumulée $F = 0.5$ ou effectif cumulé $N = \frac{n}{2}$. On l'obtiendra en général par lecture graphique (valeur approchée $M_e = x_{\frac{1}{2}} = F^{-1}(0.5)$) sur la courbe des fréquences cumulées, ou par une formule d'interpolation linéaire (valeur exacte) sur la courbe des effectifs cumulées.

Exemple:

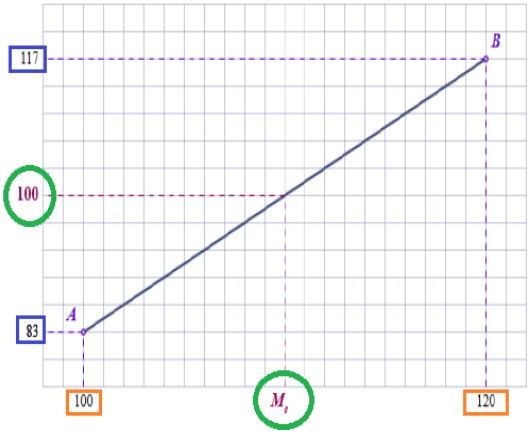
Cas d'une variable quantitative continue :

Budget (*en milliers d'euros*)	[0;50[	[50;70[	[70;100[	[100;120[	[120;150[	[150;200[	[200;240[
Nombre d'entreprises	10	28	45	34	42	33	8
Effectifs cumulés	10	38	83	117	159	192	200

Il y a 200 entreprises, donc la classe médiane est la classe [100; 120[.

$N = \frac{n}{2} = 100$

Calculons la médiane par interpolation linéaire :



La médiane est l'abscisse du point de la droite passant par les points $A(100;83)$ et $B(120;117)$ dont l'ordonnée est égale à 100.

La droite (AB) a pour équation, $y = mx + p$ avec

$$m = \frac{117-83}{120-100} = 1{,}7$$

Comme $A(100;83)$ est un point de la droite (AB), nous obtenons la relation

$$y = 1{,}7(x-100)+83 \quad \Leftrightarrow \quad y = 1{,}7x - 87$$

La médiane est la valeur associé à un effectif égal à 100 d'où x est solution de l'équation

$$1{,}7x - 87 = 100 \quad \Leftrightarrow \quad x = \frac{100+87}{1{,}7} = 110$$

Le budget médian est de 110 milliers d'euros.

1.2.3 Paramètres de dispersion

• **L'étendue**
L'étendue est défini par:

$$E = x_{max} - x_{min}.$$

Exemple:
Pour la série 1 1 2 1 1 3 5 5 5 5 5 3 2 5, on a: $E = 5 - 1 = 4$.
• **La variance**

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2.$$

La variance peut aussi s'écrire:

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{J} n_i \times (x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{J} n_i \times x_i^2 - \bar{x}^2.$$

• **L'écart type**: $\sigma_X = \sqrt{\sigma_X^2}$.
Exemple:
Soit la série statistique 2 3 4 4 5 6 7 9 de taille 8. On a:

$$\bar{x} = \frac{2+3+4+4+5+6+7+9}{8} = 5.$$

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

$$= \frac{(2-5)^2 + (3-5)^2 + (4-5)^2 + (4-5)^2 + (5-5)^2 + (6-5)^2 + (7-5)^2 + (9-5)^2}{8} = 4.5,$$

ou bien : $\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2 = \frac{2^2+3^2+4^2+4^2+5^2+6^2+7^2+9^2}{8} - 5^2 = 4.5.$

L'écart type: $\sigma_X = \sqrt{4.5} = 2.12$.
Remarque
Pour calculer la moyenne et la variance dans le cas d'une variable continue, on calcule les centres des classes qui vont jouer le rôle des valeurs x_i du cas discret.
Exemple:

classe	n_i	centre x_i
$[0;10[$	10	$\frac{0+10}{2} = 5$
$[10;20[$	4	15
$[20;30[$	20	25
$[30;40[$	6	35

$$\bar{x} = \frac{10 \times 5 + 4 \times 15 + 20 \times 25 + 6 \times 35}{40} = 20.5.$$

1.2.4 Utilisation d'une calculatrice de type Casio



On efface les mémoires statistiques :

SECONDE MODE CLR 1 EXE

SHIFT MODE CLR 3 =

On passe en mode statistique MODE CLR SD 2



Exemple:

Note (x_i)	Effectif (n_i)
12	1
15	4

12 ; 1 M+ (n = 1)

15 ; 4 M+ (n = 5)

Note (x_i)	Effectif (n_i)
12	1
15	4

→ 12 ; 1 M+ (n = 1)

→ 15 ; 4 M+ (n = 5)

* Pour déterminer l'effectif total
☞ On trouve : N = 5

SHIFT SECONDE S-SUM 1 N 3 = EXE

* Pour déterminer la moyenne
☞ On trouve la note moyenne : $\bar{x} = 14{,}4$

SECONDE S-VAR 2 $\bar{x}$ 1 EXE

* Pour déterminer l'écart type
☞ On trouve l'écart type : $\sigma = 1{,}2$

SECONDE S-VAR 2 $x\sigma n$ 2 EXE

* Pour déterminer $\Sigma n_i x_i$
☞ On trouve : $\Sigma n_i x_i = 72$

SECONDE S-SUM 1 2 EXE

* Pour déterminer $\Sigma n_i x_i^2$
☞ On trouve : $\Sigma n_i x_i^2 = 1044$

SECONDE S-SUM 1 1 EXE



mode statistique MODE SETUP 3 1-VAR 1

Les mémoires statistiques sont automatiquement effacées quand on entre dans la mode « STAT »

On montre la colonne des fréquences)

SHIFT MODE SETUP ▼ 4 1

Exemple:

Note (x_i)	Effectif (n_i)
12	1
15	4

	STAT X	Freq
1	12	1
2	15	4

Enregistrer chaque donnée en appuyant sur : = ou EXE

Finalement, pour sortir, appuyer sur AC AC



Note (x_i)	Effectif (n_i)
12	1
15	4

→

	STAT X	Freq
1	12	1
2	15	4

* Pour déterminer l'effectif total : STAT-Var-n
☞ On trouve : **N = 5**

SHIFT STAT 1 5 **N** 1

* Pour déterminer la moyenne : STAT-Var-$\bar{x}$
☞ On trouve la note moyenne : $\bar{x} = 14{,}4$

SHIFT STAT 1 5 $\bar{x}$ 2

* Pour déterminer l'écart type : STAT-Var-xσn
☞ On trouve l'écart type : $\sigma = 1{,}2$

SHIFT STAT 1 5 σ 3

* Pour déterminer $\Sigma n_i x_i$: STAT-Sum-Σx
☞ On trouve : $\Sigma n_i x_i = 72$

SHIFT STAT 1 4 2

* Pour déterminer $\Sigma n_i x_i^2$: STAT-Sum-Σx²
☞ On trouve : $\Sigma n_i x_i^2 = 1044$

SHIFT STAT 1 4 1

1.3 Statistique descriptive bivariée

L'objectif de cette partie est d'étudier sur une même population de n individus, deux caractères différents X et Y et de rechercher s'il existe un lien entre ces deux variables. Chacune des deux variables peut être, soit quantitative, soit qualitative. La série statistique est alors une suite de n couples des valeurs prises par les deux variables sur chaque individu: $(x_1, y_1), ..., (x_n, y_n)$.
L'effectif associe à l'observation (x_i, y_j) est noté n_{ij} et sa fréquence $f_{ij} = n_{ij}/n$.

1.3.1 Deux variables qualitatives

•Tableau de contingence des effectifs
On s'intéresse à une éventuelle relation entre la variable $X=$ (le sexe) de $n = 200$ personnes et la variable $Y =$ (la couleur des yeux).

X/Y	Bleu	Vert	Marron	Total
Homme	$n_{11} = 10$	$n_{12} = 50$	$n_{13} = 20$	$n_{1\bullet} = 80$
Femme	$n_{21} = 20$	$n_{22} = 60$	$n_{23} = 40$	$n_{2\bullet} = 120$
Total	$n_{\bullet 1} = 30$	$n_{\bullet 2} = 110$	$n_{\bullet 3} = 60$	$n = 200$

Les nombres $n_{1\bullet}, n_{2\bullet}$ et $n_{\bullet 1}, n_{\bullet 2}, n_{\bullet 3}$ sont appelés effectifs marginaux.
Par exemple la valeur $n_{22} = 60$ exprime que 60 femmes ont une couleur verte des yeux et on a:

$$\begin{cases} n_{11} + n_{12} + n_{13} = n_{1\bullet}, \\ n_{21} + n_{22} + n_{23} = n_{2\bullet}, \\ n_{11} + n_{21} = n_{\bullet 1}, \\ n_{12} + n_{22} = n_{\bullet 2}, \\ n_{13} + n_{23} = n_{\bullet 3}, \\ n_{11} + n_{12} + n_{13} + n_{21} + n_{22} + n_{23} = n. \end{cases}$$

•Tableau de contingence des fréquences

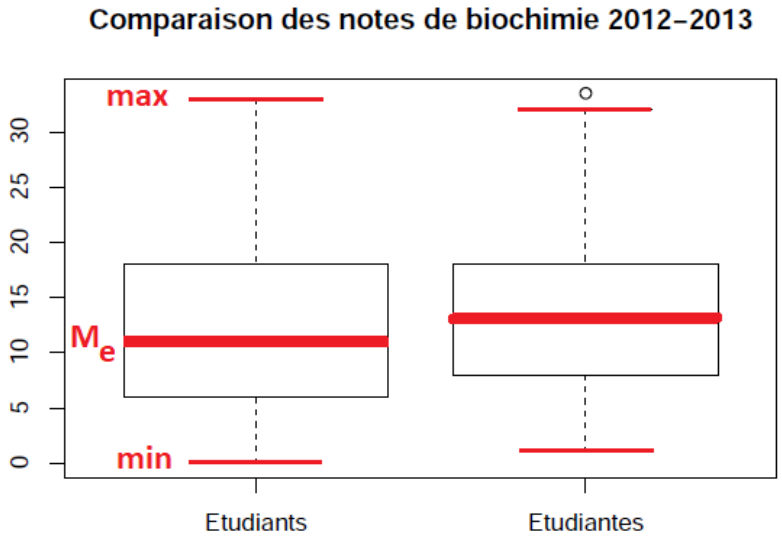
$$\begin{cases} f_{ij} = \frac{n_{ij}}{n}, f_{i\bullet} = \frac{n_{i\bullet}}{n}, f_{\bullet j} = \frac{n_{\bullet j}}{n} \\ f_{11} + f_{12} + f_{13} = f_{1\bullet}, \\ f_{21} + f_{22} + f_{23} = f_{2\bullet}, \\ f_{11} + f_{21} = f_{\bullet 1}, \\ f_{12} + f_{22} = f_{\bullet 2}, \\ f_{13} + f_{23} = f_{\bullet 3}, \\ f_{11} + f_{12} + f_{13} + f_{21} + f_{22} + f_{23} = 1. \end{cases}$$

Les nombres $f_{1\bullet}, f_{2\bullet}$ et $f_{\bullet 1}, f_{\bullet 2}, f_{\bullet 3}$ sont appelées fréquences marginales.

X/Y	Bleu	Vert	Marron	Total
Homme	$f_{11} = 0.05$	$f_{12} = 0.25$	$f_{13} = 0.10$	$f_{1\bullet} = 0.40$
Femme	$f_{21} = 0.10$	$f_{22} = 0.30$	$f_{23} = 0.20$	$f_{2\bullet} = 0.60$
Total	$f_{\bullet 1} = 0.15$	$f_{\bullet 2} = 0.55$	$f_{\bullet 3} = 0.30$	1

1.3.2 Une variable quantitative et une variable qualitative

• Diagramme en boîtes à moustaches
La boîte, (verticale ou bien horizontale), est la partie du graphique comprise entre les premier et troisième quartiles, (ces quartiles sépare la population en quatre parties égaux en effectifs). La médiane est située à l'intérieur de la boîte et représentée par un trait horizontal. Dans les parties basse et haute du graphique figurent les moustaches, joignant le minimum au premier quartile et le troisième quartile au maximum.
Exemple:
Soient X= notes des étudiants (quantitative) et Y= sexe (qualitative)



1.3.3 Deux variables quantitatives

On considère une population sur laquelle on étudie deux variables quantitatives X et Y. On veut savoir si les deux variables sont liés par une liaison linéaire du type $Y = a + bX$, i.e., que l'on peut prévoir les valeurs de Y à partir des valeurs de X. Précisons dès maintenant que l'existence d'une telle liaison entre les deux variables X et Y ne signifie pas obligatoirement un lien de cause à effet entre elles.

Exemple:
Neuf étudiants émettent un avis pédagogique vis-à-vis d'un professeur selon une échelle d'appréciation de 1 à 20. On relève par ailleurs la note obtenue par ces étudiants l'année précédente auprès du professeur.

Y= avis	5	7	16	6	12	14	10	9	8
X= résultat	8	11	10	13	9	17	7	15	16

Covariance
La covariance est définie par:

$$\sigma_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{x}\bar{y}.$$

Corrélation
Le coefficient de corrélation est définie par:

$$r := r_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}.$$

Le coefficient de corrélation mesure la dépendance linéaire entre les variables X et Y:
- Si le coefficient de corrélation est positif, les points du nuage sont alignés le long d'une droite croissante. Dans ce cas X et Y évoluent dans le même sens.
- Si le coefficient de corrélation est négatif, les points sont alignés le long d'une droite décroissante. Dans ce cas X et Y évoluent dans des sens opposés.
- La corrélation est parfaite si $|r| = 1$. X et Y sont dites: fortement corrélées.
- La corrélation est très forte si $|r| > 0.8$.
- La corrélation est forte si $|r|$ se situe entre 0.5 et 0.8.
- La corrélation est d'intensité moyenne : si $|r|$ se situe entre 0.2 et 0.5.
- La corrélation est faible si $|r|$ se situe entre 0 et 0,2.
- La corrélation est nulle si $r = 0$.

Droite de régression linéaire et Prédiction
La droite de régression linéaire est la droite qui ajuste au mieux un nuage de points au sens des moindres carrés. On considère que la variable X est explicative et que la variable Y est dépendante. L'équation de la droite de régression de Y en X est:

$$y = \hat{a} + \hat{b}x,$$

avec

$$\hat{b} = \frac{\sigma_{XY}}{\sigma_X^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x} \quad \text{(la droite de régression passe par le point } (\bar{x}, \bar{y})).$$

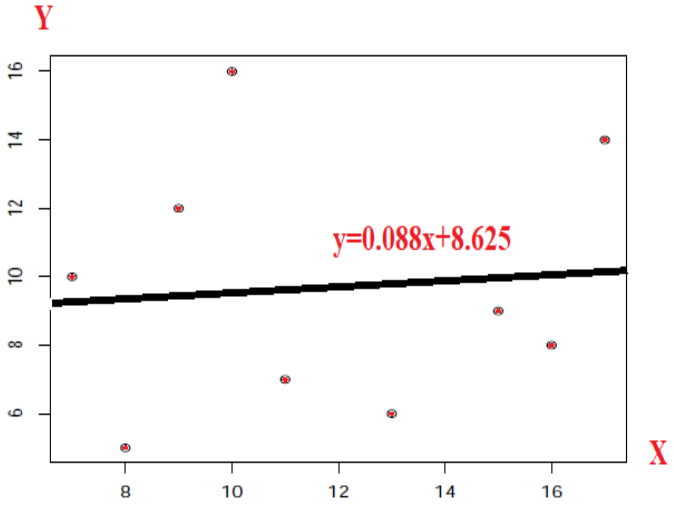
Dans notre exemple, on a:

$$\begin{cases} \bar{x} = 106/9 = 11.78 \\ \bar{y} = 87/9 = 9.667 \\ \sigma_X^2 = 1354/9 - 11.78^2 = 11.73 \\ \sigma_Y^2 = 951/9 - 9.667^2 = 12.22 \\ \sigma_{XY} = 1034/9 - 9.667 \times 11.78 = 1.037 \\ r_{XY} = \frac{1.037}{\sqrt{11.73}\times\sqrt{12.22}} = 0.087 \end{cases}$$

Finalement l'équation de la droite de régression de Y en X est:

$$y = 0.088x + 8.625.$$

FIGURE 1.5 – Droite de régression de Y en X



Prédiction
Dans notre exemple si on veut prédire, sur la base de notre modèle, l'avis pour un étudiant ayant obtenu $x = 12/20$, alors la valeur ajustée est:

$$y = 0.088 \times 12 + 8.625 = 9.681.$$

Résidus ou erreurs de prédiction
Les résidus de la régression sont définis par:

$$e_i = y_i - (\hat{a} + \hat{b}x_i) = y_i - y_i^*.$$

Le résidu e_i est l'erreur que l'on commet en utilisant la droite de régression pour prédire y_i à partir de x_i. Les résidus sont les différences entre les valeurs observées y_i et les valeurs ajustées y_i^* de la variable dépendante.
Par exemple pour la valeur $x_3 = 12$, on donne $y_3 = 10$ et on a $y_3^* = 0.088 \times 12 + 8.625 = 9.681$, donc $e_3 = y_3 - y_3^* = 0.319$.

Moyenne résiduelle

$$\bar{e} = \frac{1}{n}\sum_{i=1}^{n} e_i = 0.$$

Variance résiduelle
La variance résiduelle est la variance des résidus:

$$\sigma_e^2 = \frac{1}{n}\sum_{i=1}^{n} e_i^2.$$

La variance résiduelle peut également s'écrire:

$$\sigma_e^2 = \sigma_y^2 \times (1 - r_{XY}^2).$$

Dans notre exemple on a:

$$\sigma_e^2 = 12.22 \times (1 - 0.087^2) = 12.127.$$

Le coefficient de détermination
On le noté R^2. C'est le carré du coefficient de corrélation: $R^2 = r_{XY}^2$. Il représente la proportion de variance expliquée par le modèle.
Dans notre modèle, on a $R^2 = 0.087^2 = 0.008$. (0.8% est très faible donc on a un mauvais ajustement).

1.3.4 Utilisation d'une calculatrice de type Casio

Y= pression	1003	1005	1010	1011	1014
X= température	10	15	20	25	30



On efface les mémoires statistiques:

SECONDE MODE CLR 1 EXE

SHIFT MODE CLR 3 =

MODE CLR REG Lin

mode statistique 3 1

Exemple: Y=a+bX

Y	1003	1005	1010	1011	1014
X	10	15	20	25	30

10 , 1003 M+ = ou EXE

15 , 1005 M+ = ou EXE etc...



Y	1003	1005	1010	1011	1014
X	10	15	20	25	30

10 , 1003 M+ = ou EXE

15 , 1005 M+ = ou EXE etc...

la moyenne et l'écart type de X: SHIFT SECONDE S-VAR 2 $\bar{x}$ 1 $x\sigma n$ 2 = EXE

la moyenne et l'écart type de Y: SECONDE S-VAR 2 $\bar{y}$ 1 $y\sigma n$ 2 = EXE

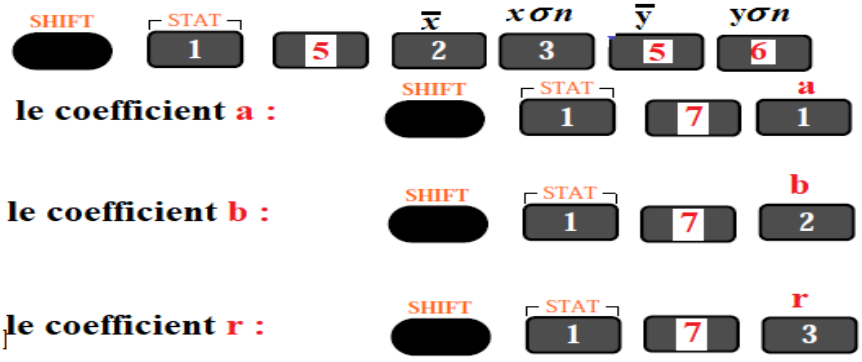
les coefficient a, b et r : SECONDE S-VAR 2 a 1 b 2 r 3 = EXE



Y	1003	1005	1010	1011	1014
X	10	15	20	25	30

	STAT X	Y	Freq
1	10	1003	1
2	15	1005	1

Enregistrer les données En appuyant sur : ou EXE



1.4 Exercices

NB: Le tableau statistique contient: modalités, effectifs, fréquences, pourcentages, effectifs cumulés, fréquences cumulées et pourcentages cumulés.

Exercice 1:
On donne les couleurs de $n = 15$ plantes.

V V R N R R V R R R J N N N N

1. De quel type est la variable couleur?
2. Construire le tableau statistique et en déduire le mode.
3. Construire le diagramme en secteurs.

Exercice 2:
Trente éprouvettes d'acier spécial sont soumises à des essais de résistance. Pour chacune, on note le nombre de chocs nécessaires pour obtenir la rupture. Les résultats obtenus sont les suivants :

2 2 3 1 2 1 4 2 3 2
3 2 3 3 4 1 1 4 2 3
2 3 2 2 3 4 3 2 3 2

1. De quel type est cette variable?
2. Construire le tableau statistique et en déduire le mode.
3. Construire le diagramme en bâtonnets des effectifs.
4. Déterminer la médiane, la moyenne, la variance et l'écart type de cette variable.
5. Déterminer la fonction de répartition et tracer sa courbe.

Exercice 3:
On pèse les $n = 50$ élèves d'une classe et nous obtenons les résultats résumés dans le tableau suivant:

43 43 43 47 48 48 48 48 49 49
49 50 50 51 51 52 53 53 53 54
54 56 56 56 57 59 59 59 62 62
63 63 65 65 67 67 68 70 70 70
72 72 73 77 77 81 83 86 92 93

1. De quel type est la variable poids?
2. Construire le tableau statistique en adoptant quatres classes seulement.
4. Déterminer la fonction de répartition et tracer sa courbe.
5. Déterminer la médiane directement et par interpolation linéaire.
6. Déterminer la classe modale et les centres des classes.
7. En déduire la moyenne, la variance et l'écart type de la variable poids.

Exercice 4:
Considérons un échantillon de $n = 10$ fonctionnaires (ayant entre 40 et 50 ans) d'un ministère. Soit X le nombre d'années de service et Y le nombre de jours d'absence pour raison de maladie (au cours de l'année précédente) déterminé pour chaque personne appartenant à cet échantillon.

x_i	2	14	16	8	13	20	24	7	5	11
y_i	3	13	17	12	10	8	20	7	2	8

1. Déterminer les moyennes de X et Y et la covariance entre X et Y.
2. Déterminer le coefficient de corrélation entre les variables X et Y. Donner une interprétation.
3. Déterminer la droite de régression linéaire Y en fonction de X.
4. Tracer le nuage de points (X, Y).
5. Tracer la droite de régression linéaire de Y en X.
6. vérifier que la droite de régression passe par le point $(\bar{x}, \bar{y})$.
7. Établir, sur la base de ce modèle, le nombre de jours d'absence pour un fonctionnaire ayant 22 ans de service.
8. Déterminer la variance résiduelle et le coefficient de détermination. Interpréter.

Exercice 5:
On étudie un échantillon de taille $n = 100$ sur lequel ont été mesurés deux caractères X et Y. On a observé les résultats suivants:

$$\sum_{i=1}^{100} x_i = 800 \qquad \sum_{i=1}^{100} y_i = 1200 \qquad \sum_{i=1}^{100} x_i^2 = 7200$$

$$\sum_{i=1}^{100} y_i^2 = 16000 \qquad \sum_{i=1}^{100} x_i y_i = 10200$$

1. Déterminer les moyennes, les variances et la covariance de X et Y.
2. En déduire le coefficient de corrélation entre X et Y. Interpréter.
3. Déterminer la droite de régression linéaire de Y en X.
4. Déterminer la variance résiduelle et le coefficient de détermination. Interpréter.
5. Déterminer la droite de régression linéaire de X en Y.

Chapitre 2

Notion de probabilités et variables aléatoires

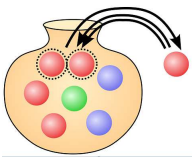
L'objectif ici de proposer un modèle mathématique permettant de décrire une situation aléatoire qui est définie à l'aide du langage des événements. La notion de probabilité permet de quantifier la chance qu'ont les événements d'être réalisés ou non.

2.1 Vocabulaires

- **Expérience aléatoire:** on ne peut pas prédire a priori son résultat.
- **Réalisation:** un résultat possible de l'expérience aléatoire.
- **Espace fondamental Ω:** l'ensemble de tous les résultats possibles.
- **Évènement:** sous ensemble de Ω.

Exemples:

1) on tire simultanément deux boules dans une urne qui contient quatres boules rouges, deux boules bleues et une boule verte:



$$\Omega = \{(R_1, R_2), (R_1, R_3), (R_2, R_3), (R_1, V_1), ...\} \Longrightarrow \text{card } (\Omega) = C_7^2 = 21.$$

2) on lance une pièce de monnaie deux fois:



$$\Omega = \{(P, P), (F, P), (P, F), (F, F)\} \Longrightarrow \text{card } (\Omega) = 4.$$

L'évènement A: (obtenir pile une seule fois) est $A = \{(F, P), (P, F)\}$.

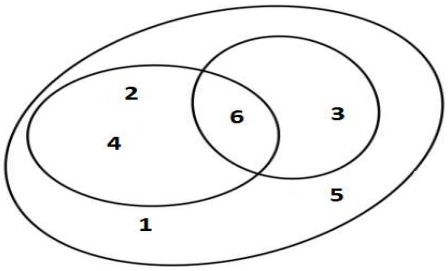
3) on lance un dé une seule fois:



$$\Omega = \{1, ..., 6\} \Longrightarrow \text{card } (\Omega) = 6.$$

L'évènement B: (obtenir un nombre pair) est $A = \{2, 4, 6\}$.

- **L'union:** $A \cup B$ est réalisé dés que A ou B est réalisé.
- **L'intersection:** $A \cap B$ est réalisé dés que A et B sont réalisés conjointement.
  Dans un lancer de dé, si l'évènement A est (obtenir un nombre pair) et l'évènement B est (obtenir un multiple de 3), alors $A = \{2, 4, 6\}$, $B = \{3, 6\}$ et $A \cap B = \{6\}$.



- **Le complémentaire $\bar{A}$:** c'est l'évènement $\Omega \backslash A$.
  Dans l'exemple du lancer de dé, pour $A = \{2, 4, 6\}$, on a $\bar{A} = \{1, 3, 5\}$= (obtenir un nombre impair).

2.2 Notion de probabilités

Définition
Une probabilité P sur un ensemble fini $\Omega = \{\omega_1, ..., \omega_n\}$ est une pondération $p_1, p_2, ..., p_n$ des éléments de cet ensemble telle que:

- Pour tout $k \in [1 : n]$, $p_k \geq 0$.
- $\sum_{k=1}^{n} p_k = 1$.

On attribue à toute éventualité ω_i la probabilité $p_i = P(\{\omega_i\})$ et on attribue à tout évènement $A \subset \Omega$ la probabilité:

$$P(A) = \sum_{k, \omega_k \in A} p_k.$$

Exemple:
Dans un lancer d'un dé équilibré, on a $\Omega = \{1, ..., 6\}$ et $p_k = P(\{k\}) = 1/6$, pour tout $k \in [1 : 6]$. Si l'évènement A est (obtenir un nombre pair strictement supérieur à 3) alors $A = \{4, 6\}$ et $P(A) = P(\{4\}) + P(\{6\}) = 1/6 + 1/6 = 1/3$.

Remarque
Dans le cas où les symétries font que tous les résultats possibles $\omega_1, ..., \omega_n$ sont équiprobables, on a:

$$P(A) = \frac{card(A)}{card(\Omega)}.$$

Dans l'exemple précédent, on a

$$P(A) = \frac{card(A)}{card(\Omega)} = \frac{2}{6} = \frac{1}{3}.$$

Propriétés

1. Soit A et B deux événements, alors

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

2. $0 \leq P(A) \leq 1$.
3. $P(\bar{A}) = 1 - P(A)$.
4. $P(\Omega) = 1$, (événement certain) et $P(\emptyset) = 0$, (événement impossible).

Probabilité conditionnelle et indépendance
• Soient deux événements A et B, si $P(B) > 0$, alors

$$P_B(A) = \frac{P(A \cap B)}{P(B)}.$$

• On dit que deux événements A et B sont indépendants si $P(A \cap B) = P(A).P(A)$ ou encore si $P_B(A) = P(A)$ ou $P_A(B) = P(B)$.

Exemple:
Nous jetons un dé équilibré et nous considérons les deux événements: $A =$ (le résultat est impair) et $B =$ (le résultat est ≤ 4).
$A = \{1, 3, 5\} \Rightarrow P(A) = \frac{1}{2}$
$B = \{1, 2, 3, 4\} \Rightarrow P(B) = \frac{2}{3}$
$A \cap B = \{1, 3\} \Rightarrow P(A \cap B) = \frac{1}{3}$
On a $P(A \cap B) = \frac{1}{3} = P(A).P(B)$ donc A et B sont indépendants.

2.3 Notion de variables aléatoires

La notion de variable aléatoire formalise l'association d'une valeur au résultat d'une expérience aléatoire. Une variable aléatoire X est une application mesurable de l'ensemble fondamental Ω dans $\mathbb{R}$.

2.3.1 Variables aléatoires discrètes

Définition

• Une variable aléatoire discrète prend uniquement des valeurs dans un sous ensemble discret $E = \{x_1, ..., x_n, ...\}$.

• Une distribution de probabilité p_X est une fonction qui associe à chaque valeur x_i la probabilité: $p_i = p_X(x_i) = P(X = x_i)$.

Exemple:

On considère une expérience aléatoire consistant à lancer deux pièces de monnaie. L'ensemble des résultats possibles est: $\Omega = \{(P, P), (F, P), (P, F), (F, F)\}$.

Considérons la variable aléatoire X représentant le nombre de faces obtenues. Les valeurs prises par X sont 0,1,2.

$p_1 = P(X = 0) = 1/4$, $p_2 = P(X = 1) = 1/2$ et $p_3 = P(X = 2) = 1/4$.

x_i	0	1	2
$p_i = P(X = x_i)$	1/4	1/2	1/4

Espérance mathématique

$$E(X) = 0 \times 1/4 + 1 \times 1/2 + 2 \times 1/4 = 1.$$

Variance

$$V(X) = E(X - E(X))^2 = (0-1)^2 \times 1/4 + (1-1)^2 \times 1/2 + (2-1)^2 \times 1/4 = 1/2.$$

Écart type

$$\sigma(X) = \sqrt{V(X)} = \sqrt{1/2} = 0.70.$$

Quelques lois discrètes usuelles

Nom	Loi	$\mathbb{E}(X)$	$\mathrm{Var}(X)$
Bernoulli $\mathcal{B}(p)$	$\mathbb{P}(X = 1) = p = 1 - \mathbb{P}(X = 0)$	p	$p(1-p)$
binomiale $\mathcal{B}(n, p)$	$\forall 0 \leq k \leq n,\ \mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$
Poisson $\mathcal{P}(\lambda)$	$\forall n \in \mathbb{N},\ \mathbb{P}(X = n) = \exp(-\lambda)\frac{\lambda^n}{n!}$	λ	λ
géométrique $\mathcal{G}eo(p)$	$\forall n \in \mathbb{N}^*,\ \mathbb{P}(X = n) = p(1-p)^{n-1}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$

2.3.2 Variables aléatoires continues

Définition

• Une variable aléatoire X continue prend des valeurs dans un intervalle de $\mathbb{R}$.

• La fonction de répartition de X est définie par:

$$\Phi(x) = P(X \leq x).$$

• X possède une densité notée $f(x)$ telles que:

$$\Phi(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt \quad \text{ou encore} \quad F'(x) = f(x).$$

Espérance mathématique

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx.$$

Variance

$$V(X) = E(X - E(X))^2 = \int_{-\infty}^{+\infty} (x - E(X))^2 f(x)dx.$$

Quelques lois continues usuelles

Nom	Densité	$\mathbb{E}(X)$	$\mathrm{Var}(X)$
uniforme $\mathcal{U}[a,b]$	$\frac{1}{b-a}\ 1_{[a,b]}(x)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
exponentielle $\mathcal{E}(\lambda)$	$\lambda \exp(-\lambda x) 1_{\{x\geq 0\}}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
normale $\mathcal{N}_1(m,\sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}}\ \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$	m	σ^2
Cauchy $\mathcal{C}(a)$	$\frac{a}{\pi}\ \frac{1}{x^2+a^2}$	non intég	-

Par exemple: si X suit la loi exponentielle $\mathcal{E}(\lambda)$, alors quand $x > 0$, sa fonction de répartition vaut:

$$\Phi(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt = \int_{0}^{x} \lambda \exp(-\lambda t)dt = \Big[-\exp(-\lambda t)\Big]_0^x = 1 - e^{-\lambda x}.$$

On calcule la moyenne par une intégration par partie:

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_{0}^{+\infty} x\lambda \exp(-\lambda x)dx = \Big[-\frac{1+x\lambda}{\lambda} \exp(-\lambda x)\Big]_0^{+\infty} = \frac{1}{\lambda}.$$

• **Loi normale $\mathcal{N}(0,1)$ de moyenne 0 et de variance 1**

La table statistique ci-dessus nous donne pour chaque $z > 0$ la valeur:

$$\Phi(z) = P(Z \leq z) = P(Z < z).$$

Pour $z < 0$, on a $\Phi(-z) = 1 - \Phi(z)$.
On a aussi $P(Z \geq z) = P(Z > z) = 1 - \Phi(z)$,
et $P(a < X < b) = \Phi(b) - \Phi(a)$.

Exemples:

$P(Z \leq 0.25) = \Phi(0.25) = \Phi(0.20 + 0.05) = 0.5987$. Cette dernière valeur est l'intersection de la ligne 0.2 et la colonne 0.05 dans la table statistique.
$P(Z > 0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013$.
$\Phi(-0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013$.
$P(|Z| < 0.25) = P(-0.25 < Z < 0.25) = \Phi(0.25) - \Phi(-0.25)$
$= \Phi(0.25) - (1 - \Phi(0.25)) = 2\Phi(0.25) - 1 = 0.1974$.

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\, dx \quad \text{pour la loi normale } \mathcal{N}(0,1).$$

Z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Loi normale $\mathcal{N}(\mu, \sigma^2)$ de moyenne $\mu > 0$ et de variance σ^2

Si X suit la loi normale $\mathcal{N}(\mu, \sigma^2)$ alors Z suit la loi normale $\mathcal{N}(0,1)$ avec $Z = \dfrac{X - \mu}{\sigma}$.

Exemple:

Si $X \sim \mathcal{N}(72, 64)$ alors la moyenne est $\mu = 72$ et l'écart type $\sigma = 8$. Dans ce cas la variable aléatoire:

$$Z = \frac{X - 72}{8} \sim \mathcal{N}(0,1),$$

par suite

$$P(X > 80) = 1 - P(X \leq 80) = 1 - P\left(\frac{X - 72}{8} \leq \frac{80 - 72}{8}\right)$$
$$= 1 - P(Z \leq 1) = 1 - \Phi(1) = 1 - 0.8413 = 0.1587.$$

2.4 Exercices

Exercice 1:
On tire simultanément deux boules dans une urne qui contient: trois boules vertes, deux boules noires et une boule rouge. Soit X la variable aléatoire qui correspond au nombre de boules vertes tirées.

1. Déterminer la loi de X.
2. En déduire $E(X)$, $V(X)$ et $\sigma(X)$.
3. Calculer $P(X \leq 1)$ et $P(X > 1)$.

Exercice 2:
On lance une pièce de monnaie équilibré trois fois successive. Soit X la variable aléatoire qui correspond au nombre de faces obtenues.

1. Déterminer la loi de X.
2. En déduire $E(X)$, $V(X)$ et $\sigma(X)$.
3. Calculer $P(X \leq 2)$ et $P(X > 2)$.

Exercice 3:
On lance deux trièdres équilibrés numérotés 0, 1, 2, 3. Soit X la variable aléatoire qui correspond à la somme des deux chiffres obtenus.

1. Déterminer la loi de X.
2. En déduire $E(X)$, $V(X)$ et $\sigma(X)$.

Exercice 4:
Soit X une variable aléatoire qui suit la loi exponentielle de paramètre 1.

1. Vérifier que $\int_{-\infty}^{+\infty} f(x)dx = 1$.
2. Calculer $E(X)$, $V(X)$ et $\sigma(X)$.
3. Calculer $P(X \leq 1)$ et $P(X > 1)$.

Exercice 5:
Soit $Z \sim \mathcal{N}(0, 1)$. Déterminer:

1. $P(Z \leq 1.23)$.
2. $P(Z \leq -1.23)$.
3. $P(Z > 1.23)$.
4. $P(|Z| < 1.23)$.
5. $P(Z \in [-0.88; 0.36])$.
6. $P(Z \in [0.45; 1.23])$.

Exercice 6:
Soit $Z \sim \mathcal{N}(0,1)$. Déterminer les valeurs de z telles que:

1. $P(Z \leq z) = 0.975$.
2. $P(Z \leq -z) = 0.3438$.
3. $P(Z \leq z) = 0.9332$.
4. $P(Z > z) = 0.0125$.
5. $P(|Z| < z) = 0.3438$.
6. $P(Z \in [z; 2.01]) = 0.3438$.

Exercice 7:
Soit une variable aléatoire $X \sim \mathcal{N}(53, \sigma^2 = 100)$ représentant le résultat d'un examen pour un étudiant d'une section. Déterminer la probabilité pour que le résultat soit compris entre 33.4 et 72.6.

Exercice 8:
Soit une variable aléatoire $X \sim \mathcal{N}(50, \sigma^2 = 100)$. Déterminer z tel que $P(X \leq z) = 0.67$.

Exercice 9:
Sur une route principale où la vitesse est limitée à 80 km/h, un radar a mesuré la vitesse de toutes les automobiles pendant une journée. En supposant que les vitesses recueillies soient distribuées normalement avec une moyenne de 72 km/h et un écart-type de 8 km/h, quelle est approximativement la proportion d'automobiles ayant commis un excès de vitesse?

Exercice 10:
On suppose que la glycémie est distribuée normalement dans la population, avec une moyenne de $1g/l$ et un écart type $0.03g/l$. On mesure la glycémie chez un individu. Calculer la probabilité pour que sa glycémie soit:

1. inférieure à 1.06.
2. supérieure 0.9985.

Chapitre 3

Échantillonnage et estimation

3.1 Échantillonnage

3.1.1 Introduction

Une université reçoit 7000 applications par année provenant d'éventuels étudiants. Le formulaire de demande d'admission inclut le score d'un test d'aptitude (SAT) ainsi que l'information sur le lieu de résidence de l'étudiant. Le directeur des admissions aimerait avoir une idée sur:

- le score moyen SAT des postulants,
- la proportion des postulants qui sont résidents de la province?

Il y a deux façons d'obtenir cette information:

1)- Effectuer un recensement des 7000 postulants

- Scores SAT: $x_1, ..., x_{7000}$
- Moyenne de la population

$$\mu = \frac{1}{7000} \sum_{i=1}^{7000} x_i = 990$$

- Variance de la population

$$\sigma^2 = \frac{1}{7000} \sum_{i=1}^{7000} (x_i - \mu)^2 = 6400$$

- Proportion des résidants de la population

$$p = \frac{5040}{7000} = 0.72$$

2)- Prendre un échantillon de taille $n = 50$ postulants est faire des estimations ponctuelles

No	**Postulant**	**SAT**	**Résidant**
1	Mohammed	1025	Oui
2	Rachid	950	Oui
3	Hassan	1090	Non
.	.....	.....	.....
.	.....	.....	.....
50	Karim	1279	oui
	Total	**49850**	**34 oui**

Dans ce cas on prend:

- $\bar{x}$ comme estimation de la moyenne μ :

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{50}\sum_{i=1}^{50} x_i = 997 \simeq 990 = \mu$$

- s^2 comme estimation de la variance σ^2 :

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{50-1}\sum_{i=1}^{50}(x_i - \bar{x})^2 = 6301 \simeq 6400 = \sigma^2$$

- $\bar{p}$ comme estimation de la proportion p :

$$\bar{p} = \frac{n_{oui}}{n} = \frac{34}{50} = 0.68 \simeq 0.72 = p$$

Les erreurs d'échantillonnage sont:

- $|\bar{x} - \mu|$ pour la moyenne échantillonnale.
- $|s^2 - \sigma^2|$ pour la variance échantillonnale.
- $|\bar{p} - p|$ pour la proportion échantillonnale.

Raisons pour faire un échantillonnage au lieu d'un recensement

- Lorsque la population est très grande.
- Par souci d'économie.
- Obtenir de l'information rapidement.

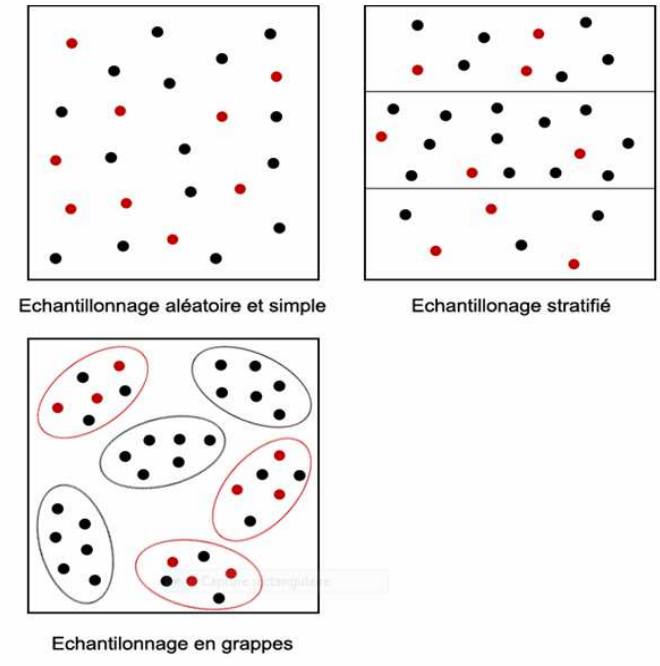
Méthodes d'échantillonnage

L'échantillonnage aléatoire et simple: le choix se fait parmi tous les individus de la population (au sens statistique), qui ne forme qu'un grand ensemble.

L'échantillonnage stratifié: si la population est très hétérogène, elle peut être divisée en sous-ensembles exclusifs (ou strates). Au sein de ces strates l'échantillonnage est ensuite aléatoire et simple. Les strates sont identifiées dans l'analyse statistique comme les niveaux d'un facteur fixe.

L'échantillonnage en grappes: si les strates sont très nombreuses, on en choisit certaines au hasard (les grappes). Au sein de ces grappes l'échantillonnage est ensuite aléatoire et simple. Les grappes sont identifiées dans l'analyse statistique comme les niveaux d'un facteur aléatoire.

L'échantillonnage par degrés: il est une généralisation de l'échantillonnage en grappes (qui est en fait un échantillonnage du premier degré). Au sein de la population on choisit des grappes " primaires ", puis à l'intérieur de celles-ci des grappes " secondaires " (toujours au hasard), et ainsi du suite. . . Au dernier niveau l'échantillonnage est aléatoire et simple.



3.1.2 Distribution d'échantillonnage de la moyenne

Théorème centrale limite 1

Lorsque la variance σ^2 de la population est **connue** et que l'échantillon prélevé est grand ($n \geq 30$), alors la moyenne échantillonnale vérifie:

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim \mathcal{N}(\mu, \frac{\sigma^2}{n}), \quad i.e., \quad Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1).$$

Remarques

- Le théorème précédant est vrai aussi lorsque la variance est **connue**, l'échantillon est petit et que la variable aléatoire X suit une loi normale $\mathcal{N}(\mu, \sigma^2)$.

- Lorsque la variance σ^2 de la population est **inconnue** et que l'échantillon prélevé est grand ($n \geq 30$), alors

$$\bar{X} \sim \mathcal{N}(\mu, \frac{s^2}{n}), \quad i.e., \quad \frac{\bar{X}-\mu}{\frac{s}{\sqrt{n}}} \sim \mathcal{N}(0,1).$$

Exemple:
Les statistiques des notes obtenues en mathématiques au BAC STI en France pour l'année 2006 sont: Moyenne nationale =10.44, Écart-type=1.46. Une classe de BTS comporte 35 élèves en 2006/2007 issus d'un BAC STI en 2006. Calculer la probabilité que la moyenne de cette classe soit supérieure à 10.
Corrigé:

$$n = 35 > 30 \Rightarrow \bar{X} \sim \mathcal{N}(10.44, \frac{1.46^2}{n}) \Rightarrow Z = \frac{\bar{X}-10.44}{\frac{1.46}{\sqrt{35}}} \sim \mathcal{N}(0,1).$$

$$P(\bar{X} > 10) = 1 - P(\bar{X} \leq 10) = 1 - P\Big(\frac{\bar{X}-10.44}{\frac{1.46}{\sqrt{35}}} \leq \frac{10-10.44}{\frac{1.46}{\sqrt{35}}}\Big)$$
$$= 1 - P(Z \leq -1.78) = 1 - \Phi(-1.78) = \Phi(1.78) = 0.9625.$$

Théorème centrale limite 2:
Si la variance de la population est **inconnue**, si la variable X suit une distribution normale $\mathcal{N}(\mu, \sigma^2)$, et si la taille de l'échantillon est petite ($n < 30$), alors

$$T = \frac{\bar{X}-\mu}{\frac{s}{\sqrt{n}}} \sim t(n-1) : \text{Loi de Student à n-1 degré de liberté ddl.}$$

La table suivante nous donne les valeurs t telles que: $P(T > t) = \alpha$. La colonne nous donne la probabilité α et la ligne nous le ddl $n-1$.

Table de la loi Student T : $P(T > t) = \alpha$

Degrés de liberté	Aire dans la queue supérieure de la distribution					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250

Pour n=7, on a : ddl=n-1=6. Alors : P(T>t)=0.05 nous donne t=1.943.

Exemple:
Pour estimer le montant hebdomadaire moyen dépensé par les familles de 4 personnes pour leur épicerie, on tire un échantillon aléatoire de 25 personnes. On suppose que les montants dépensés sont distribués normalement avec une moyenne 120 et une variance inconnue. Si la variance de l'échantillon de taille 25 est 36, calculer la probabilité que la moyenne de l'échantillon soit supérieure à 123.
Corrigé:
On a $n = 25 < 30$ et la variance de la population est inconnue, (on connaît la variance de l'échantillon $s^2 = 36$), donc

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{\bar{X} - 120}{\frac{6}{\sqrt{25}}} \sim t(25-1) = t(24).$$

$$P(\bar{X} > 123) = P\left(\frac{\bar{X}-120}{\frac{6}{\sqrt{25}}} \geq \frac{123-120}{\frac{6}{\sqrt{25}}}\right) = P(T > 2.5) \simeq P(T > 2.492) = 0.01.$$

	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.0010	0.0005
1	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	127.3	318.3	636.6
2	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	14.09	22.33	31.60
23	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.767
24	0.685	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.091	3.467	3.745
25	0.684	0.856	1.058	1.316	1.708	2.060	2.485	2.787	3.078	3.450	3.725

3.1.3 Distribution d'échantillonnage de la proportion

Si p est la proportion de la population, alors pour un échantillon de taille grande $n > 30$, la proportion échantillonnale vérifie:

$$\bar{p} \sim \mathcal{N}\Big(p, \frac{p(1-p)}{n}\Big) \quad i.e., \quad Z = \frac{\bar{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1).$$

Exemple:
$p = 0.8$ est la proportion de Canadiens satisfaits du libre échange. $n = 100$ personnes interrogées. Quelle est la probabilité que la proportion des personnes interrogées satisfaites du libre échange soit inférieure ou égale à 0.9?
Corrigé:

$$Z = \frac{\bar{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1) \Rightarrow P(\bar{p} \leq 0.9) = P\left(Z \leq \frac{0.9 - 0.8}{\sqrt{\frac{0.8(1-0.8)}{100}}}\right) = P(Z \leq 2.5) = 0.9938.$$

3.1.4 Distribution d'échantillonnage de la variance

Si σ^2 est la variance de la population et S^2 est la variance échantillonnale d'un échantillon de taille n. Alors $Y^2 = \frac{(n-1)S^2}{\sigma^2}$ suit la loi khi-deux à $\nu = n-1$ ddl de table statistique ci-dessus qui nous les valeurs de x tel que $P(Y^2 > x) = \alpha$.

Exemple:

Pour $\alpha = 0.05$, $n = 10$, on a $\nu = 10 - 1 = 9$ et $x = 16.9190$.

Table de la loi Khi-deux Y^2 : $P(Y^2 > x) = \alpha$

ν \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010	0,001
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349	10,8276
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103	13,8155
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902	26,1245
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660	27,8772
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093	29,5883

pour $\alpha = 0.05$ et $n = 10$, on a $\nu = 10 - 1 = 9$ et $x = 16.9190$.

3.2 Estimation

3.2.1 Estimation ponctuelle

Estimer un paramètre, par exemple: une moyenne, une variance, une proportion, etc..., c'est chercher une valeur approchée en se basant sur les résultats d'un échantillon. Lorsqu'un paramètre est estimé par un seul nombre déduit des résultats de l'échantillon, ce nombre est appelé une estimation ponctuelle du paramètre.

- $\bar{X}$ est un estimateur de la moyenne μ :

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

- S^2 est un estimateur de la variance σ^2 :

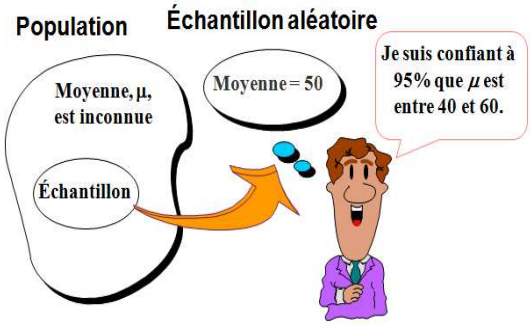
$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2.$$

- $\bar{p}$ est un estimateur de la proportion p.

3.2.2 Estimation par intervalle de confiance

Les estimations ponctuelles, bien qu'utiles, ne fournissent aucune information concernant la précision des estimations, c'est-à-dire qu'elles ne tiennent pas compte de l'erreur possible dans l'estimation due aux fluctuations d'échantillonnage. La théorie des intervalles de confiance (IC) consiste à construire, autour de l'estimation ponctuelle, un intervalle qui aura une grande probabilité $(1-\alpha)$ de contenir la vraie valeur du paramètre.

1) Estimation par IC de la moyenne μ de la population



• 1er **cas:** Lorsque la taille de l'échantillon est grande $(n \geq 30)$ et la variance de la population de X est **connue**, on obtient un intervalle de confiance pour μ au seuil de confiance $(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = [\bar{x} - z_\alpha \frac{\sigma}{\sqrt{n}}; \bar{x} + z_\alpha \frac{\sigma}{\sqrt{n}}] \quad i.e., \quad P\Big(\mu \in IC_{(1-\alpha)\%}\Big) = (1-\alpha).$$

$\Phi(z_\alpha) = 1 - \frac{\alpha}{2}$, où Φ est la fonction de répartition de la loi normale $\mathcal{N}(0,1)$.
Ceci est aussi vrai pour de petits échantillons lorsque la variable aléatoire X suit une loi normale et que la variance de X est connue.
Lorsque la taille de l'échantillon est grande $(n \geq 30)$ et la variance de la population de X est **inconnue**, on obtient un intervalle de confiance pour μ au seuil de confiance $(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = [\bar{x} - z_\alpha \frac{s}{\sqrt{n}}; \bar{x} + z_\alpha \frac{s}{\sqrt{n}}].$$

Exemple:
On a observé la taille de $n = 200$ hommes marocains adultes. Après calcul , on a obtenu une moyenne de $\bar{x} = 168$ cm. Si on suppose que la variance connue vaut $\sigma^2 = 1$. Donnez un intervalle de confiance à 95% de la vraie moyenne de la population.
Corrigé:
Puisque $\alpha = 0.05$ (5%), alors $\Phi(z_\alpha) = 1 - \frac{0.05}{2} = 0.975$, par suite $z_\alpha = 1.96$. Finalement $IC_{95\%} = [167.86; 168.14]$, i.e., $P(\mu \in [167.86; 168.14]) = 0.95$.

• 2me **cas:** Lorsque la taille de l'échantillon est petite $(n < 30)$ et X suit une loi normale de variance **inconnue**, on obtient un intervalle de confiance pour μ au seuil de confiance

$(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = [\bar{x} - t_\alpha \frac{s}{\sqrt{n}}; \bar{x} + t_\alpha \frac{s}{\sqrt{n}}]$$

t_α se déduit da la table student comme suit: $P(T > t_\alpha) = \frac{\alpha}{2}$.

Exemple:

Un reporter pour un journal étudiant est en train de rédiger un article sur le coût du logement près du campus. Un échantillon de 10 appartements (trois et demi) dans un rayon de 1 km de l'université a permis d'estimer le coût moyen du loyer mensuel à 350 par mois et un écart type de 30. Quel est l'intervalle de confiance de 95% pour la moyenne des loyers mensuels? Supposons que les loyers suivent une loi normale.

Corrigé:

pour un coefficient de confiance de $0,95$, on a $\alpha = 0,05$, et $\frac{\alpha}{2} = 0,025$. On a $n-1 = 10-1 = 9$ degrés de liberté, alors la table de la distribution Student nous donne $t_\alpha = 2,262$. Finalement $IC_{95\%} = [328.54; 371.46]$. i.e., nous sommes confiants à 95% que la moyenne des loyers mensuels (le vrai paramètre de la population μ), se trouve entre 328.54 et 371.46.

2) Détermination de la taille de l'échantillon:

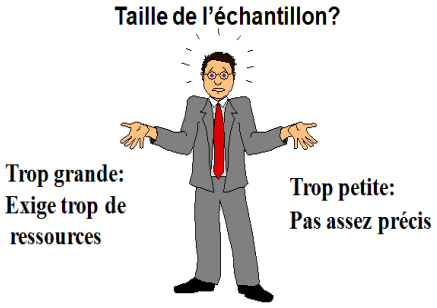
Quelle est la taille n de l'échantillon qui permettrait d'affirmer qu'en utilisant un estimateur ponctuel, l'erreur commise pour un coefficient de confiance $(1-\alpha)$ serait moindre que la marge d'erreur E?

Si par exemple on fixe:

$$E = z_\alpha \frac{\sigma}{\sqrt{n}},$$

l'erreur maximale commise pour un coefficient de confiance $(1-\alpha)$, alors la taille de l'échantillon sera:

$$n = \left[\frac{z_\alpha . \sigma}{E}\right]^2.$$



Exemple:

Si on fixe une marge d'erreur $E = 500$, alors pour un écart type de $\sigma = 5000$ et pour $z_\alpha = 1.96$, on trouve $n = 384$. i.e., on a besoin d'un échantillon de taille $n = 384$ pour arriver à une précision de ± 500 à un seuil de confiance de 95%.

3) Estimation par IC de la proportion p de la population
Soit $\Phi(z_\alpha) = 1 - \frac{\alpha}{2}$. Lorsque n est grand ($n \geq 30$) et si $\bar{p}$ est la proportion échantillonnale alors un intervalle de confiance pour la proportion p inconnue de la population au seuil de confiance $(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = \left[\bar{p} - z_\alpha \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}; \bar{p} + z_\alpha \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}\right].$$

Exemple:
SPI est une compagnie qui se spécialise dans les sondages politiques. À l'aide de sondages téléphoniques, les interviewers demandent aux citoyens pour qui ils voteraient si les élections avaient lieu aujourd'hui. Récemment, SPI a trouvé que 220 votants sur 500 voterait pour un candidat particulier. SPI veut estimer l'intervalle de confiance à 95% pour la proportion des votants qui sont en faveur de ce candidat.

Corrigé:
On a $n = 500$, $\bar{p} = 220/500 = 0.44$ et $z_\alpha = 1.96$ donc $IC_{95\%} = [0.3965; 0.4835]$, i.e., SPI est confiant à 95% que la proportion des votants qui favoriseront ce candidat est entre 0.3965 et 0.4835.

4) Estimation par IC de la variance σ^2 de la population
Soit n la taille de l'échantillon et s^2 la variance échantillonnale. Ici $Y^2 = \frac{(n-1)S^2}{\sigma^2}$ suit la loi de loi khi-deux à $n-1$ ddl. On cherche les deux nombres a et b tels que:

$$P(Y^2 \geq a) = \frac{\alpha}{2}, \quad P(Y^2 \geq b) = 1 - \frac{\alpha}{2}.$$

L'intervalle de confiance au seuil $(1-\alpha)$ pour la variance inconnue σ^2 de la population est de la forme:

$$IC_{(1-\alpha)\%} = \left[\frac{(n-1)s^2}{a}; \frac{(n-1)s^2}{b}\right].$$

Exemple:
Pour $n = 31$ $s^2 = 100$, on a le ddl $= 31 - 1 = 30$. $\alpha = 0.05$ donc $\frac{\alpha}{2} = 0.025$ donne $a = 46.98$ et $1 - \frac{\alpha}{2} = 0.975$ donne $b = 16.80$. Finalement $IC_{95\%} = [0.3965; 0.4835]$.

3.3 Exercices

Exercice 1 (Échantillonnage):
Pour estimer l'âge moyen d'une population de 4000 employés, un échantillon aléatoire de 40 employés est sélectionné. Quelle est la probabilité que l'âge moyen des employés de l'échantillon soit compris entre l'âge moyen de la population ± 2 si l'on sait que l'écart type de la population est de 8,2 ans?

Exercice 2 (Échantillonnage):
Une élection a eu lieu et un candidat a eu une proportion 40% des voix. On prélève un échantillon de 100 bulletins de vote. Quelle est la probabilité que, dans l'échantillon, le candidat ait entre 35% et 45% des voix?

Exercice 3 (Estimation):
Dans le cadre d'une étude sur la violence verbale au travail, on a interrogé au hasard 500 salariés de différents secteurs. 145 d'entre eux déclarent avoir déjà subi une violence verbale au travail.

1) Identifier la population, la variable et son type.
2) Donner une estimation ponctuelle de la proportion de salariés ayant déjà subi une violence verbale.
3) Donner une estimation de cette proportion par un intervalle de confiance à 90% et 99%.
4) Si avec les mêmes données on calculait un intervalle de confiance à 99%, serait-il plus grand ou plus petit que celui trouvé à la question précédente?

Exercice 4 (Estimation):
On admet que le taux de cholestérol chez une femme suit une loi normale. Sur un échantillon de 10 femmes, on a obtenu les taux de cholestérol (en g/l) suivants:

3	1.8	2.1	2.7	1.4	1.9	2.2	2.5	1.7	2

1)- Déterminer une estimation ponctuelle de la moyenne et de la variance du taux.
2)- Déterminer un intervalle de confiance pour la moyenne du taux au seuil 5%.

Exercice 5 (Estimation):
Une machine produit des pièces de type X. La masse, exprimée en (g), d'une pièce tiré au hasard dans la production, est distribuée selon une loi normale. On tire un échantillon de 17 pièces de masses suivantes:

250 254 254 253 256 250 257 251
253 255 250 255 252 261 252 251 255

1) Donner une estimation ponctuelle de la moyenne et la variance de production.

2) Déterminer une estimation par intervalle de confiance à 99% de la masse moyenne.

3) On suppose maintenant que la variance de la population est connue $\sigma^2 = 8.51$. Préciser la loi de la moyenne échantillonnale et déterminer la taille minimale donner a un échantillon pour obtenir un intervalle de confiance pour la moyenne au niveau 95% d'amplitude inférieure à 2. Conclure.

Exercice 6 (Estimation):
Dans la fabrication de comprimés effervescents, il est prévu que chaque comprimé doit contenir 1625 mg de bicarbonate de sodium. Afin de contrôler la fabrication de ces médicaments, on a prélevé un échantillon de 150 comprimés et on a mesuré la quantité de bicarbonate de sodium pour chacun d'eux:

Classes	$[1610; 1615[$	$[1615; 1620[$	$[1620; 1625[$	$[1625; 1630[$	$[1630; 1635[$
Effectifs	7	8	42	75	18

1) En convenant que les valeurs mesurés sont regroupées au centre de chaque classe, donner une estimation ponctuelle de la moyenne et la variance de la quantité de bicarbonate de sodium dans la population formée de l'ensemble de tous les comprimés fabriqués et supposée très grande.

2) Déterminer une estimation par intervalle de confiance à 95% de la quantité moyenne de bicarbonate de sodium dans la population.

Exercice 7 (Estimation):
On a mesuré le poids de raisin produit par m^2 sur $10m^2$ pris au hasard dans une vigne. On suppose que le poids de raisin produits par une souche de cette vigne suit une loi normale $\mathcal{N}(\mu, \sigma^2)$. On a obtenu les résultats suivants exprimés en (Kg):

24	34	36	41	43	47	54	59	65	69

1) Déterminer une estimation ponctuelle de la moyenne théorique μ et de la variance théorique σ^2.

2) Déterminer une estimation par intervalle de confiance à 95% de μ.

3) Déterminer une estimation par intervalle de confiance à 95% de σ^2.

Chapitre 4

Tests d'hypothèses

4.1 Introduction

La majorité des tests élémentaires reposent sur le principe suivant:

1. On définit une hypothèse nulle notée (H_0) contre l'hypothèse alternative (H_1). Le test a pour objectif d'accepter ou de rejeter (H_0) avec un risque connu à partir des données échantillonale dont on dispose.
2. On détermine alors une statistique qui est une variable aléatoire construite à partir des données échantillonnale.
   - Sous (H_0), cette variable suit une loi de probabilité connue: (normale, student, khi-deux,...)
   - On détermine alors l'intervalle dont lequel doit tomber la statistique avec une probabilité donnée $(1-\alpha)$, (le plus souvent 95% pour $\alpha = 5\%$).
3. On définit alors la règle de décision suivante:
   - Si la statistique tombe dans l'intervalle, on ne peut rejeter (H_0).
     Attention, cela ne veut pas dire que (H_0) est vraie mais que le test et les données ne permettent pas de voir un écart significatif à (H_0).
   - Si la statistique ne tombe pas dans l'intervalle, on rejette (H_0) avec le risque α de se tromper, (par exemple $\alpha = 5\%$).

4.2 Tests de conformité

4.2.1 Test de conformité de la proportion à une référence

$$\text{Test bilatéral} : \begin{cases} H_0 : p = p_0, \\ H_1 : p \neq p_0. \end{cases}$$

On calcule:

$$u = \frac{\bar{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}},$$

avec $\bar{p}$ c'est la proportion echantillonale estimateur de p la proportion inconnue de la population.
On détermine z_α pour la loi normale $\mathcal{N}(0,1)$, $(\Phi(z_\alpha) = 1 - \frac{\alpha}{2})$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:
Sur un échantillon de taille $n = 400$ de naissances, on a observé 206 mâles, soit une proportion de mâles de $\bar{p} = 206/400 = 0.515$. On se demande si il y a autant de mâles que de femelles. i.e., si $p_0 = 0.5$. On peut effectuer alors le test:

$$\begin{cases} H_0 : p = p_0 = 0.5, \\ H_1 : p \neq p_0 = 0.5. \end{cases}$$

On calcul alors

$$u = \frac{\bar{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{0.515 - 0.5}{\sqrt{\frac{0.5(1-0.5)}{400}}} = 0.6.$$

Pour $\alpha = 5\%$, on a $z_\alpha = 1.96$.
Comme $u \in]-z_\alpha; z_\alpha[$, alors on ne peut rejeter H_0, i.e., il est possible que $p = 0.5$.

4.2.2 Test de conformité de la moyenne à une référence

- **Cas d'un petit échantillon $n < 30$ où σ est inconnue**

$$\text{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0, \\ H_1 : \mu \neq \mu_0. \end{cases}$$

On calcule:

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}.$$

On détermine t_α pour la loi student à $n-1$ ddl, $(P(T > t_\alpha) = \frac{\alpha}{2})$, et on décide que:

1. Si $t \in]-t_\alpha; t_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:
$n = 25$, $X \sim \mathcal{N}(\mu, \sigma^2)$, $\bar{x} = 15$ et $s = 9$.
Peut on affirmer que la moyenne inconnue de la population est 12.

$$\text{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0 = 12, \\ H_1 : \mu \neq \mu_0 = 12. \end{cases}$$

On calcule:

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} = \frac{15 - 12}{\frac{9}{\sqrt{25}}} = 1.67.$$

Le ddl est 24, donc pour $\alpha = 5\%$, on trouve $t_\alpha = 2.07$.
Comme $t \in]-t_\alpha; t_\alpha[$, on ne peut rejeter H_0.

• **Cas d'un grand échantillon $n \geq 30$ où σ est inconnue**

$$\text{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0, \\ H_1 : \mu \neq \mu_0. \end{cases}$$

On calcule:

$$u = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}.$$

On détermine z_α pour la loi normale $\mathcal{N}(0,1)$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

4.2.3 Test de conformité de la variance à une référence

$$\text{Test bilatéral} : \begin{cases} H_0 : \sigma^2 = \sigma_0^2, \\ H_1 : \sigma^2 \neq \sigma_0^2. \end{cases}$$

Ici on travaille avec la loi Khi-deux à $n-1$ ddl. On cherche les deux nombres a et b tels que: $P(Y^2 \geq a) = \frac{\alpha}{2}$ et $P(Y^2 \geq b) = 1 - \frac{\alpha}{2}$. On calcule:

$$y^2 = \frac{n-1}{\sigma_0^2} s^2.$$

1. Si $y^2 \in]a; b[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:

$$\text{Test bilatéral} : \begin{cases} H_0 : \sigma^2 = \sigma_0^2 = 90, \\ H_0 : \sigma^2 \neq \sigma_0^2 = 90. \end{cases}$$

Pour $n = 31$, $s^2 = 100$, on a le ddl $= 31 - 1 = 30$. $\alpha = 0.05$ donc $\frac{\alpha}{2} = 0.025$ donne $a = 46.98$ et $1 - \frac{\alpha}{2} = 0.975$ donne $b = 16.80$.

$$y^2 = \frac{n-1}{\sigma_0^2} s^2 = \frac{30}{90} \times 100 = 33.34.$$

Comme $y^2 \in]a; b[$, on ne peut rejeter H_0.

4.3 Test d'indépendance du khi-deux entre deux variables qualitatives

Le test du khi-deux est largement utilisé pour l'étude de l'indépendance entre deux caractères qualitatifs. La présentation des résultats se fait sous forme d'un tableau de contingence à deux entrées. Chaque entrée représente les modalités d'une des variables. On détermine alors le tableau attendu sous l'hypothèse d'indépendance.

Exemple:

Un échantillon de $n = 1000$ personnes ont été interrogées sur une question précise. On a demandé à ces personnes de préciser leur sexe. Nous voudrions savoir si la réponse Y à la question est indépendante du sexe X.

X/Y	Favorable	Défavorable	Indécis	Total
Masculin	$n_{11} = 210$	$n_{12} = 194$	$n_{13} = 91$	$n_{1\bullet} = 495$
Féminin	$n_{21} = 292$	$n_{22} = 151$	$n_{23} = 62$	$n_{2\bullet} = 505$
Total	$n_{\bullet 1} = 502$	$n_{\bullet 2} = 345$	$n_{\bullet 3} = 153$	$n = 1000$

Sous hypothèse d'indépendance, la distribution conjointe est simplement le produit des distributions marginales, i.e., $f_{ij} = f_{i\bullet} f_{\bullet j}$. Si l'on estime f_{ij} par $\frac{n_{ij}}{n}$ et $f_{i\bullet}$ par $\frac{n_{i\bullet}}{n}$ et $f_{\bullet j}$ par $\frac{n_{\bullet j}}{n}$, on devrait donc avoir $n_{ij} \approx \frac{n_{i\bullet} n_{\bullet j}}{n}$.

L'idée est de calculer l'écart entre les deux termes, le n_{ij} observé et le n_{ij} prédit ou théorique, si cet écart devient trop important, on devra rejeter l'hypothèse que les variables sont indépendantes. On calcule:

$$Q = \sum_{i=1}^{k} \sum_{j=1}^{l} \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}}$$

La statistique Q est distribuée suivant une khi-deux à $(k-1)(l-1)$ ddl où k et l désignent le nombre de valeurs des deux variables.

NB: Test de validité du test: il faut que la fréquence théorique $\frac{n_{i\bullet} n_{\bullet j}}{n} \geq 5$ pour tous i et j. Nous acceptons H_0 si $Q \leq q_\alpha$ avec $P(Y^2 > q_\alpha) = \alpha$.

Dans notre exemple, pour $\alpha = 0.05$, on a le ddl est $(3-1) \times (2-1) = 2$, $q_\alpha = 5.99$ et la valeur de Q est:

$$Q = \frac{\left(\frac{495\times 502}{1000} - 210\right)^2}{\frac{495\times 502}{1000}} + \frac{\left(\frac{495\times 345}{1000} - 194\right)^2}{\frac{495\times 345}{1000}} + \frac{\left(\frac{495\times 153}{1000} - 91\right)^2}{\frac{495\times 153}{1000}} +$$

$$\frac{\left(\frac{505\times 502}{1000} - 292\right)^2}{\frac{505\times 502}{1000}} + \frac{\left(\frac{505\times 345}{1000} - 151\right)^2}{\frac{505\times 345}{1000}} + \frac{\left(\frac{505\times 153}{1000} - 62\right)^2}{\frac{505\times 153}{1000}} = 24.15.$$

Finalement on rejette H_0 avec un risque $\alpha = 0.05$ de se tromper.

4.4 Tests d'homogénéité dans le cas des échantillons indépendants

Dans deux populations P_1 et P_2, on étudie un même caractère. On cherche à comparer les deux populations quant à ce caractère pour savoir si elles sont homogènes ou pas.

4.4.1 Test de comparaison de deux proportions

Soit p_1 (resp. p_2) la proportion d'individus ayant la propriété dans P_1 (resp. dans P_2). On extrait deux échantillons indépendants E_1 et E_2 de tailles resp. n_1 et n_2.

$$\text{Test bilatéral} : \begin{cases} H_0 : p_1 = p_2 = p, \\ H_1 : p_1 \neq p_2. \end{cases}$$

Dans l'échantillon E_1 de taille n_1 on estime la proportion p_1 par $\overline{p_1}$ et dans l'échantillon E_2 de taille n_2 on estime la proportion p_2 par $\overline{p_2}$ et en regroupant les deux échantillons, on peut estimer p par:

$$\bar{p} = \frac{n_1\overline{p_1} + n_2\overline{p_2}}{n_1 + n_2}.$$

NB: Test de validité du test: $n_1\overline{p_1} \geq 5$**,** $n_1(1-\overline{p_1}) \geq 5$**,** $n_2\overline{p_2} \geq 5$ **et** $n_2(1-\overline{p_2}) \geq 5$**.**

On calcule

$$u = \frac{\overline{p_1} - \overline{p_2}}{\sqrt{(\frac{1}{n_1} + \frac{1}{n_2})\overline{p}(1-\overline{p})}}.$$

On détermine z_α pour la loi normale $\mathcal{N}(0,1)$, $(\Phi(z_\alpha) = 1 - \frac{\alpha}{2})$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:
Dans une même catégorie sociale, un échantillon de 40 hommes a fourni 8 fumeurs et un échantillon de 60 femmes a fourni 18 fumeuses. On se demande si la proportion de fumeurs est la même pour les deux sexes.

$$\text{Test bilatéral} : \begin{cases} H_0 : p_1 = p_2, \\ H_1 : p_1 \neq p_2. \end{cases}$$

$n_1 = 40$, $\overline{p_1} = \frac{8}{40} = 0.2$, $n_2 = 60$ et $\overline{p_2} = \frac{18}{60} = 0.3$.
$n_1\overline{p_1} = 8 \geq 5$, $n_1(1-\overline{p_1}) = 32 \geq 5$, $n_2\overline{p_2} = 18 \geq 5$ et $n_2(1-\overline{p_2}) = 42 \geq 5$.
$\bar{p} = 0.26$, $u = -1.12$ et pour $\alpha = 5\%$, $z_\alpha = 1.96$.
Comme $u \in]-z_\alpha; z_\alpha[$, alors on ne peut rejeter H_0: la proportion de fumeurs ne diffère pas significativement entre les deux sexes.

4.4.2 Test de comparaison de deux variances

$$\text{Test bilatéral} : \begin{cases} H_0 : \sigma_1^2 = \sigma_2^2, \\ H_1 : \sigma_1^2 \neq \sigma_2^2. \end{cases}$$

Dans l'échantillon E_1 de taille n_1 (resp. l'échantillon E_2 de taille n_2), on estime la variance σ_1^2 (resp. σ_2^2) par:

$$s_1^2 = \frac{1}{n_1 - 1}\sum_{i=1}^{n_1}(x_i - \overline{x_1})^2 \qquad \text{resp.} \qquad s_2^2 = \frac{1}{n_2 - 1}\sum_{i=1}^{n_2}(x_i - \overline{x_2})^2.$$

On calcule $f = \frac{s_1^2}{s_2^2}$ telle que $f \geq 1$ sinon on permute les échantillons de sorte que $f \geq 1$. Dans la table de la loi F de Fisher-Snédécor et avec le ddl $(n_1 - 1, n_2 - 1)$, on cherche f_α tel que $P(F \geq f_\alpha) = \frac{\alpha}{2}$, et on décide que:

1. Si $f < f_\alpha$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:

Dans un article de la revue "Biometrica", le biologiste Latter donne la longueur (en mm) des oeufs de Coucou trouvés dans les nids de deux espèces d'oiseaux :

- dans des nids de petite taille (Roitelet) :

19,8	22,1	21,5	20,9	22,0	21,0	22,3	21,0
20,3	20,9	22,0	22,0	20,8	21,2	21,0	

- dans des nids de taille plus grande (Fauvette) :

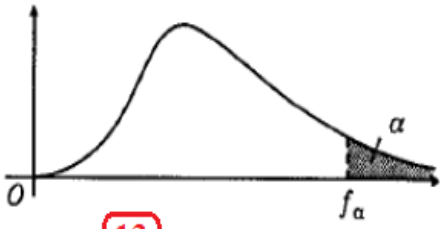
22,0	23,9	20,9	23,8	25,0	24,0	23,8
21,7	22,8	23,1	23,5	23,0	23,0	23,1

On se demande si le Coucou adapte la taille de ses oeufs à la taille du nid.

Observation sur l'échantillon E_1 de taille $n_1 = 15$: $\overline{x_1} = 21.25$ et $s_1^2 = 0.516$.
Observation sur l'échantillon E_2 de taille $n_2 = 14$: $\overline{x_2} = 23.11$ et $s_2^2 = 1.101$.
Comme $f = \frac{s_1^2}{s_2^2} < 1$, on permute les deux échantillons et on prend $f' = \frac{s_2^2}{s_1^2} = 2.14 > 1$.
Le ddl de la loi F de Fisher-Snédécor est $(n_2 - 1, n_1 - 1) = (13, 14) = (v_1, v_2)$.
Pour $\alpha = 5\%$ on trouve que la valeur de f_α telle que $P(F \geq f_\alpha) = \frac{\alpha}{2}$ est compris entre 2.95 et 3.15.
Comme $f' < f_\alpha$, on ne peut rejeter H_0 et les variances des deux populations ne sont pas différentes significativement au risque 5%.

Lois de Fisher ($\alpha = 0{,}025$)

Si F est une variable aléatoire qui suit la loi de Snédécor à (ν_1, ν_2) degrés de liberté, la table donne le nombre f_α tel que $P(F \geqslant f_\alpha) = \alpha = 0{,}025$.



13

ν_2 \ ν_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	648	800	864	900	922	937	957	969	985	993	1 001	1 018
2	38,5	39,0	39,2	39,2	39,3	39,3	39,4	39,4	39,4	39,4	39,5	39,5
3	17,4	16,0	15,4	15,1	14,9	14,7	14,5	14,4	14,3	14,2	14,1	13,9
4	12,2	10,6	9,98	9,60	9,36	9,20	8,98	8,84	8,66	8,56	8,46	8,26
5	10,0	8,43	7,76	7,39	7,15	6,98	6,76	6,62	6,43	6,33	6,23	6,02
6	8,81	7,26	6,60	6,23	5,99	5,82	5,60	5,46	5,27	5,17	5,07	4,85
7	8,07	6,54	5,89	5,52	5,29	5,12	4,90	4,76	4,57	4,47	4,36	4,14
8	7,57	6,06	5,42	5,05	4,82	4,65	4,43	4,30	4,10	4,00	3,89	3,67
9	7,21	5,71	5,08	4,72	4,48	4,32	4,10	3,96	3,77	3,67	3,56	3,33
10	6,94	5,46	4,83	4,47	4,24	4,07	3,85	3,72	3,52	3,42	3,31	3,08
11	6,72	5,26	4,63	4,28	4,04	3,88	3,66	3,53	3,33	3,23	3,12	2,88
12	6,55	5,10	4,47	4,12	3,89	3,73	3,51	3,37	3,18	3,07	2,96	2,72
13	6,41	4,97	4,35	4,00	3,77	3,60	3,39	3,25	3,05	2,95	2,84	2,60
14	6,30	4,86	4,24	3,89	3,66	3,50	3,29	3,15	2,95	2,84	2,73	2,49
15	6,20	4,76	4,15	3,80	3,58	3,41	3,20	3,06	2,86	2,76	2,64	2,40
16	6,12	4,69	4,08	3,73	3,50	3,34	3,12	2,99	2,79	2,68	2,57	2,32
17	6,04	4,62	4,01	3,66	3,44	3,28	3,06	2,92	2,72	2,62	2,50	2,25
18	5,98	4,56	3,95	3,61	3,38	3,22	3,01	2,87	2,67	2,56	2,44	2,19
19	5,92	4,51	3,90	3,56	3,33	3,17	2,96	2,82	2,62	2,51	2,39	2,13

4.4.3 Test de comparaison de deux moyennes

$$\text{Test bilatéral : } \begin{cases} H_0 : \mu_1 = \mu_2, \\ H_1 : \mu_1 \neq \mu_2. \end{cases}$$

• **Cas de grands échantillons indépendants** $n_1 > 30$ **et** $n_2 > 30$
On calcule

$$u = \frac{\overline{x_1} - \overline{x_2}}{\sqrt{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)}}.$$

On détermine z_α pour la loi normale $\mathcal{N}(0,1)$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

• **Cas de petits échantillons extraits de populations gaussiennes** $n_1 < 30$ **et** $n_2 < 30$ **et tel que** $\sigma = \sigma_1 = \sigma_2$
La variance commune σ^2 peut être estimer par:

$$s^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}.$$

On calcule

$$t = \frac{\overline{x_1} - \overline{x_2}}{s\sqrt{(\frac{1}{n_1} + \frac{1}{n_2})}}.$$

On détermine t_α dans la table de Student à $n_1 + n_2 - 2$ ddl, et on décide que:

1. Si $t \in]-t_\alpha; t_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:

Dans un article de la revue "Biometrica", le biologiste Latter donne la longueur (en mm) des oeufs de Coucou trouvés dans les nids de deux espèces d'oiseaux :

- dans des nids de petite taille (Roitelet) :

19,8	22,1	21,5	20,9	22,0	21,0	22,3	21,0
20,3	20,9	22,0	22,0	20,8	21,2	21,0	

- dans des nids de taille plus grande (Fauvette) :

22,0	23,9	20,9	23,8	25,0	24,0	23,8
21,7	22,8	23,1	23,5	23,0	23,0	23,1

On se demande si le Coucou adapte la taille de ses oeufs à la taille du nid.

Observation sur l'échantillon E_1 de taille $n_1 = 15$: $\overline{x_1} = 21.25$ et $s_1^2 = 0.516$.
Observation sur l'échantillon E_2 de taille $n_2 = 14$: $\overline{x_2} = 23.11$ et $s_2^2 = 1.101$.
On est dans le cas des petits échantillons $n_1 < 30$, $n_2 < 30$.
$s^2 = 0.798$, $t = -5.61$ et le ddl de la loi Student est $n_1 + n_2 - 2 = 27$. Pour pour $\alpha = 0.05$, on trouve $t_\alpha = 2.052$. Comme t n'est pas dans $]-t_\alpha; t_\alpha[$, on rejette H_0 avec une probabilité α de se tromper. La taille moyenne des oeufs de Coucou sont différentes dans les nids de Roitelet et de Fauvettes.

4.5 Test de normalité: test de Shapiro et Wilk

La plupart des méthodes de test paramétriques requièrent la normalité des données. Il est donc important de disposer d'une méthode permettant de vérifier cette normalité. Il existe plusieurs tests pour vérifier la normalité des données observées. Nous présentons ici le test de Shapiro et Wilk pour une série d'observations d'une variable quantitative.

NB: Ce test est valable pour des petits échantillons ($n \leq 30$)**.**

Exemple:
Nous avons réalisé $n = 10$ mesures d'un alésage en (mm). On a obtenu les résultats suivants:

12.124; 12.230; 12.327; 12.242; 12.466; 12.215; 12.026; 12.359; 12.215; 12.387.

On désire tester la normalité de cette série de résultats.

Démarche de vérification:

— Classer les différentes valeurs de la série par ordre croissant:

12.026; 12.124; 12.215; 12.215; 12.230; 12.242; 12.327; 12.359; 12.387; 12.466.

— Calculer la moyenne $\bar{x}$ de la série de mesure:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 12.259.$$

— Calculer le nombre:

$$T^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 = 0.1514.$$

— Calculer les différences respectives d_i:

$$d_1 = x_{10} - x_1 = 12.466 - 12.026 = 0.440$$

$$d_2 = x_9 - x_2 = 12.387 - 12.124 = 0.263$$

$$d_3 = x_8 - x_3 = 12.359 - 12.215 = 0.144$$

$$d_4 = x_7 - x_4 = 12.327 - 12.215 = 0.112$$

$$d_5 = x_6 - x_5 = 12.242 - 12.230 = 0.012$$

— A chacune de ces différences d_i, on affecte le coefficient a_i, donné par la table ci-dessus et on calcule $d_i * a_i$:

$$d_1 * a_1 = 0.440 * 0.5739 = 0.2525$$

$$d_2 * a_2 = 0.263 * 0.3291 = 0.0865$$

Figure – **Valeurs des a_i :**

n / J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

$$d_3 * a_3 = 0.144 * 0.2141 = 0.0308$$

$$d_4 * a_4 = 0.112 * 0.1224 = 0.0137$$

$$d_5 * a_5 = 0.012 * 0.0399 = 0.0005$$

— Calculer la valeur:

$$b = \sum_{i=1}^{5} d_i * a_i = 0.384$$

— Calculer le rapport:

$$W = \frac{b^2}{T^2} = 0.9739$$

— Par exemple pour $\alpha = 0.05$, on trouve $w_\alpha = 0.842$ dans la table suivante de Shapiro et Wilk.

Table de Shapiro et Wilk

n	Risque 5 % $W_{0,05}$	Risque 1 % $W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

— Si $W > w_\alpha$, on accepte la normalité des donnés, sinon on rejette cette hypothèse. Dans notre exemple, on a: $W = 0.9739 > w_\alpha = 0.842$, l'hypothèse de normalité est acceptée.

4.6 Exercices

Exercice 1:
On admet que le taux de cholestérol chez une femme suit une loi normale $\mathcal{N}(\mu, \sigma^2)$. Sur

un échantillon de 10 femmes, on a obtenu les résultats suivants:

$$\sum_{i=1}^{10} x_i = 21.3 \qquad \sum_{i=1}^{10} x_i^2 = 47.49$$

1. Déterminer une estimation ponctuelle de la moyenne et de la variance du taux.
2. Déterminer un intervalle de confiance pour la moyenne du taux au seuil 5%.
3. Tester au seuil 5% l'hypothèse que la moyenne de la population est 2.

Exercice 2:
Dans une usine du secteur de l'agroalimentaire, une machine à embouteiller est alimentée par un réservoir d'eau et par une file d'approvisionnement en bouteilles vides. Pour contrôler le bon fonctionnement de la machine. Pour une production d'une heure, on suppose que la variable aléatoire X qui à toute bouteille, prise au hasard dans cette production, associe le volume d'eau (en litres) qu'elle contient, est une variable aléatoire d'espérance μ et d'écart-type σ inconnus. On a prélevé un échantillon de 100 bouteilles, et on a obtenu un volume d'eau moyen: 1,495 l et un écart-type corrigé de 0,01.

1. Déterminer un intervalle de confiance pour la moyenne au seuil 1%.
2. Tester au seuil 1% si la moyenne vaut 1.5 l.

Exercice 3:
On sait qu'une maladie atteint 10% des individus d'une population donnée. Un chercheur a expérimenté un traitement sur un échantillon de n individus : il a alors recensé 5% de malades.

1. Déterminer la valeur maximale de n qui permette au chercheur de conclure à l'efficacité du traitement au risque de 5%
2. Déterminer un intervalle de confiance pour la proportion au seuil 5%.

Exercice 4:
Le volume d'une pipette d'un type donné suit une loi normale $\mathcal{N}(\mu, \sigma^2)$. Le fabriquant annonce un écart-type $\sigma_0 = 0.2\mu l$. Pour le vérifier, on pipette 20 fois un liquide, on observe une moyenne de $10\mu l$ et un écart-type de $0.4\mu l$.

1. Déterminer un intervalle de confiance pour la variance au seuil 5%.
2. Tester au seuil 5% si l'écart type vaut 0.2.

Exercice 5:
Une étude a été réalisée sur le cancer de la gorge. Pour cela, une population de 1000 personnes a été interrogée. les résultats obtenus sont donnés dans le tableau de contingences suivant:

	Atteint du cancer de la gorge	Non atteint du cancer de la gorge
Fumeur	344	258
Non-fumeur	160	238

1. Doit-on rejeter au risque 5% l'hypothèse d'indépendance des deux caractères: X=(être fumeur) et Y=(être atteint du cancer de la gorge) .
2. Vérifier la validité du test.

Exercice 6:
Nous avons réalisé 10 dosages. On a obtenu les résultats suivants:

60 80 55 45 60 65 65 60 70 40

1. Utiliser le test de Shapiro et Wilk pour tester la normalité de ces données.

Exercice 7:
On compare les effets d'un même traitement dans deux hôpitaux différents. Dans le premier hôpital, 70 des 100 malades traités montrent des signes de guérison. Dans le deuxième hôpital, c'est le cas pour 100 des 150 malades traités.

1. Quelle conclusion peut-on en tirer au risque de 5%? (comparer les proportions).

Exercice 8:
Sur deux groupes de même taille: 10 malades, on expérimente les effets d'un traitement destiné à diminuer la pression artérielle. On observe les résultats suivants (valeurs de la tension artérielle systolique en cm Hg). On supposera les populations gaussiennes.

Groupe 1	15	18	17	20	21	18	17	15	19	16
Groupe 2	12	16	17	18	17	15	18	14	16	18

1. Le traitement a-t-il une action significative, au risque de 5%? (comparer les variances puis comparer les moyennes).

4.7 Exercices de révisions

Exercice 1 (Variable continue et construction des classes):
On a relevé les salaires annuels en (DH) de $n = 30$ personnes:

1860	2010	2110	2380	2600	2770	2770	2810	2920	2950
3180	3250	3250	3280	3360	4310	4320	4960	5430	5670
5710	5850	6230	6250	6960	7470	7880	8710	9440	9590

1. De quel type est la variable salaire? Déterminer sa médiane. Interpréter.
2. Construire le tableau statistique en adoptant des classes de même amplitude selon la règle de Sturge.
3. Construire l'histogramme des fréquences.
4. Déterminer la classe modale et les centres des classes.
5. En déduire la moyenne, la variance et l'écart type de la variable salaire.

Exercice 2 (Régression linéaire):
On considère la série double statistique suivante:

x_i	2	3	5	1	4
y_i	4	9	11	3	8

1. De quel type sont les variables X et Y.
2. Déterminer les médianes, les moyennes et les variances de X et Y.
3. Déterminer la covariance et le coefficient de corrélation entre X et Y. Donner une interprétation.
4. Déterminer la droite de régression linéaire de Y en X.
5. Tracer le nuage de points et la droite de régression linéaire de Y en X.
6. Vérifier que la droite de régression passe par le point $(\bar{x}, \bar{y})$.
7. Établir, sur la base de ce modèle, la valeur y^* correspond à la valeur $x^* = 3,5$.
8. Déterminer la variance résiduelle et le coefficient de détermination. Interpréter.

Exercice 3 (Loi de probabilité discrète):
On lance deux trièdres équilibrés numérotés: 1; 2; 3; 4. On note X la variable aléatoire qui donne le plus grand des deux numéros obtenus.

1. Donner la loi de X. En déduire: $P(X \leq 2)$, $E(X)$, $V(X)$ et $\sigma(X)$.

Exercice 4 (Loi de probabilité continue):
Soit X une variable aléatoire continue qui suit la loi de Pareto de densité: $f(x) = \frac{1_{(x>1)}}{x^2}$.

1. Vérifier que $\int_{-\infty}^{+\infty} f(x)dx = 1$ puis calculer $E(X)$.

Exercice 5 (Comparaisons des proportions):
Pour traiter un certain type de tumeur, on a utilisé deux schémas thérapeutiques:
- Sur 40 malades traités avec le schéma A, on a observé la mort de 6 malades,
- Sur 60 malades traités avec le schéma B, on a observé la mort de 15 malades.

1. Donner une estimation ponctuelle des proportions dans les deux populations.
2. Pour la population 1, donner une estimation par intervalle de confiance de la proportion au risque 1%.
3. Tester au risque 1% pour la population 2 si la proportion vaut 20%.
4. Comparer au risque 5% les proportions des deux populations. Peut-on dire que les schémas A et B diffèrent significativement au risque 5% ?

Exercice 6 (Comparaisons des moyennes):
Sur deux groupes de même taille: 9 malades, on expérimente les effets d'un nouveau médicament. On observe les résultats suivants:

Groupe 1	15	18	17	20	21	18	17	15	19
Groupe 2	12	16	17	18	17	15	18	14	16

1. Donner une estimation ponctuelle des moyennes et variances dans les deux populations.
2. Pour la population 1, donner une estimation par intervalle de confiance de la moyenne au risque 5%.
3. Pour la population 1, donner une estimation par intervalle de confiance de la variance au risque 5%.
4. Tester au risque 5% pour la population 2 si la moyenne vaut 16.
5. Tester au risque 5% pour la population 2 si la variance vaut 4.
6. Comparer au risque 5% les variances des deux populations.
7. Comparer au risque 5% les moyennes des deux populations.

Exercice 7 (Test de Shapiro et Wilk):
Afin de tester l'hypothèse que la consommation de caféine facilite l'apprentissage, trois groupes d'étudiants se préparent à un examen: le groupe 1 boit une tasse, le groupe 2 boit 2 tasses et le groupe 3 boit 3 tasses de café. Voici leurs scores à l'examen:

Groupe 1	Groupe 2	Groupe 3
50	48	57
42	47	59
53	65	48

1. Utiliser le test de Shapiro et Wilk pour tester la normalité des neuf données.

Exercice 8 (Test d'indépendance de Khi-deux):
Une étude a été réalisée sur le cancer de la gorge. Pour cela, une population de 1000 personnes a été interrogée. les résultats obtenus sont donnés dans le tableau de contingences suivant:

	Atteint du cancer de la gorge	Non atteint du cancer de la gorge
Fumeur	344	258
Non-fumeur	160	238

1. Doit-on rejeter au risque 5% l'hypothèse d'indépendance des deux caractères: X=(être fumeur) et Y=(être atteint du cancer de la gorge) .
2. Vérifier la validité du test.

4.8 Examen (session normale 2016-2017)

Exercice 1 (2 pts=1+1):
Soit $X \sim \mathcal{N}(\mu = 170, \sigma^2 = 64)$.

1. Calculer $P(160 < X < 176)$.
2. Déterminer la valeur de z tel que $P(170 - z < X < 170 + z) = 0,668$.

Exercice 2 (9 pts=2+2+1+1+1+2):
On considère la série double statistique suivante:

y_i	5	1	3	2	4
x_i	11	3	9	4	8

1. Déterminer les médianes, les moyennes et les variances de X et Y.
2. Déterminer la covariance et le coefficient de corrélation entre X et Y. Donner une interprétation.
3. Déterminer la droite de régression linéaire de Y en X.
4. Tracer le nuage de points et la droite de régression linéaire de Y en X.
5. Établir, sur la base de ce modèle, la valeur y^* correspond à la valeur $x^* = 4,5$.
6. Déterminer la variance résiduelle et le coefficient de détermination. Donner une interprétation.

Exercice 3 (5 pts=1+1+2+1):
Dans une université, on veut comparer les proportions de réussite dans la filière STU S3 sur deux années différentes:
- Pour l'année 2014, on note 80 succès pour 120 interrogés,
- Pour l'année 2015, on note 70 succès pour 110 interrogés.

1. Pour l'année 2014, estimer par intervalle de confiance la proportion au risque 5%.
2. Pour l'année 2015, tester au risque 5% si la proportion vaut 60%.
3. Comparer au risque 5% les proportions des deux années. Peut-on dire que les deux années diffèrent significativement au risque 5% ?
4. Vérifier les conditions de validité de ce dernier test.

Exercice 4 (4 pts):
Le tableau suivant présente la production laitière en litres par jours de trois races de vaches:

Race (1)	Race (2)	Race (3)
147	153	142
150	148	165
148	159	157

1. Tester au risque 5% la normalité des données.

Bon courage

Loi Normale N(0,1) : P(Z<z)

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,500 0	0,504 0	0,508 0	0,512 0	0,516 0	0,519 9	0,523 9	0,527 9	0,531 9	0,535 9
0,1	0,539 8	0,543 8	0,547 8	0,551 7	0,555 7	0,559 6	0,563 6	0,567 5	0,571 4	0,575 3
0,2	0,579 3	0,583 2	0,587 1	0,591 0	0,594 8	0,598 7	0,602 6	0,606 4	0,610 3	0,614 1
0,3	0,617 9	0,621 7	0,625 5	0,629 3	0,633 1	0,636 8	0,640 6	0,644 3	0,648 0	0,651 7
0,4	0,655 4	0,659 1	0,662 8	0,666 4	0,670 0	0,673 6	0,677 2	0,680 8	0,684 4	0,687 9
0,5	0,691 5	0,695 0	0,698 5	0,701 9	0,705 4	0,708 8	0,712 3	0,715 7	0,719 0	0,722 4
0,6	0,725 7	0,729 1	0,732 4	0,735 7	0,738 9	0,742 2	0,745 4	0,748 6	0,751 7	0,754 9
0,7	0,758 0	0,761 1	0,764 2	0,767 3	0,770 4	0,773 4	0,776 4	0,779 4	0,782 3	0,785 2
0,8	0,788 1	0,791 0	0,793 9	0,796 7	0,799 5	0,802 3	0,805 1	0,807 8	0,810 6	0,813 3
0,9	0,815 9	0,818 6	0,821 2	0,823 8	0,826 4	0,828 9	0,831 5	0,834 0	0,836 5	0,838 9
1,0	0,841 3	0,843 8	0,846 1	0,848 5	0,850 8	0,853 1	0,855 4	0,857 7	0,859 9	0,862 1
1,1	0,864 3	0,866 5	0,868 6	0,870 8	0,872 9	0,874 9	0,877 0	0,879 0	0,881 0	0,883 0
1,2	0,884 9	0,886 9	0,888 8	0,890 7	0,892 5	0,894 4	0,896 2	0,898 0	0,899 7	0,901 5
1,3	0,903 2	0,904 9	0,906 6	0,908 2	0,909 9	0,911 5	0,913 1	0,914 7	0,916 2	0,917 7
1,4	0,919 2	0,920 7	0,922 2	0,923 6	0,925 1	0,926 5	0,927 9	0,929 2	0,930 6	0,931 9
1,5	0,933 2	0,934 5	0,935 7	0,937 0	0,938 2	0,939 4	0,940 6	0,941 8	0,942 9	0,944 1
1,6	0,945 2	0,946 3	0,947 4	0,948 4	0,949 5	0,950 5	0,951 5	0,952 5	0,953 5	0,954 5
1,7	0,955 4	0,956 4	0,957 3	0,958 2	0,959 1	0,959 9	0,960 8	0,961 6	0,962 5	0,963 3
1,8	0,964 1	0,964 9	0,965 6	0,966 4	0,967 1	0,967 8	0,968 6	0,969 3	0,969 9	0,970 6
1,9	0,971 3	0,971 9	0,972 6	0,973 2	0,973 8	0,974 4	0,975 0	0,975 6	0,976 1	0,976 7

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

Tables des valeurs des a_i

n / J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

4.9 Examen (session de rattrapage 2016-2017)

Exercice 1 (2 pts=1+1):
Soit X une variable aléatoire de densité de probabilité: $f(x) = \frac{1_{(x>1)}}{x^2}$.

1. Vérifier que $\int_{-\infty}^{+\infty} f(x)dx = 1$.
2. Calculer l'espérance $E(X)$.

Exercice 2 (9 pts=1+2+2+1+1+1+1):
On considère la série double statistique suivante:

x_i	16	8	7	5	11	2	14	13	20	24
y_i	17	12	7	2	8	3	13	10	8	20

1. Déterminer les médianes de X et Y. Donner une interprétation.
2. Déterminer les moyennes et les variances de X et Y.
3. Déterminer la covariance et le coefficient de corrélation entre X et Y. Donner une interprétation.
4. Déterminer la droite de régression linéaire de Y en X.
5. Tracer le nuage de points et la droite de régression linéaire de Y en X.
6. Établir, sur la base de ce modèle, la valeur y^* correspond à la valeur $x^* = 10$.
7. Déterminer la variance résiduelle et le coefficient de détermination. Donner une interprétation.

Exercice 3 (9 pts=1+1+1+1+1+2+2):
Sur deux groupes de deux types de produits, on test un nouveau processus. On observe les résultats suivants:

Produit A	17	18	17	15	14	16	18	12	16	18
Produit B	17	15	19	16	15	18	21	18	17	20

1. Donner une estimation ponctuelle des moyennes et variances dans les deux groupes.
2. Pour le groupe B, estimer par intervalle de confiance la moyenne au risque 5 %.
3. Pour le groupe A, estimer par intervalle de confiance la variance au risque 5 %.
4. Pour le groupe B, tester au risque 5 % si la moyenne vaut 16.
5. Pour le groupe A, tester au risque 5 % si la variance vaut 20.
6. Comparer au risque 5 % les variances des deux groupes.
7. Pour le groupe A, tester au risque 5 % la normalité des données.

Bon courage

Loi Student : P(T>t) = alpha

Degrés de liberté	alpha : Aire dans la queue supérieure de la distribution					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250

Loi Khi-deux à v ddl : $P(Y^2>x)$

v \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103
3	0,1148	0,2158	0,3518	0,5844	6,2514	7,8147	9,3484	11,3449
4	0,2971	0,4844	0,7107	1,0636	7,7794	9,4877	11,1433	13,2767
5	0,5543	0,8312	1,1455	1,6103	9,2364	11,0705	12,8325	15,0863
6	0,8721	1,2373	1,6354	2,2041	10,6446	12,5916	14,4494	16,8119
7	1,2390	1,6899	2,1673	2,8331	12,0170	14,0671	16,0128	18,4753
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093

Loi Fisher Snédécor à (v_1, v_2) ddl

$P(F \geq f_\alpha) = \alpha = 0.025$

v_2 \ v_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	648	800	864	900	922	937	957	969	985	993	1 001	1 018
2	38,5	39,0	39,2	39,2	39,3	39,3	39,4	39,4	39,4	39,4	39,5	39,5
3	17,4	16,0	15,4	15,1	14,9	14,7	14,5	14,4	14,3	14,2	14,1	13,9
4	12,2	10,6	9,98	9,60	9,36	9,20	8,98	8,84	8,66	8,56	8,46	8,26
5	10,0	8,43	7,76	7,39	7,15	6,98	6,76	6,62	6,43	6,33	6,23	6,02
6	8,81	7,26	6,60	6,23	5,99	5,82	5,60	5,46	5,27	5,17	5,07	4,85
7	8,07	6,54	5,89	5,52	5,29	5,12	4,90	4,76	4,57	4,47	4,36	4,14
8	7,57	6,06	5,42	5,05	4,82	4,65	4,43	4,30	4,10	4,00	3,89	3,67
9	7,21	5,71	5,08	4,72	4,48	4,32	4,10	3,96	3,77	3,67	3,56	3,33
10	6,94	5,46	4,83	4,47	4,24	4,07	3,85	3,72	3,52	3,42	3,31	3,08

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

Tables des valeurs des a_i

n \ J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

4.10 Examen (session normale 2017-2018)

Exercice 1 (3 pts=1+2)

1. Nous supposons que l'âge auquel un enfant commence à marcher est une variable aléatoire suivant la loi normale de moyenne 13 mois et une variance 2,25 mois. Quelle est la probabilité qu'un enfant commence à marcher entre 11 et 15 mois ?
2. Le score obtenu sur la qualité d'un produit a pour moyenne 84 et un écart-type de 35. Quelle est la probabilité d'observer sur un échantillon de taille 75 un score moyen supérieure à 90 ?

Exercice 2 (7 pts=2+2+1+2)
Dans la série statistique suivante, X représente le nombre de jours d'exposition au soleil d'une feuille et Y le nombre de stomates aérifères au millimètre carré :

X	22	26	2	4	12	18	28	30	7	10
Y	31	36	4	10	23	28	48	53	25	20

1. Déterminer l'équation de la droite de regression linéaire de Y en X.
2. Calculer les coefficients de corrélation et de détermination. Commenter les résultats.
3. Quel nombre de stomates peut-on prévoir après 20 jours d'exposition au soleil ?
4. Tracer le nuage de points et la droite de régression linéaire de Y en X.

Exercice 3 (4 pts=1+1+1+1)
Pour traiter un certain type de tumeur, on a utilisé deux schémas thérapeutiques:
- Sur 40 malades traités avec le schéma A, on a observé une mortalité de 6 malades.
- Sur 60 malades traités avec le schéma B, on a observé une mortalité de 15 malades.

1. Pour le schéma A, estimer par intervalle de confiance la proportion au risque 5%.
2. Pour le schéma B, tester au risque 5% si la proportion vaut 20%.
3. Comparer au risque 5% les proportions pour les deux schémas.
4. Vérifier la validité du test de la question (3).

Exercice 4 (6 pts)
Pour mesurer l'influence de nourriture sur la croissance du poids des bébés, on a mesuré le poids des bébés pour quatres types de nourriture.

Type (1)	Type (2)	Type (3)	Type (4)
4	25	17	15
19	21	10	23
20	9	13	16

1. Tester au risque 5 % la normalité des données.

Loi Normale N(0,1) : P(Z<z)

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,500 0	0,504 0	0,508 0	0,512 0	0,516 0	0,519 9	0,523 9	0,527 9	0,531 9	0,535 9
0,1	0,539 8	0,543 8	0,547 8	0,551 7	0,555 7	0,559 6	0,563 6	0,567 5	0,571 4	0,575 3
0,2	0,579 3	0,583 2	0,587 1	0,591 0	0,594 8	0,598 7	0,602 6	0,606 4	0,610 3	0,614 1
0,3	0,617 9	0,621 7	0,625 5	0,629 3	0,633 1	0,636 8	0,640 6	0,644 3	0,648 0	0,651 7
0,4	0,655 4	0,659 1	0,662 8	0,666 4	0,670 0	0,673 6	0,677 2	0,680 8	0,684 4	0,687 9
0,5	0,691 5	0,695 0	0,698 5	0,701 9	0,705 4	0,708 8	0,712 3	0,715 7	0,719 0	0,722 4
0,6	0,725 7	0,729 1	0,732 4	0,735 7	0,738 9	0,742 2	0,745 4	0,748 6	0,751 7	0,754 9
0,7	0,758 0	0,761 1	0,764 2	0,767 3	0,770 4	0,773 4	0,776 4	0,779 4	0,782 3	0,785 2
0,8	0,788 1	0,791 0	0,793 9	0,796 7	0,799 5	0,802 3	0,805 1	0,807 8	0,810 6	0,813 3
0,9	0,815 9	0,818 6	0,821 2	0,823 8	0,826 4	0,828 9	0,831 5	0,834 0	0,836 5	0,838 9
1,0	0,841 3	0,843 8	0,846 1	0,848 5	0,850 8	0,853 1	0,855 4	0,857 7	0,859 9	0,862 1
1,1	0,864 3	0,866 5	0,868 6	0,870 8	0,872 9	0,874 9	0,877 0	0,879 0	0,881 0	0,883 0
1,2	0,884 9	0,886 9	0,888 8	0,890 7	0,892 5	0,894 4	0,896 2	0,898 0	0,899 7	0,901 5
1,3	0,903 2	0,904 9	0,906 6	0,908 2	0,909 9	0,911 5	0,913 1	0,914 7	0,916 2	0,917 7
1,4	0,919 2	0,920 7	0,922 2	0,923 6	0,925 1	0,926 5	0,927 9	0,929 2	0,930 6	0,931 9
1,5	0,933 2	0,934 5	0,935 7	0,937 0	0,938 2	0,939 4	0,940 6	0,941 8	0,942 9	0,944 1
1,6	0,945 2	0,946 3	0,947 4	0,948 4	0,949 5	0,950 5	0,951 5	0,952 5	0,953 5	0,954 5
1,7	0,955 4	0,956 4	0,957 3	0,958 2	0,959 1	0,959 9	0,960 8	0,961 6	0,962 5	0,963 3
1,8	0,964 1	0,964 9	0,965 6	0,966 4	0,967 1	0,967 8	0,968 6	0,969 3	0,969 9	0,970 6
1,9	0,971 3	0,971 9	0,972 6	0,973 2	0,973 8	0,974 4	0,975 0	0,975 6	0,976 1	0,976 7

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

n / J	2	3	4	5	6	7	8	9	10	11	12
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739	0.5601	0.5475
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291	0.3315	0.3325
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141	0.2260	0.2347
4						0.0000	0.0561	0.0947	0.1224	0.1429	0.1586
5								0.0000	0.0399	0.0695	0.0922
6											0.0303

Bon courage

4.11 Examen (session de rattrapage 2017-2018)

Exercice 1 (8 pts=3+1+2+2)
Un échantillon de 48 poissons de la même espèce à fourni les poids suivants (en g):

60	82	92	97	101	104	109	118	131	155	69	82
93	97	101	104	110	120	133	165	70	85	93	99
101	105	110	121	138	166	74	85	93	99	102	106
110	125	140	128	79	87	94	99	102	107	114	180

1. Construire le tableau statistique en adoptant quatres classes.
2. Tracer la fonction de répartition.
3. Déterminer la médiane par interpolation linéaire.
4. Utiliser les quatres classes pour calculer la moyenne, la variance et l'écart type.

Exercice 2 (4 pts=3+1)
Le tableau ci-dessus résume la présence ou l'absence d'une infection bactérienne en fonction de l'usage ou non d'une antibiothérapie ou d'un placebo:

	Antibio	Placebo
Absence	74	27
Présence	10	29

1. Doit-on rejeter au risque 5% l'hypothèse d'indépendance des deux caractères.
2. Vérifier la validité du test.

Exercice 3 (8 pts=1+1+1+1+2+2)
On a mesuré, dans deux classes différentes, après une course de 400 mètres, le pouls (en battements par minute) de sept étudiants suivants un cours d'éducation physique:

Classe 1	74	87	77	99	103	81	60
Classe 2	83	96	99	110	130	95	74

1. Pour la classe (1), estimer par intervalle de confiance la moyenne au risque 5%.
2. Pour la classe (1), tester au risque 5% si la moyenne vaut 80.
3. Pour la classe (2), estimer par intervalle de confiance la variance au risque 5%.
4. Pour la classe (2), tester au risque 5% si la variance vaut 330.
5. Comparer au risque 5% les variances des deux classes.
6. Comparer au risque 5% les moyennes des deux classes.

Bon courage

Loi Student : P(T>t)

Degrés de liberté	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250
10	0,879	1,372	1,812	2,228	2,764	3,169
11	0,876	1,363	1,796	2,201	2,718	3,106
12	0,873	1,356	1,782	2,179	2,681	3,055

Loi Khi-deux à v ddl : $P(Y^2>x)$

v \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103
3	0,1148	0,2158	0,3518	0,5844	6,2514	7,8147	9,3484	11,3449
4	0,2971	0,4844	0,7107	1,0636	7,7794	9,4877	11,1433	13,2767
5	0,5543	0,8312	1,1455	1,6103	9,2364	11,0705	12,8325	15,0863
6	0,8721	1,2373	1,6354	2,2041	10,6446	12,5916	14,4494	16,8119
7	1,2390	1,6899	2,1673	2,8331	12,0170	14,0671	16,0128	18,4753
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093

Loi Fisher Snédécor à (v_1, v_2) ddl

$P(F \geq f_\alpha) = \alpha = 0{,}025$

v_2 \ v_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	648	800	864	900	922	937	957	969	985	993	1 001	1 018
2	38,5	39,0	39,2	39,2	39,3	39,3	39,4	39,4	39,4	39,4	39,5	39,5
3	17,4	16,0	15,4	15,1	14,9	14,7	14,5	14,4	14,3	14,2	14,1	13,9
4	12,2	10,6	9,98	9,60	9,36	9,20	8,98	8,84	8,66	8,56	8,46	8,26
5	10,0	8,43	7,76	7,39	7,15	6,98	6,76	6,62	6,43	6,33	6,23	6,02
6	8,81	7,26	6,60	6,23	5,99	5,82	5,60	5,46	5,27	5,17	5,07	4,85
7	8,07	6,54	5,89	5,52	5,29	5,12	4,90	4,76	4,57	4,47	4,36	4,14
8	7,57	6,06	5,42	5,05	4,82	4,65	4,43	4,30	4,10	4,00	3,89	3,67
9	7,21	5,71	5,08	4,72	4,48	4,32	4,10	3,96	3,77	3,67	3,56	3,33
10	6,94	5,46	4,83	4,47	4,24	4,07	3,85	3,72	3,52	3,42	3,31	3,08

4.12 Références

[1] Emile Amzallag et Norbert Piccioli. *Introduction à la statistique.*

[2] Renée Veysseyre. *Aide-mémoire: Statistique et probabilités pour l'ingénieur.*

[3] Yves Tillé. *Résumé du cours de statistique descriptive.*