Cours et Exercices

Complément de Probabilités

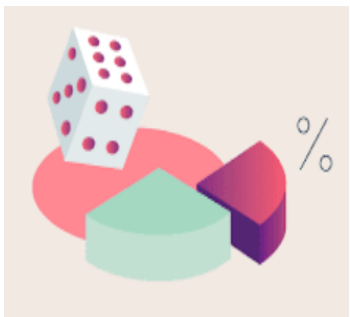
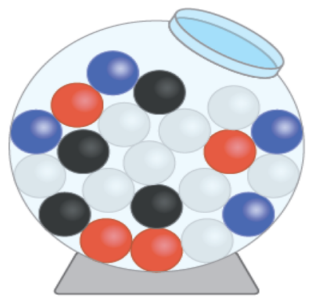
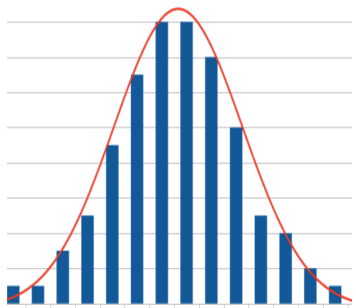
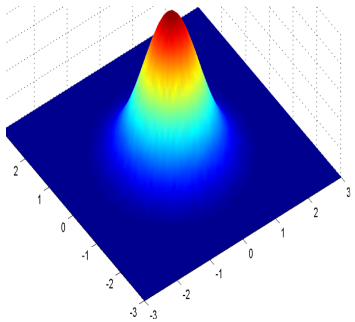
Master: Modélisation Stochastique, Déterministe et Data Science

Master: Théorie Spectrale et Applications

Université Mohammed Premier
Faculté des Sciences Oujda

Année universitaire : 2024-2025 2026-2027

Enseignant : Sghir Aissa
a.sghir@ump.ac.ma
Laboratoire de Modélisation Stochastique et Déterministe

Plan :

1. Rappel sur les espaces probabilisés
2. Rappel sur les variables aléatoires
3. Fonctions génératrice et caractéristique
4. Vecteurs aléatoires, Vecteurs Gaussiens
5. Espérance conditionnelle
6. Convergences et approximations

Plan :

1. Rappel sur les espaces probabilisés
2. Rappel sur les variables aléatoires
3. Fonctions génératrice et caractéristique
4. Vecteurs aléatoires, Vecteurs Gaussiens
5. Espérance conditionnelle
6. Convergences et approximations

Espaces probabilisés

Descriptif du chapitre 1 :

- **Rappels sur les tribus et les mesures.**
- **Probabilités : vocabulaire et propriétés.**
- **Probabilité conditionnelle et indépendance.**
- **Théorème des probabilités totales.**
- **Théorème de Bayes.**
- **Espace probabilisé produit.**

Espaces probabilisés

Introduction :

Un espace probabilisé $(\Omega, \mathcal{A}, P)$ fait appel aux points suivants :

- **Une expérience dite aléatoire où tous les résultats possibles sont connus mais non prévisibles.**
- **Un ensemble Ω appelé espace fondamental ou univers, qui contient l'ensemble de tous les résultats possibles, (dites aussi épreuves).**
- **Une famille $\mathcal{A}$ de $\mathcal{P}(\Omega)$ dite tribu, (ou σ-algèbre), stable par complémentaire et par union dénombrable. Les parties de $\mathcal{A}$ sont appelées des événements.**
- **Une probabilité P qui est une mesure qui quantifie la chance de réalisation des événements de la tribu $\mathcal{A}$.**

Espaces probabilisés

Exemples d'expériences aléatoires :

Cas d'un univers fini :

1) Un lancer de trois pièces de monnaie.



$$\Omega = \{(P,P,P),(P,P,F),...,(F,F,F)\} \Longrightarrow \textbf{card}\ (\Omega) = 2^3 = 8.$$

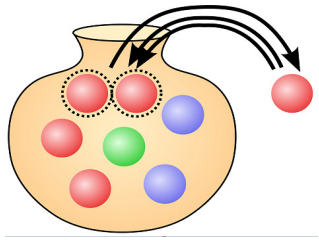
2) Un lancer de deux dés.



$$\Omega = \{(1,1),(1,2),\ldots,(6,6)\} \Longrightarrow \textbf{card}\ (\Omega) = 6^2 = 36.$$

Espaces probabilisés

3) Un tirage au hasard et simultané de deux boules dans une urne qui contient quatre boules rouges, deux boules bleues et une boule verte donne :



$$\Omega = \{(R_1, R_2), (R_1, R_3), (R_2, R_3), (R_1, V_1), ...\} \Longrightarrow \textbf{card}\ (\Omega) = C_7^2 = 21.$$

4) Pour un tirage successif et sans remise, on obtient :

$$\Omega = \{(R_1, R_2), (R_2, R_1), (R_1, R_3), (R_3, R_1), (R_1, V_1), ...\} \Longrightarrow \textbf{card}\ (\Omega) = A_7^2 = 42.$$

5) Pour un tirage successif et avec remise, on obtient :

$$\Omega = \{(R_1, R_1), (R_1, R_2), (R_2, R_1), (R_2, R_2), ...\} \Longrightarrow \textbf{card}\ (\Omega) = 7^2 = 49.$$

Espaces probabilisés

Cas d'un univers infini :

1) Un lancer d'une pièce de monnaie jusqu'à l'obtention de "Face". Le nombre de lancers peut varier de 1 à l'infini.

2) Un tirage d'un nombre réel dans l'intervalle $[0, 1]$. L'univers des résultats est infini, contenant tous les nombres réels entre 0 et 1.

3) La mesure du temps d'attente jusqu'à la prochaine arrivée d'un bus peut être modélisé par un nombre positif réel, pouvant aller de zéro à l'infini.

4) Si l'on choisit un point aléatoire sur une ligne infinie, l'univers des résultats est constitué de tous les nombres réels, représentant les coordonnées de chaque point.

Espaces probabilisés

Tribu (ou σ-algèbre) :

Définition

On appelle tribu, (ou σ-algèbre), sur un ensemble E, une partie $\mathcal{A}$ de $\mathcal{P}(E)$, l'ensemble des parties de E, vérifiant les propriétés suivantes :

- $\emptyset \in \mathcal{A}$ **et** $E \in \mathcal{A}$.
- $\mathcal{A}$ **est stable par complémentaire : si** $A \in \mathcal{A}$ **alors** $\bar{A} \in \mathcal{A}$.
- $\mathcal{A}$ **est stable par union dénombrable : si** $(A_n)_n$ **est une suite des éléments de** $\mathcal{A}$ **alors** $\bigcup_n A_n$ **est un élément de** $\mathcal{A}$.

$(E, \mathcal{A})$ **est appelé un espace mesurable.**

Exemples de tribus :

1) **Tribu grossière :** $\{\emptyset, E\}$ **est la plus petite tribu sur** E.
2) **Tribu discrète :** $\mathcal{P}(E)$ **est la plus grosse tribu sur** E.
3) **Pour** $A \subset E$, $\{\emptyset, A, \bar{A}, E\}$ **est une tribu sur** E.

Espaces probabilisés

Mesure positive :

Définition

Soit $(E, \mathcal{A})$ un espace mesurable. Une mesure positive sur $(E, \mathcal{A})$ est une application μ de $\mathcal{A}$ dans $[0, +\infty]$ tel que :

- $\mu(\emptyset) = 0$.
- **σ-additivité : si $(A_n)_n$ est une suite des éléments de $\mathcal{A}$ deux à deux disjoints, (c-à-d : $\forall\ i \neq j,\ A_i \cap A_j = \emptyset$), alors,**

$$\mu\Big(\bigcup_n A_n\Big) = \sum_n \mu(A_n).$$

Le triplet $(E, \mathcal{A}, \mu)$ est appelé un espace mesuré.

Espaces probabilisés

Exemples de mesure positives :

1. **La mesure de Dirac en un point $a \in E$:**

$$\delta_a(A) = \begin{cases} 1 & \text{si } a \in A, \\ 0 & \text{sinon.} \end{cases}$$

2. **La mesure de comptage sur $\mathbb{N}$ définie sur $\mathcal{A} = \mathcal{P}(\mathbb{N})$ par :**

$$\mu(A) = \begin{cases} \text{Card}(A) & \text{si } A \text{ est dénombrable fini,} \\ +\infty & \text{sinon.} \end{cases}$$

3. **La mesure de Lebesgue sur $\mathbb{R}^n$ définie sur $\mathcal{B}(\mathbb{R}^n)$ la tribu borélienne par :**

$$\lambda(P) = \prod_{i=1}^{n}(b_i - a_i) \quad \text{pour tout pavé} \quad P = \prod_{i=1}^{n}]a_i, b_i[.$$

$\mathcal{B}(\mathbb{R}^n)$ est la plus petite tribu sur $\mathbb{R}^n$ contenant tous les ouverts de $\mathbb{R}^n$.

Espaces probabilisés

Probabilité :

Définition

Soit $(\Omega, \mathcal{A})$ un espace probabilisable, (Ω est un univers). On appelle probabilité sur $(\Omega, \mathcal{A})$ toute application P de $\mathcal{A}$ dans $[0,1]$ tel que :

- $P(\Omega) = 1$.
- **σ-additivité : si $(A_n)_n$ est une suite des éléments de $\mathcal{A}$ deux à deux disjoints, (c-à-d : $\forall\ i \neq j,\ A_i \cap A_j = \emptyset$), alors,**

$$P\Big(\bigcup_n A_n\Big) = \sum_n P(A_n).$$

Remarque

- **P est une mesure positive sur $(\Omega, \mathcal{A})$ telle que $P(\Omega) = 1$.**
- **Le triplet $(\Omega, \mathcal{A}, P)$ est appelé un espace probabilisé.**
- **Tout élément $A \in \mathcal{A}$ est appelé un événement.**

Espaces probabilisés

Exercice :

Considérons la mesure discrète sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ définie par :

$$\mu_1 = \frac{1}{2}\delta_1 + \frac{1}{4}\delta_2 + \frac{1}{4}\delta_3.$$

$\mathcal{B}(\mathbb{R})$ est la tribu borélienne engendrée par l'ensemble des ouverts de $\mathbb{R}$.

1. **Calculer $\mu_1\left(\left[0, \frac{3}{2}\right]\right)$.**
2. **Vérifier que μ_1 est une probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.**

Corrigé :

1. $$\mu_1\left(\left[0, \frac{3}{2}\right]\right) = \frac{1}{2}\delta_1\left(\left[0, \frac{3}{2}\right]\right) + \frac{1}{4}\delta_2\left(\left[0, \frac{3}{2}\right]\right) + \frac{1}{4}\delta_3\left(\left[0, \frac{3}{2}\right]\right)$$
$$= \left(\frac{1}{2} \times 1\right) + \left(\frac{1}{4} \times 0\right) + \left(\frac{1}{4} \times 0\right) = \frac{1}{2}.$$
2. **Il suffit de voir que :**
$$\mu_1\left(\mathbb{R}\right) = \frac{1}{2}\delta_1\left(\mathbb{R}\right) + \frac{1}{4}\delta_2\left(\mathbb{R}\right) + \frac{1}{4}\delta_3\left(\mathbb{R}\right) = \frac{1}{2} + \frac{1}{4} + \frac{1}{4} = 1.$$

Espaces probabilisés

Exemples de probabilités :

1) Probabilité sur un espace au plus dénombrable :

Soit I une partie de $\mathbb{N}$. Une probabilité P sur un ensemble au plus dénombrable $\Omega = (\omega_k)_{k\in I}$ est une pondération $(p_k)_{k\in I}$ des éléments de cet ensemble telle que :

- **Pour tout $k \in I$, $p_k \geq 0$,**
- $\sum_{k\in I} p_k = 1$.

On attribue à toute éventualité $\omega_i \in \Omega$ la probabilité $p_i = P(\{\omega_i\})$, et on attribue à tout événement $A \subset \Omega$ la probabilité :

$$P(A) = \sum_{\omega_k \in A} p_k.$$

On peut écrire à l'aide de la mesure de Dirac :

$$P = \sum_{k\in I} p_k \delta_{\omega_k} \quad \textbf{avec} \quad \delta_{\omega_k}(A) = \begin{cases} 1 & \textbf{si } \omega_k \in A, \\ 0 & \textbf{sinon.} \end{cases}$$

Espaces probabilisés

2) Probabilité uniforme :

Si $\Omega = \{\omega_1, ..., \omega_n\}$ est fini et les symétries font que tous les résultats possibles $\omega_1, ..., \omega_n$ sont équiprobables, c-à-d ces résultats ont la même pondération $p_k = \dfrac{1}{Card(\Omega)}$ pour tout $k \in [1 : n]$, alors,

$$\forall\, A \subset \Omega, \quad P(A) = \frac{card(A)}{card(\Omega)}.$$

3) Probabilité conditionnelle :

Soient $(\Omega, \mathcal{A}, P)$ un espace probabilisé et A un événement de $\mathcal{A}$ avec $P(A) \neq 0$. La probabilité conditionnelle, notée P_A ou $P(B|A)$ est définie par :

$$\forall\, B \subset \Omega, \quad P_A(B) = P(B|A) = \frac{P(A \cap B)}{P(A)}.$$

Espaces probabilisés

Propriétés

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé.

- **Pour tout** $A \in \mathcal{A}$, $0 \leq P(A) \leq 1$.
- $P(\bar{A}) = 1 - P(A)$.
- $P(\Omega) = 1$, **(événement certain)**, $P(\emptyset) = 0$, **(événement impossible)**.
- **Si** $A \subset B$ **alors** $P(A) \leq P(B)$ **et** $P(B \setminus A) = P(B) - P(A)$.
- **Soit** A **et** B **deux événements, alors,**

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

- **Inégalité de Boole : soit** $(A_i)_{i \in [1:n]}$ **une suite des événements de** $\mathcal{A}$**, alors,**

$$P\Big(\bigcup_{i=1}^{n} A_i\Big) \leq \sum_{i=1}^{n} P(A_i).$$

Espaces probabilisés

- **Formule de Poincaré : Soit $(A_i)_{1\leq i\leq n}$ une suite des événements de $\mathcal{A}$, alors,**

$$P\Big(\bigcup_{i=1}^{n} A_i\Big) = \sum_{k=1}^{n}(-1)^{k+1} \sum_{1\leq i_1<i_2<\ldots<i_k\leq n}^{n} P(A_{i_1}\cap\ldots\cap A_{i_k}).$$

- **Continuité croissante de P : soit $(A_n)_n$ une suite croissante des événements de $\mathcal{A}$, alors,**

$$P\Big(\bigcup_{n} A_n\Big) = \lim_{n\to+\infty} P(A_n) = \sup_{n} P(A_n).$$

- **Continuité décroissante de P : soit $(A_n)_n$ une suite décroissante des événements de $\mathcal{A}$, alors,**

$$P\Big(\bigcap_{n} A_n\Big) = \lim_{n\to+\infty} P(A_n) = \inf_{n} P(A_n).$$

Espaces probabilisés

Exercice 1 :

Une urne contient cinq boules rouges, trois boules vertes et une boule noire. On suppose que toutes les boules sont indiscernables au toucher. Dans un tirage au hasard, successif et sans remise de trois boules, calculer les probabilités des événements suivants :

1. **A=(Tirer trois boules de même couleur).**
2. **B=(Tirer exactement deux boules rouges).**
3. **C=(Tirer trois boules de couleurs différents deux à deux).**

Corrigé :

1. $P(A) = \dfrac{\textbf{Card}(A)}{\textbf{Card}(\Omega)} = \dfrac{A_5^3 + A_3^3}{A_9^3} = \dfrac{11}{84}.$
2. $P(B) = \dfrac{\textbf{Card}(B)}{\textbf{Card}(\Omega)} = C_3^2 \times \dfrac{A_5^2 \times A_4^1}{A_9^3} = \dfrac{10}{21}.$ **(C_3^2 pour l'ordre des 2R).**
3. $C = (1R, 1V, 1N) \quad P(C) = 3! \times \dfrac{A_5^1 \times A_3^1 \times A_1^1}{A_9^3} = \dfrac{5}{28}$ **(3! pour l'ordre).**

Espaces probabilisés

Exercice 2 :

Soit $n \geq 1$. Déterminer une probabilité P sur $\Omega = [1 : n]$ telle que : pour tout $k \in \Omega$ la probabilité de l'événement $A_k = [1 : k]$ soit proportionnelle à k^2.

Corrigé :

Nous allons déterminer les valeurs $P(\{k\})$ pour tout $k \in \Omega$. Pour cela, nous cherchons tout d'abord la constante de proportionnalité λ.

On a : $1 = P(\Omega) = P([1 : n]) = \lambda n^2$, **donc,** $\lambda = \dfrac{1}{n^2}$.

Maintenant puisque l'événement $\{k\} = A_k \backslash A_{k-1}$, **alors,**

$$P(\{k\}) = P(A_k) - P(A_{k-1}).$$

Finalement, on obtient :

$$P(\{k\}) = \lambda k^2 - \lambda(k-1)^2 = \frac{2k-1}{n^2}.$$

Espaces probabilisés

Probabilité conditionnelle et indépendance :

Définition

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé et A un événement de $\mathcal{A}$ avec $P(A) \neq 0$. On appelle probabilité conditionnelle, notée P_A (ou $P(B|A)$), la probabilité définie pour tout événement B de $\mathcal{A}$ par :

$$P_A(B) = P(B|A) = \frac{P(A \cap B)}{P(A)}.$$

Remarque

$(\Omega, \mathcal{A}, P_A)$ est un espace probabilisé.

Espaces probabilisés

Théorème (probabilités composés)

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé. Si $(A_i)_{1\leq i\leq n}$ est une suites des événements de $\mathcal{A}$ telles que $P(A_1 \cap ..... \cap A_{n-1}) > 0$, alors,

$$P(A_1 \cap ..... \cap A_n) = P(A_1) \times P(A_2|A_1) \times P(A_3|A_2 \cap A_1) \times ..... \times P(A_n|A_{n-1} \cap ..... \cap A_1).$$

Remarque

- **Pour $n = 2$, si $P(A) > 0$, alors,**

$$P(A \cap B) = P(A) \times P(B|A).$$

- **Pour $n = 3$, si $P(A_1 \cap A_2) > 0$, alors,**

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) \times P(A_2|A_1) \times P(A_3|A_2 \cap A_1).$$

Espaces probabilisés

Définition

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé.

- **On dit que $(\mathcal{A}_i)_{i\in[1:n]}$ est une famille indépendante de sous tribus de $\mathcal{A}$ si pour toute famille des événements $(A_i)_{i\in[1:n]}$ où $A_i \in \mathcal{A}_i$, pour tout $i \in [1 : n]$, on a :**

$$P\left(\bigcap_{i=1}^{n} A_i\right) = \prod_{i=1}^{n} P(A_i).$$

- **On dit que les événements $(A_i)_{i\in I}$ sont mutuellement indépendants si pour toute partie J finie et non vide de I, on a :**

$$P\left(\bigcap_{i\in J} A_i\right) = \prod_{i\in J} P(A_i).$$

Espaces probabilisés

Définition

On dit que deux événements A et B sont indépendants si on a :

$$P(A \cap B) = P(A) \times P(B).$$

Exemple :

Nous jetons un dé équilibré et nous considérons les deux événements : $A =$ **(le résultat est impair) et** $B =$ **(le résultat est** ≤ 4**). Alors,**
$\Omega = \{1, \ldots, 6\}$.

$$A = \{1,3,5\} \Longrightarrow P(A) = \frac{3}{6} = \frac{1}{2},$$

$$B = \{1,2,3,4\} \Longrightarrow P(B) = \frac{4}{6} = \frac{2}{3},$$

$$A \cap B = \{1,3\} \Longrightarrow P(A \cap B) = \frac{2}{6} = \frac{1}{3}.$$

On a : $P(A \cap B) = \frac{1}{3} = P(A) \times P(B)$**, donc** A **et** B **sont indépendants.**

Espaces probabilisés

Remarque

- **Si $P(A) \neq 0$, alors A et B sont indépendants ssi $P_A(B) = P(B)$.**
- **Si A et B sont indépendants alors ($\bar{A}$ et B), (A et $\bar{B}$) et ($\bar{A}$ et $\bar{B}$) les sont aussi.**

Exercice :

Soient A et B deux événements d'un espace probabilité $(\Omega, \mathcal{A}, P)$ tels que : $P(A) = \frac{1}{3}$, $P(B) = \frac{1}{4}$ et $P(A \cup B) = \frac{4}{9}$.

1. **Calculer $P_B(A)$, $P_B(\bar{A})$, et $P_B(A \cap \bar{B})$.**
2. **Soit C un événement indépendant de $\mathcal{A}$ tel que $P(A \cap C) = \frac{1}{5}$.**

   Calculer $P(\bar{A} \cap C)$.

Espaces probabilisés

Corrigé :

1. $$P_B(A) = \frac{P(A \cap B)}{P(B)} = \frac{P(A) + P(B) - P(A \cup B)}{P(B)} = \frac{5}{9}.$$

   $$P_B(\bar{A}) = 1 - P_B(A) = \frac{4}{9}.$$

   $$P_B(A \cap \bar{B}) = \frac{P(A \cap \bar{B} \cap B)}{P(B)} = \frac{P(\emptyset)}{P(B)} = 0.$$

2. $$P(\bar{A} \cap C) = P(\bar{A}) \times P(C) = (1 - P(A)) \times \frac{P(A \cap C)}{P(A)} = \frac{2}{5}.$$

Espaces probabilisés

Théorème (des probabilités totales)

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé, et soit $(B_i)_{1\leq i\leq n}$ une partition de Ω, c-à-d : $\Omega = \bigcup_{i=1}^{n} B_i$ et $\forall\ i \neq j,\ B_i \cap B_j = \emptyset$. Soit A un événement quelconque de $\mathcal{A}$, alors,

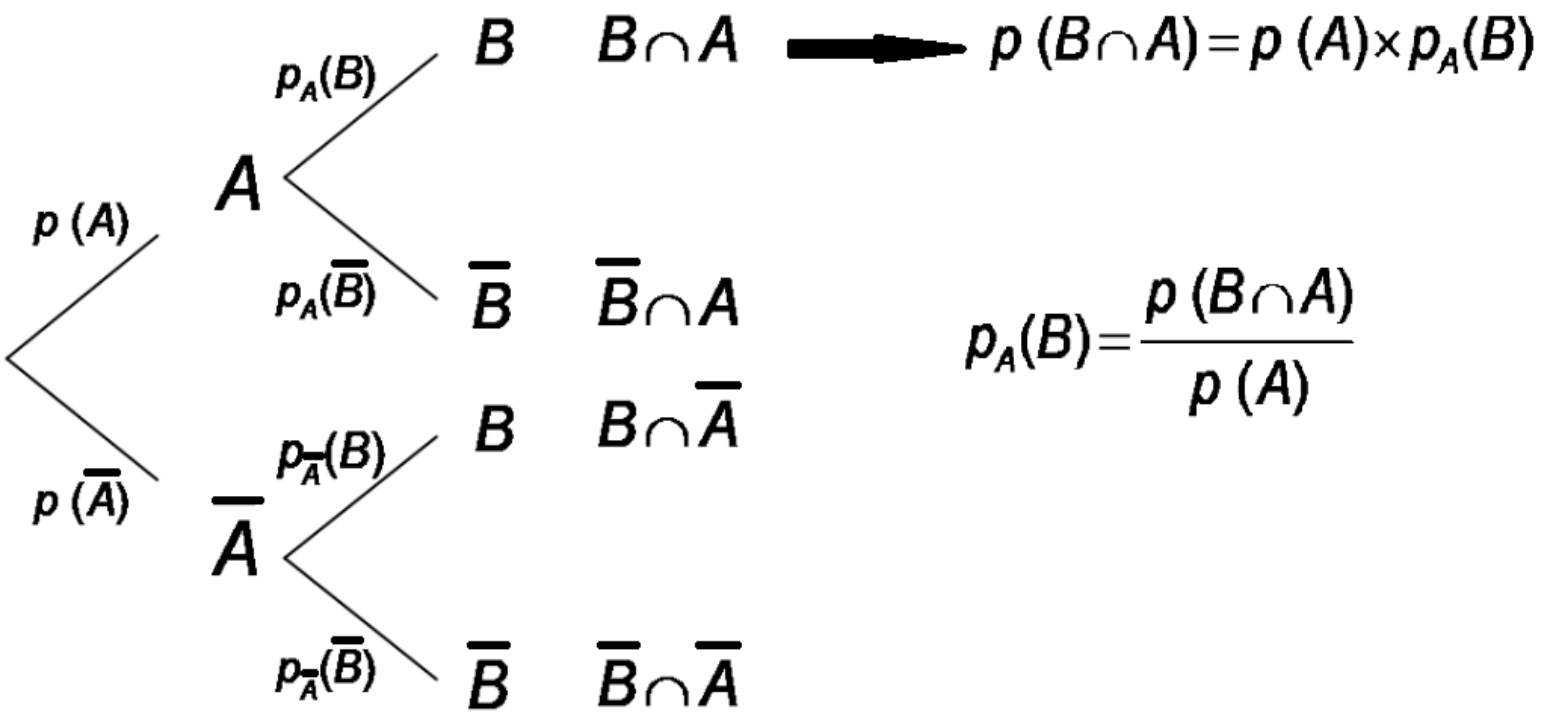
$$P(A) = \sum_{i=1}^{n} P(B_i \cap A) = \sum_{i=1}^{n} P(B_i) \times P_{B_i}(A)$$

Exemple : $(n = 2,\ B_1 = A,\ B_2 = \bar{A})$

$$\begin{aligned} P(B) &= P(A \cap B) + P(\bar{A} \cap B) \\ &= P(A) \times P(B|A) + P(\bar{A}) \times P(B|\bar{A}). \end{aligned}$$

Espaces probabilisés

Un arbre de probabilité pondéré permet d'illustrer aisément la situation :



$$p(B \cap A) = p(A) \times p_A(B)$$

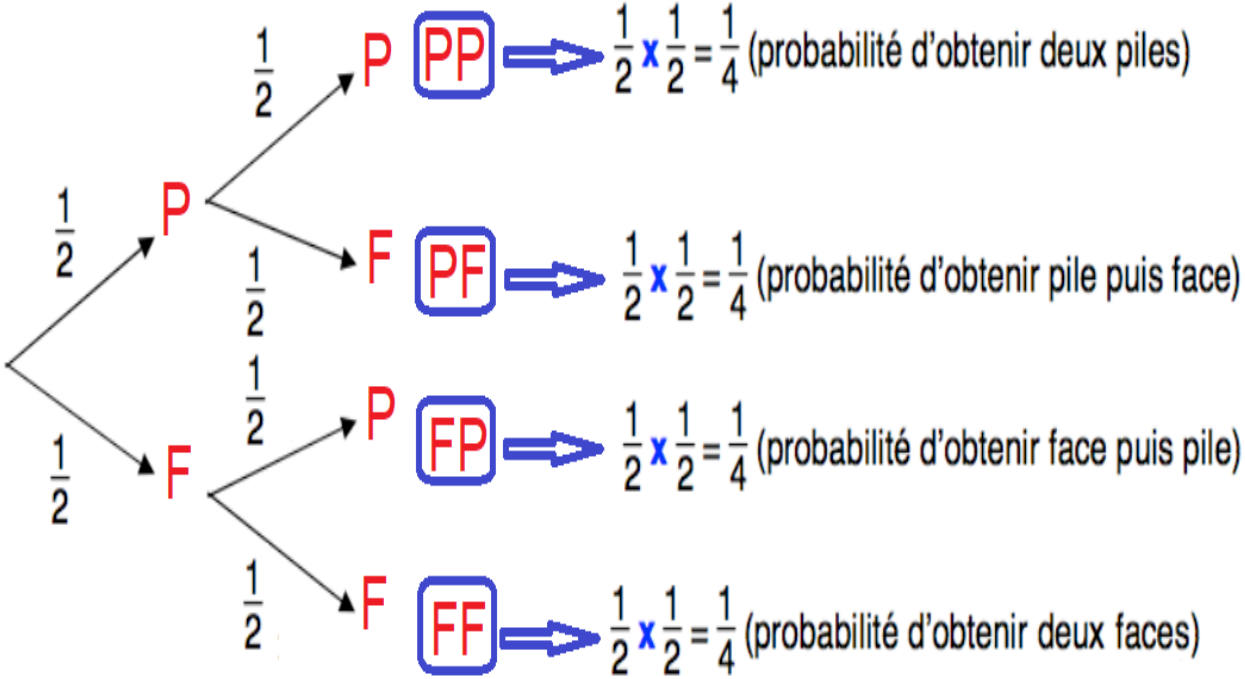
$$p_A(B) = \frac{p(B \cap A)}{p(A)}$$

Espaces probabilisés

Exemple :

Un lancer d'une pièce de monnaie équilibrée deux fois successives donne : $\Omega = \{PP, FF, PF, FP\}$.

On a par exemple : $P(\{PP\} = \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$.



Espaces probabilisés

Théorème (de Bayes)

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé, et soit A un événement de $\mathcal{A}$ tel que $P(A) > 0$, alors pour tout $i \in [1 : n]$, on a :

$$P_A(B_i) = \frac{P(B_i) \times P_{B_i}(A)}{P(A)}$$

$$= \frac{P(B_i) \times P_{B_i}(A)}{\sum_{j=1}^{n} P(B_j) \times P_{B_j}(A)}.$$

Espaces probabilisés

Exemple :

Une population d'adultes est composée de 30% de fumeurs (B_1) et de 70% de non-fumeurs (B_2). Notons A l'événement=(mourir d'un cancer du poumon). Supposons en outre que la probabilité de mourir d'un cancer du poumon est égale à $P(A|B_1) = 20\%$ si l'on est fumeur et de $P(A|B_2) = 1\%$ si l'on est non-fumeur.

Corrigé :

On a $P(B_1) = \dfrac{30}{100} = 0,3$, $P(B_2) = \dfrac{70}{100} = 0,7$ **et** $\Omega = B_1 \cup B_2$.

Les théorèmes des probabilités totales et de Bayes donnent (resp.) :

$$P(A) = \sum_{i=1}^{2} P(A|B_i) \times P(B_i) = P(A|B_1) \times P(B_1) + P(A|B_2) \times P(B_2) \simeq 0,13.$$

$$P(B_1|A) = \frac{P(B_1) \times P(A|B_1)}{\sum_{j=1}^{2} P(B_j) \times P(A|B_j)} = \frac{P(B_1) \times P(A|B_1)}{P(A)} \simeq 0,9.$$

Espaces probabilisés

Espace probabilisé produit :

Jusqu'à présent, on a essentiellement parlé de l'observation d'un phénomène unique. On peut pourtant s'intéresser à un phénomène φ qui est la juxtaposition de n phénomènes φ_i où chaque phénomène φ_i est modélisé par $(\Omega_i, \mathcal{A}_i, P_i)$. Pour modéliser $\varphi = (\varphi_1, ..., \varphi_n)$, il nous faut déterminer l'espace probabilisé $(\Omega, \mathcal{A}, P)$ associé.

Définition

Si ω_i est l'observation du phénomène φ_i, le n-uplet $\omega = (\omega_1, ..., \omega_n)$ est une observation du phénomène φ. On prendra donc comme espace fondamental le produit cartésien :

$$\Omega = \Omega_1 \times ... \times \Omega_n = \prod_{i=1}^{n} \Omega_i.$$

Espaces probabilisés

Intéressons nous maintenant à la construction de la tribu $\mathcal{A}$ sur Ω. Si pour tout $i \in [1:n]$, l'ensemble A_i est un événement de $\mathcal{A}_i$, il est naturel d'attendre que le pavé $A = A_1 \times ... \times A_n$ soit un événement de $\mathcal{A}$. C'est pourquoi on pose la définition suivante :

Définition

On appelle tribu produit des $(\mathcal{A}_i)_{i\in[1:n]}$, et on la note $\mathcal{A} = \mathcal{A}_1 \otimes ... \otimes \mathcal{A}_n$, la tribu engendrée par les pavés mesurables $A_1 \times ... \times A_n$ où A_i appartient à $\mathcal{A}_i$, pour tout $i \in [1:n]$, c-à-d :

$$\mathcal{A} = \sigma\Big(\Big\{A_1 \times ... \times A_n, \quad A_i \in \mathcal{A}_i, \quad i \in [1:n]\Big\}\Big).$$

Espaces probabilisés

Il nous faut maintenant définir une probabilité P sur cet espace produit $(\Omega, \mathcal{A})$, à partir de l'ensemble des $(P_i)_{i\in[1:n]}$.

Théorème

Il existe une probabilité unique P sur l'espace produit $(\Omega, \mathcal{A})$ telle que pour tout A_i dans $\mathcal{A}_i$, pour $i \in [1 : n]$, on a :

$$P\Big(A_1 \times ... \times A_n\Big) = \prod_{i=1}^{n} P_i(A_i).$$

P est appelée probabilité produit des $(P_i)_{i\in[1:n]}$ et est notée $P = P_1 \otimes ... \otimes P_n$. $(\Omega, \mathcal{A}, P)$ est dit un espace probabilisé produit.

Espaces probabilisés

Exemple :

Une urne (A) contient cinq boules noires, deux boules vertes et une boule rouge. Une autre urne (B) contient deux boules noires et une boule verte. On tire au hasard et simultanément, deux boules de l'urne (A) et une boule de l'urne (B). On suppose que toutes les boules sont indiscernables au toucher. Calculer les probabilités des événements suivants :

- **C=(Tirer au moins une boule verte).**
- **D=(Tirer au plus deux boules vertes).**

Corrigé :

1. $\mathbf{Card}(\Omega) = \mathbf{Card}(\Omega_1) \times \mathbf{Card}(\Omega_2) = C_8^2 \times C_3^1 = 84.$
   - $C = \Big((1V) \ ou \ (2V) \ ou \ (3V)\Big).$ • $\bar{C} = ((0V)) = ((3\bar{V})).$
   - $P(C) = 1 - P(\bar{C}) = 1 - \dfrac{\mathbf{Card}(C_1)}{\mathbf{Card}(\Omega_1)} \times \dfrac{\mathbf{Card}(C_2)}{\mathbf{Card}(\Omega_2)} = 1 - \dfrac{C_6^2 \times C_2^1}{84} = \dfrac{9}{14}.$
2. $D = \Big((2V) \ ou \ (1V) \ ou \ (0V)\Big).$ • $\bar{D} = ((3V)).$

Espaces probabilisés

Remarque

- **Il n'est pas évident de généraliser la notion d'espace probabilisé produit à une infinité dénombrable $(\Omega_i, \mathcal{A}_i, P_i)_{i\in\mathbb{N}}$ des espaces probabilisés quelconques.**
- **C'est la mesure de probabilisé produit qui pose problème si on ne fait pas certaines hypothèses sur la structure des espaces probabilisables $(\Omega_i, \mathcal{A}_i)_{i\in\mathbb{N}}$.**
- **Ce type des espaces probabilisés infini est utilisé pour modélisé la répétition d'une infinité d'expériences indépendantes, par exemple : le temps d'attente du premier succès qui est modélisé par la loi géométrique.**

Espaces probabilisés

TD (1) :

Exercice 1 :

On pose pour tout $n \in \mathbb{N}^*$: $P(\{n\}) = \frac{1}{2^n}$ et A_n=\{les multiples de n\}.

1. **Montrer que $(\mathbb{N}^*, \mathcal{P}(\mathbb{N}^*), P)$ est un espace probabilisé.**
2. **Calculer la probabilité de l'événement : $A = \{n \in \mathbb{N}^*, n \geq 10\}$.**
3. **Vérifier que : $\forall\ n \in \mathbb{N}^*, \quad P(A_n) = \frac{1}{2^n - 1}$.**
4. **Calculer la probabilité de $A_2 \cap A_3$ puis $A_2 \cup A_3$.**
5. **Montrer par absurde que pour tous $p, q \geq 2$, A_p et A_q ne sont pas indépendants. (Utiliser le ppcm de p et q).**

Espaces probabilisés

Exercice 2 :

Considérons la mesure discrète sur $(\mathbb{N}^*, \mathcal{P}(\mathbb{N}^*)$ définie par :

$$\mu_2 = \sum_{n=1}^{+\infty} \frac{3}{2^n} \delta_n.$$

1. **Soit $k \in \mathbb{N}^*$. Calculer $\mu_2([1:k])$, puis $\mu_2(\mathbb{N}^*)$.**
2. **μ_2 est-elle une probabilité sur $(\mathbb{N}^*, \mathcal{P}(\mathbb{N}^*)$.**

Espaces probabilisés

Exercice 3 :

I) 1.1 **Soit $n \geq 1$. Démontrer qu'il existe une unique probabilité sur $\Omega = [-n : n]$ définie pour tout $k \in [-n : n]$ par :**

$$P(\{k\}) = \frac{n+1-|k|}{(n+1)^2}.$$

1.2 **Calculer $P(A)$ la probabilité de l'événement $A = [-n+1 : n-1]$.**

II) 2.1 **Démontrer qu'il existe une unique probabilité sur $\mathbb{N}$ définie pour tout $n \in \mathbb{N}$ par :**

$$P(\{n\}) = \frac{1}{(n+1)(n+2)}.$$

2.2 **Calculer $P(B)$ ou B est l'ensemble des nombres pairs.**
On admettra qu'il existe une constante γ telle que :

$$\sum_{k=1}^{N} \frac{1}{k} = \ln(N) + \gamma + o(1).$$

Espaces probabilisés

Exercice 4 :

On sait qu'à une date donnée, 3% d'une population est atteinte d'une "hépatite". On dispose de tests de dépistage de la maladie :
si la personne est malade, alors le test est positif avec une probabilité de 95%,
si la personne est saine, alors le test est positif avec une probabilité de 10%.

1. **Tracer l'arbre pondérée des probabilités.**
2. **Quelle est la probabilité pour une personne d'être malade si son test est positif ?**
3. **Quelle est la probabilité pour une personne d'être saine si son test est positif ?**
4. **Quelle est la probabilité pour une personne d'être malade si son test est négatif ?**
5. **Quelle est la probabilité pour une personne d'être saine si son test est négatif ?**

Espaces probabilisés

Exercice 5 :

Une urne (U_1) contient six boules vertes et trois boules rouges.
Une autre urne (U_2) contient quatre boules vertes et une boule rouge.
On suppose que toutes les boules sont indiscernables au toucher.

I) On choisit au hasard et simultanément deux boules de (U_1) et une boule de (U_2). Calculer les probabilités des événements suivants :

1. A=(Tirer trois boules vertes).
2. B=(Tirer au moins une boule verte).

II) On choisit au hasard une urne, puis on tire au hasard, successivement et sans remise, deux boules. On suppose que les deux urnes ont la même probabilité d'être tirées.

1. Tracer l'arbre pondérée des probabilités.
2. Calculer les probabilités des événements suivants :
   C = (Tirer au plus une boule verte).
   D = (Tirer exactement une seule boule verte).
   E = (Choisir l'urne U_1 sachant qu'on a tiré deux boules vertes).

Plan :

1. Rappel sur les espaces probabilisés
2. Rappel sur les variables aléatoires
3. Fonctions génératrice et caractéristique
4. Vecteurs aléatoires, Vecteurs Gaussiens
5. Espérance conditionnelle
6. Convergences et approximations

Variables aléatoires

Descriptif du chapitre 2 :

- **Fonctions mesurables.**
- **Loi de probabilité d'une variable aléatoire.**
- **Densité de probabilité.**
- **Espérance, variance et moments.**
- **Fonction de répartition.**
- **Lois usuelles discrètes et à densité.**
- **Table statistique et loi gaussienne.**

Variables aléatoires

Fonction mesurable :

Définition

Soient $(E, \mathcal{A})$ et $(F, \mathcal{B})$ deux espaces mesurables. Une fonction $f : E \to F$ est dite mesurable si $f^{-1}(B) \in \mathcal{A}$ pour tout $B \in \mathcal{B}$.

On dit que f est borélienne si $\mathcal{B}$ est une tribu borélienne.

Variable aléatoire :

Définition

Soit $(\Omega, \mathcal{A})$ un espace probabilisable, où Ω est un univers associée à une expérience aléatoire, et soit $(E, \mathcal{B})$ un espace mesurable. Toute application mesurable X de $(\Omega, \mathcal{A})$ vers $(E, \mathcal{B})$ est dite une variable aléatoire, (notée v.a).

L'événement $X^{-1}(B) = \{\omega \in \Omega \ : \ X(\omega) \in B\}$ est noté par : $(X \in B)$.

Variables aléatoires

Notations :

Nous verrons dans la suite la classification des v.a(s) grâce au théorème de Radon Nikodym. Pour l'instant, notons qu'on étudie le plus souvent les v.a(s) quand l'espace d'arrivée est souvent :

- $(E, \mathcal{B}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$, **alors l'application** X **est dite variable aléatoire réelle, (notée v.a.r). Dans ce cas, pour tout intervalle** I **de** $\mathbb{R}$**, on a :** $(X \in I) \in \mathcal{A}$. **De plus, pour tout réel** x**, on note :** $(X \leq x) = \{\omega \in \Omega \ : \ X(\omega) \leq x\} = X^{-1}\Big(]-\infty, x]\Big)$.
- $(E, \mathcal{B}) = (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$, **alors l'application** $X = (X_1, \ldots, X_n)$ **est dite vecteur aléatoire.**
- E **est au plus dénombrable et** $\mathcal{B} = \mathcal{P}(E)$, **alors l'application** X **est dite variable aléatoire discrète, (notée v.a.d).**

Variables aléatoires

Lois de probabilité d'une variable aléatoire :

Définition

Soit X une v.a de $(\Omega, \mathcal{A}, P)$ vers $(E, \mathcal{B})$. On appelle loi de probabilité de X et on la note P_X, la probabilité image de P par X définie sur $(E, \mathcal{B})$ par :

$$\forall\, B \in \mathcal{B} \ : \quad P_X(B) = P(X^{-1}(B)).$$

Proposition

$(E, \mathcal{B}, P_X)$ est un espace probabilisé.

Variables aléatoires

Preuve :

- $\forall\, B \in \mathcal{B}\ :\ P_X(B) = P(X^{-1}(B)) \Longrightarrow 0 \leq P_X(B) \leq 1.$
- $P_X(E) = P(X^{-1}(E)) = P(\Omega) = 1.$
- **Soit $(B_n)_n$ une suite des événements deux à deux disjoints dans $\mathcal{B}$, alors,**

$$P_X\Big(\bigcup_n B_n\Big) = P\Big(X^{-1}\Big(\bigcup_n B_n\Big)\Big) = P\Big(\bigcup_n \Big(X^{-1}(B_n)\Big)\Big)$$

$$= \sum_n P\Big(X^{-1}(B_n)\Big) = \sum_n P_X(B_n),$$

car P est une probabilité sur $(\Omega, \mathcal{A})$.

Variables aléatoires

Espérance d'une variable aléatoire :

Définition

Soit X une v.a de $(\Omega, \mathcal{A}, P)$ vers $(E, \mathcal{B})$ et g une application mesurable de $(E, \mathcal{B})$ vers $\mathbb{R}$. Si $g(X)$ est dans $L^1(\Omega, \mathcal{A}, P)$, (c-à-d : $g(X)$ est intégrable), alors l'espérance de $g(X)$ est définie par :

$$E(g(X)) = \int_\Omega g(X)dP = \int_\Omega g(X(\omega))dP(\omega).$$

Théorème (de transfert)

Soit X une v.a de $(\Omega, \mathcal{A}, P)$ vers $(E, \mathcal{B})$ et de loi de probabilité P_X, et soit g une application mesurable de $(E, \mathcal{B})$ vers $\mathbb{R}$. Si $g(X) \in L^1(\Omega, \mathcal{A}, P)$, alors,

$$E(g(X)) = \int_{\mathbb{R}} g(x)dP_X(x).$$

Variables aléatoires

Théorème de Radon-Nikodym :

Définition

Soit $(E, \mathcal{A}, \mu)$ un espace mesuré et ν une mesure sur $(E, \mathcal{A})$. On dit que ν est absolument continue par rapport à μ, (et on note $\nu \ll \mu$), si pour tout $A \in \mathcal{A}$: $\mu(A) = 0 \Longrightarrow \nu(A) = 0$.

Théorème

Soit $(E, \mathcal{A}, \mu)$ un espace mesuré et ν une mesure sur $(E, \mathcal{A})$. On suppose que μ et ν sont σ-finies. Alors ν est absolument continue par rapport à μ si et seulement s'il existe une fonction mesurable $f : (E, \mathcal{A}) \to (\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+))$ telle que, pour tout $A \in \mathcal{A}$, on a : $\nu(A) = \int_A f(x) d\mu(x)$.

La fonction f s'appelle alors la dérivée de Radon-Nikodym de ν par rapport à μ, et est parfois notée $\frac{d\nu}{d\mu}$.

Variables aléatoires

Remarque

- **Si P_X est absolument continue par rapport à la mesure de Lebesgue, et de densité f_X, (au sens de Radon-Nikodym : $dP_X(x) = f_X(x)dx$), alors,**

$$E(g(X)) = \int_{\mathbb{R}} g(x) f_X(x) dx,$$

avec $\int_{\mathbb{R}} f_X(x)dx = 1.$

- **Si P_X est absolument continue par rapport à la mesure de comptage, et de densité $P_X(x) = P(X = x)$, alors,**

$$E(g(X)) = \sum_{x \in E} g(x) P(X = x),$$

avec $E = X(\Omega) = \{x_1, x_2, \ldots\ldots\}$ **et** $\sum_{x \in E} P_X(x)dx = 1.$

Variables aléatoires

Fonction de répartition :

Définition

Soit X une v.a définie sur $(\Omega, \mathcal{A}, P)$ et de loi de probabilité P_X. La fonction de répartition de X, notée F_X, est une application définie sur $\mathbb{R}$ par :

$$F_X(x) = P(X \leq x) = P_X\Big(]-\infty, x]\Big).$$

Remarque

- **Si P_X est absolument continue par rapport à la mesure de Lebesgue, et de densité f_X, alors,** $F_X(x) = \int_{-\infty}^{x} f_X(t)dt.$
- **Si P_X est absolument continue par rapport à la mesure de comptage, et de densité $P(X = x)$, alors,** $F_X(x) = \sum_{y \leq x} P(X = y).$

Variables aléatoires

Exemple 1 (cas discret) :

Dans un lancer de deux pièces de monnaie équilibrées, l'ensemble des résultats possibles est : $\Omega = \{(P,P),(F,P),(P,F),(F,F)\}$.

Considérons la v.a.d X **représentant le nombre de faces obtenues.**

Les valeurs prises par X **sont :** $E = X(\Omega) = \{0,1,2\}$. **On a :**

$$P_X(0) = P(X=0) = P(\textbf{obtenir 0 faces}) = P(PP) = \frac{1}{4},$$

$$P_X(1) = P(X=1) = P(\textbf{obtenir 1 face}) = P(PF,FP) = \frac{2}{4} = \frac{1}{2},$$

$$P_X(2) = P(X=2) = P(\textbf{obtenir 2 faces}) = P(FF) = \frac{1}{4}.$$

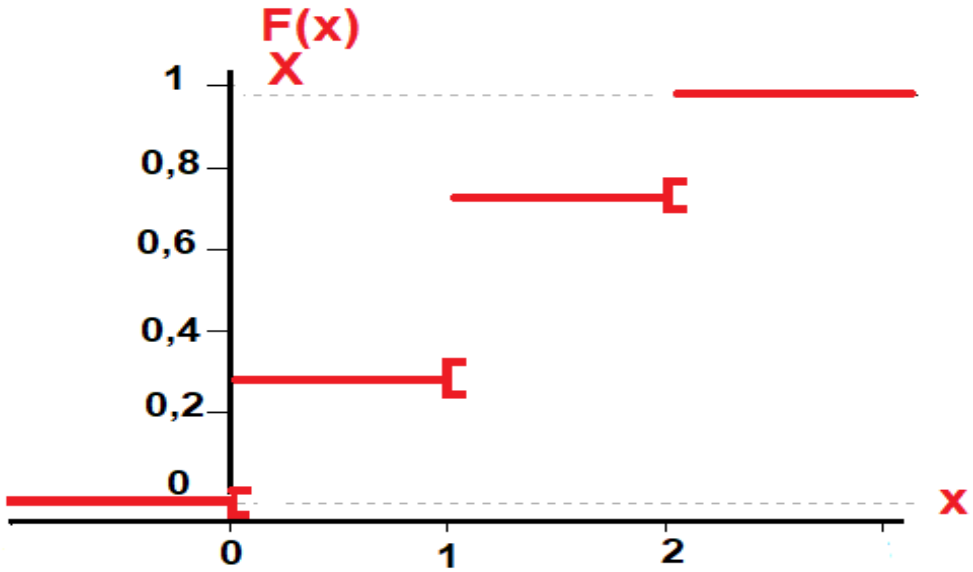
x	**0**	**1**	**2**	$\sum$
$P_X(x) = P(X=x)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	**1**

$$E(X) = \sum_{x=0}^{2} xP(X=x) = \left(0 \times \frac{1}{4}\right) + \left(1 \times \frac{1}{2}\right) + \left(2 \times \frac{1}{4}\right) = 1.$$

Variables aléatoires

Par exemple : $F_X(0) = P(X \leq 0) = P(X = 0) = \frac{1}{4}, \ldots$ **etc...**

$$F_X(x) = \begin{cases} 0, & x < 0 \\ P(X = 0) = \frac{1}{4}, & 0 \leq x < 1 \\ P(X = 1) + P(X = 0) = \frac{1}{4} + \frac{1}{2} = \frac{3}{4}, & 1 \leq x < 2 \\ 1, & x \geq 2. \end{cases}$$



Variables aléatoires

Exemple 2 (cas continu) :

Soit X une v.a définie sur $(\Omega, \mathcal{A}, P)$, et de densité de probabilité :

$$f_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ \lambda \exp(-\lambda x) & \text{si } x \geq 0 \end{cases} \qquad (\lambda > 0).$$

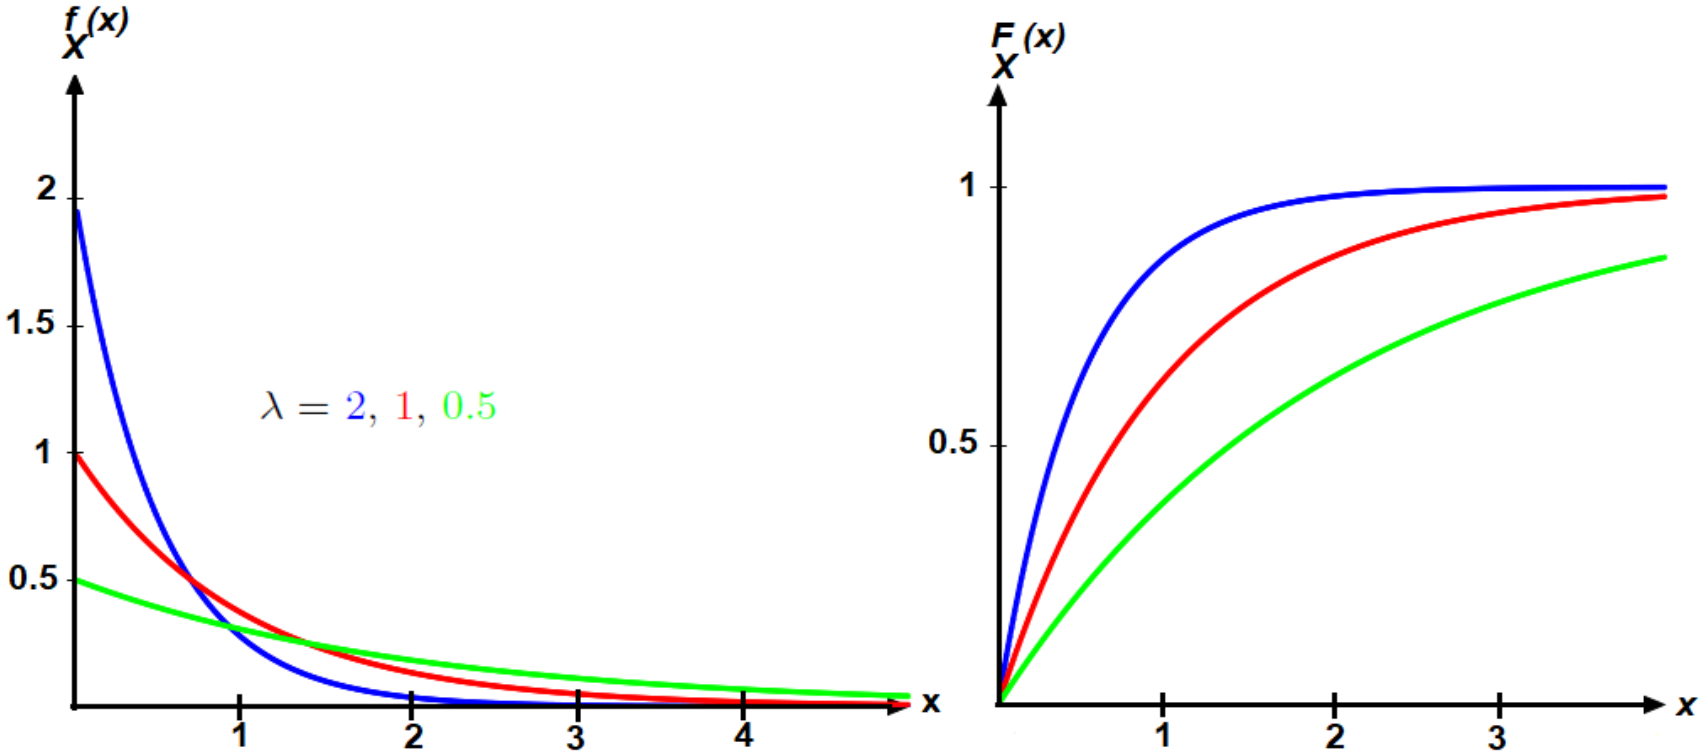
Alors, $F_X(x) = 0$ si $x < 0$, et si $x \geq 0$, on a :

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)dt = \int_0^x \lambda \exp(-\lambda t)dt = 1 - \exp(-\lambda x).$$

Des intégrations par parties simple nous donnent :

$$\begin{aligned} E(X) &= \int_{-\infty}^{+\infty} x f_X(x)dx = \int_0^{+\infty} x\lambda \exp(-\lambda x)dx \\ &= \Big[-x \exp(-\lambda x) \Big]_0^{+\infty} + \int_0^{+\infty} \exp(-\lambda x)dx \\ &= \Big[-\frac{1 + x\lambda}{\lambda} \exp(-\lambda x) \Big]_0^{+\infty} = \frac{1}{\lambda}. \end{aligned}$$

Variables aléatoires



Variables aléatoires

Propriétés

Soit X une v.a définie sur $(\Omega, \mathcal{A}, P)$ et soit F_X sa fonction de répartition.

1. **F_X est à valeurs dans $[0,1]$ et F_X est croissante sur $\mathbb{R}$.**
2. $\lim\limits_{x \longrightarrow -\infty} F_X(x) = 0$ **et** $\lim\limits_{x \longrightarrow +\infty} F_X(x) = 1$.
3. **F_X est continue à droite en tout point de $\mathbb{R}$.**
4. **En tout point $x \in \mathbb{R}$, F_X admet une limite à gauche notée $F_X(x^-)$.**
5. **Pour tout $x \in \mathbb{R}$: $P(X < x) = F_X(x^-)$.**
6. **Pour tout $x \in \mathbb{R}$: $P(X = x) = F_X(x) - F_X(x^-)$.**
7. **Si $x < y$, alors : $P(x < X \leq y) = F_X(y) - F_X(x)$.**
8. **L'ensemble des points de discontinuité de F_X est au plus dénombrable.**
9. **La fonction de répartition caractérise la loi : deux v.a(s) ont la même loi si et seulement s'ils ont la même fonction de répartition.**

Variables aléatoires

Remarque

Le point (7) dans la proposition précédente permet de retrouver facilement la loi d'une variable aléatoire discrète X à travers sa fonction de répartition F_X.

Dans l'exemple (1) précédent, on a :

$$F_X(x) = \begin{cases} 0, & x < 0 \\ P(X=0) = \frac{1}{4}, & 0 \leq x < 1 \\ P(X=1) + P(X=0) = \frac{1}{4} + \frac{1}{2} = \frac{3}{4}, & 1 \leq x < 2 \\ 1, & x \geq 2. \end{cases}$$

Par conséquent,

$$P(X=0) = F_X(0) - F_X(0^-) = \frac{1}{4} - 0 = \frac{1}{4}.$$
$$P(X=1) = F_X(1) - F_X(1^-) = \frac{3}{4} - \frac{1}{4} = \frac{1}{2}.$$
$$P(X=2) = F_X(2) - F_X(2^-) = 1 - \frac{3}{4} = \frac{1}{4}.$$

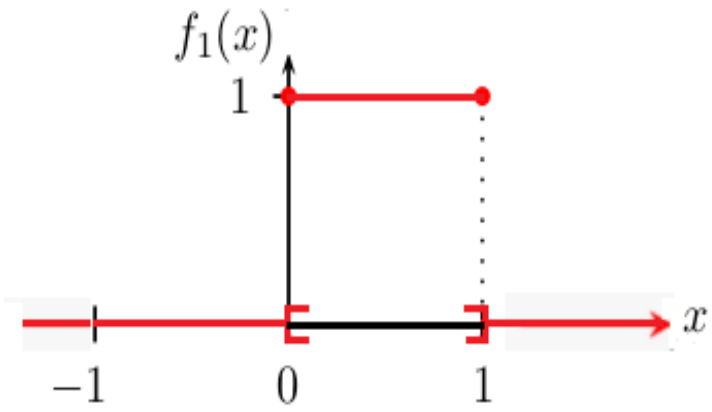
Variables aléatoires

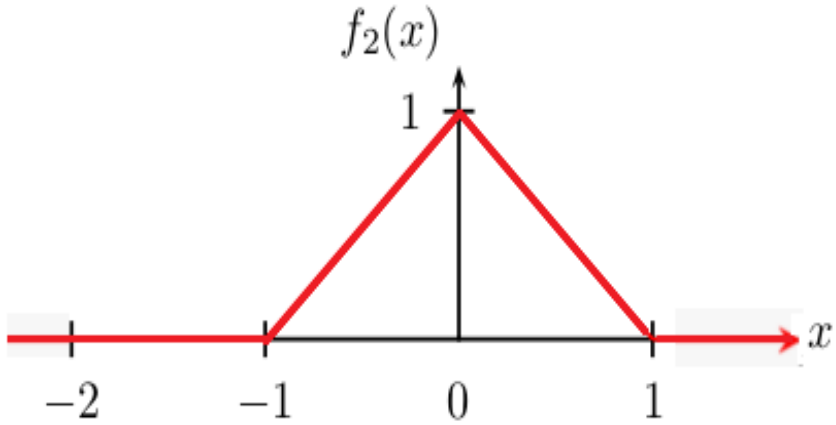
Définition

On appelle densité de probabilité sur $\mathbb{R}$ toute fonction $f : \mathbb{R} \to \mathbb{R}$ vérifiant :

- **f est positive sur $\mathbb{R}$.**
- **f est continue par morceaux sur $\mathbb{R}$ sauf en un nombre fini de points.**
- $\int_{-\infty}^{+\infty} f(x)dx = 1.$

Exemples :





Variables aléatoires

Propriétés

Soit X une v.a définie sur $(\Omega, \mathcal{A}, P)$, de densité de probabilité f_X, et soit F_X sa fonction de répartition, alors,

- **Pour tout réel x,** $P(X = x) = 0$.
- **Pour tout intervalle $I \in \mathcal{B}(\mathbb{R})$,** $P_X(I) = P(X \in I) = \int_I f_X(x)dx$.
- **Pour tous réels a, b :** $P(a \leq X \leq b) = \int_a^b f_X(x)dx$.
- **Pour tous réels a, b :** $P(a \leq X \leq b) = F_X(b) - F_X(a)$.
- **Si f_X est continue sur $\mathbb{R}$, alors** $F'_X(x) = f_X(x)$.

Variables aléatoires

- Lois discrètes usuelles :

Nom	Loi
Bernoulli $\mathcal{B}(p)$	$\mathbb{P}(X=1)=p=1-\mathbb{P}(X=0)$
binomiale $\mathcal{B}(n,p)$	$\forall 0\leq k\leq n,\ \mathbb{P}(X=k)=C_n^k\, p^k(1-p)^{n-k}$
Poisson $\mathcal{P}(\lambda)$	$\forall n\in\mathbb{N},\ \mathbb{P}(X=n)=\exp(-\lambda)\frac{\lambda^n}{n!}$
géométrique $\mathcal{G}eo(p)$	$\forall n\in\mathbb{N}^*,\ \mathbb{P}(X=n)=p(1-p)^{n-1}$

- Densités usuelles sur $\mathbb{R}$:

Nom	Densité
uniforme $\mathcal{U}[a,b]$	$\frac{1}{b-a}\,1_{[a,b]}(x)$
exponentielle $\mathcal{E}(\lambda)$	$\lambda\exp(-\lambda x)1_{\{x\geq 0\}}$
normale $\mathcal{N}(m,\sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}}\ \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$
Cauchy $\mathcal{C}(a)$	$\frac{a}{\pi}\ \frac{1}{x^2+a^2}$

Variables aléatoires

Indépendance des variables aléatoires :

Soit $(X_i)_{i\in[1:n]}$ une suite de v.a définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$, et à valeurs respectivement dans $(E_i, \mathcal{B}_i)_{i\in[1:n]}$.

Définition

La famille $(X_i)_{i\in[1:n]}$ est dite indépendante si et seulement si pour tous $(B_i)_{i\in[1:n]}$ où $B_i \in \mathcal{B}_i$, pour tout $i \in [1 : n]$, on a :

$$P\left(\bigcap_{i=1}^{n}\left(X_i \in B_i\right)\right) = \prod_{i=1}^{n} P(X_i \in B_i).$$

Théorème

La suite $(X_i)_{i\in[1:n]}$ est indépendante si et seulement si pour toutes fonctions g_i, mesurables et bornées, de $(E_i, \mathcal{B}_i)$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, on a :

$$E\Big(\prod_{i=1}^{n} g_i(X_i)\Big) = \prod_{i=1}^{n} E(g_i(X_i)).$$

Variables aléatoires

Remarque

Soient $X_1, \ldots, X_n$ n v.a.d(s) définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$ et à valeurs (resp.) dans $E_1, \ldots, E_n$. On dit que $X_1, \ldots, X_n$ sont indépendantes si et seulement si :

$$\forall x_1 \in E_1, \ldots, \forall x_n \in E_n, \quad P\Big((X_1 = x_1) \cap, \ldots, \cap (X_n = x_n)\Big) = \prod_{i=1}^{n} P(X_i = x_i).$$

Exemple :

Si A et B sont deux événements indépendants. Alors les deux v.a.d(s) χ_A et χ_B sont aussi indépendantes. En effet,

$$P((\chi_A = 1) \cap (\chi_B = 1)) = P(A \cap B) = P(A)P(B) = P(\chi_A = 1) \times P(\chi_B = 1).$$

$$P((\chi_A = 0) \cap (\chi_B = 0)) = P(\bar{A} \cap \bar{B}) = P(\bar{A})P(\bar{B}) = P(\chi_A = 0) \times P(\chi_B = 0).$$

$$P((\chi_A = 0) \cap (\chi_B = 1)) = P(\bar{A} \cap B) = P(\bar{A})P(B) = P(\chi_A = 0) \times P(\chi_B = 1).$$

Variables aléatoires

Proposition

Soient $X_1, \ldots, X_n$ n v.a(s) indépendantes et définies sur le même espace $(\Omega, \mathcal{A}, P)$. Si tous les $E(X_i^2)$, $i \in [1:n]$ existent, alors $V\left(\sum_{i=1}^{n} X_i\right)$ existe et :

$$V\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} V(X_i).$$

Application :

On sait que si $X_1, \ldots, X_n$ sont n v.a.d(s) indépendantes définies sur le même espace $(\Omega, \mathcal{A}, P)$ et suivant chacune une loi de Bernoulli $\mathcal{B}(p)$, alors la v.a.d $X = X_1 + \ldots + X_n$ suit la loi Binomiale $\mathcal{B}(n, p)$. Dans ce cas, on a :

$$E(X) = \sum_{i=1}^{n} E(X_i) = E(X_1) \sum_{i=1}^{n} 1 = np.$$

$$V(X) = \sum_{i=1}^{n} V(X_i) = V(X_1) \sum_{i=1}^{n} 1 = np(1-p).$$

Variables aléatoires

Exemples de calcul des lois de probabilités :

Exemple 1 :

Soient $X \sim \mathcal{P}(\lambda)$ et $Y \sim \mathcal{P}(\mu)$ deux v.a.d(s) indépendantes. Montrer que $Z \sim \mathcal{P}(\lambda+\mu)$.

Correction :

$$P(Z=z) = P((Z=z)\cap\Omega) = P\Big((X+Y=z)\cap\bigcup_{x=0}^{+\infty}(X=x)\Big)$$

$$= P\Big(\bigcup_{x=0}^{+\infty}((Y=z-X)\cap(X=x))\Big)$$

$$= \sum_{x=0}^{z} P(X=x)P(Y=z-x) \quad \textbf{(par indépendance)}$$

$$= \sum_{x=0}^{z} \frac{e^{-\lambda}\lambda^{x}}{x!}\cdot\frac{e^{-\mu}\lambda^{z-x}}{(z-x)!} = \frac{e^{-(\lambda+\mu)}(\lambda+\mu)^{z}}{z!} \quad \textbf{(binôme de Newton)}$$

Variables aléatoires

Exemple 2 :

Soit X une v.a sur $(\Omega, \mathcal{A}, P)$ de densité de probabilités f_X et de fonction de répartition F_X. Trouver la loi de $Z = X^2$.

Correction :

- $x \leq 0 \Longrightarrow F_Z(x) = P(Z \leq x) = 0.$
- $x > 0 \Longrightarrow F_Z(x) = P(Z \leq x) = P\left(-\sqrt{x} \leq X \leq \sqrt{x}\right) = F_X(\sqrt{x}) - F_X(-\sqrt{x}).$

En dérivant on obtient la densité de Z :

$$f_Z(x) = F_Z'(x) = \begin{cases} 0 & \text{si } x \leq 0, \\ \dfrac{1}{2\sqrt{x}}\left(f_X(\sqrt{x}) + f_X(-\sqrt{x})\right) & \text{si } x > 0. \end{cases}$$

Variables aléatoires

Exemple 3 :

Soit X une v.a sur $(\Omega, \mathcal{A}, P)$ de densité f_X et de fonction de répartition F_X.
Trouver la loi de $U = \exp(X)$.

Correction :

- $x \leq 0 \Rightarrow F_U(x) = P(U \leq x) = 0.$
- $x > 0 \Rightarrow F_U(x) = P\Big(U \leq x\Big) = P\Big(X \leq \ln(x)\Big) = F_X(\ln(x)).$

En dérivant on obtient la densité de U :

$$f_U(x) = F'_U(x) = \begin{cases} 0 & \text{si } x \leq 0, \\ \dfrac{1}{x} f_X(\ln(x)) & \text{si } x > 0. \end{cases}$$

Variables aléatoires

Une autre caractérisation de la densité :

Théorème (méthode de la fonction muette)

Soit X une v.a sur $(\Omega, \mathcal{A}, P)$. Alors X est de densité de probabilité f_X si et seulement si pour toute fonction bornée $g : \mathbb{R} \to \mathbb{R}$, on a :

$$E(g(X)) = \int_{\mathbb{R}} g(x) f_X(x) dx.$$

Exemple :

Soit X une v.a sur $(\Omega, \mathcal{A}, P)$ de densité f_X et de fonction de répartition F_X.

Trouver la loi de $Y = aX + b$.

Variables aléatoires

Correction :

Pour $Y = aX + b$ et $a > 0$. Le changement de variable $y = ax + b$ nous donne :

$$E(g(Y)) = E(g(aX+b)) = \int_{\mathbb{R}} g(ax+b) f_X(x) dx = \int_{\mathbb{R}} g(y) f_X\left(\frac{y-b}{a}\right) \frac{dy}{a}.$$

D'autre part, on a :

$$E(g(Y)) = \int_{\mathbb{R}} g(y) f_Y(y) dy.$$

Par conséquent,

$$f_Y(x) = \frac{1}{a} f_X\left(\frac{x-b}{a}\right).$$

On fait de même pour $a < 0$.

N.B : On peut suivre le chemin de la fonction de répartition.

Variables aléatoires

Moments d'une variable aléatoire réelle :

Définition

Soit X une v.a définie sur $(\Omega, \mathcal{A}, P)$.

- **Si $X \in L^1(\Omega, \mathcal{A}, P)$, on définit l'espérance de X par :**

$$E(X) = \int_\Omega X dP.$$

- **Si $X \in L^p(\Omega, \mathcal{A}, P)$, $(p \geq 1)$, on définit le moment d'ordre p de X par :**

$$E(X^p) = \int_\Omega X^p dP.$$

- **Si $X \in L^2(\Omega, \mathcal{A}, P)$, on définit la variance et l'écart type de X par :**

$$V(X) = E\Big((X - E(X))\Big)^2 \quad \text{et} \quad \sigma(X) = \sqrt{V(X)}.$$

Variables aléatoires

Remarque

- **Si P_X est absolument continue par rapport à la mesure de Lebesgue, et de densité de probabilité f_X, alors,**

$$E(X^p) = \int_{\mathbb{R}} x^p dP_X(x) = \int_{\mathbb{R}} x^p f_X(x) dx.$$

$$V(X) = \int_{\mathbb{R}} (x - E(X))^2 dP_X(x) = \int_{\mathbb{R}} (x - E(X))^2 f_X(x) dx.$$

- **Si P_X est absolument continue par rapport à la mesure de comptage, et de densité $P_X(x) = P(X = x)$, alors,**

$$E(X^p) = \sum_x x^p P(X = x).$$

$$V(X) = \sum_x (x - E(X))^2 P(X = x).$$

Variables aléatoires

Propriétés

Si X est une v.a intégrable sur $(\Omega, \mathcal{A}, P)$, alors,

- **Positivité : si $X \geq 0$, alors $E(X) \geq 0$.**
- **Croissance : si $X \leq Y$, alors $E(X) \leq E(Y)$.**
- **Linéarité : $E(aX + bY) = aE(X) + bE(Y)$ pour tous réels a et b.**
- **Si $X = a$, alors $E(X) = a$.**
- $\forall A \in \mathcal{A}$, $E(1_A) = P(A)$.
- **Inégalité de Jensen : soit g est une fonction définie sur un intervalle de $I \subset \mathbb{R}$, convexe et continue. Si X est une v.a à valeurs dans I telle que $E(X)$ existe, alors,**

$$g\Big(E(X)\Big) \leq E\Big(g(X)\Big).$$

En particulier : $|E(X)| \leq E|X|$.

Variables aléatoires

Si de plus X et Y sont de carré intégrable sur $(\Omega, \mathcal{A}, P)$, alors,

- $V(X) \geq 0$.
- $V(X) = 0$ **si et seulement si** $X = 0$.
- **Formule König-Huygens :** $V(X) = E(X^2) - (E(X))^2$.
- **Pour tous réels** a **et** b, $V(aX + b) = a^2 V(X)$.
- **Si on pose :**

$$Y = \frac{X - E(X)}{\sqrt{V(X)}} = \frac{X - E(X)}{\sigma(X)},$$

alors $E(Y) = 0$ **et** $V(Y) = 1$. **On dit que** Y **est une v.a centrée réduite.**

Variables aléatoires

Exemples :

1. **Si $X \sim \mathcal{P}(\lambda)$, alors,**

$$E(X) = \sum_{x=0}^{+\infty} x P_X(x) = \sum_{x=0}^{+\infty} x e^{-\lambda} \frac{\lambda^x}{x!} = e^{-\lambda} \sum_{x=1}^{+\infty} \frac{\lambda^x}{(x-1)!} = \lambda e^{-\lambda} \sum_{x=0}^{+\infty} \frac{\lambda^x}{x!} = \lambda.$$

2. **Si $X \sim \mathcal{E}(\lambda)$, alors,**

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx = \int_0^{+\infty} \lambda x e^{-\lambda x} dx = \frac{1}{\lambda}.$$

$$V(X) = E\Big((X - E(X)\Big)^2 = \int_{-\infty}^{+\infty} \Big(x - E(X)\Big)^2 f_X(x) dx$$

$$= \int_0^{+\infty} \lambda \Big(x - \frac{1}{\lambda}\Big)^2 e^{-\lambda x} dx = \frac{1}{\lambda^2}.$$

$$\sigma(X) = \sqrt{V(X)} = \frac{1}{\lambda}.$$

Variables aléatoires

	Notation	Paramètres	Loi de X	$\mathbb{E}(X)$	$\mathbb{V}(X)$
Loi uniforme	$\mathcal{U}([\![1,n]\!])$	$n \in \mathbb{N}^*$	$X(\Omega) = [\![1,n]\!]$ $\forall k \in [\![1,n]\!],\ \mathbb{P}\big([X=k]\big) = \dfrac{1}{n}$	$\dfrac{n+1}{2}$	$\dfrac{n^2-1}{12}$
	$\mathcal{U}([\![a,b]\!])$	$(a,b) \in \mathbb{N}^2$ $b \geqslant a$	$X(\Omega) = [\![a,b]\!]$ $\forall k \in [\![a,b]\!],\ \mathbb{P}\big([X=k]\big) = \dfrac{1}{b-a+1}$	$\dfrac{a+b}{2}$	$\dfrac{(b-a)(b-a+2)}{12}$
Loi de Bernoulli	$\mathcal{B}(1,p)$	$p \in]0,1[$	$X(\Omega) = \{0,1\}$ $\mathbb{P}\big([X=1]\big) = p$ et $\mathbb{P}\big([X=0]\big) = 1-p = q$	p	pq
Loi binomiale	$\mathcal{B}(n,p)$	$n \in \mathbb{N}^*$, $p \in]0,1[$	$X(\Omega) = [\![0,n]\!]$ $\forall k \in [\![0,n]\!],\ \mathbb{P}\big([X=k]\big) = \binom{n}{k} p^k q^{n-k}$	np	npq
Loi géométrique	$\mathcal{G}(p)$	$p \in]0,1[$	$X(\Omega) = \mathbb{N}^*$ $\forall k \in \mathbb{N}^*,\ \mathbb{P}\big([X=k]\big) = p\,q^{k-1}$	$\dfrac{1}{p}$	$\dfrac{q}{p^2}$
Loi de Poisson	$\mathcal{P}(\lambda)$	$\lambda > 0$	$X(\Omega) = \mathbb{N}$ $\forall k \in \mathbb{N},\ \mathbb{P}\big([X=k]\big) = \mathrm{e}^{-\lambda}\,\dfrac{\lambda^k}{k!}$	λ	λ

Variables aléatoires

Nom de la loi	Notation	Paramètres	Densité en x	Fonction de répartition en x	$E(X)$	$V(X)$
Uniforme	$\mathcal{U}([a,b])$	$(a,b) \in \mathbb{R}^2$ avec $a<b$	$\begin{cases} \frac{1}{b-a} & \text{si } x \in [a,b] \\ 0 & \text{sinon} \end{cases}$	$\begin{cases} 0 & \text{si } x \le a \\ \frac{x-a}{b-a} & \text{si } a<x<b \\ 1 & \text{si } x \ge b \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponentielle	$\mathcal{E}(\lambda)$	$\lambda \in \mathbb{R}_+^*$	$\begin{cases} 0 & \text{si } x<0 \\ \lambda e^{-\lambda t} & \text{si } x \ge 0 \end{cases}$	$\begin{cases} 0 & \text{si } x<0 \\ 1-e^{-\lambda x} & \text{si } x \ge 0 \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Normale centrée réduite	$\mathcal{N}(0;1)$		$\frac{1}{\sqrt{2\pi}} e^{-x^2/2}$	$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-x^2/2} dx$	0	1
Normale	$\mathcal{N}(\mu;\sigma^2)$	$\mu \in \mathbb{R}$ et $\sigma \in \mathbb{R}_+^*$	$\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$	$\Phi\left(\frac{x-\mu}{\sigma}\right)$	μ	σ^2

Variables aléatoires

Table statistique de la loi $\mathcal{N}(0,1)$:

La table statistique ci-dessus nous donne pour chaque $z > 0$, la valeur : $\Phi(z) = P(Z \leq z)$, où Φ est la fonction de répartition de $\mathcal{N}(0,1)$.

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133

$$\Phi(0.5) = P(Z \leq 0.5) = \Phi(0.5 + 0.00) = 0.6915.$$

Variables aléatoires

Dans cette table statistique, on a trouvé que :

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Cette dernière valeur est l'intersection de la ligne 0.2 et la colonne 0.05 dans la table statistique. On a aussi :

- $P(Z > 0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013.$
- $\Phi(-0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013.$
- $$\begin{aligned} P(-0.25 < Z < 0.25) &= \Phi(0.25) - \Phi(-0.25) \\ &= \Phi(0.25) - (1 - \Phi(0.25)) \\ &= 2\Phi(0.25) - 1 = 0,1974. \end{aligned}$$

Variables aléatoires

- **Si maintenant X suit la loi normale $\mathcal{N}(\mu, \sigma^2)$, alors $Z = \dfrac{X-\mu}{\sigma}$ suit la loi normale centrée réduite $\mathcal{N}(0,1)$.**

  Par exemple, pour la normale $\mathcal{N}(72, 64)$, on a : $\mu = 72$ et $\sigma = 8$.

  Par suite,

$$P(X > 80) = 1 - P(X \leq 80) = 1 - P\left(\frac{X-72}{8} \leq \frac{80-72}{8}\right)$$

$$= 1 - P(Z \leq 1) = 1 - \Phi(1) = 1 - 0.8413 = 0.1587.$$

Variables aléatoires

TD (2) :

Exercice 1 :

Une urne (A) contient six boules noires et quatre boules vertes.
Une autre urne (B) contient trois boules noires et une boule verte.

- **I) Première expérience aléatoire :**

  On tire, d'une manière indépendante, au hasard et successivement et sans remise deux boules de l'urne (A) et une boule de l'urne (B). On suppose que toutes les boules sont indiscernables au toucher. Soit X la v.a.d qui correspond au nombre de boules vertes tirées.

- **1. Déterminer la loi de X. En déduire $E(X)$, $V(X)$ et $\sigma(X)$.**
- **3. Calculer $P(X > 2)$ et $P(X \leq 2)$.**
- **4. Déterminer puis tracer la fonction de répartition de X.**
- **5. Retrouver la loi de X à travers sa fonction de répartition.**

Variables aléatoires

- **II) Deuxième expérience aléatoire :**

  On choisit au hasard une urne, puis on tire simultanément deux boules. On suppose que les deux urnes ont la même probabilité d'être tirées et que toutes les boules sont indiscernables au toucher. Soit Y la v.a.d qui correspond au nombre de boules vertes restantes dans l'urne choisie.

- **1. Tracer l'arbre pondéré des probabilités.**
- **2. Déterminer la loi de Y.**
- **3. En déduire $E(Y)$, $V(Y)$ et $\sigma(Y)$.**

Variables aléatoires

Exercice 2 :

Soit U une variable aléatoire qui suit la loi uniforme $\mathcal{U}([0,1])$. Déterminez les lois des v.a(s) suivantes :

1. $X = -\ln(U)$.
2. $Y = a + (b-a)U$.
3. $Z = \chi_{\{U \leq p\}}, \quad (0 < p < 1)$.
4. $T = \sum_{i=1}^{n} \chi_{\{U_i \leq p\}}$ **ou $U_1, \ldots, U_n$ sont n v.a(s) indépendantes et de même loi que U.**

Variables aléatoires

Exercice 3 :

Soient X et Y deux v.a.d(s) indépendantes et suivant la même loi uniforme sur $[1 : n]$.

1. **Déterminer $P(X = Y)$.**
2. **En utilisant la symétrie : $P(X \geq Y) = P(X \leq Y)$, déterminer $P(X \geq Y)$.**
3. **Déterminer la loi de $Z = X + Y$, (discuter les cas : $k \leq n$ et $k > n$).**

Exercice 4 :

Soient X et Y deux v.a.d(s) indépendantes telles que X suit la loi de Bernoulli $\mathcal{B}(p)$ et Y suit la loi de Poisson $\mathcal{P}(1)$. On pose : $Z = XY$.

1. **Trouver la loi de Z, (discuter les cas : $k = 0$ et $k \neq 0$).**
2. **En déduire $E(Z)$ et $V(Z)$.**

Variables aléatoires

Exercice 5 :

Soient X et Y deux v.a.d(s) indépendantes telles que X suit la loi géométrique $\mathcal{G}(p)$ et Y suit la loi géométrique $\mathcal{G}(q)$ avec $(p+q-pq) \in]0,1[$. On cherche la loi de la v.a.d $Z = \min(X, Y)$.

1. **Pour $k \in \mathbb{N}^*$, calculer $P(X \geq k)$.**
2. **En déduire $P(Z \geq k)$, puis F_Z la fonction de répartition de Z.**
3. **Quelle est la loi de Z ?**
4. **Calculer $P(X < Y)$.**

Variables aléatoires

Exercice 6 :

Soit Z une variable aléatoire qui suit la loi normale centrée réduite $\mathcal{N}(0,1)$.

1. **Déterminer :** $P(Z \leq 2.37)$, $P(Z < -2.37)$, $P(Z > 2.37)$, $P(|Z| < 2.37)$ **et** $P(Z \in [-1.88; 0.36])$.
2. **Déterminer les nombres** a, b **et** c **tels que :** $P(Z > a) = 0.025$, $P(Z \leq -b) = 0.33$ **et** $P(|Z| < c) = 0.34$.
3. **Soit** X **une variable aléatoire qui suit la loi normale** $\mathcal{N}(53, 100)$. **Calculer** $P(33.4 < X \leq 72.6)$.

Variables aléatoires

Exercice 7 (Loi de Laplace) :

Soit X une variable aléatoire de densité de probabilité f_X définie sur $\mathbb{R}$ par : $f_X(x) = a\exp(-|x|)$.

1. **Déterminer la constante a.**
2. **Démontrer que X admet des moments de tout ordre. Puis les calculer.**

Exercice 8 (Loi de Cauchy) :

Soit X une variable aléatoire de densité de probabilité f_X définie sur $\mathbb{R}$ par : $f_X(x) = \dfrac{b}{1+x^2}$.

1. **Déterminer la constante b.**
2. **Déterminer F_X la fonction de répartition de X.**
3. **X admet-elle une espérance ?**

Variables aléatoires

Exercice 9 :

Soit X une variable aléatoire de densité de probabilité f_X définie sur $\mathbb{R}$ par :

$$f_X(x) = \begin{cases} 0 & \text{si } x < 1 \\ \dfrac{a}{x\sqrt{x}} & \text{si } x \geq 1 \end{cases}$$

1. **Déterminer la constante a.**
2. **Déterminer la fonction de répartition associée à X.**
3. **X admet-elle une espérance ? Si oui, la déterminer.**

Variables aléatoires

Exercice 10 :

Soit X une variable aléatoire de densité de probabilité f_X définie sur $\mathbb{R}$ par :

$$f_X(x) = \frac{b}{(1+|x|)^2}.$$

1. **Déterminer la constante b.**
2. **Calculer $E(X)$ et $V(X)$, (si elles existent).**
3. **Déterminer la loi de la v.a $Y = \ln(1+|X|)$.**

Plan :

1. Rappel sur les espaces probabilisés
2. Rappel sur les variables aléatoires
3. **Fonctions génératrice et caractéristique**
4. Vecteurs aléatoires, Vecteurs Gaussiens
5. Espérance conditionnelle
6. Convergences et approximations

Fonctions génératrice et caractéristique

Descriptif du chapitre 3 :

- **Fonction génératrice des moments.**
- **Caractérisation des lois discrètes.**
- **Fonction caractéristique et moments.**
- **Caractérisation des lois de probabilités.**
- **Théorème d'inversion.**
- **Produit de convolution et loi de la somme.**

Fonctions génératrice et caractéristique

Fonction génératrice des moments et de probabilités :

Définition

Soient $(\Omega, \mathcal{A}, P)$ un espace probabilisé, $X : \Omega \to \mathbb{N}$ une v.a.d à valeurs entières et P_X sa loi image. On appelle fonction génératrice de X la fonction $g_X : [-1, 1] \to \mathbb{R}$ définie par :

$$g_X(s) = E(s^X) = \sum_{n=0}^{+\infty} s^n P(X = n).$$

Exemple :

Si $X \sim \mathcal{B}(p)$, alors $X(\Omega) = \{0, 1\}$ et $\forall x \in \{0, 1\} : P(X = x) = p^x(1 - p)^{1-x}$. Par conséquent,

$$g_X(s) = \sum_{n=0}^{1} s^n P(X = n) = s^0 \times P(X = 0) + s^1 \times P(X = 1) = 1 - p + sp.$$

Fonctions génératrice et caractéristique

Propriétés

Soit X une v.a.d à valeurs entières, définie sur un espace probabilisé $(\Omega, \mathcal{A}, P)$, et soit g_X sa fonction génératrice. Alors,

1. **g_X est de C^∞ sur $]-1,1[$ et continue sur $[-1,1]$. Si de plus on note $g_X^{(n)}$ sa dérivée d'ordre n, alors,**

$$\forall\, n \in \mathbb{N}, \quad P(X=n) = \frac{g_X^{(n)}(0)}{n!}.$$

2. **La fonction génératrice d'une v.a entière caractérise sa loi : deux v.a.d(s) $X, Y : \Omega \to \mathbb{N}$ ont la même loi si et seulement si on a :**

$$\forall\, s \in [-1,1], \quad g_X(s) = g_Y(s).$$

3. **$g_X(1) = 1$. De plus, en cas d'existence, on a :**

$$E(X) = g_X^{'}(1) \text{ et } V(X) = g_X^{''}(1) + g_X^{'}(1) - (g_X^{'}(1))^2.$$

Fonctions génératrice et caractéristique

Preuve :

- **Puisque** $s \in [-1,1]$, **alors** $|s^n P(X=n)| \leq P(X=n)$, **et par suite on a convergence normale des séries car** $\sum_{n=0}^{+\infty} P(X=n) = 1 < +\infty$.

  Finalement g_X **est de** C^∞ **sur** $]-1,1[$ **et continue sur** $[-1,1]$, **et le développement en série entière de** g_X **donne :**

$$\forall\ n \in \mathbb{N}, \quad P(X=n) = \frac{g_X^{(n)}(0)}{n!}.$$

- **Conséquence immédiate du fait que** $P(X=n) = \dfrac{g_X^{(n)}(0)}{n!}$.

- **Il suffit de remarquer que :** $g_X^{'}(s) = \Big(E(s^X)\Big)^{'} = E\Big(Xs^{X-1}\Big)$,

$$g_X^{''}(s) = \Big(E(s^X)\Big)^{''} = E\Big(X(X-1)s^{X-2}\Big).$$

N.B : $g_X^{(k)}(s) = \Big(E(s^X)\Big)^{(k)} = E\Big(X(X-1)\ldots(X-k+1)s^{X-k}\Big).$

Fonctions génératrice et caractéristique

Exemples :

1) Si $X \sim \mathcal{B}(p)$, on a trouvé que $g_X(s) = 1 - p + sp$. Donc $g_X^{'}(s) = p$ et $g_X^{''}(s) = 0$, par suite :

- $P(X = 0) = \dfrac{g_X^{(0)}(0)}{0!} = g_X(0) = 1 - p.$
- $P(X = 1) = \dfrac{g_X^{'}(0)}{1!} = p.$
- $E(X) = g_X^{'}(1) = p.$
- $E(X(X-1)) = g_X^{''}(1) = 0.$
- $V(X) = g_X^{''}(1) + g_X^{'}(1) - (g_X^{'}(1))^2 = p(1-p).$

2) Pour la loi uniforme discrète sur $[1 : N]$, la règle de l'hôpital donne :

$$E(X) = g_X^{'}(1^-) = \lim_{s \to 1^-} g_X(s) = \frac{N+1}{2}.$$

Fonctions génératrice et caractéristique

Proposition

Soient $X_1, ..., X_n$ n v.a.d(s) indépendantes et à valeurs entières, définie sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$, et soient $g_{X_1}, \ldots, g_{X_n}$, (respectivement), leurs fonctions génératrices. Alors,

$$\forall\, s \in [-1,1], \quad g_{X_1+\ldots+X_n}(s) = \prod_{i=1}^{n} g_{X_i}(s).$$

En particulier, dans le cas i.i.d, on obtient : $g_{X_1+\ldots+X_n}(s) = \Big(g_{X_1}(s)\Big)^n$.

Preuve :

Il suffit de voir que par indépendance, on a :

$$g_{X_1+\ldots+X_n}(s) = E\Big(s^{\sum_{i=1}^{n} X_i}\Big) = E\Big(\prod_{i=1}^{n} s^{X_i}\Big) = \prod_{i=1}^{n} g_{X_i}(s).$$

Fonctions génératrice et caractéristique

Exemple :

Si $X_1, ..., X_n$ sont n v.a.d(s) indépendantes et de même loi de Bernoulli $\mathcal{B}(p)$, alors, $X := X_1 + ... + X_n \sim \mathcal{B}(n, p)$ la loi Binomiale. Par conséquent, pour tout $s \in [-1, 1]$, on a :

$$g_X(s) = \prod_{i=1}^{n} g_{X_i}(s) = \Big(g_{X_1}(s)\Big)^n = (1 - p + sp)^n.$$

Remarque

D'autres lois usuelles discrètes seront traités au TD(s), avec plus de détails sur le calcul de leurs espérances et variances à travers ces fonctions génératrices.

Fonctions génératrice et caractéristique

Nom	Loi de probabilité	Fonction génératrice
$\mathcal{B}(p)$	$P(X=1)=p=1-P(X=0)$	$1-p+ps$
$\mathcal{B}(n,p)$	$k\in[0:n],\ P(X=k)=C_n^k p^k(1-p)^{n-k}$	$(1-p+ps)^n$
$\mathcal{P}(\lambda)$	$k\in\mathbb{N},\ P(X=k)=\dfrac{e^{-\lambda}\lambda^k}{k!}$	$e^{\lambda(s-1)}$
$\mathcal{G}(p)$	$k\in\mathbb{N}^*,\ P(X=k)=p(1-p)^{k-1}$	$\dfrac{ps}{1-(1-p)s},\ \lvert s\rvert<\dfrac{1}{1-p}$

Fonctions génératrice et caractéristique

TD (3) :

Exercice 1 :

On rappelle que la fonction génératrice des moments de la v.a.d X, à valeurs entières et de loi image P_X, est la fonction $g_X : [-1, 1] \to \mathbb{R}$ définie par :

$$g_X(s) = E(s^X) = \sum_{n=0}^{+\infty} s^n P(X = n).$$

Calculer g_X et retrouver, si possible, la loi de X, $E(X)$ et $V(X)$ dans les cas suivants :

1. $X \sim \mathcal{U}([1 : N])$ **la loi Uniforme discrète.**
2. $X \sim \mathcal{B}(n, p)$ **la loi Binomiale.**
3. $X \sim Geo(p)$ **la loi Géométrique.**
4. $X \sim \mathcal{P}(\lambda)$ **la loi de Poisson.**

Fonctions génératrice et caractéristique

Exercice 2 :

Une v.a.d à valeurs entières a pour fonction génératrice :

$$g_X(s) = k(3 + 2s^2)^3, \quad s \in [0, 1].$$

1. **Déterminer la constante k.**
2. **Déterminer la loi de probabilité de X.**
3. **Calculez $E(X)$ et $V(X)$.**

Fonctions génératrice et caractéristique

Exercice 3 :

Soit X une v.a.d à valeurs entières dont la loi est donnée par :

$$P(X = k) = aC_{n+k}^{k} p^{k}, \quad a > 0,\ p \in]0, 1[.$$

1. **Utiliser la fonction génératrice pour calculer a, $E(X)$ et $V(X)$.**

Exercice 4 :

1. **Soit $X \sim \mathcal{P}(\lambda)$. Calculer $E(X(X-1)\cdots(X-r+1))$, $r \in \mathbb{N}^*$.**
2. **Retrouver ce résultat par la fonction génératrice.**
3. **En déduire $E(X^3)$ pour $\lambda = 1$.**

Fonctions génératrice et caractéristique

Exercice 5 :

Soit $(X_n)_n$ une suite de v.a.d(s) entières i.i.d et N une v.a entière indépendante de la suite $(X_n)_n$. On pose :

$$S := X_1 + X_2 + ... + X_N.$$

Par exemple, N est le nombre d'appels arrivant un certain jour à un livreur de pizza, et X_i est le nombre de pizza commandées lors de chaque appel. S correspond donc au nombre total de pizzas commandées ce jour là.

1. **En remarquant que $\sum_{n\in\mathbb{N}} 1_{\{N=n\}} = 1$, Montrer que : $g_S = g_N \circ g_{X_1}$.**
2. **En déduire l'identité de Wald : $E(S) = E(N)E(X_1)$.**
3. **Trouver la loi de probabilité de S si $N \sim \mathcal{P}(\lambda)$ et $X_1 \sim \mathcal{B}(p)$.**

Fonctions génératrice et caractéristique

Fonction caractéristique :

Définition

Soit X une v.a, définie sur un espace probabilisé $(\Omega, \mathcal{A}, P)$. La fonction caractéristique de X est une fonction à valeurs complexes, définie sur $\mathbb{R}$ par :

$$\varphi_X(t) = E(e^{itX}) = \int_\Omega e^{itX} dP.$$

Remarque

- **Pour une v.a.d, φ_X apparaît comme le prolongement de g_X sur le cercle unité complexe et on a : $\varphi_X(t) = g_X(e^{it})$.**
- **Décomposition : $\varphi_X(t) = E(\cos(tX)) + iE(\sin(tX))$.**
- **φ_X est la transformée de Fourier de la mesure de probabilité P_X.**

Fonctions génératrice et caractéristique

Caractérisation

- **Si P_X est la loi image de X, alors :** $\varphi_X(t) = \int_{\mathbb{R}} e^{itx} dP_X(x), \quad \forall t \in \mathbb{R}.$
- **Si P_X est absolument continue par rapport à la mesure de Lebesgue, et de densité f_X, (au sens de Radon-Nikodym :** $dP_X(x) = f_X(x)dx$**), alors,**

$$\varphi_X(t) = \int_{\mathbb{R}} e^{itx} f_X(x)dx, \quad \forall t \in \mathbb{R}.$$

- **Si P_X est absolument continue par rapport à la mesure de comptage, et de densité $P_X(x)$, alors,**

$$\varphi_X(t) = \sum_x e^{itx} P_X(x), \quad \forall t \in \mathbb{R}.$$

Fonctions génératrice et caractéristique

Exemples :

1. **Si** $X \sim \mathcal{B}(p)$, **alors** $\forall x \in \{0,1\}$: $P(X=x) = p^x(1-p)^{1-x}$. **Par suite,**

$$\varphi_X(t) = \sum_{x=0}^{1} e^{itx} P(X=x) = (1-p)\cdot e^{it\cdot 0} + p\cdot e^{it\cdot 1} = 1-p+pe^{it}.$$

2. **Si** $X \sim \mathcal{E}(\lambda)$, **alors** $f_X(x) = \lambda e^{-\lambda x}$, $x \geq 0$. **Par suite,**

$$\varphi_X(t) = \int_{-\infty}^{+\infty} e^{itx} f_X(x)dx = \lambda \int_0^{+\infty} e^{-(\lambda - it)x}\, dx = \left[\frac{-\lambda e^{-(\lambda-it)x}}{\lambda - it}\right]_0^{+\infty} = \frac{\lambda}{\lambda - it}.$$

Remarque

D'autres lois usuelles seront traités au TD(s), avec plus de détails sur le calcul de leurs espérances et variances à travers ces fonctions caractéristiques.

Fonctions génératrice et caractéristique

Nom	Masse/Densité de probabilité	Fonction caractéristique
$\mathcal{B}(p)$	$P(X=1)=1-P(X=0)$	$1-p+pe^{it}$
$\mathcal{B}(n,p)$	$P(X=k)=C_n^k p^k(1-p)^{n-k}$	$(1-p+pe^{it})^n$
$\mathcal{P}(\lambda)$	$P(X=k)=\frac{\lambda^k e^{-\lambda}}{k!}$	$e^{\lambda(e^{it}-1)}$
$\mathcal{G}(p)$	$P(X=k)=p(1-p)^{k-1}$	$\frac{pe^{it}}{1-(1-p)e^{it}}$
$\mathcal{U}([a,b])$	$f_X(x)=\frac{1}{b-a}$, $x\in[a,b]$	$\frac{e^{itb}-e^{ita}}{it(b-a)}$
$\mathcal{E}(\lambda)$	$f_X(x)=\lambda e^{-\lambda x}$, $x\geq 0$	$\frac{\lambda}{\lambda-it}$
$\mathcal{N}(\mu,\sigma^2)$	$f_X(x)=\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$e^{i\mu t-\frac{\sigma^2 t^2}{2}}$

Fonctions génératrice et caractéristique

Propriétés

Soient X et Y deux v.a(s), définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$, et soient φ_X et φ_Y, (respectivement), leurs fonctions caractéristiques. Alors,

1. $\varphi_X(0) = 1$ **et** $\forall\ t \in \mathbb{R}, \quad |\varphi_X(t)| \leq 1.$
2. $\forall\ t \in \mathbb{R}, \quad \overline{\varphi_X(t)} = \varphi_X(-t) = \varphi_{-X}(t).$
3. **Linéarité :** $\varphi_{aX}(t) = \varphi_X(at)$ **et** $\varphi_{X+b}(t) = e^{itb}\varphi_X(t), \quad \forall\ a, b \in \mathbb{R}.$
4. **Si** $U = \dfrac{X - m}{\sigma}$ **est la v.a centrée réduite associée à X, alors,**

$$\varphi_U(t) = e^{-i\frac{tm}{\sigma}}\varphi_X\left(\frac{t}{\sigma}\right) \quad \text{et} \quad \varphi_X(t) = e^{itm}\varphi_U(\sigma t).$$

5. **Si X et Y sont deux v.a(s) indépendantes, alors** $\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t).$
6. **La fonction φ_X est uniformément continue pour toutes les valeurs $t \in \mathbb{R}$.**

Fonctions génératrice et caractéristique

Preuve :

1. $\varphi_X(0) = E(e^{i.0.X}) = 1.$
   $|\varphi_X(t)| = \left| \int_{\mathbb{R}} e^{itx} dP_X(x) \right| \leq \int_{\mathbb{R}} |e^{itx}| dP_X(x) = \int_{\mathbb{R}} dP_X(x) = P_X(\mathbb{R}) = 1.$
2. $\varphi_{-X}(t) = \varphi_X(-t) = E(e^{-itX}) = E(\overline{e^{itX}}) = \overline{E(e^{itX})} = \overline{\varphi_X(t)}.$
3. $\varphi_{aX}(t) = E(e^{itaX}) = E(e^{i(ta)X}) = \varphi_X(at).$
   $\varphi_{X+b}(t) = E(e^{it(X+b)}) = E(e^{itb}e^{itX}) = e^{itb}E(e^{itX}).$
4. **Il suffit de prendre dans le point (3) :** $a = \frac{1}{\sigma}$ **et** $b = -\frac{m}{\sigma}$.
5. **Puisque** X **et** Y **sont indépendantes, alors,**

$$\varphi_{X+Y}(t) = E\left(e^{it(X+Y)}\right) = E\left(e^{it(X)}e^{it(Y)}\right) = E(e^{itX}) \times E(e^{itY}) = \varphi_X(t)\varphi_Y(t).$$

Fonctions génératrice et caractéristique

(6) **Pour tout $t, h \in \mathbb{R}$, on a :**

$$\begin{aligned}
|\varphi_X(t+h) - \varphi_X(t)| &= \left|E\left(e^{itX} e^{it\frac{hX}{2}} \left(e^{it\frac{hX}{2}} - e^{-it\frac{hX}{2}}\right)\right)\right| \\
&= \left|E\left(e^{itX} e^{it\frac{hX}{2}} 2i \sin\left(\frac{hX}{2}\right)\right)\right| \\
&\leq 2E\left|\sin\left(\frac{hX}{2}\right)\right| \\
&\leq E(|h||X| \wedge 2),
\end{aligned}$$

car $|\sin(x)| \leq |x| \wedge 1$. Finalement, par convergence dominée la limite est 0 quand $h \to 0$, indépendamment de t, ce qui garantit l'uniforme continuité de la fonction caractéristique φ_X.

Fonctions génératrice et caractéristique

Remarque

La linéarité de la fonction caractéristique permet de voir qu'une transformation linéaire d'une loi normale est aussi une loi normale. Plus précisément, si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $Y := aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$, et on a :

$$\varphi_Y(t) = e^{itb}\varphi_X(at) = e^{i(a\mu+b)t - \frac{a^2\sigma^2t^2}{2}}.$$

Ce résultat peut se déduire aussi en utilisant la loi de X :

$$F_Y(y) = P(Y \leq y) = \begin{cases} F_X\left(\dfrac{y-b}{a}\right) & \text{si } a > 0, \\ 1 - F_X\left(\dfrac{y-b}{a}\right) & \text{si } a < 0. \end{cases}$$

Finalement, on trouve que : $f_Y(y) = \dfrac{1}{|a|} f_X\left(\dfrac{y-b}{a}\right)$.

Fonctions génératrice et caractéristique

Exemples :

1. **Si $X \sim \mathcal{N}(m_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(m_2, \sigma_2^2)$, et X et Y sont indépendantes, alors le tableau précédent donne la fonction caractéristique de leur somme $Z := X + Y$ comme suit :**

$$\varphi_Z(t) = \varphi_X(t)\varphi_Y(t) = e^{it(m_1+m_2)} e^{-t^2 \frac{(\sigma_1^2+\sigma_2^2)}{2}}.$$

On déduit que $Z \sim \mathcal{N}(m, \sigma^2)$, où $m = m_1 + m_2$ et $\sigma^2 = \sigma_1^2 + \sigma_2^2$.

Le même raisonnement utilisé dans l'exemple (1) donne :

2. **Si $X \sim \mathcal{B}(n, p)$ et $Y \sim \mathcal{B}(m, p)$, alors $X + Y \sim \mathcal{B}(n + m, p)$.**
3. **Si $X \sim \mathcal{P}(\lambda)$ et $Y \sim \mathcal{P}(\mu)$, alors $X + Y \sim \mathcal{P}(\lambda + \mu)$.**

Fonctions génératrice et caractéristique

Théorème

Soit X une v.a définie sur un espace probabilisé $(\Omega, \mathcal{A}, P)$. Alors, φ_X est une fonction caractéristique d'une v.a X si et seulement si elle possède les propriétés suivantes :

- $\varphi_X(0) = 1$ **et** $\forall\ t \in \mathbb{R}, \quad |\varphi_X(t)| \leq 1.$
- φ_X **est uniformément continue pour toutes les valeurs** $t \in \mathbb{R}$.
- φ_X **est définie positive, i.e.,** $\sum_{j,k} \varphi_X(t_j - t_k) z_j \bar{z}_k \geq 0,$

  pour tous $t_1, \cdots, t_n$ **réels, et tous** $z_1, \ldots, z_n$ **complexes.**

N.B : pour la positivité, il suffit d'observer que :

$$\sum_{j,k} \varphi_X(t_j - t_k) z_j \bar{z}_k = E\Big(\sum_{j,k} z_j e^{it_j X} \bar{z}_k e^{-it_k X} \Big) = E\Big| \sum_{j=1}^{n} z_j e^{it_j X} \Big|^2.$$

Fonctions génératrice et caractéristique

Produit de convolution et loi de la somme :

Proposition

Soient X et Y deux v.a(s), indépendantes, définie sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$, et de densités de probabilités respectives f_X et f_Y. La somme $X+Y$ a pour densité de probabilité :

$$f_{X+Y}(u) = f_X * f_Y(u) = \int_{-\infty}^{-\infty} f_X(u-v) f_Y(v) dv.$$

Preuve :

Comme X et Y sont indépendantes, on obtient,

Fonctions génératrice et caractéristique

$$\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t) = \Big(\int_{-\infty}^{\infty} f_X(x)e^{itx}dx\Big)\Big(\int_{-\infty}^{+\infty} f_Y(v)e^{itv}dv\Big)$$
$$= \int_{-\infty}^{+\infty} f_Y(v)\Big(\int_{-\infty}^{+\infty} f_X(x)e^{it(x+v)}dx\Big)dv.$$

Le changement de variable : $u = x + v$ et le théorème de Fubini donnent :

$$\varphi_{X+Y}(t) = \int_{-\infty}^{+\infty} f_Y(v)\Big(\int_{-\infty}^{+\infty} f_X(u-v)e^{itu}du\Big)dv$$
$$= \int_{-\infty}^{+\infty} e^{itu}\Big(\int_{-\infty}^{+\infty} f_Y(v)f_X(u-v)dv\Big)du$$
$$= \int_{-\infty}^{+\infty} f_X * f_Y(u)e^{itu}du$$
$$= \int_{-\infty}^{+\infty} f_{X+Y}(u)e^{itu}du.$$

Fonctions génératrice et caractéristique

Finalement, puisque la fonction caractéristique caractérise la loi de la v.a, on a donc pour $X+Y$ la densité : $f_{X+Y}(u) = f_X * f_Y(u)$.

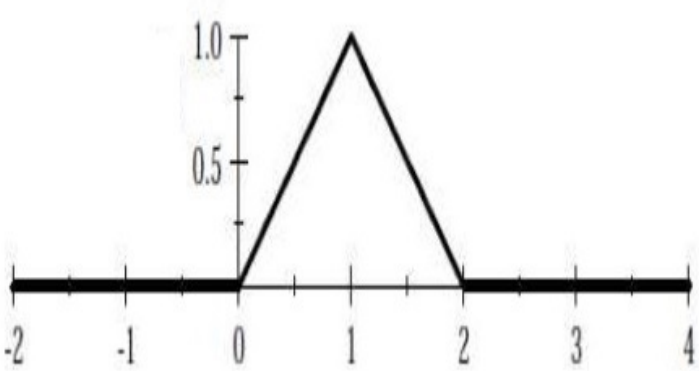
Exemple :

Soient X et Y deux v.a(s) indépendantes de lois Uniforme sur $[0,1]$. Pour tout $z \in \mathbb{R}$, on a :

$$f_{X+Y}(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x)dx = \int_0^1 f_Y(z-x)dx = \int_{z-1}^{z} f_Y(u)du.$$

Finalement, on obtient,

$$f_{X+Y}(z) = \begin{cases} 0 & \text{si } z \in]-\infty, 0], \\ z & \text{si } z \in]0,1], \\ 2-z & \text{si } z \in]1,2], \\ 0 & \text{si } z \in]2,+\infty[. \end{cases}$$



Fonctions génératrice et caractéristique

Remarque

Si X et Y sont deux v.a.d(s) indépendantes, définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$, alors,

$$P(X+Y=z) = \sum_x P(X=x) \times P(Y=z-x).$$

En effet,

$$\begin{aligned} P(X+Y=z) &= P\Big((X+Y=z) \cap \bigcup_x (X=x)\Big) \\ &= \sum_x P\Big((X=x) \cap (Y=z-x)\Big) \\ &= \sum_x P(X=x) \times P(Y=z-x). \end{aligned}$$

Fonctions génératrice et caractéristique

Exemple :

Soient $X \sim \mathcal{P}(\lambda)$ et $Y \sim \mathcal{P}(\mu)$ deux v.a.d(s) indépendantes. Alors, $Z \sim \mathcal{P}(\lambda + \mu)$. En effet, on a :

$$P(Z = z) = \sum_{x=0}^{z} P(X = x)P(Y = z - x)$$

$$= \sum_{x=0}^{z} \frac{e^{-\lambda}\lambda^{x}}{x!} \cdot \frac{e^{-\mu}\lambda^{z-x}}{(z-x)!}$$

$$= \frac{e^{-(\lambda+\mu)}(\lambda+\mu)^{z}}{z!}.$$

La dernière formule est obtenue à l'aide de la formule du binôme de Newton.

Fonctions génératrice et caractéristique

Moments d'une v.a :

Proposition

Soit X une v.a, définie sur un espace probabilisé $(\Omega, \mathcal{A}, P)$, et soit φ_X sa fonction caractéristique. Alors,

- **Si $E|X|^n$ est finie pour un entier $n \geq 1$, alors φ_X est continûment dérivable jusqu'à l'ordre n et on a :**

$$E(X^n) = \frac{\varphi_X^{(n)}(0)}{i^n}.$$

- **Si φ_X est de classe C^∞, alors,**

$$\varphi_X(t) = \sum_{n=0}^{+\infty} \frac{t^n}{n!} i^n E(X^n).$$

Fonctions génératrice et caractéristique

Preuve :

- **Calcul simple des dérivées à l'intérieur de l'espérance.**
- **Utiliser la formule de Mac-Laurin.**

Exemple :

D'après le tableau précédant, si $U \sim \mathcal{N}(0,1)$, on obtient,

$$\varphi_U(t) = e^{-\frac{t^2}{2}} = 1 - \frac{t^2}{2} + \frac{1}{2!}\Big(-\frac{t^2}{2}\Big)^2 + \ldots\ldots$$

On identifie à la formule $E(X^n) = \dfrac{\varphi_X^{(n)}(0)}{i^n}$, on déduit que :

- **les moments d'ordre impair sont nuls,**
- **les moments d'ordre pair sont égaux à $\dfrac{(2n)!}{2^n n!}$.**

Fonctions génératrice et caractéristique

Théorème d'inversion :

La fonction caractéristique détermine la loi de probabilité d'une v.a, ainsi deux v.a(s) ont même fonction caractéristique si et seulement si elles ont la même loi de probabilité. Plus précisent, on a :

Théorème d'inversion

Soient $a, b \in \mathbb{R}$ tels que $a < b$. Si X est une v.a de fonction de répartition F_X et de fonction caractéristique φ_X. Alors,

$$F_X(b) - F_X(a) = \lim_{T \longrightarrow +\infty} \frac{1}{2\pi} \int_{-T}^{T} \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt,$$

en chaque point de continuité de F_X.

Fonctions génératrice et caractéristique

Preuve :

Comme $\forall\, a, b \in \mathbb{R}$, $\left|e^{ia} - e^{ib}\right| \leq |b-a|$, **on en déduit que :**

$$\left|\frac{e^{-ita} - e^{-itb}}{it}\varphi_X(t)\right| \leq |\varphi_X(t)|\left|\frac{e^{-ita} - e^{-itb}}{it}\right| \leq 1.|b-a| = |b-a|.$$

Donc, en vertu du théorème de Fubini, on peut permuter les opérateurs d'intégration et écrire :

$$\lim_{T\longrightarrow+\infty} \frac{1}{2\pi}\int_{-T}^{T} \frac{e^{-ita} - e^{-itb}}{it}\varphi_X(t)dt$$

$$= \lim_{T\to+\infty} \frac{1}{2\pi}\int_{-T}^{T} \frac{e^{-ita} - e^{-itb}}{it}\int_{-\infty}^{+\infty} e^{itx}dP_X dt$$

$$= \lim_{T\to+\infty} \frac{1}{2\pi}\int_{-\infty}^{+\infty} dP_X \int_{-T}^{T} \frac{e^{it(x-a)} - e^{it(x-b)}}{it}dt$$

Fonctions génératrice et caractéristique

$$= \lim_{T\to+\infty} \frac{1}{2\pi} \int_{-\infty}^{+\infty} dP_X \int_{-T}^{T} \frac{\sin(t(x-a)) - \sin(t(x-b))}{t} dt$$
$$= F_X(b) - F_X(a).$$

On a utilisé le théorème de la convergence dominée pour prendre la limite $T \to +\infty$. En effet, la fonction de Dirichlet :

$$u(T,z) = \int_0^T \frac{\sin tz}{t} dt$$

satisfait $\sup_{T,z} |u(T,z)| \leq C$, **et**

$$\lim_{T\to+\infty} u(T,z) = \begin{cases} \pi/2 & \text{si } z > 0 \\ -\pi/2 & \text{si } z < 0 \\ 0 & \text{si } z = 0. \end{cases}$$

Fonctions génératrice et caractéristique

Cas particuliers :

Remarque

- **Si X est une v.a.d, alors,**

$$P(X = n) = \lim_{T \longrightarrow +\infty} \frac{1}{2T} \int_{-T}^{T} e^{-int} \varphi_X(t) dt.$$

- **Si X est une v.a et φ_X intégrable, alors la densité de X est donnée par :**

$$f_X(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-ixt} \varphi_X(t) dt.$$

Fonctions génératrice et caractéristique

Application : (loi de Cauchy)

Si X suit la loi de Cauchy, alors X a pour fonction caractéristique : $\varphi_X(t) = e^{-|t|}, \quad t \in \mathbb{R}$. **En effet, d'après le théorème d'inversion on a :**

$$
\begin{aligned}
f_X(x) &= \frac{1}{2\pi}\int_{\mathbb{R}} e^{-itx}e^{-|t|}dt \\
&= \frac{1}{2\pi}\int_{-\infty}^{0} e^{-itx+t}dt + \frac{1}{2\pi}\int_{0}^{\infty} e^{-itx-t}dt \\
&= \Big[\frac{e^{-itx+t}}{2\pi(1-ix)}\Big]_{-\infty}^{0} + \Big[-\frac{e^{-itx-t}}{2\pi(1+ix)}\Big]_{0}^{+\infty} \\
&= \frac{1}{2\pi(1-ix)} + \frac{1}{2\pi(1+ix)} \\
&= \frac{1}{\pi(1+x^2)}.
\end{aligned}
$$

Fonctions génératrice et caractéristique

TD (4) :

Exercice 1 :

On note φ_X la fonction caractéristique de la loi d'une v.a X. Calculer φ_X et en déduire, si possible, $E(X)$ et $V(X)$ dans les cas suivants :

1. $X \sim \mathcal{U}([1:N])$ **la loi uniforme discrète.**
2. $X \sim \mathcal{B}(n,p)$ **la loi binomiale.**
3. $X \sim Geo(p)$ **la loi géométrique.**
4. $X \sim \mathcal{P}(\lambda)$ **la loi de poisson.**
5. $X \sim \mathcal{U}([-a,a])$ **la loi uniforme continue.**
6. $X \sim \mathcal{E}(\lambda)$ **la loi exponentielle.**

Exercice 2 :

1. **Montrer que si X est une v.a qui suit la loi de Cauchy de densité de probabilité :** $f_X(x) = \dfrac{1}{\pi(1+x^2)}$, $x \in \mathbb{R}$, **alors X a pour fonction caractéristique :** $\varphi_X(t) = e^{-|t|}$, $t \in \mathbb{R}$.

Fonctions génératrice et caractéristique

Exercice 3 :

Soit $U \sim \mathcal{N}(0,1)$ et φ_U sa fonction caractéristique.

1. **Montrer que φ_U vérifie l'EDO : $\varphi_U'(t) = -t\varphi_U(t)$ et en déduire $\varphi_U(t)$.**
2. **Soit $X \sim \mathcal{N}(m, \sigma^2)$. Écrire X en fonction de U.**
3. **En déduire $\varphi_X(t)$.**

Exercice 4 :

1. **Soit X une v.a et φ_X sa fonction caractéristique. Montrer que φ_X est à valeur réelles si et seulement si X a une loi symétrique, i.e., $P_X = P_{-X}$.**
2. **Montrer que si X et Y sont deux v.a.(s) i.i.d, alors $X - Y$ a une loi symétrique.**
3. **Montrer qu'il n'existe pas deux v.a.(s) i.i.d telles que $X - Y \sim \mathcal{U}([-1,1])$.**

Fonctions génératrice et caractéristique

Exercice 5 :

Soient X_1 et X_2 deux v.a(s) i.i.d qui suivent la loi de Laplace, de densité de probabilité $f_X(x) = \frac{1}{2}e^{-|x|}$. Notons $\varphi = \varphi_{X_i}$ la fonction caractéristique de X_i. On définit les v.a(s) Y_1 et Y_2 par :

$$\begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} = \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}.$$

1. **Montrer que $\varphi(t) = \left(1 + t^2\right)^{-1}$ pour $t \in \mathbb{R}$.**
2. **Montrer que Y_1 et Y_2 ont la même loi. Calculer $E(Y_1)$.**
3. **Montrer que Y_1 et Y_2 sont non corrélées, c-à-d $Cov(Y_1, Y_2) \neq 0$.**
4. **Trouver la loi de Y_1 et Y_2.**

Plan :

1. Rappel sur les espaces probabilisés
2. Rappel sur les variables aléatoires
3. Fonctions génératrice et caractéristique
4. **Vecteurs aléatoires, Vecteurs Gaussiens**
5. Espérance conditionnelle
6. Convergences et approximations

Vecteurs aléatoires, Vecteurs Gaussiens

Descriptif du chapitre 4 :

- **Loi conjointe et lois marginales.**
- **Moyenne et matrice de covariances.**
- **Vecteur aléatoire discret.**
- **Vecteur aléatoire à densité.**
- **Fonctions génératrices et caractéristiques.**
- **Fonction de répartition.**
- **Vecteur Gaussien.**

Vecteurs aléatoires, Vecteurs Gaussiens

Vecteurs aléatoires

Loi conjointe et lois marginales

Définition

- **On appelle vecteur aléatoire à n dimensions, toute application mesurable X d'un espace probabilisé $(\Omega, \mathcal{A}, P)$ vers $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$.**
- **L'événement $X^{-1}(B)$ est noté par $(X \in B)$.**
- **On écrit $X = (X_1, \ldots, X_n)'$, où les composantes $X_k,\ k \in [1:n]$, sont n v.a(s) définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$.**
- **On appelle loi conjointe de X, et on la note P_X, la probabilité image de P par X définie sur $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ par :**

$$\forall\, B \in \mathcal{B}(\mathbb{R}^n) \ : \quad P_X(B) = P(X^{-1}(B)) = P(X \in B).$$

- **Les lois images P_{X_k} des composantes $X_k,\ k \in [1:n]$ sont appelées lois marginales de X.**

Vecteurs aléatoires, Vecteurs Gaussiens

Remarque

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire défini sur $(\Omega, \mathcal{A}, P)$.

1. **La loi conjointe du vecteur X détermine les lois marginales. Plus précisément, pour tout borélien $B \in \mathcal{B}(\mathbb{R})$, on a :**

$$\forall\, k \in [1:n]: \quad P_{X_k}(B) = P_X(\mathbb{R}^{k-1} \times B \times \mathbb{R}^{n-k}).$$

2. **La réciproque de (1), est en général fausse. Néanmoins, si les v.a(s) $X_k,\ k \in [1:n]$, sont indépendantes, alors,**

$$P_X(B_1 \times \ldots \times B_n) = \prod_{k=1}^{n} P_{X_k}(B_k).$$

Dans ce cas, la loi conjointe P_X de X s'écrit :

$$P_X = P_{X_1} \otimes \ldots \otimes P_{X_n}.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Vecteur aléatoire discret

Proposition

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire discret, défini sur $(\Omega, \mathcal{A}, P)$, où l'ensemble de ses réalisations possibles $X(\Omega)$ est au plus dénombrable. Alors,

- **La loi conjointe du vecteur discret X est donnée par :**

$$P\Big((X_1 = x_1) \cap \ldots \cap (X_n = x_n)\Big), \quad \text{où les} \quad x_k \in X_k(\Omega), \ k \in [1 : n].$$

- **Les lois marginales P_{X_k}, $k \in [1 : n]$ du vecteur discret X sont données par :**

$$P(X_k = x_k) = \sum_{\substack{x_j \in X_j(\Omega) \\ \forall\ j \neq k}} P\Big((X_1 = x_1) \cap \ldots (X_k = x_k) \ldots \cap (X_n = x_n)\Big).$$

Vecteurs aléatoires, Vecteurs Gaussiens

Exemples :

1) Un vecteur aléatoire $X = (X_1, \ldots, X_n)'$ suit une loi multinomiale de paramètres $m, p_1, p_2, \ldots, p_n$ si on a :

$$P\Big((X_1 = x_1) \cap \ldots \cap (X_n = x_n)\Big) = \frac{m!}{x_1! \times \cdots \times x_n!} p_1^{x_1} p_2^{x_2} \cdots p_n^{x_n},$$

où $p_1, p_2, \ldots, p_n \in [0,1]$, $\sum_{i=1}^{n} p_i = 1$, $x_1, \ldots, x_n \in \{0, \ldots, m\}$ **et** $\sum_{j=1}^{n} x_j = m$.

2) Dans un lancer d'un dé équilibré, on note Y la v.a.d qui vaut 1 si le résultat est impair et 2 si le résultat est pair : $(Y(\Omega) = \{1, 2\})$, et Z la v.a.d qui vaut 0 si le résultat est 1, 1 si le résultat est 6 et 2 sinon : $(Z(\Omega) = \{0, 1, 2\})$.

Vecteurs aléatoires, Vecteurs Gaussiens

Alors, la loi du couple aléatoire discret $(Y, Z)'$ est donnée par :

$$
\begin{aligned}
P((Y=1)\cap(Z=0)) &= P(\{1\}) = \frac{1}{6},\\
P((Y=1)\cap(Z=1)) &= P(\emptyset) = 0,\\
P((Y=1)\cap(Z=2)) &= P(\{3,5\}) = \frac{2}{6} = \frac{1}{3},\\
P((Y=2)\cap(Z=0)) &= P(\emptyset) = 0,\\
P((Y=2)\cap(Z=1)) &= P(\{6\}) = \frac{1}{6},\\
P((Y=2)\cap(Z=2)) &= P(\{2,4\}) = \frac{2}{6} = \frac{1}{3}.
\end{aligned}
$$

Vecteurs aléatoires, Vecteurs Gaussiens

Y \ Z	**0**	**1**	**2**
1	$\frac{1}{6}$	**0**	$\frac{1}{3}$
2	**0**	$\frac{1}{6}$	$\frac{1}{3}$

Remarque

$$P(Y=y)=\sum_{z=0}^{2}P((Y=y)\cap(Z=z)).$$

$$P(Z=z)=\sum_{y=1}^{2}P((Y=y)\cap(Z=z)).$$

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice :

Soit $(X, Y)'$ un couple aléatoire discret dont la loi conjointe est donné par :

$$P\big((X=i)\cap(Y=j)\big)=\frac{a}{2^{i+j}},\quad i,j\in\mathbb{N}^*,\ a>0.$$

1. **Trouver la valeur de a.**
2. **Trouver les lois marginales de X et Y.**

Correction :

1. $$\sum_{i,j\geq 1} P\big((X=i)\cap(Y=j)\big)=1 \iff a.\sum_{i=1}^{+\infty}\frac{1}{2^i}.\sum_{j=1}^{+\infty}\frac{1}{2^j}=1 \iff a=1.$$
2. $$P(X=i)=\sum_{j=1}^{+\infty}P\big((X=i)\cap(Y=j)\big)=\frac{1}{2^i}\sum_{j=1}^{+\infty}\frac{1}{2^j}=\frac{1}{2^i}=\frac{1}{2}\Big(1-\frac{1}{2}\Big)^{i-1}.$$

   On déduit que $X\sim Geo\Big(\frac{1}{2}\Big)$ la loi géométrique. Il en est de même pour la v.a Y.

Vecteurs aléatoires, Vecteurs Gaussiens

Fonction génératrice

Définition

Soit $X = (X_1, ..., X_n)'$ un vecteur aléatoire discret, défini sur $(\Omega, \mathcal{A}, P)$, et à valeurs dans $\mathbb{N}^n$. La fonction génératrice de X est définie pour tout $s = (s_1, ..., s_n) \in [-1, 1]^n$ par :

$$g_X(s) = E(s_1^{X_1} .....s_n^{X_n}) = \sum_{(n_1, ..., n_n) \in \mathbb{N}^n} s_1^{n_1} .....s_n^{n_n} P\Big((X_1 = n_1), ..., (X_n = n_n)\Big).$$

Proposition

1. **La fonction génératrice de chaque composante $X_k,\ k \in [1 : n]$ est :**

$$g_{X_k}(s_k) = g_X(1, \ldots, 1, s_k, 1, \ldots, 1).$$

2. **Si les v.a(s) $X_k,\ k \in [1 : n]$ sont indépendantes, alors pour tout $s = (s_1, ..., s_n) \in [-1, 1]^n$, on a :** $g_X(s) = \prod_{k=1}^{n} g_{X_k}(s_k).$

Vecteurs aléatoires, Vecteurs Gaussiens

Fonction de répartition

Définition

Soit $X = (X_1, ..., X_n)'$ un vecteur aléatoire défini sur $(\Omega, \mathcal{A}, P)$. La fonction de répartition conjointe de X, notée F_X, est une application de $\mathbb{R}^n$ vers $[0, 1]$ définie par :

$$F_X(x) = P\Big(\bigcap_{k=1}^{n}(X_k \leq x_k)\Big), \quad x = (x_1, ..., x_n)' \in \mathbb{R}^n.$$

Remarque

Si P_X est la loi image de X, alors,

$$F_X(x) = P_X\Big(\prod_{k=1}^{n}]-\infty, x_k]\Big), \quad x = (x_1, ..., x_n)' \in \mathbb{R}^n.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Théorème

Soit $X = (X_1, ..., X_n)'$ un vecteur aléatoire, défini sur $(\Omega, \mathcal{A}, P)$, et de fonction de répartition F_X. Alors,

- **F_X est croissante et continue à droite par rapport à chaque variable x_k, $k \in [1 : n]$. De plus, on a :**

$$\lim_{x_k \to -\infty} F_X(x_1, \ldots, x_k, \ldots, x_n) = 0,$$

$$\lim_{\substack{x_k \to +\infty \\ \forall\ k}} F_X(x_1, \ldots, x_k, \ldots, x_n) = 1.$$

- **Les fonctions de répartition des X_k, $k \in [1 : n]$ sont données par :**

$$F_{X_k}(x_k) = \lim_{\substack{x_j \to +\infty \\ \forall\ j \neq k}} F_X(x_1, \ldots, x_k, \ldots, x_n).$$

Vecteurs aléatoires, Vecteurs Gaussiens

Exemple :

Soit $(X, Y)'$ un couple aléatoire de fonction de répartition conjointe :

$$F_{(X,Y)}(x, y) = P\Big((X \leq x) \cap (Y \leq y)\Big).$$

Alors,

- $\lim\limits_{x \to -\infty} F_{(X,Y)}(x, y) = \lim\limits_{y \to -\infty} F_{(X,Y)}(x, y) = 0$ **et** $\lim\limits_{\substack{x \to +\infty \\ y \to +\infty}} F_{(X,Y)}(x, y) = 1.$
- **La fonction de répartition de X est donnée par :**

$$F_X(x) = \lim_{y \to +\infty} F_{(X,Y)}(x, y).$$

- **La fonction de répartition de Y est donnée par :**

$$F_X(y) = \lim_{x \to +\infty} F_{(X,Y)}(x, y).$$

Vecteurs aléatoires, Vecteurs Gaussiens

Vecteur aléatoire à densité

Définition

Soit $X = (X_1, ..., X_n)'$ un vecteur aléatoire défini sur $(\Omega, \mathcal{A}, P)$. On dit que X admet la densité de probabilité conjointe f_X sur $\mathbb{R}^n$, si f_X est positive, intégrable, et pour tout $B \in \mathcal{B}(\mathbb{R}^n)$, on a :

$$P(X \in B) = \int_B f_X(x_1, ..., x_n) dx_1 ... dx_n.$$

Remarque

- **La densité conjointe f_X vérifie :** $\int_{\mathbb{R}^n} f_X(x) dx = 1.$
- **Pour tous $x \in \mathbb{R}^n$, on a :** $F_X(x) = \int_{-\infty}^{x_1} ..... \int_{-\infty}^{x_n} f_X(t_1, ..., t_n) dt_1 ... dt_n.$

Vecteurs aléatoires, Vecteurs Gaussiens

Proposition

Soit $X = (X_1, ..., X_n)'$ un vecteur aléatoire, défini sur $(\Omega, \mathcal{A}, P)$, de fonction de répartition F_X, et de densité de probabilité f_X. Alors,

- **Si F_X est continue sur $\mathbb{R}^n$ et si $\dfrac{\partial^n F_X}{\partial_{x_1} ... \partial_{x_n}}(x)$ existent presque partout sur $\mathbb{R}^n$, alors, la densité de la loi P_X par rapport à la mesure de Lebesgue sur $\mathbb{R}^n$ vaut :**

$$f_X(x_1, ..., x_n) = \frac{\partial^n F_X}{\partial_{x_1} ... \partial_{x_n}}(x_1, ..., x_n).$$

- **Pour tout $k \in [1 : n]$, la densité de probabilité de X_k est donnée par :**

$$f_{X_k}(x_k) = \int_{\mathbb{R}^{n-1}} f_X\left(x_1, \ldots, x_{k-1}, x_k, x_{k+1}, \ldots, x_n\right) \mathrm{d}\widetilde{x_k}, \quad x \in \mathbb{R},$$

où $\widetilde{x_k} := (x_1, \cdots, x_{k-1}, x_{k+1}, \cdots, x_n)$.

Vecteurs aléatoires, Vecteurs Gaussiens

Exemple :

Soit $(X, Y)'$ un couple aléatoire de fonction de répartition conjointe :

$$F_{(X,Y)}(x, y) = P\Big((X \leq x) \cap (Y \leq y)\Big).$$

Alors,

- **La densité conjointe du couple $(X, Y)'$ est donnée par :**

$$f_{(X,Y)}(x, y) = \frac{\partial^2 F_X}{\partial_x \partial_y}(x, y) \quad \textbf{avec} \quad \int_{\mathbb{R}^2} f_{(X,Y)}(x, y)dxdy = 1.$$

- **La densité de X est donnée par :**

$$f_X(x) = \int_{\mathbb{R}} f_{(X,Y)}(x, y)dy.$$

- **La densité de Y est donnée par :**

$$f_X(y) = \int_{\mathbb{R}} f_{(X,Y)}(x, y)dx.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Application :

Soit $(X, Y)'$ un couple aléatoire dont la loi est donnée par la densité de probabilité conjointe :

$$f_{(X,Y)}(x, y) = \frac{xy}{2}, \quad 0 \leq y \leq x \leq 2.$$

Il faut distinguer plusieurs cas, on trouve que :

$$F_{X,Y}(x, y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f_{(X,Y)}(s, t) dsdt = \begin{cases} 0 & \text{si } x < 0 \text{ ou } y < 0, \\ \frac{y^2}{16}\left(2x^2 - y^2\right) & \text{si } 0 \leq y \leq x \leq 2, \\ \frac{y^2}{16}\left(8 - y^2\right) & \text{si } 0 < y \leq 2 \leq x, \\ \frac{x^4}{16} & \text{si } 0 \leq x \leq y \text{ et } x < 2, \\ 1 & \text{si } x \leq 2 \text{ et } y \leq 2. \end{cases}$$

Vecteurs aléatoires, Vecteurs Gaussiens

Théorème

Soit $X = (X_1, ..., X_n)'$ un vecteur aléatoire, défini sur $(\Omega, \mathcal{A}, P)$, de fonction de répartition F_X, et de densité de probabilité f_X. Il y a équivalence entre les assertions suivantes :

1. **Les composantes X_k, $k \in [1 : n]$ sont des v.a(s) indépendantes.**
2. **La fonction de répartition conjointe est le produit des fonctions de répartitions marginales :**

$$F_X(x) = \prod_{k=1}^{n} F_{X_k}(x_k), \quad x = (x_1, ..., x_n)' \in \mathbb{R}^n.$$

3. **La densité conjointe est le produit des densités marginales :**

$$f_X(x) = \prod_{k=1}^{n} f_{X_k}(x_k), \quad x = (x_1, ..., x_n)' \in \mathbb{R}^n.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Exemple 1 :

On considère un couple aléatoire $(X, Y)'$ de densité de probabilité conjointe :

$$\begin{cases} f_{(X,Y)}(x,y) = axy^2, \quad 0 \leq x \leq y \leq 1, \\ f_{(X,Y)}(x,y) = 0 \quad \textbf{sinon}. \end{cases}$$

1. **Déterminer la constante a.**
2. **Déterminer les densités marginales de X et Y.**

Corrigé :

1. $\displaystyle\int_{\mathbb{R}^2} f_{(X,Y)}(x,y)dxdy = 1 \iff a.\int_0^1 x\Big(\int_x^1 y^2 dx\Big)dy = 1 \iff a = 10.$
2. $x \in [0,1] : \; f_X(x) = \displaystyle\int_{\mathbb{R}} f_{(X,Y)}(x,y)dy = ax\int_x^1 y^2 dy = \frac{10}{3}(x - x^4).$
3. $y \in [0,1] : \; f_Y(y) = \displaystyle\int_{\mathbb{R}} f_{(X,Y)}(x,y)dx = ay^2\int_0^y xdx = 5y^4.$

Vecteurs aléatoires, Vecteurs Gaussiens

Exemple 2 :

On considère la fonction suivante :

$$f(x,y) = \begin{cases} 2(x+y-2xy), & (x,y) \in [0,1]\times[0,1], \\ 0 & \textbf{sinon.} \end{cases}$$

1. **Calculer la probabilité de l'événement** $A = \left(|X-Y| \leq \frac{1}{2}\right)$.

Corrigé :

1. **Une simple manipulation des intégrales donne :**

$$P(A) = \int_0^{\frac{1}{2}} \left(\int_0^{x+\frac{1}{2}} f(x,y)dy \right) dx + \int_{\frac{1}{2}}^1 \left(\int_{x-\frac{1}{2}}^1 f(x,y)dy \right) dx = \frac{31}{48}.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Moyenne et matrice de covariances

Définition

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire défini sur $(\Omega, \mathcal{A}, P)$.

- **Si $X_k,\ k \in [1 : n]$ sont intégrables, la moyenne de X est le vecteur :**

$$E(X) = \Big(E(X_1), \ldots, E(X_n)\Big)'.$$

- **Si $X_k,\ k \in [1 : n]$ sont de carré intégrable, la variance de X est la matrice :**

$$V(X) = \begin{pmatrix} V(X_1) & \mathrm{Cov}(X_1, X_2) & \cdots & \mathrm{Cov}(X_1, X_n) \\ \mathrm{Cov}(X_2, X_1) & V(X_2) & \cdots & \mathrm{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{Cov}(X_n, X_1) & \mathrm{Cov}(X_n, X_2) & \cdots & V(X_n) \end{pmatrix}.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Remarque

- $V(X)$ **est une matrice symétrique positive.**
- $V(X) = E\Big((X - E[X])(X - E[X])'\Big)$.

Exemple :

Si $X_k,\ k \in [1 : n]$ **sont** n **v.a.(s) i.i.d centrées et de variance finie** σ^2**, alors,**

$$E(X) = (0, \ldots, 0)',$$

$$V(X) = \begin{pmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{pmatrix} = \sigma^2 I_n.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Rappel sur la covariance

Définition

Soient X et Y deux v.a(s) de carré intégrable définis sur $(\Omega, \mathcal{A}, P)$.

- **La covariance de X et Y est définie par :**

$$Cov(X,Y) = E\Big((X - E(X))(Y - E(Y))\Big).$$

- **X et Y sont dites non corrélées si et seulement si $Cov(X,Y) = 0$.**

Exemple :

Si X et Y sont indépendantes alors elles sont non corrélées.

Vecteurs aléatoires, Vecteurs Gaussiens

Propriétés

Soient X et Y deux v.a(s) de carré intégrable définies sur $(\Omega, \mathcal{A}, P)$. Alors,

- **Symétrie :** $Cov(X, Y) = Cov(Y, X)$.
- **Positivité :** $Cov(X, X) = V(X) \geq 0$.
- **Formule de König-Huygens :** $Cov(X, Y) = E(XY) - E(X)E(Y)$.
- **Bilinéarité : pour tous $a, b \in \mathbb{R}$, on a :**

$$Cov(aX + bY, Z) = aCov(X, Z) + bCov(Y, Z).$$

$$Cov(X, aY + bZ) = aCov(X, Z) + bCov(X, Y).$$

- $V(X_1 + \ldots + X_n) = \sum_{i=1}^{n} V(X_i) + 2 \sum_{1 \leq i < j \leq n} Cov(X_i, X_j)$.
- **Inégalité de Cauchy-Schwarz :** $|Cov(X, Y)| \leq \sqrt{V(X)}\sqrt{V(Y)}$.

Vecteurs aléatoires, Vecteurs Gaussiens

Théorème de Transfert

Théorème

Soient $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire, défini sur $(\Omega, \mathcal{A}, P)$, et de densité de probabilité f_X. Alors, en cas d'existence, pour toute fonction mesurable $g : \mathbb{R}^n \to \mathbb{R}$, on a :

$$E(g(X)) = \int_{\mathbb{R}^n} g(x) f_X(x) dx = \int_{\mathbb{R}^n} g(x_1, \ldots, x_n) f_X(x_1, \ldots, x_n) dx_1 \ldots dx_n.$$

Remarque

Pour un couple à densité $(X, Y)'$ et un couple discret $(U, V)'$, on a :

- $Cov(X, Y) = \int_{\mathbb{R}^2} \Big((x - E(X))(y - E(Y)) \Big) f_{(X,Y)}(x, y) dxdy.$
- $Cov(U, V) = \sum_u \sum_v \Big((u - E(U))(v - E(V)) \Big) P\Big((U = u) \cap (V = v) \Big).$

Vecteurs aléatoires, Vecteurs Gaussiens

Méthode de la fonction muette

Théorème

Soient $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire défini sur $(\Omega, \mathcal{A}, P)$. Alors X est de densité de probabilité f_X si et seulement si pour toute fonction mesurable et bornée $g : \mathbb{R}^n \to \mathbb{R}$, on a :

$$E(g(X)) = \int_{\mathbb{R}^n} g(x) f_X(x) dx, \quad x = (x_1, \ldots, x_n)'.$$

Exemple :

Quelle est la densité de probabilité conjointe du couple aléatoire :

$$(Z, W)' = (X + Y, X - Y)',$$

sachant que le couple aléatoire $(X, Y)'$ est de densité de probabilité conjointe :

$$f_{(X,Y)}(x, y) = \lambda^2 \exp(-\lambda(x + y)) 1_{(x>0)} 1_{(y>0)}.$$

Vecteurs aléatoires, Vecteurs Gaussiens

On cherche à mettre $E(g(Z,W))$ sous la forme :

$$E(g(Z,W)) = \int_{\mathbb{R}^2} g(z,w) f_{(Z,W)}(z,w) dz dw.$$

D'après le théorème de transfert, on a :

$$E(g(Z,W)) = E\Big(g(X+Y, X-Y)\Big) = \int_{\mathbb{R}^2} g(x-y, x+y) f_{(X,Y)}(x,y) dx dy$$

$$= \int_{\mathbb{R}^2} g(x-y, x+y) \lambda^2 \exp(-\lambda(x+y)) 1_{(x>0)} 1_{(y>0)} dx dy$$

$$= \int_0^{+\infty} \int_0^{+\infty} g(x-y, x+y) \lambda^2 \exp(-\lambda(x+y)) dx dy.$$

On a besoin du théorème suivant de changement de variables dans $\mathbb{R}^n$:

Vecteurs aléatoires, Vecteurs Gaussiens

Théorème

Soient φ une bijection continûment différentiable ainsi que son inverse φ^{-1} d'un ouvert O de $\mathbb{R}^n$ sur un ouvert O' de $\mathbb{R}^n$, $f : \mathbb{R}^n \to \mathbb{R}$ bornée et $g : \mathbb{R}^n \to \mathbb{R}$ intégrable. Alors,

$$\int_O f(\varphi(x))g(x)dx = \int_{O'} f(x)g(\varphi^{-1}(x))\left|\text{Jac } \varphi^{-1}(x)\right|dx.$$

Pour appliquer le lemme précédent, on pose :

$$(z, w) = \varphi(x, y) = (x - y, x + y), \quad O =]0, +\infty[^2.$$

Alors, $x - y > 0$ et $x + y > 0$. Par suite,

$$O' = \{(x, y); x > |y|\}, \quad \varphi^{-1}(z, w) = \left(\frac{z + w}{2}, \frac{z - w}{2}\right), \quad \left|\text{Jac } \varphi^{-1}(z, w)\right| = \frac{1}{2}.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Par conséquent,

$$E(g(Z,W)) = \int_{((z,w);z>|w|)} g(z,w)\lambda^2 \exp\Big(-\lambda\Big(\frac{z+w}{2}+\frac{z-w}{2}\Big)\Big)\frac{1}{2}dzdw$$

$$= \int_{((z,w);z>|w|)} g(z,w)\frac{\lambda^2}{2}\exp(-\lambda z)dzdw$$

$$= \int_{\mathbb{R}^2} g(z,w)\frac{\lambda^2}{2}\exp(-\lambda z)1_{((z,w);z>|w|)}dzdw.$$

On conclut que $(Z,W)'$ possède la densité conjointe :

$$f_{(Z,W)}(z,w) = \frac{\lambda^2}{2}\exp(-\lambda z)1_{((z,w);z>|w|)}.$$

On peut aussi déduire les densités marginales de Z et W :

$$f_{(Z)}(z) = \int_{\mathbb{R}} f_{(Z,W)}(z,w)dw \quad \textbf{et} \quad f_{(W)}(w) = \int_{\mathbb{R}} f_{(Z,W)}(z,w)dz.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Densité de probabilité de la somme de deux v.a(s) indépendantes :

Proposition

Soient X et Y deux v.a(s) indépendantes, définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$, et de densités de probabilité, (respectives), f_X et f_Y. Alors, la densité de probabilités de $Z = X + Y$ est donné par :

$$f_Z(z) = f_X * f_Y(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx.$$

Preuve :

Il suffit d'appliquer la méthode de la fonction muette :

$$E(g(Z)) = \int_{\mathbb{R}^2} g(x+y) f_X(x) f_Y(y) dxdy$$

$$= \int_{\mathbb{R}} g(z) \left(\int_{\mathbb{R}} f_X(x) f_Y(z-x) dx \right) dz = \int_{\mathbb{R}} g(z) f_X * f_Y(x) dz.$$

Vecteurs aléatoires, Vecteurs Gaussiens

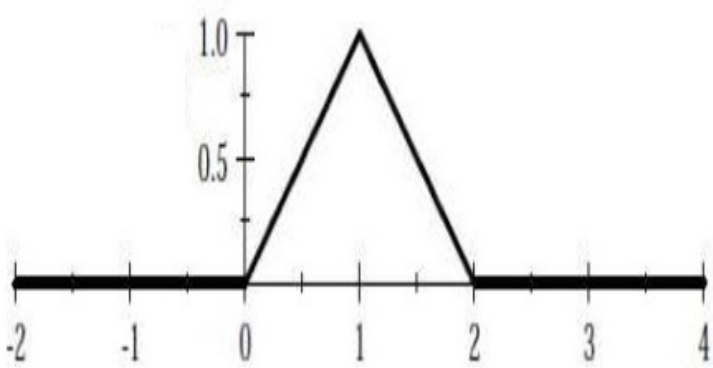
Exemple :

Soient X et Y deux v.a(s) indépendantes de lois Uniforme sur $[0,1]$. Pour tout $z \in \mathbb{R}$, on a :

$$f_{X+Y}(z) = \int_{\mathbb{R}} f_X(x) f_Y(z-x)dx = \int_0^1 f_Y(z-x)dx = \int_{z-1}^{z} f_Y(u)du.$$

Finalement, on obtient,

$$f_{X+Y}(z) = \begin{cases} 0 & \text{si } z \in]-\infty, 0], \\ z & \text{si } z \in]0,1], \\ 2-z & \text{si } z \in]1,2], \\ 0 & \text{si } z \in]2,+\infty[. \end{cases}$$



Vecteurs aléatoires, Vecteurs Gaussiens

Fonction caractéristique

Définition

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire, défini sur un espace probabilisé $(\Omega, \mathcal{A}, P)$, et de loi image P_X. La fonction caractéristique de X est une fonction à valeurs complexes, définie pour tout $t = (t_1, \ldots, t_n)' \in \mathbb{R}^n$ par :

$$\varphi_X(t) = E(e^{it'X}) = E\left(e^{i(t_1X_1+\ldots+t_nX_n)}\right) = \int_{\mathbb{R}^n} e^{it'x} dP_X(x).$$

Propriétés

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire, défini sur un espace probabilisé $(\Omega, \mathcal{A}, P)$, et de fonction caractéristique φ_X. Alors,

- $\varphi_X(0, \cdots, 0) = 1$, **et** $\forall\, t \in \mathbb{R}^n :\ \varphi_X(-t) = \overline{\varphi_X(t)}$ **et** $|\varphi_X(t)| \leq 1$.
- φ_X **est continue sur** $\mathbb{R}^n$.

Vecteurs aléatoires, Vecteurs Gaussiens

Théorème

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire, défini sur un espace probabilisé $(\Omega, \mathcal{A}, P)$, et de fonction caractéristique φ_X. Alors,

- **La fonction caractéristique de chaque X_k, $k \in [1 : n]$ est donnée par :**

$$\forall\, t_k \in \mathbb{R} : \ \varphi_{X_k}(t_k) = \varphi_X(0, \ldots, 0, t_k, 0, \ldots, 0).$$

- **Si les v.a(s) $X_1, \ldots, X_n$ sont indépendantes, alors,**

$$\varphi_{X_1+\ldots+X_n}(t) = \prod_{k=1}^{n} \varphi_{X_k}(t_k), \quad \forall\, t = (t_1, \ldots, t_n) \in \mathbb{R}^n.$$

- **Les composantes $X_1, \ldots, X_n$ sont indépendantes si et seulement on a :**

$$\varphi_X(t) = \prod_{k=1}^{n} \varphi_{X_k}(t_k), \quad \forall\, t = (t_1, \ldots, t_n)' \in \mathbb{R}^n.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Vecteurs Gaussiens

Définition

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire défini sur un espace probabilisé $(\Omega, \mathcal{A}, P)$. On dit que X est gaussien, (ou normal), dans $\mathbb{R}^n$ si toute combinaison linéaire de ses composantes est une v.a gaussienne dans $\mathbb{R}$, i.e., pour tout $\alpha = (\alpha_1, ..., \alpha_n)' \in \mathbb{R}^n$, la v.a :

$$Z = \alpha' X = \alpha_1 X_1 + ... + \alpha_n X_n$$

suit une loi gaussienne dans $\mathbb{R}$.

On écrit : $X \sim \mathcal{N}(\mu_X, \Gamma_X)$, où $u_X = E(X)$ est le vecteur moyenne de X, et Γ_X est la matrice de covariance du vecteur X.

Vecteurs aléatoires, Vecteurs Gaussiens

Proposition

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire dans $\mathbb{R}^n$ défini sur un espace probabilisé $(\Omega, \mathcal{A}, P)$.

- **Si X est un vecteur gaussien dans $\mathbb{R}^n$, alors toutes les composantes $X_k,\ k \in [1:n]$ sont gaussiennes dans $\mathbb{R}$.**
- **Si X est un vecteur gaussien dans $\mathbb{R}^n$, alors toute combinaison linéaire $Z = \alpha' X$ suit la gaussienne $\mathcal{N}(\alpha' \mu_X, \alpha' \Gamma_X \alpha)$.**
- **Si $X \sim \mathcal{N}(\mu_X, \Gamma_X)$, A une matrice non nulle et b un vecteur, alors,**

$$Y = AX + b \sim \mathcal{N}\Big(A\mu_X + b, A\Gamma_X A'\Big).$$

Vecteurs aléatoires, Vecteurs Gaussiens

Preuve :

- **Il suffit de prendre :** $\alpha = (0, \dots, 0, 1, 0 \dots, 0)'$ **et voir que :** $\alpha' X = X_k$.
- $$E(Z) = E\Big(\alpha' X\Big) = E\Big(\sum_{k=1}^{n} \alpha_k X_k\Big) = \sum_{k=1}^{n} \alpha_k E(X_k) = \alpha' E(X).$$
  $$V(Z) = V\Big(\alpha' X\Big) = V\Big(\sum_{k=1}^{n} \alpha_k X_k\Big) = \sum_{i=1}^{n}\sum_{j=1}^{n} \alpha_i \alpha_j Cov(X_i, X_j) = \alpha' \Gamma_X \alpha.$$
- **Il est clair que** Y **est une transformation linéaire de** X. **Par conséquent,** Y **est un vecteur gaussien dans** $\mathbb{R}^n$. **De plus, on a :**
  - $\forall\ i \in [1 : n],\ E(Y_i) = E\Big(\sum_{j=1}^{n} a_{ij} X_j + b_i\Big) = \sum_{j=1}^{n} a_{ij} E(X_j) + b_i.$
  - $V(Z) = E\Big((Y - E[Y])(Y - E[Y])'\Big) = E\Big(A(X - E[X])(X - E[X])' A'\Big)$
    $= AV(X)A'.$

Vecteurs aléatoires, Vecteurs Gaussiens

Proposition

Soient $\mu \in \mathbb{R}^n$ et Γ une matrice symétrique positive. Il existe alors un vecteur gaussien X de vecteur moyenne μ et de matrice de covariance Γ.

Exemple :

Montrer qu'il existe un vecteur gaussien dans $\mathbb{R}^3$ de paramètres :

$$\mu_X = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \quad \Gamma_X = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}.$$

Il est clair que Γ_X est symétrique et positive. En effet,

$$x'\Gamma_X x = \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

$$= \left(x_1 + \frac{x_2}{2} + x_3^2\right)^2 + \frac{3}{4}\left(x_2 + \frac{x_3}{3}\right)^2 + \frac{23}{36}x_3^2 \geq 0.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Théorème

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire, défini sur un espace probabilisé $(\Omega, \mathcal{A}, P)$, de moyenne μ_X et de matrice de variance Γ_X. Alors,

- **La densité conjointe de X est donnée par :**

$$f_X(x) = \frac{1}{(2\pi)^{\frac{n}{2}}\sqrt{det(\Gamma_X)}} \exp\left(-\frac{1}{2}\left[(x-\mu_X)'\Gamma_X^{-1}(x-\mu_X)\right]\right),$$

  avec $x = (x_1, ..., x_n)'$.

- **La fonction caractéristique de X est donnée par :**

$$\varphi_X(t) = \exp\left(it'\mu_X - \frac{1}{2}t'\Gamma_X t\right), \quad t \in \mathbb{R}^n.$$

Vecteurs aléatoires, Vecteurs Gaussiens

Remarque

Si X est un vecteur gaussien dans $\mathbb{R}^n$, alors $t'X$ est une v.a gaussienne dans $\mathbb{R}$, de moyenne $t'\mu_X$ et de variance $t\Gamma_X t'$. Par suite, pour tout $u \in \mathbb{R}$, on a :

$$\varphi_{t'X}(u) = E\left(e^{iut'X}\right) = exp\left(iut'\mu_X - \frac{1}{2}u^2 t'\Gamma_X t\right).$$

Prenons $u = 1$, on trouve que :

$$\varphi_X(t) = E\left(e^{it'X}\right) = \exp\left(it'\mu_X - \frac{1}{2}t'\Gamma_X t\right).$$

Vecteurs aléatoires, Vecteurs Gaussiens

Proposition

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire, défini sur un espace probabilisé $(\Omega, \mathcal{A}, P)$, de moyenne $\mu_X = m$ et de matrice de variances Γ_X. Alors, les v.a(s) $X_k,\ k \in [1:n]$ sont indépendantes si et seulement si la matrice de covariances de Γ_X est diagonale.

Preuve :

Il suffit, bien sûr, de montrer la réciproque. Supposons donc que Γ_X soit diagonale telle que $V(X_i) = \sigma_i^2$, alors sa fonction caractéristique est de la forme :

$$\varphi_X(t) = \exp\left(\sum_{i=1}^{n}\left(it_i m_i - \frac{1}{2}t_i^2\sigma_i^2\right)\right) = \prod_{i=1}^{n}\varphi_{X_i}(t_i).$$

D'où le résultat.

Vecteurs aléatoires, Vecteurs Gaussiens

Exemple :

Soient X et Y sont deux v.a(s) i.i.d de loi $\mathcal{N}(0,1)$. Alors, $E(X) = E(Y) = 0$ et $V(X) = V(Y) = 1$, et par suite $(X, Y)'$ est un vecteur gaussien de moyenne $m = (0,0)$ et de matrice de covariances diagonale :

$$\Gamma_X = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2.$$

La densité du couple $(X, Y)'$ est alors donnée par :

$$f_{(X,Y)}(x,y) = \frac{1}{2\pi} \exp\left(- \frac{x^2 + y^2}{2} \right) = f_X(x) f_Y(y).$$

La fonction caractéristique est donnée par :

$$\varphi_{(X,Y)}(t_1, t_2) = \exp\left(-\frac{1}{2}(t_1^2 + t_2^2) \right) = \varphi_{X_1}(t_1)\varphi_{X_2}(t_2).$$

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice :

Montrer que X_1 et $X_2 - X_3$ sont deux v.a(s) indépendants sachant que $X = (X_1, X_2, X_3)'$ est un vecteur gaussien dans $\mathbb{R}^3$ de matrice de covariances :

$$\Gamma_X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 4 \end{pmatrix}.$$

Correction :

Il suffit de voir que $Y = (X_1, X_2 - X_3)'$ est un vecteur gaussien. En effet,

$$Y = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & -1 \end{pmatrix} X.$$

De plus, on a :

$$Cov(Y_1, Y_2) = Cov(X_1, X_2 - X_3) = Cov(X_1, X_2) - Cov(X_1, X_3) = 1 - 1 = 0.$$

D'où le résultat puisque Γ_Y est devenue une matrice diagonale.

Vecteurs aléatoires, Vecteurs Gaussiens

TD (3) :

Exercice 1 :

Soient X et Y deux v.a.d(s) dont la loi conjointe est donnée par le tableau suivant :

$X \backslash Y$	0	1	2	3
0	0,22	0,20	0,00	0,02
1	0,05	0,11	0,04	0,01
2	0,04	0,07	0,02	0,22

1. **Vérifier que l'on dispose bien d'une loi de probabilité.**
2. **Déterminer les lois marginales de X et Y.**
3. **Calculer $E(X), E(Y), V(X)$ et $V(Y)$.**
4. **Trouver la matrice de covariances du couple $(X, Y)'$.**

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice 2 :

Soient X et Y deux v.a.d(s) à valeurs dans $\mathbb{N}$. On suppose que la loi conjointe du couple discret $(X, Y)'$ est donnée par :

$$\forall\,(i,j) \in \mathbb{N}^2 : \quad P((X=i)\cap(Y=j)) = a\frac{(i+j)}{i!j!}.$$

1. **Déterminer la valeur du réel a.**
2. **Déterminer les lois marginales de X et Y.**
3. **Les v.a.d(s) X et Y sont elles indépendantes ?**
4. **Démontrer que le couple $(X, Y)'$ admet une covariance et la calculer.**

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice 3 :

On considère le couple aléatoire $(X, Y)'$ de fonction de densité conjointe :

$$\begin{cases} f_{(X,Y)}(x,y) = ce^{-b(x+y)}, & 0 < x < y < +\infty, \\ f_{(X,Y)}(x,y) = 0 \quad \textbf{sinon.} \end{cases}$$

1. **Déterminer une relation entre b et c.**
   Dans la suite, on prend : $b = 1$ et $c = 2$.
2. **Déterminer les densités marginales de X et Y.**
3. **Montrer que X et Y ne sont pas indépendantes.**
4. **Calculer $E(X)$ et $E(XY)$.**

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice 4 :

Soient X et Y deux v.a(s) i.i.d qui possèdent la densité de probabilité :

$$f(x) = \frac{1_{(x>1)}}{x^2}.$$

On pose :

$$(Z, W)' = \left(\ln(X), 1 + \frac{\ln(Y)}{\ln(X)}\right)'.$$

1. **Déterminer la matrice de covariances du vecteur $(X, Y)'$.**
2. **Déterminer la densité conjointe du couple $(Z, W)'$.**
3. **Les v.a(s) Z et W sont-elles indépendantes ?**
4. **Quelle est la loi de probabilité de W ?**

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice 5 :

Supposons que $R \sim \mathcal{E}\left(\frac{1}{2}\right)$ **la loi Exponentielle de paramètre** $\frac{1}{2}$, **et** $\Theta \sim \mathcal{U}([0, 2\pi])$ **la loi Uniforme continue sur** $[0, 2\pi]$. **Supposons de plus que** R **et** Θ **sont indépendantes. Posons :**

$$X = \sqrt{R}\cos(\Theta), \quad Y = \sqrt{R}\sin(\Theta).$$

1. **Déterminer la densité conjointe du couple** $(X, Y)'$.
2. **En déduire que** X **et** Y **sont i.i.d de loi commune** $\mathcal{N}(0, 1)$.

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice 6 :

Soit $(X, Y)'$ un vecteur aléatoire gaussien dans $\mathbb{R}^2$ centré, et de matrice de covariances l'identité I_2. On pose :

$$Z = \frac{X+Y}{2}, \quad Q = \frac{X-Y}{2}, \quad U = \frac{(X-Z)^2}{2} + \frac{(Y-Z)^2}{2}.$$

1. **Déterminer la loi de Z et Q.**
2. **Calculer la matrice de covariances du couple $(Z, Q)'$.**
3. **Z et Q sont-elles indépendantes ?**
4. **Calculer $E(U)$.**
5. **Montrer que Z et U sont indépendantes.**

Vecteurs aléatoires, Vecteurs Gaussiens

Exercice 7 :

Considérons la matrice : $\Gamma = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 2 & 2 \\ -1 & 2 & 5 \end{pmatrix}$

1. **Montrer qu'il existe, dans $\mathbb{R}^3$, un vecteur gaussien $X = (X_1, X_2, X_3)'$ de moyenne $m = (0, 1, 1)'$ et de matrice de covariance Γ.**
2. **Préciser les relations d'indépendance entre les coordonnées de X.**
   Posons :
   $$Y_1 = X_1 + X_3, \quad Y_2 = \alpha X_1 + 2X_2 + \beta X_3 \quad \text{et} \quad Y_3 = -X_1 - X_2 + X_3.$$
3. **Montrer que $Y = (Y_1, Y_2, Y_3)'$ est un vecteur gaussien dont on donnera les paramètres.**
4. **Les v.a(s) Y_1, Y_2 et Y_3 sont-elles mutuellement indépendantes ?**
5. **Pour quelles valeurs de (α, β), les v.a(s) Y_2 et Y_3 sont-elles indépendantes ?**
6. **Montrer que X admet une densité de probabilité, puis la calculer.**

Plan :

1. Rappel sur les espaces probabilisés
2. Rappel sur les variables aléatoires
3. Fonctions génératrice et caractéristique
4. Vecteurs aléatoires, Vecteurs Gaussiens
5. **Espérance conditionnelle**
6. Convergences et approximations

Espérance conditionnelle

Descriptif du chapitre 5 :

- **Espérance conditionnelle : définition et propriétés.**
- **Caractérisation par projection orthogonale.**
- **Cas du couple discret.**
- **Cas du couple à densité.**
- **Cas du vecteur Gaussien.**

Espérance conditionnelle

Espérance conditionnelle :

Théorème

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé, $X : \Omega \to \mathbb{R}$ une v.a intégrable et $\mathcal{B} \subset \mathcal{A}$ une sous-tribu. Alors, il existe une unique fonction intégrable, notée $E(X \mid \mathcal{B})$, appelée l'espérance conditionnelle de X sachant la sous-tribu $\mathcal{B}$, qui satisfait les deux conditions suivantes :

- **$E(X \mid \mathcal{B})$ est $\mathcal{B}$-mesurable,**
- **pour toute v.a Y qui est $\mathcal{B}$-mesurable bornée, on a :**

$$E\Big(E(X \mid \mathcal{B})Y\Big) = E(XY).$$

Remarque

L'unicité est à comprendre "presque sûrement, (p.s)". Deux fonctions qui satisfont les conditions précédentes sont égales presque sûrement.

Espérance conditionnelle

Remarque

- **Pour $Y = 1_B$, $B \in \mathcal{B}$, on obtient :** $\int_B E(X \mid \mathcal{B})dP = \int_B XdP.$
- **La probabilité conditionnelle d'un événement $A \subset \Omega$, relativement à la tribu $\mathcal{B}$ est la fonction définie par :**

$$P\Big(A|\mathcal{B}\Big) = E\Big(1_A|\mathcal{B}\Big).$$

Preuve de l'existence de $E(X \mid \mathcal{B})$:

On commence par le cas où X est de carré intégrable. L'espace $L^2(\Omega, \mathcal{A}, P)$ est muni d'un produit scalaire :

$$\langle X, Y\rangle = \int XYdP = E(XY).$$

On a donc une notion d'orthogonalité et de projection orthogonale.

Espérance conditionnelle

- **Considérons le sous-espace fermé $L^2(\Omega, \mathcal{B}, P)$ constitué des fonctions de carré intégrable qui sont $\mathcal{B}$-mesurables. $E(X \mid \mathcal{B})$ est définie comme la projection orthogonale de X sur $L^2(\Omega, \mathcal{B}, P)$. Cette projection orthogonale appartient au sous-espace si bien que $E(X \mid \mathcal{B})$ est $\mathcal{B}$-mesurable. C'est la première condition.**
- **$X - E(X \mid \mathcal{B})$ est orthogonale à tous les éléments Y de $L^2(\Omega, \mathcal{B}, P)$:**

$$\langle X - E(X \mid \mathcal{B}), Y \rangle = 0.$$

Autrement dit, $E\Big(\Big(X - E(X \mid \mathcal{B})\Big) Y\Big) = 0$. C'est la seconde condition.

On peut généraliser cela aux v.a(s) positives. Soit $X \geq 0$, on pose :

$$X_n = \min(X, n).$$

X_n est borné, donc de carré intégrable et converge, en croissant, vers X.

Espérance conditionnelle

On va vérifier dans la suite que $E(X_n \mid \mathcal{B})$ est une fonction positive, et que la suite $E(X_n \mid \mathcal{B})$ est croissante. On définit alors,

$$E(X \mid \mathcal{B}) = \lim_{n\to\infty} E(X_n \mid \mathcal{B}) \in [0, +\infty].$$

En utilisant le théorème de convergence monotone, on montre que $E(X \mid \mathcal{B})$ satisfait les conditions voulues pour tout $Y \geq 0$.

Pour les v.a(s) intégrables, on les écrit comme différence de v.a(s) intégrables positives, pour lesquelles on a vu comment définir l'espérance conditionnelle.

Remarque

Le passage du cadre L^2 au cadre des v.a(s) positives, puis au cadre L^1 par décomposition comme différence de deux fonctions croissantes intégrables, est justifié par les propriétés de l'espérance conditionnelle qui vont être détaillées dans la suite.

Espérance conditionnelle

Proposition 1

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé, $X : \Omega \to \mathbb{R}$ une v.a intégrable et $\mathcal{B} \subset \mathcal{A}$ une tribu. Alors,

- $E(X \mid \mathcal{A}) = X$.
- $E\Big(X \mid \{\varnothing, \Omega\}\Big) = E(X)$.
- **Si X est $\mathcal{B}$-mesurable, alors $E(X \mid \mathcal{B}) = X$.**
- **Si X est indépendante de $\mathcal{B}$, alors $E(X \mid \mathcal{B}) = E(X)$.**
- **Linéarité : pour tout $a \in \mathbb{R}$:** $E\Big(aX + Y \mid \mathcal{B}\Big) = aE(X \mid \mathcal{B}) + E(Y \mid \mathcal{B})$.

Espérance conditionnelle

Preuve :

- **La v.a $E(X \mid \mathcal{A})$ est la projection de X sur $L^2(\Omega, \mathcal{A}, P)$, cette projection est égale à l'identité : $E(X \mid \mathcal{A}) = X$.**
- **Pour $E\Big(X \mid \{\varnothing, \Omega\}\Big)$, toute fonction mesurable relativement à la tribu $\{\varnothing, \Omega\}$ est constante. La v.a $E(X \mid \{\varnothing, \Omega\})$ est donc constante. Nous avons $E\Big(E(X \mid \mathcal{B})\Big) = E(X)$, cette constante vaut donc $E(X)$.**
- **Si X est $\mathcal{B}$-mesurable, X est dans $L^2(\Omega, \mathcal{B}, P)$, elle est donc égale à sa projection sur $L^2(\Omega, \mathcal{B}, P)$, c-à-d : $E\Big(E(X \mid \mathcal{B})\Big) = X$.**

Espérance conditionnelle

- **Si X est indépendante de $\mathcal{B}$, elle est indépendante de toute v.a Y $\mathcal{B}$-mesurable. Nous avons alors,**

$$E\Big(E(X \mid \mathcal{B})Y\Big) = E(XY) = E(X)E(Y) = E\Big(E(X \mid \mathcal{B})\Big)E(Y).$$

Prenons $Y = E\Big(X \mid \mathcal{B}\Big)$ qui est bien $\mathcal{B}$-mesurable. Nous avons,

$$E(Y^2) = E\left(E(X \mid \mathcal{B})^2\right) = \Big(E\Big(E(X \mid \mathcal{B})\Big)\Big)^2 = \Big(E(Y)\Big)^2,$$

ou encore $V(Y) = V\Big(E(X \mid \mathcal{B})\Big) = 0$. Ceci montre que $E\Big(X \mid \mathcal{B}\Big)$ est constante p.s. En conséquence, $E\Big(X \mid \mathcal{B}\Big) = E(X)$.

- **C'est la linéarité de la projection orthogonale.**

Espérance conditionnelle

Proposition 2

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé, $X : \Omega \to \mathbb{R}$ une v.a intégrable et $\mathcal{B} \subset \mathcal{A}$ une tribu. Alors,

- **Positivité : si $X \geq 0$, alors, $E(X \mid \mathcal{B}) \geq 0$.**
- **Monotonie : si $X \leq Y$, alors, $E(X \mid \mathcal{B}) \leq E(Y \mid \mathcal{B})$.**
- **Pour tout Y qui est $\mathcal{B}$-mesurable, positive si X est positive, bornée si X est intégrable, on a :**

$$E\Big(YX \mid \mathcal{B}\Big) = YE(X \mid \mathcal{B}).$$

- **Si $\mathcal{B}_1 \subset \mathcal{B}_2$, alors,**

$$E\Big(E\left(X \mid \mathcal{B}_1\right) \mid \mathcal{B}_2\Big) = E\Big(X \mid \mathcal{B}_1\Big),$$

$$E\Big(E\left(X \mid \mathcal{B}_2\right) \mid \mathcal{B}_1\Big) = E\Big(X \mid \mathcal{B}_1\Big).$$

Espérance conditionnelle

Preuve :

- **Positivité : soit $X \geq 0$. On prend : $Y = 1_{(E(X|\mathcal{B})<0)}$. Alors,**

$$E\Big(E(X \mid \mathcal{B})Y\Big) \leq 0 \text{ et } E(XY) \geq 0.$$

Ces deux expressions sont égales, elles sont donc toutes les deux nulles, ce qui implique que $E(X \mid \mathcal{B})1_{(E(X|\mathcal{B})<0)} = 0$ p.s, et par conséquent,

$$E(X \mid \mathcal{B}) \geq 0 \quad p.s.$$

- **Monotonie : d'après la linéarité et le point précédent, on obtient,**

$$E(Y \mid \mathcal{B}) - E(X \mid \mathcal{B}) = E\Big(Y - X \mid \mathcal{B}\Big) \geq 0.$$

Espérance conditionnelle

- **Soit Y $\mathcal{B}$-mesurable. La fonction $YE(X \mid \mathcal{B})$ est aussi $\mathcal{B}$-mesurable. De plus, pour tout Z qui est $\mathcal{B}$-mesurable, on a :**

$$E\Big(ZYE(X \mid \mathcal{B})\Big) = E(ZYX),$$

car ZY est $\mathcal{B}$-mesurable. La fonction $YE(X \mid \mathcal{B})$ satisfait donc les deux propriétés caractérisant $E(YX \mid \mathcal{B})$, et nous avons l'égalité :

$$E(YX \mid \mathcal{B}) = YE(X \mid \mathcal{B}) \quad \textbf{p.s.}$$

Espérance conditionnelle

- **Soit $\mathcal{B}_1 \subset \mathcal{B}_2$. La fonction $E\left(X \mid \mathcal{B}_1\right)$ est $\mathcal{B}_2$-mesurable si bien que :**

$$E\left(E\left(X \mid \mathcal{B}_1\right) \mid \mathcal{B}_2\right) = E\left(X \mid \mathcal{B}_1\right).$$

Démontrons l'égalité $E\left(E\left(X \mid \mathcal{B}_2\right) \mid \mathcal{B}_1\right) = E\left(X \mid \mathcal{B}_1\right)$. La fonction $E\left(E\left(X \mid \mathcal{B}_2\right) \mid \mathcal{B}_1\right)$ est $\mathcal{B}_1$-mesurable. De plus, pour toute v.a Y $\mathcal{B}_1$-mesurable, Y est à la fois $\mathcal{B}_1$ et $\mathcal{B}_2$-mesurable et d'après la propriété précédente, on a :

$$\begin{aligned} E\left(YE\left(E\left(X \mid \mathcal{B}_2\right) \mid \mathcal{B}_1\right)\right) &= E\left(E\left(E\left(YX \mid \mathcal{B}_2\right) \mid \mathcal{B}_1\right)\right) \\ &= E\left(E\left(YX \mid \mathcal{B}_2\right)\right) \\ &= E(YX). \end{aligned}$$

Ce sont les deux propriétés qui caractérisent $E\left(X \mid \mathcal{B}_1\right)$.

Espérance conditionnelle

Proposition 3 (Inégalité de Jensen)

Soit $(\Omega, \mathcal{A}, P)$ un espace probabilisé, $X : \Omega \to \mathbb{R}$ une v.a intégrable et $\mathcal{B} \subset \mathcal{A}$ une sous-tribu. Soit $\varphi : \mathbb{R} \to \mathbb{R}$ une fonction convexe. On suppose que X et $\varphi(X)$ sont intégrables ou positives. Alors,

$$\varphi\Big(E(X \mid \mathcal{B})\Big) \leq E\Big(\varphi(X) \mid \mathcal{B}\Big).$$

Preuve :

Une fonction convexe admet des dérivées à gauche et à droite en chaque point. Appliquons l'inégalité de convexité :

$$\varphi(x) \geq \varphi(x_0) + \varphi'_+(x_0)(x - x_0)$$

pour $x = X$ et $x_0 = E(X \mid \mathcal{B})$, on obtient :

$$\varphi(X) \geq \varphi\Big(E(X \mid \mathcal{B})\Big) + \varphi'_+\Big(E(X \mid \mathcal{B})\Big)\Big(X - E(X \mid \mathcal{B})\Big).$$

Espérance conditionnelle

On prend maintenant l'espérance conditionnelle des deux termes de cette inégalité, on obtient :

$$E\Big(\varphi(X) \mid \mathcal{B}\Big) \geq E\Big(\varphi\Big(E(X \mid \mathcal{B})\Big) \mid \mathcal{B}\Big) + E\Big(X - E(X \mid \mathcal{B})\Big)\varphi'_+\Big(E(X \mid \mathcal{B}) \mid \mathcal{B}\Big)$$

Les fonctions $\varphi\Big(E(X \mid \mathcal{B})\Big)$ **et** $\varphi'_+\Big(E(X \mid \mathcal{B})\Big)$ **sont** $\mathcal{B}$**-mesurables si bien que :**

$$E\Big(\varphi\Big(E(X \mid \mathcal{B}\Big) \mid \mathcal{B}\Big) = \varphi\Big(E(X \mid \mathcal{B})\Big),$$

$$E\Big(\Big(X - E(X \mid \mathcal{B})\Big)\varphi'_+\Big(E(X \mid \mathcal{B})\Big)\Big) = \varphi'_+\Big(E(X \mid \mathcal{B})\Big)E\Big(X - E(X \mid \mathcal{B}) \mid \mathcal{B}\Big) = 0.$$

L'inégalité est démontrée.

Espérance conditionnelle

Exemples :

Les fonctions $x \mapsto |x|, x \mapsto x^+, x \mapsto e^x, x \mapsto |x|^p$ pour $p \geq 1$ sont convexes. Appliquons, par exemple, l'inégalité de Jensen aux fonctions $x \mapsto |x|$ et $x \mapsto |x|^p$, on obtient :

$$\Big|E(X \mid \mathcal{B})\Big| \leq E\Big(|X| \mid \mathcal{B}\Big).$$

$$\Big|E(X \mid \mathcal{B})\Big|^p \leq E\Big(|X|^p \mid \mathcal{B}\Big).$$

Utilisons maintenant la monotonie de l'espérance :

$$\Big\|E(X \mid \mathcal{B})\Big\|_p^p = E\Big(\Big|E(X \mid \mathcal{B})\Big|^p\Big) \leq E\Big(E\Big(|X|^p \mid \mathcal{B}\Big)\Big) = E\left(|X|^p\right) = \|X\|_p^p.$$

Nous avons démontré l'inégalité recherchée entre la norme L^p d'une variable aléatoire et celle de son espérance conditionnelle.

Espérance conditionnelle

Conditionnement relativement à une v.a :

Définition

Soient $(\Omega, \mathcal{A}, P)$ un espace probabilisé et $X : \Omega \to \mathbb{R}$ une v.a. La tribu engendrée par X, notée $\sigma(X)$, est définie par :

$$\sigma(X) = \left\{ X^{-1}(B) \in \mathcal{A} \mid B \text{ borélien de } \mathbb{R} \right\}.$$

Exemple :

Si $X \sim \mathcal{B}(p)$, alors, $\sigma(X) = \left\{ \emptyset, \Omega, X^{-1}(\{0\}), X^{-1}(\{1\}) \right\}$.

Proposition

Soient $(\Omega, \mathcal{A}, P)$ un espace probabilisé et $X : \Omega \to \mathbb{R}$ une v.a. Alors, une v.a $Y : \Omega \to \mathbb{R}$ est $\sigma(X)$-mesurable si et seulement si il existe une fonction $f : \mathbb{R} \to \mathbb{R}$ borélienne telle que : $Y = f(X)$.

Espérance conditionnelle

Définition

Soient X et Y deux v.a(s) définies sur $(\Omega, \mathcal{A}, P)$.

- **L'espérance conditionnelle de Y relativement à X, notée $E(Y \mid X)$, est définie par :**
$$E(Y \mid X) = E\Big(Y \mid \sigma(X)\Big).$$
- **Soit $A \in \mathcal{A}$. La probabilité conditionnelle de A relativement à X est définie par :**
$$P(A \mid X) = E\Big(1_A \mid \sigma(X)\Big).$$

Remarque

La v.a $E(Y \mid X)$ est $\sigma(X)$-mesurable, donc c'est une fonction de X, sa valeur en x est notée par $E(Y \mid X = x)$. C'est l'espérance de Y sachant que X a pris la valeur x, et on a pour P-presque tout $\omega \in \Omega$,

$$E(Y \mid X)(\omega) = E\Big(Y \mid X = X(\omega)\Big).$$

Espérance conditionnelle

Exemples de calcul d'espérances conditionnelles :

Cas du couple aléatoire discret :

Définition

Soient X et Y deux v.a.d(s), définies sur $(\Omega, \mathcal{A}, P)$, et à valeurs, (respectivement), dans E et F. Pour $y \in F$, si $P(Y = y) > 0$, on appelle loi conditionnelle de X sachant l'événement $(Y = y)$ la famille des nombres :

$$\Big(P\Big(X = x | Y = y\Big)\Big)_{x \in E}.$$

Remarque

- **Pour tout $y \in F$ tel que $P(Y = y) > 0$, on a :**

$$P(X = x | Y = y) = \frac{P((X = x) \cap (Y = y))}{P(Y = y)}.$$

Espérance conditionnelle

- **Si X et Y sont indépendantes, alors,** $P\Big(X = x|Y = y\Big) = P(X = x)$.
- **Formule des probabilités totales :**

$$P(X = x) = \sum_{y \in F} P\Big(X = x|Y = y\Big)P(Y = y).$$

- **Formule de Bayes :**

$$P\Big(X = x|Y = y\Big) = \frac{P\Big(Y = y|X = x\Big)P(X = x)}{P(Y = y)}.$$

Espérance conditionnelle

Définition

Soient X et Y deux v.a.d(s), définies sur $(\Omega, \mathcal{A}, P)$, et à valeurs, (respectivement), dans E et F. On appelle espérance conditionnelle de X sachant Y la v.a.d notée : $E(X|Y)$, et égale à $h(Y)$ où h est la fonction définie par :

$$h(y) = E\Big(X|Y = y\Big) = \sum_{x \in E} xP\Big(X = x|Y = y\Big).$$

$h(y)$ est l'espérance de la v.a.d X par rapport à sa loi conditionnelle.

Espérance conditionnelle

Exemple :

Soient $X \sim \mathcal{P}(\lambda)$ et $Y \sim \mathcal{P}(\mu)$ deux v.a.d(s) indépendantes. Alors, $X + Y \sim \mathcal{P}(\lambda + \mu)$, et pour tout $0 \leq i \leq n$, on a :

$$P\Big(X = i | X + Y = n\Big) = \frac{P\Big((X = i) \cap (X + Y = n)\Big)}{P(X + Y = n)}$$

$$= \frac{P(X = i)P(Y = n - i)}{P(X + Y = n)}$$

$$= \frac{\frac{e^{-\lambda}\lambda^i}{i!} \cdot \frac{e^{-\mu}\mu^{n-i}}{(n-i)!}}{e^{-(\lambda+\mu)}\frac{(\lambda+\mu)^n}{n!}}$$

$$= C_n^i \Big(\frac{\lambda}{\lambda+\mu}\Big)^i \Big(\frac{\mu}{\lambda+\mu}\Big)^{n-i}$$

Espérance conditionnelle

Finalement, on obtient,

$$P\Big(X = i | X + Y = n\Big) = C_n^i \Big(\frac{\lambda}{\lambda+\mu}\Big)^i \Big(1 - \frac{\lambda}{\lambda+\mu}\Big)^{n-i}.$$

Ainsi, la loi conditionnelle de X sachant $(X + Y = n)$ est la loi Binomiale $\mathcal{B}\Big(\frac{\lambda}{\lambda+\mu}\Big)$ d'espérance :

$$h(n) = E\Big(X | X + Y = n\Big) = \frac{n\lambda}{\lambda+\mu}.$$

Par conséquent,

$$E\Big(X | X + Y\Big) = \frac{\lambda(X+Y)}{\lambda+\mu}.$$

N.B : Si $X \sim \mathcal{B}(n, p)$, alors $E(X) = np$.

Espérance conditionnelle

Théorème de l'espérance totale

Soient X et Y deux v.a.d(s), définies sur $(\Omega, \mathcal{A}, P)$, et à valeurs, (respectivement), dans E et F, et telles que $E(|X|) < +\infty$. Alors, la v.a.d $E(X|Y)$ admet une espérance, et on a :

$$E\Big(E(X|Y)\Big) = E(X).$$

Preuve :

$$\begin{aligned} E\Big(E(X|Y)\Big) &= E(h(Y)) \\ &= \sum_{y\in F} h(y)P(Y=y) \\ &= \sum_{y\in F} E(X|Y=y)P(Y=y) \end{aligned}$$

Espérance conditionnelle

$$= \sum_{y\in F}\Big(\sum_{x\in E} xP\Big(X=x|Y=y\Big)\Big)P(Y=y)$$

$$= \sum_{x\in E} x\Big(\sum_{y\in F} P\Big(X=x|Y=y\Big)P(Y=y)\Big)$$

$$= \sum_{x\in E} x\sum_{y\in F} P\Big((X=x)\cap(Y=y)\Big)$$

$$= \sum_{x\in E} x\ P\Big((X=x)\cap\bigcup_{y\in F}(Y=y)\Big)$$

$$= \sum_{x\in E} x\ P\Big((X=x)\cap\Omega\Big)$$

$$= \sum_{x\in E} xP(X=x) = E(X).$$

Espérance conditionnelle

Exercice :

Soient $X_1, ..., X_n$ n v.a.d(s) i.i.d, définies sur $(\Omega, \mathcal{A}, P)$, de loi commune une Bernoulli $\mathcal{B}(p)$, $p \in]0,1[$, et soit $S_n := X_1 + ... + X_n$ leur somme. Pour $s \in [0, n]$, donner la loi conditionnelle de X_1 sachant $(S_n = s)$ et en déduire une formule de la v.a.d $E(X_1|S_n)$.

Corrigé :

Puisque les v.a.d(s) $X_1, ..., X_n$ sont i.i.d, on a :

$$E(X_1|S_n) = E(X_2|S_n)..... = E(X_n|S_n).$$

D'autre part, par linéarité, on obtient :

$$S_n = E(S_n|S_n) = E\Big(\sum_{i=1}^{n} X_i|S_n\Big) = \sum_{i=1}^{n} E(X_i|S_n) = nE(X_1|S_n).$$

Finalement, on trouve que : $E(X_1|S_n) = \dfrac{S_n}{n}$ **et** $E\Big(X_1|S_n = s\Big) = \dfrac{s}{n}$.

Espérance conditionnelle

Cas du couple aléatoire à densité :

Définition

Soit (X, Y) un couple aléatoire, défini sur $(\Omega, \mathcal{A}, P)$, de densité conjointe $f_{(X,Y)}$, et de densités marginales f_X et f_Y.

- **La densité conditionnelle de Y sachant $(X = x)$ est définie par :**

$$f(y|x) := \frac{f_{(X,Y)}(x, y)}{f_X(x)}, \quad \text{pour tout } x \in \mathbb{R} \text{ tel que } f_X(x) \neq 0.$$

- **La densité conditionnelle de X sachant $(Y = y)$ est définie par :**

$$f(x|y) := \frac{f_{(X,Y)}(x, y)}{f_Y(y)}, \quad \text{pour tout } y \in \mathbb{R} \text{ tel que } f_Y(y) \neq 0.$$

Espérance conditionnelle

Définition

Soit (X, Y) un couple aléatoire, défini sur $(\Omega, \mathcal{A}, P)$, de densité conjointe $f_{(X,Y)}$, et de densités marginales f_X et f_Y.

- **On appelle espérance conditionnelle de X sachant Y la v.a notée : $E(X|Y)$, et égale à $h(Y)$ où h est la fonction définie par :**

$$h(y) = E\Big(X|Y = y\Big) = \int_{\mathbb{R}} xf(x|y)dx.$$

- **On appelle espérance conditionnelle de Y sachant X la v.a notée : $E(Y|X)$, et égale à $h(X)$ où h est la fonction définie par :**

$$h(x) = E\Big(Y|X = x\Big) = \int_{\mathbb{R}} yf(y|x)dy.$$

Espérance conditionnelle

Exemple :

Soit (X, Y) un couple aléatoire continu de densité conjointe :

$$f_{(X,Y)}(x,y) = 2 \times 1_D, \quad D = \Big\{0 \leqslant x \leqslant 1,\ 0 \leqslant y \leqslant 1,\ 0 \leqslant x+y \leqslant 1\Big\}.$$

- $f_X(x) = \displaystyle\int_{\mathbb{R}^2} f_{(X,Y)}\,dy = 2\int_0^{1-x} dy = 2(1-x), \quad 0 \leq x \leq 1.$
- $f(y|x) := \dfrac{f_{(X,Y)}(x,y)}{f_X(x)} = \dfrac{1}{1-x}, \quad 0 < x < 1.$
- $E\Big(Y|X=x\Big) = \displaystyle\int_{\mathbb{R}} y f(y|x)dx = \int_0^1 \frac{y}{1-x}dx = \frac{1-x}{2}.$
- **Finalement, on obtient :** $E\Big(Y|X\Big) = \dfrac{1-X}{2}.$

Espérance conditionnelle

Théorème de l'espérance totale

Soit (X, Y) un couple aléatoire, défini sur $(\Omega, \mathcal{A}, P)$, de densité conjointe $f_{(X,Y)}$, et de densités marginales f_X et f_Y, telles que $E(|Y|) < +\infty$. Alors, la v.a $E(Y|X)$ admet une espérance, et on a :

$$E\Big(E(Y|X)\Big) = E(Y).$$

Preuve :

On peut suivre le même raisonnement utilisé dans le cas discret.

Espérance conditionnelle

Application :

Soit un couple aléatoire (X, Y) de densité conjointe :

$$f_{X,Y}(x,y) = \frac{1}{x} e^{-x-\frac{y}{x}}, \quad x > 0,\ y > 0.$$

On veut calculer $E(Y)$. Alors,

- $f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)dy = e^{-x},\ x > 0$ **(une loi exponentielle, $\lambda = 1$).**
- $f(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)} = \frac{1}{x} e^{-\frac{y}{x}},\ x > 0,$ **(une loi exponentielle, $\mu = \frac{1}{x}$).**

On a donc,

$$E\Big(Y|X = x\Big) = \int_{\mathbb{R}} y f(y|x)dx = \frac{1}{\mu} = x.$$

Finalement, on obtient :

$$E(Y|X) = X \quad \textbf{et} \quad E\Big(E(Y|X)\Big) = E(X) = \lambda = 1.$$

Espérance conditionnelle

Généralisation à n v.a(s) :

Définition

Soit $X = (X_1, \ldots, X_n)'$ un vecteur aléatoire défini sur Ω. La tribu engendrée par les X_i, notée $\sigma(X_1, \ldots, X_n)$, est définie par :

$$\sigma(X_1, \ldots, X_n) = \left\{ (X_1, \ldots, X_n)^{-1}(A), \mid A \subset \mathbb{R}^n \text{ borélien} \right\}.$$

On pose : $E\Big(Y \mid X_1, X_2, \ldots, X_n\Big) := E\Big(Y \mid \sigma(X_1, \ldots, X_n)\Big)$.

Remarque

Toute fonction $\sigma(X_1, \ldots, X_n)$-mesurable est de la forme : $f(X_1, X_2, \ldots, X_n)$ où $f : \mathbb{R}^n \to \mathbb{R}$ est borélienne. On a donc une fonction :

$$(x_1, \ldots, x_n) \mapsto E\Big(Y \mid X_1 = x_1, \ldots, X_n = x_n\Big)$$

définie de $\mathbb{R}^n$ dans $\mathbb{R}$ qui, composée avec $(X_1, X_2, \ldots, X_n)$, redonne la v.a $E(Y \mid X_1, X_2, \ldots, X_n)$.

Espérance conditionnelle

Cas Gaussien :

Théorème

Soit $(X, Y_1, \ldots, Y_n)' : \Omega \to \mathbb{R}^{n+1}$ un vecteur gaussien défini sur $(\Omega, \mathcal{A}, P)$, alors $E\Big(X \mid Y_1, \ldots, Y_n\Big)$ est une v.a. gaussienne, et il existe des nombres $a_1, \ldots, a_n, b \in \mathbb{R}$ tels que :

$$E\Big(X \mid Y_1, \ldots, Y_n\Big) = a_1 Y_1 + \cdots + a_n Y_n + b.$$

Pour calculer les coefficients $a_1, \ldots, a_n, b$, on pose : $Y := Y_1, \ldots, Y_n$ et Γ la matrice de covariance du vecteur $(X, Y)'$, alors,

$$\Gamma = \begin{pmatrix} \Gamma_X & \Gamma_{X,Y} \\ \Gamma'_{X,Y} & \Gamma_Y \end{pmatrix},$$

alors, on a la formule explicite :

$$E\Big(X \mid Y_1, \ldots, Y_n\Big) = E(X) + \Gamma_{X,Y}\Gamma_Y^{-1}\Big(Y - E(Y)\Big).$$

Espérance conditionnelle

Exemple :

Soit $(X, Y, Z)'$ un vecteur gaussien centré de matrice de covariance :

$$\Gamma = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & 1 & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & 1 \end{pmatrix}.$$

Alors,

$$E\Big(Z \mid X, Y\Big) = \Big(\frac{1}{2}, \frac{1}{2}\Big) \begin{pmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{pmatrix}^{-1} \begin{pmatrix} X \\ Y \end{pmatrix}.$$

Par conséquent,

$$E\Big(Z \mid X, Y\Big) = \frac{X + Y}{3}.$$

Espérance conditionnelle

TD (4) :

Exercice 1 :

Dans une expérience consistant à jeter deux tétraèdres parfaitement symétriques, dont les faces sont numérotées de 1 à 4, on considère les v.a.d(s) X, égale à la somme des points, et Y, égale à leur différence en valeur absolue.

1. **Spécifier un espace probabilisé permettant de décrire cette expérience.**
2. **Déterminer la loi conjointe de X et Y ainsi que leurs espérances.**
3. **Calculer $E(X|Y)$ et $E(Y|X)$.**

Espérance conditionnelle

Exercice 2 :

On considère le vecteur aléatoire $(X, Y)'$ de fonction de densité conjointe :

$$f_{(X,Y)}(x, y) = 4y(x - y)e^{-(x+y)}, \quad 0 \leq y \leq x.$$

1. **Vérifier que $f_{(X,Y)}$ définie bien une densité de probabilité sur $\mathbb{R}^2$.**
2. **Déterminer les densités marginales de X et Y.**
3. **Déterminer la densité conditionnelle de X sachant Y.**
4. **Déterminer $E(X|Y)$.**
5. **Calculer $P(X < 1|Y = y)$.**

Espérance conditionnelle

Exercice 3 :

On considère le vecteur gaussien $(X, Y)'$ de fonction de densité conjointe :

$$f_{(X,Y)}(x, y) = \frac{1}{2\pi} e^{-x^2+xy-\frac{y^2}{2}}, \quad (x, y) \in \mathbb{R}^2.$$

1. **Vérifier que $f_{(X,Y)}$ définie bien une densité de probabilité sur $\mathbb{R}^2$.**
2. **Déterminer les densités marginales de X et Y.**
3. **En déduire $E(X), E(Y), V(X)$ et $V(Y)$.**
4. **Déterminer la densité conditionnelle $f(y|x)$. En déduire $E(Y|X)$.**
5. **Déterminer $f(x|y)$ et $E(X|Y)$.**
6. **Trouver la matrice de covariances du vecteur gaussien $(X, Y)'$.**

Espérance conditionnelle

Exercice 4 :

Soit $(X, Y, Z)'$ un vecteur gaussien centré de matrice de covariance :

$$\Gamma = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}.$$

1. **Montrer que $E\Big(X \mid Y, Z\Big) = \dfrac{Y+Z}{3}$.**
2. **Montrer que $E\Big(X \mid Z\Big) = \dfrac{Z}{2}$.**
3. **Montrer que $(Y+Z, Z)'$ est un vecteur gaussien de matrice de covariance :**
$$\widetilde{\Gamma} = \begin{pmatrix} 6 & 3 \\ 3 & 2 \end{pmatrix}.$$
4. **En déduire $E\Big(Y+Z \mid Z\Big)$.**
5. **Conclure que l'on a bien $E\Big(E\Big(X \mid Y, Z\Big) \mid Z\Big) = E\Big(X \mid Z\Big)$.**

Espérance conditionnelle

Exercice 5 :

Soient X une v.a définie sur un espace probabilisé $(\Omega, \mathcal{A}, P)$ et $\mathcal{B}_1 \subset \mathcal{B}_2$ deux sous-tribus de $\mathcal{A}$.

1. **Montrer que :**

$$E\left(\left[X - E\left(X \mid \mathcal{B}_2\right)\right]^2\right) + E\left(\left[E\left(X \mid \mathcal{B}_2\right) - E\left(X \mid \mathcal{B}_1\right)\right]^2\right) = E\left(\left[X - E\left(X \mid \mathcal{B}_1\right)\right]^2\right).$$

2. **On pose : $V\left(X \mid \mathcal{B}_1\right) = E\left(X^2 \mid \mathcal{B}_1\right) - \left(E\left(X \mid \mathcal{B}_1\right)\right)^2$. Montrer que :**

$$V(X) = E\Big(V\left(X \mid \mathcal{B}_1\right)\Big) + V\Big(E\left(X \mid \mathcal{B}_1\right)\Big).$$

3. **Soit $Y_1, Y_2, \ldots$ une suite de v.a(s) i.i.d d'espérance et de variance finies. Soit N une v.a.d à valeurs dans $\mathbb{N}$, indépendante de tous les Y_i. Soit finalement $X := Y_1 + Y_2 + \cdots + Y_N$. Calculer $E(X_N)$ et $V(X_N)$.**

Plan :

1. Rappel sur les espaces probabilisés
2. Rappel sur les variables aléatoires
3. Fonctions génératrice et caractéristique
4. Vecteurs aléatoires, Vecteurs Gaussiens
5. Espérance conditionnelle
6. Convergences et approximations

Convergences et approximations

Descriptif du chapitre 6 :

- **Convergence presque sûre.**
- **Convergence en probabilité.**
- **Convergence en norme $p \geq 1$.**
- **Convergence en loi.**
- **Loi faible et loi forte des grands nombres.**
- **Théorème de la limite centrale.**
- **Convergences et approximations.**

Convergences et approximations

Deux inégalités classiques :

Proposition

1. **Inégalité de Markov simple : soit X une v.a positive et intégrable. Pour tout $\lambda > 0$, on a :**

$$P(X \geq \lambda) \leq \frac{E(X)}{\lambda}.$$

En particulier, si X_n est intégrable, alors, pour tout $\lambda > 0$, on a :

$$P\Big(|X| \geq \lambda\Big) \leq \frac{E|X|}{\lambda}.$$

2. **Inégalité de Bienaymé-Tchebychev : soit X une v.a de carré intégrable. Pour tout $\lambda > 0$, on a :**

$$P\Big(|X - E(X)| \geq \lambda\Big) \leq \frac{V(X)}{\lambda^2}.$$

Convergences et approximations

Preuve :

1. **Étant donné que :** $1_{(X\geq\lambda)} \leq \dfrac{X}{\lambda}$, **on obtient :**

$$P(X \geq \lambda) = E\left(1_{(X\geq\lambda)}\right) \leq E\left(\frac{X}{\lambda}\right) = \frac{E(X)}{\lambda}.$$

2. **Il suffit de voir que :** $1_{\left(|X-E(X)|\geq\lambda\right)} \leq \dfrac{(X-E(X))^2}{\lambda^2}$.

Proposition

Inégalité de Markov généralisée : si $h : \mathbb{R} \to \mathbb{R}_+^*$ **est une fonction croissante et** X **une v.a telle que** $h(X)$ **est intégrable, alors, pour tout** $\lambda > 0$, **on a :**

$$P(X \geq \lambda) \leq \frac{E(h(X))}{h(\lambda)}.$$

Convergences et approximations

Applications :

1. **Pour $h(x) = x$, on trouve l'inégalité de Markov simple.**
2. **Pour $h(x) = x^2$, on trouve l'inégalité de Bienaymé-Tchebychev.**
3. **Pour $h(x) = e^{tx}$, si e^{tX} est intégrable, on trouve l'inégalité de Chernoff :**

$$P(X \geq \lambda) \leq e^{-\sup_{t \geq 0}(t\lambda - H(t))},$$

où $H(t) = \ln\left(E(e^{tX})\right)$.

Exemple 1 :

Soit $X \sim \mathcal{B}(20, 0.5)$. **On va vérifier l'inégalité de Bienaymé-Tchebychev pour** $\lambda = 3$. **On a :** $E(X) = 20 \times 0.5 = 10$ **et** $V(X) = 20 \times 0.5 \times (1 - 0.5) = 5$.

Convergences et approximations

Par conséquent,

$$\begin{aligned}
P\Big(|X - E(X)| \geq \lambda\Big) &= 1 - P(|X - 10| < 3) \\
&= 1 - P(7 < X < 13) \\
&= 1 - \sum_{k=8}^{12} P(X = k) \\
&= 1 - \sum_{k=8}^{12} C_{20}^{k} \left(\frac{1}{2}\right)^{k} \left(\frac{1}{2}\right)^{20-k} \\
&= 1 - \left(\frac{1}{2}\right)^{20} \sum_{k=8}^{12} C_{20}^{k} \\
&= 1 - 0,7368 = 0,2632 \\
&< \frac{V(X)}{\lambda^2} = 0,555.
\end{aligned}$$

Convergences et approximations

Exemple 2 :

Si $X \sim \mathcal{N}(\mu, \sigma^2)$ et Φ sa fonction de répartition, alors $E(X) = \mu$, $V(X) = \sigma^2$, et l'inégalité de Bienaymé-Tchebychev, donne pour tout $\lambda > 0$:

$$P\Big(|X - \mu| < \lambda\Big) \geq 1 - \frac{\sigma^2}{\lambda^2}.$$

Par conséquent,

$$P\Big(-\frac{\lambda}{\sigma} < \frac{X-\mu}{\sigma} < \frac{\lambda}{\sigma}\Big) < 1 - \frac{\sigma^2}{\lambda^2}.$$

Le fait que $\dfrac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$ implique que :

$$\Phi\Big(\frac{\lambda}{\sigma}\Big) - \Phi\Big(-\frac{\lambda}{\sigma}\Big) < 1 - \frac{\sigma^2}{\lambda^2}.$$

Finalement, on obtient :

$$\Phi\Big(\frac{\lambda}{\sigma}\Big) < 1 - \frac{\sigma^2}{2\lambda^2} \quad (*).$$

Pour $\lambda = 4$ et $\sigma = 2.5$, la table statistique de $\mathcal{N}(0,1)$, confirme le résultat dans $(*)$: $\Phi\Big(\dfrac{\lambda}{\sigma}\Big) = 0.9452$ et $2 - \dfrac{\sigma^2}{\lambda^2} = 1.6094$.

Convergences et approximations

Notations :

Dans la suite de ce chapitre, on note :

- $(X_n)_n$ **est une suite de v.a(s), et** X **est une v.a définies sur le même espace probabilisé** $(\Omega, \mathcal{F}, P)$.
- $\left(\varphi_{X_n}\right)_n$ **est la famille des fonctions caractéristiques de** $(X_n)_n$, **et** φ_X **celle de** X.
- $\left(F_{X_n}\right)_n$ **est la famille des fonctions de répartition de** $(X_n)_n$, **et** F_X **celle de** X.
- **Dans le cas continu,** $\left(f_{X_n}\right)_n$ **est la famille des densités de probabilité de** $(X_n)_n$, **et** f_X **celle de** X.
- **Dans le cas discret,** $\left(P_{X_n}\right)_n$ **est la famille des lois de probabilité de** $(X_n)_n$, **et** P_X **celle de** X.

Convergences et approximations

Définition

Lorsque $n \to +\infty$, on dit que :

- $X_n \xrightarrow{p.s} X$ **si pour presque tout** $\omega \in \Omega$, **on a :** $\lim_{n\to+\infty} X_n(\omega) = X(\omega)$.

  C-à-d : $P\Big(\Big\{\omega, \lim_{n\to+\infty} X_n(\omega) = X(\omega)\Big\}\Big) = 1.$

- $X_n \xrightarrow{P} X$ **si** $\forall\, \epsilon \geq 0, \quad \lim_{n\to+\infty} P\Big(|X_n - X| > \epsilon\Big) = 0.$

- **Soit** $p \geq 1$. $X_n \xrightarrow{L^p} X$ **si** $(X_n)_n$ **et** X **sont** p**-intégrables et on a :**

  $$\lim_{n\to+\infty} E\Big(|X_n - X|^p\Big) = 0.$$

- $X_n \xrightarrow{\mathcal{L}} X$ **si pour toute** $f : \mathbb{R} \longmapsto \mathbb{R}$ **continue et bornée, on a :**

  $$\lim_{n\to+\infty} E\Big(f(X_n)\Big) = E\Big(f(X)\Big).$$

Convergences et approximations

Remarque

- $X_n \xrightarrow{p.s} X$ **si il existe un négligeable** $\mathcal{N}$, $\big(P(\mathcal{N}) = 0\big)$, **tel que pour tout** $\omega \in \Omega \setminus \mathcal{N}$ **on a :** $\lim\limits_{n\to+\infty} X_n(\omega) = X(\omega)$.
- $X_n \xrightarrow{P} X$ **si** $\forall\, \epsilon > 0, \quad \lim\limits_{n\to+\infty} P\Big(|X_n - X| \leq \epsilon\Big) = 1.$
- **Si on note :** $\|X\|_p = \Big(E|X|^p\Big)^{\frac{1}{p}}$, **alors,** $X_n \xrightarrow{L^p} X$ **si** $(X_n)_n$ **et** X **sont** p**-intégrables, et on a :** $\lim\limits_{n\to+\infty} \|X_n - X|\|_p = 0.$
- $X_n \xrightarrow{\mathcal{L}} X$ **si pour toute** $f : \mathbb{R} \longmapsto \mathbb{R}$ **continue et bornée, on a :**

$$\lim_{n\to+\infty} \int_\Omega f(X_n) dP_{X_n} = \int_\Omega f(X) dP_X.$$

Convergences et approximations

Exemple :

Considérons la suite de v.a.d(s) $(X_n)_n$ où chaque X_n prenant deux valeurs 0 et $\sqrt{n}$ avec les probabilités suivantes :

$$P(X_n = 0) = 1 - \frac{1}{n}, \qquad P(X_n = \sqrt{n}) = \frac{1}{n}.$$

Lorsque $n \to +\infty$, on a :

1. $X_n \xrightarrow{L^1} 0$, **car** $E|X_n - 0| = E(X_n) = 0 \times \left(1 - \frac{1}{n}\right) + \sqrt{n} \times \frac{1}{n} = \frac{1}{\sqrt{n}} \longrightarrow 0.$
2. $X_n \xrightarrow{p} 0$, **car d'après l'inégalité de Markov simple on a :**

$$P\Big(|X_n| \geq \epsilon\Big) \leq \frac{E|X_n|}{\epsilon} = \frac{1}{\epsilon\sqrt{n}} \longrightarrow 0.$$

Convergences et approximations

Théorème de Portemanteau

Les cinq assertions suivantes sont équivalentes :

- **Pour toute fonction f bornée et continue :** $\lim_{n\to+\infty} E\Big(f(X_n)\Big) = E\big(f(X)\big).$
- **Pour toute fonction f bornée et uniformément continue :**

$$\lim_{n\to+\infty} E\Big(f(X_n)\Big) = E\left(f(X)\right).$$

- **Pour tout fermé F :** $\limsup_{n\to+\infty} P\left(X_n \in F\right) \leq P\left(X \in F\right).$
- **Pour tout ouvert O :** $\liminf_{n\to+\infty} P\left(X_n \in O\right) \geq P\left(X \in O\right).$
- **Pour tout borélien A tel que** $P\left(X \in \partial A\right) = 0,$

$$\lim_{n\to+\infty} P\left(X_n \in A\right) = P\left(X \in A\right).$$

Convergences et approximations

Remarque

- **Une autre définition de la convergence en loi est proposée comme suit :**

$$X_n \xrightarrow{\mathcal{L}} X \text{ si } \lim_{n\to+\infty} F_{X_n}(x) = F_X(x) \text{ en tout } x \in \mathcal{C}_F,$$

où $\mathcal{C}_F$ est l'ensemble des points de continuité de F.

- **Dans la pratique, on utilise les deux astuces suivants :**
  - **Dans le cas des v.a.d(s) :**

$$X_n \xrightarrow{\mathcal{L}} X \quad \text{si} \quad \lim_{n\to+\infty} P(X_n = x) = P(X = x).$$

  - **Dans le cas des v.a(s) à densités :**

$$X_n \xrightarrow{\mathcal{L}} X \quad \text{si} \quad \lim_{n\to+\infty} f_{X_n}(x) = f_X(x).$$

Convergences et approximations

Exemple 1 :

Soit $(X_n)_n$ une suite de v.a.d(s) telle que chaque X_n suit une loi Binomiale $\mathcal{B}\left(n, \frac{\lambda}{n}\right)$, alors, $X_n \xrightarrow{\mathcal{L}} X \sim \mathcal{P}(\lambda)$ une loi de Poisson. En effet,

$$\begin{aligned}
\lim_{n\to+\infty} P(X_n = x) &= \lim_{n\to+\infty} C_n^x \left(\frac{\lambda}{n}\right)^x \left(1-\frac{\lambda}{n}\right)^{n-x} \\
&= \lim_{n\to+\infty} \frac{n!}{x!(n-x)!} \left(\frac{\lambda}{n}\right)^x \left(1-\frac{\lambda}{n}\right)^{n-x} \\
&= \frac{\lambda^x}{x!} \lim_{n\to+\infty} \left(\prod_{k=0}^{x-1} \frac{(n-k)}{n}\right) \left(1-\frac{\lambda}{n}\right)^{-x} \left(1-\frac{\lambda}{n}\right)^n \\
&= \frac{\lambda^x}{x!} \left(\prod_{k=0}^{x-1} 1\right) \lim_{n\to+\infty} e^{-x \ln\left(1-\frac{\lambda}{n}\right)} e^{n \ln\left(1-\frac{\lambda}{n}\right)} \\
&= \frac{\lambda^x}{x!} \times 1 \times 1 \times e^{-\lambda} = P(X = x).
\end{aligned}$$

Convergences et approximations

Exemple 2 :

Si $X_n \sim \mathcal{N}\left(0, \frac{1}{n}\right)$, **alors,**

$$f_{X_n}(x) = \sqrt{\frac{n}{2\pi}} e^{-\frac{nx^2}{2}} \to \begin{cases} 0 & \text{si } x \neq 0, \\ +\infty & \text{si } x = 0. \end{cases}.$$

qui est la densité de probabilité d'une v.a dégénérée en 0, (égale à une fonction de Dirac δ_0**). Ce comportement suggère que la masse de probabilité se concentre en** $x = 0$**. Finalement,**

$$X_n \xrightarrow{\mathcal{L}} X = 0, \ p.s,$$

qui est une v.a dégénérée en 0.

Convergences et approximations

Exemple 3 :

Soit $(X_n)_n$ une suite de v.a(s) telle que chaque X_n admet pour densité :

$$f_{X_n}(x) = \frac{n}{\pi(1+n^2x^2)}, \quad x \in \mathbb{R}.$$

La fonction de répartition de X_n est donnée par :

$$F_{X_n}(x) = \int_{-\infty}^{x} f_{X_n}(t)dt = \frac{1}{\pi}\left(\arctan(nx) + \frac{\pi}{2}\right).$$

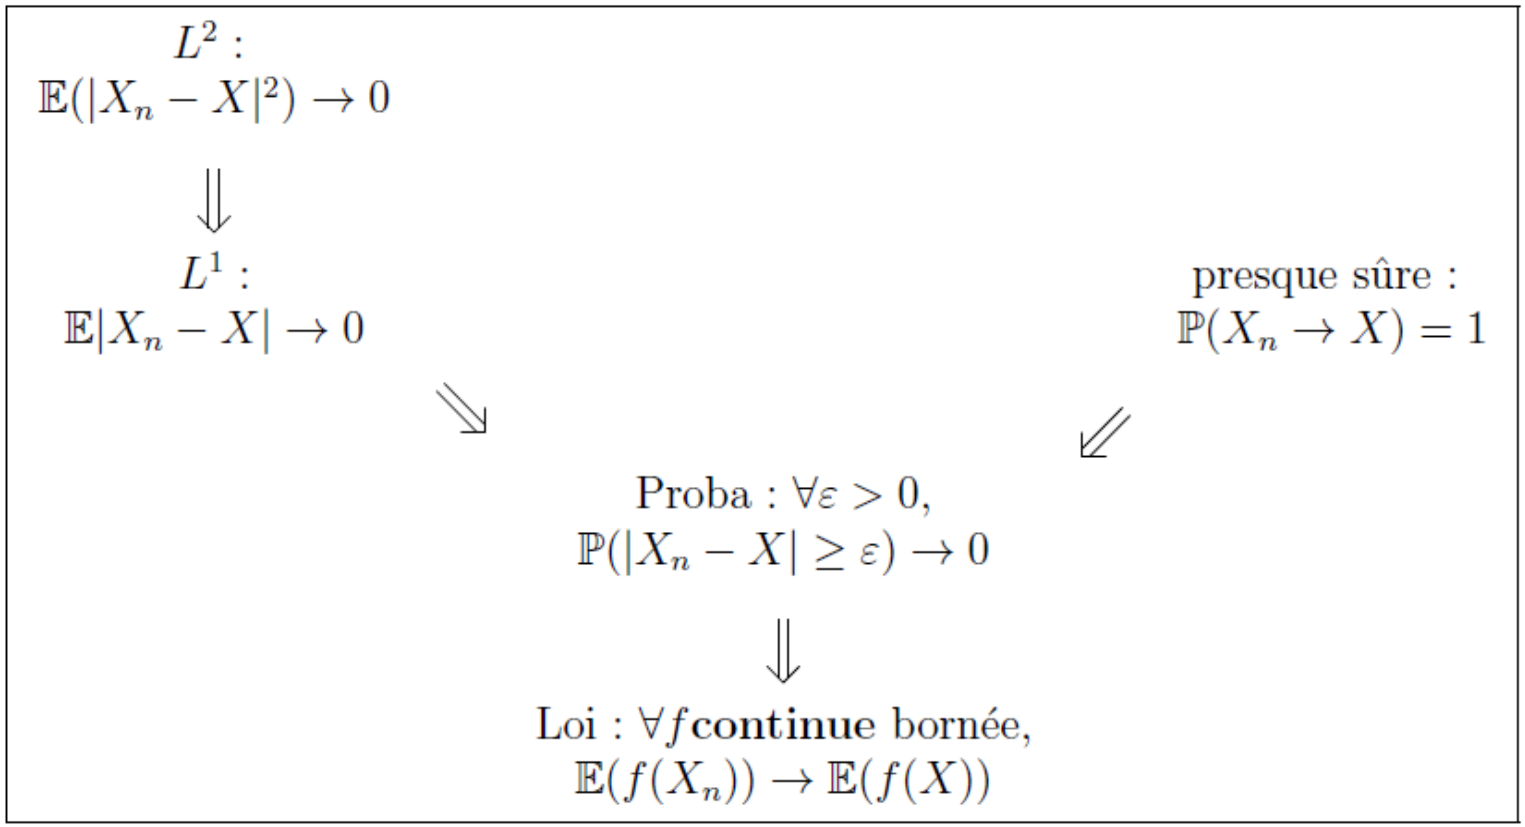
- **Si** $x < 0$, $\arctan(nx) \to -\frac{\pi}{2}$, **et donc,** $F_{X_n}(x) \to 0$.
- **Si** $x > 0$, $\arctan(nx) \to \frac{\pi}{2}$, **et donc,** $F_{X_n}(x) \to 1$.

Finalement, $F_{X_n}(x) \to F_X(x) = \begin{cases} 0 & \text{si } x < 0, \\ 1 & \text{si } x \geq 0. \end{cases}$, **et par suite,** $X_n \xrightarrow{\mathcal{L}} X = 0$ $p.s$,

qui est une v.a dégénérée en 0.

Convergences et approximations

Dans la suite, on va démontrer les implications suivantes :



Convergences et approximations

Proposition

Soit $p \geq 1$. Si $X_n \xrightarrow{L^p} X$, alors, $X_n \xrightarrow{P} X$.

Preuve :

Il suffit d'appliquer l'inégalité de Markov généralisée pour $h(x) = x^p$:

$$\forall\, \varepsilon > 0, \quad P\Big(|X_n - X| \geq \varepsilon\Big) \leq \frac{E\big(|X_n - X|^p\big)}{\varepsilon^p}.$$

Remarque

La réciproque est en général fausse. Dans l'exemple précédent, page 223, on a trouvé que : $X_n \xrightarrow{p} 0$, mais :

$$E|X_n - 0|^2 = E(X_n^2) = 0^2 \times \left(1 - \frac{1}{n}\right) + \left(\sqrt{n}\right)^2 \times \frac{1}{n} = 1 \neq 0.$$

On a aussi : $E|X_n - 0|^3 = E(X_n^3) = 0^3 \times \left(1 - \frac{1}{n}\right) + \left(\sqrt{n}\right)^3 \times \frac{1}{n} = \sqrt{n} \to +\infty.$

Convergences et approximations

Inégalité de Cauchy-Schwarz (ICS) :

Si X et Y sont deux v.a(s) de carré intégrable, alors,

$$\left|E(XY)\right| \leq \|X\|_2 \|Y\|_2.$$

Proposition

1. **Si $X_n \xrightarrow{L^2} X$, alors, $X_n \xrightarrow{L^1} X$.**
2. **Si $X_n \xrightarrow{L^2} X$, alors, on a la convergence des espérances et variances.**

Preuve :

1. **On applique l'ICS pour $Y = 1$:** $E|X_n - X| \leq \sqrt{E|X_n - X|^2}$.
2. **On applique l'ICS pour X_n et X :** $\left(\sqrt{E|X_n|^2} - \sqrt{E|X|^2}\right)^2 \leq E|X_n - X|^2$.

Convergences et approximations

Théorème de la convergence dominée (TCD)

Si $X_n \xrightarrow{p.s} X$, et si il existe une v.a $Y \in L^1(\Omega)$ telle que $|X_n| \leq Y$ pour tout $n \in \mathbb{N}$, alors, $X_n \xrightarrow{L^1} X$. En particulier, $\lim_{n\to+\infty} E(X_n) = E(X)$.

Théorème de la convergence monotone

Si (X_n) est une suite croissante de v.a(s) positives, alors,

$$\lim_{n\to+\infty} E\Big(X_n\Big) = E\Big(\lim_{n\to+\infty} X_n\Big).$$

Lemme de Fatou

Si (X_n) est une suite de v.a(s) positives, alors,

$$\liminf_{n\to+\infty} E\Big(X_n\Big) \geq E\Big(\liminf_{n\to+\infty} X_n\Big).$$

Convergences et approximations

Proposition

$X_n \xrightarrow{p.s} X$, **si :** $\forall\, \varepsilon > 0,\ \sum_n P\Big(|X_n - X| \geq \varepsilon\Big) < +\infty.$

Exemple :

Si $X_n \sim \mathcal{B}\Big(\frac{1}{n}\Big)$, **alors,** $\forall\, \varepsilon > 0,\ P\big(|X_n - 0| \geq \varepsilon\big) = P(X_n = 1) = \frac{1}{n^2}.$

Par conséquent, le critère de Riemann implique que : $X_n \xrightarrow{p.s} 0.$

Lemme de Borel-Cantelli

1. **Si** $\sum_{n\geq 0} P(A_n) < +\infty,$ **alors,** $P\big(\limsup_{n\to\infty} A_n\big) = 0.$
2. **Si les** A_n **sont indépendants et** $\sum_{n\geq 0} P(A_n) = +\infty,$ **alors,**

$$P(\limsup_{n\to\infty} A_n) = 1, \quad \textbf{où} \quad \limsup_{n\to\infty} A_n = \bigcap_{n\geq 0} \bigcup_{m\geq n} A_m.$$

Convergences et approximations

Proposition

Les deux assertions suivantes sont équivalentes :

- $X_n \xrightarrow{p.s} X$.
- $\forall\, \epsilon > 0,\ P\left(\limsup_{n\to\infty} \{|X_n - X| \geq \epsilon\}\right) = 0.$

Proposition

Soit $g : \mathbb{R} \longmapsto \mathbb{R}$ une fonction continue.

- **Si** $X_n \xrightarrow{p.s} X$, **alors,** $g(X_n) \xrightarrow{p.s} g(X)$.
- **Si** $X_n \xrightarrow{P} X$, **alors,** $g(X_n) \xrightarrow{P} g(X)$.
- **Si** $X_n \xrightarrow{\mathcal{L}} X$, **alors,** $g(X_n) \xrightarrow{\mathcal{L}} g(X)$.

Convergences et approximations

Proposition

Si $X_n \xrightarrow{p.s} X$, alors, $X_n \xrightarrow{P} X$.

Preuve :

Soit $\varepsilon > 0$. Si $X_n \xrightarrow{p.s} X$, alors, $|X_n - X| \xrightarrow{p.s} 0$, et par continuité de la fonction $g(x) = 1_{(|x| \geq \varepsilon)}$ en 0, on en déduit que $Y_n = 1_{(|X_n - X| \geq \varepsilon)} \xrightarrow{p.s} 0$. Finalement, le TCD implique que : $\lim_{n \to +\infty} E(Y_n) = \lim_{n \to +\infty} P(|X_n - X| \geq \varepsilon) = 0$.

Remarque

Inversement, si $X_n \xrightarrow{P} X$, alors il existe une sous suite $(X_{n_k})_k$ telle que $X_{n_k} \xrightarrow{p.s} X$.

Convergences et approximations

Théorème de Paul Lévy

- $X_n \xrightarrow{\mathcal{L}} X$ **si et seulement si** φ_{X_n} **converge simplement vers** φ_X.
- **Si** $\left(\varphi_{X_n}\right)_n$ **est une suite de fonctions caractéristiques qui converge simplement vers une fonction** φ **dont la partie réelle est continue en** 0, **alors il existe une v.a** X **telle que** $\varphi_X = \varphi$ **et** $X_n \xrightarrow{\mathcal{L}} X$.

Exemple : (approximation de la loi de Poisson par la loi Binomiale)

Si $X_n \sim \mathcal{B}(n, p_n)$ **telle que :** $np_n \to \lambda > 0$, **lorsque** $n \to +\infty$, **alors,** $X_n \xrightarrow{\mathcal{L}} X$ **qui suit une loi de Poisson** $\mathcal{P}(\lambda)$. **En effet, lorsque** $n \to +\infty$, **on a :**

$$\varphi_{X_n}(t) = \left(1 - p_n + p_n e^{it}\right)^n$$

$$= \left(1 - \frac{np_n(1 - e^{it})}{n}\right)^n$$

Convergences et approximations

$$= e^{n \ln\left(1 - \frac{np_n(1-e^{it})}{n}\right)} \longrightarrow e^{\lambda(e^{it}-1)} = \varphi_X(t).$$

Application :

Soit $X \sim \mathcal{B}(100, 0.05)$. **Nous allons calculer :** $P(X = 2)$.

- **Calcul exact :**

$$P(X = 2) = C_{100}^2 (0.05)^2 (1 - 0.05)^{100-2} \approx 0.0812.$$

- **Calcul approché :**

  On approche $\mathcal{B}(100, 0.05)$ **par :** $\mathcal{P}(\lambda = 100 \times 0.05 = 5)$. **Par suite,**

$$P(X = 2) \approx e^{-5} \frac{5^2}{2!} \approx 0.0843.$$

Convergences et approximations

Proposition

Si $X_n \xrightarrow{P} X$, **alors,** $X_n \xrightarrow{\mathcal{L}} X$.

Preuve :

Soient $t \in \mathbb{R}$ **et** $\varepsilon > 0$. **On a :**

$$\begin{aligned}
\left|e^{itX_n} - e^{itX}\right| &= \left|e^{itX_n} - e^{itX}\right| 1_{\left\{|X_n - X| \geq \varepsilon\right\}} + \left|e^{itX_n} - e^{itX}\right| 1_{\left\{|X_n - X| < \varepsilon\right\}} \\
&\leq \left(\left|e^{itX_n}\right| + \left|e^{itX}\right|\right) 1_{\left\{|X_n - X| \geq \varepsilon\right\}} + \left|e^{itX_n} - e^{itX}\right| 1_{\left\{|X_n - X| < \varepsilon\right\}} \\
&\leq 2 \times 1_{\left\{|X_n - X| \geq \varepsilon\right\}} + \left|e^{itX_n} - e^{itX}\right| 1_{\left\{|X_n - X| < \varepsilon\right\}}.
\end{aligned}$$

Convergences et approximations

Comme $\forall\, a, b \in \mathbb{R}$, $\left|e^{ia} - e^{ib}\right| \leq |b-a|$, **on en déduit que :**

$$\begin{aligned}\left|e^{itX_n} - e^{itX}\right| &\leq 2 \times 1_{\left\{|X_n - X| \geq \varepsilon\right\}} + |t|\left|X_n - X\right| 1_{\left\{|X_n - X| < \varepsilon\right\}} \\ &\leq 2 \times 1_{\left\{|X_n - X| < \varepsilon\right\}} + |t|\varepsilon,\end{aligned}$$

puis que,

$$\begin{aligned}|\varphi_{X_n}(t) - \varphi_X(t)| = \left|E\left(e^{itX_n} - e^{itX}\right)\right| &\leq E\left|e^{itX_n} - e^{itX}\right| \\ &\leq 2P\Big(|X_n - X| \geq \varepsilon\Big) + |t|\varepsilon.\end{aligned}$$

Convergences et approximations

Le terme $|t|\varepsilon$ est arbitrairement petit, (uniformément en n), pour ε petit tandis qu'à ε fixé le second terme converge vers 0 lors $n \to +\infty$ par définition de la convergence en probabilité. Finalement, $\left(\varphi_{X_n}\right)_n$ converge simplement vers une φ, et on en déduit la convergence en loi via le théorème de Paul Lévy.

Théorème de Slutsky

Si $X_n \xrightarrow{\mathcal{L}} X$ **et** $Y_n \xrightarrow{P} c =$ **(constante), alors,** $(X_n, Y_n) \xrightarrow{\mathcal{L}} (X, c)$.
En particulier,

$$X_n Y_n \xrightarrow{\mathcal{L}} cX,$$

$$X_n + Y_n \xrightarrow{\mathcal{L}} X + c,$$

$$\frac{X_n}{Y_n} \xrightarrow{\mathcal{L}} \frac{X}{c}, \quad \text{lorsque } c \neq 0.$$

Convergences et approximations

Loi faible des grands nombres :

Théorème (1)

Soit $(X_n)_n$ est une suite de v.a(s) i.i.d, possédant une espérance $E(X_1)$ et une variance $V(X_1)$. On pose :

$$\overline{X_n} = \frac{1}{n}\sum_{i=1}^{n} X_i \quad \text{(appelée la moyenne empirique)}.$$

Alors,

$$\overline{X_n} \xrightarrow{P} E(X_1).$$

Preuve :

Les X_i sont de même loi, alors, $E(\overline{X_n}) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \frac{1}{n}\Big(nE(X_1)\Big) = E(X_1),$

et par indépendance : $V(\overline{X_n}) = \frac{1}{n^2}\sum_{i=1}^{n} V(X_i) = \frac{1}{n}\Big(nV(X_1)\Big) = \frac{V(X_1)}{n}.$

Convergences et approximations

Par conséquent, l'inégalité de Bienaymé-Tchebychev donne :

$$\forall\, \varepsilon > 0, \quad \leq P\Big(|\overline{X_n} - E(X_1)| \geq \epsilon\Big) \leq \frac{V(\overline{X_n})}{\epsilon^2} = \frac{V(X_1)}{n\epsilon^2}.$$

Finalement, le théorème des gendarmes nous donne le résultat.

Application :

Dans une succession de n épreuves de Bernoulli indépendantes : $X_i \sim \mathcal{B}(p)$, on a : $\overline{X_n} \xrightarrow{p} E(X_1) = p$. Ce résultat justifie le fait que l'on peut avoir une valeur approchée de la probabilité du succès en prenant la fréquence du succès sur un grand nombre de tentatives. Par exemple, pour voir si une pièce est équilibrée, on la lance un grand nombre de fois, et la fréquence de pile doit être proche du résultat $\frac{1}{2}$.

Convergences et approximations

Théorème (2)

Soit $(X_n)_n$ est une suite de v.a(s) i.i.d, possédant une espérance $E(X_1)$ et une variance $V(X_1)$. Alors,

$$\overline{X_n} \xrightarrow{L^2} E(X_1).$$

Preuve :

$$E\left(\left(\overline{X_n} - E(X_1)\right)^2\right) = E\left(\left(\frac{(X_1 - E(X_1)) + \cdots + (X_n - E(X_n))}{n}\right)^2\right)$$

$$= \sum_{i=1}^{n} \frac{1}{n^2} E\left((X_i - E(X_i))^2\right)$$

$$= \frac{V(X_1)}{n} \xrightarrow[n\to+\infty]{} 0.$$

Convergences et approximations

Loi forte des grands nombres (LFGN) :

Théorème

Soit $(X_n)_n$ une suite de v.a(s) i.i.d, possédant une espérance $E(X_1)$ et une variance $V(X_1)$. Alors,

$$\overline{X_n} \xrightarrow{p.s} E(X_1).$$

Application : (approximation d'une fonction de répartition)

On définit la fonction de répartition empirique comme suit :

$$F_n(x) = \frac{1}{n}\sum_{i=1}^{n} 1_{(X_i \leq x)}, \quad x \in \mathbb{R}.$$

Alors, lorsque n tend vers l'infini, $F_n(x) \xrightarrow{c.s} F(x)$ qui est la fonction de répartition de X_1. Il suffit d'appliquer la LFGN pour : $Y_i = 1_{(X_i \leq x)}$. Par suite,

$$F_n(x) \xrightarrow{c.s} E(Y_1) = E\left(1_{(X_1 \leq x)}\right) = P(X_1 \leq x) = F(x).$$

Convergences et approximations

Théorème de la limite centrale (TCL) :

Théorème

Soit $(X_n)_n$ une suite de v.a(s) i.i.d, possédant une espérance $E(X_1)$ et une variance $V(X_1)$. Alors,

$$Z_n = \frac{\sqrt{n}\left(\overline{X_n} - E(X_1)\right)}{\sigma(X_1)} \xrightarrow{\mathcal{L}} X \sim \mathcal{N}(0,1).$$

Preuve :

Posons : $Y_i = \dfrac{X_i - E(X_1)}{\sigma(X_1)}$. **Les v.a(s)** Y_i **sont i.i.d, centrées,** $(E(Y_i) = 0)$**,**

et réduites, $(V(Y_i) = 1)$**. De plus, on a :**

$$Z_n = \sum_{i=1}^{n} \frac{Y_i}{\sqrt{n}}.$$

Convergences et approximations

On a vu dans le chapitre (3) que si Y est une v.a centré réduite, alors sa fonction caractéristique admet le développement limité suivant :

$$\varphi_Y(t) = 1 - \frac{t^2}{2} + o(t^2), \qquad t \to 0.$$

On déduit par indépendance que :

$$\varphi_{Z_n}(t) = \left(\varphi_{Y_1}\left(\frac{t}{\sqrt{n}}\right)\right)^n = \left(1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right)^n \longrightarrow e^{\frac{-t^2}{2}}, \quad \textbf{lorsque } n \to +\infty.$$

Mais cette limite est la fonction caractéristique de la loi normale centrée réduite $\mathcal{N}(0,1)$, d'où l'on déduit le TCL grâce au théorème de convergence de Paul Lévy.

Convergences et approximations

Application : (approximation de la loi Binomiale par la loi normale)

Si $X_n \sim \mathcal{B}(n,p)$, **alors,** $X_n = \sum_{i=1}^{n} Y_i$ **qui est la somme de** n **v.a(s) i.i.d de loi commune** $\mathcal{B}(p)$. **Donc ce cas, on a :**

$$E(Y_1) = p,\ V(Y_1) = p(1-p),\ X_n = n\overline{Y_n}.$$

$$E(X_n) = np \text{ et } V(X_n) = np(1-p).$$

Par conséquent, le TCL implique que :

$$Z_n = \frac{\sqrt{n}\left(\overline{Y_n} - E(Y_1)\right)}{\sigma(Y_1)} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

Finalement, on déduit que :

$$Z_n = \frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

Convergences et approximations

Remarque

Le TCL assure que, pour n assez grand, on a l'approximation suivante :

$$\overline{X_n} \approx E(X_1) + \frac{\sigma(X_1)}{\sqrt{n}}\mathcal{N}(0,1).$$

Ce qui indique que la convergence dans la LFGN a lieu à la vitesse $\frac{\sigma(X_1)}{\sqrt{n}}$.

On a aussi :

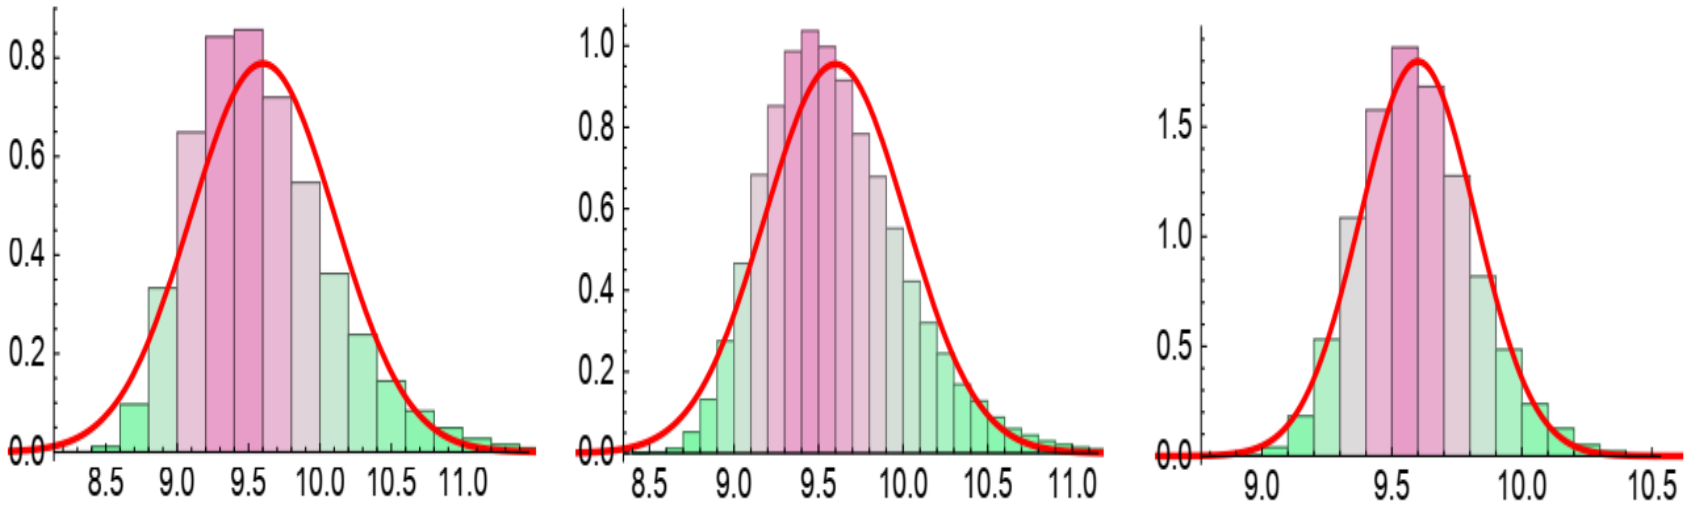
$$\overline{X_n} \approx \mathcal{N}\Big(E(X_1), \frac{V(X_1)}{n}\Big),$$

et,

$$\sum_{i=1}^{n} X_i \approx \mathcal{N}\Big(nE(X_1), nV(X_1)\Big).$$

Convergences et approximations

Exemple de simulation : (histogramme et densité)



Plus n est assez grand, plus les sommets de l'histogramme seront bien ajustés par le graphe d'une densité de la loi normale considérée.

Convergences et approximations

Application en Actuariat :

- **L'actuariat est une science mathématique qui utilise des outils de probabilités, statistiques, informatiques et financiers pour gérer les coûts liés à des événements incertains dits sinistres.**
- **Les actuaires appliquent cette science à des domaines comme l'assurance, les régimes de retraite, les caisses de prévoyance, etc,...**
- **L'objectif de l'assureur est de rester solvable pour qu'en cas de sinistre, il puisse indemniser ses assurés.**
- **Cet assureur considère donc les n risques auxquels il est soumis et qui seront représentés par des v.a(s) positives $X_1, \ldots, X_n$, où chaque X_n représente le montant que l'assureur doit indemniser à l'assuré n lors de la réalisation d'un sinistre.**

Convergences et approximations

- **Afin de se couvrir l'assureur demande à chaque assuré n une prime pure $E(X_n)$. Il se garantit donc de ne pas perdre d'argent en moyenne.**
- **Cependant, ce critère n'est pas assez sécurisant pour l'assureur car la moyenne ne mesure pas les extrémités des distributions. L'assureur demande donc une prime chargé, plus élevée : $(1+\eta)E(X_n)$.**
- **L'assureur calcule la probabilité de bénéfice :**

$$P_{\text{benéfice}} = P\Big(X_1 + \cdots + X_n \leq n(1+\eta)E(X_1)\Big).$$

- **L'assureur calcule aussi la probabilité de ruine :**

$$P_{\text{ruine}} = P\Big(X_1 + \cdots + X_n > n(1+\eta)E(X_1)\Big),$$

qui correspond à la probabilité pour l'assureur de ne pas être en mesure d'indemniser ses assurés.

Convergences et approximations

- **Le besoin du chargement η est justifié dans le cas i.i.d par le TCL :**

$$\frac{\sum_{i=1}^{n} X_i - nE(X_1)}{\sqrt{nV(X_1)}} \approx \mathcal{N}(0,1).$$

Par conséquent, on a :

- **Sans chargement $(\eta = 0)$:**

$$P_{\text{ruine}} = P\Big(\sum_{i=1}^{n} X_i > nE(X_1)\Big) \underset{n\to+\infty}{\longrightarrow} P\Big(\mathcal{N}(0,1) > 0\Big) = F(0) = \frac{1}{2}.$$

- **Avec un chargement $\eta \neq 0$:**

$$P_{\text{ruine}} = P\Big(\sum_{i=1}^{n} X_i > n(1+\eta)E(X_1)\Big) \approx P\Big(\mathcal{N}(0,1) > n.\eta E(X_1)\Big) \underset{n\to+\infty}{\longrightarrow} 0.$$

Convergences et approximations

TD 5 :

Exercice 1 :

1. **Soit X une v.a absolument continue. Pour tout $n \in \mathbb{N}$, on pose : $X_n = e^{\frac{1}{n}} X$. Montrer que (X_n) converge en loi vers X.**
2. **Soit $W_n \sim \mathcal{P}(n)$. Montrer que $\left(\frac{W_n - n}{\sqrt{n}}\right)$ converge en loi vers $\mathcal{N}(0,1)$.**
3. **Soit $Y_n \sim \mathcal{P}\left(\frac{1}{n}\right)$. Montrer que (Y_n) converge en loi vers une v.a Y à déterminer. Distinguer les deux cas : $P(Y_n = 0)$ et $P(Y_n = k),\ k \neq 0$.**
4. **Soit Z_n de densité de probabilité : $f_n(x) = n^2 x \exp\left(-\frac{n^2 x^2}{2}\right),\ x \geq 0$. Montrer que (Z_n) converge en probabilité vers 0.**
5. **Soit $T_n \sim \mathcal{E}\left(\frac{1}{n}\right)$. Montrer que $\left(\frac{T_n}{n \ln(n)}\right)$ converge en probabilité vers 0.**

Convergences et approximations

Exercice 2 :

Soit $(U_n)_n$ une suite de v.a(s) i.i.d suivant la loi uniforme sur $[0,1]$.

1. **Étudier la convergence presque sûre des suites de v.a(s) :**

$$X_n = \frac{1}{n}\sum_{i=1}^{n} U_i, \quad Y_n = \frac{1}{n}\sum_{i=1}^{n} U_i^2, \quad Z_n = \frac{1}{n}\sum_{i=1}^{n} \ln(U_i),$$

$$W_n = \frac{U_1U_2 + U_2U_3 + \cdots + U_{n-2}U_{n-1} + U_{n-1}U_n}{n}.$$

2. **On pose :** $M_n = \max\{U_1, ..., U_n\}$ **et** $N_n = n(1 - M_n)$.

   Montrer que :

$$F_{N_n} = \begin{cases} 0 & \text{si } x \leq 0, \\ 1 - \left(1 - \frac{x}{n}\right)^n & \text{si } 0 \leq x \leq n, \\ 1 & \text{si } x \geq n. \end{cases}$$

En déduire que (N_n) converge en loi vers X de loi exponentielle $\mathcal{E}(1)$.

Convergences et approximations

Exercice 3 :

1. **Soit $W_n \sim \mathcal{T}(n)$ la loi de Student de densité de probabilité :**

$$g_n(x) = \frac{1}{\sqrt{n\pi}} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \ x \in \mathbb{R}.$$

   Montrer que (W_n) converge en loi vers $\mathcal{N}(0,1)$. Utiliser la formule de Stirling pour $\Gamma(x)$ lorsque x est assez grand.

2. **Soit $(X_n)_n$ une suite de v.a(s) i.i.d et de carré intégrable. Trouver la limite presque sûre de la suite de v.a(s) :**

$$V_n = \frac{1}{n}\sum_{i=1}^{n} X_i^2 - \overline{X}_n^2.$$

3. **En appliquant le TCL à une suite de v.a(s) i.i.d suivant toutes une loi de Poisson $\mathcal{P}(1)$, montrer que :**

$$\lim_{n\to+\infty} e^{-n} \sum_{k=0}^{n} \frac{n^k}{k!} = \frac{1}{2}.$$

Convergences et approximations

Exercice 4 :

Soient $a > 1$ et X une v.a intégrable telle que $X \in]0, +\infty[$ presque sûrement, c-à-d : $P(X > 0) = 1$.

1. **Utiliser le TCD pour montrer que :**

$$\lim_{n\to\infty} E\left(n \ln\left(1 + \left(\frac{X}{n}\right)^a\right)\right) = \begin{cases} E(X) & \text{si } a = 1, \\ 0 & \text{si } a > 1. \end{cases}$$

   On pourra utiliser l'inégalité $\ln(1 + y^a) \leq ay$, pour tout $y \geq 0$.

2. **Utiliser le lemme de Fatou pour montrer que la limite ci-dessus est égale à $+\infty$ si $a \in]0, 1[$.**

Convergences et approximations

FIN ET MERCI