Université Mohammed Premier
Faculté des Sciences - Oujda
Département de Mathématiques

TP sous R et RStudio

Modélisation Statistique

SMA S6	Année universitaire : 2025-2026

Énoncés originaux et corrections détaillées

TP 1	Programmation de base, structures et graphiques
TP 2	Statistique descriptive univariée avec R
TP 3	Simulation de variables aléatoires discrètes
TP 4	Lois à densité et loi forte des grands nombres
TP 5	Modèle linéaire simple : estimation et ajustement
TP 6	Diagnostic du modèle linéaire simple
TP 7	Modèle linéaire multiple avec R

Enseignant : SGHIR AISSA
a.sghir@ump.ac.ma

Chaque TP est suivi de sa correction : code ou procédure, résultats numériques, graphiques et interprétation.

TP 1 - Programmation de base, structures et graphiques

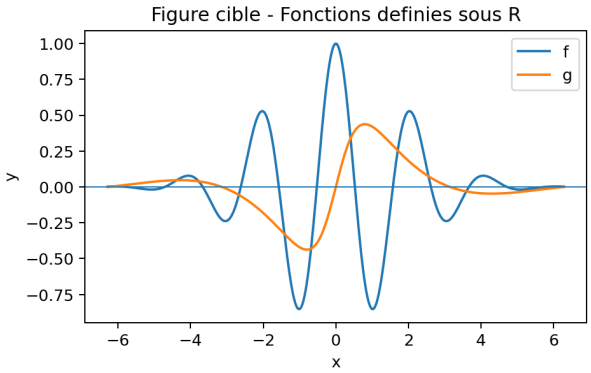
Objectif. Consolider les outils fondamentaux du cours avant de passer à la modélisation statistique.

A. Vecteurs, matrices et tableaux

1. Créer le vecteur x=seq(-2*pi,2*pi,length=400). Construire ensuite f=exp(-0.15*x^2)*cos(3*x) et g=sin(x)/(1+x^2).
2. Former un data.frame contenant x, f et g. Calculer longueur, minimum, maximum, moyenne, variance et écart type des colonnes f et g.
3. Construire la matrice A=matrix(c(4,1,2,1,3,0,2,0,5),nrow=3,byrow=TRUE). Calculer sa transposée, son déterminant, son inverse et ses valeurs propres.

B. Boucles et fonctions

4. Écrire une fonction resume=function(z) qui retourne moyenne, variance, écart type, minimum et maximum.
5. À l'aide d'une boucle for, calculer les dix premiers termes de u1=1, u(n+1)=0.6 u(n)+2. Conjecturer sa limite.
6. Tracer f et g sur la même figure avec plot, lines et legend.




```
x=seq(-2*pi,2*pi,length=400)
f=exp(-0.15*x^2)*cos(3*x)
g=sin(x)/(1+x^2)

plot(x,f,type="l")
lines(x,g)
legend("topright",c("f","g"),lty=c(1,1))
```

Commandes utiles : c, seq, matrix, t, det, solve, eigen, data.frame, for, function, plot, lines, legend.

Correction détaillée - TP 1

Programmation de base, structures et graphiques

1. Vecteurs et résumés numériques

```
x <- seq(-2*pi,2*pi,length=400)
f <- exp(-0.15*x^2)*cos(3*x)
g <- sin(x)/(1+x^2)
donnees <- data.frame(x,f,g)
sapply(donnees[c("f","g")], function(z) c(n=length(z),min=min(z),max=max(z),moy=mean(z),var=var(z),
sd=sd(z)))
```

Pour f : min ≈ -0,85243 ; max ≈ 0,99885 ; moyenne ≈ -0,000060 ; variance ≈ 0,12876 ; écart type ≈ 0,35883. Pour g : min ≈ -0,43740 ; max ≈ 0,43740 ; moyenne ≈ 0 ; variance ≈ 0,03703 ; écart type ≈ 0,19242.

2. Matrice

```
A <- matrix(c(4,1,2,1,3,0,2,0,5),nrow=3,byrow=TRUE)
t(A); det(A); solve(A); eigen(A)
```

On obtient det(A)=43. L'inverse est approximativement ((0,34884,-0,11628,-0,13953),(-0,11628,0,37209,0,04651),(-0,13953,0,04651,0,25581)). Les valeurs propres sont ≈ 6,66908 ; 3,47602 ; 1,85490, toutes positives.

3. Fonction et récurrence

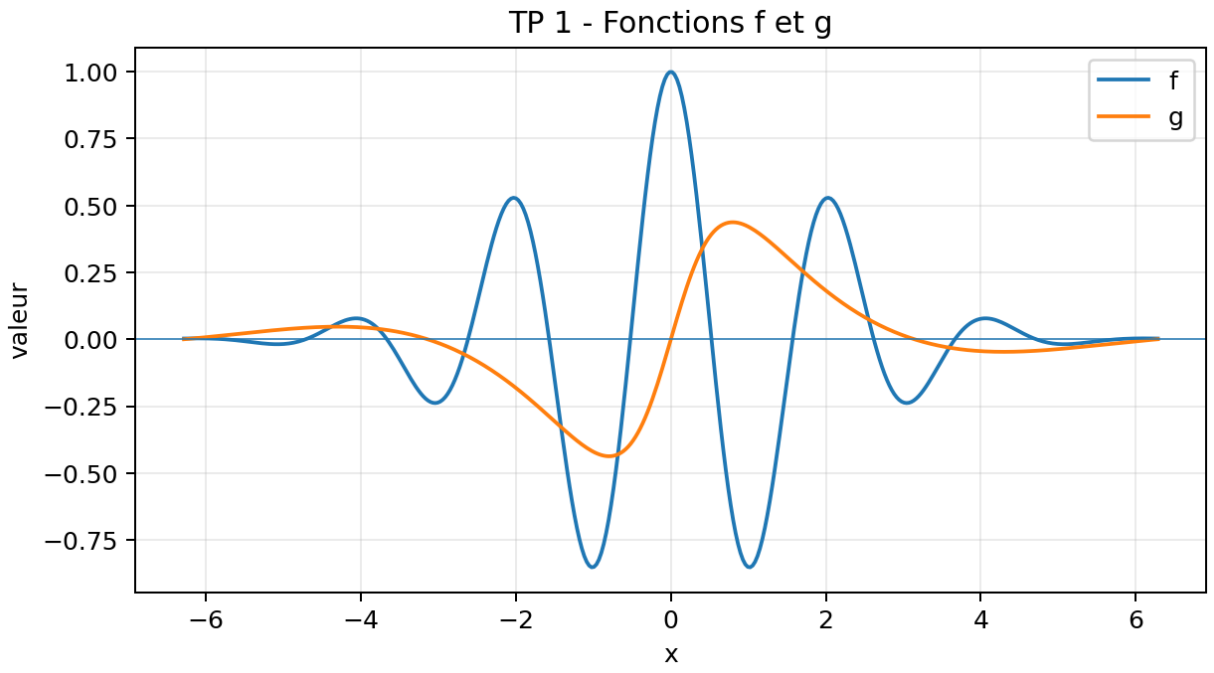
```
resume <- function(z) c(moyenne=mean(z),variance=var(z),ecart.type=sd(z),minimum=min(z),maximum=max(
z))
u <- numeric(10); u[1] <- 1
for(n in 1:9) u[n+1] <- 0.6*u[n] + 2
u
```

Les dix termes sont 1 ; 2,6 ; 3,56 ; 4,136 ; 4,4816 ; 4,68896 ; 4,813376 ; 4,888026 ; 4,932815 ; 4,959689. Le point fixe L vérifie L=0,6L+2, donc L=5. On peut aussi écrire u_n=5-4(0,6)^(n-1).

4. Tracé

```
plot(x,f,type="l",lwd=2,xlab="x",ylab="valeur")
lines(x,g,lwd=2,lty=2)
legend("topright",c("f","g"),lty=c(1,2),lwd=2)
```

Graphique(s) de correction



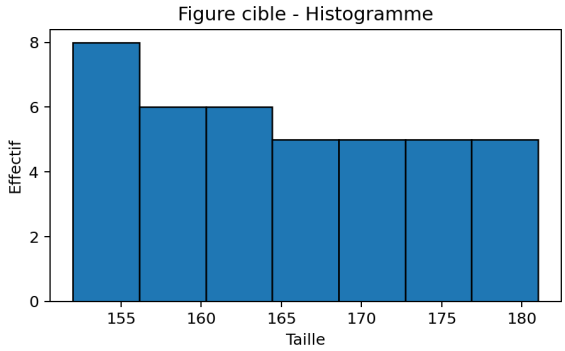
TP 2 - Statistique descriptive univariée avec R

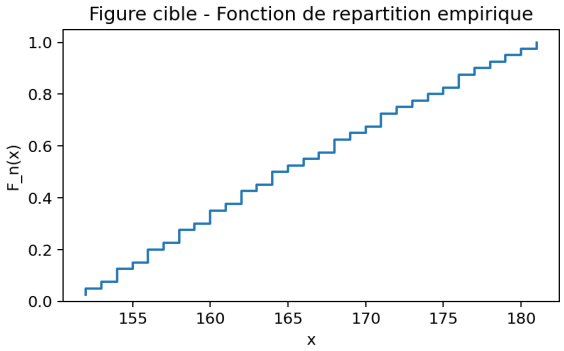
Objectif. Construire un tableau statistique complet et relier les résumés numériques aux représentations graphiques.

On considère les 40 tailles suivantes (en cm) :

152	152	153	154	154	155	156	156	157	158
158	159	160	160	161	162	162	163	164	164
165	166	167	168	168	169	170	171	171	172
173	174	175	176	176	177	178	179	180	181

1. Créer le vecteur X et calculer mean(X), median(X), var(X), sd(X), min, max et quartiles.
2. Construire cinq classes de même amplitude avec cut. Former le tableau des effectifs, effectifs cumulés, fréquences et fréquences cumulées.
3. Tracer l'histogramme de X avec les classes choisies. Comparer visuellement sa forme avec la moyenne et la médiane.
4. Tracer la fonction de répartition empirique ecdf(X). Lire graphiquement une valeur approchée de la médiane.
5. Modifier le nombre de classes et expliquer l'effet sur l'apparence de l'histogramme.





Commandes utiles : table, cumsum, cut, data.frame, mean, median, var, sd, quantile, hist, ecdf, plot.

Correction détaillée - TP 2

Statistique descriptive univariée avec R

1. Résumés numériques

Avec les 40 tailles : moyenne = 165,4 cm, médiane = 164,5 cm, variance (échantillonnale, fonction var de R) ≈ 75,11795, écart type ≈ 8,66706, min = 152, max = 181. Quartiles R (type 7) : Q1=158 ; Q2=164,5 ; Q3=172,25.

```
X <- c(152,152,153,154,154,155,156,156,157,158,158,159,160,160,161,162,162,163,164,164,165,166,167,
168,168,169,170,171,171,172,173,174,175,176,176,177,178,179,180,181)
c(mean=mean(X),median=median(X),variance=var(X),sd=sd(X),min=min(X),max=max(X))
quantile(X)
```

2. Cinq classes

Un choix simple et lisible consiste à prendre les bornes 152, 158, 164, 170, 176 et 182. Les effectifs correspondants sont 9, 9, 8, 7, 7 ; les fréquences sont 0,225 ; 0,225 ; 0,20 ; 0,175 ; 0,175.

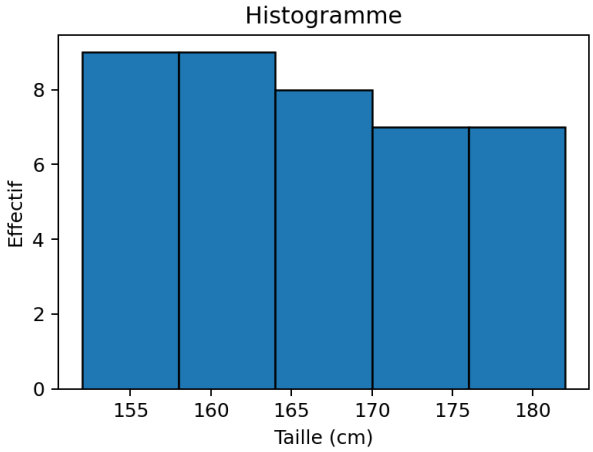
```
br <- c(152,158,164,170,176,182)
cl <- cut(X,breaks=br,right=FALSE,include.lowest=TRUE)
eff <- table(cl); freq <- prop.table(eff)
data.frame(effectif=eff, cum.effectif=cumsum(eff), frequence=freq, cum.frequence=cumsum(freq))
```

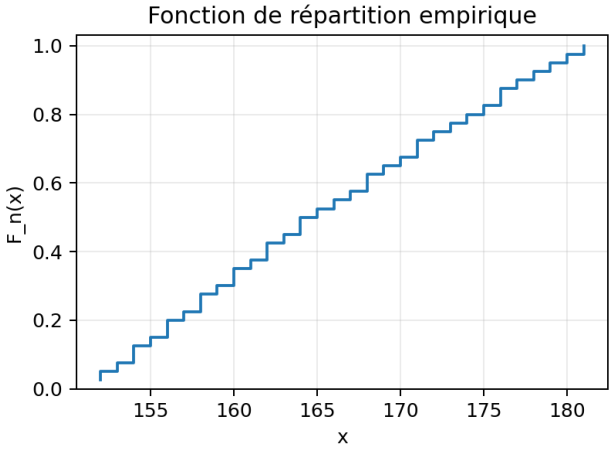
3. Histogramme et fonction de répartition

```
hist(X,breaks=br,col="steelblue",main="Histogramme",xlab="Taille")
Fn <- ecdf(X); plot(Fn,verticals=TRUE,do.points=FALSE,main="Fonction de répartition empirique")
```

La moyenne (165,4) est légèrement supérieure à la médiane (164,5), ce qui suggère une très faible asymétrie à droite. La fonction ecdf est une fonction en escalier, continue à droite ; elle atteint 0,5 au voisinage de 164-165 cm. Le nombre de classes modifie fortement l'aspect visuel de l'histogramme, mais pas les données ni les indicateurs numériques.

Graphique(s) de correction





TP 3 - Simulation de variables aléatoires discrètes

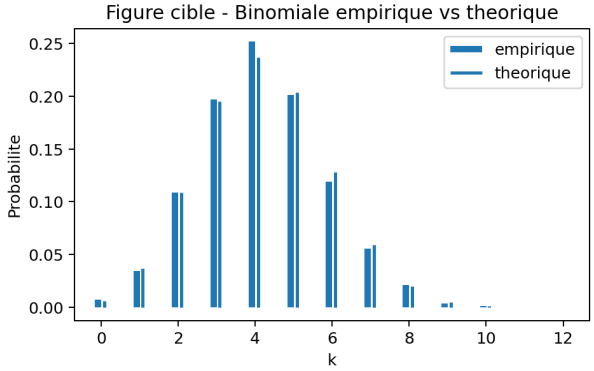
Objectif. Comparer une loi théorique discrète aux fréquences obtenues par simulation.

A. Loi binomiale B(12,0.35)

1. Fixer set.seed(123), puis simuler n=4000 réalisations avec rbinom. Comparer moyenne et variance empiriques aux valeurs théoriques.
2. Calculer les fréquences empiriques des valeurs 0,...,12 et les comparer aux probabilités dbinom(0:12,12,0.35).
3. Représenter sur un même graphique les probabilités empiriques et théoriques. Commenter les écarts.

B. Loi de Poisson P(2)

4. Répéter les trois questions précédentes pour un échantillon simulé par rpois(4000,2).
5. Calculer P(X=3), P(X<=3) et le quantile 0.95 avec dpois, ppois et qpois.
6. Refaire l'expérience avec n=100 puis n=10000 et expliquer l'effet de la taille de l'échantillon.




```
set.seed(123)
X=rbinom(4000,size=12,prob=0.35)

freq=table(factor(X,levels=0:12))/length(X)
theo=dbinom(0:12,size=12,prob=0.35)

cbind(empirique=freq,theorique=theo)
```

Commandes utiles : set.seed, rbinom, rpois, table, dbinom, dpois, ppois, qpois, mean, var, plot, points, lines.

Correction détaillée - TP 3

Simulation de variables aléatoires discrètes

A. Loi binomiale B(12,0,35)

Valeurs théoriques : E(X)=np=12×0,35=4,2 et V(X)=np(1-p)=2,73. Avec 4000 simulations, mean(X) et var(X) doivent être proches de ces valeurs ; les écarts restants sont dus à la variabilité Monte-Carlo.

```
set.seed(123)
X <- rbinom(4000,size=12,prob=0.35)
c(moyenne=mean(X),variance=var(X))
freq <- table(factor(X,levels=0:12))/length(X)
theo <- dbinom(0:12,12,0.35)
cbind(empirique=as.numeric(freq),theorique=theo)
```

B. Loi de Poisson P(2)

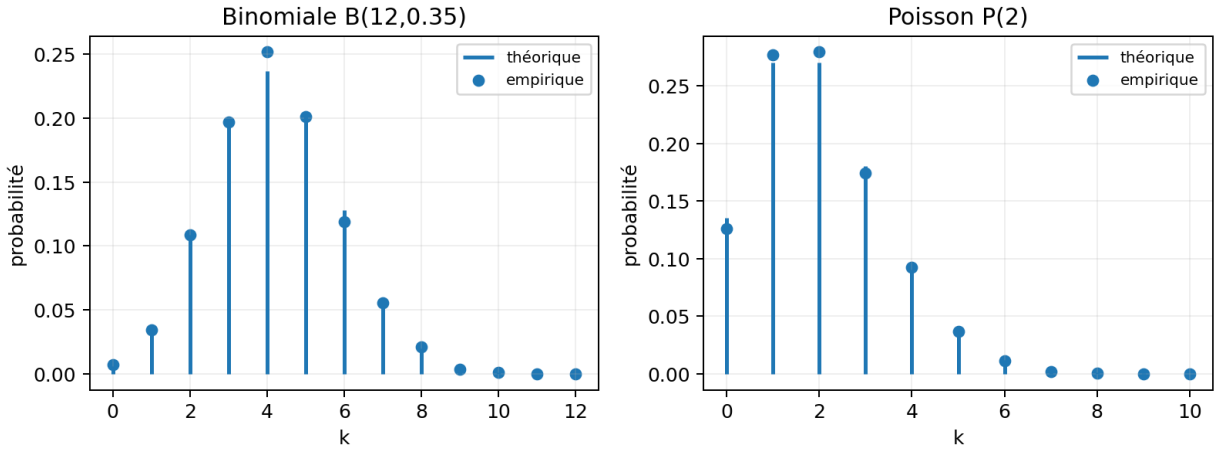
E(X)=V(X)=2. Les probabilités demandées sont P(X=3)=e^-2 2^3/3! ≈ 0,18045, P(X≤3) ≈ 0,85712 et le quantile d'ordre 0,95 vaut 5.

```
set.seed(123)
Y <- rpois(4000,2)
c(mean(Y),var(Y))
dpois(3,2); ppois(3,2); qpois(0.95,2)
```

Effet de la taille de simulation

Avec n=100, les fréquences empiriques présentent des fluctuations visibles. Avec n=4000 elles se rapprochent de la loi théorique. Avec n=10000, l'accord devient généralement très bon : c'est une illustration de la loi des grands nombres appliquée aux fréquences.

Graphique(s) de correction



TP 4 - Lois à densité et loi forte des grands nombres

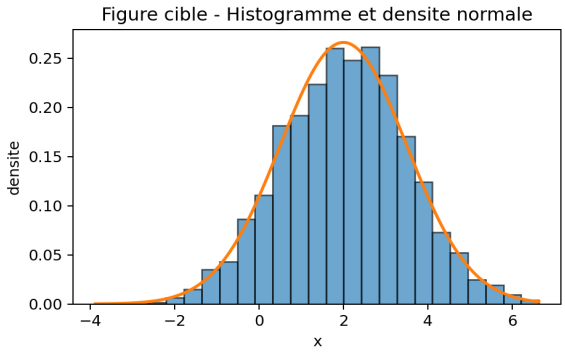
Objectif. Relier simulation, densité théorique, fonction de répartition empirique et convergence des moyennes empiriques.

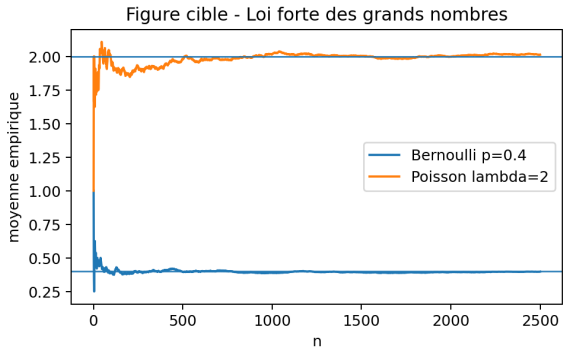
A. Loi normale N(2,1.5²)

1. Simuler 3000 observations. Tracer l'histogramme avec prob=TRUE puis superposer la densité théorique avec curve(dnorm(...),add=TRUE).
2. Construire la fonction de répartition empirique avec ecdf et superposer la fonction théorique pnorm.
3. Comparer les quantiles théoriques 0.025, 0.5 et 0.975 avec les quantiles empiriques.

B. Loi forte des grands nombres

4. Simuler 2500 Bernoulli B(0.4), calculer cumsum(X)/(1:n) et tracer l'évolution avec la droite y=0.4.
5. Refaire la même expérience pour une loi de Poisson P(2) avec la droite y=2.
6. Expliquer le contenu de la loi forte des grands nombres et le rôle de la taille n.





Commandes utiles : rnorm, dnorm, pnorm, qnorm, hist, curve, ecdf, quantile, cumsum, abline, legend.

Correction détaillée - TP 4

Lois à densité et loi forte des grands nombres

1. Loi normale N(2,1,5²)

La densité théorique est f(x)=1/(1,5√(2π)) exp(-(x-2)²/(2×1,5²)). Les quantiles théoriques sont q0,025≈-0,93995, q0,5=2, q0,975≈4,93995.

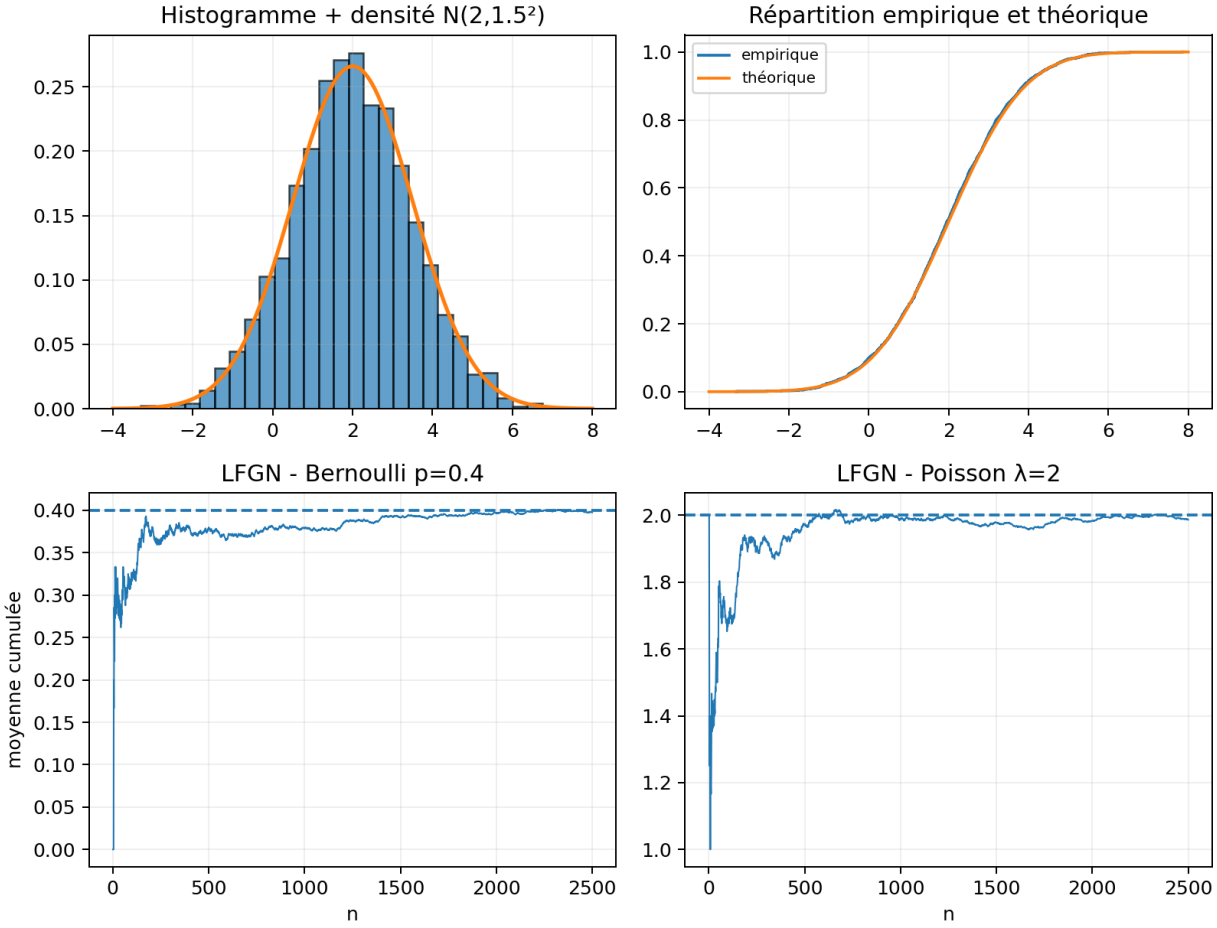
```
set.seed(123)
X <- rnorm(3000,mean=2,sd=1.5)
hist(X,prob=TRUE,breaks=30,col="lightblue")
curve(dnorm(x,2,1.5),add=TRUE,lwd=2,col="red")
Fn <- ecdf(X); plot(Fn)
curve(pnorm(x,2,1.5),add=TRUE,col="red",lwd=2)
rbind(theorique=qnorm(c(.025,.5,.975),2,1.5),empirique=quantile(X,c(.025,.5,.975)))
```

2. Loi forte des grands nombres

```
B <- rbinom(2500,1,.4); plot(cumsum(B)/(1:2500),type="l"); abline(h=.4,col="red")
P <- rpois(2500,2); plot(cumsum(P)/(1:2500),type="l"); abline(h=2,col="red")
```

Si X1,X2,... sont i.i.d. et E|X1|<∞, alors la moyenne empirique converge presque sûrement vers E(X1). Pour Bernoulli(0,4), la limite est 0,4 ; pour Poisson(2), elle est 2. Les fluctuations sont fortes au début puis se stabilisent quand n augmente.

Graphique(s) de correction



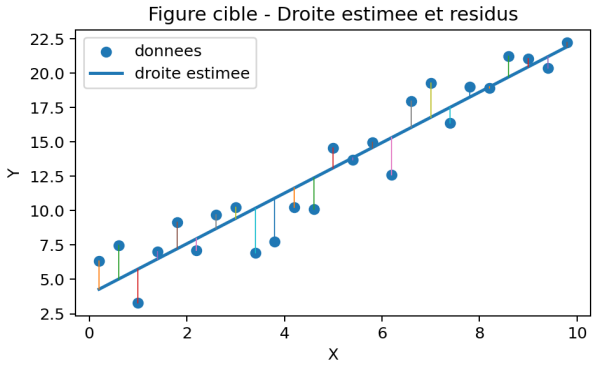
TP 5 - Modèle linéaire simple : estimation et ajustement

Objectif. Ajuster un modèle $Y=\beta 0+\beta 1X+\varepsilon$ et relier les sorties de R aux formules des moindres carrés.

On considère les observations suivantes :

X	0.2	0.6	1.0	1.4	1.8	2.2	2.6	3.0	3.4	3.8	4.2	4.6	
Y	6.3	7.5	3.3	7.0	9.2	7.1	9.7	10.3	6.9	7.7	10.3	10.1	
X	5.0	5.4	5.8	6.2	6.6	7.0	7.4	7.8	8.2	8.6	9.0	9.4	9.8
Y	14.6	13.7	15.0	12.6	17.9	19.3	16.4	19.0	18.9	21.2	21.1	20.4	22.2

1. Créer X et Y puis ajuster modele=lm(Y~X). Afficher summary(modele) et coef(modele).
2. Retrouver manuellement les estimateurs de la pente et de l'ordonnée à l'origine. Comparer aux coefficients de R.
3. Extraire valeurs prédites et résidus. Vérifier que la somme des résidus est proche de zéro.
4. Tracer le nuage, la droite estimée avec abline(modele) et les segments représentant les résidus.
5. Donner et interpréter le coefficient R^2.




```
modele=lm(Y~X)
summary(modele)
coef(modele)

Yhat=fitted(modele)
e=residuals(modele)

plot(X,Y)
abline(modele)
segments(X,Y,X,Yhat)
```

Commandes utiles : lm, summary, coef, fitted, residuals, plot, abline, segments.

Correction détaillée - TP 5

Modèle linéaire simple : estimation et ajustement

1. Ajustement

```
modele <- lm(Y~X)
summary(modele); coef(modele)
Yhat <- fitted(modele); e <- residuals(modele)
sum(e)
```

Les moindres carrés donnent pente = 1,83904 et ordonnée à l'origine = 3,91281. Ainsi : $\hat{Y}$ = 3,91281 + 1,83904 X. La somme des résidus est nulle à l'erreur d'arrondi près.

2. Formules manuelles

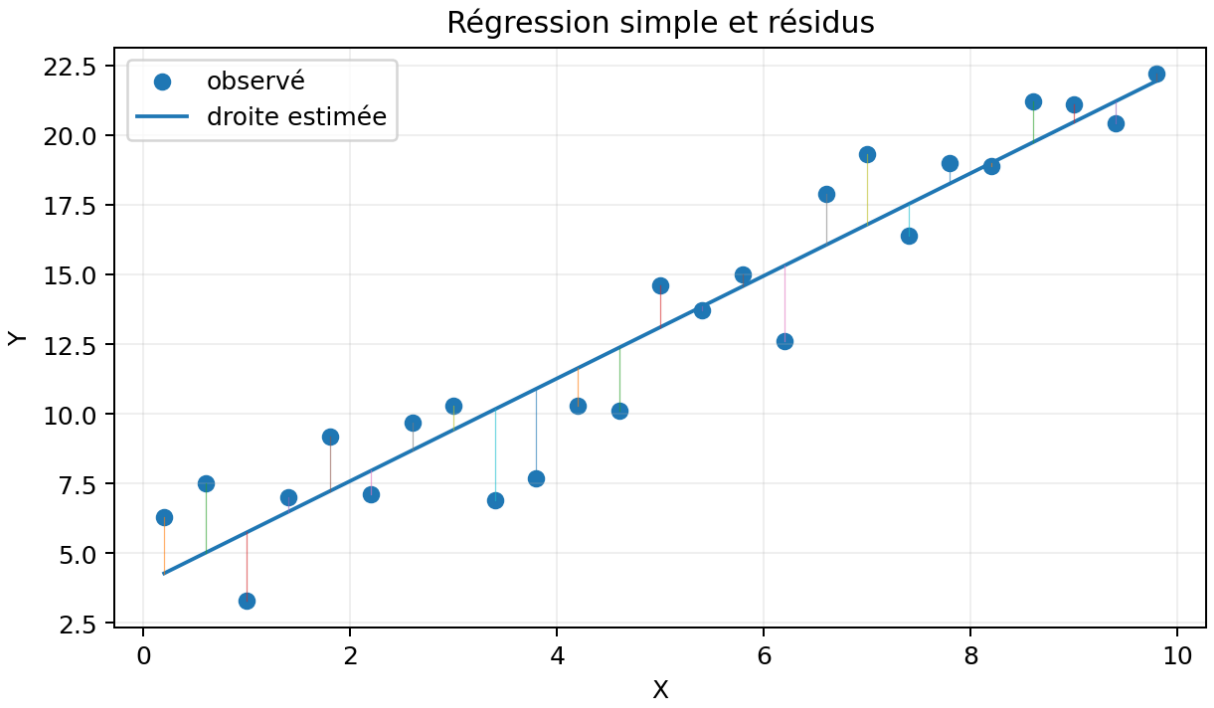
La pente est b1 = $\Sigma(x_i-\bar{x})(y_i-\bar{y}) / \Sigma(x_i-\bar{x})^2$ et b0 = $\bar{y}$-b1$\bar{x}$. Les valeurs obtenues coïncident avec coef(modele).

3. Qualité de l'ajustement

Le coefficient de corrélation est r≈0,95035 et R^2≈0,90316 : environ 90,3 % de la variabilité observée de Y est expliquée par X dans ce modèle linéaire. La variance résiduelle estimée est MSE≈3,27954.

```
plot(X,Y,pch=19); abline(modele,col="blue",lwd=2)
segments(X,Y,X,Yhat,col="gray50")
```

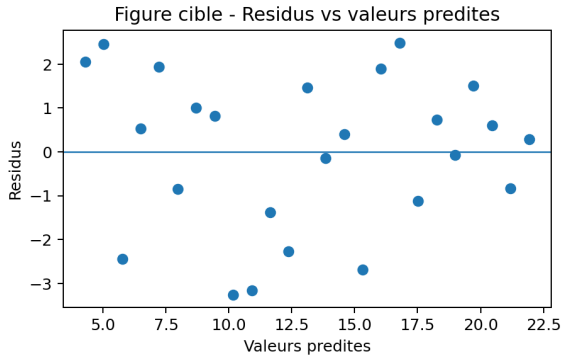
Graphique(s) de correction

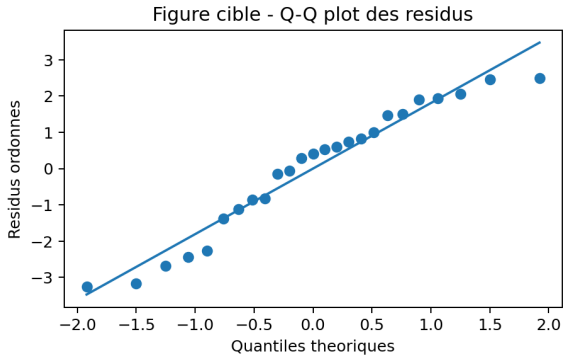


TP 6 - Diagnostic du modèle linéaire simple

Objectif. Évaluer graphiquement la validité des hypothèses portant sur les erreurs du modèle linéaire.

1. Reprendre le modèle du TP 5. Extraire residus=residuals(modele) et valeurs_predites=fitted(modele).
2. Tracer les résidus en fonction des valeurs prédites et ajouter la droite y=0. Décrire centre, dispersion et structure éventuelle.
3. Tracer le Q-Q plot des résidus avec qqnorm et qqline. La normalité paraît-elle plausible ?
4. Identifier le résidu de plus grande valeur absolue et retrouver l'observation correspondante.
5. Simuler un nouveau modèle dans lequel l'écart type des erreurs augmente avec X. Comparer le graphique résidus-prédits.
6. Rédiger une conclusion sur les hypothèses : moyenne nulle, variance constante et normalité.





Commandes utiles : residuals, fitted, plot, abline, qqnorm, qqline, which.max, abs, rnorm.

Correction détaillée - TP 6

Diagnostic du modèle linéaire simple

1. Résidus vs valeurs prédites

Le nuage doit être centré autour de 0 sans forme systématique. Pour les données du TP5, les résidus restent globalement répartis de part et d'autre de zéro ; aucune structure en éventail très nette n'apparaît.

2. Normalité

```
residus <- residuals(modele); valeurs_predites <- fitted(modele)
plot(valeurs_predites,residus); abline(h=0,lty=2)
qqnorm(residus); qqline(residus,col="red")
shapiro.test(residus)
```

À titre de contrôle, le test de Shapiro-Wilk sur ces résidus donne W≈0,940 et p≈0,150 : au seuil 5 %, on ne rejette pas la normalité. Le Q-Q plot doit être interprété conjointement au test.

3. Observation la plus atypique

```
i <- which.max(abs(residus)); c(indice=i,residu=residus[i])
```

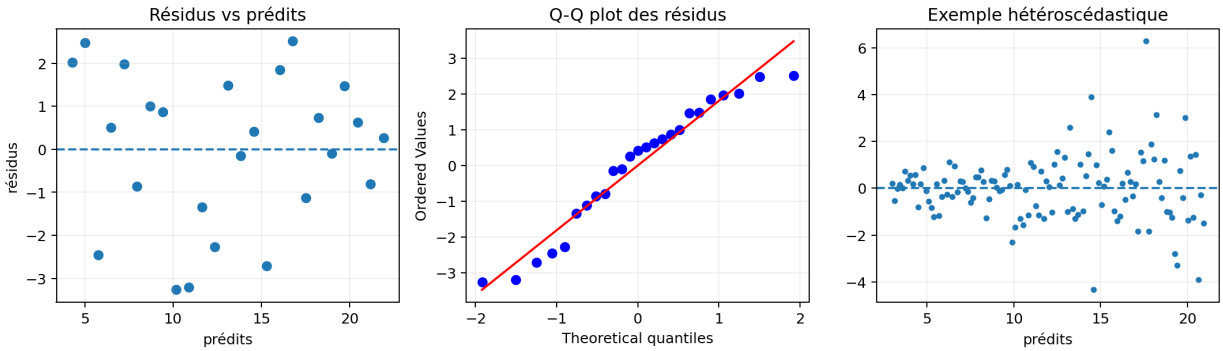
L'observation de plus grand résidu absolu est l'observation 9, avec un résidu d'environ -3,266.

4. Hétéroscédasticité simulée

```
set.seed(1)
Xh <- seq(0,10,length=120)
eh <- rnorm(120,sd=.3+.18*Xh)
Yh <- 3+1.8*Xh+eh
mh <- lm(Yh~Xh)
plot(fitted(mh),residuals(mh)); abline(h=0,lty=2)
```

Dans le modèle hétéroscédastique, la dispersion des résidus augmente avec les prédictions : l'hypothèse de variance constante est violée. La conclusion complète doit porter sur moyenne résiduelle nulle, homoscédasticité et normalité.

Graphique(s) de correction



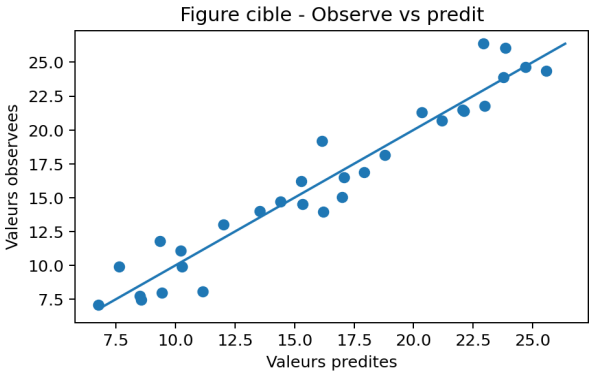
TP 7 - Modèle linéaire multiple avec R

Objectif. Ajuster un modèle $Y=\beta0+\beta1X1+\beta2X2+\varepsilon$ et interpréter correctement les effets partiels.

Utiliser les données suivantes générées directement sous R :

```
set.seed(321)
n=30
X1=seq(1,10,length=n)
X2=rep(c(2,1,4,3,6,5,8,7,10,9),3)
erreur=rnorm(n,sd=1.8)
Y=10+2.2*X1-1.1*X2+erreur
donnees=data.frame(X1,X2,Y)
```

1. Ajuster modele=lm(Y~X1+X2). Donner l'équation estimée.
2. Interpréter le coefficient de X1 lorsque X2 est maintenue constante, puis celui de X2 lorsque X1 est maintenue constante.
3. Comparer les coefficients estimés aux valeurs utilisées pour générer les données. Expliquer pourquoi ils ne sont pas exactement égaux.
4. Extraire valeurs prédites, résidus et R^2. Tracer Y observé en fonction de Y prédit et ajouter la droite y=x.
5. Ajuster lm(Y~X1) et lm(Y~X2). Comparer leurs R^2 au modèle multiple.
6. Construire les graphiques de diagnostic des résidus comme dans le TP 6 et conclure.



Interprétation attendue.

Dans un modèle multiple, chaque coefficient mesure l'effet d'une variable explicative lorsque les autres variables du modèle sont maintenues fixes.

Le coefficient R^2 quantifie la part de variabilité de Y expliquée conjointement par X1 et X2.

Commandes utiles : lm, summary, coef, fitted, residuals, plot, abline, data.frame, rnorm.

Correction détaillée - TP 7

Modèle linéaire multiple avec R

1. Modèle multiple

```
set.seed(321)
n <- 30
X1 <- seq(1,10,length=n)
X2 <- rep(c(2,1,4,3,6,5,8,7,10,9),3)
erreur <- rnorm(n,sd=1.8)
Y <- 10+2.2*X1-1.1*X2+erreur
modele <- lm(Y~X1+X2)
summary(modele); coef(modele)
```

Les coefficients estimés doivent être proches des paramètres de génération : intercept 10, effet de X1 égal à +2,2 et effet de X2 égal à -1,1. Ils ne sont pas exactement égaux parce que l'échantillon contient un bruit aléatoire.

2. Interprétation partielle

Le coefficient de X1 mesure la variation moyenne de Y pour une augmentation d'une unité de X1 à X2 maintenue constante. Le coefficient de X2 se lit de la même manière à X1 constante. Cette interprétation conditionnelle est essentielle en régression multiple.

3. Comparaison des modèles et diagnostics

```
Yhat <- fitted(modele); e <- residuals(modele)
summary(modele)$r.squared
plot(Yhat,Y); abline(0,1,lty=2)
plot(Yhat,e); abline(h=0,lty=2)
qqnorm(e); qqline(e)
summary(lm(Y~X1))$r.squared
summary(lm(Y~X2))$r.squared
```

Le modèle multiple doit avoir un R^2 au moins aussi grand que chacun des modèles simples. Il faut toutefois privilégier aussi le R^2 ajusté et examiner les résidus : l'ajout d'un prédicteur n'est utile que s'il apporte une information explicative réelle et ne dégrade pas les hypothèses du modèle.

Graphique(s) de correction

