Université Mohammed Premier
Faculté des Sciences Oujda
Département de Mathématiques

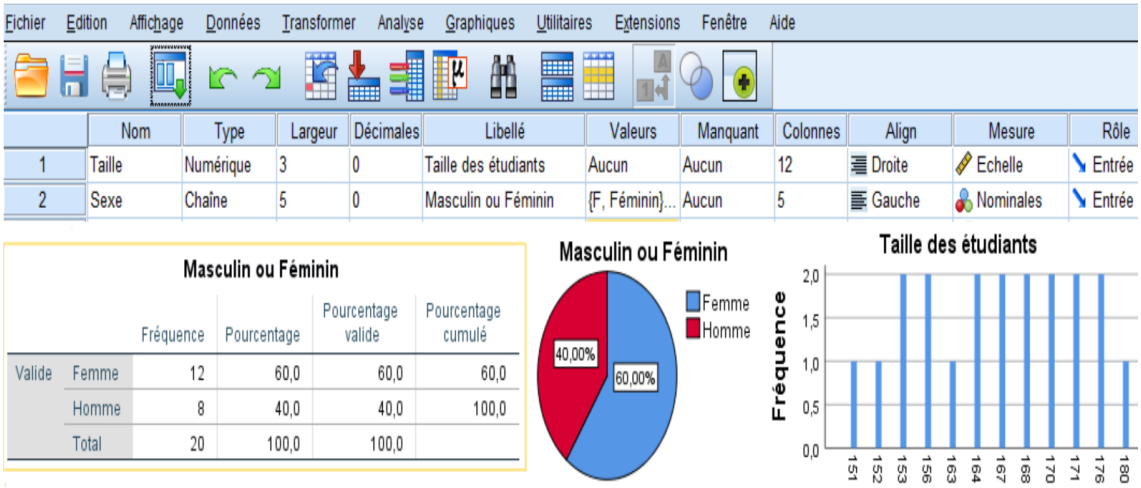
Cours et Travaux Pratiques

BIOSTATISTIQUE SOUS SPSS 25

Enseignant: SGHIR AISSA
a.sghir@ump.ac.ma

Année universitaire: 2023-2024

Master : AGRO (MATH)



	Nom	Type	Largeur	Décimales	Libellé	Valeurs	Manquant	Colonnes	Align	Mesure	Rôle
1	Taille	Numérique	3	0	Taille des étudiants	Aucun	Aucun	12	Droite	Echelle	Entrée
2	Sexe	Chaîne	5	0	Masculin ou Féminin	{F, Féminin}...	Aucun	5	Gauche	Nominales	Entrée

Masculin ou Féminin

		Fréquence	Pourcentage	Pourcentage valide	Pourcentage cumulé
Valide	Femme	12	60,0	60,0	60,0
	Homme	8	40,0	40,0	100,0
	Total	20	100,0	100,0	

Table des matières

Introduction **4**

1 Pratique de la Statistique Descriptive Univariée sous SPSS 25 **5**
1.1 Vocabulaires 5
1.2 Le logiciel SPSS 25 7
1.2.1 Démarrage 7
1.2.2 Affichage des variables et affichage des données 8
1.2.3 Valeurs et étiquette 9
1.2.4 La fenêtre Viewer 9
1.2.5 Transformation des variables 10
1.3 Exemples d'études Statistiques 11
1.3.1 Variable qualitative nominale 11
1.3.2 Variable qualitative ordinale 13
1.3.3 Variable quantitative discrète 13
1.3.4 Variable quantitative continue 15
1.4 Paramètres de position 18
1.4.1 Le mode 18
1.4.2 La moyenne 18
1.4.3 La médiane 18
1.5 Paramètres de dispersion 20
1.5.1 L'étendue 20
1.5.2 La variance et l'écart type 20
1.6 TP 1 sous SPSS 25 23

2 Pratique de la Statistique Descriptive Bivariée sous SPSS 25 **25**
2.1 Deux variables qualitatives (tableau de contingence) 25
2.2 Une variable quantitative et une variable qualitative (boîte à moustache) . 27
2.3 Deux variables quantitatives (régression linéaire et prédiction) 28
2.4 TP 2 sous SPSS 25 34

3 Notion de probabilités et variables aléatoires **35**
3.1 Vocabulaires 35
3.2 Notion de probabilités 36

3.3 Notion de variables aléatoires 37
3.3.1 Variables aléatoires discrètes 38
3.3.2 Variables aléatoires continues 39

4 Pratique de l'échantillonnage et l'estimation sous SPSS 25 42
4.1 Échantillonnage 42
4.1.1 Introduction 42
4.1.2 Distribution d'échantillonnage de la moyenne 44
4.1.3 Distribution d'échantillonnage de la proportion 46
4.1.4 Distribution d'échantillonnage de la variance 47
4.2 Estimation 48
4.2.1 Estimation ponctuelle 48
4.2.2 Estimation par intervalle de confiance 48

5 Tests d'hypothèses 54
5.1 Introduction 54
5.2 Tests de conformité 55
5.2.1 Test de conformité de la variance à une référence 55
5.2.2 Test de conformité de la moyenne à une référence 55
5.2.3 Test de conformité de la proportion à une référence 56
5.3 Test d'indépendance du khi-deux entre deux variables qualitatives 59
5.4 Tests d'homogénéité dans le cas des échantillons indépendants 62
5.4.1 Test de comparaison de deux proportions 62
5.4.2 Test de comparaison de deux variances 64
5.4.3 Test de comparaison de deux moyennes 66
5.4.4 Cas d'échantillons appariés 68
5.5 Test de normalité: test de Shapiro et Wilk 69
5.6 TP 3 sous SPSS 25 73

6 Modèle linéaire et Analyse de la variance (ANOVA) sous SPSS 25 75
6.1 Modèle linéaire simple 75
6.1.1 Test de la significativité du coefficient de corrélation 75
6.1.2 Estimation des paramètres 77
6.2 Modèle linéaire multiple 79
6.3 ANOVA à un facteur 81
6.4 ANOVA à un facteur à mesures répétées 86
6.5 ANOVA à deux facteurs 88
6.6 TP 4 sous SPSS 25 91

Introduction

La statistique est un ensemble de méthodes scientifiques dont l'objectif principal est d'analyser, structurer, valider et modéliser des informations numériques. Les méthodes statistiques peuvent être classés en deux groupes:

1) La Statistique descriptive qui regroupe les méthodes dont l'objectif principal est la description des données étudiées. Cette description des données se fait à travers leur représentation graphique, et le calcul des résumés numériques. Dans cette optique, on ne fait pas appel à des outils de type probabiliste.

- **Statistique descriptive univariée:** étude de la population selon une seule variable.
- **Statistique descriptive bivariée:** étude des corrélations et relations éventuelles entre deux variables de la même population.
- **Statistique descriptive multivariée:** étude des relations éventuelles entre plusieurs variables de la même population.

2) La statistique inférentielle. Ce terme regroupe les méthodes dont l'objectif principal est de préciser un phénomène sur une population globale, à partir de son observation sur une partie restreinte (échantillon) de cette population. Ce passage ne se fait que moyennant des hypothèses de type probabiliste.

NB: La statistique descriptive précède en général la statistique inférentielle dans une démarche de traitement de données: les deux aspects de la statistique se complètent bien plus qu'ils ne s'opposent.

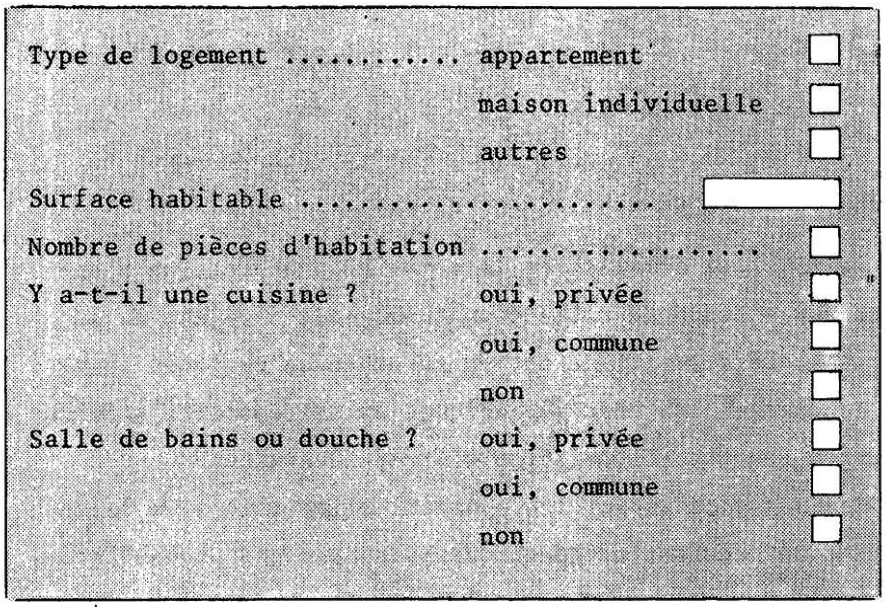
Dans ce cours de Biostatistique, pour valider la théorie des études statistiques, nous utiliserons le logiciel SPSS 25 (Statistical Package for the Social Sciences) qui fonctionne dans un environnement graphique Windows, et qui permet de traiter les données avec efficacité et d'effectuer des analyses sur de grandes bases de données. Il offre plusieurs possibilités pour organiser et synthétiser les informations statistiques.

Chapitre 1

Pratique de la Statistique Descriptive Univariée sous SPSS 25

1.1 Vocabulaires

- **Statistique descriptive univariée:** regroupe les méthodes dont l'objectif principal est la description des données étudiées selon une seule variable.
- **Population:** ensemble des individus objets de l'étude. (étudiants, entreprises, plantes, animaux, produits,...)
- **Échantillon:** sous-ensemble issu de la population. (une classe, une ville, hommes,...)
- **Unité statistique:** chaque individu. (un étudiant, une plante, une femme,...)
- **Variable:** caractère ou propriété mesuré sur chaque individu notée X, (note, taille, poids, sexe, âge, couleur, mesure,...)
- **Modalités:** les valeurs possibles de la variable.
- **Série statistique:** suite des valeurs prises par une variable X notées $x_1, x_2, x_3, ...$
- **Variable quantitative:** les modalités sont mesurables ou repérables.
  - **Variable quantitative discrète:** l'ensemble des modalités est fini ou dénombrable. (Note, taille, poids, âge, mesure,...)
  - **Variable quantitative continue:** l'ensemble des modalités est un intervalle fini ou infini. ($[8; 20[$, $[0; +\infty[$, $\mathbb{R}$,...)
- **Variable qualitative:** les modalités ne sont pas mesurables.
  - **Variable qualitative nominale:** les modalités ne peuvent pas être ordonnées. (sexe, couleur,...)
  - **Variable qualitative ordinale:** les modalités peuvent être ordonnées. (taille d'un vêtement: XXL, XL, L, M, S).
- **Questionnaire:** c'est un formulaire de questions pour la collection des données. Il peut être sous format papier ou numérique via a Internet. Par exemple:



- **Effectif totale** n**:** le nombre de toutes les valeurs prises par la variable.
- **Effectif** n_i**:** nombre d'apparitions de la valeur x_i dans la série statistique.

$$\sum_{i=1}^{J} n_i = n_1 + n_2 + ... + n_J = n.$$

- **Fréquence** f_i **associée à la valeur** x_i**:**

$$\begin{cases} f_i = \frac{n_i}{n}, \\ \sum\limits_{i=1}^{J} f_i = f_1 + f_2 + ... + f_J = 1. \end{cases}$$

- **Pourcentage** p_i **associé à la valeur** x_i**:**

$$\begin{cases} p_i = 100 \times f_i \ \%, \\ \sum\limits_{i=1}^{J} p_i = p_1 + p_2 + ... + p_J = 100 \ \%. \end{cases}$$

- **Effectif cumulé** N_i**:**

$$\begin{cases} N_1 = n_1, \\ N_2 = n_1 + n_2, \\ N_3 = n_1 + n_2 + n_3, \\ ..... \\ ..... \\ N_J = n_1 + n_2 + ... + n_J = n. \end{cases}$$

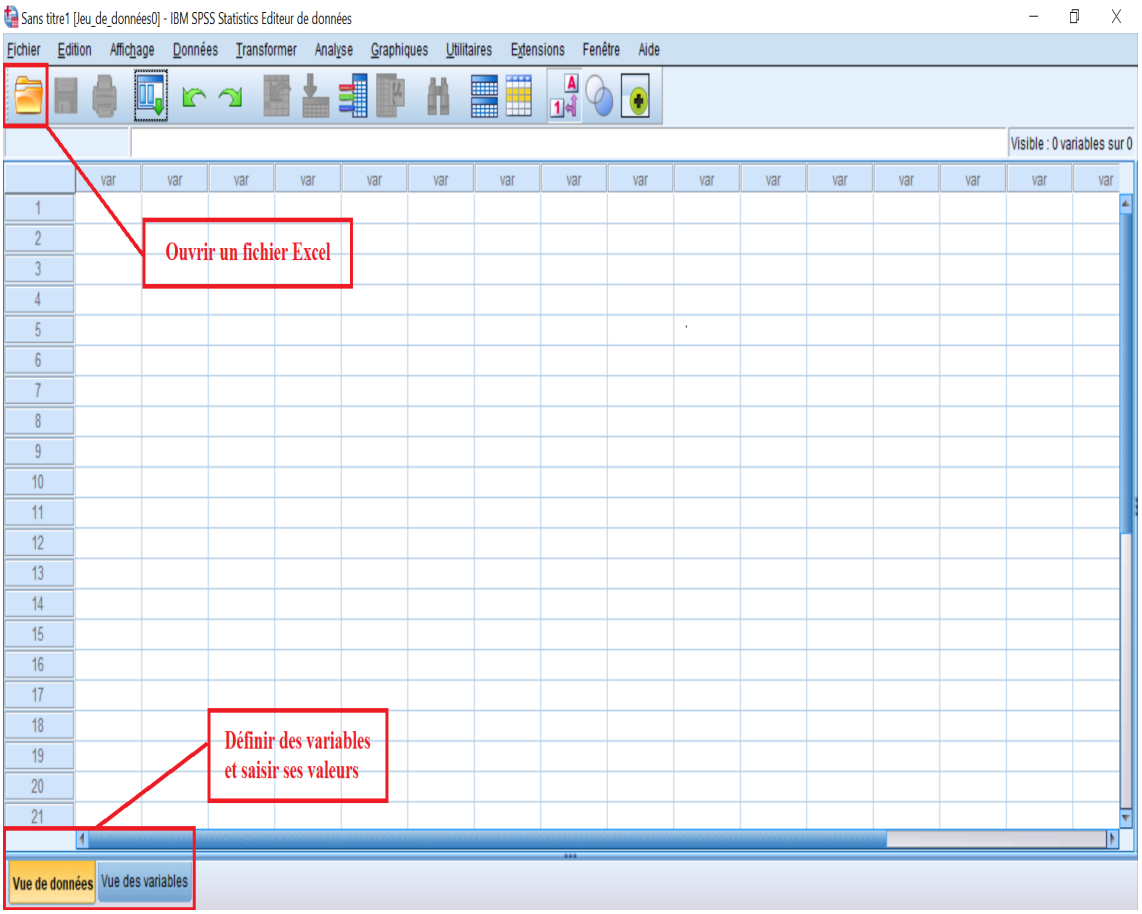
- **Fréquence cumulée F_i:**

$$\begin{cases} F_1 = f_1, \\ F_2 = f_1 + f_2, \\ F_3 = f_1 + f_2 + f_3, \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ F_J = f_1 + f_2 + \ldots + f_J = 1. \end{cases}$$

1.2 Le logiciel SPSS 25

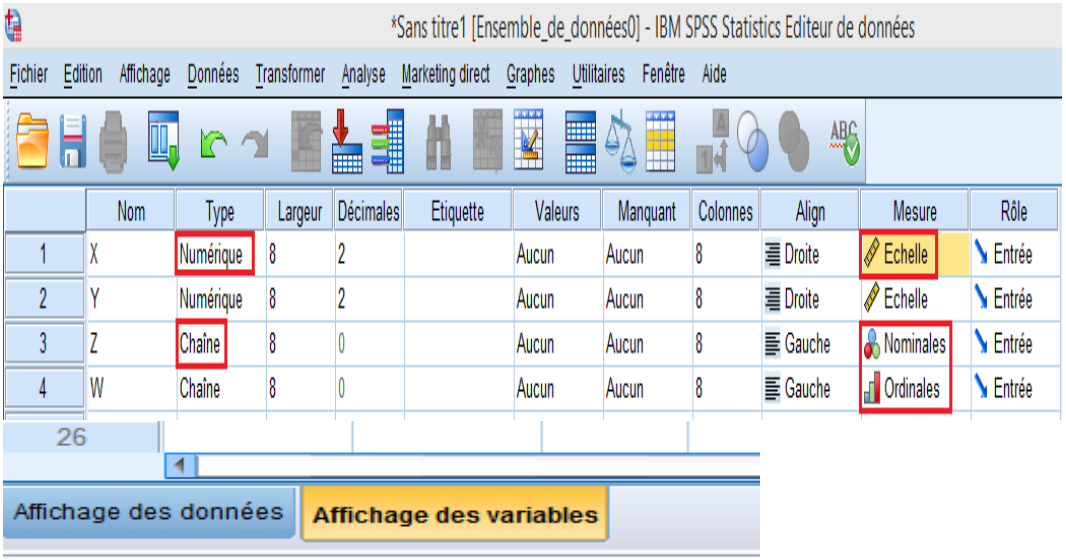
1.2.1 Démarrage

Cette fenêtre s'ouvre lorsque on clique deux fois sur l'icône IBM SPSS 25.

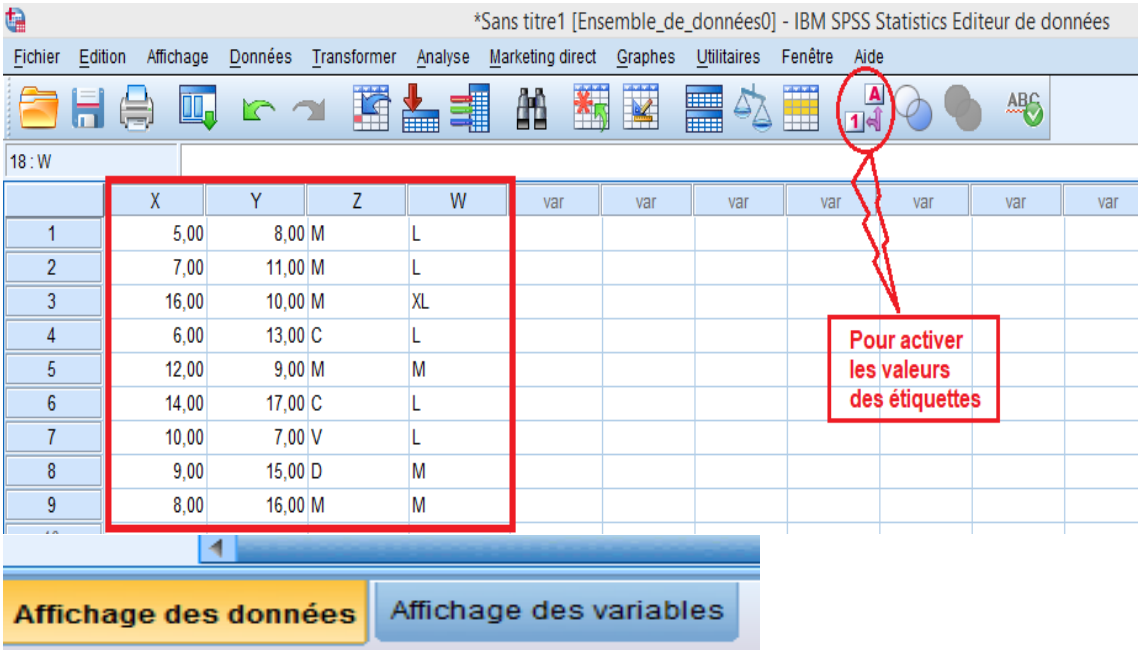


1.2.2 Affichage des variables et affichage des données

Cet onglet permet de définir précisément la nature des variables et la façon dont elles seront affichées: numérique pour quantitative et chaîne pour qualitative.

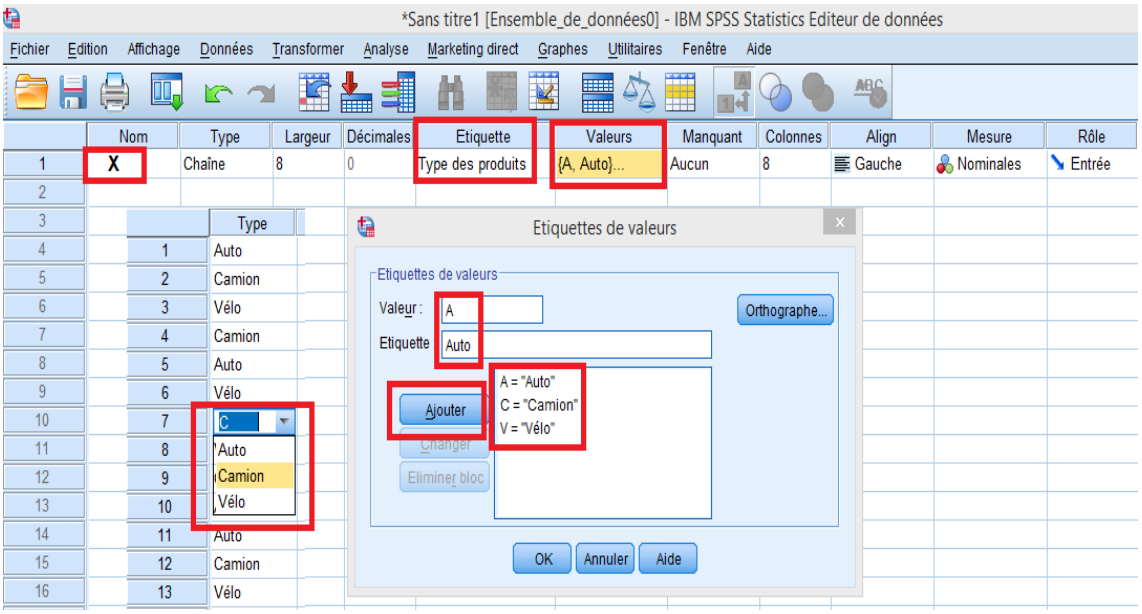


Cette fenêtre affiche le tableau des données dont les lignes correspondent aux observations (individus) et les colonnes aux variables (caractères).



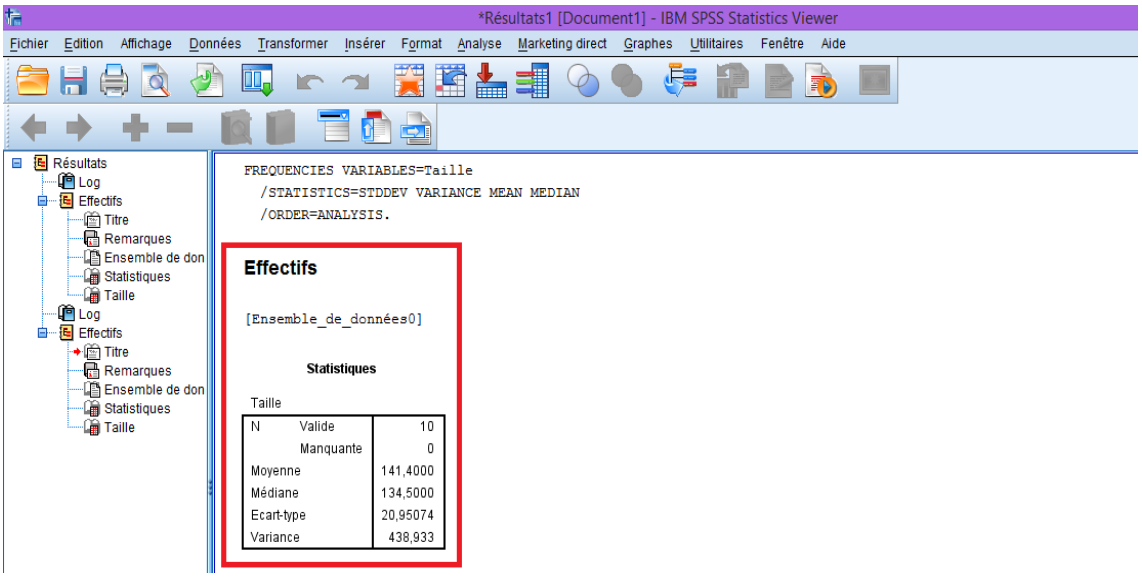
1.2.3 Valeurs et étiquette

Ces deux cases permettent de donner des codes simples aux valeurs des observations.



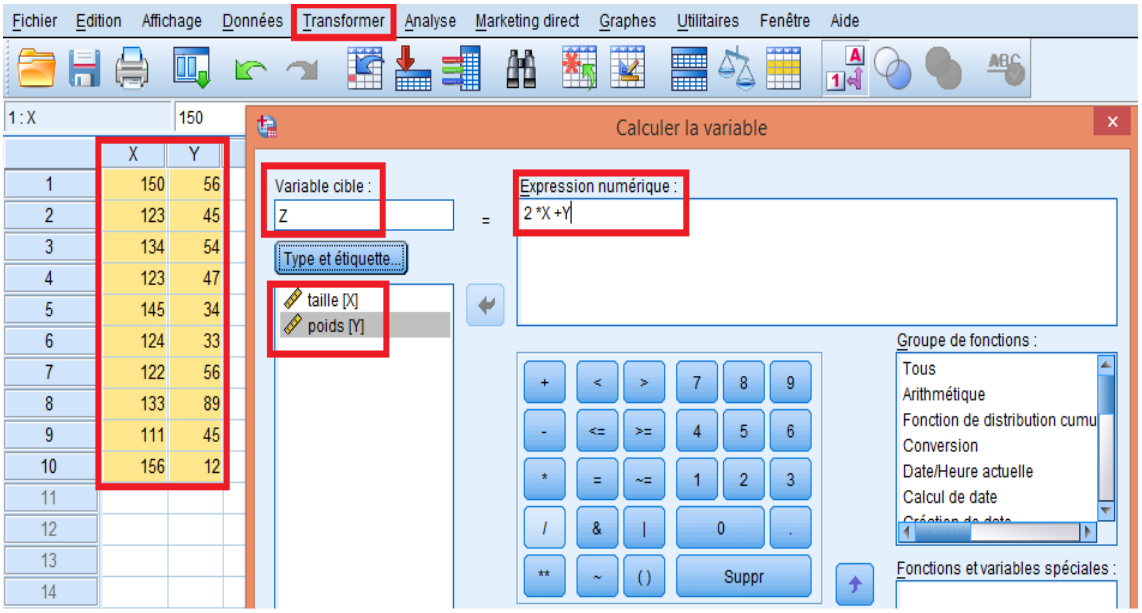
1.2.4 La fenêtre Viewer

Cette fenêtre contient la suite chronologique des traitements statistiques effectués. Le navigateur de résultat, dans la partie gauche de la fenêtre, permet de passer rapidement d'un résultat à l'autre.



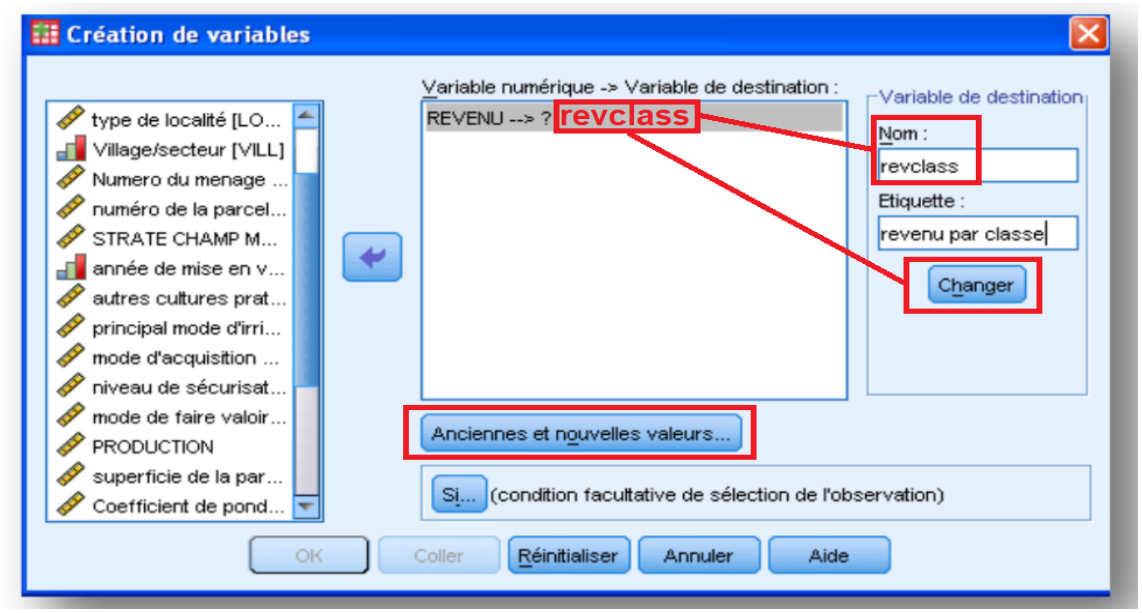
1.2.5 Transformation des variables

Sous SPSS 25: le chemin Transformer > Calculer la variable permet de définir une nouvelle variable Z à partir des variables initiales X et Y. Par exemple: $Z = 2X + Y$.

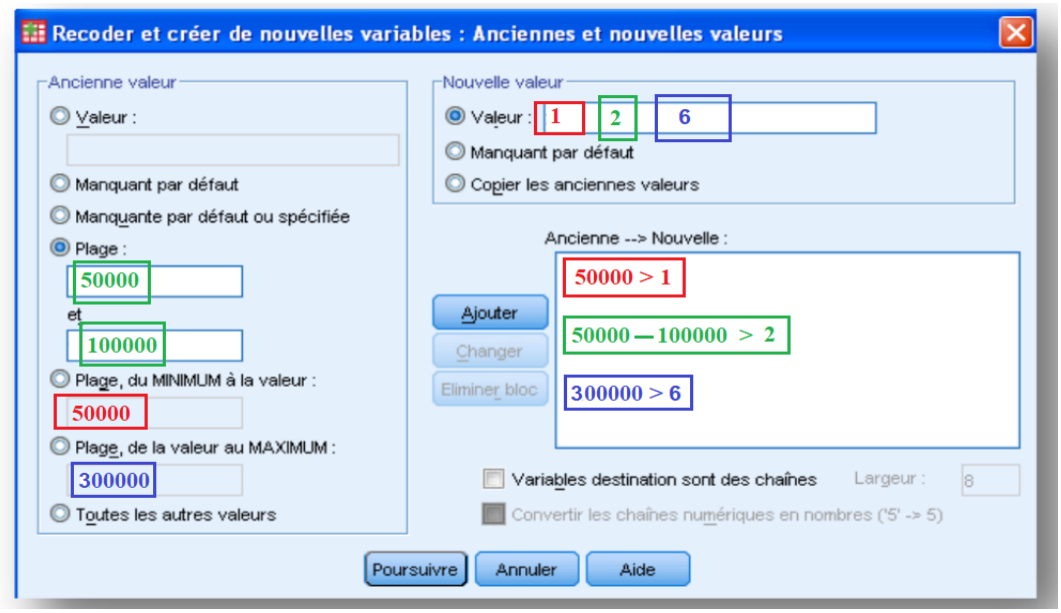


	X	Y
1	150	56
2	123	45
3	134	54
4	123	47
5	145	34
6	124	33
7	122	56
8	133	89
9	111	45
10	156	12

Recoder une variable: lorsqu'on a le revenu des ménages, on peut vouloir recoder cette variable en cinq groupe de 1 à 5. Par exemple si revenu < 50000 alors revclass = 1; si $50000 \leq$ revenu < 100000 alors revclass = 2;.....; si revenu ≥ 30000 alors revclass = 6.



Sous SPSS 25: Transformer > Création de variables > Changer > Anciennes et nouvelles valeurs: Saisissez 50000 dans la zone plage du MINIMUM puis tapez 1 dans la zone Nouvelle valeur et cliquez sur ajouter. Ensuite tapez dans la zone Plage 50000 et 100000 puis dans valeur mettez 2 et cliquez sur ajouter, ainsi de suite jusqu'à la fin, Saisissez 300000 dans la zone plage du MAXIMUM puis tapez 6 dans la zone Nouvelle valeur et cliquez sur ajouter. ....(Notons que la nouvelle variable est de type qualitative).



1.3 Exemples d'études Statistiques

1.3.1 Variable qualitative nominale

On note C : célibataire, M : marié, V : veuf, D : divorcé. On s'intéresse à la variable X=(état-civil) sur une population de $n = 20$ personnes:

M	D	M	C	C	M	C	C	C	M	C	M	V	M	V	D	C	C	M	C

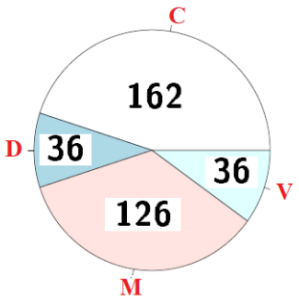
Tableau statistique:

x_i	n_i	f_i	$p_i\%$	N_i	F_i	P_i
C	9	0.45	45	9	0.45	45
M	7	0.35	35	16	0.75	75
V	2	0.10	10	18	0.85	85
D	2	0.10	10	**20**	**1**	**100**

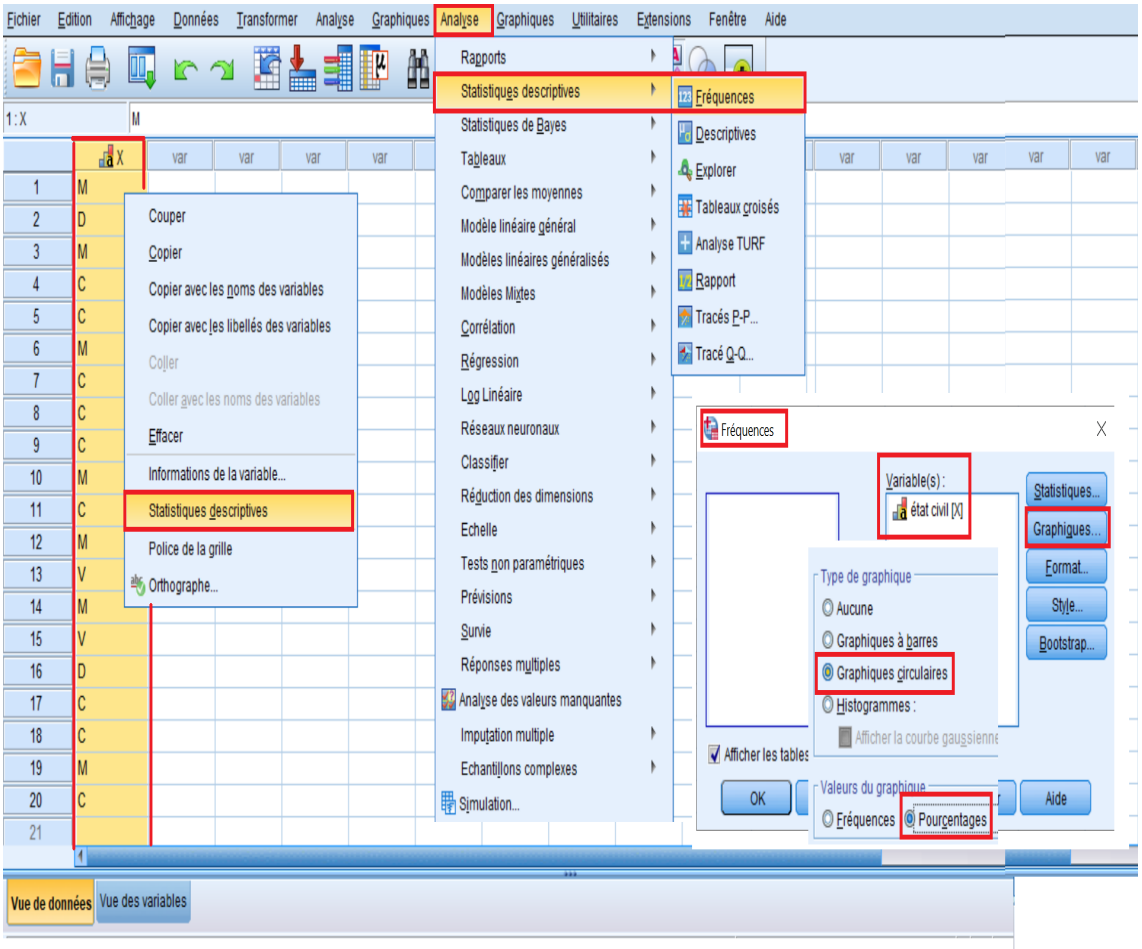
Par exemple: le nombre d'apparition de la valeur $x_2 = M$ dans la série statistique est $n_2 = 7$, sa fréquence est $f_2 = \frac{n_2}{n} = \frac{7}{20} = 0.35$, son pourcentage $p_2 = 100 \times f_2 = 100 \times 0.35 = 35\ \%$.

Diagramme en secteurs:
Le tableau statistique d'une variable qualitative est représenté par le diagramme en secteurs formés par les degrés obtenus comme suit:

x_i	p_i %	$d_i = p_i \times 3.6\ °$
C	45	162
M	35	126
V	10	36
D	10	36



Sous SPSS 25: ou bien cliquez à droite sur la colonne jaune des 20 valeurs de X puis sélectionnez Statistiques descriptives, ou bien suivez le chemin: Analyse > Statistiques descriptives > Fréquences.

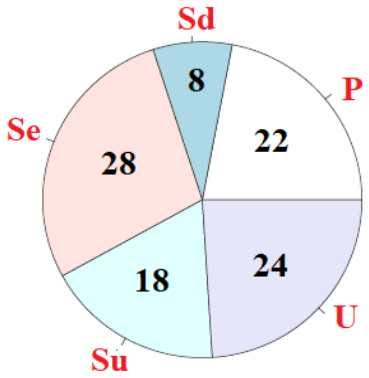


1.3.2 Variable qualitative ordinale

On interroge une population de $n = 50$ personnes sur leur dernier diplôme obtenu. On note: Sd : Sans diplôme, P : Primaire, Se : Secondaire, Su : Supérieur non-universitaire et U : Universitaire.

Sd Sd Sd Sd P P P P P P P P P P P Se Se Su
Se Se Se Se Se Se Se Se Se Se Se Se Su Su Su
Su Su Su Su U U U U U U U U U U U U U Su

x_i	n_i	N_i	f_i	p_i	F_i
Sd	4	4	0.08	8	0.08
P	11	15	0.22	22	0.30
Se	14	29	0.28	28	0.58
Su	9	38	0.18	18	0.76
U	12	**50**	0.24	24	**1**



Sous SPSS 25: si vous cliquez deux fois sur une figure, vous aurez des choix multiples pour modifier la taille, les couleurs et l'épaisseur, ajouter un titre, afficher les pourcentages associées, ...

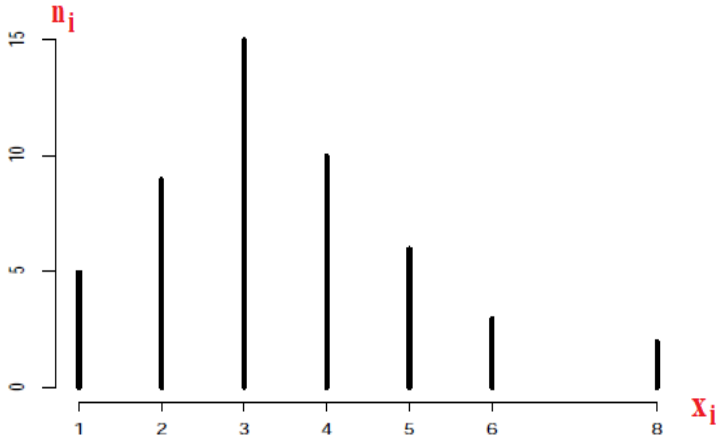
1.3.3 Variable quantitative discrète

Un quartier est composé d'une population de 50 ménages, et la variable X représente le nombre de personnes par ménage. Les valeurs de la variable sont:

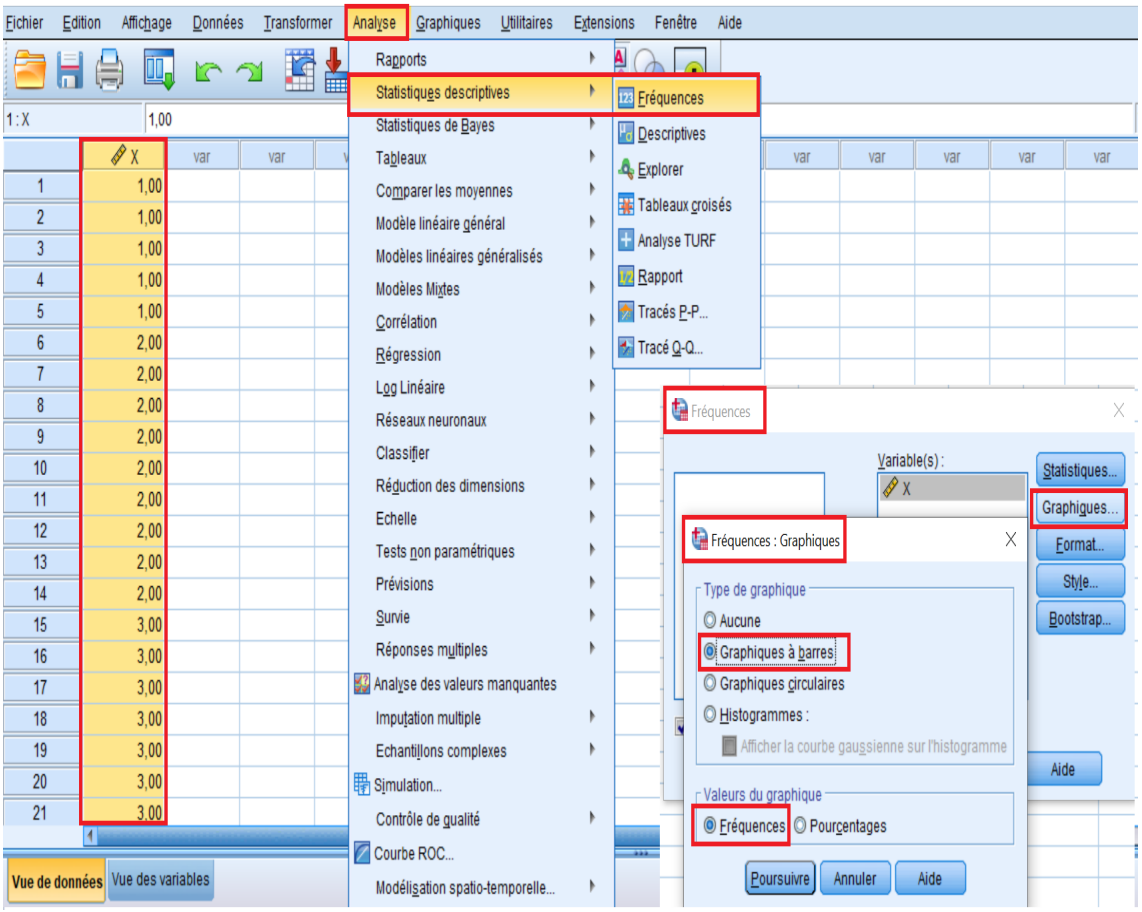
1	1	1	1	1	2	2	2	2	2
2	2	2	2	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	4
4	4	4	4	4	4	4	4	4	5
5	5	5	5	5	6	6	6	8	8

x_i	n_i	N_i	f_i	F_i
1	5	5	0.10	0.10
2	9	14	0.18	0.28
3	15	29	0.30	0.58
4	10	39	0.20	0.78
5	6	45	0.12	0.90
6	3	48	0.06	0.96
8	2	50	0.04	1

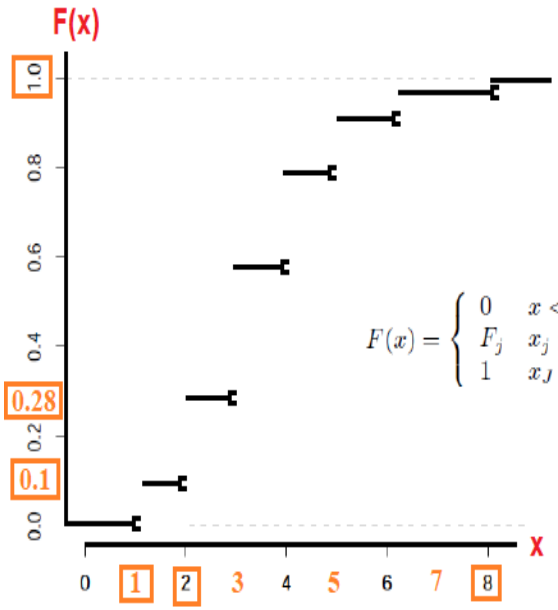
Diagramme en bâtonnets:



Sous SPSS 25: Analyse > Statistiques descriptives > Fréquences > Graphiques > Graphiques à barres.



Fonction de répartition:
Les fréquences cumulées sont représentées au moyen de la fonction de répartition. Cette fonction est définie de $\mathbb{R}$ dans $[0, 1]$ et vaut:



x_i	F_i
1	0.10
2	0.28
3	0.58
4	0.78
5	0.90
6	0.96
8	1

Sous SPSS 25: Graphes > Générateur de diagrammes > Courbes > Diagramme en ligne simple > Pourcentage cumulé > Type > Sauts (pour discret), (voir page 13).

1.3.4 Variable quantitative continue

Très souvent, la prise en compte de toute les valeurs observées ne permet pas de donner une interprétation simple des résultats et conduit à des calculs inutiles. On peut souvent se contenter de regarder des regroupements en classes.
On mesure la variable X=taille en centimètre d'une population de 50 élèves d'une classe.

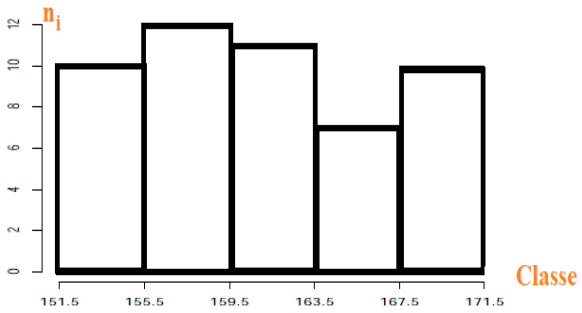
152	152	152	153	153	154	154	154	155	155
156	156	156	156	156	157	157	157	158	158
159	159	160	160	160	161	160	160	161	162
162	162	163	164	164	164	164	165	166	167
168	168	168	169	169	170	171	171	171	171

Tableau statistique:
Pour construire le tableau statistique, il faut procéder à des regroupements en classes (intervalles) de même amplitude. En règle générale, on choisit au moins cinq classes, sinon on utilise par exemple la règle de Sturge: le nombre de classes est $J = 1+(3.3\times log_{10}(n))$.

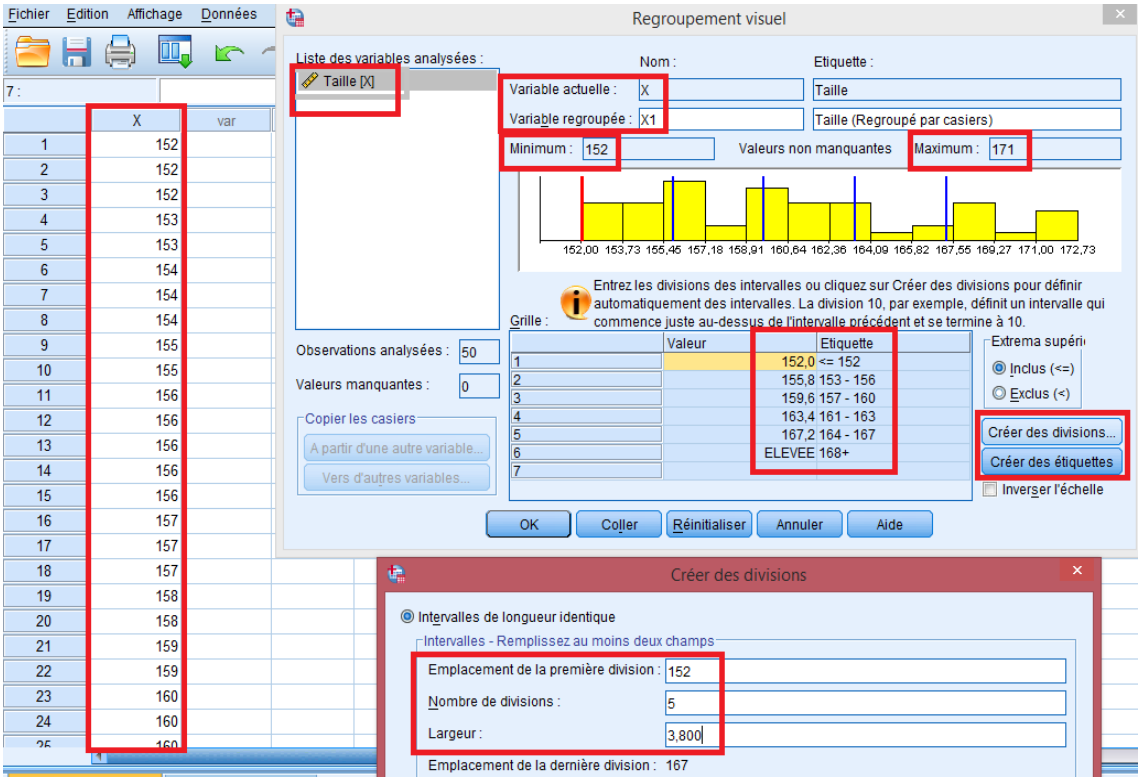
La longueur de chaque classe est $l = \dfrac{x_{\max} - x_{\min}}{J}$. Pour $J = 5$, on prend $l \simeq 4$.

classe	n_i	N_i	f_i	F_i
$[151.5;\ 155.5[$	10	10	0.20	0.20
$[155.5;\ 159.5[$	12	22	0.24	0.44
$[159.5;\ 163.5[$	11	33	0.22	0.66
$[163.5;\ 167.5[$	7	40	0.14	0.80
$[167.5;\ 171.5[$	10	**50**	0.20	**1**

Histogramme des effectifs:



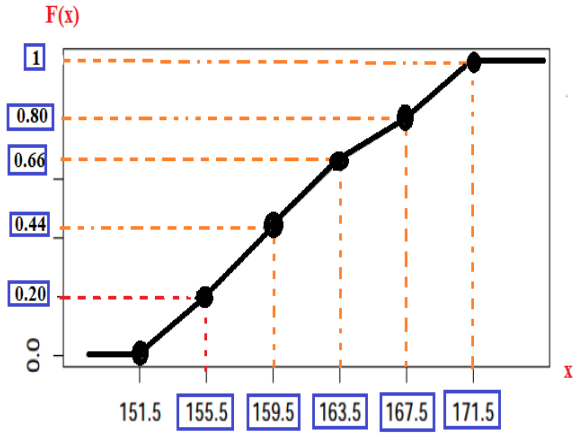
Sous SPSS 25: Transformer > Regroupement visuel permet de transformer une variable quantitative en une variable qualitative en définissant des classes de valeurs.



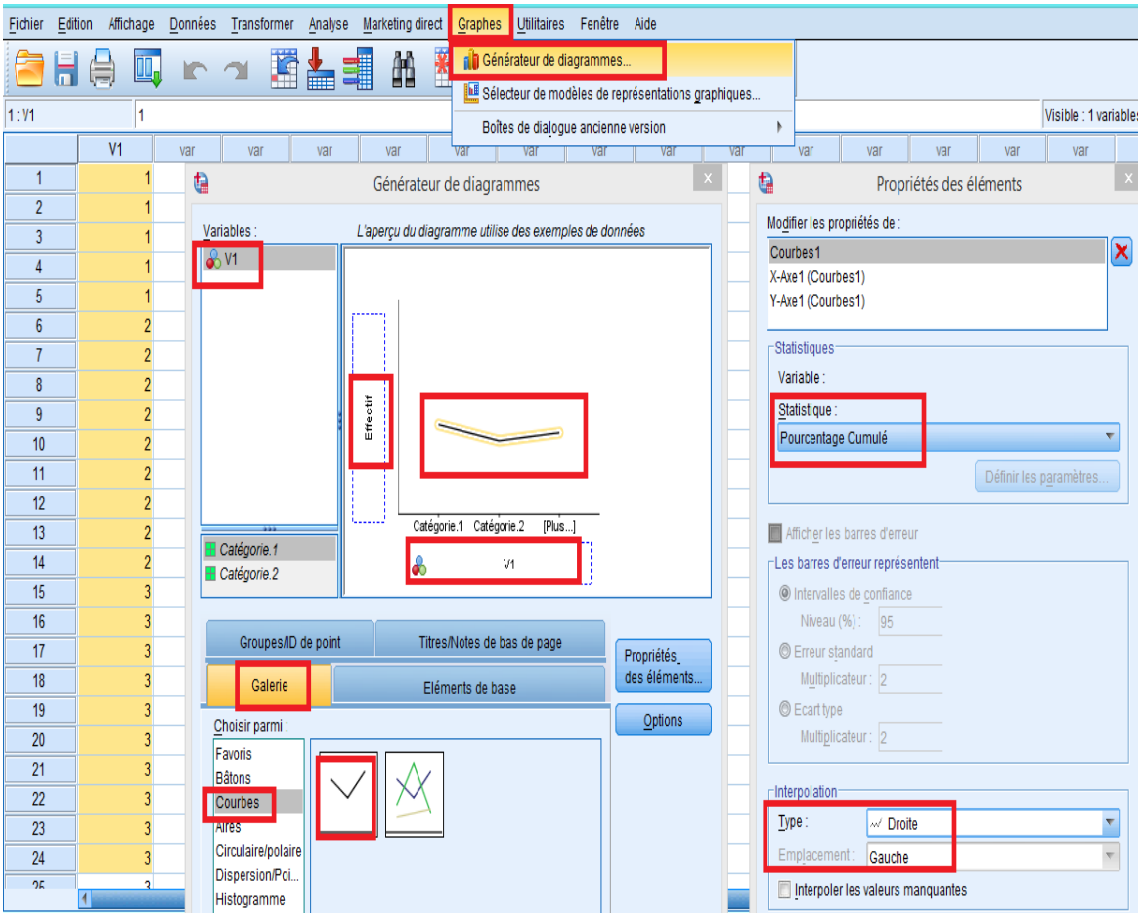
Fonction de répartition:

$$F(x)=\begin{cases}0 & x<c_1^- \\ F_{j-1}+\dfrac{f_j}{c_j^+-c_j^-}(x-c_j^-) & c_j^- \le x<c_j^+ \\ 1 & c_j^+ \le x\end{cases}$$

classe	F_i
[151.5 ; 155.5[	0.20
[155.5 ; 159.5[	0.44
[159.5 ; 163.5[	0.66
[163.5 ; 167.5[	0.80
[167.5 ; 171.5[	1



Sous SPSS 25: Graphes > Générateur de diagrammes > Courbes > Diagramme en ligne simple > Pourcentage cumulé > Type > Droite (pour continue).



1.4 Paramètres de position

1.4.1 Le mode

Le mode est la valeur x_i correspondant à l'effectif (ou fréquence) le plus élevé.

x_i	n_i	f_i
C	**9**	**0.45**
M	7	0.35
V	2	0.10
D	2	0.10

1.4.2 La moyenne

La moyenne $\bar{x}$ ne peut être définie que sur une variable quantitative comme suit:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + ... + x_n}{n}.$$

La moyenne peut être calculée à partir des valeurs distinctes et des effectifs:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{J} n_i \times x_i = \frac{(n_1 \times x_1) + ... + (n_J \times x_J)}{n}.$$

Exemple:
Les nombres d'enfants de 8 familles sont les suivants $0, 0, 1, 1, 1, 2, 3, 4$. La moyenne est:

$$\bar{x} = \frac{0+0+1+1+1+2+3+4}{8} = 1.5.$$

On peut aussi faire: $\bar{x} = \dfrac{(2\times 0)+(3\times 1)+(1\times 2)+(1\times 3)+(1\times 4)}{8} = 1.5.$

1.4.3 La médiane

• Cas d'une variable quantitative discrète:
La médiane, notée M_e ou $x_{\frac{1}{2}}$, est une valeur centrale de la série statistique qui la partage en deux groupes de même effectifs. Elle est obtenue de la manière suivante:
– On trie la série statistique par ordre croissant des valeurs observées.
– Si n est impair, alors la médiane est la valeur du rang $\dfrac{n+1}{2}$.
– Si n est pair, alors la médiane est la moyenne des deux valeurs de rang $\dfrac{n}{2}$ et $\dfrac{n}{2}+1$.

Exemples:
Pour : 0 0 1 **1** 2 2 3, on a: $x_{\frac{1}{2}} = 1$.
Pour : 0 0 1 **1** **2** 2 3 4, on a: $x_{\frac{1}{2}} = \dfrac{1+2}{2} = 1.5$.

• **Cas d'une variable quantitative continue:**

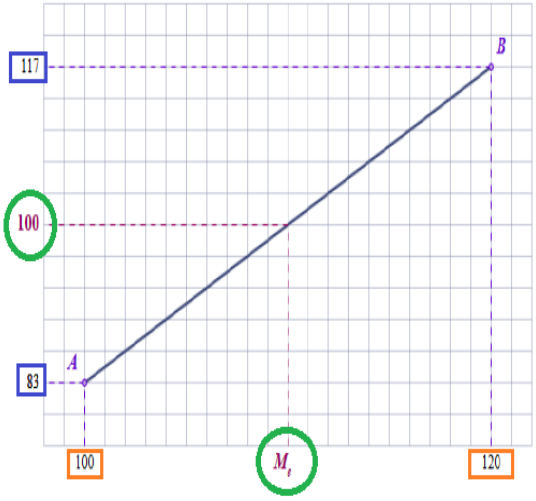
La médiane est la valeur (abscisse) correspondant à la fréquence cumulée $F = 0.5$ ou effectif cumulé $N = \dfrac{n}{2}$. On l'obtiendra par lecture graphique: $M_e = x_{\frac{1}{2}} = F^{-1}(0.5)$) sur la courbe des fréquences cumulées, ou par une formule d'interpolation linéaire.

Budget (*en milliers d'euros*)	[0;50[	[50;70[	[70;100[	[100;120[	[120;150[	[150;200[	[200;240[
Nombre d'entreprises	10	28	45	34	42	33	8
Effectifs cumulés	10	38	83	117	159	192	200

Il y a 200 entreprises, donc la classe médiane est la classe [100;120[.

$N = \dfrac{n}{2} = 100$

Calculons la médiane par interpolation linéaire :



La médiane est l'abscisse du point de la droite passant par les points $A(100;83)$ et $B(120;117)$ dont l'ordonnée est égale à 100.

La droite (AB) a pour équation, $y = mx + p$ avec

$$m = \frac{117-83}{120-100} = 1{,}7$$

Comme $A(100;83)$ est un point de la droite (AB), nous obtenons la relation

$$y = 1{,}7(x-100)+83 \quad \Leftrightarrow \quad y = 1{,}7x - 87$$

La médiane est la valeur associé à un effectif égal à 100 d'où x est solution de l'équation

$$1{,}7x - 87 = 100 \quad \Leftrightarrow \quad x = \frac{100+87}{1{,}7} = 110$$

Le budget médian est de 110 milliers d'euros.

1.5 Paramètres de dispersion

1.5.1 L'étendue

L'étendue est défini par: $E = x_{max} - x_{min}$.
Pour la série 1 1 2 1 1 3 5 5 5 5 5 3 2 5, on a: $E = 5 - 1 = 4$.

1.5.2 La variance et l'écart type

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2.$$

La variance peut aussi s'écrire:

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{J} n_i \times (x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{J} n_i \times x_i^2 - \bar{x}^2.$$

L'écart type est défini par: $\sigma_X = \sqrt{\sigma_X^2}$.

Soit la série statistique 2 3 4 4 5 6 7 9 de taille 8. On a:

$$\bar{x} = \frac{2+3+4+4+5+6+7+9}{8} = 5.$$

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

$$= \frac{(2-5)^2 + (3-5)^2 + (4-5)^2 + (4-5)^2 + (5-5)^2 + (6-5)^2 + (7-5)^2 + (9-5)^2}{8} = 4.5,$$

ou bien : $\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2 = \frac{2^2+3^2+4^2+4^2+5^2+6^2+7^2+9^2}{8} - 5^2 = 4.5.$

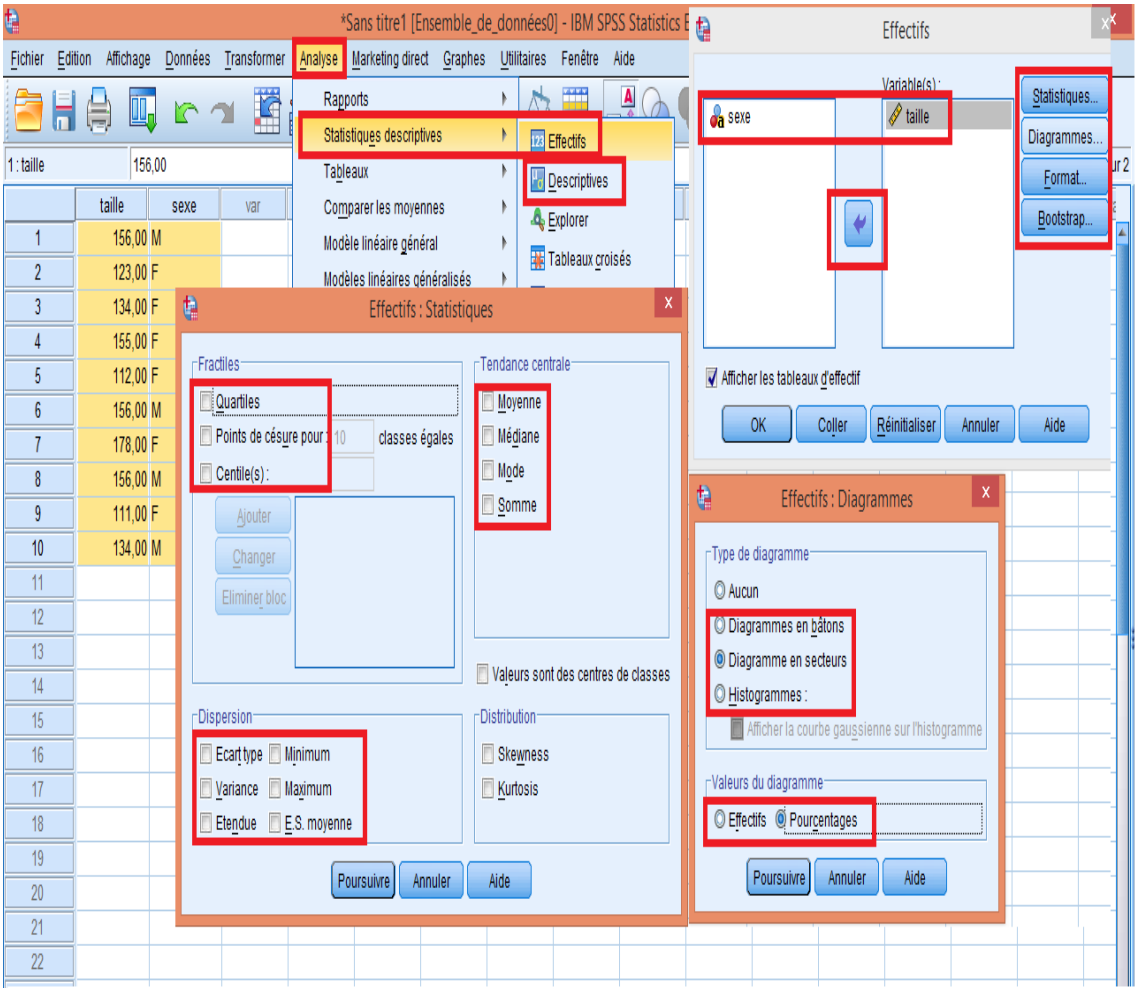
L'écart type: $\sigma_X = \sqrt{4.5} = 2.12$.

Remarque
Pour calculer la moyenne et la variance dans le cas d'une variable continue, on calcule les centres des classes qui vont jouer le rôle des valeurs x_i du cas discret.

classe	n_i	centre x_i
$[0;10[$	10	$\frac{0+10}{2} = 5$
$[10;20[$	4	15
$[20;30[$	20	25
$[30;40[$	6	35

$$\bar{x} = \frac{10 \times 5 + 4 \times 15 + 20 \times 25 + 6 \times 35}{40} = 20.5.$$

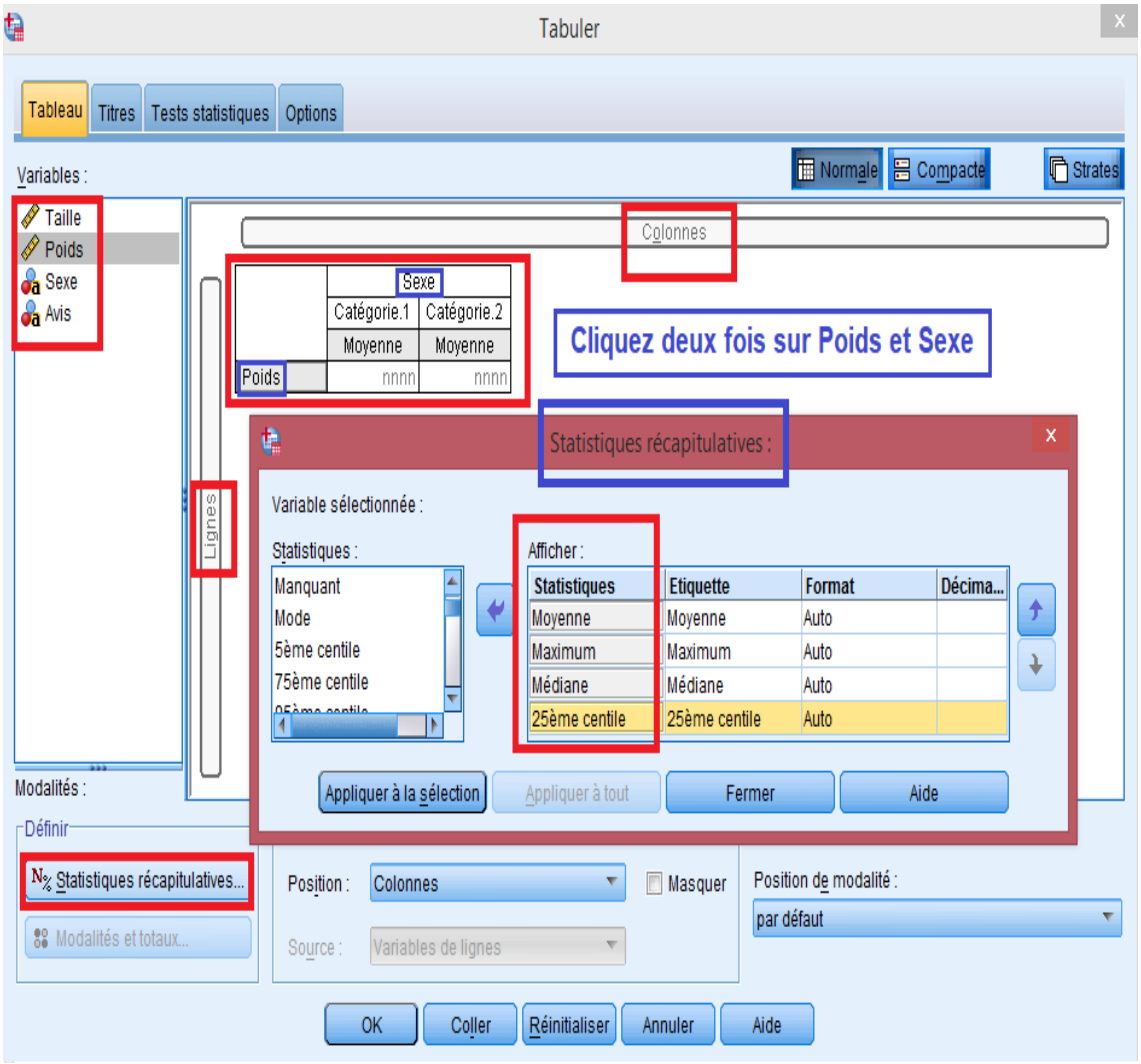
Sous SPSS 25: le chemin: Analyse > Statistiques descriptives > Effectifs ou Descriptives permet de faire une analyse statistique des données: calculs des moyennes, des variances, ..., et obtention des diagrammes en secteurs, des histogrammes,...



NB: On peut obtenir les statistiques descriptives d'une variable en cliquant à droite par la souris sur la colonne jaune de la variable. Ceci permet aussi de trier la variable par ordre croissant ou décroissant.

Le chemin suivant: Analyse > Tableaux > Tabuler (sous SPSS 20) ou Tableaux personnalisés (sous SPSS 25) permet de construire des tableaux de la forme:

		Poids					
		Moyenne	Maximum	Minimum	Médiane	25 centile	75 centile
Sexe	Femme	70	88	50	72	59	81
	Homme	69	85	50	69	57	81



1.6 TP 1 sous SPSS 25

NB: Le tableau statistique contient: modalités, effectifs, fréquences, pourcentages, effectifs cumulés, fréquences cumulées et pourcentages cumulés.

Exercice 1

On donne les couleurs de $n = 20$ plantes.

Vert	**Vert**	**Rouge**	**Noir**	**Rouge**	**Rouge**	**Vert**	**Rouge**	**Noir**	**Rouge**
Rouge	**Rouge**	**Rouge**	**Jaune**	**Rouge**	**Jaune**	**Noir**	**Noir**	**Noir**	**Noir**

1. Saisir ces données sous SPSS en utilisant **des étiquettes et des libellés**.
2. Construire le tableau statistique et en déduire le mode.
3. Construire le diagramme en secteurs où les pourcentages sont collés sur le digramme.
4. Donner un titre au diagramme, changer les couleurs, la taille et les polices.

Exercice 2

Trente éprouvettes d'acier spécial sont soumises à des essais de résistance. Pour chacune, on note le nombre de chocs nécessaires pour obtenir la rupture. Les résultats obtenus sont les suivants :

2	2	3	1	2	1	4	2	3	2
3	2	3	3	4	1	1	4	2	3
2	3	2	2	3	4	3	2	3	2

1. Construire le tableau statistique et en déduire le mode.
2. Construire le diagramme en bâtonnets des effectifs. Modifier ces paramètres.
3. Déterminer: la médiane, la moyenne, la variance et l'écart type de cette variable.
4. Tracer la fonction de répartition de cette variable.
5. Calculer la nouvelle variable qui représente le nombre de chocs au carré.

Exercice 3

On pèse les $n = 50$ élèves d'une classe et nous obtenons les résultats résumés dans le tableau suivant:

43	**43**	**43**	**47**	**48**	**48**	**48**	**48**	**49**	**49**
49	**50**	**50**	**51**	**51**	**52**	**53**	**53**	**53**	**54**
54	**56**	**56**	**56**	**57**	**59**	**59**	**59**	**62**	**62**
63	**63**	**65**	**65**	**67**	**67**	**68**	**70**	**70**	**70**
72	**72**	**73**	**77**	**77**	**81**	**83**	**86**	**92**	**93**

1. Construire le tableau statistique en adoptant quatre classes seulement.
2. Refaire le même regroupement via le chemin: **Transformer > Recoder une variable.**
3. Tracer la fonction de répartition de cette variable.
4. Tracer l'histogramme de cette variable. Modifier ces paramètres.
5. Déterminer la médiane, la moyenne, la variance et l'écart type de cette variable.

Exercice 4

1. Importer le fichier nommé: **TP 1** depuis **Excel** vers SPSS.
2. Construire le tableau statistique de la variable produit.
3. Construire le diagramme en secteurs de la variable produit.
4. Construire le tableau statistique de la variable diamètre.
5. Construire le diagramme en bâtonnets des effectifs de la variable diamètre.
6. Déterminer la médiane, la moyenne, la variance et l'écart type de la variable diamètre.
7. Tracer la fonction de répartition de la variable diamètre.
8. Construire la nouvelle variable égale au carré du diamètre moins sa racine carrée puis calculer sa moyenne et ses trois quartiles en donnant des interprétations.
9. Construire le tableau statistique de la variable température en adoptant trois classes en suivant les deux chemins: **Transformer > recoder une variable et Transformer > Regroupement visuel.**
10. Déterminer la médiane, la moyenne, la variance et l'écart type de la variable température .
11. Tracer l'histogramme de la variable poids.
12. Tracer la fonction de répartition de la variable température.

Chapitre 2

Pratique de la Statistique Descriptive Bivariée sous SPSS 25

L'objectif de cette partie est d'étudier sur une même population de n individus, deux caractères différents X et Y et de rechercher s'il existe un lien entre ces deux variables. Chacune des deux variables peut être, soit quantitative, soit qualitative.
La série statistique est alors une suite de n couples des valeurs prises par les deux variables sur chaque individu: $(x_1, y_1), ..., (x_n, y_n)$. L'effectif associe à l'observation (x_i, y_j) est noté n_{ij} et sa fréquence notée: $f_{ij} = \dfrac{n_{ij}}{n}$.

2.1 Deux variables qualitatives (tableau de contingence)

Tableau de contingence des effectifs n_{ij}:
On s'intéresse à une éventuelle relation entre la variable $X=$ (le sexe) de $n = 200$ personnes et la variable $Y =$ (la couleur des yeux).

X/Y	Bleu	Vert	Marron	Total
Homme	$n_{11} = 10$	$n_{12} = 50$	$n_{13} = 20$	$n_{1\bullet} = 80$
Femme	$n_{21} = 20$	$n_{22} = 60$	$n_{23} = 40$	$n_{2\bullet} = 120$
Total	$n_{\bullet 1} = 30$	$n_{\bullet 2} = 110$	$n_{\bullet 3} = 60$	$n = 200$

Les nombres $n_{1\bullet}, n_{2\bullet}$ et $n_{\bullet 1}, n_{\bullet 2}, n_{\bullet 3}$ sont appelés effectifs marginaux.
Par exemple la valeur $n_{22} = 60$ exprime que 60 femmes ont une couleur verte des yeux et on a:

$$\begin{cases} n_{11} + n_{12} + n_{13} = n_{1\bullet}, \\ n_{21} + n_{22} + n_{23} = n_{2\bullet}, \\ n_{11} + n_{21} = n_{\bullet 1}, \\ n_{12} + n_{22} = n_{\bullet 2}, \\ n_{13} + n_{23} = n_{\bullet 3}, \\ n_{11} + n_{12} + n_{13} + n_{21} + n_{22} + n_{23} = n. \end{cases}$$

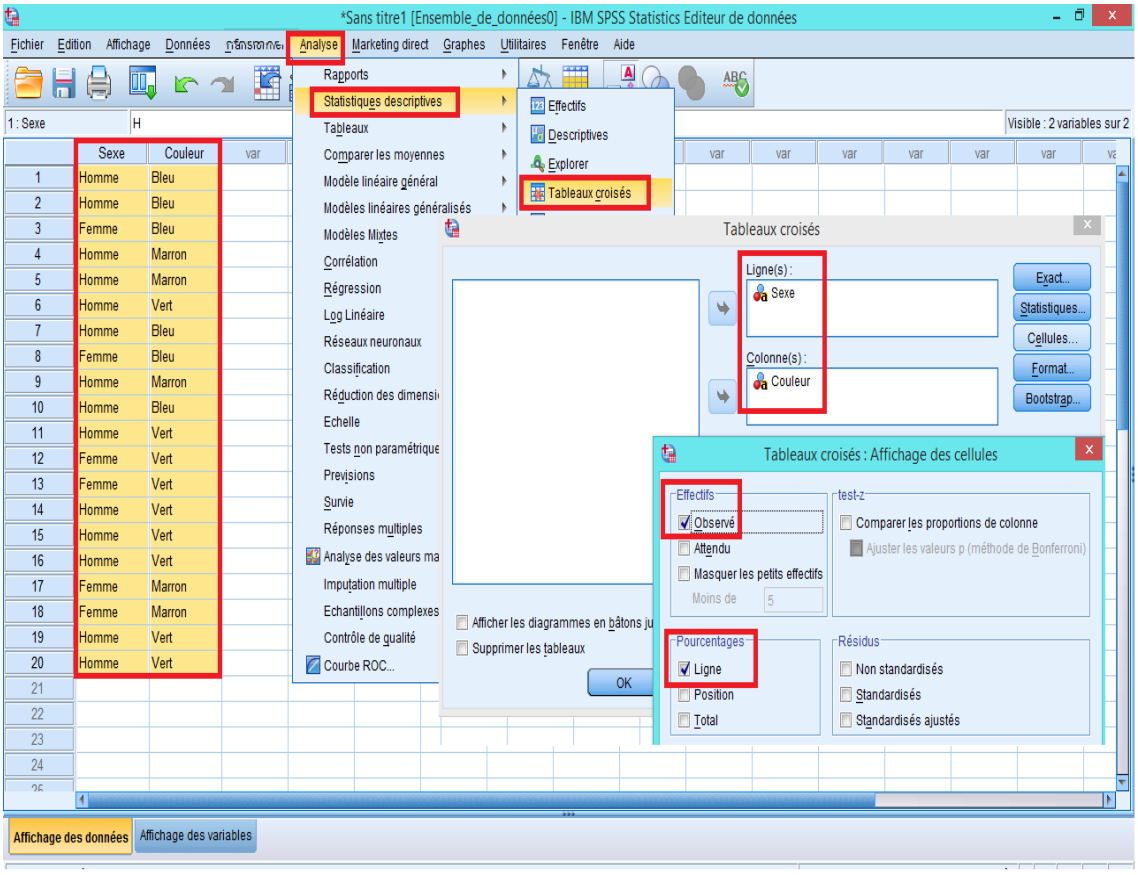
Tableau de contingence des fréquences $f_{ij} = \dfrac{n_{ij}}{n}$:

$$\begin{cases} f_{ij} = \frac{n_{ij}}{n}, f_{i\bullet} = \frac{n_{i\bullet}}{n}, f_{\bullet j} = \frac{n_{\bullet j}}{n} \\ f_{11} + f_{12} + f_{13} = f_{1\bullet}, \\ f_{21} + f_{22} + f_{23} = f_{2\bullet}, \\ f_{11} + f_{21} = f_{\bullet 1}, \\ f_{12} + f_{22} = f_{\bullet 2}, \\ f_{13} + f_{23} = f_{\bullet 3}, \\ f_{11} + f_{12} + f_{13} + f_{21} + f_{22} + f_{23} = 1. \end{cases}$$

Les nombres $f_{1\bullet}, f_{2\bullet}$ et $f_{\bullet 1}, f_{\bullet 2}, f_{\bullet 3}$ sont appelées fréquences marginales.

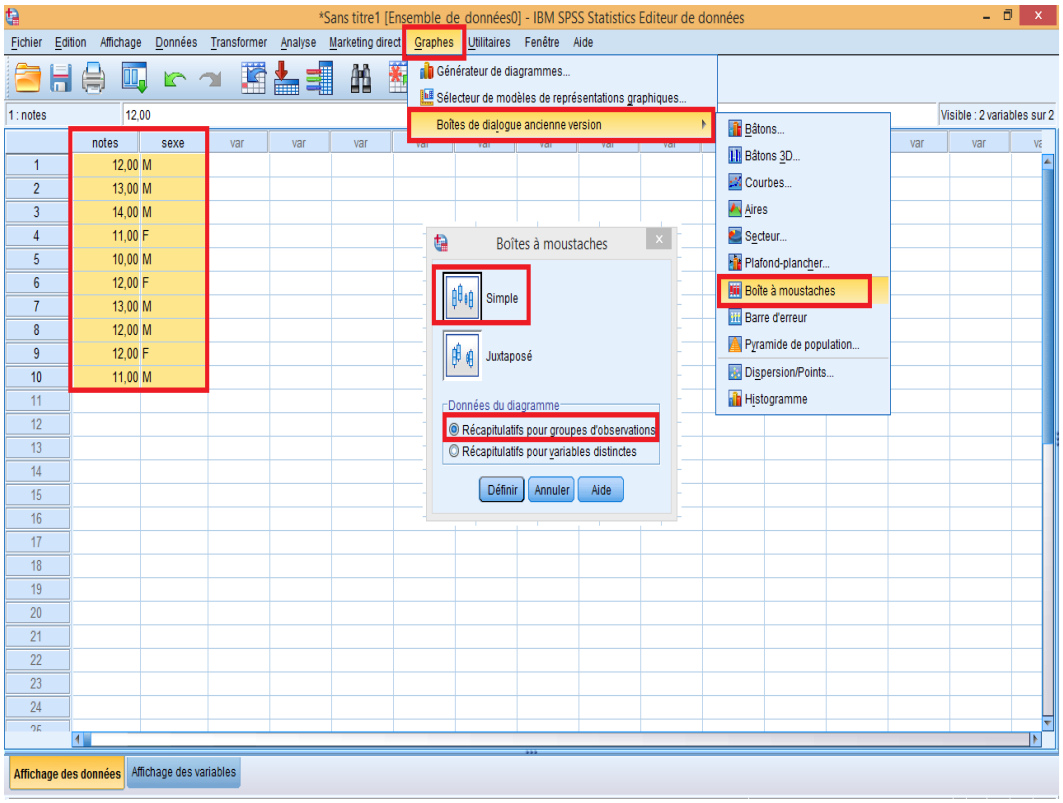
X/Y	Bleu	Vert	Marron	Total
Homme	$f_{11} = 0.05$	$f_{12} = 0.25$	$f_{13} = 0.10$	$f_{1\bullet} = 0.40$
Femme	$f_{21} = 0.10$	$f_{22} = 0.30$	$f_{23} = 0.20$	$f_{2\bullet} = 0.60$
Total	$f_{\bullet 1} = 0.15$	$f_{\bullet 2} = 0.55$	$f_{\bullet 3} = 0.30$	1

Sous SPSS 25: Analyse > Statistiques descriptives > Tableaux croisés.



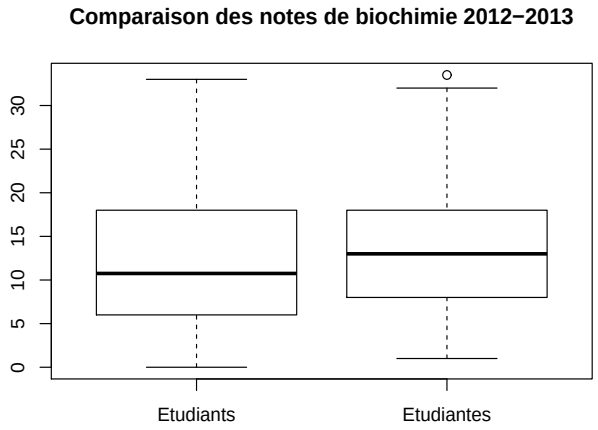
2.2 Une variable quantitative et une variable qualitative (boîte à moustache)

Diagramme à boîtes à moustaches:
La boîte, (verticale ou bien horizontale), est la partie du graphique comprise entre les premier et troisième quartiles. La médiane est située à l'intérieur de la boîte et elle est représentée par un trait horizontal. Dans les parties basse et haute du graphique figurent les moustaches, joignant le min au premier quartile et le troisième quartile au max.
Exemple:
On considère X= notes des étudiants (quantitative) et Y= sexe (qualitative).
Sous SPSS 25: Graphes > Boîtes de dialogue ancienne version > Boîte à moustache.



Sous SPSS 25: pour trouver les valeurs sur les Boîtes: Analyse > Tableaux > Tabuler ou Tableaux personnalisés sous SPSS 25.

		Poids					
		Moyenne	Maximum	Minimum	Médiane	25 centile	75 centile
Sexe	Femme	70	88	50	72	59	81
	Homme	69	85	50	69	57	81



2.3 Deux variables quantitatives (régression linéaire et prédiction)

On considère une population sur laquelle on étudie deux variables quantitatives X et Y. On veut savoir si les deux variables sont liés par une liaison linéaire du type $Y = a + bX$, i.e., que l'on peut prévoir les valeurs de Y à partir des valeurs de X. Précisons dès maintenant que l'existence d'une telle liaison entre les deux variables X et Y ne signifie pas obligatoirement un lien de cause à effet entre elles.

Exemple:
Neuf étudiants émettent un avis pédagogique vis-à-vis d'un professeur selon une échelle d'appréciation de 1 à 20. On relève par ailleurs la note obtenue par ces étudiants l'année précédente auprès du professeur.

Y= avis	5	7	16	6	12	14	10	9	8
X= résultat	8	11	10	13	9	17	7	15	16

Covariance:
La covariance est définie par:

$$\sigma_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{x}\bar{y}.$$

Corrélation:
Le coefficient de corrélation est définie par:

$$r := r_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}.$$

Le coefficient de corrélation mesure la dépendance linéaire entre les variables X et Y:

- Si le coefficient de corrélation est positif, les points du nuage sont alignés le long d'une droite croissante. Dans ce cas X et Y évoluent dans le même sens.
- Si le coefficient de corrélation est négatif, les points sont alignés le long d'une droite décroissante. Dans ce cas X et Y évoluent dans des sens opposés.
- La corrélation est parfaite si $|r| = 1$. X et Y sont dits: fortement corrélées.
- La corrélation est très forte si $|r| > 0.8$.
- La corrélation est forte si $|r|$ se situe entre 0.5 et 0.8.
- La corrélation est d'intensité moyenne : si $|r|$ se situe entre 0.2 et 0.5.
- La corrélation est faible si $|r|$ se situe entre 0 et 0,2.
- La corrélation est nulle si $r = 0$.

Droite de régression linéaire et Prédiction:

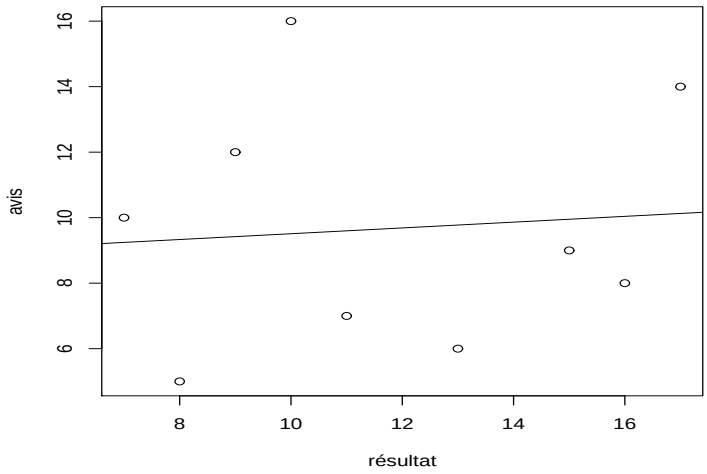
La droite de régression linéaire est la droite qui ajuste au mieux un nuage de points au sens des moindres carrés. On considère que la variable X est explicative et que la variable Y est dépendante. L'équation de la droite de régression de Y en X est: $y = \hat{a} + \hat{b}x$, avec

$$\hat{b} = \frac{\sigma_{XY}}{\sigma_X^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x} \quad \text{(la droite de régression passe par le point } (\bar{x}, \bar{y})).$$

Dans notre exemple, on a:

$$\begin{cases} \bar{x} = 106/9 = 11.78 \\ \bar{y} = 87/9 = 9.667 \\ \sigma_X^2 = 1354/9 - 11.78^2 = 11.73 \\ \sigma_Y^2 = 951/9 - 9.667^2 = 12.22 \\ \sigma_{XY} = 1034/9 - 9.667 \times 11.78 = 1.037 \\ r_{XY} = \frac{1.037}{\sqrt{11.73} \times \sqrt{12.22}} = 0.087 \end{cases}$$

Finalement l'équation de la droite de régression de Y en X est: $y = 0.088x + 8.625$.



Prédiction:
Dans notre exemple si on veut prédire, sur la base de notre modèle, l'avis pour un étudiant ayant obtenu $x = 12/20$, alors la valeur ajustée est:

$$y = 0.088 \times 12 + 8.625 = 9.681.$$

Résidus ou erreurs de prédiction:
Les résidus de la régression sont définis par:

$$e_i = y_i - (\hat{a} + \hat{b}x_i) = y_i - \hat{y}_i.$$

Le résidu e_i est l'erreur que l'on commet en utilisant la droite de régression pour prédire y_i à partir de x_i. Les résidus sont les différences entre les valeurs observées y_i et les valeurs ajustées $\hat{y}_i$ de la variable dépendante.
Par exemple pour la valeur $x_3 = 12$, on donne $y_3 = 10$ et on a $\hat{y}_3 = 0.088 \times 12 + 8.625 = 9.681$, donc $e_3 = y_3 - \hat{y}_3 = 0.319$.
Moyenne résiduelle:

$$\bar{e} = \frac{1}{n}\sum_{i=1}^{n} e_i = 0.$$

Variance résiduelle:
La variance résiduelle est la variance des résidus:

$$\sigma_e^2 = \frac{1}{n}\sum_{i=1}^{n} e_i^2.$$

La variance résiduelle peut également s'écrire:

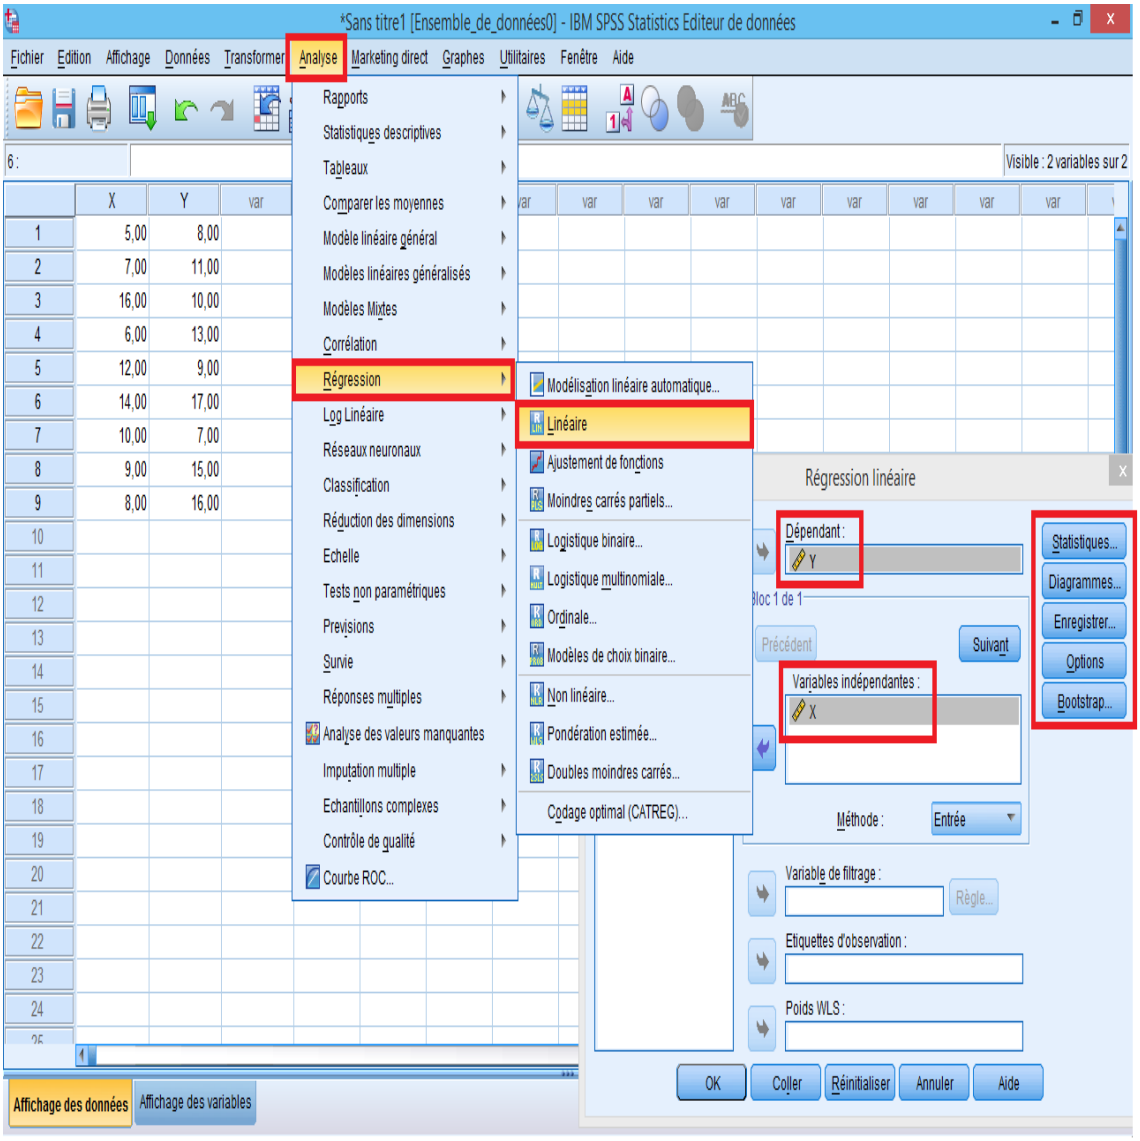
$$\sigma_e^2 = \sigma_y^2 \times (1 - r_{XY}^2).$$

Dans notre exemple on a:

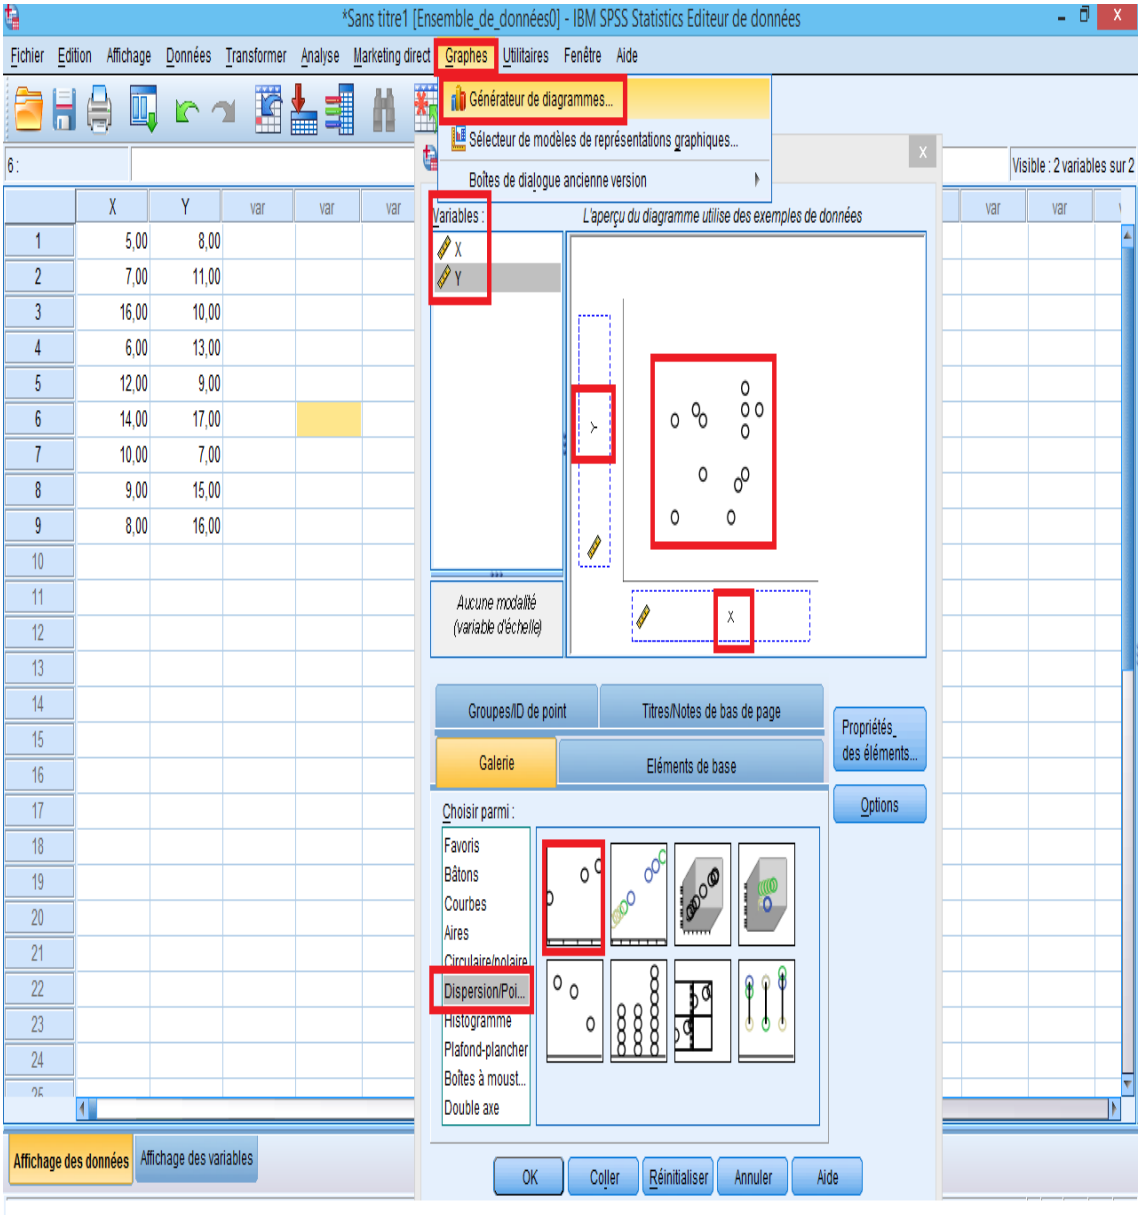
$$\sigma_e^2 = 12.22 \times (1 - 0.087^2) = 12.127.$$

Le coefficient de détermination:
On le noté R^2. C'est le carré du coefficient de corrélation: $R^2 = r_{XY}^2$. Il représente la proportion de variance expliquée par le modèle.
Dans notre modèle, on a $R^2 = 0.087^2 = 0.008$. (0.8% est très faible donc on a un mauvais ajustement).

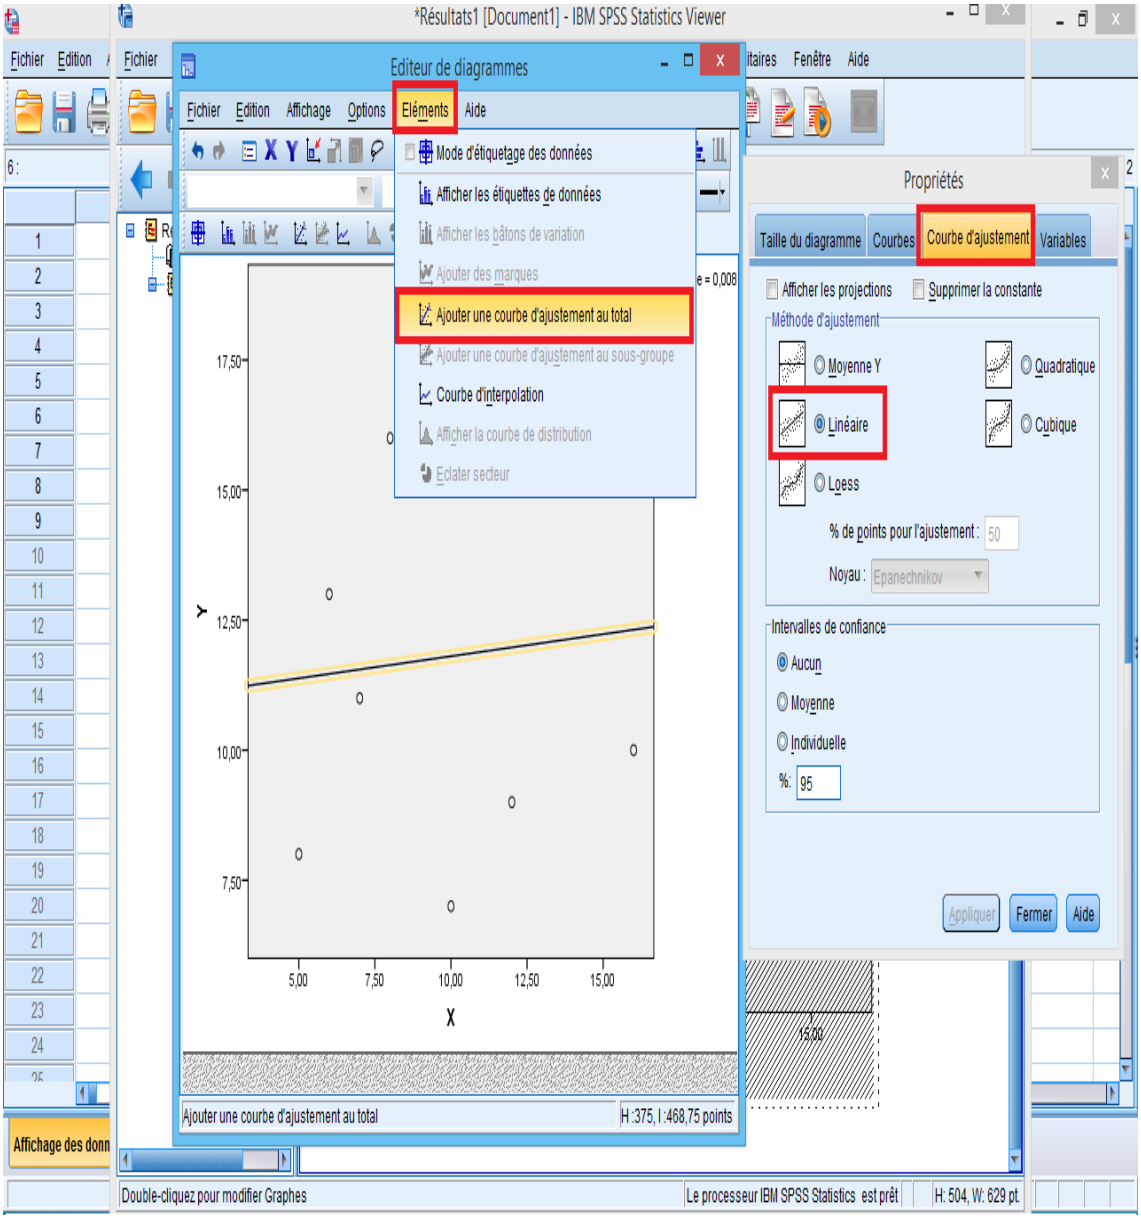
Sous SPSS 25: Analyse > Régression > Linéaire.
Si $Y = a + bX$, alors Y est la variable Dépendant et X est la Variable indépendante.



Sous SPSS 25: pour obtenir le nuage de points: Graphes > Générateur de diagrammes > Dispersion points.



Sous SPSS 25: pour tracer la droite de régression et son équation, cliquez deux fois sur la figure du nuage de points puis suivez le chemin suivant: Éléments > Régression > Ajouter une courbe d'ajustement > Linéaire.



2.4 TP 2 sous SPSS 25

Exercice 1

Considérons un échantillon de $n = 10$ fonctionnaires (ayant entre 40 et 50 ans) d'un ministère. Soit X le nombre d'années de service et Y le nombre de jours d'absence pour raison de maladie (au cours de l'année précédente) déterminé pour chaque personne appartenant à cet échantillon.

x_i	2	14	16	8	13	20	24	7	5	11
y_i	3	13	17	12	10	8	20	7	2	8

1. Déterminer les moyennes de X et Y et la covariance entre X et Y.
2. Déterminer le coefficient de corrélation entre les variables X et Y.
3. Déterminer la droite de régression linéaire de Y en X.
4. Tracer le nuage de points (X, Y).
5. Tracer la droite de régression linéaire de Y en X.
6. Trouver les coefficients de la droite de régression .

Exercice 2

1. Importer le fichier nommé **TP2** depuis **Excel** vers SPSS 25.
2. Déterminer et Tracer la droite de régression linéaire de la Taille en Poids.
3. Tracer les Boîtes à moustaches entre le Sexe et le Poids.
4. Tracer les tableaux de contingences des effectifs et des fréquences entre le Sexe et l'Avis.

Chapitre 3

Notion de probabilités et variables aléatoires

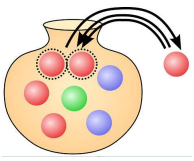
L'objectif ici de proposer un modèle mathématique permettant de décrire une situation aléatoire qui est définie à l'aide du langage des événements. La notion de probabilité permet de quantifier la chance qu'ont les événements d'être réalisés ou non.

3.1 Vocabulaires

- **Expérience aléatoire:** on ne peut pas prédire a priori son résultat.
- **Réalisation:** un résultat possible de l'expérience aléatoire.
- **Espace fondamental Ω:** l'ensemble de tous les résultats possibles.
- **Évènement:** sous ensemble de Ω.

Exemples:

1) On tire simultanément deux boules dans une urne qui contient quatre boules rouges, deux boules bleues et une boule verte:



$$\Omega = \{(R_1, R_2), (R_1, R_3), (R_2, R_3), (R_1, V_1), ...\} \Longrightarrow \text{card } (\Omega) = C_7^2 = 21.$$

2) On lance une pièce de monnaie deux fois:



$$\Omega = \{(P, P), (F, P), (P, F), (F, F)\} \Longrightarrow \text{card } (\Omega) = 4.$$

L'évènement A: (obtenir pile une seule fois) est $A = \{(F, P), (P, F)\}$.

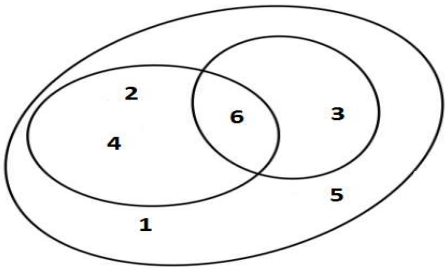
3) On lance un dé une seule fois:



$$\Omega = \{1, ..., 6\} \Longrightarrow \text{card } (\Omega) = 6.$$

L'évènement B: (obtenir un nombre pair) est $A = \{2, 4, 6\}$.

- **L'union:** $A \cup B$ est réalisé dés que A ou B est réalisé.
- **L'intersection:** $A \cap B$ est réalisé dés que A et B sont réalisés conjointement.
  Dans un lancer de dé, si l'évènement A est (obtenir un nombre pair) et l'évènement B est (obtenir un multiple de 3), alors $A = \{2, 4, 6\}$, $B = \{3, 6\}$ et $A \cap B = \{6\}$.



- **Le complémentaire $\bar{A}$:** c'est l'évènement $\Omega \backslash A$.
  Dans l'exemple du lancer de dé, pour $A = \{2, 4, 6\}$, on a $\bar{A} = \{1, 3, 5\}$= (obtenir un nombre impair).

3.2 Notion de probabilités

Définition
Une probabilité P sur un ensemble fini $\Omega = \{\omega_1, ..., \omega_n\}$ est une pondération $p_1, p_2, ..., p_n$ des éléments de cet ensemble telle que:

- Pour tout $k \in [1 : n]$, $p_k \geq 0$.
- $\sum_{k=1}^{n} p_k = 1$.

On attribue à toute éventualité ω_i la probabilité $p_i = P(\{\omega_i\})$ et on attribue à tout évènement $A \subset \Omega$ la probabilité:

$$P(A) = \sum_{k, \omega_k \in A} p_k.$$

Exemple:
Dans un lancer d'un dé équilibré, on a $\Omega = \{1, ..., 6\}$ et $p_k = P(\{k\}) = 1/6$, pour tout $k \in [1 : 6]$. Si l'évènement A est (obtenir un nombre pair strictement supérieur à 3) alors $A = \{4, 6\}$ et $P(A) = P(\{4\}) + P(\{6\}) = 1/6 + 1/6 = 1/3$.

Remarque
Dans le cas où les symétries font que tous les résultats possibles $\omega_1, ..., \omega_n$ sont équiprobables, on a:

$$P(A) = \frac{card(A)}{card(\Omega)}.$$

Dans l'exemple précédent, on a

$$P(A) = \frac{card(A)}{card(\Omega)} = \frac{2}{6} = \frac{1}{3}.$$

Propriétés

1. Soit A et B deux événements, alors

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

2. $0 \leq P(A) \leq 1$.
3. $P(\bar{A}) = 1 - P(A)$.
4. $P(\Omega) = 1$, (événement certain) et $P(\emptyset) = 0$, (événement impossible).

Probabilité conditionnelle et indépendance
• Soient deux événements A et B, si $P(B) > 0$, alors

$$P_B(A) = \frac{P(A \cap B)}{P(B)}.$$

• On dit que deux événements A et B sont indépendants si $P(A \cap B) = P(A).P(A)$ ou encore si $P_B(A) = P(A)$ ou $P_A(B) = P(B)$.

Exemple:
Nous jetons un dé équilibré et nous considérons les deux événements: $A =$ (le résultat est impair) et $B =$ (le résultat est ≤ 4).
$A = \{1, 3, 5\} \Rightarrow P(A) = \frac{1}{2}$
$B = \{1, 2, 3, 4\} \Rightarrow P(B) = \frac{2}{3}$
$A \cap B = \{1, 3\} \Rightarrow P(A \cap B) = \frac{1}{3}$
On a $P(A \cap B) = \frac{1}{3} = P(A).P(B)$ donc A et B sont indépendants.

3.3 Notion de variables aléatoires

La notion de variable aléatoire formalise l'association d'une valeur au résultat d'une expérience aléatoire. Une variable aléatoire X est une application mesurable de l'ensemble fondamental Ω dans $\mathbb{R}$.

3.3.1 Variables aléatoires discrètes

Définition

• Une variable aléatoire discrète prend uniquement des valeurs dans un sous ensemble discret $E = \{x_1, ..., x_n, ...\}$.

• Une distribution de probabilité p_X est une fonction qui associe à chaque valeur x_i la probabilité: $p_i = p_X(x_i) = P(X = x_i)$.

Exemple:

On considère une expérience aléatoire consistant à lancer deux pièces de monnaie. L'ensemble des résultats possibles est: $\Omega = \{(P, P), (F, P), (P, F), (F, F)\}$.

Considérons la variable aléatoire X représentant le nombre de faces obtenues. Les valeurs prises par X sont 0,1,2.

$p_1 = P(X = 0) = 1/4$, $p_2 = P(X = 1) = 1/2$ et $p_3 = P(X = 2) = 1/4$.

x_i	0	1	2
$p_i = P(X = x_i)$	1/4	1/2	1/4

Espérance mathématique:

$$E(X) = 0 \times 1/4 + 1 \times 1/2 + 2 \times 1/4 = 1.$$

Variance:

$$V(X) = E(X - E(X))^2 = (0 - 1)^2 \times 1/4 + (1 - 1)^2 \times 1/2 + (2 - 1)^2 \times 1/4 = 1/2.$$

Écart type:

$$\sigma(X) = \sqrt{V(X)} = \sqrt{1/2} = 0.70.$$

Quelques lois discrètes usuelles:

Nom	Loi	$\mathbb{E}(X)$	$\mathrm{Var}(X)$
Bernoulli $\mathcal{B}(p)$	$\mathbb{P}(X = 1) = p = 1 - \mathbb{P}(X = 0)$	p	$p(1-p)$
binomiale $\mathcal{B}(n, p)$	$\forall 0 \leq k \leq n,\ \mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$
Poisson $\mathcal{P}(\lambda)$	$\forall n \in \mathbb{N},\ \mathbb{P}(X = n) = \exp(-\lambda)\frac{\lambda^n}{n!}$	λ	λ
géométrique $\mathcal{G}eo(p)$	$\forall n \in \mathbb{N}^*,\ \mathbb{P}(X = n) = p(1-p)^{n-1}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$

3.3.2 Variables aléatoires continues

Définition

• Une variable aléatoire X continue prend des valeurs dans un intervalle de $\mathbb{R}$.
• La fonction de répartition de X est définie par: $\Phi(x) = P(X \leq x)$.
• X possède une densité notée $f(x)$ telles que:

$$\Phi(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt \quad \text{ou encore} \quad F'(x) = f(x).$$

Espérance mathématique:

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx.$$

Variance:

$$V(X) = E(X - E(X))^2 = \int_{-\infty}^{+\infty} (x - E(X))^2 f(x)dx.$$

Quelques lois continues usuelles:

Nom	Densité	$\mathbb{E}(X)$	$\mathrm{Var}(X)$
uniforme $\mathcal{U}[a,b]$	$\frac{1}{b-a}\, 1_{[a,b]}(x)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
exponentielle $\mathcal{E}(\lambda)$	$\lambda \exp(-\lambda x) 1_{\{x \geq 0\}}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
normale $\mathcal{N}_1(m, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}}\ \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$	m	σ^2
Cauchy $\mathcal{C}(a)$	$\frac{a}{\pi}\ \frac{1}{x^2+a^2}$	non intég	-

Par exemple:

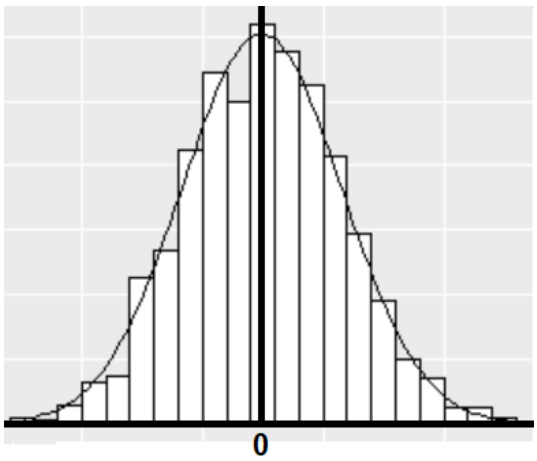
si X suit la loi exponentielle $\mathcal{E}(\lambda)$, alors quand $x > 0$, sa fonction de répartition vaut:

$$\Phi(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt = \int_{0}^{x} \lambda \exp(-\lambda t)dt = \Big[-\exp(-\lambda t) \Big]_0^x = 1 - e^{-\lambda x}.$$

On calcule la moyenne par une intégration par partie:

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_{0}^{+\infty} x\lambda \exp(-\lambda x)dx = \Big[-\frac{1 + x\lambda}{\lambda} \exp(-\lambda x) \Big]_0^{+\infty} = \frac{1}{\lambda}.$$

• **Loi normale $\mathcal{N}(0,1)$ de moyenne 0 et de variance 1:**
Densité et histogramme :



La table statistique ci-dessus nous donne pour chaque $z > 0$ la valeur:

$$\Phi(z) = P(Z \leq z) = P(Z < z).$$

Pour $z < 0$, on a $\Phi(-z) = 1 - \Phi(z)$.
On a aussi $P(Z \geq z) = P(Z > z) = 1 - \Phi(z)$, et $P(a < X < b) = \Phi(b) - \Phi(a)$.
Exemples:
$P(Z \leq 0.25) = \Phi(0.25) = \Phi(0.20{+}0.05) = 0.5987$. Cette dernière valeur est l'intersection de la ligne 0.2 et la colonne 0.05 dans la table statistique.
$P(Z > 0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013$.
$\Phi(-0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013$.
$P(|Z| < 0.25) = P(-0.25 < Z < 0.25) = \Phi(0.25) - \Phi(-0.25)$
$= \Phi(0.25) - (1 - \Phi(0.25)) = 2\Phi(0.25) - 1 = 0.1974.$

• **Loi normale $\mathcal{N}(\mu, \sigma^2)$ de moyenne $\mu > 0$ et de variance σ^2:**
Si X suit la loi normale $\mathcal{N}(\mu, \sigma^2)$ alors Z suit la loi normale $\mathcal{N}(0,1)$ avec

$$Z = \frac{X - \mu}{\sigma}.$$

Exemple:
Si $X \sim \mathcal{N}(72, 64)$ alors la moyenne est $\mu = 72$ et l'écart type $\sigma = 8$. Dans ce cas la variable aléatoire:

$$Z = \frac{X - 72}{8} \sim \mathcal{N}(0,1),$$

par suite

$$P(X > 80) = 1 - P(X \leq 80) = 1 - P\left(\frac{X - 72}{8} \leq \frac{80 - 72}{8}\right)$$
$$= 1 - P(Z \leq 1) = 1 - \Phi(1) = 1 - 0.8413 = 0.1587.$$

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} \exp\Big(-\frac{x^2}{2}\Big) dx.$$

Z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998
3,5	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998

Chapitre 4

Pratique de l'échantillonnage et l'estimation sous SPSS 25

4.1 Échantillonnage

4.1.1 Introduction

Une université reçoit 7000 applications par année provenant d'éventuels étudiants. Le formulaire de demande d'admission inclut le score d'un test d'aptitude (SAT) ainsi que l'information sur le lieu de résidence de l'étudiant. Le directeur des admissions aimerait avoir une idée sur:

- le score moyen SAT des postulants,
- la proportion des postulants qui sont résidents de la province?

Il y a deux façons d'obtenir cette information:

1)- Effectuer un recensement des 7000 postulants:

- Scores SAT: $x_1, ..., x_{7000}$.
- Moyenne de la population:

$$\mu = \frac{1}{7000} \sum_{i=1}^{7000} x_i = 990.$$

- Variance de la population:

$$\sigma^2 = \frac{1}{7000} \sum_{i=1}^{7000} (x_i - \mu)^2 = 6400.$$

- Proportion des résidents de la population:

$$p = \frac{5040}{7000} = 0.72.$$

2)- Prendre un échantillon de taille $n = 50$ postulants est faire des estimations ponctuelles:

No	**Postulant**	**SAT**	**Résidant**
1	Mohammed	1025	Oui
2	Rachid	950	Oui
3	Hassan	1090	Non
.	.....	.....	.....
.	.....	.....	.....
50	Karim	1279	oui
	Total	**49850**	**34 oui**

Dans ce cas on prend:

- $\bar{x}$ comme estimateur de la moyenne μ :

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{50}\sum_{i=1}^{50} x_i = 997 \simeq 990 = \mu.$$

- s^2 comme estimateur de la variance σ^2 :

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{50-1}\sum_{i=1}^{50}(x_i - \bar{x})^2 = 6301 \simeq 6400 = \sigma^2.$$

- $\bar{p}$ comme estimateur de la proportion p :

$$\bar{p} = \frac{n_{oui}}{n} = \frac{34}{50} = 0.68 \simeq 0.72 = p.$$

Les erreurs d'échantillonnage sont:

- $|\bar{x} - \mu|$ pour la moyenne échantillonnale.
- $|s^2 - \sigma^2|$ pour la variance échantillonnale.
- $|\bar{p} - p|$ pour la proportion échantillonnale.

Raisons pour faire un échantillonnage au lieu d'un recensement:

- Lorsque la population est très grande.
- Par souci d'économie.
- Obtenir de l'information rapidement.

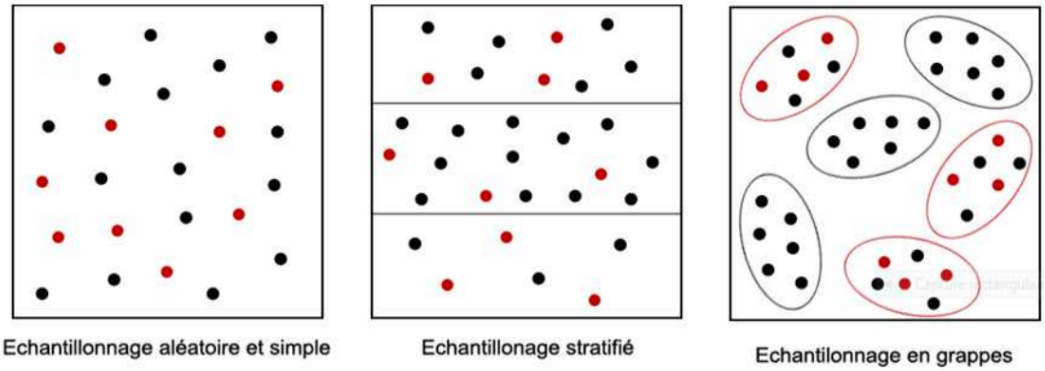
Méthodes d'échantillonnage:

L'échantillonnage aléatoire et simple: le choix se fait parmi tous les individus de la population (au sens statistique), qui ne forme qu'un grand ensemble.

L'échantillonnage stratifié: si la population est très hétérogène, elle peut être divisée en sous-ensembles exclusifs (ou strates). Au sein de ces strates l'échantillonnage est ensuite aléatoire et simple. Les strates sont identifiées dans l'analyse statistique comme les niveaux d'un facteur fixe.

L'échantillonnage en grappes: si les strates sont très nombreuses, on en choisit certaines au hasard (les grappes). Au sein de ces grappes l'échantillonnage est ensuite aléatoire et simple. Les grappes sont identifiées dans l'analyse statistique comme les niveaux d'un facteur aléatoire.

L'échantillonnage par degrés: il est une généralisation de l'échantillonnage en grappes (qui est en fait un échantillonnage du premier degré). Au sein de la population on choisit des grappes " primaires ", puis à l'intérieur de celles-ci des grappes " secondaires " (toujours au hasard), et ainsi du suite. . . Au dernier niveau l'échantillonnage est aléatoire et simple.



4.1.2 Distribution d'échantillonnage de la moyenne

Théorème centrale limite 1:

Lorsque la variance σ^2 de la population est **connue** et que l'échantillon prélevé est grand ($n \geq 30$), alors la moyenne échantillonnale vérifie:

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim \mathcal{N}(\mu, \frac{\sigma^2}{n}), \quad i.e., \quad Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1).$$

Remarques

- Le théorème précédant est vrai aussi lorsque la variance est **connue**, l'échantillon est petit et que la variable aléatoire X suit une loi normale $\mathcal{N}(\mu, \sigma^2)$.
- Lorsque la variance σ^2 de la population est **inconnue** et que l'échantillon prélevé est grand ($n \geq 30$), alors

$$\bar{X} \sim \mathcal{N}(\mu, \frac{s^2}{n}), \quad i.e., \quad \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim \mathcal{N}(0,1).$$

Exemple:
Les statistiques des notes obtenues en mathématiques au BAC STI en France pour l'année 2006 sont: Moyenne nationale =10.44, Écart-type=1.46. Une classe de BTS comporte 35 élèves en 2006/2007 issus d'un BAC STI en 2006. Calculer la probabilité que la moyenne de cette classe soit supérieure à 10.
Corrigé:
On a:

$$n = 35 > 30 \Rightarrow \bar{X} \sim \mathcal{N}(10.44, \frac{1.46^2}{n}) \Rightarrow Z = \frac{\bar{X} - 10.44}{\frac{1.46}{\sqrt{35}}} \sim \mathcal{N}(0, 1).$$

Par conséquent,

$$P(\bar{X} > 10) = 1 - P(\bar{X} \leq 10) = 1 - P\Big(\frac{\bar{X} - 10.44}{\frac{1.46}{\sqrt{35}}} \leq \frac{10 - 10.44}{\frac{1.46}{\sqrt{35}}}\Big)$$

$$= 1 - P(Z \leq -1.78) = 1 - \Phi(-1.78) = \Phi(1.78) = 0.9625.$$

La probabilité que la moyenne de cette classe soit supérieure à 10 est $\simeq 96.25$ %.

Théorème centrale limite 2:
Si la variance de la population est **inconnue**, si la variable X suit une distribution normale $\mathcal{N}(\mu, \sigma^2)$, et si la taille de l'échantillon est petite ($n < 30$), alors

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim t(n-1) : \text{Loi de Student à n-1 degré de liberté ddl.}$$

La table statistique ci-dissous nous donne les valeurs t telles que: $P(T > t) = \alpha$. La colonne nous donne la probabilité α et la ligne nous le ddl $n - 1$.
Exemple:
Pour estimer le montant hebdomadaire moyen dépensé par les familles de 4 personnes pour leur épicerie, on tire un échantillon aléatoire de 25 personnes. On suppose que les montants dépensés sont distribués normalement avec une moyenne 120 et une variance inconnue. Si la variance de l'échantillon de taille 25 est 36, calculer la probabilité que la moyenne de l'échantillon soit supérieure à 123.
Corrigé:
On a: $n = 25 < 30$ et la variance de la population est inconnue, (on connaît la variance de l'échantillon $s^2 = 36$), donc

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{\bar{X} - 120}{\frac{6}{\sqrt{25}}} \sim t(25-1) = t(24).$$

Par suite:
$P(\bar{X} > 123) = P\left(\frac{\bar{X}-120}{\frac{6}{\sqrt{25}}} \geq \frac{123-120}{\frac{6}{\sqrt{25}}}\right) = P(T > 2.5) \simeq P(T > 2.492) = 0.01.$

FIGURE 4.1 – Table de la loi Student T: $P(T > t)$

Degrés de liberté	Aire dans la queue supérieure de la distribution					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250
10	0,879	1,372	1,812	2,228	2,764	3,169
11	0,876	1,363	1,796	2,201	2,718	3,106
12	0,873	1,356	1,782	2,179	2,681	3,055
13	0,870	1,350	1,771	2,160	2,650	3,012
14	0,868	1,345	1,761	2,145	2,624	2,977
15	0,866	1,341	1,753	2,131	2,602	2,947
16	0,865	1,337	1,746	2,120	2,583	2,921
17	0,863	1,333	1,740	2,110	2,567	2,898
18	0,862	1,330	1,734	2,101	2,552	2,878
19	0,861	1,328	1,729	2,093	2,539	2,861
20	0,860	1,325	1,725	2,086	2,528	2,845
21	0,859	1,323	1,721	2,080	2,518	2,831
22	0,858	1,321	1,717	2,074	2,508	2,819
23	0,858	1,319	1,714	2,069	2,500	2,807
24	0,857	1,318	1,711	2,064	2,492	2,797

4.1.3 Distribution d'échantillonnage de la proportion

Si p est la proportion de la population, alors pour un échantillon de taille grande $n > 30$, la proportion échantillonnale vérifie:

$$\bar{p} \sim \mathcal{N}\Big(p, \frac{p(1-p)}{n}\Big) \quad i.e., \quad Z = \frac{\bar{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1).$$

Exemple:
$p = 0.8$ est la proportion de Canadiens satisfaits du libre échange. $n = 100$ personnes interrogées. Quelle est la probabilité que la proportion des personnes interrogées satisfaites du libre échange soit inférieure ou égale à 0.9?

Corrigé:

$$Z = \frac{\bar{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1) \Rightarrow P(\bar{p} \leq 0.9) = P\left(Z \leq \frac{0.9 - 0.8}{\sqrt{\frac{0.8(1-0.8)}{100}}}\right) = P(Z \leq 2.5) = 0.9938.$$

4.1.4 Distribution d'échantillonnage de la variance

Si σ^2 est la variance de la population et S^2 est la variance échantillonnale d'un échantillon de taille n. Alors $Y^2 = \frac{(n-1)S^2}{\sigma^2}$ suit la loi khi-deux à $\nu = n - 1$ ddl de table statistique ci-dessus qui nous les valeurs de x tel que $P(Y^2 > x) = \alpha$.

Exemple:

Pour $\alpha = 0.05$, $n = 10$, on a $\nu = 10 - 1 = 9$ et $x = 16.9190$.

FIGURE 4.2 – Table de la loi Khi-deux: $P(Y^2 > x) = \alpha$

ν \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010	0,001
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349	10,8276
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103	13,8155
3	0,1148	0,2158	0,3518	0,5844	6,2514	7,8147	9,3484	11,3449	16,2662
4	0,2971	0,4844	0,7107	1,0636	7,7794	9,4877	11,1433	13,2767	18,4668
5	0,5543	0,8312	1,1455	1,6103	9,2364	11,0705	12,8325	15,0863	20,5150
6	0,8721	1,2373	1,6354	2,2041	10,6446	12,5916	14,4494	16,8119	22,4577
7	1,2390	1,6899	2,1673	2,8331	12,0170	14,0671	16,0128	18,4753	24,3219
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902	26,1245
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660	27,8772
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093	29,5883
11	3,0535	3,8157	4,5748	5,5778	17,2750	19,6751	21,9200	24,7250	31,2641
12	3,5706	4,4038	5,2260	6,3038	18,5493	21,0261	23,3367	26,2170	32,9095
13	4,1069	5,0088	5,8919	7,0415	19,8119	22,3620	24,7356	27,6883	34,5282
14	4,6604	5,6287	6,5706	7,7895	21,0641	23,6848	26,1189	29,1412	36,1233
15	5,2293	6,2621	7,2609	8,5468	22,3071	24,9958	27,4884	30,5779	37,6973
16	5,8122	6,9077	7,9616	9,3122	23,5418	26,2962	28,8454	31,9999	39,2524
17	6,4078	7,5642	8,6718	10,0852	24,7690	27,5871	30,1910	33,4087	40,7902
18	7,0149	8,2307	9,3905	10,8649	25,9894	28,8693	31,5264	34,8053	42,3124
19	7,6327	8,9065	10,1170	11,6509	27,2036	30,1435	32,8523	36,1909	43,8202
20	8,2604	9,5908	10,8508	12,4426	28,4120	31,4104	34,1696	37,5662	45,3147
21	8,8972	10,2829	11,5913	13,2396	29,6151	32,6706	35,4789	38,9322	46,7970
22	9,5425	10,9823	12,3380	14,0415	30,8133	33,9244	36,7807	40,2894	48,2679
23	10,1957	11,6886	13,0905	14,8480	32,0069	35,1725	38,0756	41,6384	49,7282
24	10,8564	12,4012	13,8484	15,6587	33,1962	36,4150	39,3641	42,9798	51,1786

4.2 Estimation

4.2.1 Estimation ponctuelle

Estimer un paramètre, par exemple: une moyenne, une variance, une proportion, etc..., c'est chercher une valeur approchée en se basant sur les résultats d'un échantillon. Lorsqu'un paramètre est estimé par un seul nombre déduit des résultats de l'échantillon, ce nombre est appelé une estimation ponctuelle du paramètre.

- $\bar{X}$ est un estimateur de la moyenne μ :

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

- S^2 est un estimateur de la variance σ^2 :

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2.$$

- $\bar{p}$ est un estimateur de la proportion p.

4.2.2 Estimation par intervalle de confiance

Les estimations ponctuelles, bien qu'utiles, ne fournissent aucune information concernant la précision des estimations, c'est-à-dire qu'elles ne tiennent pas compte de l'erreur possible dans l'estimation due aux fluctuations d'échantillonnage. La théorie des intervalles de confiance (IC) consiste à construire, autour de l'estimation ponctuelle, un intervalle qui aura une grande probabilité $(1-\alpha)$ de contenir la vraie valeur du paramètre.

1) Estimation par IC de la variance σ^2 de la population

Soit n la taille de l'échantillon et s^2 la variance échantillonnale. Ici: $Y^2 = \frac{(n-1)S^2}{\sigma^2}$ suit la loi de loi khi-deux à $n-1$ ddl. On cherche les deux nombres a et b tels que:

$$P(Y^2 \geq a) = \frac{\alpha}{2}, \quad P(Y^2 \geq b) = 1 - \frac{\alpha}{2}.$$

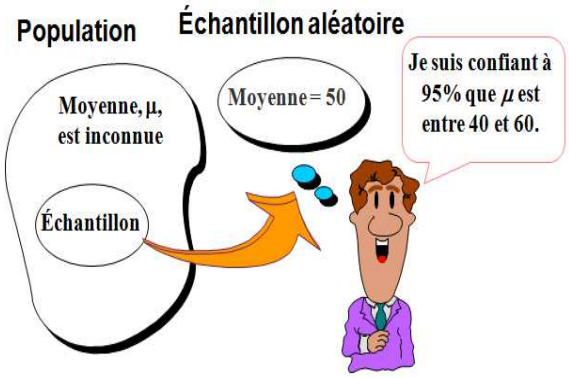
L'intervalle de confiance au seuil $(1-\alpha)$ pour la variance inconnue σ^2 de la population est de la forme:

$$IC_{(1-\alpha)\%} = \Big[\frac{(n-1)s^2}{a}; \frac{(n-1)s^2}{b}\Big].$$

Exemple:

Pour $n = 31$ $s^2 = 100$, on a le ddl $= 31 - 1 = 30$. $\alpha = 0.05$ donc $\frac{\alpha}{2} = 0.025$ donne $a = 46.98$ et $1 - \frac{\alpha}{2} = 0.975$ donne $b = 16.80$. Finalement $IC_{95\%} = [0.3965; 0.4835]$.

2) Estimation par IC de la moyenne μ de la population



• 1er **cas:** Lorsque la taille de l'échantillon est grande ($n \geq 30$) et la variance de la population de X est **connue**, on obtient un intervalle de confiance pour μ au seuil de confiance $(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = [\bar{x} - z_\alpha \frac{\sigma}{\sqrt{n}}; \bar{x} + z_\alpha \frac{\sigma}{\sqrt{n}}] \quad i.e., \quad P\Big(\mu \in IC_{(1-\alpha)\%}\Big) = (1-\alpha).$$

$\Phi(z_\alpha) = 1 - \frac{\alpha}{2}$, où Φ est la fonction de répartition de la loi normale $\mathcal{N}(0,1)$.
Ceci est aussi vrai pour de petits échantillons lorsque la variable aléatoire X suit une loi normale et que la variance de X est connue.
Lorsque la taille de l'échantillon est grande ($n \geq 30$) et la variance de la population de X est **inconnue**, on obtient un intervalle de confiance pour μ au seuil de confiance $(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = [\bar{x} - z_\alpha \frac{s}{\sqrt{n}}; \bar{x} + z_\alpha \frac{s}{\sqrt{n}}].$$

Exemple:
On a observé la taille de $n = 200$ hommes marocains adultes. Après calcul , on a obtenu une moyenne de $\bar{x} = 168$ cm. Si on suppose que la variance connue vaut $\sigma^2 = 1$. Donnez un intervalle de confiance à 95% de la vraie moyenne de la population.

Corrigé:
Puisque $\alpha = 0.05$ (5%), alors $\Phi(z_\alpha) = 1 - \frac{0.05}{2} = 0.975$, par suite $z_\alpha = 1.96$. Finalement $IC_{95\%} = [167.86; 168.14]$, i.e., $P(\mu \in [167.86; 168.14]) = 0.95$.

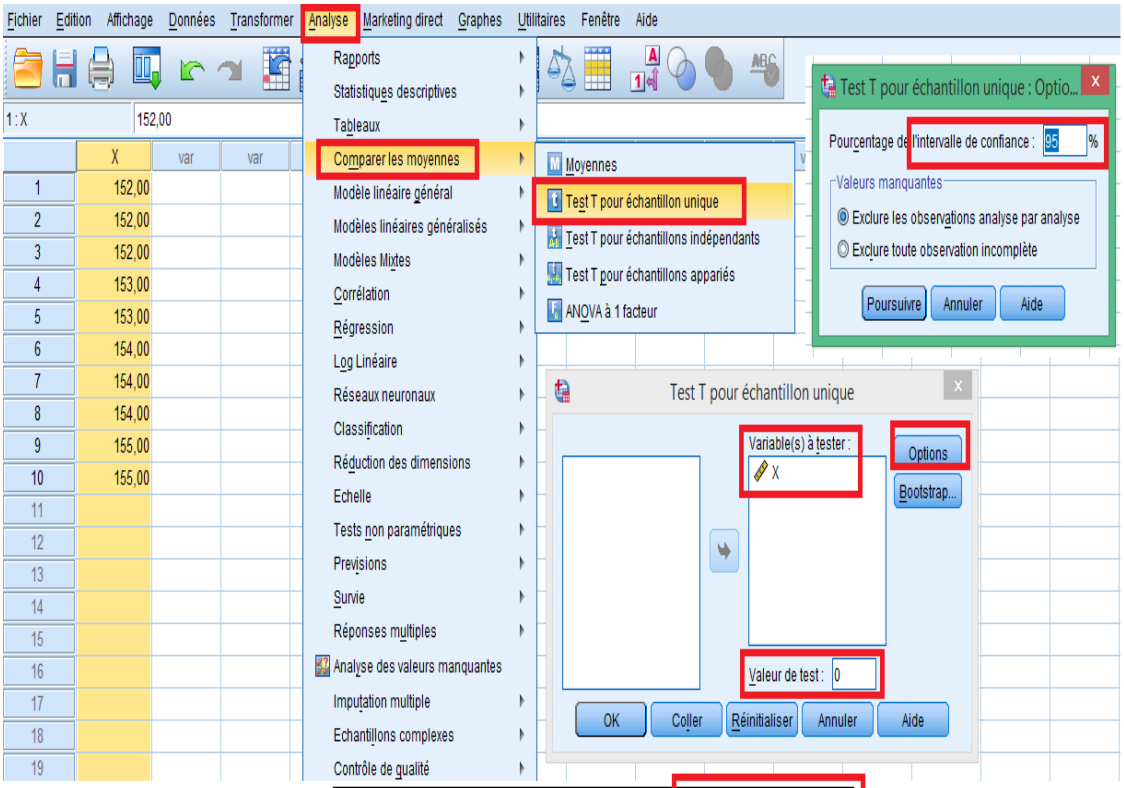
• 2me **cas:** Lorsque la taille de l'échantillon est petite ($n < 30$) et X suit une loi normale de variance **inconnue**, on obtient un intervalle de confiance pour μ au seuil de confiance $(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = [\bar{x} - t_\alpha \frac{s}{\sqrt{n}}; \bar{x} + t_\alpha \frac{s}{\sqrt{n}}]$$

t_α se déduit da la table Student comme suit: $P(T > t_\alpha) = \frac{\alpha}{2}$.

Exemple:
Un reporter pour un journal étudiant est en train de rédiger un article sur le coût du logement près du campus. Un échantillon de 10 appartements dans un rayon de 1 km de l'université a permis d'estimer le coût moyen du loyer mensuel à 350 par mois et un écart type de 30. Quel est l'intervalle de confiance de 95% pour la moyenne des loyers mensuels? Supposons que les loyers suivent une loi normale.
Corrigé:
On a $\alpha = 0,05$, et $\frac{\alpha}{2} = 0,025$. On a $n - 1 = 10 - 1 = 9$ degrés de liberté, alors la table de la distribution Student nous donne $t_\alpha = 2,262$. Finalement $IC_{95\%} = [328.54; 371.46]$. i.e., nous sommes confiants à 95% que la moyenne des loyers mensuels (le vrai paramètre de la population μ), se trouve entre 328.54 et 371.46.

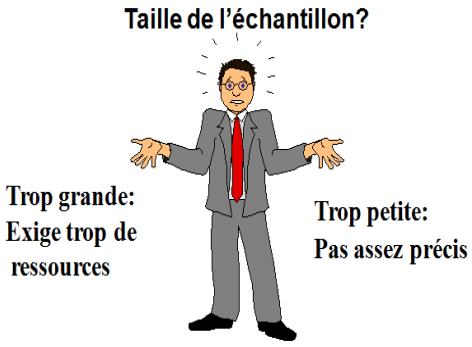
Sous SPSS 25: Si vous avez la colonne des données d'une variable quantitative X, alors suivez le chemin: Analyse > Comparer les moyennes > Test T pour échantillon unique. L'icône Options permet de modifier le seuil de l'intervalle de confiance.



Intervalle de confiance sous SPSS:

	Valeur du test = 0					
	t	ddl	Sig. (bilatérale)	Différence moyenne	Intervalle de confiance 95% de la différence	
					Inférieure	Supérieure
X	526,950	12	,000	153,46154	152,8270	154,0961

Détermination de la taille de l'échantillon:



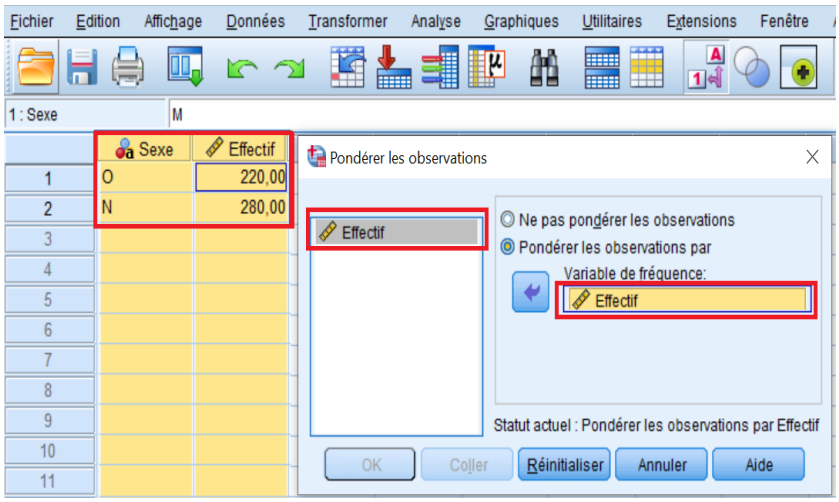
Quelle est la taille n de l'échantillon qui permettrait d'affirmer qu'en utilisant un estimateur ponctuel, l'erreur commise pour un coefficient de confiance $(1-\alpha)$ serait moindre que la marge d'erreur E?
Si par exemple on fixe: $E = z_\alpha \dfrac{\sigma}{\sqrt{n}}$, l'erreur maximale commise pour un coefficient de confiance $(1-\alpha)$, alors la taille de l'échantillon sera: $n = \left[\dfrac{z_\alpha.\sigma}{E}\right]^2$.

Exemple:
Si on fixe une marge d'erreur $E = 500$, alors pour un écart type de $\sigma = 5000$ et pour $z_\alpha = 1.96$, on trouve $n = 384$. i.e., on a besoin d'un échantillon de taille $n = 384$ pour arriver à une précision de ± 500 à un seuil de confiance de 95%.

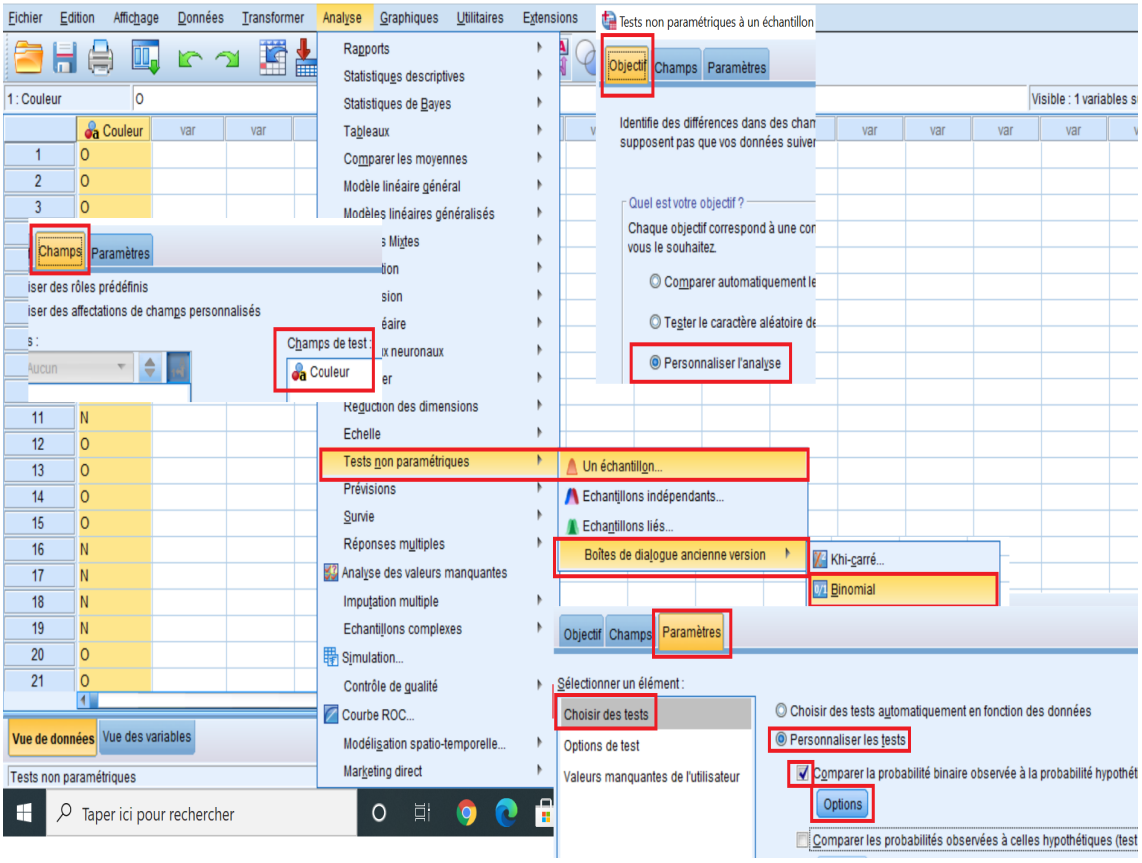
3) Estimation par IC de la proportion p de la population
Soit $\Phi(z_\alpha) = 1 - \frac{\alpha}{2}$. Lorsque n est grand $(n \geq 30)$ et si $\bar{p}$ est la proportion échantillonnale alors un intervalle de confiance pour la proportion p inconnue de la population au seuil de confiance $(1-\alpha)$ de la forme:

$$IC_{(1-\alpha)\%} = \left[\bar{p} - z_\alpha \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}; \bar{p} + z_\alpha \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}\right].$$

Exemple:
SPI est une compagnie qui se spécialise dans les sondages politiques. À l'aide de sondages téléphoniques, les interviewers demandent aux citoyens pour qui ils voteraient si les élections avaient lieu aujourd'hui. Récemment, SPI a trouvé que 220 votants sur 500 voterait pour un candidat particulier. SPI veut estimer l'intervalle de confiance à 95% pour la proportion des votants qui sont en faveur de ce candidat.
Corrigé:
On a $n = 500$, $\bar{p} = 220/500 = 0.44$ et $z_\alpha = 1.96$ donc $IC_{95\%} = [0.3965; 0.4835]$, i.e., SPI est confiant à 95% que la proportion des votants qui favoriseront ce candidat est entre 0.3965 et 0.4835.
Sous SPSS 25: au début, vous devez construire une variable qualitative à 500 observations: voter par (Oui) avec un effectif 220, ou par (Non) avec un effectif 280. Ceci en définissant une variable qualitative (Sexe (O,N)) et une variable quantitative (Effectif (220,280)), puis en suivant le chemin: Données > Pondérer les observations.



Ensuite, suivez le chemin suivant: Analyse > Tests non paramétriques > Un échantillon.
L'icône Objectif permet de choisir: Personnaliser l'analyse.
L'icône Champs permet de spécifier la variable à étudier.
L'icône Paramètres permet de choisir le type de test: Binomial, Khi-carré et Wilcoxon.



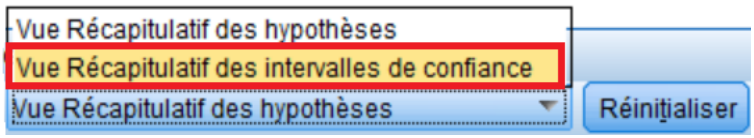
Pour obtenir l'intervalle de confiance, cliquez sur le tableau suivant:

Récapitulatif du test d'hypothèse

	Hypothèse nulle	Test	Sig.	Décision
1	Les catégories définies par Y = O et N surviennent avec les probabilités 0,5 et 0,5.	Test binomial d'un seul échantillon	,008	Rejeter l'hypothèse nulle.

Les significations asymptotiques sont affichées. Le niveau de signification est 5%

puis, sélectionner la case d'intervalle de confiance:



Chapitre 5

Tests d'hypothèses

5.1 Introduction

La majorité des tests élémentaires repose sur le principe suivant:

1. On définit une hypothèse nulle notée H_0 contre l'hypothèse alternative H_1. Le test a pour objectif d'accepter ou de rejeter H_0 avec un risque connu à partir des données dont on dispose.
2. On détermine alors une statistique qui est une variable aléatoire construite à partir des données.
   - Sous H_0, cette variable suit une loi de probabilité connue (Normale, Student, Khi-deux,...)
   - On détermine alors l'intervalle dont lequel doit tomber la statistique avec une probabilité donnée $(1-\alpha)$, (le plus souvent 95% pour $\alpha = 5\%$).
3. On définit alors la règle de décision suivante:
   - Si la statistique tombe dans l'intervalle, on accepte H_0.
     Attention, cela ne veut pas dire que H_0 est vraie mais que le test et les données ne permettent pas de voir un écart significatif à H_0.
   - Si la statistique ne tombe pas dans l'intervalle, on rejette H_0 avec le risque α de se tromper, (par exemple $\alpha = 5\%$).

N.B: sous SPSS 25, si la signification bilatérale Sig $< \alpha$, alors on rejette H_0.

	Valeur du test = 0					
	t	ddl	Sig. (bilatérale)	Différence moyenne	Intervalle de confiance 95% de la différence	
					Inférieure	Supérieure
X	526,950	12	,000	153,46154	152,8270	154,0961

5.2 Tests de conformité

5.2.1 Test de conformité de la variance à une référence

$$\text{Test bilatéral} : \begin{cases} H_0 : \sigma^2 = \sigma_0^2, \\ H_1 : \sigma^2 \neq \sigma_0^2. \end{cases}$$

Ici on travaille avec la loi Khi-deux à $n-1$ ddl. On cherche les deux nombres a et b tels que: $P(Y^2 \geq a) = \frac{\alpha}{2}$ et $P(Y^2 \geq b) = 1 - \frac{\alpha}{2}$. On calcule: $y^2 = \dfrac{n-1}{\sigma_0^2} s^2$.

1. Si $y^2 \in]a; b[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:

$$\text{Test bilatéral} : \begin{cases} H_0 : \sigma^2 = \sigma_0^2 = 90, \\ H_0 : \sigma^2 \neq \sigma_0^2 = 90. \end{cases}$$

Pour $n = 31$, $s^2 = 100$, on a le ddl $= 31 - 1 = 30$. $\alpha = 0.05$ donc $\frac{\alpha}{2} = 0.025$ donne $a = 46.98$ et $1 - \frac{\alpha}{2} = 0.975$ donne $b = 16.80$. On a: $y^2 = \dfrac{n-1}{\sigma_0^2} s^2 = \dfrac{30}{90} \times 100 = 33.34$.
Comme $y^2 \in]a; b[$, on ne peut rejeter H_0.

5.2.2 Test de conformité de la moyenne à une référence

• **Cas d'un petit échantillon $n < 30$ où σ est inconnue**

$$\text{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0, \\ H_1 : \mu \neq \mu_0. \end{cases}$$

On calcule: $t = \dfrac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$. On détermine t_α pour la loi Student à $n-1$ ddl, $(P(T > t_\alpha) = \frac{\alpha}{2})$, et on décide que:

1. Si $t \in]-t_\alpha; t_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple 1:
$n = 25$, $X \sim \mathcal{N}(\mu, \sigma^2)$, $\bar{x} = 15$ et $s = 9$.
Peut on affirmer que la moyenne inconnue de la population est 12.

$$\text{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0 = 12, \\ H_1 : \mu \neq \mu_0 = 12. \end{cases}$$

On calcule: $t = \dfrac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} = \dfrac{15 - 12}{\frac{9}{\sqrt{25}}} = 1.67$. Le ddl est 24, donc pour $\alpha = 5\% = 0.05$, on trouve $t_\alpha = 2.07$. Comme $t \in]-t_\alpha; t_\alpha[$, on ne peut rejeter H_0.

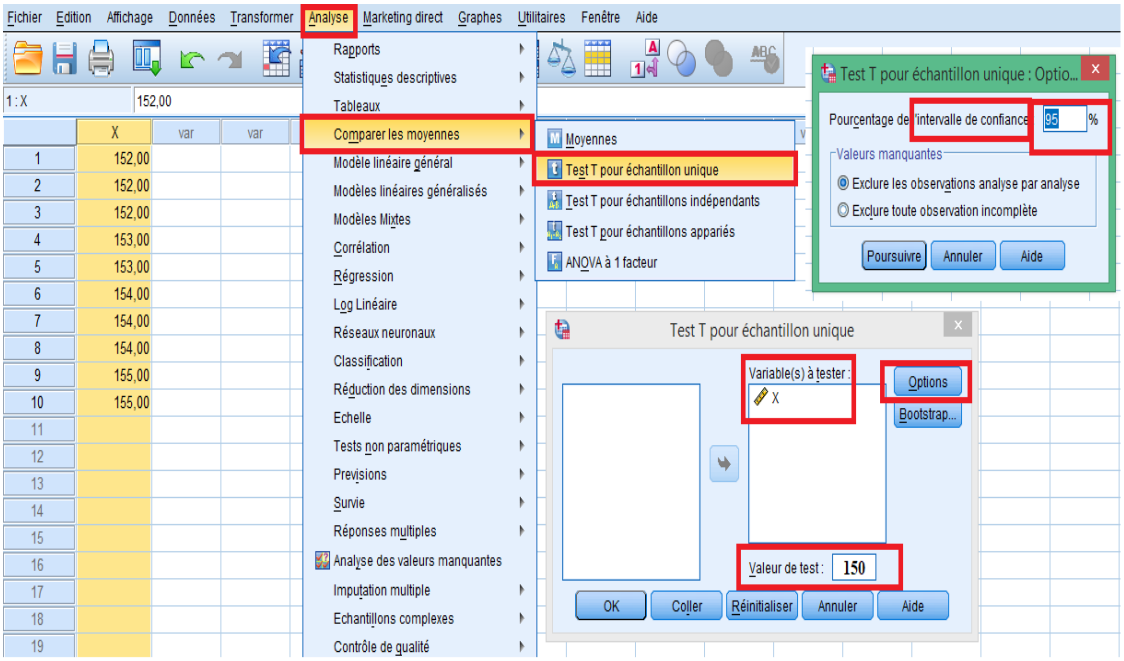
• **Cas d'un grand échantillon $n \geq 30$ où σ est inconnue**

$$\text{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0, \\ H_1 : \mu \neq \mu_0. \end{cases}$$

On calcule: $u = \dfrac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$. On détermine z_α pour la loi normale $\mathcal{N}(0,1)$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Sous SPSS 25: Analyse > Comparer les moyennes > Test T pour échantillon unique. L'icône (Options) permet changer le seuil de l'intervalle de confiance.



Intervalle de confiance sous SPSS:

	Valeur du test = 0					
	t	ddl	Sig. (bilatérale)	Différence moyenne	Intervalle de confiance 95% de la différence	
					Inférieure	Supérieure
X	526,950	12	,000	153,46154	152,8270	154,0961

5.2.3 Test de conformité de la proportion à une référence

$$\text{Test bilatéral} : \begin{cases} H_0 : p = p_0, \\ H_1 : p \neq p_0. \end{cases}$$

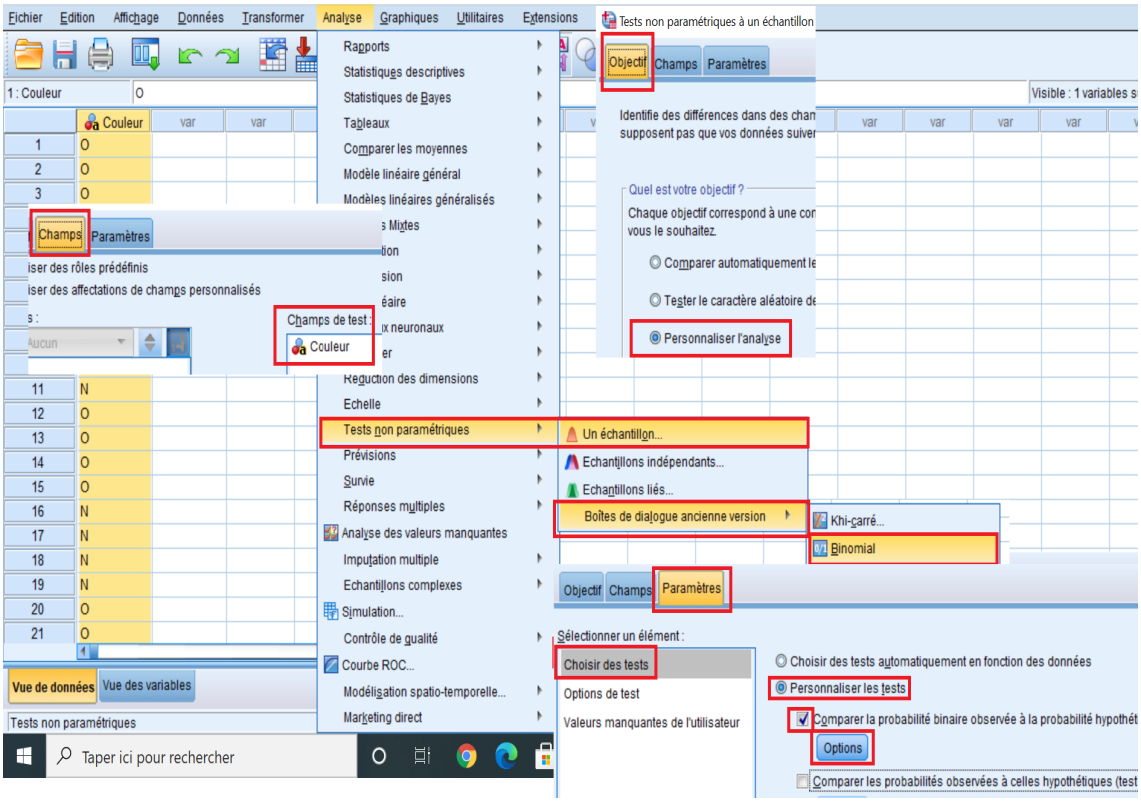
On calcule: $u = \dfrac{\bar{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$. On détermine z_α pour la normale $\mathcal{N}(0,1)$, $(\Phi(z_\alpha) = 1 - \frac{\alpha}{2})$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:
Sur un échantillon de taille $n = 400$ de naissances, on a observé 206 mâles, soit une proportion de mâles de $\bar{p} = 206/400 = 0.515$. On se demande si il y a autant de mâles que de femelles. i.e., si $p_0 = 0.5$. On peut effectuer alors le test:

$$\begin{cases} H_0 : p = p_0 = 0.5, \\ H_1 : p \neq p_0 = 0.5. \end{cases}$$

On calcule alors $u = \dfrac{\bar{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \dfrac{0.515 - 0.5}{\sqrt{\frac{0.5(1-0.5)}{400}}} = 0.6$. Pour $\alpha = 5\%$, on a $z_\alpha = 1.96$.
Comme $u \in]-z_\alpha; z_\alpha[$, alors on ne peut rejeter H_0, i.e., il est possible que $p = 0.5$.
Sous SPSS 25: Analyse > Tests non paramétriques > Un échantillon,
ou bien Analyse > Tests non paramétriques > Boites de dialogue ancien version.
L'icône Objectif permet de choisir: Personnaliser l'analyse.
L'icône Champs permet de spécifier la variable à étudier.
L'icône Paramètres permet de choisir le type de test: Binomial, Khi-carré et Wilcoxon, et aussi changer les pourcentages de références à testez: par exemples: 40% pour mâles.
Ce chemin permet aussi d'obtenir les intervalles de confiance.



Si on clique sur le tableau suivant:

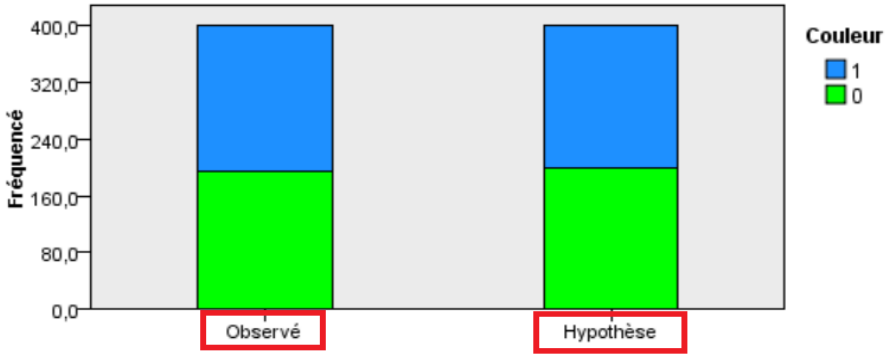
Récapitulatif du test d'hypothèse

	Hypothèse nulle	Test	Sig.	Décision
1	Les catégories définies par Y = O et N surviennent avec les probabilités 0,5 et 0,5.	Test binomial d'un seul échantillon	,008	Rejeter l'hypothèse nulle.

Les significations asymptotiques sont affichées. Le niveau de signification est 5%

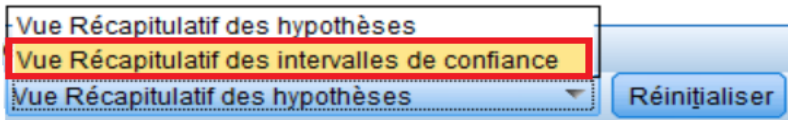
on obtient le récapitulatif suivant:

Test binomial d'un seul échantillon



N total	400
Statistique de test	206,000
Erreur standard	10,000
Statistique de test normalisé	,550
Sig. asymptotique (test des deux côtés)	,582

On peut aussi obtenir un intervalle de confiance:



5.3 Test d'indépendance du khi-deux entre deux variables qualitatives

Le test du khi-deux est largement utilisé pour l'étude de l'indépendance entre deux caractères qualitatifs. La présentation des résultats se fait sous forme d'un tableau de contingence à deux entrées. Chaque entrée représente les modalités d'une des variables. On détermine alors le tableau attendu sous l'hypothèse d'indépendance.

Exemple:
Un échantillon de $n = 1000$ personnes ont été interrogées sur une question précise. On a demandé à ces personnes de préciser leur sexe. Nous voudrions savoir si la réponse Y à la question est indépendante du sexe X.

X/Y	Favorable	Défavorable	Indécis	Total
Masculin	$n_{11} = 210$	$n_{12} = 194$	$n_{13} = 91$	$n_{1\bullet} = 495$
Féminin	$n_{21} = 292$	$n_{22} = 151$	$n_{23} = 62$	$n_{2\bullet} = 505$
Total	$n_{\bullet 1} = 502$	$n_{\bullet 2} = 345$	$n_{\bullet 3} = 153$	$n = 1000$

Sous hypothèse d'indépendance, la distribution conjointe est simplement le produit des distributions marginales, i.e., $f_{ij} = f_{i\bullet} f_{\bullet j}$. Si l'on estime f_{ij} par $\frac{n_{ij}}{n}$ et $f_{i\bullet}$ par $\frac{n_{i\bullet}}{n}$ et $f_{\bullet j}$ par $\frac{n_{\bullet j}}{n}$, on devrait donc avoir $n_{ij} \approx \frac{n_{i\bullet} n_{\bullet j}}{n}$.
L'idée est de calculer l'écart entre les deux termes, le n_{ij} observé et le n_{ij} prédit ou théorique, si cet écart devient trop important, on devra rejeter l'hypothèse que les variables sont indépendantes. On calcule:

$$Q = \sum_{i=1}^{k} \sum_{j=1}^{l} \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}}$$

La statistique Q est distribuée suivant une khi-deux à $(k-1)(l-1)$ ddl où k et l désignent le nombre de valeurs des deux variables.

NB: Test de validité du test: il faut que la fréquence théorique $\frac{n_{i\bullet} n_{\bullet j}}{n} \geq 5$ pour tous i et j. Nous acceptons H_0 si $Q \leq q_\alpha$ avec $P(Y^2 > q_\alpha) = \alpha$.

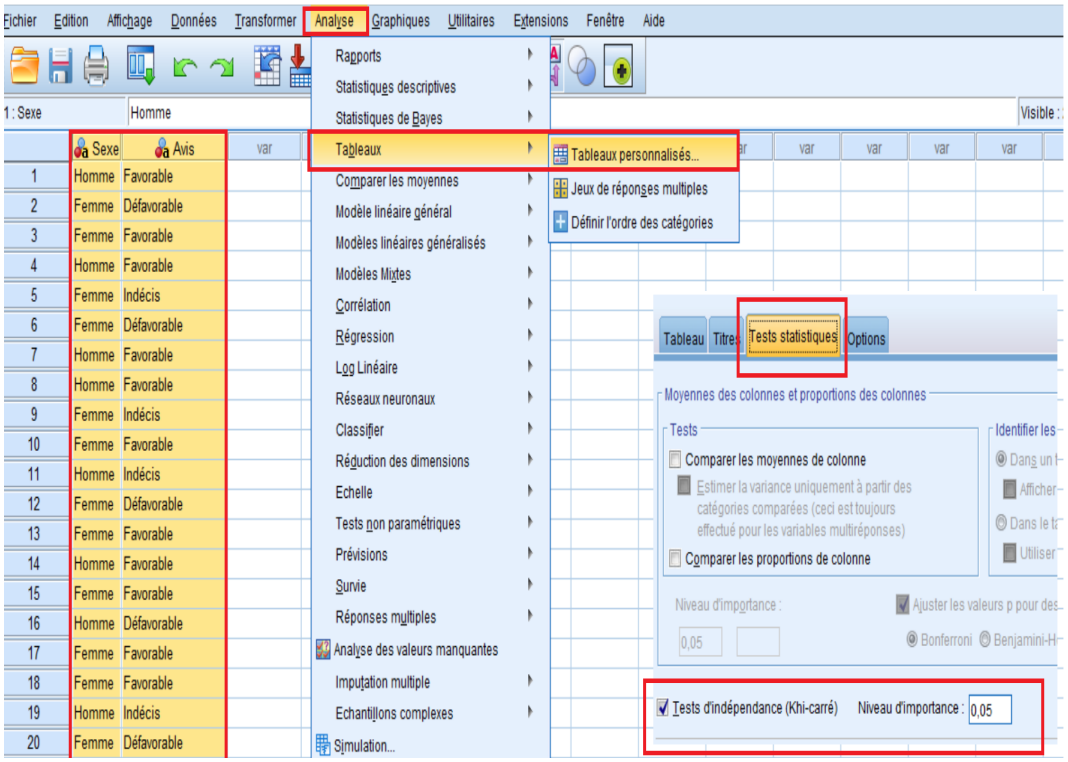
Dans notre exemple, pour $\alpha = 0.05$, on a le ddl est $(3-1) \times (2-1) = 2$, $q_\alpha = 5.99$ et la valeur de Q est:

$$Q = \frac{\left(\frac{495\times502}{1000} - 210\right)^2}{\frac{495\times502}{1000}} + \frac{\left(\frac{495\times345}{1000} - 194\right)^2}{\frac{495\times345}{1000}} + \frac{\left(\frac{495\times153}{1000} - 91\right)^2}{\frac{495\times153}{1000}} +$$

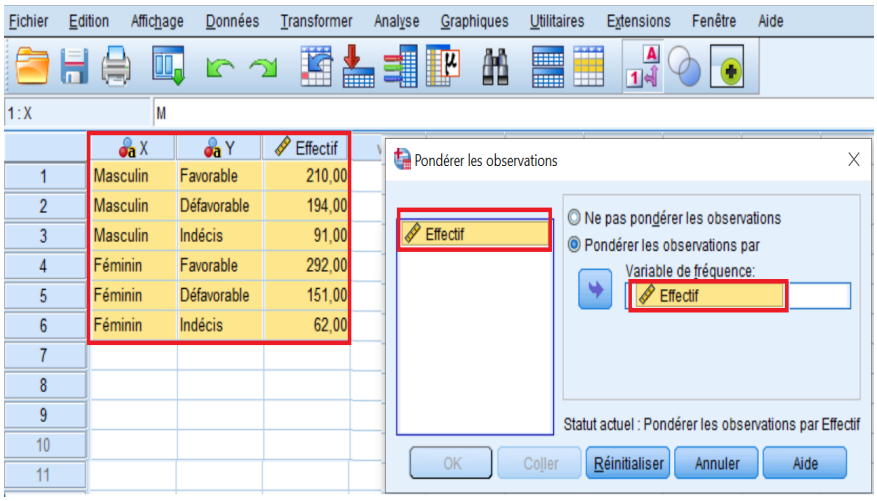
$$\frac{\left(\frac{505\times502}{1000} - 292\right)^2}{\frac{505\times502}{1000}} + \frac{\left(\frac{505\times345}{1000} - 151\right)^2}{\frac{505\times345}{1000}} + \frac{\left(\frac{505\times153}{1000} - 62\right)^2}{\frac{505\times153}{1000}} = 24.15.$$

Finalement on rejette H_0 avec un risque $\alpha = 0.05$ de se tromper.

1er cas: si vous avez les colonnes des données, alors suivez le chemin: Analyse > Tableaux > Tabular (SPSS 20) ou Tableaux personnalisés (SPSS 25) > Tests statistiques > Test d'indépendance de de Khi-deux.
L'icône Tests statistiques permet de choir le test Khi-deux et son niveau de confiance.



2me cas: Si vous avez seulement la table de contingence, alors vous devez obtenir les colonnes des données en suivant le chemin suivant: Données > Pondérer les observations.



Ensuite, suivez le chemin: Analyse > Statistiques descriptives > Tableaux croisés > Statistiques.

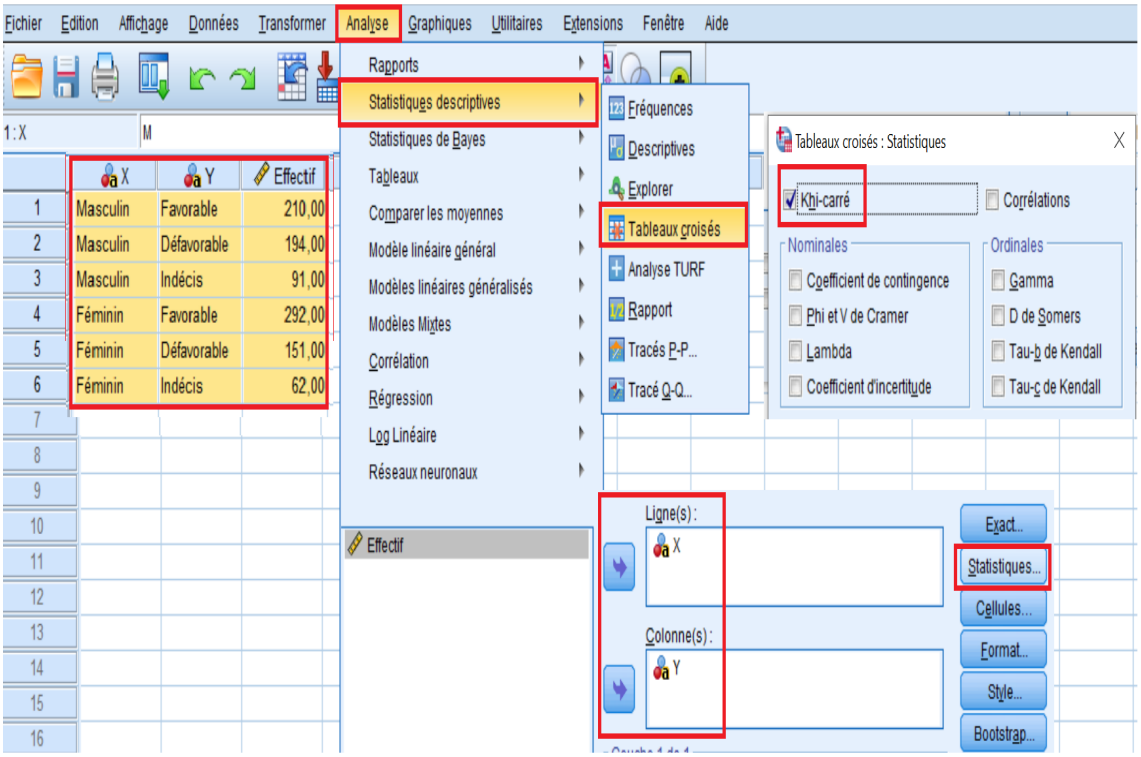


Tableau croisé X * Y

Effectif

		Y			
		Défavorable	Favorable	Indécis	Total
X	Féminin	151	292	62	505
	Masculin	194	210	91	495
Total		345	502	153	1000

Tests du khi-carré

	Valeur	ddl	Signification asymptotique (bilatérale)
khi-carré de Pearson	24,153[a]	2	,000
Rapport de vraisemblance	24,258	2	,000
N d'observations valides	1000		

5.4 Tests d'homogénéité dans le cas des échantillons indépendants

Dans deux populations P_1 et P_2, on étudie un même caractère. On cherche à comparer les deux populations quant à ce caractère pour savoir si elles sont homogènes ou pas.

5.4.1 Test de comparaison de deux proportions

Soit p_1 (resp. p_2) la proportion d'individus ayant la propriété dans P_1 (resp. dans P_2). On extrait deux échantillons indépendants E_1 et E_2 de tailles resp. n_1 et n_2.

$$\text{Test bilatéral : } \begin{cases} H_0 : p_1 = p_2 = p, \\ H_1 : p_1 \neq p_2. \end{cases}$$

Dans l'échantillon E_1 de taille n_1 on estime la proportion p_1 par $\overline{p_1}$ et dans l'échantillon E_2 de taille n_2 on estime la proportion p_2 par $\overline{p_2}$ et en regroupant les deux échantillons, on peut estimer p par:

$$\bar{p} = \frac{n_1\overline{p_1} + n_2\overline{p_2}}{n_1 + n_2}.$$

Conditions de validité du test: $n_1\overline{p_1} \geq 5$, $n_1(1-\overline{p_1}) \geq 5$, $n_2\overline{p_2} \geq 5$ **et** $n_2(1-\overline{p_2}) \geq 5$.

On calcule:

$$u = \frac{\overline{p_1} - \overline{p_2}}{\sqrt{(\frac{1}{n_1} + \frac{1}{n_2})\bar{p}(1-\bar{p})}}.$$

On détermine z_α pour la loi normale $\mathcal{N}(0,1)$, $(\Phi(z_\alpha) = 1 - \frac{\alpha}{2})$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:
Dans une même catégorie sociale, un échantillon de 40 hommes a fourni 8 fumeurs et un échantillon de 60 femmes a fourni 18 fumeuses. On se demande si la proportion de fumeurs est la même pour les deux sexes.

$$\text{Test bilatéral : } \begin{cases} H_0 : p_1 = p_2, \\ H_1 : p_1 \neq p_2. \end{cases}$$

$n_1 = 40$, $\overline{p_1} = \frac{8}{40} = 0.2$, $n_2 = 60$ et $\overline{p_2} = \frac{18}{60} = 0.3$.
$n_1\overline{p_1} = 8 \geq 5$, $n_1(1-\overline{p_1}) = 32 \geq 5$, $n_2\overline{p_2} = 18 \geq 5$ et $n_2(1-\overline{p_2}) = 42 \geq 5$.
$\bar{p} = 0.26$, $u = -1.12$ et pour $\alpha = 5\% = 0.05$, $z_\alpha = 1.96$.
Comme $u \in]-z_\alpha; z_\alpha[$, alors on ne peut rejeter H_0: la proportion de fumeurs ne diffère pas significativement entre les deux sexes.

X/Y	Fumeur	Non-Fumeur	Total
Homme	8	32	40
Femme	18	42	60

Sous SPSS 25: au début, vous construisez les colonnes des variables depuis la table de contingence via le chemin: Données > Pondérer les observations. Ensuite, suivez le chemin: Analyse > Statistiques descriptives > Tableaux croisés > Statistiques.

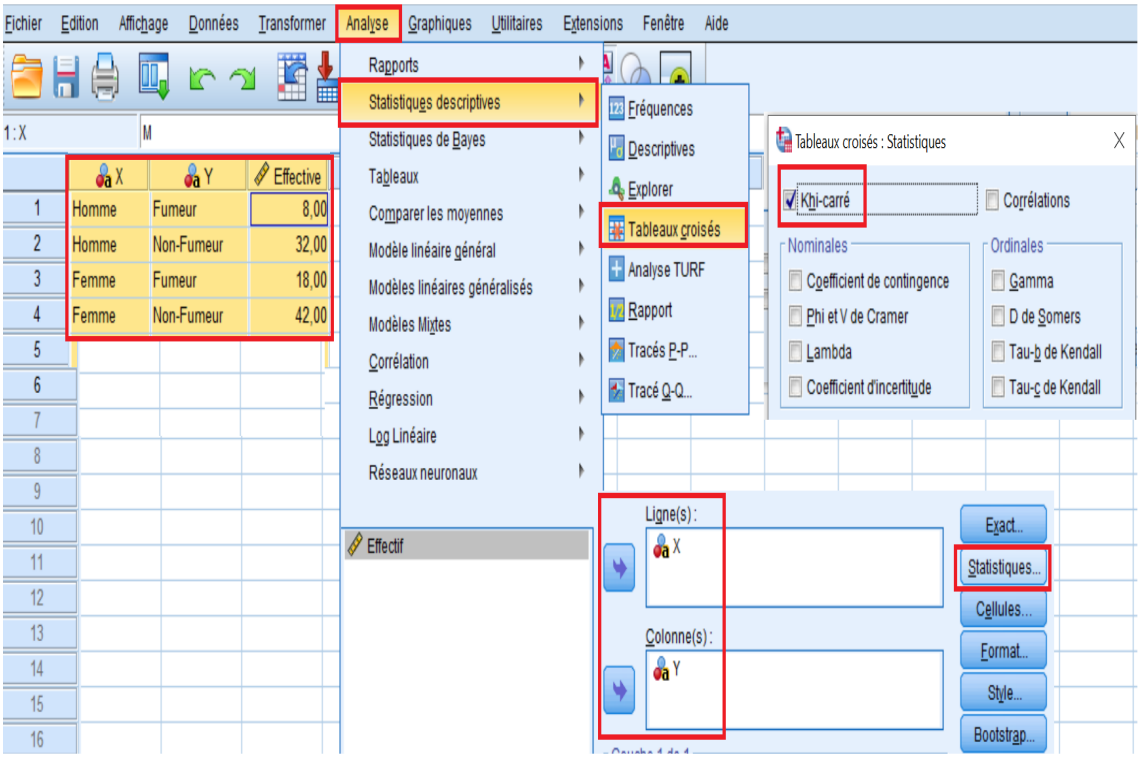


Tableau croisé Y * X

Effectif		X		
		Femme	Homme	Total
Y	Fumeur	18	8	26
	Non-Fumeur	42	32	74
Total		60	40	100

Tests du khi-carré

	Valeur	ddl	Signification asymptotique (bilatérale)	Sig. exacte (bilatérale)	Sig. exacte (unilatérale)
khi-carré de Pearson	1,247[a]	1	,264	,353	,189
Correction pour continuité[b]	,782	1	,377		
Rapport de vraisemblance	1,275	1	,259	,353	,189
Test exact de Fisher				,353	,189
N d'observations valides	100				

5.4.2 Test de comparaison de deux variances

$$\text{Test bilatéral} : \begin{cases} H_0 : \sigma_1^2 = \sigma_2^2, \\ H_1 : \sigma_1^2 \neq \sigma_2^2. \end{cases}$$

Dans l'échantillon E_1 de taille n_1 (resp. l'échantillon E_2 de taille n_2), on estime la variance σ_1^2 (resp. σ_2^2) par:

$$s_1^2 = \frac{1}{n_1 - 1}\sum_{i=1}^{n_1}(x_i - \overline{x_1})^2 \qquad \text{resp.} \qquad s_2^2 = \frac{1}{n_2 - 1}\sum_{i=1}^{n_2}(x_i - \overline{x_2})^2.$$

On calcule $f = \frac{s_1^2}{s_2^2}$ telle que $f \geq 1$ sinon on permute les échantillons de sorte que $f \geq 1$. Dans la table de la loi F de Fisher Snédécor et avec le ddl $(n_1 - 1, n_2 - 1)$, on cherche f_α tel que $P(F \geq f_\alpha) = \frac{\alpha}{2}$, et on décide que:

1. Si $f < f_\alpha$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:

Dans un article de la revue "Biometrica", le biologiste Latter donne la longueur (en mm) des oeufs de Coucou trouvés dans les nids de deux espèces d'oiseaux :

- dans des nids de petite taille (Roitelet) :

19,8	22,1	21,5	20,9	22,0	21,0	22,3	21,0
20,3	20,9	22,0	22,0	20,8	21,2	21,0	

- dans des nids de taille plus grande (Fauvette) :

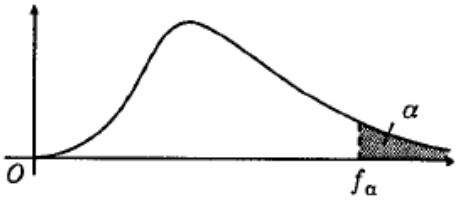
22,0	23,9	20,9	23,8	25,0	24,0	23,8
21,7	22,8	23,1	23,5	23,0	23,0	23,1

On se demande si le Coucou adapte la taille de ses oeufs à la taille du nid.

Observation sur l'échantillon E_1 de taille $n_1 = 15$: $\overline{x_1} = 21.25$ et $s_1^2 = 0.516$.
Observation sur l'échantillon E_2 de taille $n_2 = 14$: $\overline{x_2} = 23.11$ et $s_2^2 = 1.101$.
Comme $f = \frac{s_1^2}{s_2^2} = 0.46 < 1$, on permute les deux échantillons et on prend $f' = \frac{s_2^2}{s_1^2} = 2.14 > 1$.
Le ddl de la loi F de Fisher Snédécor est $(n_2 - 1, n_1 - 1) = (13, 14)$ et pour $\alpha = 5\%$ on trouve que la valeur de f_α telle que $P(F \geq f_\alpha) = \frac{\alpha}{2}$ est compris entre 2.95 et 3.15.
Comme $f' < f_\alpha$, on ne peut rejeter H_0 et les variances des deux populations ne sont pas différentes significativement au risque 5%.

Lois de Fisher ($\alpha = 0{,}025$)

Si F est une variable aléatoire qui suit la loi de Snédécor à (ν_1, ν_2) degrés de liberté, la table donne le nombre f_α tel que $P(F \geqslant f_\alpha) = \alpha = 0{,}025$.



ν_2 \ ν_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	648	800	864	900	922	937	957	969	985	993	1 001	1 018
2	38,5	39,0	39,2	39,2	39,3	39,3	39,4	39,4	39,4	39,4	39,5	39,5
3	17,4	16,0	15,4	15,1	14,9	14,7	14,5	14,4	14,3	14,2	14,1	13,9
4	12,2	10,6	9,98	9,60	9,36	9,20	8,98	8,84	8,66	8,56	8,46	8,26
5	10,0	8,43	7,76	7,39	7,15	6,98	6,76	6,62	6,43	6,33	6,23	6,02
6	8,81	7,26	6,60	6,23	5,99	5,82	5,60	5,46	5,27	5,17	5,07	4,85
7	8,07	6,54	5,89	5,52	5,29	5,12	4,90	4,76	4,57	4,47	4,36	4,14
8	7,57	6,06	5,42	5,05	4,82	4,65	4,43	4,30	4,10	4,00	3,89	3,67
9	7,21	5,71	5,08	4,72	4,48	4,32	4,10	3,96	3,77	3,67	3,56	3,33
10	6,94	5,46	4,83	4,47	4,24	4,07	3,85	3,72	3,52	3,42	3,31	3,08
11	6,72	5,26	4,63	4,28	4,04	3,88	3,66	3,53	3,33	3,23	3,12	2,88
12	6,55	5,10	4,47	4,12	3,89	3,73	3,51	3,37	3,18	3,07	2,96	2,72
13	6,41	4,97	4,35	4,00	3,77	3,60	3,39	3,25	3,05	2,95	2,84	2,60
14	6,30	4,86	4,24	3,89	3,66	3,50	3,29	3,15	2,95	2,84	2,73	2,49
15	6,20	4,76	4,15	3,80	3,58	3,41	3,20	3,06	2,86	2,76	2,64	2,40
16	6,12	4,69	4,08	3,73	3,50	3,34	3,12	2,99	2,79	2,68	2,57	2,32
17	6,04	4,62	4,01	3,66	3,44	3,28	3,06	2,92	2,72	2,62	2,50	2,25
18	5,98	4,56	3,95	3,61	3,38	3,22	3,01	2,87	2,67	2,56	2,44	2,19
19	5,92	4,51	3,90	3,56	3,33	3,17	2,96	2,82	2,62	2,51	2,39	2,13
20	5,87	4,46	3,86	3,51	3,29	3,13	2,91	2,77	2,57	2,46	2,35	2,09
22	5,79	4,38	3,78	3,44	3,22	3,05	2,84	2,70	2,50	2,39	2,27	2,00
24	5,72	4,32	3,72	3,38	3,15	2,99	2,78	2,64	2,44	2,33	2,21	1,94
26	5,66	4,27	3,67	3,33	3,10	2,94	2,73	2,59	2,39	2,28	2,16	1,88
28	5,61	4,22	3,63	3,29	3,06	2,90	2,69	2,55	2,34	2,23	2,11	1,83
30	5,57	4,18	3,59	3,25	3,03	2,87	2,65	2,51	2,31	2,20	2,07	1,79
40	5,42	4,05	3,46	3,13	2,90	2,74	2,53	2,39	2,18	2,07	1,94	1,64
50	5,34	3,98	3,39	3,06	2,83	2,67	2,46	2,32	2,11	1,99	1,87	1,55
60	5,29	3,93	3,34	3,01	2,79	2,63	2,41	2,27	2,06	1,94	1,82	1,48
80	5,22	3,86	3,28	2,95	2,73	2,57	2,36	2,21	2,00	1,88	1,75	1,40
100	5,18	3,83	3,25	2,92	2,70	2,54	2,32	2,18	1,97	1,85	1,71	1,35
∞	5,02	3,69	3,12	2,79	2,57	2,41	2,19	2,05	1,83	1,71	1,57	1,00

5.4.3 Test de comparaison de deux moyennes

$$\text{Test bilatéral : } \begin{cases} H_0 : \mu_1 = \mu_2, \\ H_1 : \mu_1 \neq \mu_2. \end{cases}$$

• **Cas de grands échantillons indépendants $n_1 > 30$ et $n_2 > 30$:**
On calcule

$$u = \frac{\overline{x_1} - \overline{x_2}}{\sqrt{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)}}.$$

On détermine z_α pour la loi normale $\mathcal{N}(0,1)$, et on décide que:

1. Si $u \in]-z_\alpha; z_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

• **Cas de petits échantillons extraits de populations gaussiennes $n_1 < 30$ et $n_2 < 30$ et tel que $\sigma = \sigma_1 = \sigma_2$:**
La variance commune σ^2 peut être estimer par:

$$s^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}.$$

On calcule

$$t = \frac{\overline{x_1} - \overline{x_2}}{s\sqrt{(\frac{1}{n_1} + \frac{1}{n_2})}}.$$

On détermine t_α dans la table de Student à $n_1 + n_2 - 2$ ddl, et on décide que:

1. Si $t \in]-t_\alpha; t_\alpha[$, on ne peut rejeter H_0.
2. Sinon, on rejette H_0 avec une probabilité α de se tromper.

Exemple:

Dans un article de la revue "Biometrica", le biologiste Latter donne la longueur (en mm) des oeufs de Coucou trouvés dans les nids de deux espèces d'oiseaux :

- dans des nids de petite taille (Roitelet) :

19,8	22,1	21,5	20,9	22,0	21,0	22,3	21,0
20,3	20,9	22,0	22,0	20,8	21,2	21,0	

- dans des nids de taille plus grande (Fauvette) :

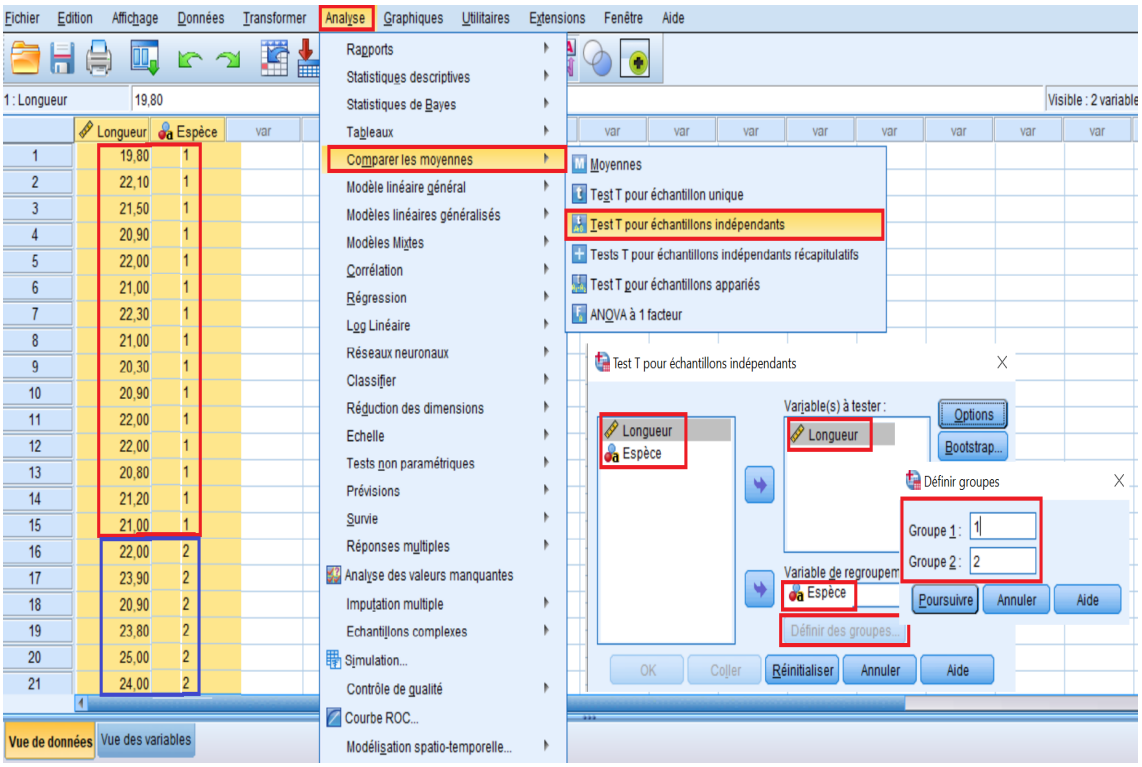
22,0	23,9	20,9	23,8	25,0	24,0	23,8
21,7	22,8	23,1	23,5	23,0	23,0	23,1

On se demande si le Coucou adapte la taille de ses oeufs à la taille du nid.

Observation sur l'échantillon E_1 de taille $n_1 = 15$: $\overline{x_1} = 21.25$ et $s_1^2 = 0.516$.
Observation sur l'échantillon E_2 de taille $n_2 = 14$: $\overline{x_2} = 23.11$ et $s_2^2 = 1.101$.
On est dans le cas des petits échantillons $n_1 < 30$, $n_2 < 30$.

$s^2 = 0.798$, $t = -5.61$ et le ddl de la loi Student est $n_1 + n_2 - 2 = 27$. Pour pour $\alpha = 0.05$, on trouve $t_\alpha = 2.052$. Comme t n'est pas dans $]-t_\alpha; t_\alpha[$, on rejette H_0 avec une probabilité α de se tromper. La taille moyenne des œufs de Coucou sont différentes dans les nids de Roitelet et de Fauvettes.

Sous SPSS 25: au début, on doit définir deux variables: (Longueur) qui est quantitative est qui contient les 29=15+14 mesures, et (Espèce) qui est qualitative à deux modalités (1) pour les 15 mesures du premier espèce, et (2) pour les 14 mesures du deuxième espèce. Ensuite, suivez le chemin: Analyse > Comparer les moyennes > Test T pour échantillons indépendants. Finalement, on aura les résultats de deux tests: comparaison les variances et comparaison de moyennes.



Test des échantillons indépendants

		Test de Levene sur l'égalité des variances		Test t pour égalité des moyennes						
									Intervalle de confiance de la différence à 95 %	
		F	Sig.	t	ddl	Sig. (bilatéral)	Différence moyenne	Différence erreur standard	Inférieur	Supérieur
Longueur	Hypothèse de variances égales	,719	,404	-5,607	27	,000	-1,86095	,33188	-2,54190	-1,18000
	Hypothèse de variances inégales			-5,535	22,800	,000	-1,86095	,33621	-2,55678	-1,16512

5.4.4 Cas d'échantillons appariés

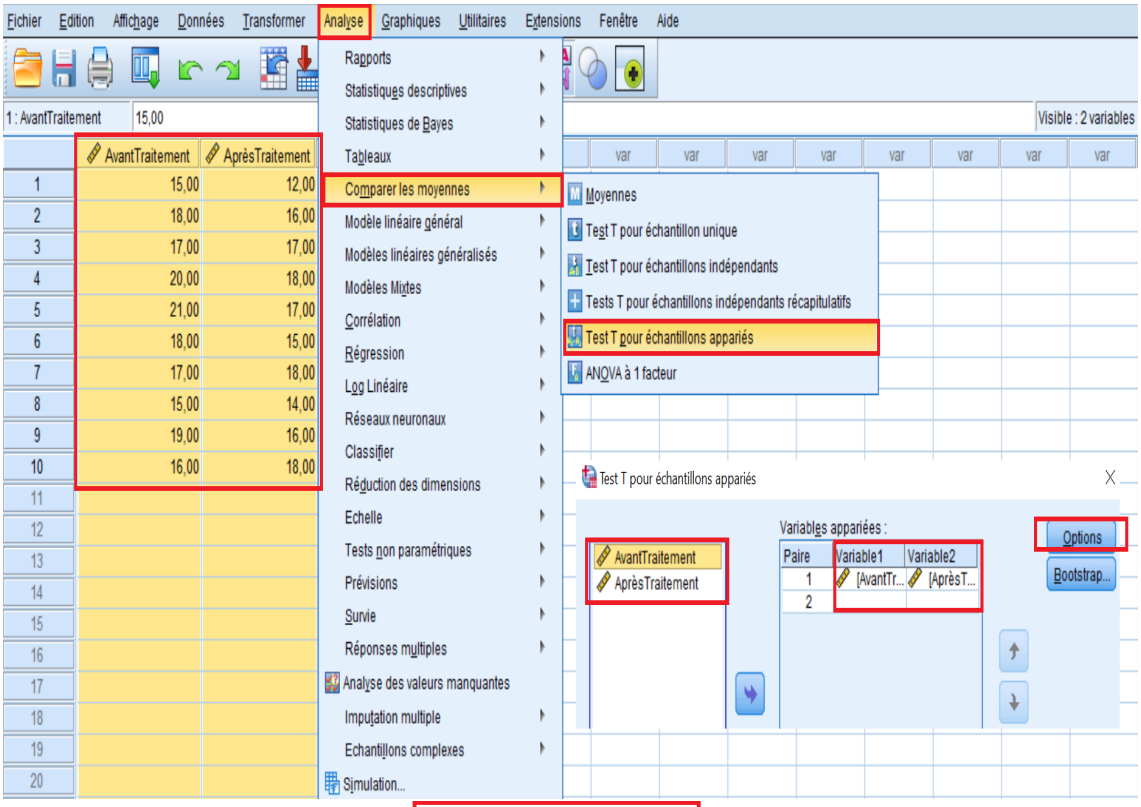
Deux échantillons E_1 et E_2 sont dits appariés, (associés par paires), lorsque chaque observation $x_{1,i}$ de E_1 est associée à une valeur $x_{2,i}$ de E_2. C'est par exemple le cas lorsque E_1 et E_2 proviennent d'un même groupe de malades avant et après traitement où les mêmes sujets ont répondu à deux reprises (mesures répétées) aux temps t_1 et t_2. Deux échantillons appariés ont donc la même taille $n_1 = n_2 = n$.

Exemple:

Chez un groupe de 10 malades, on expérimente les effets d'un traitement destiné à diminuer la pression artérielle. On observe les résultats suivants:

Avant traitement	15	18	17	20	21	18	17	15	19	16
Après traitement	12	16	17	18	17	15	18	14	16	18

Sous SPSS 25: Analyse > Comparer les moyennes > Test T pour échantillons appariés.



Test des échantillons appariés

		Différences appariées					t	ddl	Sig. (bilatéral)
		Moyenne	Ecart type	Moyenne erreur standard	Intervalle de confiance de la différence à 95 % Inférieur	Supérieur			
Paire 1	AvantTraitement - ApresTraitement	1,50000	1,95789	,61914	,09941	2,90059	2,423	9	,038

5.5 Test de normalité: test de Shapiro et Wilk

La plupart des méthodes de test paramétriques requièrent la normalité des données. Il est donc important de disposer d'une méthode permettant de vérifier cette normalité. Il existe plusieurs tests pour vérifier la normalité des données observées. Nous présentons ici le test de Shapiro et Wilk pour une série d'observations d'une variable quantitative.

NB: Ce test est valable pour des petits échantillons $(n \leq 30)$**.**

Exemple:
Nous avons réalisé $n = 10$ mesures d'un alésage en (mm). On a obtenu les résultats suivants:

12.124; 12.230; 12.327; 12.242; 12.466; 12.215; 12.026; 12.359; 12.215; 12.387.

On désire tester la normalité de cette série de résultats.

Démarche de vérification:

— Classer les différentes valeurs de la série par ordre croissant:

12.026; 12.124; 12.215; 12.215; 12.230; 12.242; 12.327; 12.359; 12.387; 12.466.

— Calculer la moyenne $\bar{x}$ de la série de mesure:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 12.259.$$

— Calculer le nombre:

$$T^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 = 0.1514.$$

— Calculer les différences respectives d_i:

$$d_1 = x_{10} - x_1 = 12.466 - 12.026 = 0.440$$

$$d_2 = x_9 - x_2 = 12.387 - 12.124 = 0.263$$

$$d_3 = x_8 - x_3 = 12.359 - 12.215 = 0.144$$

$$d_4 = x_7 - x_4 = 12.327 - 12.215 = 0.112$$

$$d_5 = x_6 - x_5 = 12.242 - 12.230 = 0.012$$

— A chacune de ces différences d_i, on affecte le coefficient a_i, donné par la table ci-dessus et on calcule $d_i * a_i$:

FIGURE 5.1 – Valeurs des a_i:

n / J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

$$d_1 * a_1 = 0.440 * 0.5739 = 0.2525$$
$$d_2 * a_2 = 0.263 * 0.3291 = 0.0865$$
$$d_3 * a_3 = 0.144 * 0.2141 = 0.0308$$
$$d_4 * a_4 = 0.112 * 0.1224 = 0.0137$$
$$d_5 * a_5 = 0.012 * 0.0399 = 0.0005$$

— Calculer la valeur:

$$b = \sum_{i=1}^{5} d_i * a_i = 0.384$$

— Calculer le rapport:

$$W = \frac{b^2}{T^2} = 0.9739$$

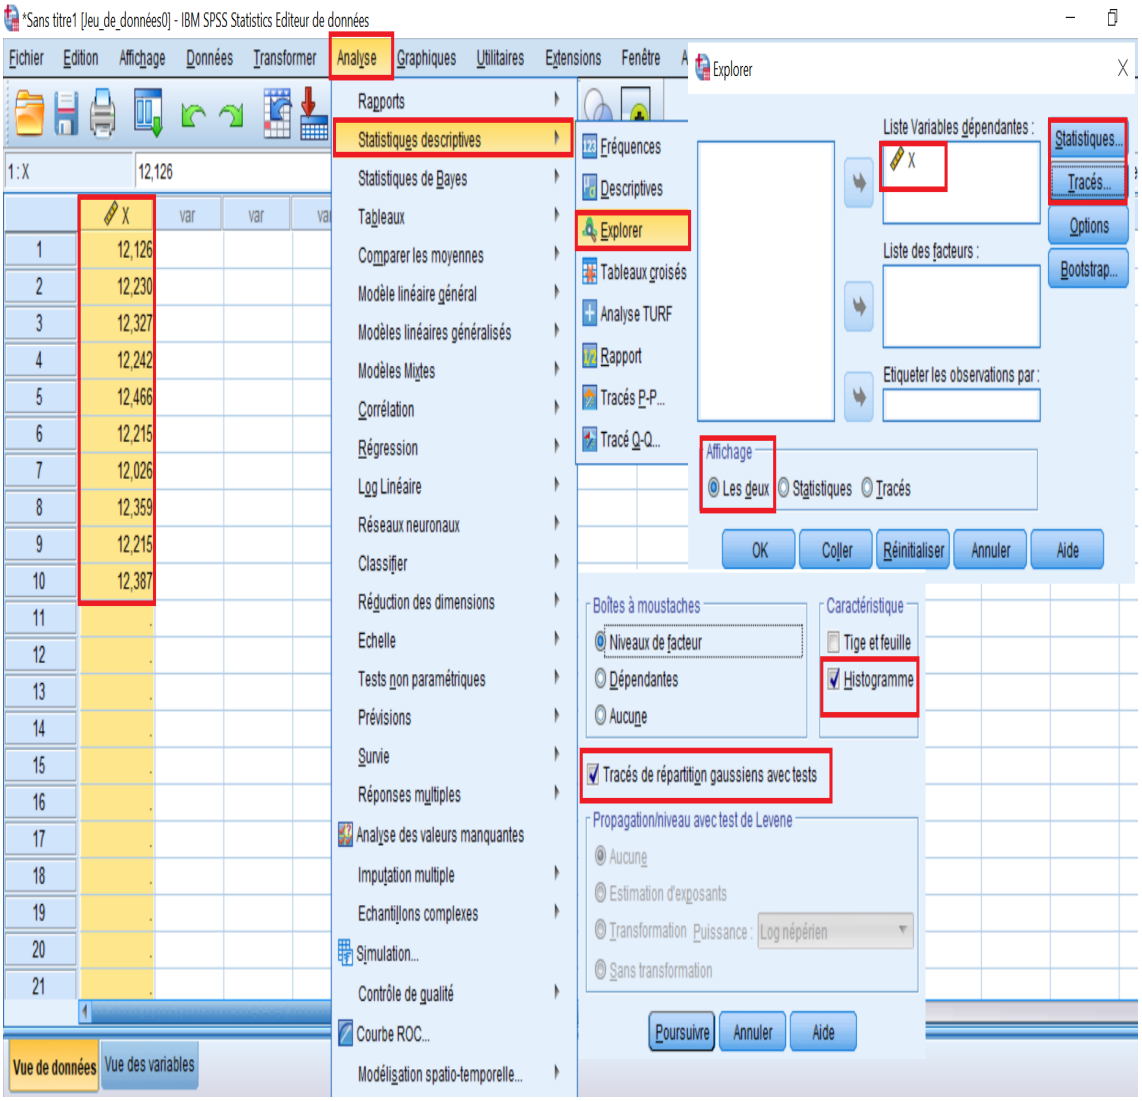
— Par exemple pour $\alpha = 0.05$, on trouve $w_\alpha = 0.842$ dans la table suivante de Shapiro et Wilk.

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

— Si $W > w_\alpha$, on accepte la normalité des donnés, sinon on rejette cette hypothèse. Dans notre exemple, on a: $W = 0.9739 > w_\alpha = 0.842$, l'hypothèse de normalité est acceptée.

Sous SPSS 25, suivez le chemin: Analyse > Statistiques descriptives > Explorer.

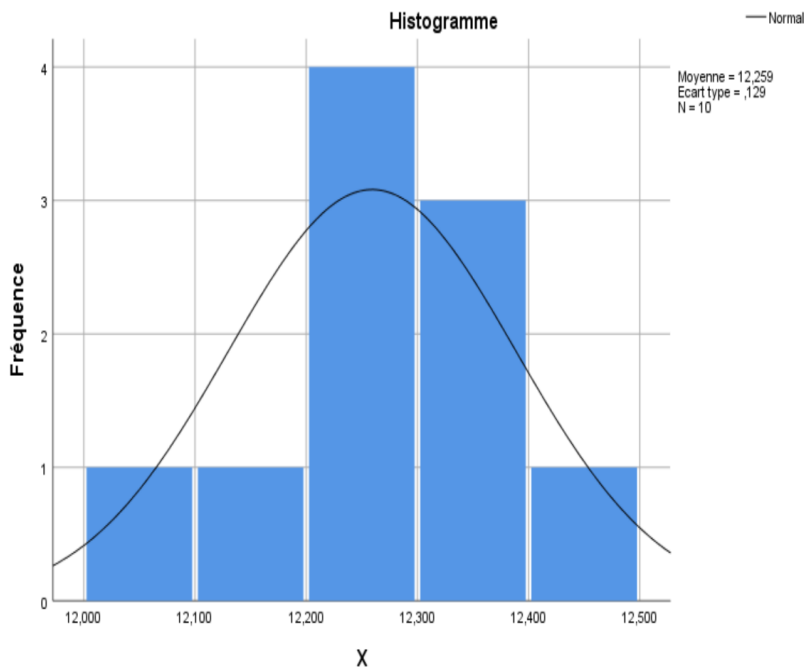


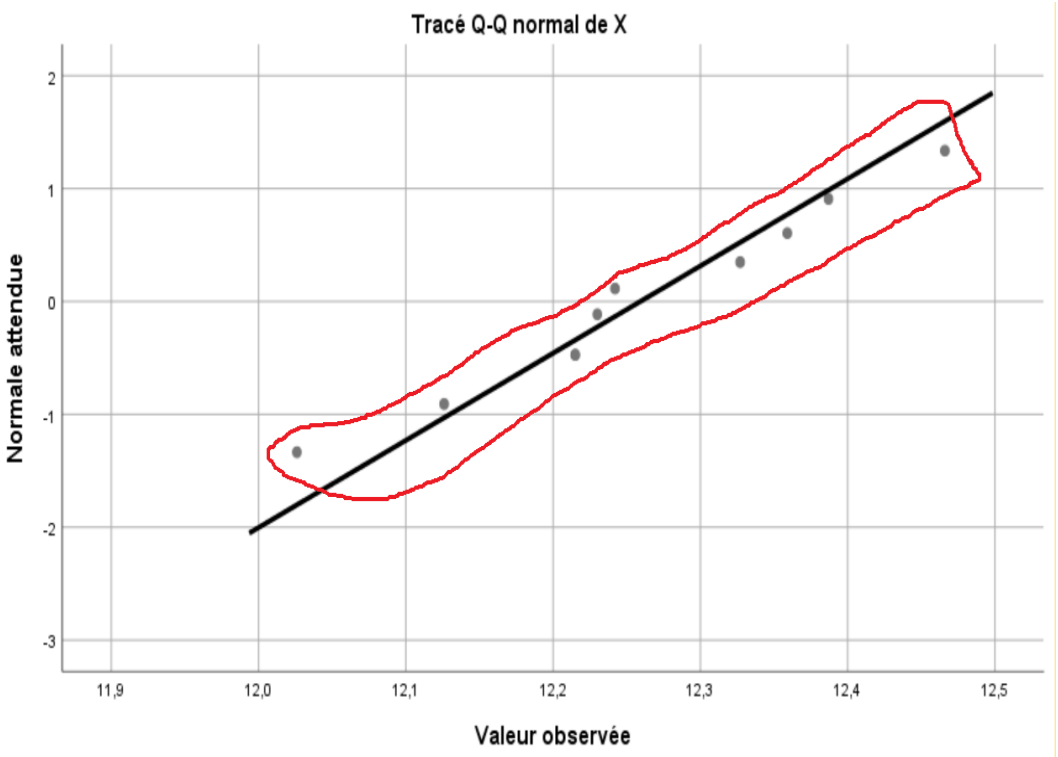
Tests de normalité

	Kolmogorov-Smirnov[a]			Shapiro-Wilk		
	Statistiques	ddl	Sig.	Statistiques	ddl	Sig.
X	,166	10	,200*	,975	10	,929

*. Il s'agit de la borne inférieure de la vraie signification.

a. Correction de signification de Lilliefors


Histogramme
Normal
Moyenne = 12,259
Ecart type = ,129
N = 10
Fréquence
0
1
2
3
4
12,000
12,100
12,200
12,300
12,400
12,500
X


Tracé Q-Q normal de X
Normale attendue
2
1
0
-1
-2
-3
11,9
12,0
12,1
12,2
12,3
12,4
12,5
Valeur observée

5.6 TP 3 sous SPSS 25

Exercice 1
On s'intéresse à une éventuelle relation entre X: le sexe de $n = 200$ personnes et Y: la couleur des yeux.

X/Y	Bleu	Vert	Marron
Homme	$n_{11} = 10$	$n_{12} = 50$	$n_{13} = 20$
Femme	$n_{21} = 20$	$n_{22} = 60$	$n_{23} = 40$

1) Appliquer le test du khi-deux pour tester l'indépendance de X et Y.

Exercice 2
Nous avons réalisé 10 dosages. On a obtenu les résultats suivants:

60	80	55	45	60	65	65	60	70	40

1) Utiliser le test de Shapiro et Wilk pour tester la normalité de ces données.

Exercice 3
On admet que le taux de cholestérol chez une femme suit une loi normale. Sur un échantillon de 10 femmes, on a obtenu les taux de cholestérol (en g/l) suivants:

3	1.8	2.1	2.7	1.4	1.9	2.2	2.5	1.7	2

1. Déterminer une estimation ponctuelle de la moyenne et de la variance du taux.
2. Déterminer un intervalle de confiance pour la moyenne du taux au seuil 5%.
3. Tester au seuil 5% si la moyenne de la population vaut $\mu = 2.5$.
4. Refaire les mêmes calculs pour la variable Taille importer du fichier **Excel TP3** au seuil 1% pour la valeur du test $\mu_0 = 160$.

Exercice 4
Sur deux groupes de même taille: 10 malades, on expérimente les effets d'un traitement destiné à diminuer la pression artérielle. On observe les résultats suivants (valeurs de la tension artérielle systolique en cm Hg). On supposera les populations gaussiennes.

Groupe 1	15	18	17	20	21	18	17	15	19	16
Groupe 2	12	16	17	18	17	15	18	14	16	18

1. Le traitement a-t-il une action significative, au risque de 5%:

1.1 Traiter le cas d'échantillons indépendants.

1.2 Traiter le cas d'échantillons appariés.

Exercice 5

Dans le cadre d'une étude sur la violence verbale au travail, on a interrogé au hasard 500 salariés de différents secteurs. 145 d'entre eux déclarent avoir déjà subi une violence verbale au travail.

1. Donner une estimation ponctuelle de la proportion des salariés ayant déjà subi une violence verbale.
2. Donner une estimation de cette proportion par un intervalle de confiance à 95%.
3. Tester au seuil 5% si la proportion de la population vaut 30%.
4. Refaire les mêmes calculs pour la variable Couleur importer du fichier **Excel TP3** au seuil 1% pour la valeur du test $p_0 = 50\%$.

Exercice 6

On compare les effets d'un même traitement dans deux hôpitaux différents. Dans le premier hôpital, 70 des 100 malades traités montrent des signes de guérison. Dans le deuxième hôpital, c'est le cas pour 100 des 150 malades traités.

1. Quelle conclusion peut-on en tirer au risque de 5%? (comparer les proportions).

Chapitre 6

Modèle linéaire et Analyse de la variance (ANOVA) sous SPSS 25

6.1 Modèle linéaire simple

On cherche à modéliser une relation linéaire entre deux variables quantitatives continues X et Y de la forme suivante:

$$Y = a + bX + \varepsilon,$$

où Y est la variable à expliquer, X est la variable explicative et ε est le terme d'erreur aléatoire du modèle. Pour n observations, on suppose que:

- ε_i est une variable aléatoire non observée qui suit la loi $\mathcal{N}(0, \sigma^2)$.
- x_i est observée et non aléatoire.
- y_i est observée et aléatoire.
- a, b et σ sont des paramètres à estimer.

Les erreurs centrées (ε_i) impliquent que y_i dépend seulement de x_i et que les autres sources de variations de y_i sont aléatoires. De plus par normalité, les erreurs (ε_i) sont indépendantes.

6.1.1 Test de la significativité du coefficient de corrélation

Le coefficient de corrélation r_{XY} permet de mesurer la relation linéaire entre X et Y sur une population. Sur un échantillon de taille n, r_{XY} est estimée par:

$$\hat{r}_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}.$$

Un test intéressant à réaliser sous la condition de normalité est le suivant:

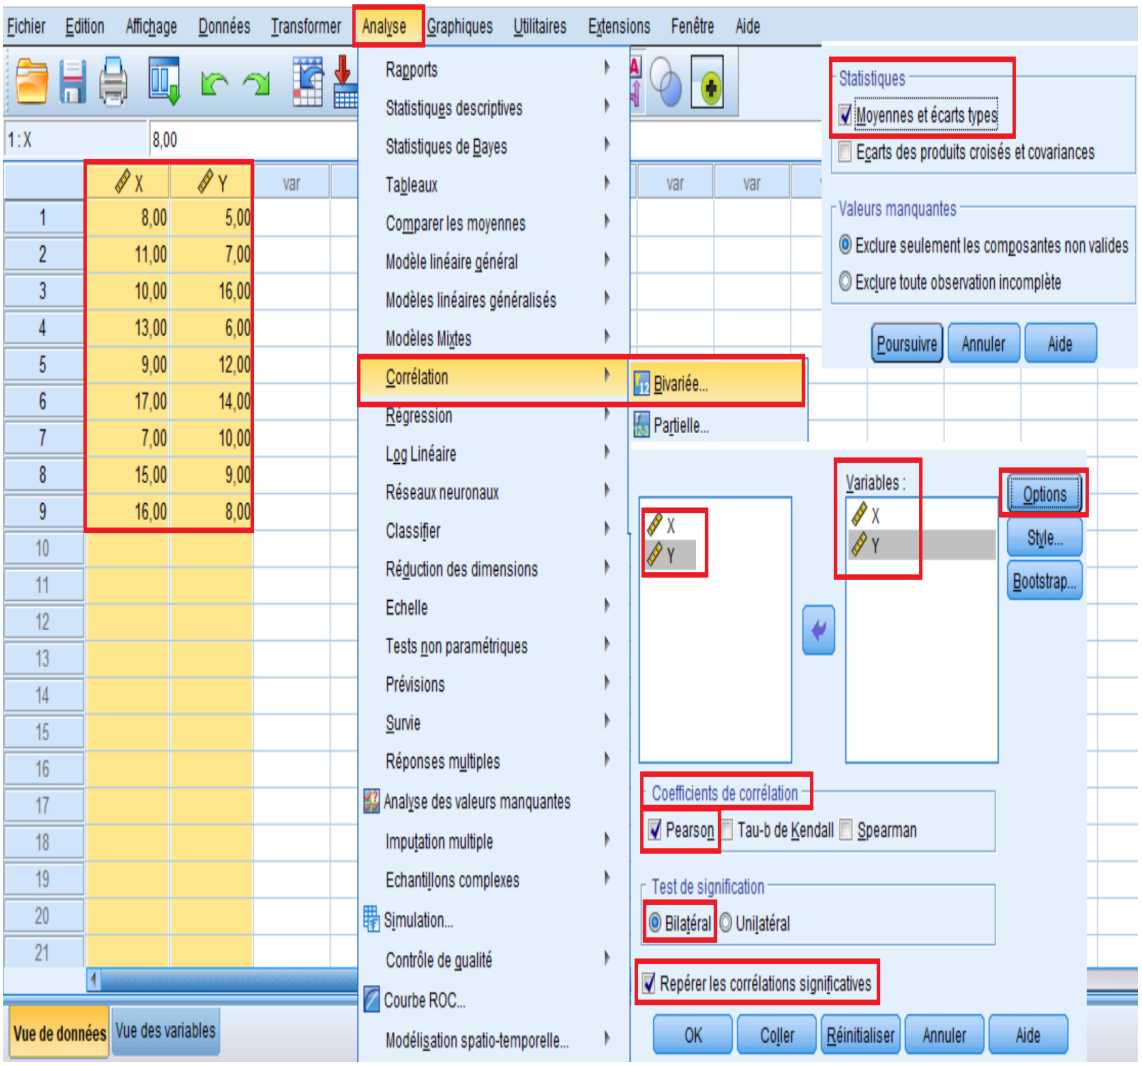
$$\text{Test Bilateral} : \begin{cases} H_0 : r_{XY} = 0 : \text{ il n'y a pas de liaison linéaire entre X et Y.} \\ H_1 : r_{XY} \neq 0 : \text{ il existe une relation linéaire entre X et Y.} \end{cases}$$

Exemple:

X	8	11	10	13	9	17	7	15	16
Y	5	7	16	6	12	14	10	9	8

$$\begin{cases} \bar{x} = 11.78, \quad \bar{y} = 9.667 \\ \sigma_X = 3.63, \quad \sigma_Y = 3.7 \\ \sigma_{XY} = 1.037 \quad r_{XY} = 0.087 \end{cases}$$

Sous SPSS 25: Analyse > Corrélation > Bivariée.



Statistiques descriptives

	Moyenne	Ecart type	N
X	11,7778	3,63242	9
Y	9,6667	3,70810	9

Corrélations

		X	Y
X	Corrélation de Pearson	1	,087
	Sig. (bilatérale)		,825
	N	9	9
Y	Corrélation de Pearson	,087	1
	Sig. (bilatérale)	,825	
	N	9	9

6.1.2 Estimation des paramètres

La droite de régression linéaire est la droite qui ajuste au mieux le nuage de points (x_i, y_i) au sens des moindres carrés. Elle a pour équation: $y = \hat{a} + \hat{b}x$, avec

- $\hat{b} = \dfrac{\sigma_{XY}}{\sigma_X^2}$ est un estimateur de b,
- $\hat{a} = \bar{y} - \hat{b}\bar{x}$ est un estimateur de a,
- $R^2 = \hat{r}_{XY}^2$ est le coefficient de détermination qui permet d'évaluer la qualité de l'ajustement.

Dans notre exemple, on a: $y = 0.088x + 8.625$, et $R^2 = 0.008$, (0.8% est très faible).

On a besoin d'effectuer les tests suivants:

- **Test de significativité de $\hat{b}$ et son intervalle de confiance:**

$$\text{Test 1} : \begin{cases} H_0 : \hat{b} = 0 : & \text{Absence de liaison linéaire entre X et Y.} \\ H_1 : \hat{b} \neq 0 : & \text{Existence de liaison linéaire entre X et Y.} \end{cases}$$

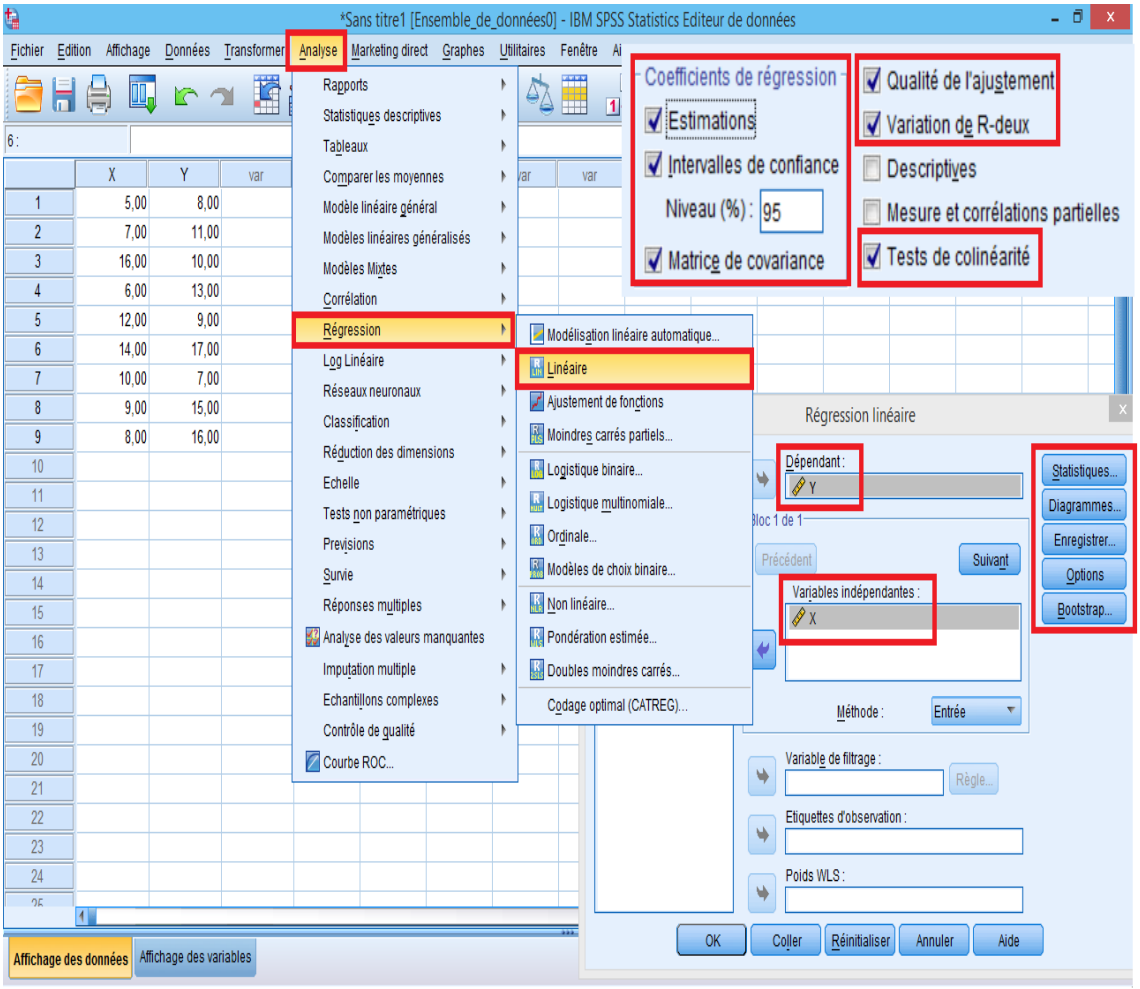
- **Test de significativité de $\hat{a}$ et son intervalle de confiance:**

$$\text{Test 2} : \begin{cases} H_0 : \hat{a} = 0 : & \text{L'ordonnée à l'origine n'est pas significative.} \\ H_1 : \hat{a} \neq 0 : & \text{L'ordonnée à l'origine est significative.} \end{cases}$$

- **Test de significativité globale du modèle:**

$$\text{Test 3} : \begin{cases} H_0 : & \text{Le modèle est non explicatif.} \\ H_1 : & \text{Le modèle est explicatif.} \end{cases}$$

Sous SPSS 25: Analyse > Régression > Linéaire.



Coefficients

Modèle		Coefficients non standardisés		Coefficients standardisés			Intervalle de confiance à 95,0% pour B		Statistiques de colinéarité	
		B	Erreur standard	Bêta	t	Sig.	Borne inférieure	Borne supérieure	Tolérance	VIF
1	(Constante)	$\hat{a}$ = 8,625	4,715		1,829	,110	-2,523	19,774		
	X	$\hat{b}$ = ,088	,384	,087	,230	,825	-,821	,997	1,000	1,000

Récapitulatif des modèles

Modèle	R	R-deux	R-deux ajusté	Erreur standard de l'estimation	Modifier les statistiques: Variation de R-deux	Variation de F	ddl1	ddl2	Sig. Variation de F
1	,087[a]	,008	-,134	3,94923	,008	,053	1	7	,825

ANOVA

Modèle		Somme des carrés	ddl	Carré moyen	F	Sig.
1	Régression	,825	1	,825	,053	,825[b]
	de Student	109,175	7	15,596		
	Total	110,000	8			

la régression est significative dans son ensemble

Estimation de la variance des erreurs

6.2 Modèle linéaire multiple

Effectuer une régression linéaire multiple d'un caractère **à expliquer** Y sur plusieurs caractères **explicatifs** $X_1, ..., X_n$ c'est trouver la combinaison linéaire des caractères explicatifs pour laquelle la variance de la série des résidus est minimale. On cherche à estimer les coefficients de la relation linéaire:

$$Y = a_0 + a_1X_1 + ... + a_nX_n + \varepsilon.$$

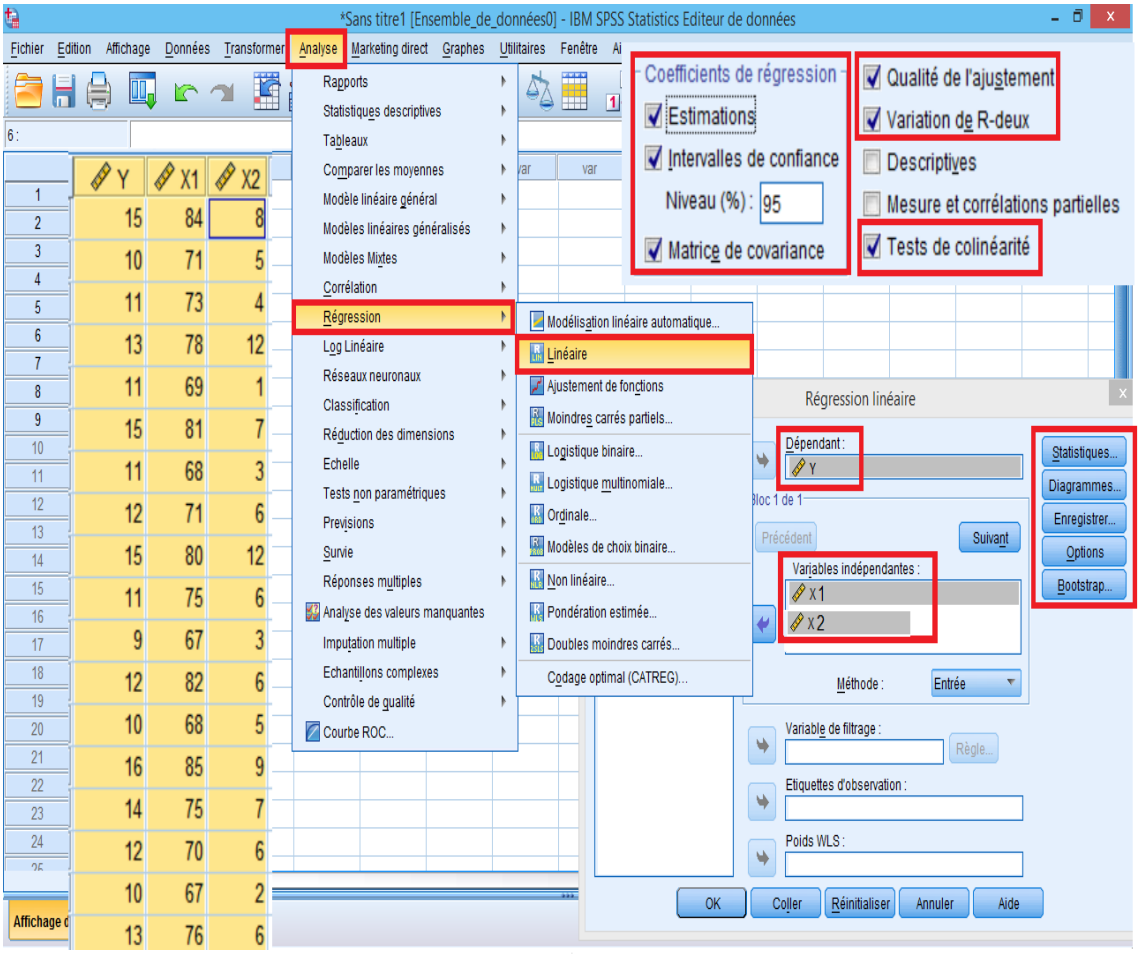
Exemple: (étudier Y la concentration d'ozone dans l'air)

Y	X_2	X_1
15	8	84
10	5	71
11	4	73
13	12	78
11	1	69
15	7	81
11	3	68
12	6	71
15	12	80
11	6	75

Y	X_2	X_1
9	3	67
12	6	82
10	5	68
16	9	85
14	7	75
12	6	70
10	2	67
13	6	76
10	5	72
9	4	69

- X_1 est la température •X_2 est la vitesse du vent,
- Y est la concentration d'ozone dans l'air: $Y = a_0 + a_1X_1 + a_2X_2 + \varepsilon$.
- Le but est d'estimer les coefficients a_0, a_1 et a_2 afin de prédire la concentration d'ozone connaissant la température et le vent.

Sous SPSS 25: Analyse > Régression > Linéaire.



ANOVA

Modèle		Somme des carrés	ddl	Carré moyen	F	Sig.
1	Régression	88,099	2	44,049	42,627	,000[b]
	de Student	27,901	27	1,033		
	Total	116,000	29			

Coefficients

Modèle		Coefficients non standardisés B	Coefficients non standardisés Erreur standard	Coefficients standardisés Bêta	t	Sig.
1	(Constante)	$\hat{a}_0$ =-8,290	3,183		-2,605	,015
	X1	$\hat{a}_1$ = ,264	,049	,747	5,383	,000
	X2	$\hat{a}_2$ = ,126	,110	,160	1,152	,259

6.3 ANOVA à un facteur

Il s'agit d'une généralisation à k populations de tailles $(n_j)_{1\leq j\leq k}$ des tests de comparaison de moyennes de deux échantillons. Elle permet d'étudier l'effet d'une variable qualitative (facteur) sur une variable quantitative. On utilise des mesures de variance afin de déterminer le caractère significatif, ou non, des différences de moyenne mesurées sur les populations.

$$\begin{cases} H_0 : \mu_1 = \mu_2 = ... = \mu_k, \\ H_1 : \text{au moins l'une des moyennes diffère des autres.} \end{cases}$$

L'analyse de variance suppose l'homogénéité des variances et la normalité des données.

Démarche de l'ANOVA:
Les moyennes:

$$\overline{x_j} = \frac{1}{n_j}\sum_{i=1}^{n_j} x_{ij} \qquad\qquad \overline{x} = \frac{1}{n}\sum_{j=1}^{k} n_j\overline{x_j}$$

La variation totale:

$$SCT = \sum_{j=1}^{k}\sum_{i=1}^{n_j}(x_{ij} - \overline{x})^2.$$

La variation intragroupe résiduelle non expliquée par le facteur:

$$SCR = \sum_{j=1}^{k}\sum_{i=1}^{n_j}(x_{ij} - \overline{x_j})^2.$$

La variation intergroupe expliquée par le facteur:

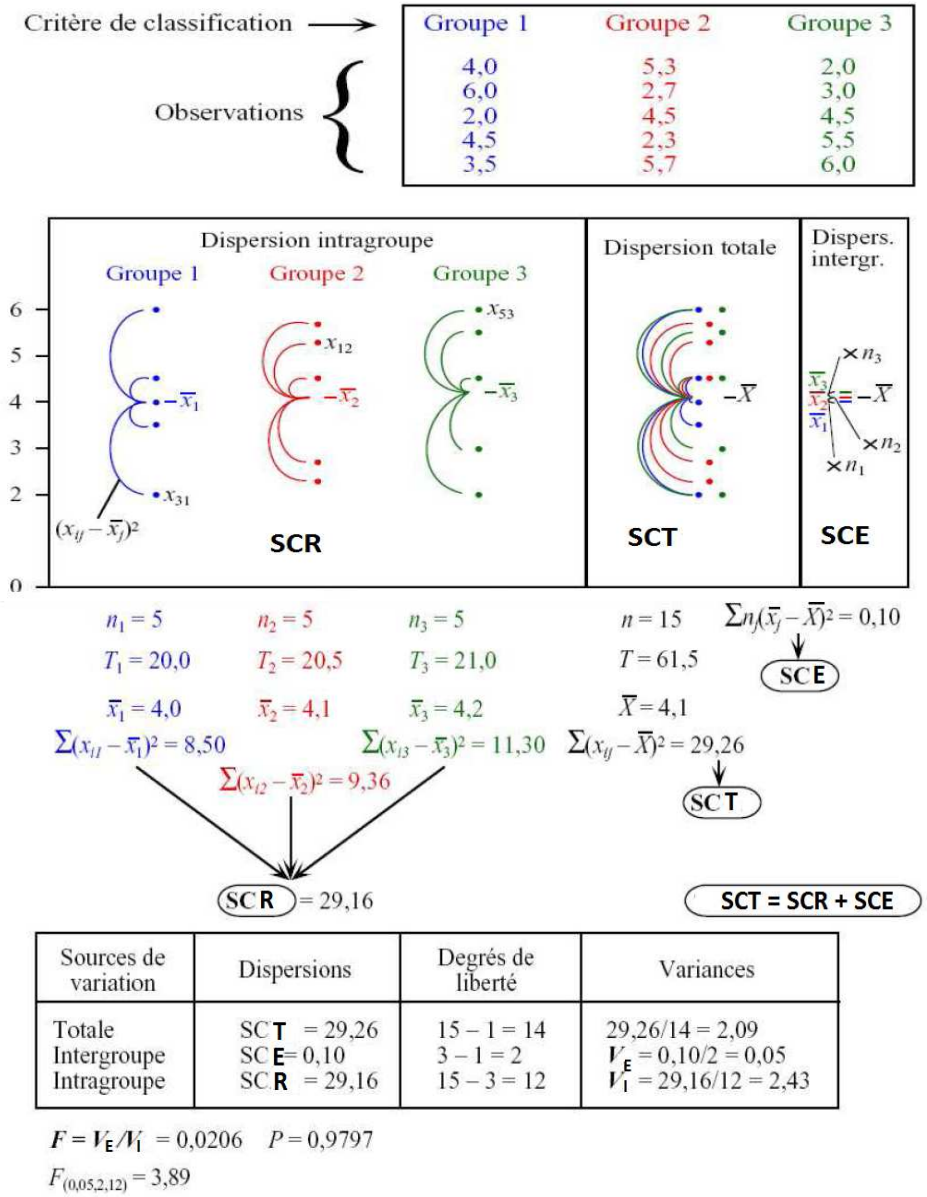
$$SCE = \sum_{j=1}^{k}\sum_{i=1}^{n_j}(\overline{x_j} - \overline{x})^2 = \sum_{j=1}^{k} n_j(\overline{x_j} - \overline{x})^2.$$

Équation d'ANOVA: $SCT = SCR + SCE$.

$$V_E = \frac{SCE}{k-1} = \frac{SCE}{ddl} \qquad\qquad V_I = \frac{SCR}{n-k} = \frac{SCR}{ddl} \qquad\qquad F = \frac{V_E}{V_I}.$$

Règle de décision: pour un seuil α, on cherche dans la table de Fisher Snédécor la valeur $F_{(\alpha,k-1,n-k)}$. On accepte H_0 si $F < F_{(\alpha,k-1,n-k)}$.

Exemple:
Soit $k = 3$ populations de taille $n_1 = n_2 = n_3 = 5$ et $n = n_1 + _2 + n_3 = 15$.



Sources de variation	Dispersions	Degrés de liberté	Variances
Totale	SCT = 29,26	15 – 1 = 14	29,26/14 = 2,09
Intergroupe	SCE = 0,10	3 – 1 = 2	V_E = 0,10/2 = 0,05
Intragroupe	SCR = 29,16	15 – 3 = 12	V_I = 29,16/12 = 2,43

$F = V_E/V_I = 0,0206$ $P = 0,9797$

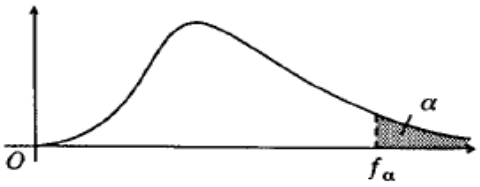
$F_{(0,05,2,12)} = 3,89$

Remarque

Pourquoi ne pas réaliser une série de tests pour comparer la moyenne de toutes les paires de groupes: Par exemple, considérons 7 groupes d'observations tirées indépendamment d'une même population statistique. Il faudrait réaliser $C_7^2 = 21$ tests pour comparer toutes les paires de groupes. Chaque test étant réalisé au niveau $\alpha = 0.05$, on a, dans chaque cas, 5 chances sur 100 de rejeter H_0 même si H_0 est vraie. La probabilité de rejeter H_0 au moins une fois au cours de 21 tests est 0.66 et non 0.05 (calcul basé sur la distribution Binomiale). Pour être valide, le test global doit avoir une erreur 0.05. La solution de ce problème est la méthode ANOVA.

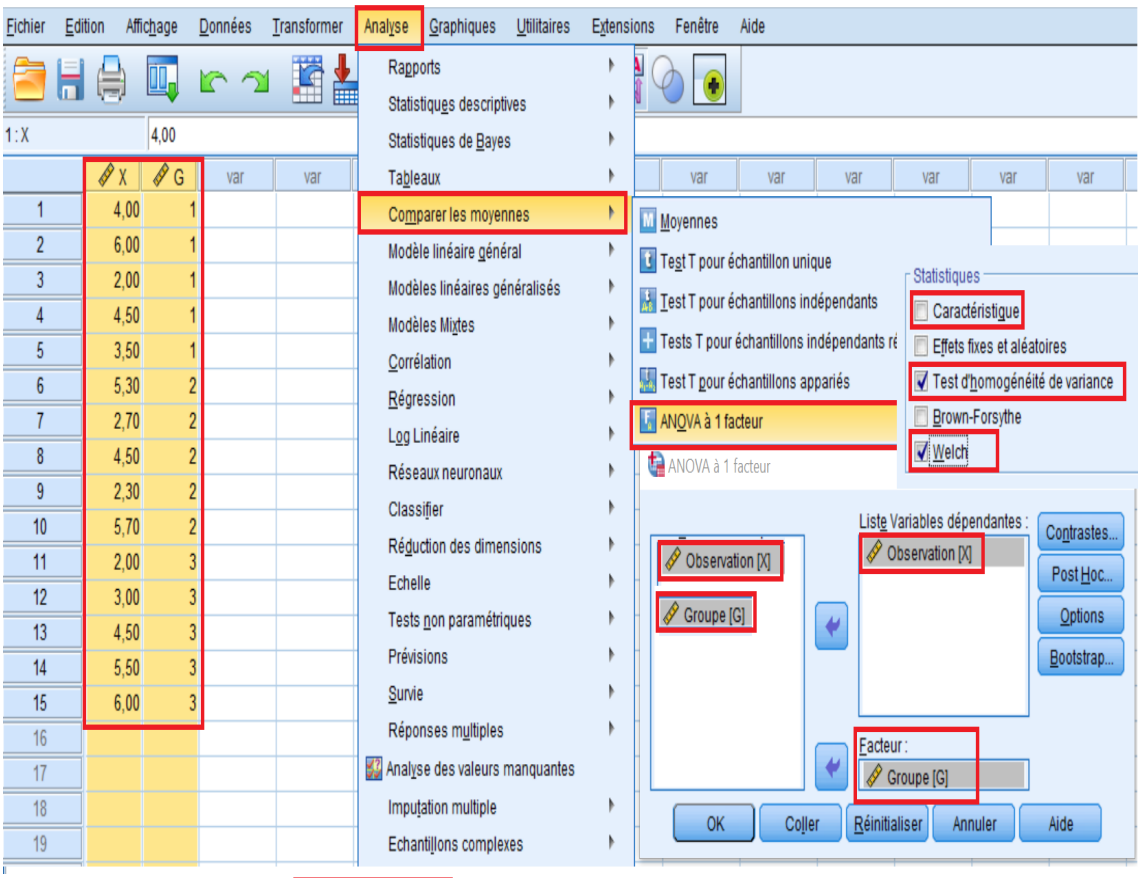
Lois de Fisher ($\alpha = 0{,}05$)

Si F est une variable aléatoire qui suit la loi de Snédécor à (ν_1, ν_2) degrés de liberté, la table donne le nombre f_α tel que $P(F \geqslant f_\alpha) = \alpha = 0{,}05$.



ν_2 \ ν_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	161	200	216	225	230	234	239	242	246	248	250	254
2	18,5	19,0	19,2	19,2	19,3	19,3	19,4	19,4	19,4	19,4	19,5	19,5
3	10,1	9,55	9,28	9,12	9,01	8,94	8,85	8,79	8,70	8,66	8,62	8,53
4	7,71	6,94	6,59	6,39	6,26	6,16	6,04	5,96	5,86	5,80	5,75	5,63
5	6,61	5,79	5,41	5,19	5,05	4,95	4,82	4,74	4,62	4,56	4,50	4,36
6	5,99	5,14	4,76	4,53	4,39	4,28	4,15	4,06	3,94	3,87	3,81	3,67
7	5,59	4,74	4,35	4,12	3,97	3,87	3,73	3,64	3,51	3,44	3,38	3,23
8	5,32	4,46	4,07	3,84	3,69	3,58	3,44	3,35	3,22	3,15	3,08	2,93
9	5,12	4,26	3,86	3,63	3,48	3,37	3,23	3,14	3,01	2,94	2,86	2,71
10	4,96	4,10	3,71	3,48	3,33	3,22	3,07	2,98	2,85	2,77	2,70	2,54
11	4,84	3,98	3,59	3,36	3,20	3,09	2,95	2,85	2,72	2,65	2,57	2,40
12	4,75	3,89	3,49	3,26	3,11	3,00	2,85	2,75	2,62	2,54	2,47	2,30
13	4,67	3,81	3,41	3,18	3,03	2,92	2,77	2,67	2,53	2,46	2,38	2,21
14	4,60	3,74	3,34	3,11	2,96	2,85	2,70	2,60	2,46	2,39	2,31	2,13
15	4,54	3,68	3,29	3,06	2,90	2,79	2,64	2,54	2,40	2,33	2,25	2,07
16	4,49	3,63	3,24	3,01	2,85	2,74	2,59	2,49	2,35	2,28	2,19	2,01
17	4,45	3,59	3,20	2,96	2,81	2,70	2,55	2,45	2,31	2,23	2,15	1,96
18	4,41	3,55	3,16	2,93	2,77	2,66	2,51	2,41	2,27	2,19	2,11	1,92
19	4,38	3,52	3,13	2,90	2,74	2,63	2,48	2,38	2,23	2,16	2,07	1,88
20	4,35	3,49	3,10	2,87	2,71	2,60	2,45	2,35	2,20	2,12	2,04	1,84
22	4,30	3,44	3,05	2,82	2,66	2,55	2,40	2,30	2,15	2,07	1,98	1,78
24	4,26	3,40	3,01	2,78	2,62	2,51	2,36	2,25	2,11	2,03	1,94	1,73
26	4,23	3,37	2,98	2,74	2,59	2,47	2,32	2,22	2,07	1,99	1,90	1,69
28	4,20	3,34	2,95	2,71	2,56	2,45	2,29	2,19	2,04	1,96	1,87	1,65
30	4,17	3,32	2,92	2,69	2,53	2,42	2,27	2,16	2,01	1,93	1,84	1,62
40	4,08	3,23	2,84	2,61	2,45	2,34	2,18	2,08	1,92	1,84	1,74	1,51
50	4,03	3,18	2,79	2,56	2,40	2,29	2,13	2,03	1,87	1,78	1,69	1,44
60	4,00	3,15	2,76	2,53	2,37	2,25	2,10	1,99	1,84	1,75	1,65	1,39
80	3,96	3,11	2,72	2,49	2,33	2,21	2,06	1,95	1,79	1,70	1,60	1,32
100	3,94	3,09	2,70	2,46	2,31	2,19	2,03	1,93	1,77	1,68	1,57	1,28
∞	3,84	3,00	2,60	2,37	2,21	2,10	1,94	1,83	1,67	1,57	1,46	1,00

Sous SPSS 50: au début, vous devez créer une variable quantitative X à 15 observations, (5+5+5), et le facteur G à trois modalités (1, 2 et 3) et un total de 15 observations. Ensuite suivez le chemin: Analyse > Comparer les moyennes > ANOVA à 1 facteur.

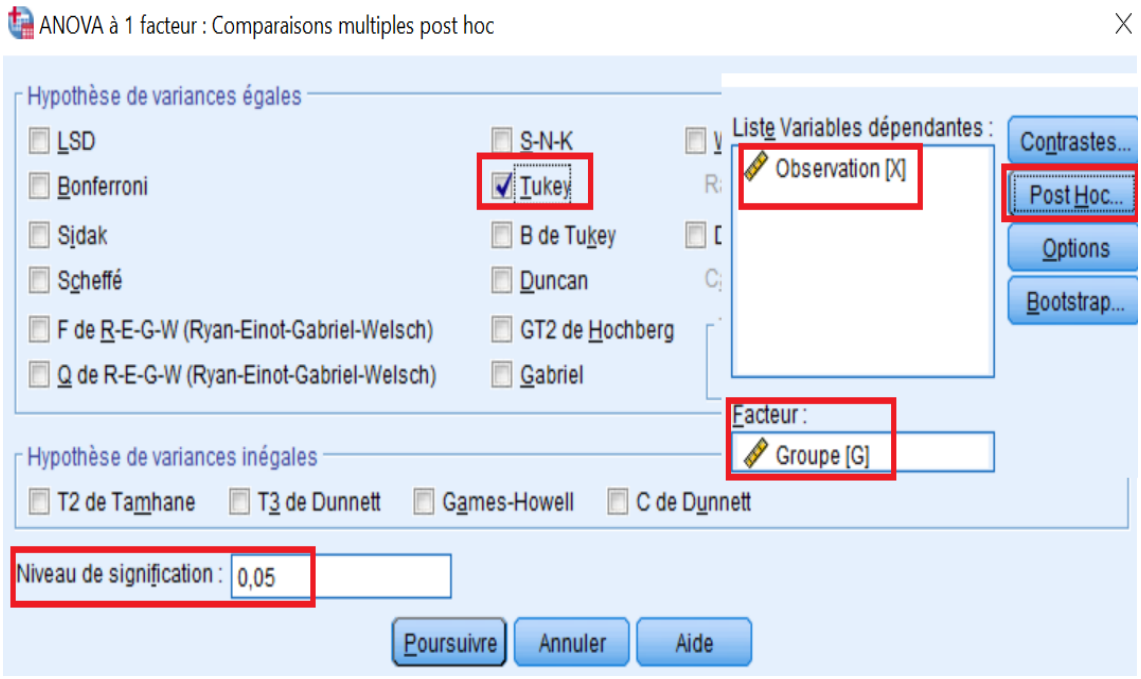


	Somme des carrés	ddl	Carré moyen	F	Sig.
Intergroupes	,100	2	,050	,021	,980
Intragroupes	29,160	12	2,430		
Total	29,260	14			

Tests de comparaisons multiples (Post Hoc)

Après avoir obtenu un test statistiquement **significatif** dans l'ANOVA: (**rejet de H_0**), la prochaine étape est d'identifier par test quels sont les groupes responsables de ce rejet, c'est-à-dire les groupes qui ont une moyenne différente de celles des autres groupes.

Sous SPSS 25: les différents tests Post Hoc proposés sont: test de Bonferroni, test de Scheffé, test de Tukey, test de Duncan, test HSD de Tukey et test de Dunnett. Si l'intervalle de confiance n'inclut pas 0, la différence est significative.



Comparaisons multiples :

Variable dépendante: Observation

Différence significative de Tukey

(I) Groupe	(J) Groupe	Différence moyenne (I-J)	Erreur standard	Sig.	Intervalle de confiance à 95 % Borne inférieure	Borne supérieure	
1	2	-,10000	,98590	,994	-2,7302	0	2,5302
	3	-,20000	,98590	,978	-2,8302	0	2,4302
2	1	,10000	,98590	,994	-2,5302	0	2,7302
	3	-,10000	,98590	,994	-2,7302	0	2,5302
3	1	,20000	,98590	,978	-2,4302	0	2,8302
	2	,10000	,98590	,994	-2,5302	0	2,7302

N.B: puisque tous les intervalles de confiance contiennent 0, alors les différences ne sont plus significatifs.

6.4 ANOVA à un facteur à mesures répétées

Lorsque nous mesurons plusieurs fois de suite, par exemple à des instants différents, la même grandeur sur les mêmes sujets, nous sommes confrontés à certains problèmes. En effet, nous ne pouvons plus utiliser l'analyse de la variance classique, car:

- **la condition d'indépendance n'est plus vérifiée,**
- **il faut prendre en compte la variabilité Inter-sujets.**

Une solution est alors d'utiliser une ANOVA à un facteur à mesures répétées.

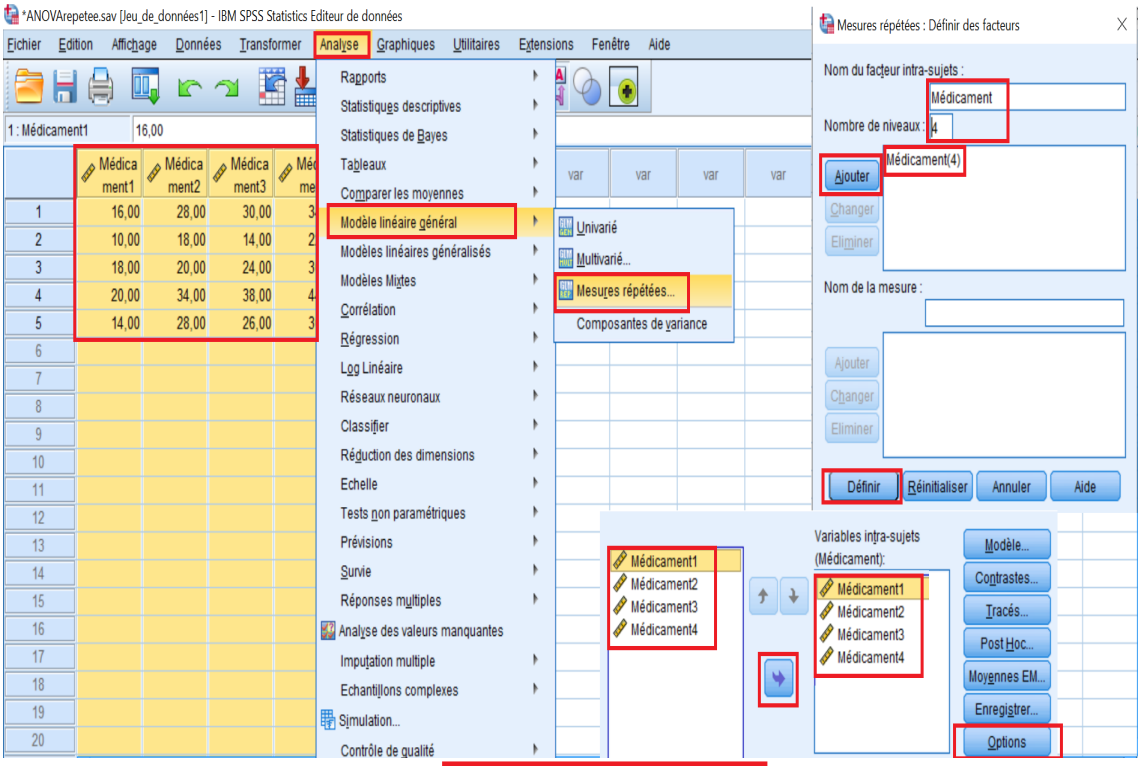
Dans un plan à mesures répétées, on cherche à vérifier des hypothèses sur les différences de moyennes obtenues par un seul groupe de n sujets. Ce groupe est soumis à p traitements expérimentaux et les sujets, mesurés sur une variable dépendante.

Exemple:
Un chercheur veut évaluer l'effet de quatre médicaments sur le temps de réaction des patients dans une série de tests classiques. Cinq sujets différents participent à l'expérience et la performance de chacun est mesurée sous l'effet de chaque médicament, l'ordre d'administration étant réparti de façon aléatoire et avec un délai suffisant entre chacun. La variable dépendante est le temps de réaction moyen en dixième de secondes aux différentes tâches.

Sujet	Médicament (1)	Médicament (2)	Médicament (3)	Médicament (4)
(1)	16	28	30	34
(2)	10	18	14	22
(3)	18	20	24	30
(4)	20	34	38	44
(5)	14	28	26	30

Source de variation	SC	dl	CM	F
Intergroupe	680.80	4		
Intra groupe	811.00	15		
Médicament (A)	698.20	3	232.73	24.76
Erreur (S|A)	112.80	12	9.40	
Total	**1491.80**	**19**		

Sous SPSS 25: Analyse > Modèle linéaire général > Mesures répétées.
L'icône Options permet de modifier le seuil du test et d'obtenir quelques statistiques descriptives.



Tests de sphéricité de Mauchly
(égalité des variances)

Mesure: MEASURE_1

Effet intrasujets	W de Mauchly	Khi-deux approx.	ddl	Signification	Epsilon[b] Greenhouse-Geisser	Epsilon[b] Huynh-Feldt	Epsilon[b] Borne inférieure
Médicament	,186	4,572	5	,495	,605	1,000	,333

Tests des effets intrasujets

Mesure: MEASURE_1

Source		Somme des carrés de type III	ddl	Carré moyen	F	Signification
Médicament	Hypothèse de sphéricité	698,200	3	232,733	24,759	,000
si on n'a pas la sphéricité	Greenhouse-Geisser	698,200	1,815	384,763	24,759	,001
	Huynh-Feldt	698,200	3,000	232,733	24,759	,000
	Borne inférieure	698,200	1,000	698,200	24,759	,008
Erreur (Médicament)	Hypothèse de sphéricité	112,800	12	9,400		
si on n'a pas la sphéricité	Greenhouse-Geisser	112,800	7,258	15,540		
	Huynh-Feldt	112,800	12,000	9,400		
	Borne inférieure	112,800	4,000	28,200		

6.5 ANOVA à deux facteurs

On veut étudier maintenant l'influence conjointe de deux facteurs indépendants A et B sur la moyenne d'une variable dépendante X. Trois effets sont à mesurer:

- Effet du premier facteur A.
- Effet du deuxième facteur B.
- Interaction entre les facteurs A et B.

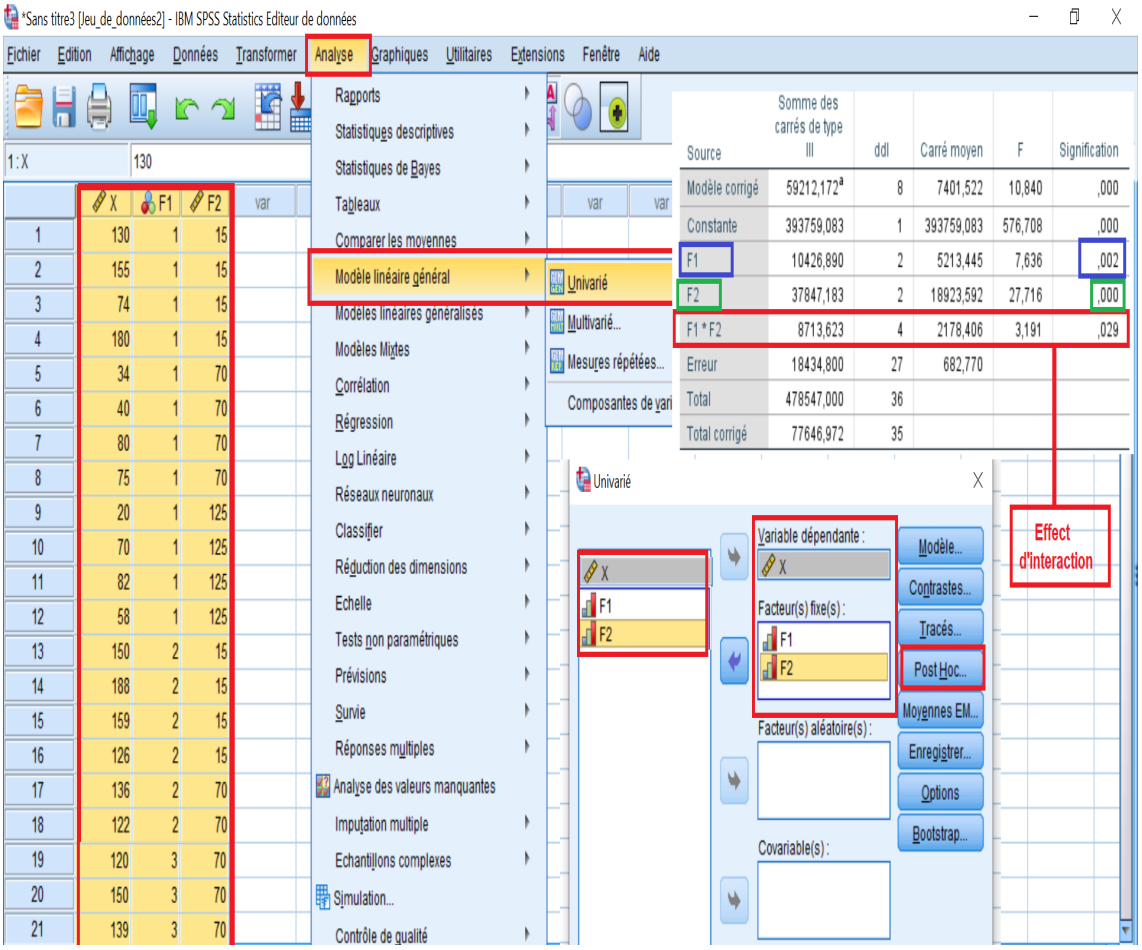
Les différents cas possibles sont:

- H_0^{AB} **acceptée :** il n'y a pas d'interaction
  - H_0^A **acceptée :** il n' y a pas d'effet du facteur A,
  - H_0^A **rejetée :** il y a un d'effet du facteur A, et une analyse plus fine peut être faites (comparaison multiples, comparaison par rapport à un groupe contrôle du facteur A. Les modalités du facteur B n'ont pas d'influence.
  - H_0^B **acceptée :** il n' y a pas d'effet du facteur B, les modalités du facteur A n'influence pas le facteur B.
  - H_0^B **rejetée :** il y a un d'effet du facteur B, et une analyse plus fine peut être faites (comparaison multiples, comparaison par rapport à un groupe contrôle du facteur B. Les modalités du facteur A n'ont pas d'influence sur cette analyse.
- H_0^{AB} **rejetée :** il y a une interaction entre le facteur A et le facteur B.
  - H_0^A **acceptée :** il n' y a pas d'effet du facteur A sur le niveaux du facteurs B mais les niveaux du facteur B influencent les effets de A
  - H_0^A **rejetée :** il y a un d'effet du facteur A, et une analyse plus fine peut être faites (comparaison multiples, comparaison par rapport à un groupe contrôle du facteur A. Les modalités du facteur B ont une influence.
  - H_0^B **acceptée :** il n' y a pas d'effet du facteur B sur les niveaux du facteur A. les modalités du facteur A influencent les effets du facteur B.
  - H_0^B **rejetée :** il y a un d'effet du facteur B, et une analyse plus fine peut être faites (comparaison multiples, comparaison par rapport à un groupe contrôle du facteur B. Les modalités du facteur A ont une influence sur cette analyse.

Exemple:
Dans le cadre d'une expérience sur la durée de vie des piles, le but est de déterminer la durée de vie en fonction du type de pile. Comme on sait que les piles ont une durée de vie qui dépend de la température d'utilisation, une analyse à deux facteurs (type de pile et température d'utilisation) est crée. Les résultats sont dans le tableau suivant:

	Température		
	15°C	**70°C**	**125°C**
Type 1	130 155 74 180	34 40 80 75	20 70 82 58
Type 2	150 188 159 126	136 122 106 115	25 70 58 45
Type 3	138 110 168 160	174 120 150 139	96 104 82 60

Sous SPSS 25: au début, à partir de la table précédente, vous devez créer trois variables: X=durée de vie, F1=type de pile et F2=température. Ensuite, suivez le chemin suivant: Analyse > Modèle linéaire général > Univarié.



On peut aussi faire des comparaisons multiples (Post Hoc) pour chaque facteur séparé si son test associé est significatif, (rejet de H_0).

F1

Tests post hoc

Comparaisons multiples :

Variable dépendante: X

Différence significative de Tukey

(I) F1	(J) F1	Différence moyenne (I-J)	Erreur standard	Signification	Intervalle de confiance à 95 % Borne inférieure	Borne supérieure
1	2	-27,45*	10,460	,036	-53,38	-1,51
	3	-40,74*	10,907	,002	-67,79	-13,70
2	1	27,45*	10,460	,036	1,51	53,38
	3	-13,29	10,705	,440	-39,84	0 13,25
3	1	40,74*	10,907	,002	13,70	67,79
	2	13,29	10,705	,440	-13,25	0 39,84

F2

Tests post hoc

Comparaisons multiples :

Variable dépendante: X

Différence significative de Tukey

(I) F2	(J) F2	Différence moyenne (I-J)	Erreur standard	Signification	Intervalle de confiance à 95 % Borne inférieure	Borne supérieure
15	70	37,25*	10,667	,005	10,80	63,70
	125	80,67*	10,667	,000	54,22	107,12
70	15	-37,25*	10,667	,005	-63,70	-10,80
	125	43,42*	10,667	,001	16,97	69,87
125	15	-80,67*	10,667	,000	-107,12	-54,22
	70	-43,42*	10,667	,001	-69,87	-16,97

6.6 TP 4 sous SPSS 25

Exercice 1 (Modèle linéaire simple)
L'analyse de la température X de fonctionnement d'un procédé chimique sur. le rendement du produit Y a donné les mesures suivantes:

Température °C	Rendement %
100	45
110	51
120	54
130	61
140	66

Température °C	Rendement %
150	70
160	74
170	78
180	85
190	89

1. Tester la significativité du coefficient de corrélation entre X et Y.
2. Estimer les paramètres de la droite de régression linéaire de Y en X.

Exercice 2 (Modèle linéaire multiple)
On étudie l'influence des heures de travail X_1 et du capital X_2 utilisé sur la production industrielle Y. Pour cela, on dispose des observations de neuf entreprises résumées dans le fichier **Excel** nommé **TP4**.

1. Trouver l'équation de la régression multiple de Y sur X_1 et X_2.
2. Tester la significativité globale de cette régression.

Exercice 3 (ANOVA à un facteur)
Pour définir l'impact de F la nature du sol sur la croissance X d'une plante, un botaniste a mesuré la hauteur des plantes pour quatre types de sol:

Type (1)	Type (2)	Type (3)	Type (4)
15	25	17	10
9	21	23	13
4	19	20	16

1. Tester l'homogénéité des variances et la normalité des données.
2. La croissance de la plante X est-elle dépendante de la nature du sol?

Exercice 4 (ANOVA à deux facteurs)
Un expérimentateur s'intéresse à la qualité sensorielle de la viande bovine selon la nature de l'herbe pâturée et la durée d'alimentation à base d'ensilage de maïs. Il peut disposer de trois types d'herbe: (H1=Trifolium preatense), (H2=Festuca arundinacea) et (H3=Bromus inermis). Il expérimentera quatre durées d'alimentation: (D1=30 jours), (D2=40 jours), (D3=50 jours) et (D4=60 jours). La caractéristique étudiée est un indice de flaveur (herbe) dans la viande (sur une échelle de 0 à 10). Les résultats sont:

	$D1$	$D2$	$D3$	$D4$
$H1$	7	7	4	4
	4	6	4	3
	7	8	6	6
$H2$	5	5	3	1
	6	5	3	2
	6	4	1	2
$H3$	7	6	5	2
	7	7	5	3
	8	8	4	6

1. Y a-t-il un effet (type d'herbe)?
2. Y a-t-il un effet (durée d'alimentation en maïs)?
3. Y a-t-il une interaction (type d'herbe*durée d'alimentation en maïs)?
4. Effectuer des comparaisons multiples (Post Hoc) pour chaque facteur et conclure.

Exercice 5 (ANOVA à mesures répétées à un facteur)
Un chercheur veut évaluer l'effet de quatre médicaments sur le temps de réaction des patients dans une série de tests. Cinq sujets différents participent à l'expérience et la performance de chacun est mesurée sous l'effet de chaque médicament, l'ordre d'administration étant réparti de façon aléatoire et avec un délai suffisant entre chacun.

Sujet	Médicament (1)	Médicament (2)	Médicament (3)	Médicament (4)
(1)	16	28	30	34
(2)	10	18	14	22
(3)	18	20	24	30
(4)	20	34	38	44
(5)	14	28	26	30

1. Tester l'homogénéité des variances et la normalité des données.
2. Établir une analyse ANOVA à mesures répétées à un facteur et interpréter ces résultats.

View publication stats

Université Mohammed Premier
Faculté des Sciences Oujda
Département de Mathématiques

Cours et Travaux Pratiques

BIOSTATISTIQUE SOUS SPSS 25

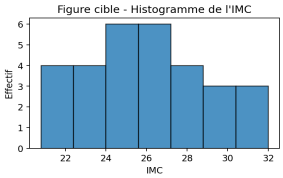
Travaux Pratiques complémentaires - Niveau Master

Master SASA - Semestre 2

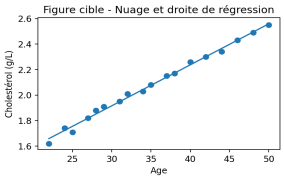
TP 1	Statistique descriptive univariée : codage, fréquences, histogramme, position et dispersion.
TP 2	Statistique descriptive bivariée : tableaux croisés, boîtes à moustaches, corrélation et régression.
TP 3	Échantillonnage et estimation : estimations ponctuelles et intervalles de confiance.
TP 4	Tests d'hypothèses : normalité, khi-deux, test t indépendant et test t apparié.
TP 5	Modèles linéaires : régression simple, régression multiple et diagnostics des résidus.
TP 6	ANOVA : un facteur et mesures répétées.
TP 7	ANOVA à deux facteurs : effets principaux, interaction et comparaisons multiples.

Consigne générale. Chaque TP doit être réalisé sous SPSS 25. Le compte rendu doit contenir les tableaux utiles, les graphiques demandés, les hypothèses statistiques, les p-values, les intervalles de confiance et une interprétation en langage statistique.

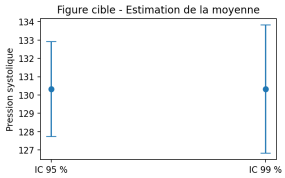
Enseignant : SGHIR AISSA



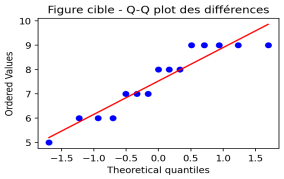
TP1



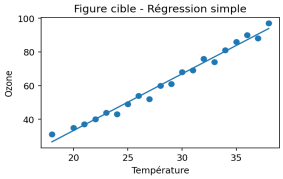
TP2



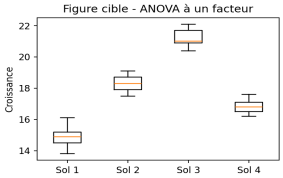
TP3



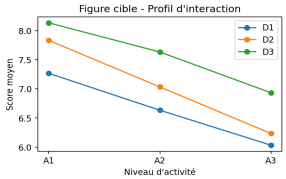
TP4



TP5



TP6



TP7

TP 1 - Statistique descriptive univariée

Objectif. Construire correctement une base SPSS, distinguer variables qualitatives et quantitatives, produire les résumés numériques et graphiques adaptés, puis interpréter les résultats.

Partie A - Variable qualitative nominale. On observe le groupe sanguin de 30 étudiants :

A	O	B	A	AB	O	A	B	O	A
A	O	B	AB	O	A	B	O	A	O
A	B	O	AB	A	O	B	A	O	A

1. Créer la variable Groupe, définir ses étiquettes et son niveau de mesure, puis construire le tableau des effectifs, fréquences et pourcentages.
2. Déterminer le mode et construire un diagramme en secteurs portant les pourcentages. Donner un titre scientifique au graphique.

Partie B - Variable quantitative continue. Les 30 valeurs de l'IMC (kg/m²) sont :

21.4	23.1	24.8	25.5	26.1	22.7	27.3	28.4	24.2	23.9
26.8	29.1	31.2	22.1	20.8	24.9	25.7	27.8	28.9	30.4
23.4	24.6	26.5	27.1	29.8	21.9	25.2	26.9	28.1	32.0

3. Calculer moyenne, médiane, variance, écart type, minimum, maximum et quartiles. Comparer moyenne et médiane et commenter l'asymétrie éventuelle.
4. Regrouper l'IMC en quatre classes pertinentes avec Transformer > Regroupement visuel. Construire le tableau des classes.
5. Tracer l'histogramme des effectifs de l'IMC et une boîte à moustaches. Identifier d'éventuelles valeurs atypiques.

Figure cible - Groupe sanguin

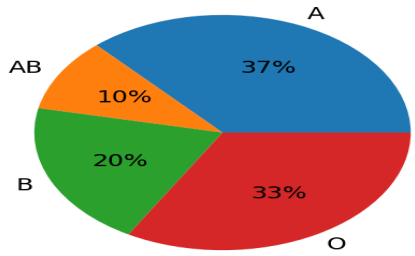
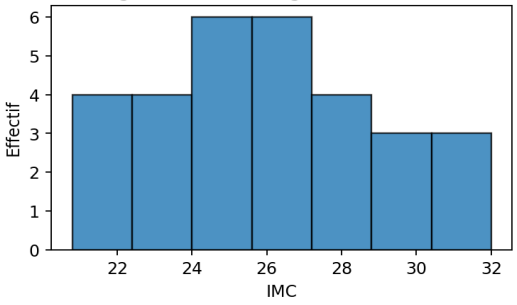


Figure cible - Histogramme de l'IMC



Sous SPSS 25 : Analyse > Statistiques descriptives > Fréquences / Descriptives ; Transformer > Regroupement visuel ; Graphiques > Générateur de diagrammes.

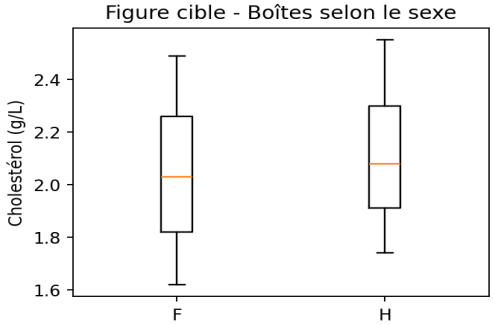
TP 2 - Statistique descriptive bivariée

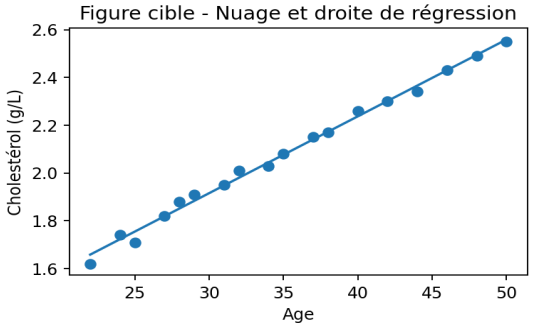
Objectif. Étudier les liaisons entre deux variables selon leur nature : qualitative-qualitative, quantitative-qualitative et quantitative-quantitative.

On dispose des observations suivantes :

Age	Chol.	Sexe	Tabac
22	1.62	F	Non
24	1.74	H	Oui
25	1.71	F	Non
27	1.82	F	Non
28	1.88	H	Oui
29	1.91	H	Oui
31	1.95	F	Non
32	2.01	H	Non
34	2.03	F	Non
35	2.08	H	Oui
37	2.15	F	Non
38	2.17	H	Oui
40	2.26	F	Non
42	2.30	H	Oui
44	2.34	F	Non
46	2.43	H	Oui
48	2.49	F	Non
50	2.55	H	Oui

1. Construire le tableau de contingence Sexe × Tabac avec effectifs, pourcentages en ligne et en colonne. Décrire l'association observée sans effectuer encore de test d'hypothèse.
2. Comparer la distribution du cholestérol selon le sexe à l'aide de statistiques descriptives par groupe et de boîtes à moustaches.
3. Calculer la covariance et le coefficient de corrélation de Pearson entre l'âge et le cholestérol. Interpréter le signe et l'intensité de la liaison.
4. Tracer le nuage de points Age-Cholestérol, ajouter la droite de régression linéaire et afficher l'équation et le coefficient R^2.
5. Estimer le cholestérol attendu à 45 ans à partir du modèle ajusté et commenter la pertinence de cette prédiction.





Sous SPSS 25 : Analyse > Statistiques descriptives > Tableaux croisés ; Graphiques > Générateur de diagrammes > Boîte à moustaches / Nuage de points ; Analyse > Corrélation > Bivariée.

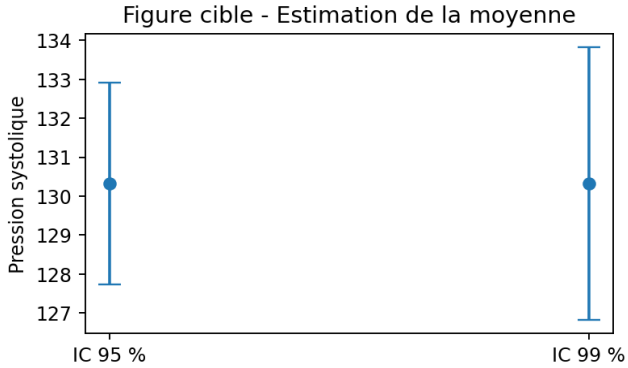
TP 3 - Échantillonnage et estimation

Objectif. Relier estimation ponctuelle, erreur standard et intervalle de confiance, et étudier l'effet du niveau de confiance sur la précision.

La pression artérielle systolique (mmHg) de 25 sujets est :

121	128	132	125	136	139	118	130	127
134	141	126	129	133	137	124	122	135
138	131	128	129	140	123	132		

1. Déterminer les estimations ponctuelles de la moyenne, de la variance et de l'écart type de la population.
2. Construire les intervalles de confiance à 95 % et à 99 % pour la moyenne. Comparer leurs amplitudes et expliquer la différence.
3. Tester, dans la même procédure, la valeur de référence μ_0=130 mmHg. Donner H_0, H_1, la statistique t, les degrés de liberté, la p-value et la conclusion.
4. Créer une variable qualitative HTA prenant la valeur 1 si la pression est ≥140 et 0 sinon. Estimer la proportion observée de sujets HTA.
5. En supposant que cette proportion provient d'un grand échantillon, expliquer comment un intervalle de confiance pour une proportion serait construit et quelles informations SPSS fournit directement ou indirectement.
6. Rédiger une conclusion statistique en distinguant clairement estimation ponctuelle, précision de l'estimation et test d'une valeur de référence.



Sous SPSS 25 : Analyse > Comparer les moyennes > Test T pour échantillon unique ; Options > Intervalle de confiance ; Analyse > Statistiques descriptives > Fréquences.

TP 4 - Tests d'hypothèses : normalité, indépendance et comparaison de moyennes

Objectif. Choisir le test adapté à la structure des données et vérifier les hypothèses avant de conclure.

A. Données appariées. Pression systolique avant et après traitement chez 15 patients :

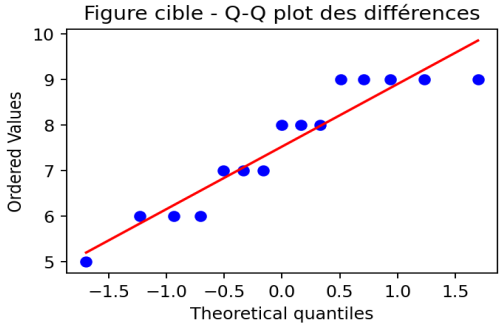
Sujet	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Avant	154	149	162	158	151	166	160	157	153	164	150	159	161	155	163
Après	145	143	154	149	146	157	151	150	147	155	144	151	153	148	156

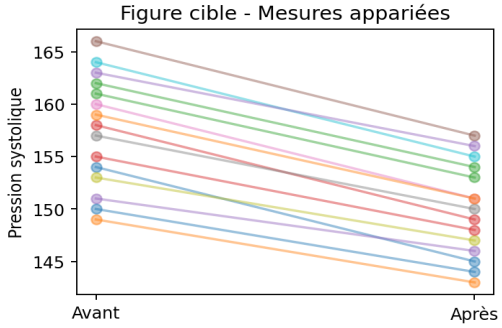
1. Créer la variable Diff=Avant-Après. Tester sa normalité par le test de Shapiro-Wilk et compléter le diagnostic par un Q-Q plot.
2. Effectuer un test t pour échantillons appariés au seuil 5 %. Donner l'intervalle de confiance de la différence moyenne et conclure sur l'effet du traitement.
3. Expliquer pourquoi traiter Avant et Après comme deux échantillons indépendants serait méthodologiquement incorrect.

B. Deux variables qualitatives. Dans une enquête, on observe :

	Amélioration forte	Modérée	Faible
Traitement A	28	16	6
Traitement B	18	20	12

4. Saisir le tableau sous forme agrégée avec une variable Effectif, puis pondérer les observations.
5. Appliquer le test d'indépendance du khi-deux entre traitement et amélioration. Vérifier les effectifs théoriques et interpréter la p-value.





Sous SPSS 25 : Analyse > Statistiques descriptives > Explorer (normalité) ; Analyse > Comparer les moyennes > Test T pour échantillons appariés ; Analyse > Statistiques descriptives > Tableaux croisés > Statistiques > Khi-deux.

TP 5 - Modèles linéaires simple et multiple

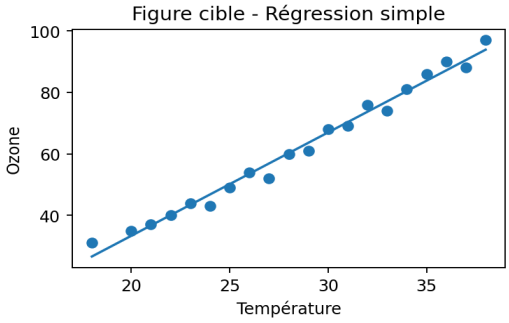
Objectif. Ajuster, tester et diagnostiquer un modèle linéaire, puis comparer l'apport d'un deuxième prédicteur.

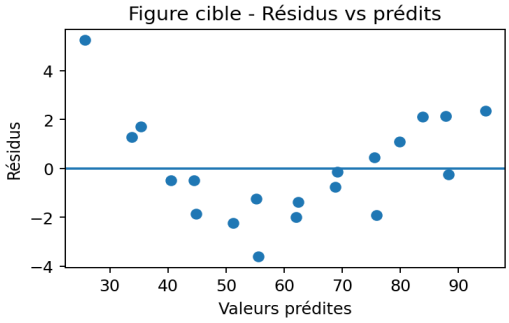
On étudie la concentration d'ozone Y en fonction de la température X_1 et de la vitesse du vent X_2 :

T	Vent	Ozone
18	14	31
20	12	35
21	13	37
22	11	40
23	10	44
24	12	43
25	9	49
26	8	54
27	10	52
28	7	60

T	Vent	Ozone
29	9	61
30	6	68
31	8	69
32	5	76
33	7	74
34	6	81
35	5	86
36	4	90
37	6	88
38	3	97

1. Ajuster la régression linéaire simple de l'ozone sur la température. Tester la significativité du coefficient de corrélation, de la pente et du modèle global.
2. Donner l'équation ajustée, R^2, l'intervalle de confiance à 95 % de la pente et la prédiction de Y pour $X_1=30$.
3. Ajuster ensuite le modèle multiple $Y=a_0+a_1X_1+a_2X_2+\varepsilon$. Comparer R^2 et R^2 ajusté au modèle simple.
4. Interpréter séparément a_1 et a_2 : que signifie un coefficient lorsque l'autre prédicteur est maintenu constant ?
5. Enregistrer valeurs prédites et résidus. Tracer les résidus standardisés en fonction des valeurs prédites et examiner la normalité des résidus.
6. Conclure sur l'intérêt de l'ajout de la vitesse du vent et sur les limites éventuelles du modèle.





Sous SPSS 25 : Analyse > Régression > Linéaire ; Statistiques : estimations, ajustement du modèle, IC ; Enregistrer : valeurs prédites et résidus ; Graphiques : résidus vs prédits.

TP 6 - ANOVA à un facteur et ANOVA à mesures répétées

Objectif. Distinguer plan indépendant et plan répété, vérifier les conditions d'application et interpréter les effets globaux avant les comparaisons.

A. ANOVA à un facteur. Croissance de plantes sous quatre types de sol :

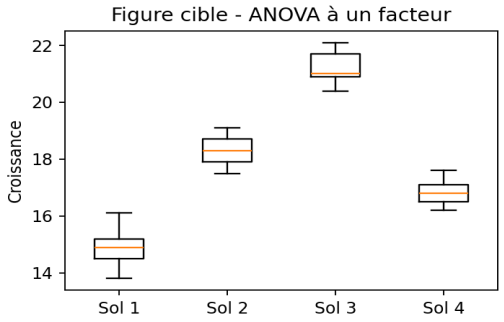
Sol 1	Sol 2	Sol 3	Sol 4
14.5	18.3	21.0	16.8
15.2	17.9	20.4	17.1
13.8	19.1	22.1	16.2
16.1	18.7	21.7	17.6
14.9	17.5	20.9	16.5

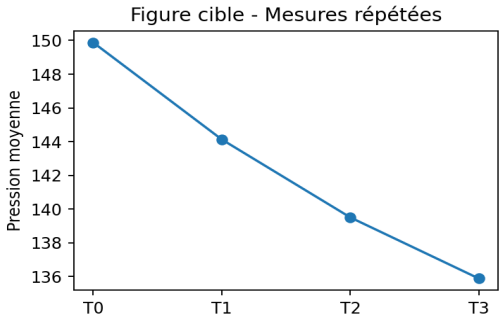
1. Mettre les données au format adapté à l'ANOVA à un facteur. Décrire chaque groupe par moyenne, écart type et boîte à moustaches.
2. Tester la normalité dans chaque groupe et l'homogénéité des variances. Formuler H_0 et H_1 de l'ANOVA.
3. Effectuer l'ANOVA. Si l'effet global est significatif, réaliser des comparaisons multiples Post Hoc adaptées et identifier les groupes différents.

B. Mesures répétées. Pression systolique de 8 patients mesurée à quatre temps :

Sujet	T0	T1	T2	T3
1	142	136	131	128
2	150	145	140	136
3	147	141	137	133
4	155	149	144	140
5	160	153	148	145
6	148	143	139	135
7	152	146	142	138
8	145	140	135	132

4. Définir un facteur intra-sujet Temps à quatre niveaux et effectuer l'ANOVA à mesures répétées.
5. Examiner le profil des moyennes au cours du temps et interpréter l'effet du temps. Effectuer les comparaisons deux à deux proposées par SPSS avec correction appropriée.





Sous SPSS 25 : Analyse > Comparer les moyennes > ANOVA à un facteur ; Post Hoc ; Analyse > Modèle linéaire général > Mesures répétées.

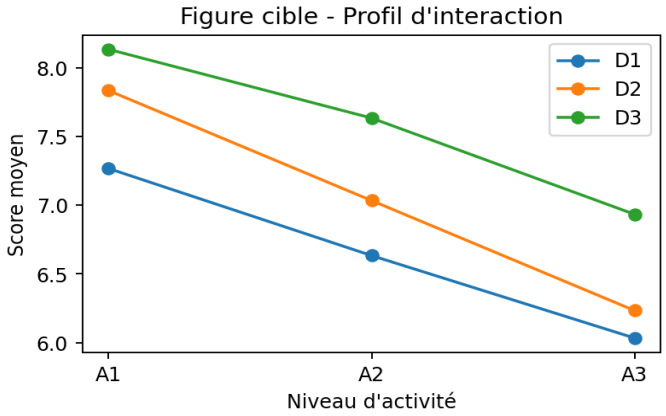
TP 7 - ANOVA à deux facteurs et interaction

Objectif. Étudier simultanément deux facteurs, distinguer effets principaux et interaction, et utiliser un profil d'interaction pour guider l'interprétation.

On étudie un score métabolique selon trois régimes alimentaires (D1, D2, D3) et trois niveaux d'activité physique (A1, A2, A3). Trois sujets sont observés dans chaque combinaison :

Régime	Activité	R1	R2	R3
D1	A1	7.2	7.5	7.1
D1	A2	6.6	6.8	6.5
D1	A3	6.0	6.2	5.9
D2	A1	7.8	8.0	7.7
D2	A2	7.0	7.2	6.9
D2	A3	6.1	6.4	6.2
D3	A1	8.1	8.3	8.0
D3	A2	7.6	7.8	7.5
D3	A3	6.9	7.1	6.8

1. Mettre les données au format long avec les variables Score, Régime et Activité. Définir correctement le niveau de mesure de chaque variable.
2. Produire les moyennes et écarts types dans les neuf cellules du plan, puis construire un graphique des moyennes par activité pour chaque régime.
3. Effectuer une ANOVA à deux facteurs incluant le terme d'interaction Régime*Activité. Tester successivement l'effet du régime, l'effet de l'activité et l'interaction.
4. Si l'interaction est significative, expliquer pourquoi l'interprétation isolée des effets principaux doit être prudente. Utiliser le graphique de profil pour décrire le sens de l'interaction.
5. Effectuer les comparaisons multiples appropriées pour les facteurs présentant un effet significatif et rapporter les différences avec leurs intervalles de confiance.
6. Rédiger une conclusion de type article scientifique : statistiques F, degrés de liberté, p-values, effets significatifs et interprétation biologique.



Sous SPSS 25 : Analyse > Modèle linéaire général > Univarié ; Modèle : effets principaux + interaction ; Post Hoc ; Graphiques : profils estimés.