Université Mohammed Premier
Faculté des Sciences - Oujda
Département de Mathématiques

BIOSTATISTIQUE SOUS SPSS 25

Cours et Travaux Pratiques - corrections détaillées

Master SASA - Semestre 2	Année universitaire : 2025-2026

Énoncés originaux et corrections détaillées

TP 1	Statistique descriptive univariée
TP 2	Statistique descriptive bivariée
TP 3	Échantillonnage et estimation
TP 4	Tests d'hypothèses : normalité, indépendance et comparaison de moyennes
TP 5	Modèles linéaires simple et multiple
TP 6	ANOVA à un facteur et ANOVA à mesures répétées
TP 7	ANOVA à deux facteurs et interaction

Enseignant : SGHIR AISSA
a.sghir@ump.ac.ma

Chaque TP est suivi de sa correction : code ou procédure, résultats numériques, graphiques et interprétation.

TP 1 - Statistique descriptive univariée

Objectif. Construire correctement une base SPSS, distinguer variables qualitatives et quantitatives, produire les résumés numériques et graphiques adaptés, puis interpréter les résultats.

Partie A - Variable qualitative nominale. On observe le groupe sanguin de 30 étudiants :

A	O	B	A	AB	O	A	B	O	A
A	O	B	AB	O	A	B	O	A	O
A	B	O	AB	A	O	B	A	O	A

1. Créer la variable Groupe, définir ses étiquettes et son niveau de mesure, puis construire le tableau des effectifs, fréquences et pourcentages.
2. Déterminer le mode et construire un diagramme en secteurs portant les pourcentages. Donner un titre scientifique au graphique.

Partie B - Variable quantitative continue. Les 30 valeurs de l'IMC (kg/m²) sont :

21.4	23.1	24.8	25.5	26.1	22.7	27.3	28.4	24.2	23.9
26.8	29.1	31.2	22.1	20.8	24.9	25.7	27.8	28.9	30.4
23.4	24.6	26.5	27.1	29.8	21.9	25.2	26.9	28.1	32.0

3. Calculer moyenne, médiane, variance, écart type, minimum, maximum et quartiles. Comparer moyenne et médiane et commenter l'asymétrie éventuelle.
4. Regrouper l'IMC en quatre classes pertinentes avec Transformer > Regroupement visuel. Construire le tableau des classes.
5. Tracer l'histogramme des effectifs de l'IMC et une boîte à moustaches. Identifier d'éventuelles valeurs atypiques.

Figure cible - Groupe sanguin

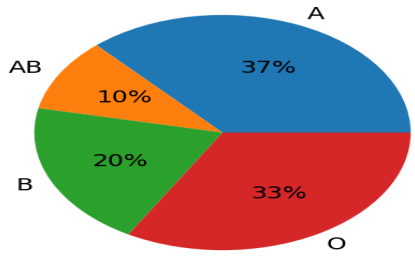
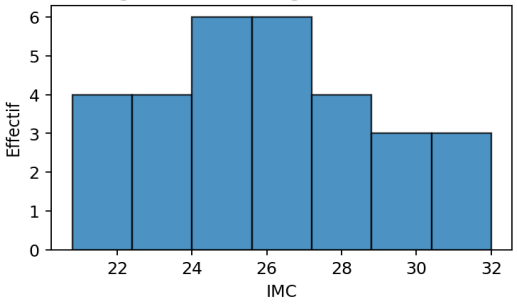


Figure cible - Histogramme de l'IMC



Sous SPSS 25 : Analyse > Statistiques descriptives > Fréquences / Descriptives ; Transformer > Regroupement visuel ; Graphiques > Générateur de diagrammes.

Correction détaillée - TP 1

Statistique descriptive univariée

Partie A - Variable qualitative

Effectifs : A=11, O=10, B=6, AB=3, soit 36,67 %, 33,33 %, 20 % et 10 %. Le mode est A. Sous SPSS : Analyse > Statistiques descriptives > Fréquences ; demander fréquences, pourcentages et diagramme en secteurs.

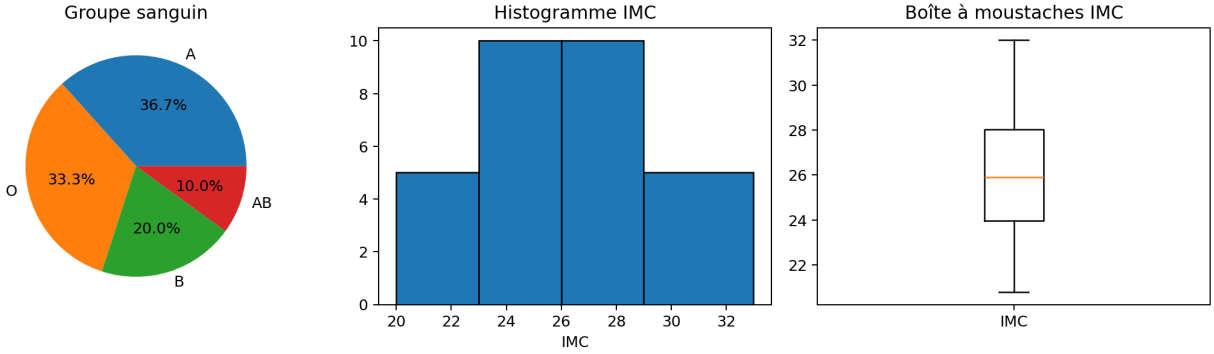
Partie B - IMC

Pour les 30 IMC : moyenne=26,02, médiane=25,90, variance échantillonnale=8,7030, écart type=2,9501, minimum=20,8, maximum=32,0, Q1≈23,975 et Q3≈28,025. La proximité moyenne-médiane indique une asymétrie faible.

Avec les classes [20,23[, [23,26[, [26,29[, [29,33], les effectifs sont 5, 10, 10, 5. La boîte à moustaches ne signale pas de valeur très atypique selon la règle 1,5×IQR.

```
SPSS :
Analyse > Statistiques descriptives > Fréquences / Descriptives
Transformer > Regroupement visuel
Graphiques > Générateur de diagrammes > Histogramme / Boîte à moustaches
```

Graphique(s) de correction



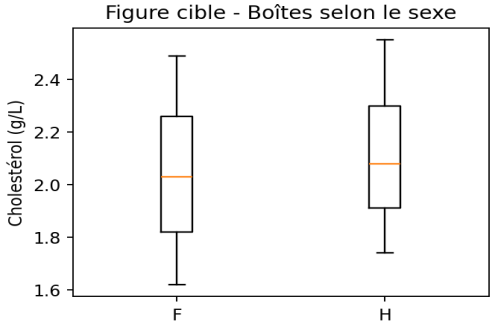
TP 2 - Statistique descriptive bivariée

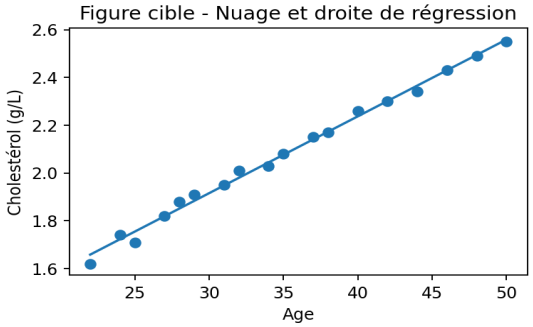
Objectif. Étudier les liaisons entre deux variables selon leur nature : qualitative-qualitative, quantitative-qualitative et quantitative-quantitative.

On dispose des observations suivantes :

Age	Chol.	Sexe	Tabac
22	1.62	F	Non
24	1.74	H	Oui
25	1.71	F	Non
27	1.82	F	Non
28	1.88	H	Oui
29	1.91	H	Oui
31	1.95	F	Non
32	2.01	H	Non
34	2.03	F	Non
35	2.08	H	Oui
37	2.15	F	Non
38	2.17	H	Oui
40	2.26	F	Non
42	2.30	H	Oui
44	2.34	F	Non
46	2.43	H	Oui
48	2.49	F	Non
50	2.55	H	Oui

1. Construire le tableau de contingence Sexe × Tabac avec effectifs, pourcentages en ligne et en colonne. Décrire l'association observée sans effectuer encore de test d'hypothèse.
2. Comparer la distribution du cholestérol selon le sexe à l'aide de statistiques descriptives par groupe et de boîtes à moustaches.
3. Calculer la covariance et le coefficient de corrélation de Pearson entre l'âge et le cholestérol. Interpréter le signe et l'intensité de la liaison.
4. Tracer le nuage de points Age-Cholestérol, ajouter la droite de régression linéaire et afficher l'équation et le coefficient R^2.
5. Estimer le cholestérol attendu à 45 ans à partir du modèle ajusté et commenter la pertinence de cette prédiction.





Sous SPSS 25 : Analyse > Statistiques descriptives > Tableaux croisés ; Graphiques > Générateur de diagrammes > Boîte à moustaches / Nuage de points ; Analyse > Corrélation > Bivariée.

Correction détaillée - TP 2

Statistique descriptive bivariée

1. Tableau Sexe × Tabac

Effectifs : femmes : 9 Non, 0 Oui ; hommes : 1 Non, 8 Oui. Pourcentages en ligne : F = 100 % Non, 0 % Oui ; H = 11,11 % Non, 88,89 % Oui. Pourcentages en colonne : parmi les Non-fumeurs, 90 % sont F et 10 % H ; parmi les fumeurs, 100 % sont H. L'association descriptive est donc très marquée.

2. Cholestérol selon le sexe

Femmes : n=9, moyenne≈2,0411, médiane=2,03, écart type≈0,2947. Hommes : n=9, moyenne≈2,1189, médiane=2,08, écart type≈0,2683. Les boîtes se recouvrent largement malgré une moyenne masculine un peu plus élevée.

3. Âge et cholestérol

Covariance échantillonnale≈2,36, corrélation de Pearson r≈0,99698 : liaison linéaire positive extrêmement forte. Régression : Chol ≈ 0,95107 + 0,032153×Âge, R^2≈0,99398.

À 45 ans, la prédiction est ≈ 2,398. Comme 45 appartient à l'intervalle observé [22,50], il s'agit d'une interpolation, donc d'une prédiction raisonnable sous le modèle.

```
SPSS : Analyse > Corrélation > Bivariée (Pearson)
Analyse > Régression > Linéaire : Chol comme dépendante, Age comme prédicteur
```

Graphique(s) de correction





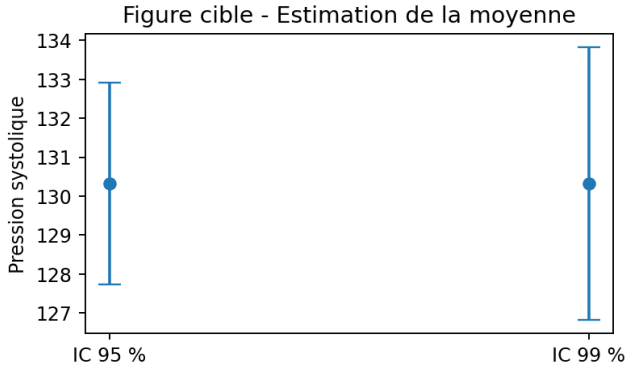
TP 3 - Échantillonnage et estimation

Objectif. Relier estimation ponctuelle, erreur standard et intervalle de confiance, et étudier l'effet du niveau de confiance sur la précision.

La pression artérielle systolique (mmHg) de 25 sujets est :

121	128	132	125	136	139	118	130	127
134	141	126	129	133	137	124	122	135
138	131	128	129	140	123	132		

1. Déterminer les estimations ponctuelles de la moyenne, de la variance et de l'écart type de la population.
2. Construire les intervalles de confiance à 95 % et à 99 % pour la moyenne. Comparer leurs amplitudes et expliquer la différence.
3. Tester, dans la même procédure, la valeur de référence μ_0=130 mmHg. Donner H_0, H_1, la statistique t, les degrés de liberté, la p-value et la conclusion.
4. Créer une variable qualitative HTA prenant la valeur 1 si la pression est ≥140 et 0 sinon. Estimer la proportion observée de sujets HTA.
5. En supposant que cette proportion provient d'un grand échantillon, expliquer comment un intervalle de confiance pour une proportion serait construit et quelles informations SPSS fournit directement ou indirectement.
6. Rédiger une conclusion statistique en distinguant clairement estimation ponctuelle, précision de l'estimation et test d'une valeur de référence.



Sous SPSS 25 : Analyse > Comparer les moyennes > Test T pour échantillon unique ; Options > Intervalle de confiance ; Analyse > Statistiques descriptives > Fréquences.

Correction détaillée - TP 3

Échantillonnage et estimation

1. Estimations ponctuelles

n=25 ; moyenne=130,32 mmHg ; variance échantillonnale=39,2267 ; écart type=6,2631.

2. Intervalles de confiance

IC95% de la moyenne : [127,735 ; 132,905]. IC99% : [126,816 ; 133,824]. L'IC99% est plus large car un niveau de confiance supérieur exige une marge d'erreur plus grande.

3. Test de mu0=130

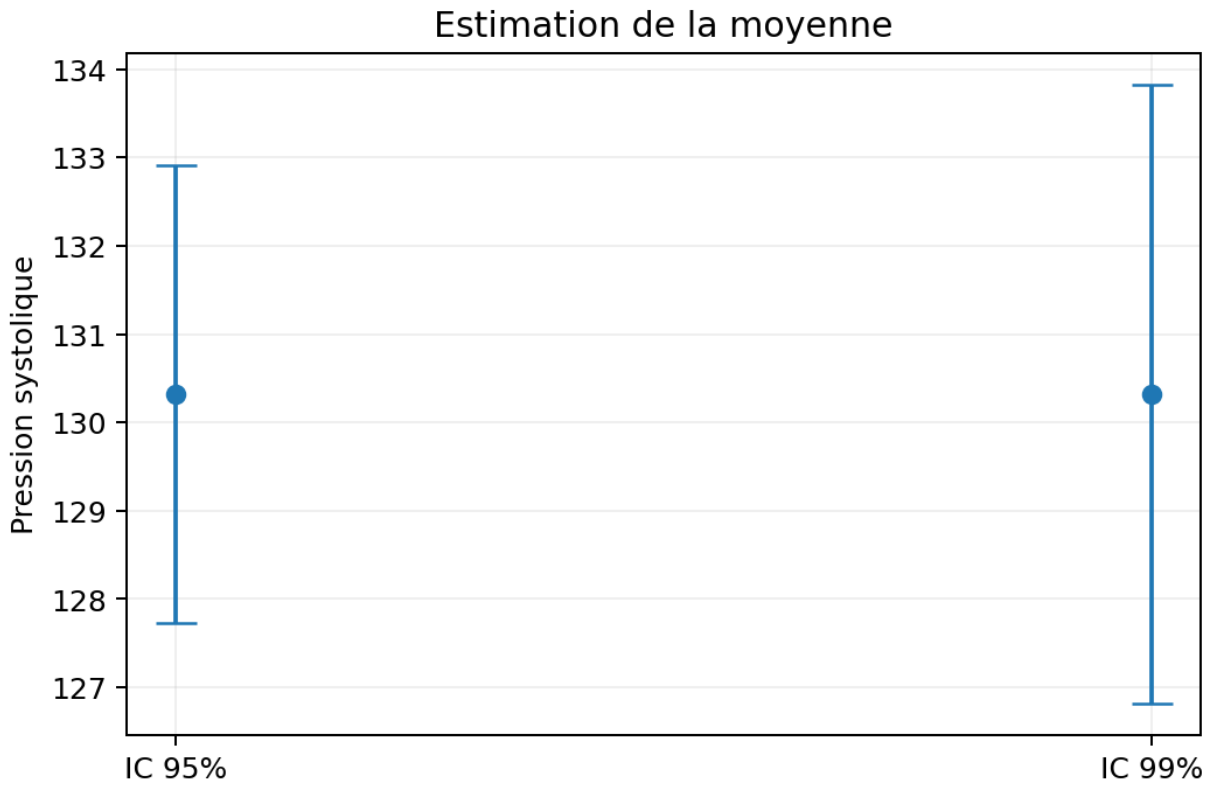
H0 : mu=130 ; H1 : mu≠130. Statistique t≈0,2555, ddl=24, p≈0,8005. On ne rejette pas H0 : les données sont compatibles avec une moyenne de 130 mmHg.

4. Proportion HTA

Deux sujets ont une pression ≥140, donc p-hat=2/25=0,08. Pour un grand échantillon, un IC approximatif serait p-hat ± z(alpha/2)√(p-hat(1-p-hat)/n). Ici n=25 et np-hat=2 : l'approximation normale est fragile ; un intervalle binomial exact ou de Wilson serait préférable.

```
SPSS : Analyse > Comparer les moyennes > Test T pour échantillon unique
Valeur test = 130 ; Options = IC 95% puis 99%
Analyse > Statistiques descriptives > Fréquences pour HTA
```

Graphique(s) de correction



TP 4 - Tests d'hypothèses : normalité, indépendance et comparaison de moyennes

Objectif. Choisir le test adapté à la structure des données et vérifier les hypothèses avant de conclure.

A. Données appariées. Pression systolique avant et après traitement chez 15 patients :

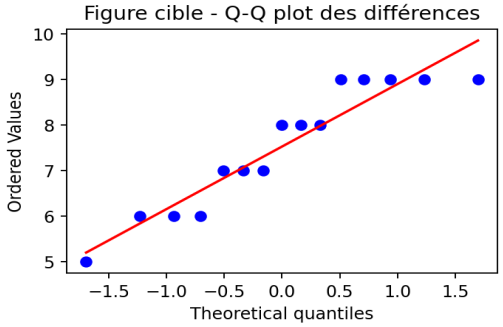
Sujet	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Avant	154	149	162	158	151	166	160	157	153	164	150	159	161	155	163
Après	145	143	154	149	146	157	151	150	147	155	144	151	153	148	156

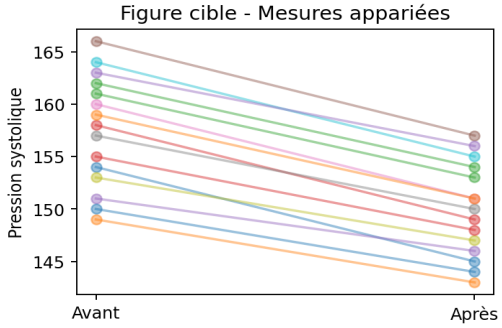
1. Créer la variable Diff=Avant-Après. Tester sa normalité par le test de Shapiro-Wilk et compléter le diagnostic par un Q-Q plot.
2. Effectuer un test t pour échantillons appariés au seuil 5 %. Donner l'intervalle de confiance de la différence moyenne et conclure sur l'effet du traitement.
3. Expliquer pourquoi traiter Avant et Après comme deux échantillons indépendants serait méthodologiquement incorrect.

B. Deux variables qualitatives. Dans une enquête, on observe :

	Amélioration forte	Modérée	Faible
Traitement A	28	16	6
Traitement B	18	20	12

4. Saisir le tableau sous forme agrégée avec une variable Effectif, puis pondérer les observations.
5. Appliquer le test d'indépendance du khi-deux entre traitement et amélioration. Vérifier les effectifs théoriques et interpréter la p-value.





Sous SPSS 25 : Analyse > Statistiques descriptives > Explorer (normalité) ; Analyse > Comparer les moyennes > Test T pour échantillons appariés ; Analyse > Statistiques descriptives > Tableaux croisés > Statistiques > Khi-deux.

Correction détaillée - TP 4

Tests d’hypothèses : normalité, indépendance et comparaison de moyennes

A. Données appariées

Les différences Avant-Après sont : 9, 6, 8, 9, 5, 9, 9, 7, 6, 9, 6, 8, 8, 7, 7. Moyenne=7,533, écart type=1,356. Shapiro-Wilk : W≈0,8826, p≈0,0519 ; au seuil 5 %, la normalité n'est pas rejetée, mais la conclusion est proche de la limite.

Test t apparié : t≈21,520, ddl=14, p≈3,97×10^-12. IC95% de la diminution moyenne : [6,783 ; 8,284] mmHg. Le traitement diminue significativement la pression.

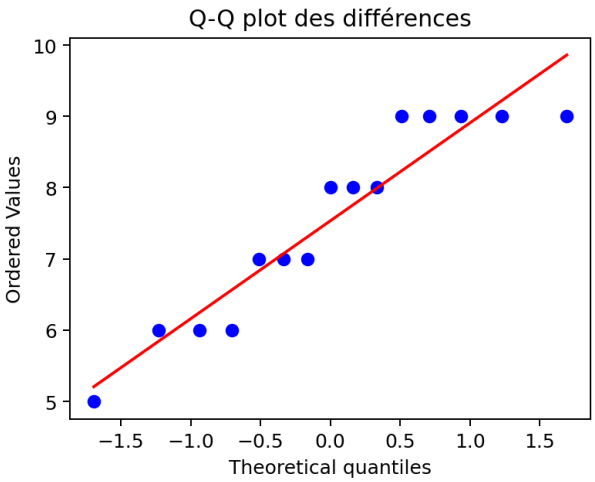
Les observations Avant et Après appartiennent aux mêmes patients : les mesures sont dépendantes. Un test pour échantillons indépendants ignorerait cette structure appariée et gaspillerait l'information intra-sujet.

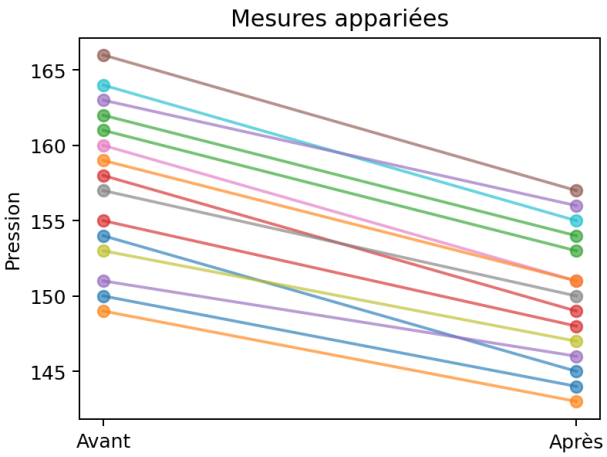
B. Traitement × amélioration

Khi-deux de Pearson : $\chi^2 \approx 4{,}618$, ddl=2, p≈0,0993. Effectifs théoriques : (23,18,9) dans chaque ligne, tous ≥5. Au seuil 5 %, on ne rejette pas l'indépendance entre traitement et niveau d'amélioration.

```
SPSS : Explorer > Graphiques de normalité
Comparer les moyennes > Test T pour échantillons appariés
Tableaux croisés > Statistiques > Khi-deux ; afficher les effectifs théoriques
```

Graphique(s) de correction





TP 5 - Modèles linéaires simple et multiple

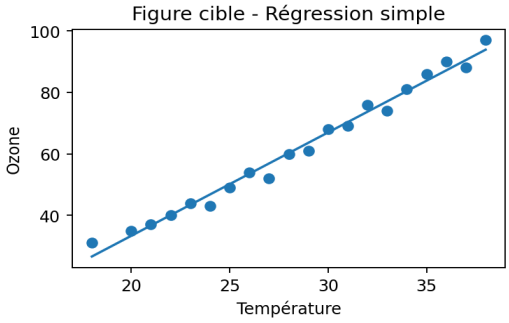
Objectif. Ajuster, tester et diagnostiquer un modèle linéaire, puis comparer l'apport d'un deuxième prédicteur.

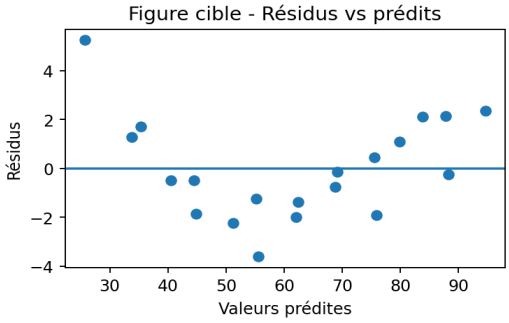
On étudie la concentration d'ozone Y en fonction de la température X_1 et de la vitesse du vent X_2 :

T	Vent	Ozone
18	14	31
20	12	35
21	13	37
22	11	40
23	10	44
24	12	43
25	9	49
26	8	54
27	10	52
28	7	60

T	Vent	Ozone
29	9	61
30	6	68
31	8	69
32	5	76
33	7	74
34	6	81
35	5	86
36	4	90
37	6	88
38	3	97

1. Ajuster la régression linéaire simple de l'ozone sur la température. Tester la significativité du coefficient de corrélation, de la pente et du modèle global.
2. Donner l'équation ajustée, R^2, l'intervalle de confiance à 95 % de la pente et la prédiction de Y pour $X_1=30$.
3. Ajuster ensuite le modèle multiple $Y=a_0+a_1X_1+a_2X_2+\varepsilon$. Comparer R^2 et R^2 ajusté au modèle simple.
4. Interpréter séparément a_1 et a_2 : que signifie un coefficient lorsque l'autre prédicteur est maintenu constant ?
5. Enregistrer valeurs prédites et résidus. Tracer les résidus standardisés en fonction des valeurs prédites et examiner la normalité des résidus.
6. Conclure sur l'intérêt de l'ajout de la vitesse du vent et sur les limites éventuelles du modèle.





Sous SPSS 25 : Analyse > Régression > Linéaire ; Statistiques : estimations, ajustement du modèle, IC ; Enregistrer : valeurs prédites et résidus ; Graphiques : résidus vs prédits.

Correction détaillée - TP 5

Modèles linéaires simple et multiple

1. Régression simple Ozone ~ Température

Équation : $\hat{Y}$ = -33,959 + 3,3641 T. R^2=0,9853 (R^2 ajusté≈0,9844). Test de pente et test global : F≈1203, p<10^-17 ; la relation linéaire est hautement significative. IC95% de la pente : [3,160 ; 3,568]. Pour T=30, $\hat{Y}$≈66,964.

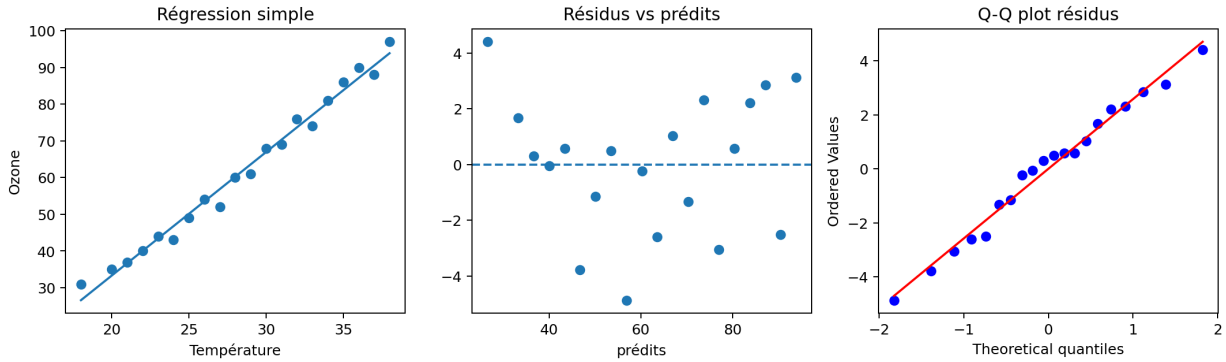
2. Modèle multiple Ozone ~ T + Vent

Équation estimée : $\hat{Y}$ = -7,434 + 2,7813 T - 1,2052 Vent. R^2≈0,9896, R^2 ajusté≈0,9884. À vent constant, +1 °C est associé à +2,781 unités d'ozone ; à température constante, +1 unité de vent est associée à -1,205 unité d'ozone.

L'ajout du vent améliore légèrement R^2. Le coefficient du vent est significatif (p≈0,016). Les diagnostics doivent néanmoins vérifier linéarité, homoscédasticité, normalité des résidus et indépendance.

```
SPSS : Analyse > Régression > Linéaire
Modèle simple : Dépendante Ozone ; Indépendante T
Modèle multiple : T et Vent
Statistiques : estimations, ajustement, IC 95% ; Enregistrer : prédits et résidus
```

Graphique(s) de correction



TP 6 - ANOVA à un facteur et ANOVA à mesures répétées

Objectif. Distinguer plan indépendant et plan répété, vérifier les conditions d'application et interpréter les effets globaux avant les comparaisons.

A. ANOVA à un facteur. Croissance de plantes sous quatre types de sol :

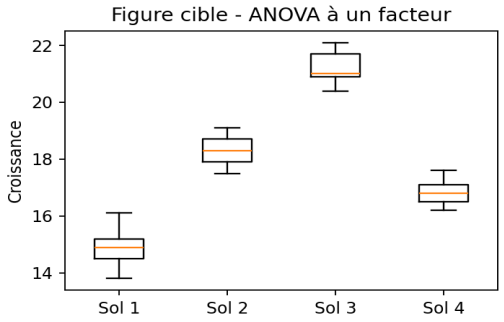
Sol 1	Sol 2	Sol 3	Sol 4
14.5	18.3	21.0	16.8
15.2	17.9	20.4	17.1
13.8	19.1	22.1	16.2
16.1	18.7	21.7	17.6
14.9	17.5	20.9	16.5

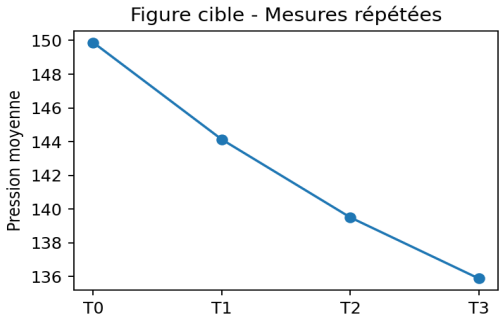
1. Mettre les données au format adapté à l'ANOVA à un facteur. Décrire chaque groupe par moyenne, écart type et boîte à moustaches.
2. Tester la normalité dans chaque groupe et l'homogénéité des variances. Formuler H_0 et H_1 de l'ANOVA.
3. Effectuer l'ANOVA. Si l'effet global est significatif, réaliser des comparaisons multiples Post Hoc adaptées et identifier les groupes différents.

B. Mesures répétées. Pression systolique de 8 patients mesurée à quatre temps :

Sujet	T0	T1	T2	T3
1	142	136	131	128
2	150	145	140	136
3	147	141	137	133
4	155	149	144	140
5	160	153	148	145
6	148	143	139	135
7	152	146	142	138
8	145	140	135	132

4. Définir un facteur intra-sujet Temps à quatre niveaux et effectuer l'ANOVA à mesures répétées.
5. Examiner le profil des moyennes au cours du temps et interpréter l'effet du temps. Effectuer les comparaisons deux à deux proposées par SPSS avec correction appropriée.





Sous SPSS 25 : Analyse > Comparer les moyennes > ANOVA à un facteur ; Post Hoc ; Analyse > Modèle linéaire général > Mesures répétées.

Correction détaillée - TP 6

ANOVA à un facteur et ANOVA à mesures répétées

A. ANOVA à un facteur

Moyennes : Sol1=14,90, Sol2=18,30, Sol3=21,22, Sol4=16,84. Écarts types : 0,851 ; 0,632 ; 0,676 ; 0,541. Les tests de Shapiro-Wilk par groupe ne signalent pas d'écart notable à la normalité ; Levene p≈0,897, donc homogénéité plausible.

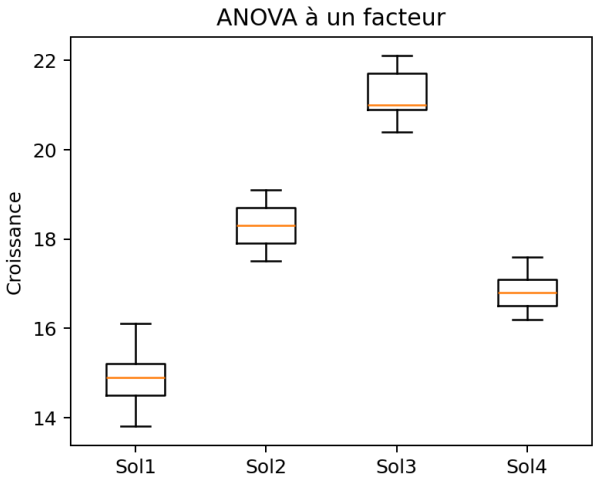
ANOVA : F≈75,652, p≈1,15×10^-9. L'effet du type de sol est significatif. Tukey HSD indique que toutes les paires de sols diffèrent significativement au seuil 5 % pour ces données.

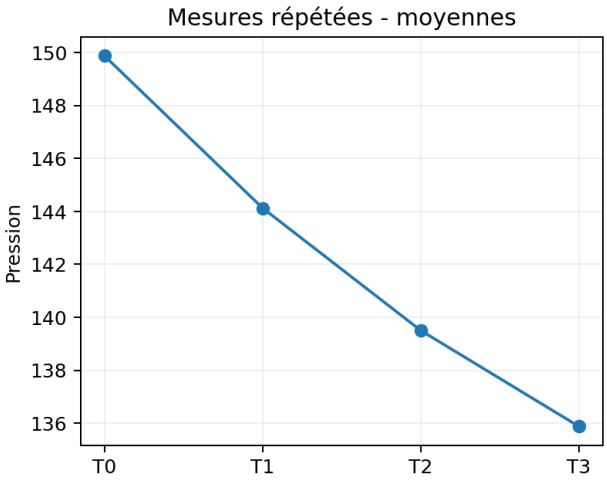
B. Mesures répétées

Moyennes aux temps T0,T1,T2,T3 : 149,875 ; 144,125 ; 139,500 ; 135,875. ANOVA à mesures répétées : F(3,21)≈1320,84, p<0,001. La pression décroît nettement avec le temps. Les comparaisons deux à deux doivent être corrigées (Bonferroni, par exemple).

```
SPSS : ANOVA à un facteur > Post Hoc (Tukey si variances homogènes)
Modèle linéaire général > Mesures répétées ; facteur intra-sujet Temps à 4 niveaux
```

Graphique(s) de correction





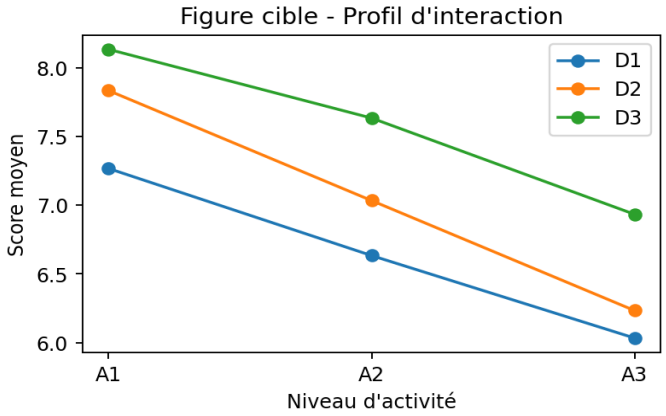
TP 7 - ANOVA à deux facteurs et interaction

Objectif. Étudier simultanément deux facteurs, distinguer effets principaux et interaction, et utiliser un profil d'interaction pour guider l'interprétation.

On étudie un score métabolique selon trois régimes alimentaires (D1, D2, D3) et trois niveaux d'activité physique (A1, A2, A3). Trois sujets sont observés dans chaque combinaison :

Régime	Activité	R1	R2	R3
D1	A1	7.2	7.5	7.1
D1	A2	6.6	6.8	6.5
D1	A3	6.0	6.2	5.9
D2	A1	7.8	8.0	7.7
D2	A2	7.0	7.2	6.9
D2	A3	6.1	6.4	6.2
D3	A1	8.1	8.3	8.0
D3	A2	7.6	7.8	7.5
D3	A3	6.9	7.1	6.8

1. Mettre les données au format long avec les variables Score, Régime et Activité. Définir correctement le niveau de mesure de chaque variable.
2. Produire les moyennes et écarts types dans les neuf cellules du plan, puis construire un graphique des moyennes par activité pour chaque régime.
3. Effectuer une ANOVA à deux facteurs incluant le terme d'interaction Régime*Activité. Tester successivement l'effet du régime, l'effet de l'activité et l'interaction.
4. Si l'interaction est significative, expliquer pourquoi l'interprétation isolée des effets principaux doit être prudente. Utiliser le graphique de profil pour décrire le sens de l'interaction.
5. Effectuer les comparaisons multiples appropriées pour les facteurs présentant un effet significatif et rapporter les différences avec leurs intervalles de confiance.
6. Rédiger une conclusion de type article scientifique : statistiques F, degrés de liberté, p-values, effets significatifs et interprétation biologique.



Sous SPSS 25 : Analyse > Modèle linéaire général > Univarié ; Modèle : effets principaux + interaction ; Post Hoc ; Graphiques : profils estimés.

Correction détaillée - TP 7

ANOVA à deux facteurs et interaction

1. Résumés des neuf cellules

Moyennes : D1-A1=7,267 ; D1-A2=6,633 ; D1-A3=6,033 ; D2-A1=7,833 ; D2-A2=7,033 ; D2-A3=6,233 ; D3-A1=8,133 ; D3-A2=7,633 ; D3-A3=6,933. Les écarts types cellulaires sont compris entre environ 0,153 et 0,208.

2. ANOVA à deux facteurs

Effet Régime : F(2,18)≈75,493, p≈1,77×10^-9. Effet Activité : F(2,18)≈159,232, p≈3,59×10^-12. Interaction Régime×Activité : F(4,18)≈1,601, p≈0,217.

L'interaction n'est pas significative : les profils sont approximativement parallèles et l'interprétation des effets principaux est pertinente. Pour le régime, Tukey met surtout en évidence D3>D1 (p≈0,0095) ; les autres contrastes ne sont pas significatifs après correction. Pour l'activité, A1>A2>A3 et les trois comparaisons sont significatives.

3. Conclusion type article

Une ANOVA factorielle 3×3 montre un effet significatif du régime, F(2,18)=75,49, p<0,001, et de l'activité, F(2,18)=159,23, p<0,001, sans interaction significative, F(4,18)=1,60, p=0,217. Le score diminue quand le niveau d'activité passe de A1 à A3, tandis que D3 présente globalement les scores les plus élevés.

```
SPSS : Modèle linéaire général > Univarié
Dépendante : Score ; Facteurs fixes : Régime, Activité
Modèle : effets principaux + interaction ; Post Hoc ; Graphiques de profils
```

Graphique(s) de correction

