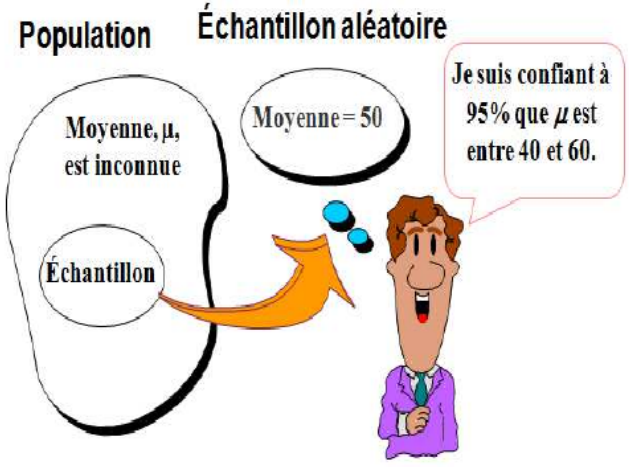
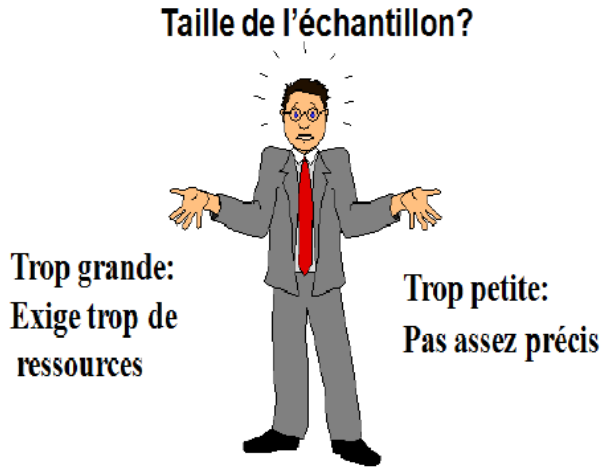
Cours et Exercices de Biostatistique

Filière: BCG-BIO-S3

SGHIR AISSA

Faculté des Sciences Oujda 2025-2026





Plan :

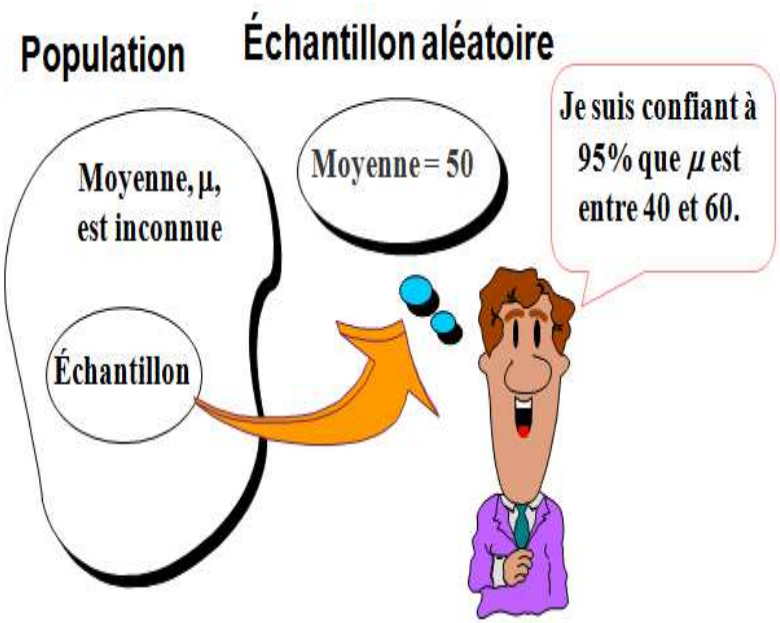
1. Introduction
2. Statistique descriptive univariée
3. Statistique descriptive bivariée
4. Notions de probabilités et variables aléatoires
5. Échantillonnage et estimation
6. Tests d'hypothèses
7. Exercices de révisions et Examens

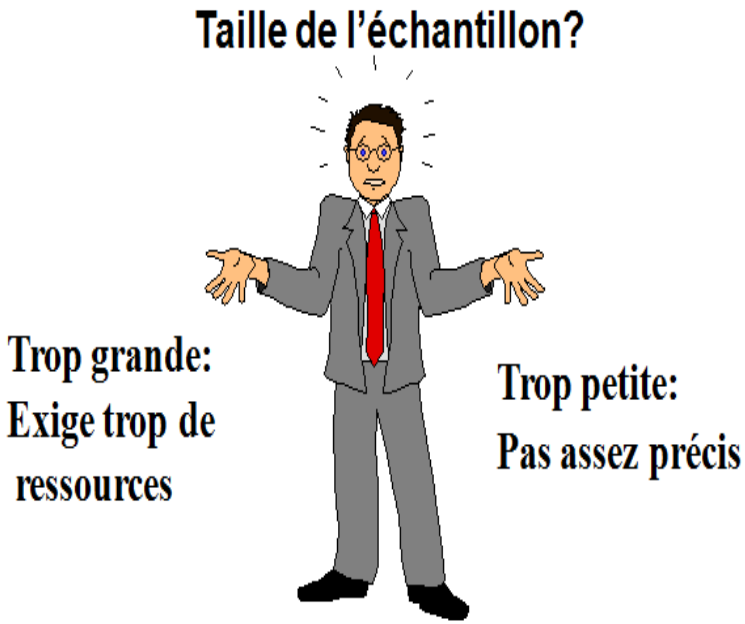
Plan :

1. Introduction
2. Statistique descriptive univariée
3. Statistique descriptive bivariée
4. Notions de probabilités et variables aléatoires
5. Échantillonnage et estimation
6. Tests d'hypothèses
7. Exercices de révisions et Examens

Introduction

Introduction





Introduction

Dans cet exemple et dans d'autres domaines, (biologie, géologie, physique, chimie, finance, ...), les managers doivent pouvoir disposer d'outils performants d'aide à la décision et l'analyse des informations recueillis.

Introduction

La statistique s'inscrit dans cette perspective et dont la définition est la suivante :

La statistique est un ensemble de méthodes scientifiques dont l'objectif est d'analyser, structurer et modéliser des informations numériques.

Introduction

Les méthodes statistiques peuvent être classés en deux groupes :

1) Les Statistiques descriptives

Elle regroupe les méthodes dont l'objectif principal est la description des données étudiées. Cette description des données se fait à travers leur représentation graphique, et le calcul de résumés numériques. Dans cette optique, on ne fait pas appel à des outils de type probabiliste.

Introduction

On cite trois types des statistiques descriptives :

Statistique descriptive univariée : étude de la population selon une seule variable.

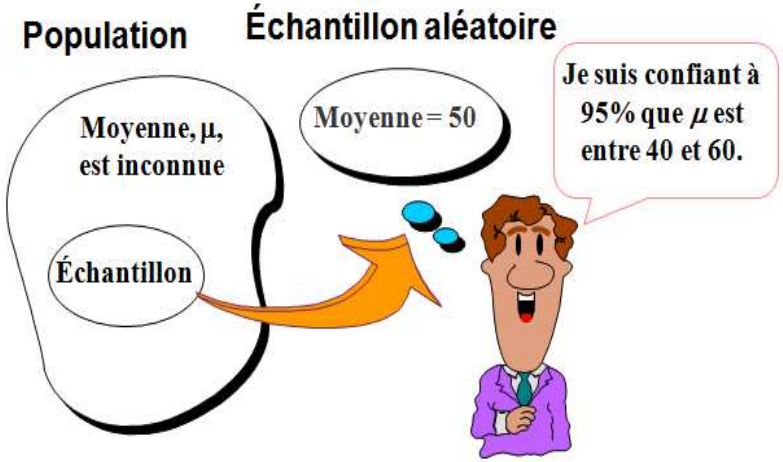
Statistique descriptive bivariée : étude des corrélations et relations éventuelles entre deux variables de la même population.

Statistique descriptive multivariée : étude des relations éventuelles entre plusieurs variables de la même population.

Introduction

2) La statistique inférentielle

Ce terme regroupe les méthodes dont l'objectif principal est de préciser un phénomène sur une population globale, à partir de son observation sur un échantillon de cette population. Ce passage ne se fait que moyennant des hypothèses de type probabiliste.



Introduction

Remarque

La statistique descriptive précède en général la statistique inférentielle dans une démarche de traitement de données : les deux aspects de la statistique se complètent bien plus qu'ils ne s'opposent.

Plan :

1 Introduction

2 Statistique descriptive univariée

3 Statistique descriptive bivariée

4 Notions de probabilités et variables aléatoires

5 Échantillonnage et estimation

6 Tests d'hypothèses

7 Exercices de révisions et Examens

Vocabulaires :

Vocabulaires :

- **Statistique :** c'est un ensemble de méthodes scientifiques dont l'objectif est d'analyser, structurer et modéliser des informations numériques.
- **Population :** ensemble des individus objets de l'étude statistique. (Étudiants, entreprises, plantes, animaux, produits,...)
- **Échantillon :** sous-ensemble issu de la population. (Une classe, une ville, hommes, femmes,...).
- **Unité statistique :** chaque individu. (Un étudiant, une plante, un homme, une femme,...)

Vocabulaires

- **Variable :** caractère ou propriété mesurée sur chaque individu notée $X, Y, \ldots$ (Note, taille, poids, sexe, couleur,...).
- **Modalités :** les valeurs possibles de la variable.
- **Série statistique :** suite des valeurs prises par une variable X notées $(x_1, x_2, x_3, \ldots)$.

Vocabulaires

Les variables sont classées en deux types :

- **Variable quantitative : les modalités sont mesurables ou repérables.**

  – Variable quantitative discrète : l'ensemble des modalités est fini ou dénombrable : (Note, taille, poids, âge, mesure,...).

  – Variable quantitative continue : l'ensemble des modalités est un intervalle fini ou infini : ($[8; 20[$, $[0; +\infty[$, $\mathbb{R}$,...)

Vocabulaires

- **Variable qualitative :** les modalités ne sont pas mesurables.

  – **Variable qualitative nominale :** les modalités ne peuvent pas être ordonnées : (sexe, couleur,...)

  – **Variable qualitative ordinale :** les modalités peuvent être ordonnées : (taille d'un vêtement : XXL, XL, L, M, S).

Vocabulaires

- **Effectif totale n : le nombre de toutes les valeurs prises par la variable.**
- **Effectif n_i : nombre d'apparitions de la valeur x_i dans la population ou dans l'échantillon.**

$$\sum_{i=1}^{J} n_i = n_1 + n_2 + ... + n_J = n.$$

Vocabulaires

- **Fréquence f_i associée à la valeur x_i :**

$$\begin{cases} f_i = \dfrac{n_i}{n}, \\ \displaystyle\sum_{i=1}^{J} f_i = f_1 + f_2 + \ldots + f_J = 1. \end{cases}$$

- **Pourcentage p_i associé à la valeur x_i :**

$$\begin{cases} p_i = (100 \times f_i) \ \ \%, \\ \displaystyle\sum_{i=1}^{J} p_i = p_1 + p_2 + \ldots + p_J = 100 \ \%. \end{cases}$$

Vocabulaires

- **Effectif cumulé N_i :**

$$\begin{cases} N_1 = n_1, \\ N_2 = n_1 + n_2, \\ N_3 = n_1 + n_2 + n_3, \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ N_J = n_1 + n_2 + \ldots + n_J = n. \end{cases}$$

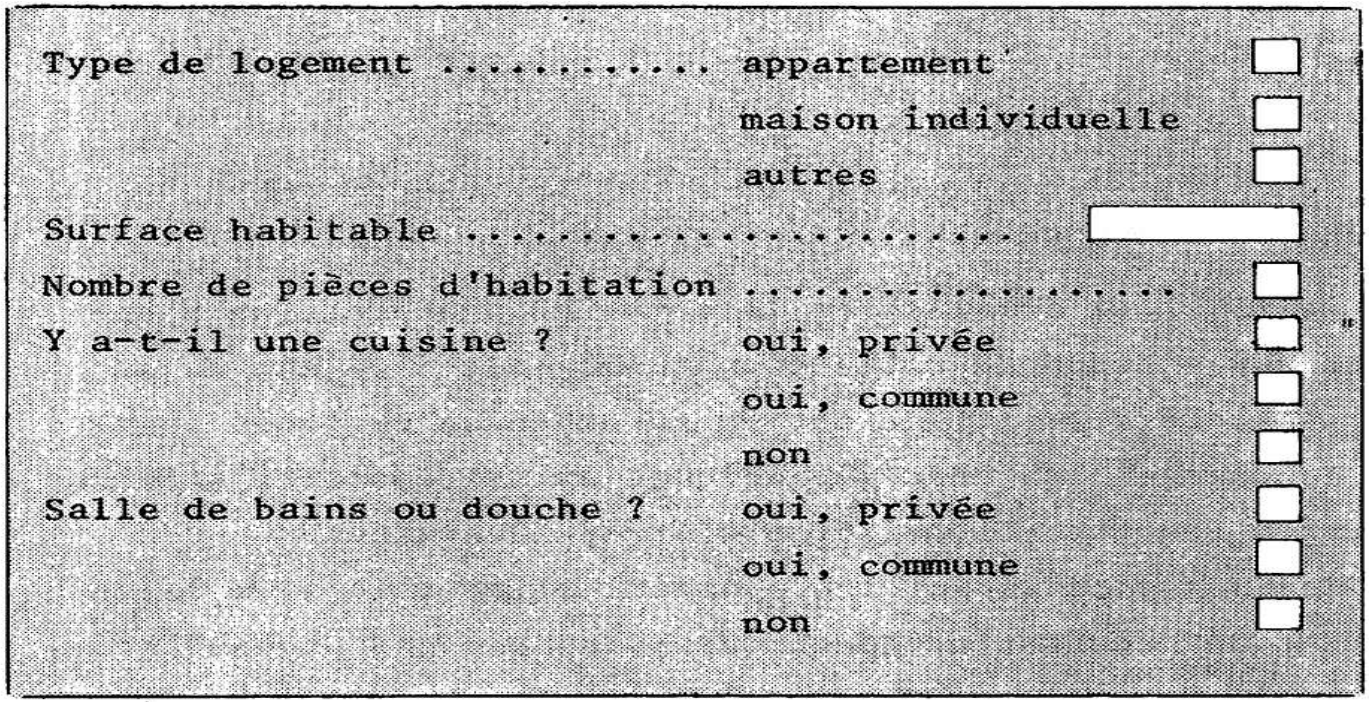
- **Fréquence cumulée F_i :**

$$\begin{cases} F_1 = f_1, \\ F_2 = f_1 + f_2, \\ F_3 = f_1 + f_2 + f_3, \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ F_J = f_1 + f_2 + \ldots + f_J = 1. \end{cases}$$

Exemples

Remarque

Avant de citer les exemples de cette section, nous présentons un exemple d'un modèle de questionnaire pour la collection des informations sur une population.



Exemples

Variable qualitative nominale :

On s'intéresse à la variable X =état-civil sur une population de n = 20 personnes. Considérons la série statistique suivante avec C : célibataire, M : marié, V : veuf, D : divorcé.

M	D	M	C	C	M	C	C	C	M	C	M	V	M	V	D	C	C	M	C

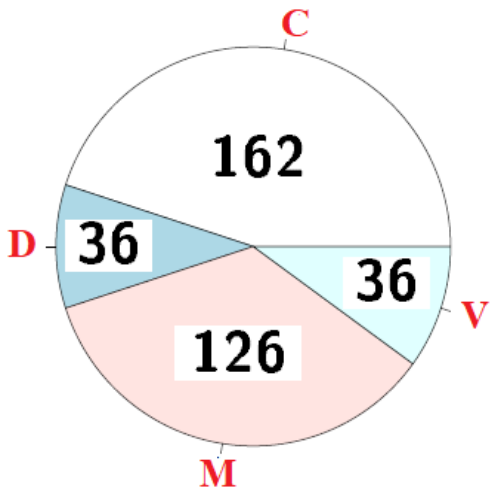
Tableau statistique :

x_i	n_i	f_i	$p_i\%$	N_i	F_i
C	9	0.45	45	9	0.45
M	7	0.35	35	16	0.75
V	2	0.10	10	18	0.85
D	2	0.10	10	20	1

Exemples

Diagramme en secteurs :

x_i	p_i %	$d_i = p_i \times 3.6$ °
C	45	162
M	35	126
V	10	36
D	10	36



Exemples

Variable qualitative ordinale :

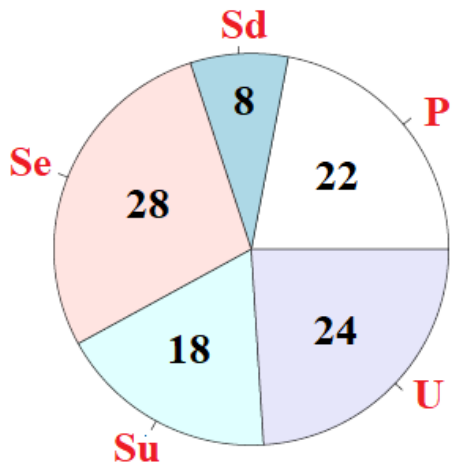
On interroge une population de $n = 50$ personnes sur leur dernier diplôme : Sd : Sans diplôme, P : Primaire, Se : Secondaire, Su : Supérieur non-universitaire et U : Universitaire.

Sd	Sd	Sd	Sd	P	P	P	P	P	P	P	P	P	P	P	Se	Se	Su
Se	Se	Se	Se	Se	Se	Se	Se	Se	Se	Se	Se	Se	Su	Su	Su		
Su	Su	Su	Su	U	U	U	U	U	U	U	U	U	U	U	U	Su	

Exemples

Tableau statistique :

x_i	n_i	N_i	f_i	p_i	F_i
Sd	4	4	0.08	8	0.08
P	11	15	0.22	22	0.30
Se	14	29	0.28	28	0.58
Su	9	38	0.18	18	0.76
U	12	50	0.24	24	1



Exemples

Variable quantitative discrète :

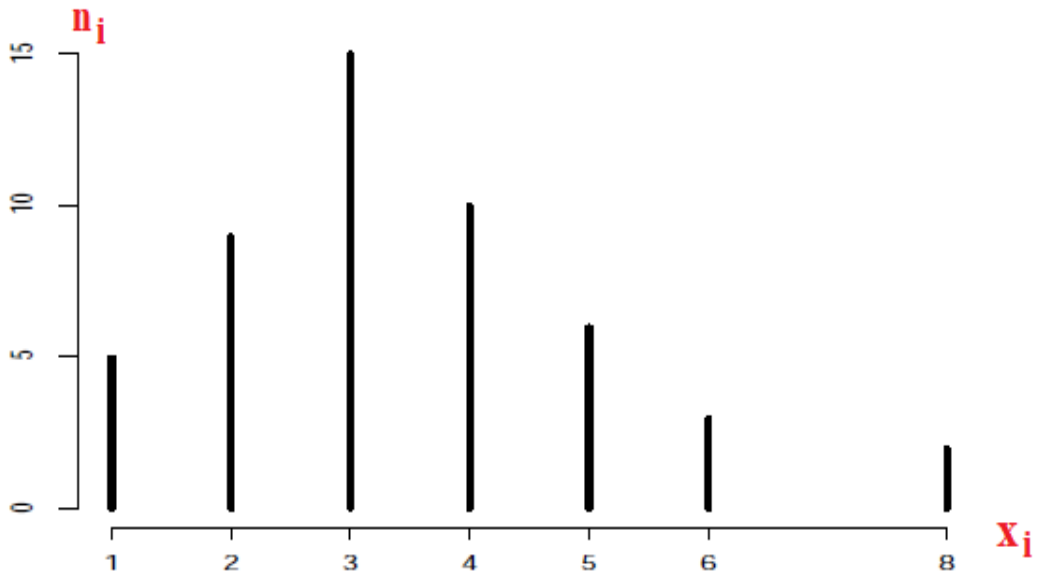
Un quartier est composé d'une population de 50 ménages, et la variable X représente le nombre de personnes par ménage. Les valeurs de la variable sont :

1	1	1	1	1	2	2	2	2	2
2	2	2	2	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	4
4	4	4	4	4	4	4	4	4	5
5	5	5	5	5	6	6	6	8	8

Exemples

Diagramme en bâtonnets des effectifs :

x_i	n_i	N_i	f_i	F_i
1	5	5	0.10	0.10
2	9	14	0.18	0.28
3	15	29	0.30	0.58
4	10	39	0.20	0.78
5	6	45	0.12	0.90
6	3	48	0.06	0.96
8	2	50	0.04	1

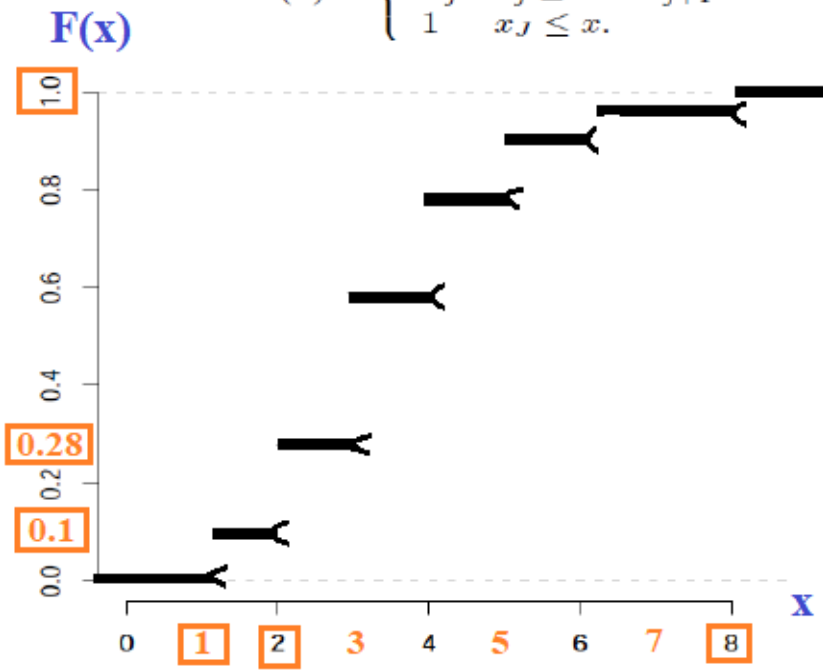


Exemples

Fonction de répartition :

Les fréquences cumulées sont représentées au moyen de la fonction de répartition. Cette fonction est définie de $\mathbb{R}$ dans $[0, 1]$ et vaut :

$$F(x) = \begin{cases} 0 & x < x_1 \\ F_j & x_j \leq x < x_{j+1} \\ 1 & x_J \leq x. \end{cases}$$



x_i	F_i
1	0.10
2	0.28
3	0.58
4	0.78
5	0.90
6	0.96
8	1

Exemples

Variable quantitative continue :

Très souvent, la prise en compte de toute les valeurs observées ne permet pas de donner une interprétation simple des résultats et conduit à des calculs inutiles. On peut souvent se contenter de regarder des regroupements en classes.

Exemples

Exemple :

On mesure la variable X=taille en centimètre d'une population de 50 élèves d'une classe.

152	152	152	153	153
154	154	154	155	155
156	156	156	156	156
157	157	157	158	158
159	159	160	160	160
161	160	160	161	162
162	162	163	164	164
164	164	165	166	167
168	168	168	169	169
170	171	171	171	171

Exemples

Tableau statistique :

On va procéder à des regroupements en classes (intervalles) de même amplitude. En règle générale, on choisit au moins cinq classes, sinon on utilise la règle de Sturge : le nombre de classes est $J = 1 + (3.3 \times \log_{10}(n))$.

La longueur de chaque classe est $l = \frac{x_{max} - x_{min}}{J}$.

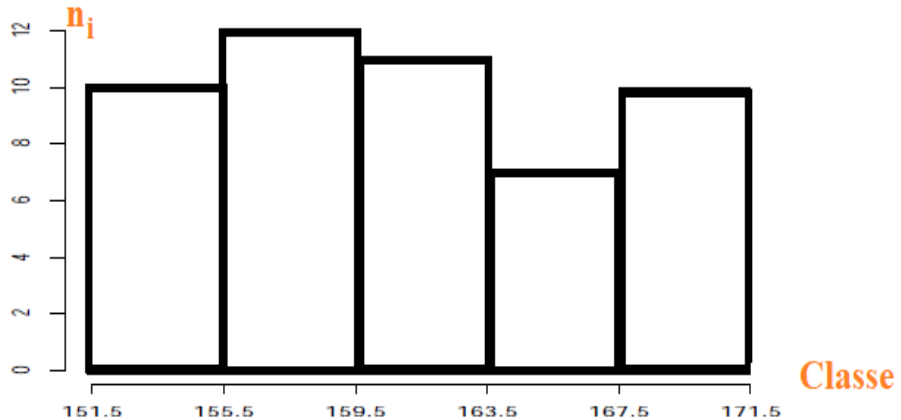
Par exemple pour $J = 5$, $x_{max} = 171$ et $x_{min} = 152$, on prend $l = 3.8 \simeq 4$.

classe	n_i	N_i	f_i	F_i
[151.5 ; 155.5[	10	10	0.20	0.20
[155.5 ; 159.5[	12	22	0.24	0.44
[159.5 ; 163.5[	11	33	0.22	0.66
[163.5 ; 167.5[	7	40	0.14	0.80
[167.5 ; 171.5[	10	50	0.20	1

Variable quantitative continue

Histogramme des effectifs :

classe	n_i	N_i	f_i	F_i
[151.5 ; 155.5[	10	10	0.20	0.20
[155.5 ; 159.5[	12	22	0.24	0.44
[159.5 ; 163.5[	11	33	0.22	0.66
[163.5 ; 167.5[	7	40	0.14	0.80
[167.5 ; 171.5[	10	50	0.20	1



Exemples

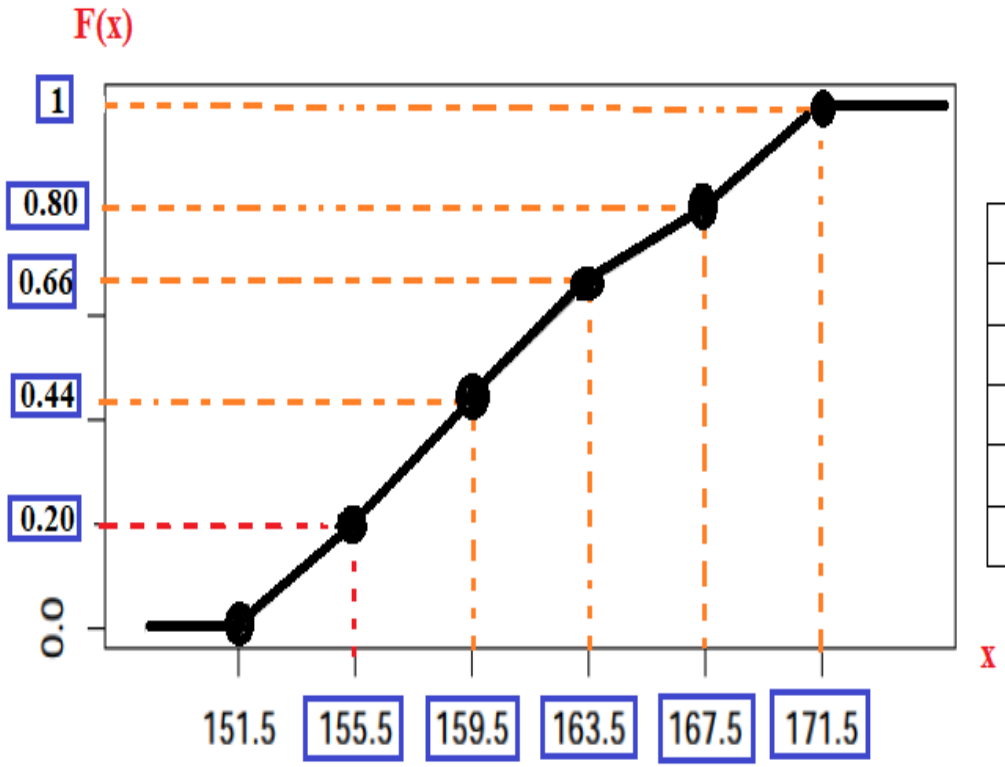
Fonction de répartition :

Si $[c_j^-; c_j^+[$ désigne la classe j, on note, de manière générale :

- c_j^- la borne inférieure de la classe j,
- c_j^+ la borne supérieure de la classe j,
- $c_j = (c_j^+ + c_j^-)/2$ le centre de la classe j,
- $a_j = c_j^+ - c_j^-$ l'amplitude de la classe j,
- n_j l'effectif de la classe j,
- N_j l'effectif cumulé de la classe j,
- f_j la fréquence de la classe j,
- F_j la fréquence cumulée de la classe j.

$$F(x) = \begin{cases} 0 & x < c_1^- \\ F_{j-1} + \frac{f_j}{c_j^+ - c_j^-}(x - c_j^-) & c_j^- \leq x < c_j^+ \\ 1 & c_J^+ \leq x \end{cases}$$

Exemples



classe	F_i
[151.5 ; 155.5[	0.20
[155.5 ; 159.5[	0.44
[159.5 ; 163.5[	0.66
[163.5 ; 167.5[	0.80
[167.5 ; 171.5[	1

Paramètres de position

Le mode ou classe modale :

C'est la valeur ou classe correspondant à l'effectif (ou fréquence) le plus élevé.

Exemple 1 :

x_i	n_i	f_i
C	9	0.45
M	7	0.35
V	2	0.10
D	2	0.10

le mode est $x_1 = C$: célibataire correspondant à l'effectif $n_1 = 9$ ou la fréquence $f_1 = 0.45$.

Paramètres de position

Exemple 2 :

classe	n_i	N_i	f_i	F_i
[151.5 ; 155.5[	10	10	0.20	0.20
[155.5 ; 159.5[	12	22	0.24	0.44
[159.5 ; 163.5[	11	33	0.22	0.66
[163.5 ; 167.5[	7	40	0.14	0.80
[167.5 ; 171.5[	10	50	0.20	1

la classe modale est $[155.5; 159.5[$.

Paramètres de position

La moyenne :

La moyenne $\bar{x}$ ne peut être définie que sur une variable quantitative.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + \ldots\ldots\ldots + x_n}{n}.$$

Exemple :

Les nombres d'enfants de 8 familles sont les suivants $0, 0, 1, 1, 1, 2, 3, 4$.

La moyenne est

$$\bar{x} = \frac{0+0+1+1+1+2+3+4}{8} = 1.5.$$

Paramètres de position

La moyenne peut être calculée à partir des valeurs distinctes et des effectifs.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{J} n_i \times x_i = \frac{(n_1 \times x_1) + \ldots\ldots\ldots + (n_J \times x_J)}{n}.$$

Exemple :

x_i	**0**	**1**	**2**	**3**	**4**
n_i	**2**	**3**	**1**	**1**	**1**

$$\bar{x} = \frac{(2 \times 0) + (3 \times 1) + (1 \times 2) + (1 \times 3) + (1 \times 4)}{8} = 1.5.$$

Paramètres de position

La médiane :

Cas d'une variable quantitative discrète :

La médiane, notée $M_e = x_{\frac{1}{2}}$, est une valeur centrale de la série statistique qui la partage en deux groupes de même effectifs. Elle est obtenue de la manière suivante :

On trie la série statistique par ordre croissant des valeurs observées :

Par exemple, avec la série observée :

$$3 \quad 2 \quad 1 \quad 0 \quad 0 \quad 1 \quad 2,$$

on obtient :

$$0 \quad 0 \quad 1 \quad \mathbf{1} \quad 2 \quad 2 \quad 3.$$

$n = 7$ est impair, la médiane est la valeur du rang $\frac{n+1}{2} = 4 \Longrightarrow x_{\frac{1}{2}} = 1.$

Paramètres de position

Si n **est pair, alors la médiane est la moyenne des deux valeurs de rangs :**

$$\frac{n}{2} \quad \textbf{et} \quad \frac{n}{2}+1.$$

Exemple :

Pour $n = 8$, **si on a :**

$$0 \quad 0 \quad 1 \quad \mathbf{1} \quad \mathbf{2} \quad 2 \quad 3 \quad 4$$

alors

$$x_{\frac{1}{2}} = \frac{1+2}{2} = 1.5.$$

Paramètres de position

La médiane :

Cas d'une variable quantitative continue :

De manière générale, on définira la médiane comme étant la valeur (abscisse) correspondant à la fréquence cumulée $F = 0.5$ **ou effectif cumulé** $N = \frac{n}{2}$**.**

On l'obtiendra en général par lecture graphique (valeur approchée $M_e = x_{\frac{1}{2}} = F^{-1}(0.5)$**) sur la courbe des fréquences cumulées, ou par une formule d'interpolation linéaire (valeur exacte) sur la courbe des effectifs cumulées.**

Paramètres de position

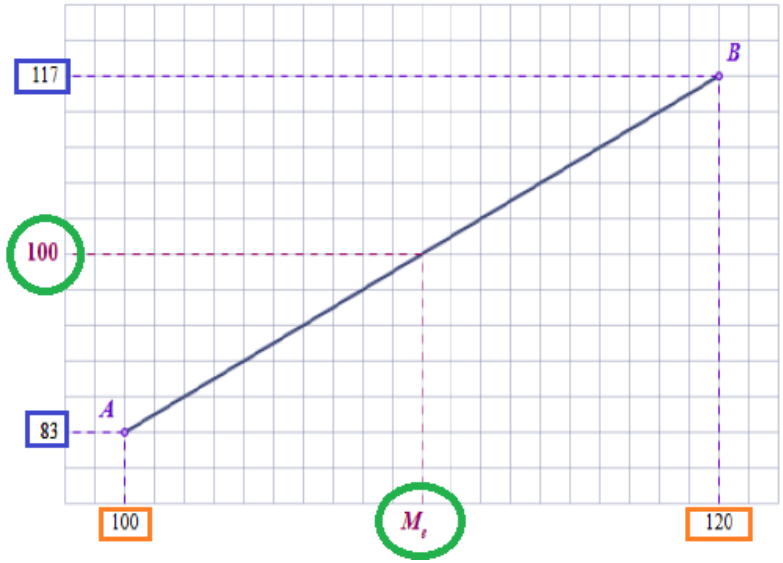
Cas d'une variable quantitative continue :

Budget (*en milliers d'euros*)	[0; 50[	[50; 70[	[70; 100[	[100; 120[	[120; 150[	[150; 200[	[200; 240[
Nombre d'entreprises	10	28	45	34	42	33	8
Effectifs cumulés	10	38	83	117	159	192	200

Il y a 200 entreprises, donc la classe médiane est la classe [100; 120[.

$N = \frac{n}{2} = 100$

Calculons la médiane par interpolation linéaire :



Paramètres de position

La médiane est l'abscisse du point de la droite passant par les points $A(100;83)$ et $B(120;117)$ dont l'ordonnée est égale à 100.

La droite (AB) a pour équation, $y = mx + p$ avec

$$m = \frac{117-83}{120-100} = 1{,}7$$

Comme $A(100;83)$ est un point de la droite (AB), nous obtenons la relation

$$y = 1{,}7(x-100)+83 \quad \Leftrightarrow \quad y = 1{,}7x - 87$$

La médiane est la valeur associé à un effectif égal à 100 d'où x est solution de l'équation

$$1{,}7x - 87 = 100 \quad \Leftrightarrow \quad x = \frac{100+87}{1{,}7} = 110$$

Le budget médian est de 110 milliers d'euros.

Paramètres de dispersion

L'étendue :

L'étendue est défini par :

$$E = x_{max} - x_{min}.$$

Exemple :

Pour la série 1 1 2 1 1 3 5 5 5 5 5 3 2 5

on a

$$E = 5 - 1 = 4.$$

Paramètres de dispersion

La variance et l'écart type :

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad \sigma_X = \sqrt{\sigma_X^2}.$$

Exemple :

Soit la série statistique 2 3 4 4 5 6 7 9 **de taille 8. On a**

$$\bar{x} = \frac{2+3+4+4+5+6+7+9}{8} = 5.$$

$$\sigma_X^2 = \frac{(2-5)^2 + (3-5)^2 + (4-5)^2 + ... + (9-5)^2}{8} = 4.5$$

$$\sigma_X = \sqrt{\sigma_X^2} = \sqrt{4.5} = 2.12$$

Paramètres de dispersion

La variance peut aussi s'écrire :

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2.$$

Exemple :

Soit la série statistique 2 3 4 4 5 6 7 9 **de taille 8. On a**

$$\bar{x} = \frac{2+3+4+4+5+6+7+9}{8} = 5.$$

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2 = \frac{2^2+3^2+4^2+4^2+5^2+6^2+7^2+9^2}{8} - 5^2 = 4.5.$$

Paramètres de dispersion

Remarque 1

La variance peut aussi s'écrire avec les effectifs :

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{J} n_i \times (x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{J} n_i \times x_i^2 - \bar{x}^2.$$

x_i	**0**	**1**	**2**	**3**	**4**
n_i	**7**	**3**	**5**	**5**	**10**

$$\bar{x} = \frac{(7 \times 0) + (3 \times 1) + (5 \times 2) + (5 \times 3) + (10 \times 4)}{30} = 2.27.$$

$$\sigma_X^2 = \frac{7 \times (0 - 2.27)^2 + 3 \times (1 - 2.27)^2 + \ldots\ldots + 10 \times (4 - 2.27)^2}{30}.$$

Paramètres de dispersion

Remarque 2

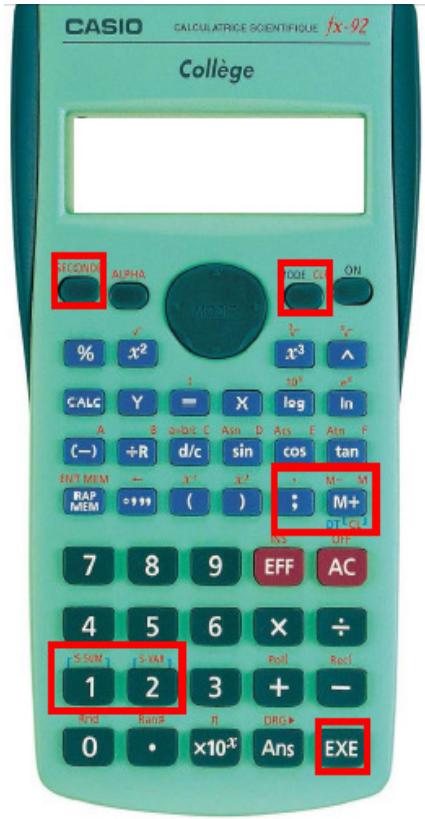
Pour calculer la moyenne et la variance dans le cas d'une variable continue, on calcule les centres des classes qui vont jouer le rôle des valeurs x_i du cas discret.

Exemple :

classe	n_i	centre x_i
$[0; 10[$	**10**	$\frac{0+10}{2} = 5$
$[10; 20[$	**4**	**15**
$[20; 30[$	**20**	**25**
$[30; 40[$	**6**	**35**

$$\bar{x} = \frac{(10 \times 5) + (4 \times 15) + (20 \times 25) + (6 \times 35)}{40} = 20.5.$$

Utilisation d'une calculatrice Casio



On efface les mémoires statistiques :

SECONDE MODE CLR 1 EXE

SHIFT MODE CLR 3 =

On passe en mode statistique MODE CLR SD 2

Exemple:

Note (x_i)	Effectif (n_i)
12	1
15	4

12 ; 1 M+ (n = 1)

15 ; 4 M+ (n = 5)



Utilisation d'une calculatrice Casio

Note (x_i)	Effectif (n_i)
12	1
15	4

→ 12 ; 1 M+ (n = 1)

→ 15 ; 4 M+ (n = 5)

* Pour déterminer l'effectif total
- ☞ On trouve : N = 5

SHIFT SECONDE (S-SUM) 1 — N 3 = EXE

* Pour déterminer la moyenne
- ☞ On trouve la note moyenne : $\overline{x} = 14{,}4$

SECONDE (S-VAR) 2 — $\overline{x}$ 1 EXE

* Pour déterminer l'écart type
- ☞ On trouve l'écart type : $\sigma = 1{,}2$

SECONDE (S-VAR) 2 — $x\sigma n$ 2 EXE

* Pour déterminer $\Sigma n_i x_i$
- ☞ On trouve : $\Sigma n_i x_i = 72$

SECONDE (S-SUM) 1 2 EXE

* Pour déterminer $\Sigma n_i x_i^2$
- ☞ On trouve : $\Sigma n_i x_i^2 = 1044$

SECONDE (S-SUM) 1 1 EXE

Utilisation d'une calculatrice Casio



mode statistique MODE SETUP 3 1-VAR 1

Les mémoires statistiques sont automatiquement effacées quand on entre dans la mode « STAT »

On montre la colonne des fréquences)

SHIFT MODE SETUP ▼ 4 1

Exemple:

Note (x_i)	Effectif (n_i)
12	1
15	4

	STAT X	Freq
1	12	1
2	15	4

Enregistrer chaque donnée en appuyant sur : = ou EXE

Finalement, pour sortir, appuyer sur AC



Utilisation d'une calculatrice Casio

Note (x_i)	Effectif (n_i)
12	1
15	4



	STAT X	Freq
1	12	1
2	15	4

* Pour déterminer l'effectif total : STAT-Var-n
☞ On trouve : **N = 5**



* Pour déterminer la moyenne : STAT-Var-$\bar{x}$
☞ On trouve la note moyenne : $\bar{x} = 14{,}4$



* Pour déterminer l'écart type : STAT-Var-xσn
☞ On trouve l'écart type : $\sigma = 1{,}2$



* Pour déterminer $\Sigma n_i x_i$: STAT-Sum-Σx
☞ On trouve : $\Sigma n_i x_i = 72$



* Pour déterminer $\Sigma n_i x_i^2$: STAT-Sum-Σx²
☞ On trouve : $\Sigma n_i x_i^2 = 1044$



Exercices

TD1

Exercice 1 :

On donne les couleurs de $n = 15$ plantes.

V	V	R	N	R	R	V	R	R	R	J	N	N	N	N

1. **De quel type est la variable couleur des plantes ?**
2. **Construire le tableau statistique et en déduire le mode.**
3. **Déterminer le mode.**
4. **Construire le diagramme en secteurs.**

Exercices

Exercice 2 :

Trente éprouvettes d'acier spécial sont soumises à des essais de résistance. Pour chacune, on note le nombre de chocs nécessaires pour obtenir la rupture. Les résultats obtenus sont les suivants :

2	2	3	1	2	1	4	2	3	2
3	2	3	3	4	1	1	4	2	3
2	3	2	2	3	4	3	2	3	2

1. **De quel type est cette variable ?**
2. **Construire le tableau statistique et en déduire le mode.**
3. **Construire le diagramme en bâtonnets des effectifs.**
4. **Déterminer la médiane, la moyenne, la variance et l'écart type de cette variable.**
5. **Déterminer la fonction de répartition et tracer sa courbe.**

Exercice

Exercice 3 :

On pèse les $n = 50$ élèves d'une classe et nous obtenons les résultats résumés dans le tableau suivant :

43	43	43	47	48	48	48	48	49	49
49	50	50	51	51	52	53	53	53	54
54	56	56	56	57	59	59	59	62	62
63	63	65	65	67	67	68	70	70	70
72	72	73	77	77	81	83	86	92	93

1. **De quel type est la variable poids ?**
2. **Construire le tableau statistique en adoptant quatres classes.**
4. **Déterminer la fonction de répartition et tracer sa courbe.**
5. **Déterminer la médiane directement et par interpolation linéaire.**
6. **Déterminer la moyenne, la variance et l'écart type de la variable poids.**

Plan :

1 Introduction

2 Statistique descriptive univariée

3 **Statistique descriptive bivariée**

4 Notions de probabilités et variables aléatoires

5 Échantillonnage et estimation

6 Tests d'hypothèses

7 Exercices de révisions et Examens

Introduction

Rappel (Chapitre 1 : Statistique descriptive univariée) :

On a caractérisé la population par une seule variable de quatre types :

- **Variable qualitative nominale.**
- **Variable qualitative ordinale.**
- **Variable quantitative discrète.**
- **Variable quantitative continue.**

On a obtenu des représentations graphiques à l'aide des tableaux statistiques basés sur : (effectifs n_i, fréquences f_i et fréquences cumulées F_i) :

- **Diagramme en secteurs pour la qualitative nominale ou ordinale.**
- **Diagramme en bâtonnets pour la quantitative discrète.**
- **Histogramme pour la quantitative continue.**
- **Fonction de répartition pour la quantitative discrète ou continue.**

Introduction

Dans cette section : (Statistique descriptive bivariée) :

- **On va étudié sur une même population de taille n individus, deux caractères différents X et Y .**
- **La série statistique est alors une suite de n couples des valeurs prises par les deux variables sur chaque individu :**

$$\{(x_1, y_1), ..., (x_n, y_n)\}.$$

- **Exemple :**

  Population=(étudiants), X=(poids) et Y=(taille).
  Pour un étudiant choisi, on a obtenu :

$$(x_1, y_1) = (70\mathbf{kg}, 160\mathbf{cm}).$$

Introduction

- **Pour la série statistique**

$$\{(x_1, y_1), \ldots\ldots\ldots\ldots, (x_n, y_n)\},$$

l'effectif associe à l'observation (x_i, y_j) **est noté** n_{ij}**,**

et sa fréquence notée : $f_{ij} = \frac{n_{ij}}{n}$.

- **On va chercher s'il existe un lien entre ces deux variables X et Y.**
- **Chacune des deux variables peut être, soit quantitative, soit qualitative.**

Deux variables qualitatives

1) Deux variables qualitatives :

Tableau de contingence des effectifs :

On s'intéresse à une éventuelle relation entre X : le sexe de n = 200 personnes et Y : la couleur des yeux.

X/Y	Bleue	Verte	Marron	Total
Homme	$n_{11} = 10$	$n_{12} = 50$	$n_{13} = 20$	$n_{1\bullet} = 80$
Femme	$n_{21} = 20$	$n_{22} = 60$	$n_{23} = 40$	$n_{2\bullet} = 120$
Total	$n_{\bullet 1} = 30$	$n_{\bullet 2} = 110$	$n_{\bullet 3} = 60$	$n = 200$

$n_{1\bullet}$,$n_{2\bullet}$ et $n_{\bullet 1}$,$n_{\bullet 2}$,$n_{\bullet 3}$ sont appelés effectifs marginaux.

$$\begin{cases} n_{11} + n_{12} + n_{13} = n_{1\bullet}, \\ n_{21} + n_{22} + n_{23} = n_{2\bullet}, \\ n_{11} + n_{21} = n_{\bullet 1}, \\ n_{12} + n_{22} = n_{\bullet 2}, \\ n_{13} + n_{23} = n_{\bullet 3}, \\ n_{11} + n_{12} + n_{13} + n_{21} + n_{22} + n_{23} = n. \end{cases}$$

Deux variables qualitatives

Tabelau de contingence des fréquences :

X/Y	**Bleue**	**Verte**	**Marron**	**Total**
Homme	$f_{11} = 0.05$	$f_{12} = 0.25$	$f_{13} = 0.10$	$f_{1\bullet} = 0.40$
Femme	$f_{21} = 0.10$	$f_{22} = 0.30$	$f_{23} = 0.20$	$f_{2\bullet} = 0.60$
Total	$f_{\bullet 1} = 0.15$	$f_{\bullet 2} = 0.55$	$f_{\bullet 3} = 0.30$	1

$f_{1\bullet}$,$f_{2\bullet}$ et $f_{\bullet 1}$,$f_{\bullet 2}$,$f_{\bullet 3}$ sont appelées fréquences marginales.

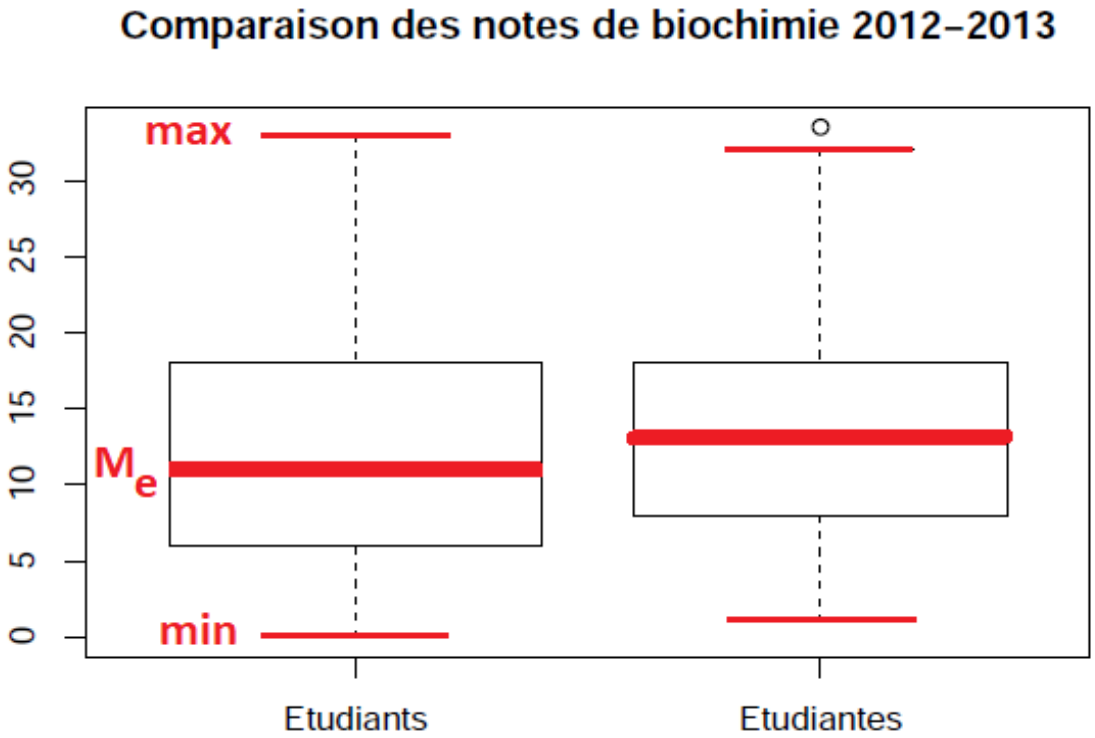
$$
\begin{cases}
f_{ij} = \frac{n_{ij}}{n}, f_{i\bullet} = \frac{n_{i\bullet}}{n}, f_{\bullet j} = \frac{n_{\bullet j}}{n} \\
f_{11} + f_{12} + f_{13} = f_{1\bullet}, \\
f_{21} + f_{22} + f_{23} = f_{2\bullet}, \\
f_{11} + f_{21} = f_{\bullet 1}, \\
f_{12} + f_{22} = f_{\bullet 2}, \\
f_{13} + f_{23} = f_{\bullet 3}, \\
f_{11} + f_{12} + f_{13} + f_{21} + f_{22} + f_{23} = 1.
\end{cases}
$$

Une variable quantitative et une variable qualitative :

2) Une variable quantitative et une variable qualitative

Diagramme en boîtes à moustaches :

Exemple : X= notes des étudiants (quantitative) et Y= sexe (qualitative)



Deux variables quantitatives

3) Deux variables quantitatives :

Covariance :

$$\sigma_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \frac{(x_1 - \bar{x})(y_1 - \bar{y}) + ... + (x_n - \bar{x})(y_n - \bar{y})}{n}.$$

$$\sigma_{XY} = \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{x}\bar{y} = \frac{x_1 y_1 + ... + x_n y_n}{n} - \bar{x}\bar{y}.$$

Coefficient de corrélation :

$$r := r_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}.$$

Deux variables quantitatives

Le coefficient de corrélation mesure la dépendance linéaire entre les variables X et Y :

- **La corrélation est parfaite si** $|r| = 1$. **X et Y sont dites : fortement corrélées.**
- **La corrélation est très forte si** $|r| > 0.8$.
- **La corrélation est forte si** $|r|$ **se situe entre 0.5 et 0.8.**
- **La corrélation est d'intensité moyenne : si** $|r|$ **se situe entre 0.2 et 0.5.**
- **La corrélation est faible si** $|r|$ **se situe entre 0 et 0,2.**
- **La corrélation est nulle si** $r = 0$.

Deux variables quantitatives

Remarque

- **Si le coefficient de corrélation r est positif, les points du nuage sont alignés le long d'une droite croissante. Dans ce cas X et Y évoluent dans le même sens.**
- **Si le coefficient de corrélation r est négatif, les points sont alignés le long d'une droite décroissante. Dans ce cas X et Y évoluent dans des sens opposés.**

Deux variables quantitatives

Droite de régression linéaire et nuage des points :

Neuf étudiants émettent un avis pédagogique vis-à-vis d'un professeur selon une échelle d'appréciation de 1 à 20. On relève par ailleurs la note obtenue par ces étudiants l'année précédente auprès du professeur.

Y= avis	5	7	16	6	12	14	10	9	8
X= résultat	8	11	10	13	9	17	7	15	16

Deux variables quantitatives

La droite de régression linéaire est la droite qui ajuste le mieux possible un nuage de points au sens des moindres carrés.

On considère que la variable X est explicative et que la variable Y est dépendante.

L'équation de la droite de régression linéaire de Y en X est :

$$(D): \quad y = \hat{a} + \hat{b}x,$$

avec

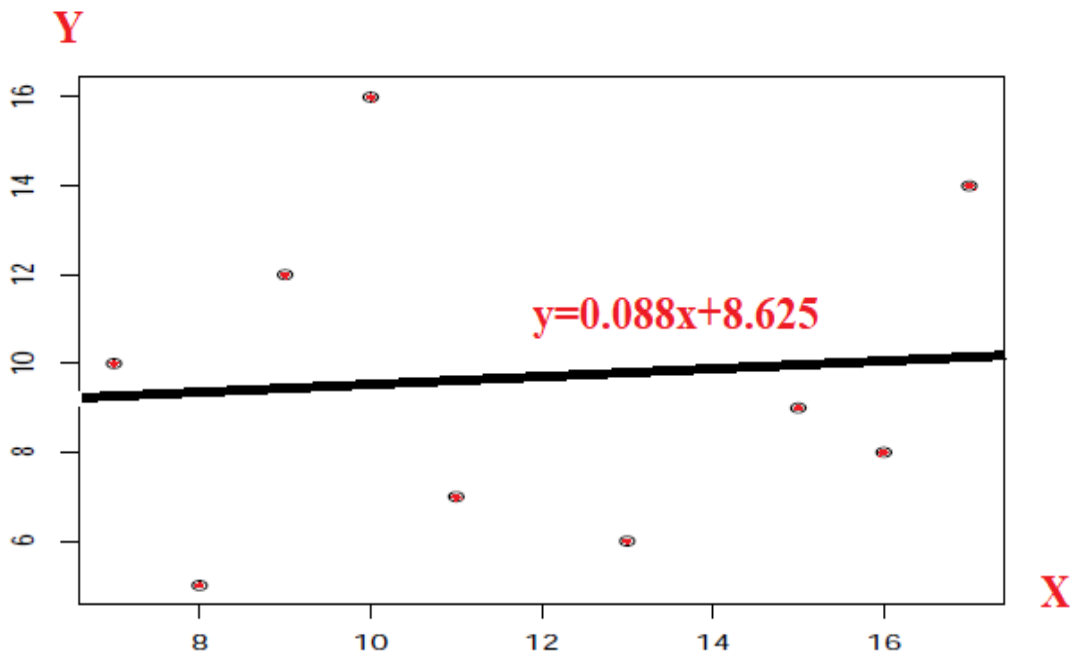
$$\hat{b} = \frac{\sigma_{XY}}{\sigma_X^2} \qquad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

N.B : la droite de régression (D) passe par le point $(\bar{x}, \bar{y})$.

Deux variables quantitatives

Dans notre exemple, on a :

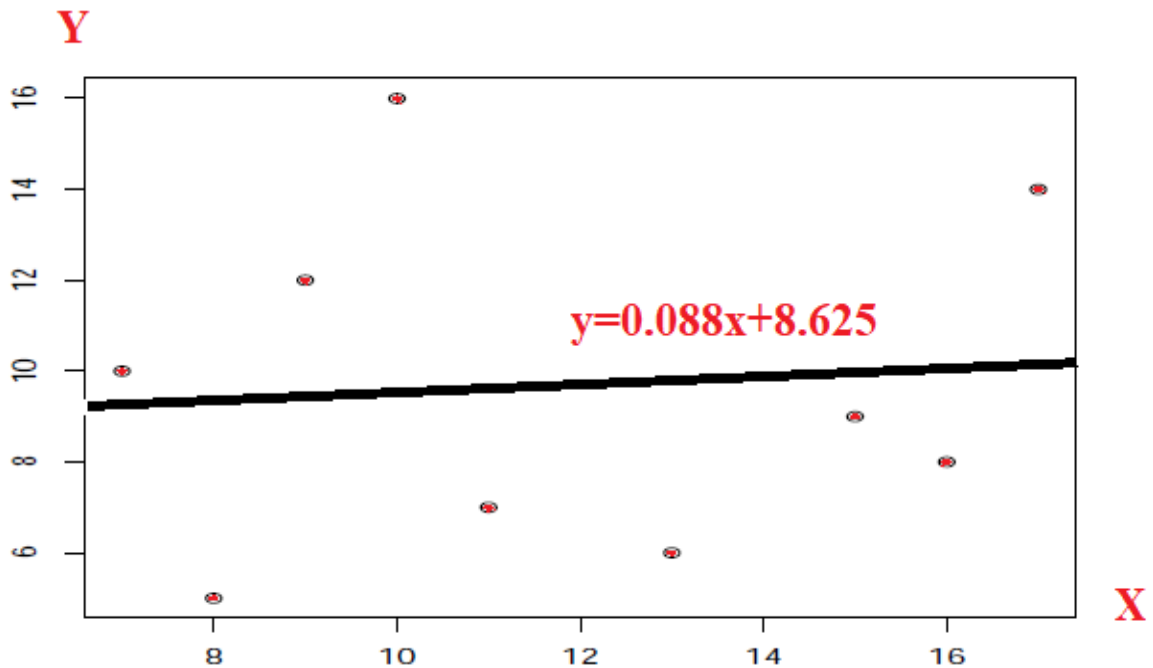
- $\bar{x} = 11.78$ $\quad \bar{y} = 9.667$ $\quad \sigma_X^2 = 11.73$
- $\sigma_Y^2 = 12.22$ $\quad \sigma_{XY} = 1.037$ $\quad r = r_{XY} = 0.087 > 0.$
- **(D)** : $y = 0.088x + 8.625$



Deux variables quantitatives

Le coefficient de détermination : $R^2 = r_{XY}^2$.

Il représente la proportion de variance expliquée par le modèle.
Dans notre modèle, on a $R^2 = 0.087^2 = 0.008$. **(0.8% très faible).**



Deux variables quantitatives

Prédiction :

Y= avis	5	7	16	6	12	14	10	9	8
X= résultat	8	11	10	13	9	17	7	15	16

Dans notre exemple si on veut prédire, sur la base de notre modèle, l'avis pour un étudiant ayant obtenu $x^* = 12$, alors la valeur ajustée est :

$$y^* = 0.088x^* + 8.625 = (0.088 \times 12) + 8.625 = 9.681.$$

Deux variables quantitatives

Résidus ou erreurs de prédiction :

Les résidus de la régression linéaire sont définis par :

$$e_i = y_i - (\hat{a} + \hat{b}x_i) = y_i - y_i^*.$$

Les résidus sont les différences entre les valeurs observées y_i et les valeurs ajustées y_i^* de la variable dépendante.

Le résidu e_i est l'erreur que l'on commet en utilisant la droite de régression linéaire pour prédire y_i à partir de x_i.

Par exemple pour la valeur $x_3 = 12$, on donne $y_3 = 10$ et on a $y_3^* = 0.088 \times 12 + 8.625 = 9.681$, **donc** $e_3 = y_3 - y_3^* = 0.319$.

Deux variables quantitatives

moyenne résiduelle :

$$\bar{e} = \frac{1}{n}\sum_{i=1}^{n} e_i = 0.$$

Variance résiduelle :

$$\sigma_e^2 = \frac{1}{n}\sum_{i=1}^{n} e_i^2.$$

La variance résiduelle peut également s'écrire :

$$\sigma_e^2 = \sigma_y^2 \times (1 - r_{XY}^2).$$

Dans notre exemple on a :

$$\sigma_e^2 = 12.22 \times (1 - 0.087^2) = 12.127.$$

Utilisation d'une calculatrice de type Casio

Utilisation d'une calculatrice Casio fx 82MS

Exemple

Y= pression	1003	1005	1010	1011	1014
X= température	10	15	20	25	30

Utilisation d'une calculatrice de type Casio

Utilisation d'une calculatrice Casio fx 82ES



On efface les mémoires statistiques:

SECONDE MODE CLR [ ] [ ] 1 EXE

SHIFT MODE CLR [ ] [ ] 3 =

mode statistique MODE CLR [ ] REG 3 Lin 1

Exemple: Y=a+bX

Y	1003	1005	1010	1011	1014
X	10	15	20	25	30

10 , 1003 M+ = ou EXE

15 , 1005 M+ = ou EXE etc...



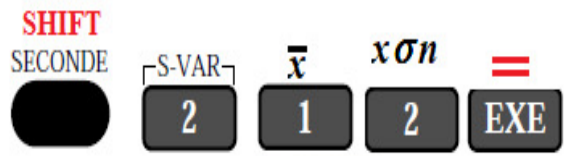
Utilisation d'une calculatrice de type Casio

Y	1003	1005	1010	1011	1014
X	10	15	20	25	30

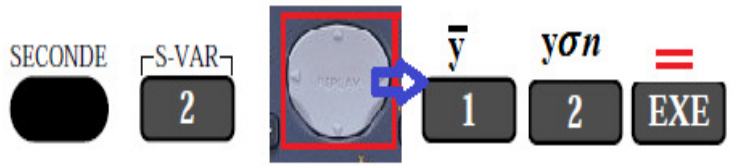
10 [,] 1003 [M+] [=] ou [EXE]

15 [,] 1005 [M+] [=] ou [EXE] etc...

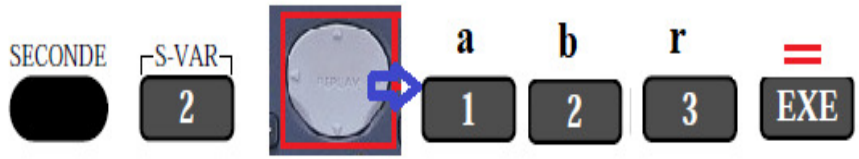
la moyenne et l'écart type de X:



la moyenne et l'écart type de Y:



les coefficient a, b et r :



Utilisation d'une calculatrice de type Casio



mode statistique MODE SETUP 3 2 a+bX

Les mémoires statistiques sont automatiquement effacées quand on entre dans la mode « STAT »

On montre la colonne des fréquences)

SHIFT MODE SETUP ▼ 4 1

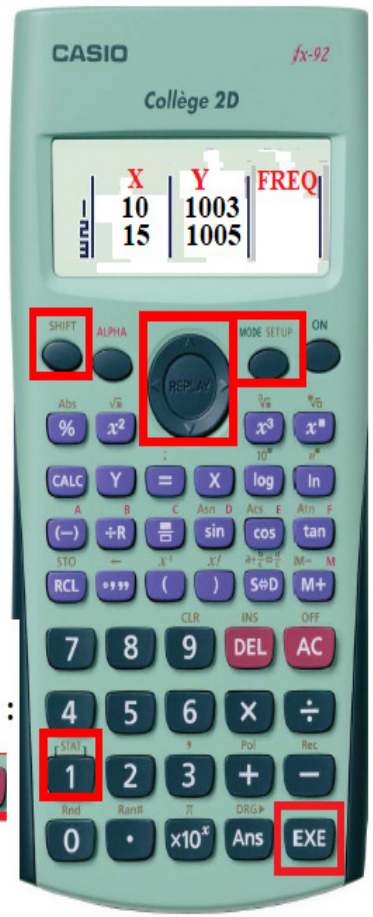
Exemple:

Y	1003	1005	1010	1011	1014
X	10	15	20	25	30

	STAT X	Y	Freq
1	10	1003	1
2	15	1005	1

Enregistrer les données En appuyant sur : = ou EXE

Pour sortir appuyer sur : AC AC



Utilisation d'une calculatrice de type Casio

Y	1003	1005	1010	1011	1014
X	10	15	20	25	30

	STAT X	Y	Freq
1	10	1003	1
2	15	1005	1

Enregistrer les données En appuyant sur : [=] ou [EXE]

[SHIFT] [STAT] [1] [5] [$\bar{x}$ 2] [$x\sigma n$ 3] [$\bar{y}$ 5] [$y\sigma n$ 6]

le coefficient a : [SHIFT] [STAT] [1] [7] [a 1]

le coefficient b : [SHIFT] [STAT] [1] [7] [b 2]

le coefficient r : [SHIFT] [STAT] [1] [7] [r 3]

Exercices

Suite du TD1

Exercice 4 :

Considérons un échantillon de $n = 10$ fonctionnaires (ayant entre 40 et 50 ans) d'un ministère. Soit X le nombre d'années de service et Y le nombre de jours d'absence pour raison de maladie (au cours de l'année précédente) déterminé pour chaque personne appartenant à cet échantillon.

x_i	2	14	16	8	13	20	24	7	5	11
y_i	3	13	17	12	10	8	20	7	2	8

1. **Déterminer les moyennes de X et Y et la covariance entre X et Y.**

Exercices

2. Déterminer le coefficient de corrélation entre les variables X et Y. Donnez une interprétation.
3. Déterminer la droite de régression linéaire Y en fonction de X.
4. Tracer le nuage de points (X, Y).
5. Tracer la droite de régression linéaire de Y en X.
6. Déterminer, sur la base de ce modèle, le nombre de jours d'absence pour un fonctionnaire ayant 22 ans de service.
7. Déterminer la variance résiduelle et le coefficient de détermination.

Interprétez.

Exercices

Exercice 5 :

On étudie un échantillon de taille $n = 100$ sur lequel ont été mesurés deux caractères X et Y. On a observé les résultats suivants :

$$\sum_{i=1}^{100} x_i = 800 \qquad \sum_{i=1}^{100} y_i = 1200 \qquad \sum_{i=1}^{100} x_i^2 = 7200$$

$$\sum_{i=1}^{100} y_i^2 = 16000 \qquad \sum_{i=1}^{100} x_i y_i = 10200$$

1. **Déterminer les moyennes, les variances et la covariance de X et Y.**
2. **En déduire le coefficient de corrélation entre X et Y. Interpréter.**
3. **Déterminer la droite de régression linéaire de Y en X.**
4. **Déterminer la variance résiduelle et le coefficient de détermination. Interpréter.**

Plan :

1. Introduction
2. Statistique descriptive univariée
3. Statistique descriptive bivariée
4. **Notions de probabilités et variables aléatoires**
5. Échantillonnage et estimation
6. Tests d'hypothèses
7. Exercices de révisions et Examens

Notions de probabilités



Réalisation:

un résultat possible de l'expérience aléatoire.

Espace fondamental Ω:

l'ensemble de tous les résultats possibles.

Événement:

sous ensemble de l'espace fondamental

Exemple:



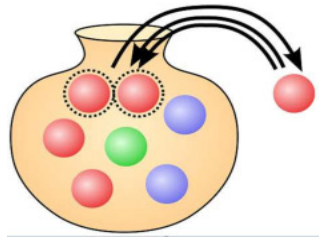
On a deux réalisations:
P ou F

$\Omega = \{P, F\}$ card $(\Omega) = 2$

Notions de probabilités

Exemples d'expériences aléatoires :

1) Si on tire au hasard et simultanément (en même temps) deux boules dans une urne qui contient 4 boules rouges, 2 boules bleues et 1 boule verte, alors :



$$\Omega = \{(R_1, R_2), (R_1, R_3), ..., (R_2, R_3), ..., (R_1, V_1), ...\} \Longrightarrow \textbf{card}\ (\Omega) = C_7^2 = 21.$$

2) Pour un tirage successif et sans remise, on a :

$$\Omega = \{(R_1, R_2), (R_2, R_1), (R_1, R_3), (R_3, R_1), ...\} \Longrightarrow \textbf{card}\ (\Omega) = A_7^2 = 42 = 21*2.$$

3) Pour un tirage successif et avec remise, on a :

$$\Omega = \{(R_1, R_1), (R_1, R_2), (R_2, R_1), ..., (V_1, V_1), ...\} \Longrightarrow \textbf{card}\ (\Omega) = 7^2 = 49 = 42+7.$$

Notions de probabilités



4) Si on lance une pièce de monnaie, alors :

$$\Omega = \{P, F\} \Longrightarrow \textbf{card}\ (\Omega) = 2 = 2^1.$$

5) Si on lance une pièce de monnaie deux fois successive, alors :

$$\Omega = \{(P, P), (F, P), (P, F), (F, F)\} \Longrightarrow \textbf{card}\ (\Omega) = 4 = 2^2.$$

L'évènement A : (obtenir pile une seule fois) est $A = \{(F, P), (P, F)\}$.

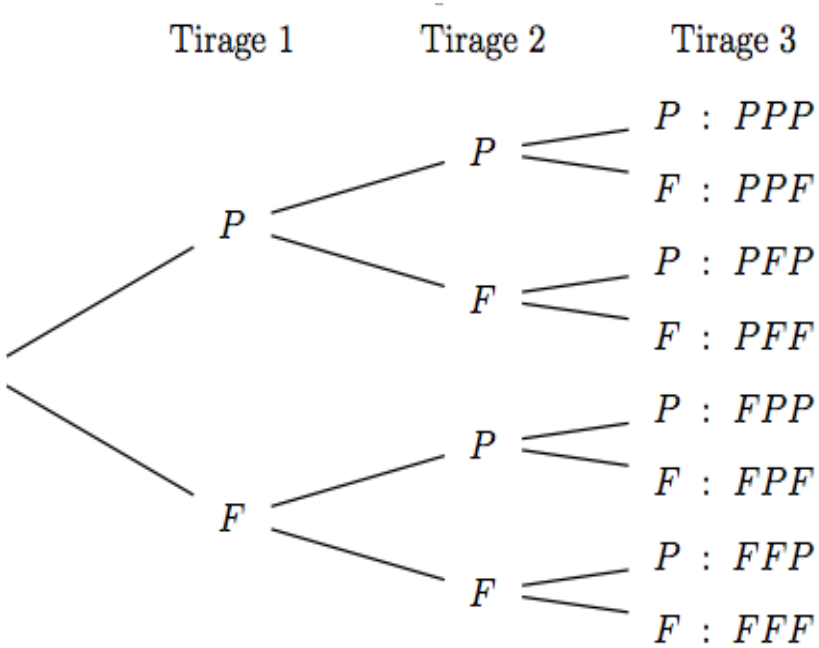
Notions de probabilités

6) Si on lance une pièce de monnaie trois fois successive, alors :

$$\Omega = \{(P,P,P),(P,P,F),.....,(F,F,F)\} \Longrightarrow \textbf{card}\ (\Omega) = 8 = 2^3.$$

L'évènement B :(obtenir face une seule fois) est :

$$B = \{(F,P,P),(P,F,P),(P,P,F)\} \Longrightarrow \textbf{card}\ (B) = 3.$$



Notions de probabilités

7) Si on lance un dé une seule fois, alors :



$$\Omega = \{1, 2, 3, 4, 5, 6\} \Longrightarrow \textbf{card}\ (\Omega) = 6 = 6^1.$$

L'évènement A **: (obtenir un nombre pair) est** $A = \{2, 4, 6\}$.

8) Si on lance un dé deux fois successive, alors :

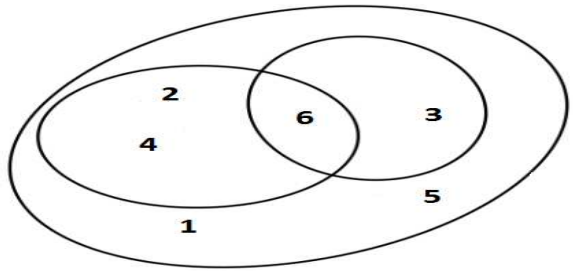
$$\Omega = \{(1,1), (1,2), (1,3), ..., (6,6)\} \Longrightarrow \textbf{card}\ (\Omega) = 6^2 = 36.$$

L'évènement B **: (la somme des deux chiffres est égale à 4) est**

$$B = \{(1,3), (3,1), (2,2)\} \Longrightarrow \textbf{card}\ (B) = 3.$$

Notions de probabilités

L'union : $A \cup B$ **est réalisé dés que A ou B est réalisé.**
L'intersection : $A \cap B$ **est réalisé dés que A et B sont réalisés conjointement.**
Le complémentaire $\bar{A}$ **: c'est l'évènement** $\Omega \backslash A$.
Exemple :
Dans un lancer de dé, on a : $\Omega = \{1, 2, 3, 4, 5, 6\}$.
Si A=(obtenir un nombre pair) et B=(obtenir un multiple de 3), alors
$A = \{2, 4, 6\}$, $B = \{3, 6\}$, $A \cap B = \{6\}$ **et** $A \cup B = \{2, 3, 4, 6\}$.



Pour $A = \{2, 4, 6\}$, **on a** $\bar{A} = \{1, 3, 5\}$**= (les nombres impairs).**

Notions de probabilités

Définition d'une probabilité

Une probabilité P **sur un ensemble fini** $\Omega = \{\omega_1, ..., \omega_n\}$ **est une pondération** $p_1, p_2, ..., p_n$ **des éléments de cet ensemble telle que :**

- **Pour tout** $k \in [1 : n]$, $p_k \geq 0$.
- $\sum_{k=1}^{n} p_k = 1$.

On attribue à toute éventualité ω_i **la probabilité** $p_i = P(\{\omega_i\})$ **et on attribue à tout évènement** $A \subset \Omega$ **la probabilité :**

$$P(A) = \sum_{k;\, !\, k \in A} p_k.$$

Notions de probabilités

Exemples :

1) Dans le lancer d'un dé équilibré, on a $\Omega = \{1, ..., 6\}$ et

$$P(\{1\}) = P(\{2\}) = P(\{3\}) = P(\{4\}) = P(\{5\}) = P(\{6\}) = \frac{1}{6},$$

$$\frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{6}{6} = 1.$$

Si l'évènement A=(obtenir un nombre pair strictement supérieur à 3), alors :

$$A = \{4, 6\} \text{ et } P(A) = P(\{4\}) + P(\{6\}) = \frac{1}{6} + \frac{1}{6} = \frac{2}{6} = \frac{1}{3}.$$

2) Dans le lancer d'une pièce de monnaie équilibrée, on a : $\Omega = \{P, F\}$ et

$$P(\{F\}) = P(\{P\}) = \frac{1}{2}, \quad \text{avec} \quad \frac{1}{2} + \frac{1}{2} = 1.$$

3) Pour 2 pièces de monnaie équilibrées : $\Omega = \{(P, P), (F, P), (P, F), (F, F)\}$

et $$P\{(P, P)\} = P\{(F, P)\} = P\{(P, F)\} = P\{(F, F)\} = \frac{1}{4}.$$

Notions de probabilités

Remarque

Dans le cas où les symétries font que tous les résultats possibles $\omega_1, ..., \omega_n$ sont équiprobables ou équilibrés, on a :

$$P(A) = \frac{card(A)}{card(\Omega)}.$$

Exemples :

1) Pour un seul dé équilibré, on a : $\Omega = \{1, ..., 6\}$ et si $A = \{4, 6\}$, alors :

$$P(A) = \frac{card(A)}{card(\Omega)} = \frac{2}{6} = \frac{1}{3}.$$

2) Pour deux dés équilibrés, on a : $\Omega = \{(1,1), (1,2)....., (6,5), (6,6)\}$ et si B est l'événement=(le produit des deux chiffres égale à 6), alors
$B = \{(1,6), (6,1), (2,3), (3,2)\}$ **et :**

$$P(B) = \frac{card(B)}{card(\Omega)} = \frac{4}{36} = \frac{1}{9}.$$

Notions de probabilités

Propriétés

1. $0 \leq P(A) \leq 1$.
2. $P(\bar{A}) = 1 - P(A)$.
3. $P(\Omega) = 1$, **(événement certain).**
4. $P(\emptyset) = 0$, **(événement impossible).**
5. **Soit** A **et** B **deux événements, alors**

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Notions de probabilités

Probabilité conditionnelle et indépendance

- **Soient deux événements A et B, si $P(B) > 0$, alors**

$$P_B(A) = \frac{P(A \cap B)}{P(B)}.$$

$P_B(A)$ **est la probabilité que A se réalise sachant que B est déjà réalisé.**

- **On dit que deux événements A et B sont indépendants si**

$$P(A \cap B) = P(A).P(B)$$

ou encore si

$$P_B(A) = P(A) \quad \textbf{ou} \quad P_A(B) = P(B).$$

Notions de probabilités

Exemple :

Nous jetons un dé équilibré et nous considérons les deux événements :
$A =$ **(le résultat est impair) et** $B =$ **(le résultat est** ≤ 4**), alors :**

$\Omega = \{1, 2, 3, 4, 5, 6\}$.

$$A = \{1, 3, 5\} \Rightarrow P(A) = \frac{\text{card}(A)}{\text{card}(\Omega)} = \frac{3}{6} = \frac{1}{2}$$

$$B = \{1, 2, 3, 4\} \Rightarrow P(B) = \frac{\text{card}(B)}{\text{card}(\Omega)} = \frac{4}{6} = \frac{2}{3}$$

$$A \cap B = \{1, 3\} \Rightarrow P(A \cap B) = \frac{\text{card}(A \cap B)}{\text{card}(\Omega)} = \frac{2}{6} = \frac{1}{3}$$

On a $P(A \cap B) = \frac{1}{3} = P(A).P(B)$ **donc** A **et** B **sont indépendants.**

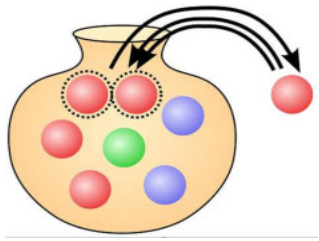
Notions de probabilités

Exercice 1 :

On tire au hasard et simultanément (en même temps) deux boules dans une urne qui contient 4 boules rouges, 2 boules bleues et 1 boule verte. Calculer les probabilités de :

A=(Tirer deux boules de même couleurs)

B=(Tirer une seule boule rouge).



Corrigé :

$$A = (2R) \text{ ou } (2B) \Longrightarrow P(A) = \frac{card(A)}{card(\Omega)} = \frac{C_4^2 + C_2^2}{C_7^2} = \frac{7}{21} = \frac{1}{3}.$$

$$B = (1R \text{ et } 1\bar{R}) \Longrightarrow P(B) = \frac{card(B)}{card(\Omega)} = \frac{C_4^1 * C_3^1}{C_7^2} = \frac{12}{21} = \frac{4}{7}.$$

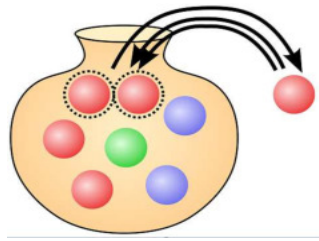
Notions de probabilités

Exercice 2 :

On tire maintenant succesivement et sans remise deux boules.
Calculer les probabilités de :

A=(Tirer deux boules de même couleurs)

B=(Tirer une seule boule rouge).



Corrigé :

$$A = (2R) \text{ ou } (2B) \Longrightarrow P(A) = \frac{card(A)}{card(\Omega)} = \frac{A_4^2 + A_2^2}{A_7^2} = \frac{14}{42} = \frac{1}{3}.$$

$$B = (1R \text{ et } 1\bar{R}) \text{ ou} (1\bar{R} \text{ et } 1R) \Longrightarrow P(B) = \frac{card(B)}{card(\Omega)} = 2 * \frac{A_4^1 * A_3^1}{A_7^2} = \frac{24}{42} = \frac{4}{7}.$$

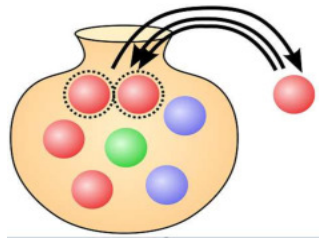
Notions de probabilités

Exercice 3 :

On tire maintenant succesivement et avec remise deux boules.
Calculer les probabilités de :

A=(Tirer deux boules de même couleurs)

B=(Tirer une seule boule rouge).

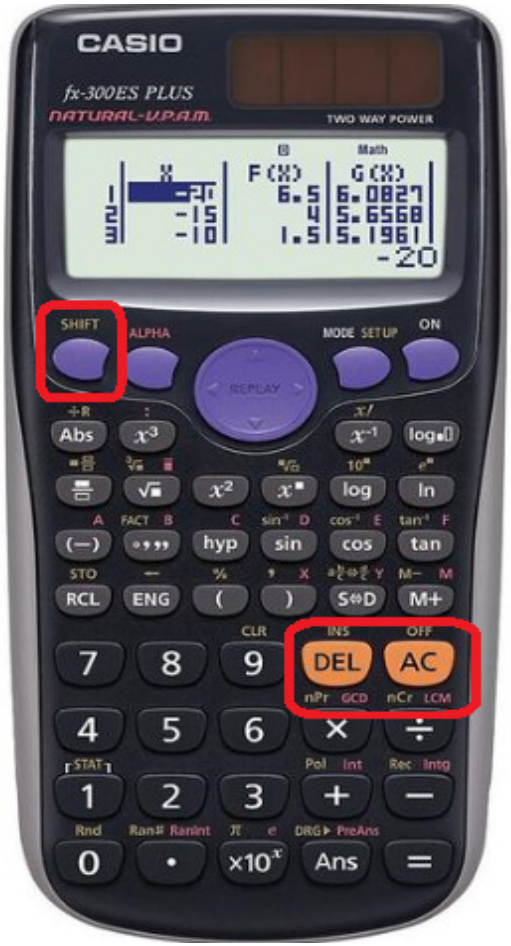


Corrigé :

$$A = (2R) \text{ ou } (2B) \text{ ou } (2V) \Longrightarrow P(A) = \frac{card(A)}{card(\Omega)} = \frac{4^2+2^2+1^2}{7^2} = \frac{21}{49} = \frac{3}{7}.$$

$$B = (1R \text{ et } 1\bar{R}) \text{ ou} (1\bar{R} \text{ et } 1R) \Longrightarrow P(B) = \frac{card(B)}{card(\Omega)} = 2 * \frac{4^1 * 3^1}{7^2} = \frac{24}{49}.$$

Notions de probabilités



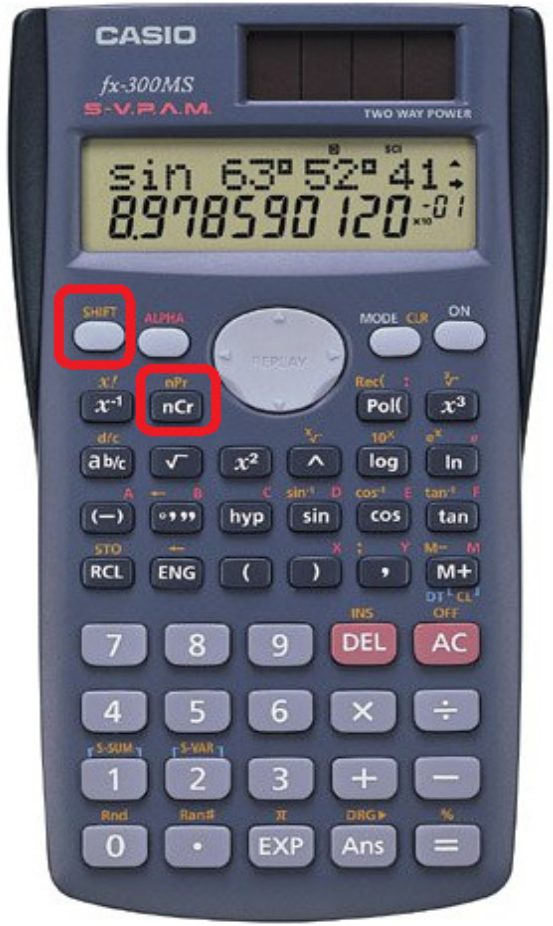
Dénombrement avec une calculatrice

C_7^2 nCr

A_7^2 nPr

7 nCr 2

7 SHIFT nCr 2



Variables aléatoires discrètes

Variables aléatoires discrètes :

Soit P une probabilité sur Ω un espace fondamental associé à une expérience aléatoire.

- **La notion d'une variable aléatoire (v.a) notée X formalise l'association d'une valeur $X(\omega)$ au résultat $\omega \in \Omega$ de l'expérience aléatoire.**
- **On note $X(\Omega)$ l'ensemble des valeurs prises par X.**
- **Une variable aléatoire discrète prend uniquement des valeurs dans un sous ensemble discret :**

$$X(\Omega) = \{x_1, x_2, ...\}.$$

- **Une loi de probabilité P_X est une fonction qui associe à chaque valeur x_i la probabilité :**

$$p_i = P_X(x_i) = P(X = x_i) \quad \textbf{avec} \quad \sum_i P_X(x_i) = 1.$$

Variables aléatoires discrètes

Exemple :

On considère une expérience aléatoire consistant à lancer deux fois une pièce de monnaie. L'ensemble des résultats possibles est :

$$\Omega = \{(P,P),(F,P),(P,F),(F,F)\}.$$

Considérons la variable aléatoire X représentant le nombre de faces obtenues.

Les valeurs prises par X sont : $X(\Omega) = \{0,1,2\}$. On a :

$$P_X(0) = P(X = 0) = P(\textbf{obtenir 0 faces}) = P\{(PP)\} = \frac{1}{4},$$

$$P_X(1) = P(X = 1) = P(\textbf{obtenir 1 face}) = P\{(PF),(FP)\} = \frac{2}{4} = \frac{1}{2},$$

$$P_X(2) = P(X = 2) = P(\textbf{obtenir 2 faces}) = P\{(FF)\} = \frac{1}{4}.$$

Variables aléatoires discrètes

La loi de X :

x_i	**0**	**1**	**2**	
$P_X(x_i) = P(X = x_i)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	$\sum = 1$

Espérance mathématique :

$$E(X) = \sum_i x_i P(X = x_i) = \left[0 \times \frac{1}{4} \right] + \left[1 \times \frac{1}{2} \right] + \left[2 \times \frac{1}{4} \right] = 1.$$

Variance :

$$V(X) = E\left[X - E(X) \right]^2 = (0-1)^2 \times \frac{1}{4} + (1-1)^2 \times \frac{1}{2} + (2-1)^2 \times \frac{1}{4} = \frac{1}{2}.$$

Écart type :

$$\sigma(X) = \sqrt{V(X)} = \sqrt{\frac{1}{2}} = 0.70.$$

Variables aléatoires discrètes

Quelques lois discrètes usuelles :

- **1) Si X suit la loi de Bernoulli $\mathcal{B}(p)$, alors $X(\Omega) = \{0, 1\}$:**

$$P(X = 1) = p \quad \textbf{et} \quad P(X = 0) = 1 - p.$$

$$E(X) = p \quad \textbf{et} \quad V(X) = p(1 - p).$$

Pour $p = \frac{1}{2}$, X modélise par exemple le lancer d'une pièce de monnaie équilibrée une seule fois. On a :

$$P(X = 1) = P(\text{obtenir (P)}) = \frac{1}{2}$$

$$P(X = 0) = P(\text{obtenir (F)}) = \frac{1}{2}.$$

$$E(X) = p = \frac{1}{2} \qquad V(X) = p(1 - p) = \frac{1}{4}.$$

Variables aléatoires discrètes

- **2) Si X suit la loi Binomiale $\mathcal{B}(n,p)$, alors $X(\Omega)=\{0,1,....,n\}$ et pour tout $0\leq k\leq n$, on a :**

$$P(X=k)=C_n^k p^k(1-p)^{n-k}.$$

$$E(X)=np \quad \text{et} \quad V(X)=np(1-p).$$

Si on lance $(n=10)$ fois d'une manière indépendante une pièce de monnaie équilibrée, alors $p=\frac{1}{2}=P((F))$.

Si X représente le nombre de face obtenues, alors X suit la loi Binomiale $\mathcal{B}\left(10,\frac{1}{2}\right)$.

La probabilité d'obtenir exactement $(k=3)$ fois (F) dans $(n=10)$ lancers :

$$P(X=3)=C_{10}^3\left(\frac{1}{2}\right)^3\left(1-\frac{1}{2}\right)^{10-3}=\frac{15}{128}.$$

$$E(X)=np=10*\frac{1}{2}=5 \qquad V(X)=np(1-p)=\frac{5}{2}.$$

Variables aléatoires discrètes

- **3) Si X suit la loi de Géométrique $\mathcal{G}eo(p)$, alors $X(\Omega) = \mathbb{N}^* = \{1, 2, ...\}$ et pour tout $n \in \mathbb{N}^*$, on a :**

$$P(X = n) = p(1-p)^{n-1}.$$

$$E(X) = \frac{1}{p} \quad \text{et} \quad V(X) = \frac{1-p}{p^2}.$$

X modélise comme exemple d'expériences aléatoires, le lancer infini d'une pièce de monnaie jusqu'à obtenir (Face : F).

Pour $p = \left[\frac{1}{2}\right]$ et $(n = 5)$ on a :

$$P(X = 5) = \left[\frac{1}{2}\right] 1 - \left[\frac{1}{2}\right]_{5-1} = \frac{1}{32}.$$

$$E(X) = \frac{1}{p} = 2 \quad \text{et} \quad V(X) = \frac{1-p}{p^2} = 2.$$

Variables aléatoires discrètes

- **4) Si X suit la loi de Poisson $\mathcal{P}(\lambda)$, alors $X(\Omega) = \mathbb{N} = \{0, 1, 2, ...\}$ et pour tout $n \in \mathbb{N}$, on a :**

$$P(X = n) = \exp(-\lambda)\frac{\lambda^n}{n!}.$$

$$E(X) = V(X) = \lambda.$$

Pour $(\lambda = 2)$, $(n = 0)$ et $(n = 5)$ on a :

$$P(X = 0) = \exp(-2)\frac{2^0}{0!} \approx 0.135.$$

$$P(X = 5) = \exp(-2)\frac{2^5}{5!} \approx 0.036.$$

$$E(X) = V(X) = \lambda = 2.$$

Variables aléatoires discrètes

Résumé :

Nom	Loi	$\mathbb{E}(X)$	$\mathrm{Var}(X)$
Bernoulli $\mathcal{B}(p)$	$\mathbb{P}(X=1)=p=1-\mathbb{P}(X=0)$	p	$p(1-p)$
binomiale $\mathcal{B}(n,p)$	$\forall 0\leq k\leq n,\ \mathbb{P}(X=k)=C_n^k\, p^k(1-p)^{n-k}$	np	$np(1-p$
Poisson $\mathcal{P}(\lambda)$	$\forall n\in\mathbb{N},\ \mathbb{P}(X=n)=\exp(-\lambda)\frac{\lambda^n}{n!}$	λ	λ
géométrique $\mathcal{G}eo(p)$	$\forall n\in\mathbb{N}^*,\ \mathbb{P}(X=n)=p(1-p)^{n-1}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$

Variables aléatoires discrètes

Exercice :

On tire simultanément 2 boules dans une urne qui contient 8 boules numérotées :

1	1	1	1	1	5	5	3

Soit X la variable aléatoire qui correspond au nombre de boules tirées numérotées par le chiffre 5.

1. **Déterminer la loi de X.**
2. **En déduire l'espérance $E(X)$ et la variance $V(X)$.**
3. **Calculer $P(X \geq 1)$ et $P(0 \leq X < 1)$.**

Variables aléatoires discrètes

Corrigé :

1	1	1	1	1	5	5	3

- **1)** $X(\Omega) = \{0, 1, 2\}$. $\textbf{card}(\Omega) = C_8^2 = 28$.

$$P(X = 0) = P\left(\overline{2}\right) = \frac{C_6^2}{C_8^2} = \frac{15}{28},$$

$$P(X = 1) = P\left(1\right) \textbf{ et } 1\left(\overline{5}\right) = \frac{C_2^1 * C_6^1}{C_8^2} = \frac{12}{28} = \frac{3}{7},$$

$$P(X = 2) = P\left(2\right) = \frac{C_2^2}{C_8^2} = \frac{1}{28}.$$

x_i	**0**	**1**	**2**	
$P_X(x_i) = P(X = x_i)$	$\frac{15}{28}$	$\frac{12}{28}$	$\frac{1}{28}$	$\sum = 1$

Variables aléatoires discrètes

- **2)**

x_i	**0**	**1**	**2**	
$P_X(x_i) = P(X = x_i)$	$\frac{15}{28}$	$\frac{12}{28}$	$\frac{1}{28}$	$\sum = 1$

$$E(X) = \sum_i x_i P(X = x_i) = 0 \times \frac{15}{28} + 1 \times \frac{12}{28} + 2 \times \frac{1}{28} = \frac{14}{28} = \frac{1}{2} = 0.5.$$

$$V(X) = E(X - E(X))^2 = (0-0.5)^2 \times \frac{15}{28} + (1-0.5)^2 \times \frac{12}{28} + (2-0.5)^2 \times \frac{1}{28} = \frac{9}{28}.$$

- **3) On a : $X(\Omega) = \{0, 1, 2\}$, donc :**

$$P(X \geq 1) = P(X = 1) + P(X = 2) = \frac{13}{28}.$$

$$P(0 \leq X < 1) = P(X = 0) = \frac{15}{28}.$$

Variables aléatoires continues

Rappel (variable aléatoire discrète) :

- **Soit P une probabilité sur Ω un espace fondamental associé à une expérience aléatoire.**
  Dans le chapitre précédent, on a vu que qu'une variable aléatoire discrète prend uniquement des valeurs dans un sous ensemble discret :

$$X(\Omega) = \{x_1, x_2, ...\}.$$

- **La loi de probabilité P_X de X a été définie par :**

$$P_X(x_i) = P(X = x_i) \quad \textbf{avec} \quad \sum_i P_X(x_i) = 1.$$

$$E(X) = \sum_i x_i P(X = x_i).$$

$$V(X) = E(X - E(X))^2 = \sum_i (x_i - E(X))^2 P(X = x_i).$$

Variables aléatoires continues

Variable aléatoire continue :

- **Maintenant, soit X une variable aléatoire qui prend ses valeurs dans un intervalle de $\mathbb{R}$. On dit que X est continue (ou à densité) si il existe une fonction $f \geq 0$ telle que pour tout $B \subset \mathbb{R}$, on a :**

$$P(X \in B) = \int_B f(x)dx.$$

f est appelée la densité de probabilité de X. Elle vérifie :

$$f \geq 0 \quad \text{et} \quad \int_{-\infty}^{+\infty} f(x)dx = 1 = P(X \in \mathbb{R}).$$

Variables aléatoires continues

Exercice :

Trouver la constante C pour que la fonction suivante soit une densité de probabilité :

$$f(x) = C(x - x^2) \quad \textbf{si} \quad x \in [0,1] \quad \textbf{et} \quad f(x) = 0 \quad \textbf{sinon.}$$

Corrigé :

f doit vérifier : $f \geq 0$ **et** $\int_{-\infty}^{+\infty} f(x)dx = 1.$

On a : $x - x^2 \geq 0$ **si** $x \in [0,1]$ **donc** $C > 0.$

$$\int_{-\infty}^{+\infty} f(x)dx = \int_0^1 C(x - x^2)dx = C\left[\frac{x^2}{2} - \frac{x^3}{3}\right]_0^1 = \frac{C}{6} = 1 \quad \textbf{donc} \quad C = 6.$$

Variables aléatoires continues

- **On définit la fonction de répartition de X par :**

$$\Phi(x) = P(X \leq x).$$

Alors :

$$\Phi(x) = \int_{-\infty}^{x} f(t)dt \quad \textbf{ou encore} \quad \Phi'(x) = f(x),$$

et pour tous $a < b$ dans $\mathbb{R}$, on a :

$$\int_{a}^{b} f(t)dt = \Phi(b) - \Phi(a).$$

Variables aléatoires continues

- **Espérance mathématique et Variance :**

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx \qquad V(X) = E(X - E(X))^2 = \int_{-\infty}^{+\infty} (x - E(X))^2 f(x) dx.$$

- **Quelques lois continues usuelles :**

Nom	Densité	$\mathbb{E}(X)$	$\mathrm{Var}(X)$
uniforme $\mathcal{U}[a,b]$	$\frac{1}{b-a}\, 1_{[a,b]}(x)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
exponentielle $\mathcal{E}(\lambda)$	$\lambda \exp(-\lambda x) 1_{\{x>0\}}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
normale $\mathcal{N}(m, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$	m	σ^2

Variables aléatoires continues

Exemple 1 (loi exponentielle $\mathcal{E}(\lambda)$) :

Si X suit la loi exponentielle $\mathcal{E}(\lambda)$, alors :

$$f(x) = \lambda e^{-x} 1_{(x>0)}. \qquad \Phi(x) = 0 \quad \textbf{si} \quad x \leq 0 \quad \textbf{et si} \quad x > 0 \quad \textbf{alors :}$$

$$\Phi(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt = \int_{0}^{x} \lambda e^{-t} dt = \Big[-e^{-t} \Big]_0^x = 1 - e^{-x}.$$

$$E(X) = \int_{-\infty}^{+\infty} x f(x)dx = \int_{0}^{+\infty} (x)(\lambda e^{-x})dx \qquad \textbf{(Intégration par parties)}$$

$$= \Big[(x)(-e^{-x}) \Big]_0^{+\infty} - \int_0^{+\infty} (1) * (-e^{-x})dx$$

$$= \Big[-xe^{-x} \Big]_0^{+\infty} - \Big[\frac{e^{-x}}{\lambda} \Big]_0^{+\infty} = [0 - 0] - \Big[0 - \frac{1}{\lambda} \Big] = \frac{1}{\lambda}.$$

Variables aléatoires continues

$$
\begin{aligned}
V(X) &= \int_{-\infty}^{+\infty} (x - E(X))^2 f(x)dx = \int_0^{+\infty} \left[x - \frac{1}{\lambda}\right]^2 \lambda e^{-x} dx \\
&= \left[\left[x - \frac{1}{\lambda}\right]^2 (-e^{-x})\right]_0^{+\infty} - \int_0^{+\infty} 2\left[x - \frac{1}{\lambda}\right](-e^{-x})dx \\
&= \left[0 + \frac{1}{\lambda^2}\right] + \frac{2}{\lambda}\int_0^{+\infty} \lambda x e^{-x} dx - \frac{2}{\lambda^2}\int_0^{+\infty} \lambda e^{-x} dx \\
&= \left[0 + \frac{1}{\lambda^2}\right] + \frac{2}{\lambda}\int_0^{+\infty} x f(x)dx - \frac{2}{\lambda^2}\int_0^{+\infty} f(x)dx \\
&= \left[0 + \frac{1}{\lambda^2}\right] + \frac{2}{\lambda}\int_{-\infty}^{+\infty} x f(x)dx - \frac{2}{\lambda^2}\int_{-\infty}^{+\infty} f(x)dx \\
&= \frac{1}{\lambda^2} + \frac{2}{\lambda}E(X) - \left[\frac{2}{\lambda^2} * 1\right] = \frac{1}{\lambda^2} + \frac{2}{\lambda^2} - \frac{2}{\lambda^2} = \frac{1}{\lambda^2}.
\end{aligned}
$$

Variables aléatoires continues

Exemple 2 (la loi normale $\mathcal{N}(0,1)$) :

Si Z suit la loi $\mathcal{N}(0,1)$, alors : $E(X) = 0$ **et** $V(X) = 1$.

Pour tout $z > 0$, **soit** $\Phi(z) = P(Z \leq z)$ **la fonction de répartition de** Z.

On a :

- $P(Z = a) = 0$ **car c'est une loi absolument continue .**
- $P(a < Z < b) = P(a < Z \leq b) = P(a \leq Z < b)$
  $= P(a \leq Z \leq b) = \Phi(b) - \Phi(a).$
- $\Phi(z) = P(Z \leq z) = P(Z < z).$
- $P(Z \geq z) = P(Z > z) = 1 - \Phi(z).$
- **Pour tout** $z < 0$: $\Phi(z) = 1 - \Phi(-z).$

Variables aléatoires continues

La table statistique ci-dessous nous donne pour chaque $z > 0$, la valeur :

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} \, \mathrm{e}^{-x^2/2} \, dx \quad \textbf{pour la loi normale} \quad \mathcal{N}(0,1).$$

Z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Variables aléatoires continues

Dans cette table statistique, on a trouvé que :

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Cette dernière valeur est l'intersection de la ligne 0.2 et la colonne 0.05 dans la table statistique.

- $P(Z > 0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013.$
- $\Phi(-0.25) = 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013.$
- $$\begin{aligned} P(-0.25 < Z < 0.25) &= \Phi(0.25) - \Phi(-0.25) \\ &= \Phi(0.25) - (1 - \Phi(0.25)) \\ &= 2\Phi(0.25) - 1. \end{aligned}$$

Variables aléatoires continues

Exemple 3 (loi normale $\mathcal{N}(\mu, \sigma^2)$ de moyenne μ et variance σ^2) :

Si X suit la loi normale $\mathcal{N}(\mu, \sigma^2)$, alors :

$$Z = \frac{X - \mu}{\sigma} \Longrightarrow Z \sim \mathcal{N}(0, 1).$$

Si par exemple $X \sim \mathcal{N}(72, 64)$ alors :

$$E(X) = \mu = 72 \quad \textbf{et} \quad \sigma = \sqrt{V(X)} = \sqrt{64} = 8.$$

Dans ce cas la variable : $Z = \frac{X - 72}{8}$ suit une loi $\mathcal{N}(0, 1)$, par suite :

$$P(X > 76) = 1 - P(X \leq 76) = 1 - P\left[\frac{X - 72}{8} \leq \frac{76 - 72}{8}\right]$$

$$= 1 - P(Z \leq 0.5) = 1 - \Phi(0.5) = 1 - \Phi(0.5 + 0.00) = 1 - 0.8413 = 0.1587.$$

Variables aléatoires continues

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133

$$\Phi(0.5) = P(Z \leq 0.5) = \Phi(0.5 + 0.00) = 0.6915.$$

Exercices

TD2

Exercice 1 :

On tire simultanément deux boules dans une urne qui contient : trois boules vertes, deux boules noires et une boule rouge. Soit X la variable aléatoire qui correspond au nombre de boules vertes tirées.

1. **Déterminer la loi de X. En déduire $E(X)$, $V(X)$ et $\sigma(X)$.**
2. **Calculer $P(X \leq 1)$ et $P(X > 1)$.**

Exercices

Exercice 2 :

On lance une pièce de monnaie équilibré trois fois successive. Soit X la variable aléatoire qui correspond au nombre de faces obtenues.

1. **Déterminer la loi de X. En déduire** $E(X)$, $V(X)$ **et** $\sigma(X)$.
2. **Calculer** $P(X \leq 2)$ **et** $P(X > 2)$.

Exercices

Exercice 3 :

On lance deux trièdres équilibrés numérotés $0,\ 1,\ 2,\ 3$**. Soit** X **la variable aléatoire qui correspond à la somme des deux chiffres obtenus.**

1. **Déterminer la loi de** X**. En déduire** $E(X)$**,** $V(X)$ **et** $\sigma(X)$.

Exercices

Exercice 4 :

Soit X une variable aléatoire qui suit la loi exponentielle de paramètre 1.

1. **Vérifier que** $\int_{-\infty}^{+\infty} f(x)dx = 1$.
2. **Calculer** $E(X)$, $V(X)$ **et** $\sigma(X)$.
3. **Calculer** $P(X \leq 1)$ **et** $P(X > 1)$.

Exercices

Exercice 5 :

Soit $Z \sim \mathcal{N}(0,1)$. **Déterminer :**

1. $P(Z \leq 1.23)$.
2. $P(Z \leq -1.23)$.
3. $P(Z > 1.23)$.
4. $P(Z \in [-1.23, 1.23])$.
5. $P(Z \in [-0.88, 0.36])$.

Exercices

Exercice 6 :

Soit $Z \sim \mathcal{N}(0,1)$. **Déterminer les valeurs** z **telles que :**

1. $P(Z \leq z) = 0.975$.
2. $P(Z \leq -z) = 0.3438$.

Exercices

Exercice 7 :

Soit une variable aléatoire $X \sim \mathcal{N}(53, \sigma^2 = 100)$ **représentant le résultat d'un examen pour un étudiant d'une section. Déterminer la probabilité pour que le résultat soit compris entre 33.4 et 72.6.**

Exercices

Exercice 8 :

Sur une route principale où la vitesse est limitée à 80 km/h, un radar a mesuré la vitesse de toutes les automobiles pendant une journée. En supposant que les vitesses recueillies soient distribuées normalement avec une moyenne de 72 km/h et un écart-type de 8 km/h, quelle est approximativement la proportion d'automobiles ayant commis un excès de vitesse ?

Exercices

Exercice 9 :

On suppose que la glycémie est distribuée normalement dans la population, avec une moyenne de $1g/l$ et un écart type $0.03g/l$. On mesure la glycémie chez un individu. Calculer la probabilité pour que sa glycémie soit :

1. **inférieure à 1.06.**
2. **supérieure 0.9985.**

Plan :

1 Introduction

2 Statistique descriptive univariée

3 Statistique descriptive bivariée

4 Notions de probabilités et variables aléatoires

5 **Échantillonnage et estimation**

6 Tests d'hypothèses

7 Exercices de révisions et Examens

Échantillonnage



Motivation :

Une université reçoit 7000 applications par année provenant d'éventuels étudiants.
Le formulaire de demande d'admission inclut :

- une variable quantitative qui est le score d'un test d'aptitude (SAT),
- une variable qualitative qui donne l'information sur le lieu de résidence de l'étudiant.

Le directeur des admissions aimerait avoir une idée sur ces deux variables.

Il y a deux façons d'obtenir cette information :

Échantillonnage

1)- Effectuer un recensement des 7000 postulants :

- Scores SAT : $x_1, \ldots\ldots\ldots\ldots, x_{7000}$
- Moyenne de la population :

$$\mu = \frac{1}{7000}\sum_{i=1}^{7000} x_i = 990$$

- Variance de la population :

$$\sigma^2 = \frac{1}{7000}\sum_{i=1}^{7000}(x_i - \mu)^2 = 6400$$

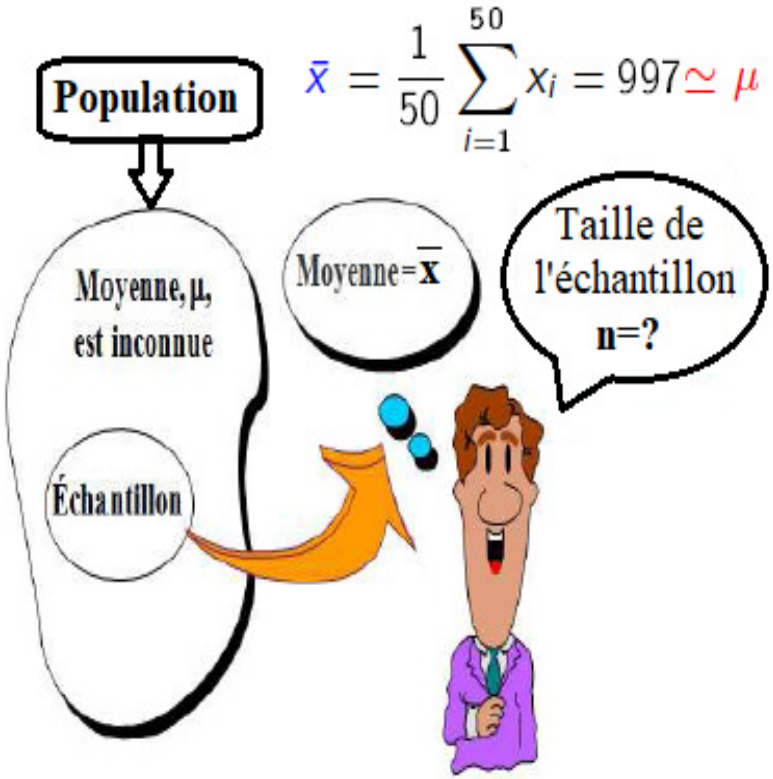
- Proportion des résidants de la population :

$$p = \frac{5040}{7000} = 0.72$$

N"	Postulant	Score SAT	Résidant
1	Mohammed	1025	Oui
2	Rachid	950	Oui
3	Hassan	1090	Non
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
7000	Karim	1279	Oui
	Total	6930000	5040 oui

Échantillonnage

2) Prendre un échantillon de taille $n = 50$ postulants est faire des estimations ponctuelles :



N"	Postulant	Score SAT	Résidant
1	Ali	1025	Oui
2	Moussa	950	Oui
3	Nouh	1090	Non
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
.	.....	.....	.....
50	Aissa	1279	Oui
	Total	49850	34 oui

Échantillonnage

Dans ce cas on prend :

- $\bar{x}$ **comme estimation de la moyenne** μ **:**

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{50}\sum_{i=1}^{50} x_i = 997 \simeq 990 = \mu$$

- s^2 **comme estimation de la variance** σ^2 **:**

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{50-1}\sum_{i=1}^{50}(x_i - \bar{x})^2 = 6301 \simeq 6400 = \sigma^2$$

- $\bar{p}$ **comme estimation de la proportion** p **:**

$$\bar{p} = \frac{n_{oui}}{n} = \frac{34}{50} = 0.68 \simeq 0.72 = p$$

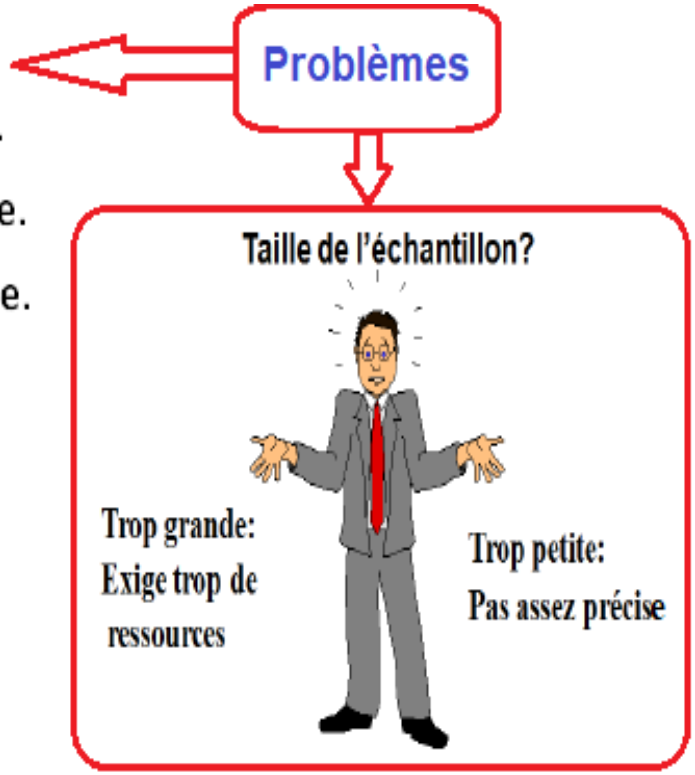
Échantillonnage

Les erreurs d'échantillonnage sont :

- $|\bar{x} - \mu|$ pour la moyenne échantillonnale.
- $|s^2 - \sigma^2|$ pour la variance échantillonnale.
- $|\bar{p} - p|$ pour la proportion échantillonnale.

Raisons pour faire un échantillonnage au lieu d'un recensement :

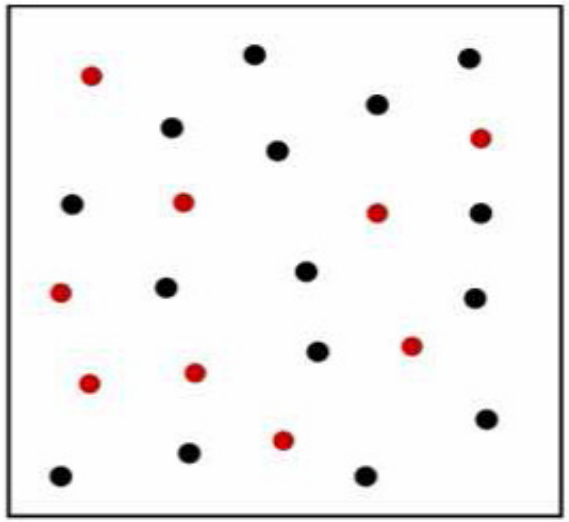
- Lorsque la population est très grande.
- Par souci d'économie (coût et temps).
- Obtenir de l'information rapidement.



Échantillonnage

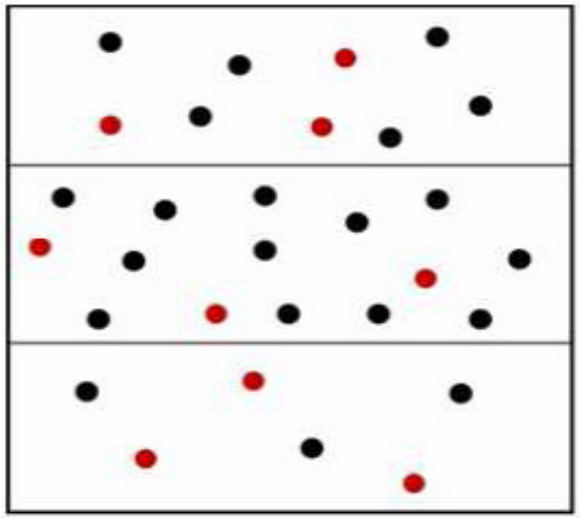
Quelques méthodes d'échantillonnage :

- **L'échantillonnage aléatoire et simple :**
  le choix se fait parmi tous les individus de la population (au sens statistique), qui ne forme qu'un grand ensemble.



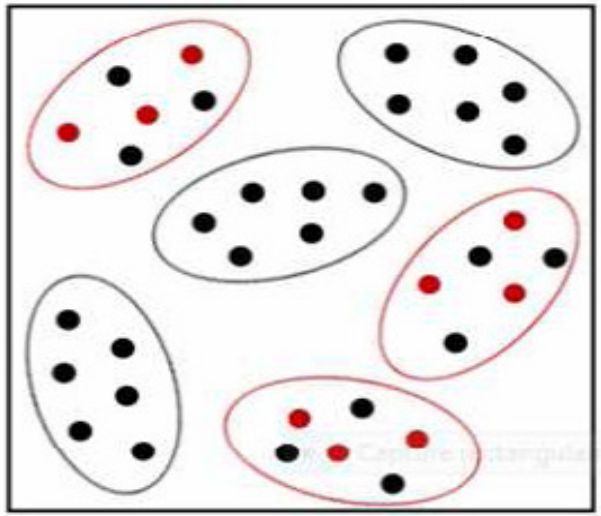
Échantillonnage

- **L'échantillonnage stratifié :**
  Si la population est très hétérogène, elle peut être divisée en sous-ensembles exclusifs (ou strates). Au sein de ces strates l'échantillonnage est ensuite aléatoire et simple. Les strates sont identifiées dans l'analyse statistique comme les niveaux d'un facteur fixe.



Échantillonnage

- **L'échantillonnage en grappes :**
  Si les strates sont très nombreuses, on en choisit certaines au hasard (les grappes). Au sein de ces grappes l'échantillonnage est ensuite aléatoire et simple. Les grappes sont identifiées dans l'analyse statistique comme les niveaux d'un facteur aléatoire.



Échantillonnage

Distribution d'échantillonnage de $\bar{X}$:

Théorème centrale limite 1 :

- **Lorsque la variance σ^2 de la population est connue et que l'échantillon prélevé est grand $(n \geq 30)$, alors**

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim \mathcal{N}(\mu, \frac{\sigma^2}{n}), \qquad \text{i.e.,} \qquad Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1).$$

- **Lorsque la variance σ^2 de la population est inconnue et que l'échantillon prélevé est grand $(n \geq 30)$, alors**

$$\bar{X} \sim \mathcal{N}(\mu, \frac{s^2}{n}), \qquad \text{i.e.,} \qquad \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim \mathcal{N}(0,1).$$

Échantillonnage

Remarque

- **Le théorème précédant est vrai aussi lorsque la variance σ^2 est connue, l'échantillon est petit (n < 30) et que la variable aléatoire X suit une loi normale $\mathcal{N}(\mu, \sigma^2)$.**

Échantillonnage

Rappel : Table de la loi Normale (0,1)

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133

$$\Phi(0.5) = P(Z \leq 0.5) = \Phi(0.5 + 0.00) = 0.6915.$$

Échantillonnage

Exemple :

Les statistiques des notes au BAC STI en France pour l'année 2006 sont :
Moyenne nationale $\mu = 10.44$, Écart type $\sigma = 1.46$.
Une classe de BTS comporte 35 élèves issus d'un BAC STI en 2006.
Calculer la probabilité que la moyenne de cette classe soit supérieure à 10.

Corrigé :

$$n = 35 > 30 \Rightarrow \bar{X} \sim \mathcal{N}\left(\mu = 10.44, \frac{\sigma^2}{n} = \frac{1.46^2}{35}\right) \Rightarrow Z = \frac{\bar{X} - 10.44}{\frac{1.46}{\sqrt{35}}} \sim \mathcal{N}(0,1).$$

$$P(\bar{X} > 10) = 1 - P(\bar{X} \leq 10) = 1 - P\left(\frac{\bar{X} - 10.44}{\frac{1.46}{\sqrt{35}}} \leq \frac{10 - 10.44}{\frac{1.46}{\sqrt{35}}}\right)$$

$$= 1 - P(Z \leq -1.78) = 1 - \Phi(-1.78) = \Phi(1.78) = 0.9625.$$

Échantillonnage

Théorème centrale limite 2 :

Si la variance σ^2 de la population est inconnue, si la variable $X \sim \mathcal{N}(\mu, \sigma^2)$, et si la taille de l'échantillon est petite ($n < 30$), alors

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim t(n-1) : \textbf{Loi de Student à n-1 degré de liberté ddl.}$$

Table de la loi Student T : $P(T > t) = \alpha$

Degrés de liberté	Aire dans la queue supérieure de la distribution					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499

Échantillonnage

Table de la loi Student T : $P(T > t) = \alpha$

Degrés de liberté	Aire dans la queue supérieure de la distribution					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250

Pour n=7, on a : ddl=n-1=6. Alors : P(T>t)=0.05 nous donne t=1.943.

Échantillonnage

Exemple :

Pour estimer le montant hebdomadaire moyen dépensé par les familles de 4 personnes pour leur épicerie, on tire un échantillon aléatoire de 25 personnes. On suppose que les montants dépensés sont distribués normalement avec une moyenne 120 et une variance inconnue. Si la variance de l'échantillon est 36, calculer la probabilité que la moyenne de l'échantillon soit supérieure à 123.

Corrigé :

On a $n = 25 < 30$ **et la variance de la population est inconnue, (on connaît la variance de l'échantillon** $s^2 = 36$**), donc**

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{\bar{X} - 120}{\frac{6}{\sqrt{25}}} \sim t(25-1) = t(24).$$

Échantillonnage

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{\bar{X} - 120}{\frac{6}{\sqrt{25}}} \sim t(25-1) = t(24).$$

$$P(\bar{X} > 123) = P\left(\frac{\bar{X} - 120}{\frac{6}{\sqrt{25}}} \geq \frac{123 - 120}{\frac{6}{\sqrt{25}}}\right) = P(T > 2.5) \simeq P(T > 2.492) = 0.01.$$

	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.0010	0.0005
1	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	127.3	318.3	636.6
2	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	14.09	22.33	31.60
23	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.767
24	0.685	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.091	3.467	3.745
25	0.684	0.856	1.058	1.316	1.708	2.060	2.485	2.787	3.078	3.450	3.725

Échantillonnage

Distribution d'échantillonnage de la proportion :

Théorème :

Si p est la proportion de la population, alors pour un échantillon de taille grande $(n>30)$, on a

$$\bar{p} \sim \mathcal{N}\left(p, \frac{p(1-p)}{n}\right) \quad \text{ou} \quad Z = \frac{\bar{p}-p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1).$$

Échantillonnage

Exemple :

$p = 0.8$ **est la proportion de Canadiens satisfaits du libre échange.** $n = 100$ **personnes interrogées. Quelle est la probabilité que la proportion des personnes interrogées satisfaites du libre échange soit inférieure ou égale à 0.9 ?**

Corrigé :

$$\textbf{On sait que :} \quad Z = \frac{\bar{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1).$$

$$P(\bar{p} \leq 0.9) = P\left(Z \leq \frac{0.9 - 0.8}{\sqrt{\frac{0.8(1-0.8)}{100}}} \right) = P(Z \leq 2.5) = 0.9938.$$

Échantillonnage

Distribution d'échantillonnage de la variance :

Théorème

Si σ^2 est la variance de la population et S^2 est la variance d'un échantillon de taille n. Alors $Y^2 = \dfrac{(n-1)S^2}{\sigma^2}$ suit la loi Khi-deux à $\nu = n - 1$ ddl.

Table de la loi Khi-deux Y^2 : $P(Y^2 > x) = \alpha$

ν \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010	0,001
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349	10,8276
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103	13,8155
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902	26,1245
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660	27,8772
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093	29,5883

pour $\alpha = 0.05$ et $n = 10$, on a $\nu = 10 - 1 = 9$ et $x = 16.9190$.

Estimation

Rappel : (estimation ponctuelle) :

Pour un échantillon de taille n, on prend :

- $\bar{X}$ **comme estimateur de la moyenne μ de la population :**

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

- S^2 **comme estimateur de la variance σ^2 de la population :**

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

- $\bar{p}$ **comme estimateur de la proportion p de la population.**

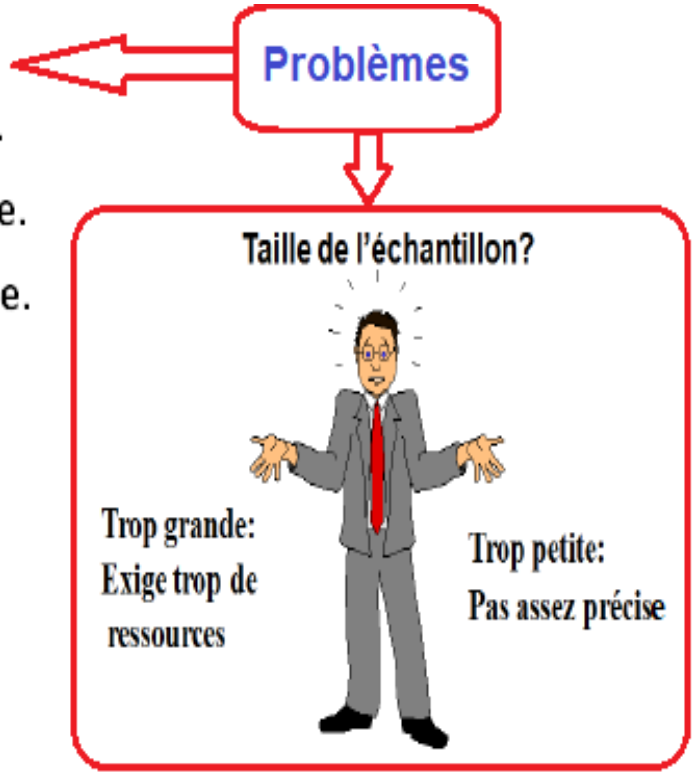
Estimation

Les erreurs d'échantillonnage sont :

- $|\bar{x} - \mu|$ pour la moyenne échantillonnale.
- $|s^2 - \sigma^2|$ pour la variance échantillonnale.
- $|\bar{p} - p|$ pour la proportion échantillonnale.

Raisons pour faire un échantillonnage au lieu d'un recensement :

- Lorsque la population est très grande.
- Par souci d'économie (coût et temps).
- Obtenir de l'information rapidement.



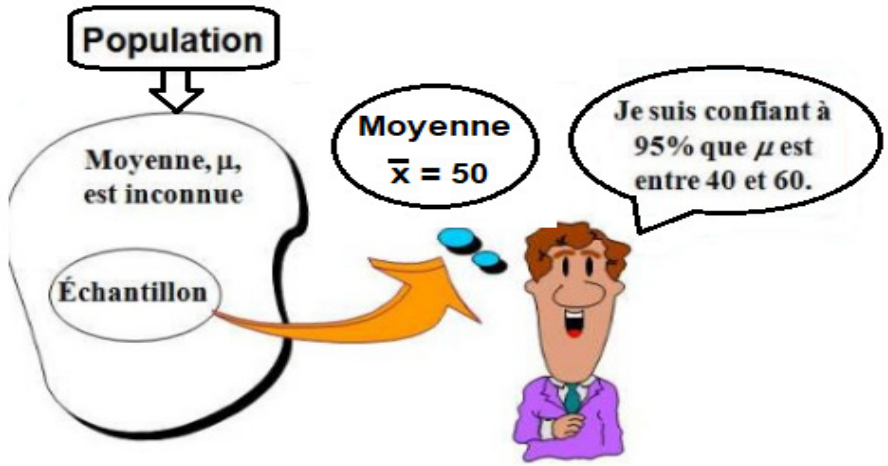
Estimation

Estimation par intervalle de confiance :

La théorie des intervalles de confiance (IC) consiste à construire, autour de l'estimation ponctuelle, un intervalle qui aura une grande probabilité $(1-\alpha)$ de contenir la vraie valeur du paramètre. Ceci répond au problème de l'erreur possible d'estimation due aux fluctuations d'échantillonnage.

Exemple :

$(1-\alpha) = 95\%$ **pour** $\alpha = 5\%$, **(i.e.,** $\alpha = 0.05$**)**



Estimation

1) Estimation par IC de la moyenne μ de la population :

Premier cas :

- **Lorsque la taille de l'échantillon est grande** $(n \geq 30)$ **et la variance de la population** σ^2 **connue, on obtient un intervalle de confiance pour** μ **au seuil de confiance** $(1-\alpha)$ **de la forme :**

$$IC_{(1-\alpha)\%} = \left[\bar{x} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} ; \bar{x} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right]$$

avec $P\left(\mu \in IC_{(1-\alpha)\%}\right) = (1-\alpha).$

$\Phi(z_{\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2}$, **où** Φ **est la fdr de la loi normale** $\mathcal{N}(0,1)$.

- **Ceci est aussi vrai pour de petits échantillons** $(n < 30)$ **lorsque** X **suit une loi normale** $\mathcal{N}(\mu, \sigma^2)$ **avec** σ^2 **connue.**

Estimation

- **Lorsque la taille de l'échantillon est grande ($n \geq 30$) et la variance de la population σ^2 est inconnue, on obtient un intervalle de confiance pour μ au seuil de confiance $(1-\alpha)$ de la forme :**

$$IC_{(1-\ )\%} = \left[\bar{x} - z\ \frac{s}{\sqrt{n}} ;\ \bar{x} + z\ \frac{s}{\sqrt{n}} \right].$$

s^2 est l'estimation de σ^2.

$\Phi(z\ ) = 1 - \frac{\alpha}{2}$, où Φ est la fonction de répartition de la loi normale $\mathcal{N}(0,1)$.

Estimation

Rappel : Table de la loi Normale (0,1)

$$\Phi(0.25) = P(Z \leq 0.25) = \Phi(0.20 + 0.05) = 0.5987.$$

Z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133

$$\Phi(0.5) = P(Z \leq 0.5) = \Phi(0.5 + 0.00) = 0.6915.$$

Estimation

Exemple :

On a observé la taille de $n = 200$ **hommes marocains adultes. Après calcul, on a obtenu une moyenne de** $\bar{x} = 168$. **Si on suppose que la variance connue vaut** $\sigma^2 = 1$. **Donnez un intervalle de confiance à** 95% **de la vraie moyenne de la population.**

Corrigé :

$$IC_{(1-\ )\%} = \left[\ \bar{x} - z\ \frac{\sigma}{\sqrt{n}}\ ;\ \bar{x} + z\ \frac{\sigma}{\sqrt{n}}\ \right]$$

Puisque $\alpha = 0.05$ **(5%), alors** $\Phi(z\ ) = 1 - \frac{\alpha}{2} = 1 - \frac{0.05}{2} = 0.975$.
Par suite $z\ = 1.96$. **Finalement** $IC_{95\%} = [167.86\ ;\ 168.14]$, **et**

$$P\left[\ \mu \in [167.86; 168.14]\ \right] = 0.95.$$

Estimation

Deuxième cas :

Lorsque la taille de l'échantillon est petite $(n < 30)$ **et** X **suit une loi normale de variance** σ^2 **inconnue, on obtient un intervalle de confiance pour** μ **au seuil de confiance** $(1-\alpha)$ **de la forme :**

$$IC_{(1-\ )\%} = \left[\bar{x} - t \ \frac{s}{\sqrt{n}} \ ; \ \bar{x} + t \ \frac{s}{\sqrt{n}} \right]$$

t **se déduit de la table Student comme suit :** $P\left[T > t \right] = \frac{\alpha}{2}$.

Estimation

Table de la loi Student T : $P(T > t) = \alpha$

Degrés de liberté	Aire dans la queue supérieure de la distribution					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250

Pour n=7, on a : ddl=n-1=6. Alors : P(T>t)=0.05 nous donne t=1.943.

Estimation

Exemple :

On veut étudier le coût du logement près du campus universitaire. Un échantillon de 10 appartements a permis d'estimer le coût moyen du loyer mensuel à 350 par mois et un écart type de 30.
Quel est l'intervalle de confiance de 95% pour la moyenne des loyers mensuels ? Supposons que les loyers suivent une loi normale.

Corrigé :

pour un coefficient de confiance de $0,95$, on a $\alpha = 0,05$, et $\frac{}{2} = 0,025$. On a $n - 1 = 10 - 1 = 9$ degrés de liberté, alors la table de la distribution Student nous donne $t \quad = 2,262$. Finalement $IC_{95\%} = [328.54; 371.46]$. i.e., nous sommes confiants à 95% que la moyenne des loyers mensuels (le vrai paramètre de la population μ), se trouve entre 328.54 et 371.46

Estimation

Détermination de la taille de l'échantillon :



Motivation : Quelle est la taille n de l'échantillon qui permettrait d'affirmer qu'en utilisant un estimateur ponctuel, l'erreur commise pour un coefficient de confiance $(1-\alpha)$ serait moindre que la marge d'erreur E ?

Estimation

Exemple : Pour la moyenne inconnue μ de la population, on a trouvé :

$$IC_{(1-\ )\%} = \left[\bar{x} - z \ \frac{\sigma}{\sqrt{n}} \ ; \ \bar{x} + z \ \frac{\sigma}{\sqrt{n}} \right].$$

Si on fixe une marge d'erreur :

$$E = z \ \frac{\sigma}{\sqrt{n}},$$

pour un coefficient de confiance $(1-\alpha)$, alors la taille de l'échantillon sera :

$$n = \left[\frac{z \ .\sigma}{E} \right]^2.$$

Pour $E = 500$, $\sigma = 5000$ et $\alpha = 5\%$, on trouve $z \ = 1.96$ et $n = 384$.

On a besoin d'un échantillon de taille $n = 384$ pour arriver à une précision de ± 500 à un seuil de confiance de 95%.

Estimation

2) Estimation par IC de la proportion p de la population :

Lorsque n est grand ($n \geq 30$) et si $\bar{p}$ est la proportion échantillonnale alors un intervalle de confiance pour la proportion p inconnue de la population au seuil de confiance $(1-\alpha)$ de la forme :

$$IC_{(1-\ )\%} = \left[\bar{p} - z\ \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}\ ;\ \bar{p} + z\ \sqrt{\frac{\bar{p}(1-\bar{p})}{n}} \right],$$

avec $\Phi(z\ ) = 1 - \frac{\alpha}{2}$ pour la loi normale $\mathcal{N}(0,1)$.

Estimation

Exemple :

SPI est une compagnie qui se spécialise dans les sondages politiques. À l'aide de sondages téléphoniques, les interviewers demandent aux citoyens pour qui ils voteraient si les élections avaient lieu aujourd'hui. Récemment, SPI a trouvé que 220 votants sur 500 voterait pour un candidat particulier. SPI veut estimer l'intervalle de confiance à 95% **pour la proportion des votants qui sont en faveur de ce candidat.**

Corrigé :

On a $n = 500$, $\bar{p} = 220/500 = 0.44$ **et** $z = 1.96$ **donc**

$IC_{95\%} = [0.3965 \ ; \ 0.4835]$, **i.e., SPI est confiant à** 95% **que la proportion des votants qui favoriseront ce candidat est entre 0.3965 et 0.4835.**

Estimation

3) Estimation par IC de la variance σ^2 de la population :

Soit n **la taille de l'échantillon et** S^2 **la variance échantillonnale.**
Ici, $Y^2 = \dfrac{(n-1)S^2}{\sigma^2}$ **suit la loi de loi Khi-deux à** $n-1$ **ddl.**
On cherche les deux nombres a **et** b **tels que :**

$$P(Y^2 \geq a) = \frac{\alpha}{2} \quad \text{et} \quad P(Y^2 \geq b) = 1 - \frac{\alpha}{2}.$$

L'intervalle de confiance au seuil $(1-\alpha)$ **pour la variance inconnue** σ^2 **de la population est de la forme :**

$$IC_{(1-\ \ )\%} = \left[\frac{(n-1)s^2}{a} \ ; \ \frac{(n-1)s^2}{b}\right].$$

Estimation

Table de la loi Khi-deux Y^2 : $P(Y^2 > x) = \alpha$

ν \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010	0,001
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349	10,8276
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103	13,8155
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902	26,1245
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660	27,8772
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093	29,5883

pour $\alpha = 0.05$ et $n = 10$, on a $\nu = 10 - 1 = 9$ et $x = 16.9190$.

Estimation

Exemple :

Pour $n = 31$ **et** $s^2 = 100$**, on a : ddl** $= 31 - 1 = 30$**.**

Pour $\alpha = 0.05$**, on a :** $\frac{\alpha}{2} = 0.025$ **et donc** $a = 46.98$**.**

Pour $\alpha = 0.05$**, on a :** $1 - \frac{\alpha}{2} = 0.975$ **et donc** $b = 16.80$**.**

Finalement

$$IC_{95\%} = \left] 0.3965 \; ; \; 0.4835 \right[.$$

Exercices

TD3

Exercice 1 (Échantillonnage) :

Pour estimer l'âge moyen d'une population de 4000 employés, un échantillon aléatoire de 40 employés est sélectionné. Quelle est la probabilité que l'âge moyen des employés de l'échantillon soit compris entre l'âge moyen de la population 2 si l'on sait que l'écart type de la population est de 8,2 ans ?

Exercices

Exercice 2 (Échantillonnage) :

Une élection a eu lieu et un candidat a eu une proportion 40% **des voix. On prélève un échantillon de 100 bulletins de vote.**

Quelle est la probabilité que, dans l'échantillon, le candidat ait entre 35% **et** 45% **des voix ?**

Exercices

Exercice 3 (Estimation) : Dans le cadre d'une étude sur la violence verbale au travail, on a interrogé au hasard 500 salariés de différents secteurs. 145 d'entre eux déclarent avoir déjà subi une violence verbale au travail.

- **1) Identifiez la population, la variable et son type.**
- **2) Donnez une estimation ponctuelle de la proportion de salariés ayant déjà subi une violence verbale.**
- **3) Donnez une estimation de cette proportion par un intervalle de confiance à 90% et 99%.**
- **4) Si avec les mêmes données on calculait un intervalle de confiance à 99%, serait-il plus grand ou plus petit que celui trouvé à la question précédente ?**

Exercices

Exercice 4 (Estimation) : On admet que le taux de cholestérol chez une femme suit une loi normale. Sur un échantillon de 10 femmes, on a obtenu les taux de cholestérol (en g/l) suivants :

3	1.8	2.1	2.7	1.4	1.9	2.2	2.5	1.7	2

- 1)- Déterminer une estimation ponctuelle de la moyenne et de la variance du taux.
- 2)- Déterminer un intervalle de confiance pour la moyenne du taux au seuil 5%.

Exercices

Exercice 5 (Estimation) : Une machine produit des pièces de type X. La masse, exprimée en (g), d'une pièce tiré au hasard dans la production, est distribuée selon une loi normale. On tire un échantillon de 17 pièces de masses suivantes :

250	254	254	253	256	250	257	251
253	255	250	255	252	261	252	251	255

- 1) Donnez une estimation ponctuelle de la moyenne et la variance de production.
- 2) Determiner une estimation par intervalle de confiance à 95% et 99% de la masse moyenne.
- 3) On suppose maintenant que la variance de la population est connue $\sigma^2 = 8.51$. Préciser la loi de la moyenne échantillonnale et déterminer la taille minimale donner a un échantillon pour obtenir un intervalle de confiance pour la moyenne au niveau 95% d'amplitude inférieure à 2. Conclure.

Exercices

Exercice 6 (Estimation) :

Dans la fabrication de comprimés effervescents, il est prévu que chaque comprimé doit contenir 1625 mg de bicarbonate de sodium. Afin de contrôler la fabrication de ces médicaments, on a prélevé un échantillon de 150 comprimés et on a mesuré la quantité de bicarbonate de sodium pour chacun d'eux :

Classes	[1610; 1615[	[1615; 1620[	[1620; 1625[	[1625; 1630[	[1630; 1635[
Effectifs	**7**	**8**	**42**	**75**	**18**

- **1) En convenant que les valeurs mesurés sont regroupées au centre de chaque classe, donner une estimation ponctuelle de la moyenne et la variance de la quantité de bicarbonate de sodium dans la population formée de l'ensemble de tous les comprimés fabriqués et supposée très grande.**
- **2) Déterminer une estimation par intervalle de confiance à 95% de la quantité moyenne de bicarbonate de sodium dans la population.**

Exercices

Exercice 7 (Estimation) :

On a mesuré le poids de raisin produit par m^2 sur 10 m^2 pris au hasard dans une vigne. On suppose que le poids de raisin produits par une souche de cette vigne suit une loi normale $\mathcal{N}(\mu, \sigma^2)$. On a obtenu les résultats suivants exprimés en (Kg) :

24	34	36	41	43	47	54	59	65	69

- **1) Déterminer une estimation ponctuelle de la moyenne théorique μ et de la variance théorique σ^2.**
- **2) Déterminer une estimation par intervalle de confiance à 95% de μ.**
- **3) Déterminer une estimation par intervalle de confiance à 95% de σ^2.**

Plan :

1 Introduction

2 Statistique descriptive univariée

3 Statistique descriptive bivariée

4 Notions de probabilités et variables aléatoires

5 Échantillonnage et estimation

6 **Tests d'hypothèses**

7 Exercices de révisions et Examens

Tests d'hypothèses

Introduction :

La majorité des tests reposent sur le principe suivant :

- **On définit une hypothèse nulle notée H_0 contre l'hypothèse alternative H_1.**

$$\textbf{Test} : \begin{cases} \textbf{hypothèse nulle} & H_0 \\ \textbf{hypothèse alternative} & H_1 \end{cases}$$

Le test a pour objectif d'accepter ou de rejeter H_0 avec un risque connu à partir des données dont on dispose.

Tests d'hypothèses

- On détermine alors une statistique qui est une variable aléatoire construite à partir des données échantillonnale .
  - Sous H_0, cette variable suit une loi de probabilité connue par exemple : (normale, student, khi-deux,...).
  - On détermine alors l'intervalle de confiance dont lequel doit tomber la statistique avec une probabilité donnée $(1-\alpha)$, (le plus souvent 95% pour $\alpha = 5\%$).

Tests d'hypothèses

- **On définit alors la règle de décision suivante :**
  - **Si la statistique tombe dans l'intervalle, on ne peut rejeter H_0. Attention, cela ne veut pas dire que H_0 est vraie mais que le test et les données ne permettent pas de voir un écart significatif à H_0.**
  - **Si la statistique ne tombe pas dans l'intervalle, on rejette H_0 avec le risque α de se tromper, (par exemple $\alpha = 5\%$).**

Tests d'hypothèses

1) Test de conformité de la proportion p à une référence p_0 :

$$\textbf{Test bilatéral} : \begin{cases} H_0 : p = p_0, \\ H_1 : p \neq p_0. \end{cases}$$

On calcule :

$$u = \frac{\bar{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}.$$

On détermine z pour la loi normale $\mathcal{N}(0,1)$: $\Phi(z) = 1 - \frac{\alpha}{2}$. Alors :

1. **Si $u \in]-z\ ; z\ [$, on ne peut rejeter H_0.**
2. **Sinon, on rejette H_0 avec une probabilité α de se tromper.**

Tests d'hypothèses

Exemple :

Sur un échantillon de taille $n = 400$ **de naissances, on a observé 206 mâles, soit une proportion de mâles de** $\bar{p} = 206/400 = 0.515$. **On se demande si il y a autant de mâles que de femelles. i.e., si** $p_0 = 0.5$. **On peut effectuer le test :**

$$\mathbf{T} : \begin{cases} H_0 : p = p_0 = 0.5, \\ H_1 : p \neq p_0 = 0.5. \end{cases}$$

On calcule :

$$u = \frac{\bar{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{0.515 - 0.5}{\sqrt{\frac{0.5(1-0.5)}{400}}} = 0.6.$$

Pour $\alpha = 5\%$, **on a** $z \quad = 1.96$. **Comme** $u \in]-z \ ; z \ [$, **alors on ne peut rejeter** H_0 **: donc il est possible que** $p = 0.5$.

Tests d'hypothèses

2) Test de conformité de la moyenne μ à une référence μ_0 :
Cas d'un petit échantillon $n < 30$ **où** σ^2 **est inconnue :**

$$\textbf{Test bilatéral :} \begin{cases} H_0 : \mu = \mu_0, \\ H_1 : \mu \neq \mu_0. \end{cases}$$

On calcule :

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}.$$

On détermine t **pour la loi student à** $n-1$ **ddl par** $P(T > t) = \frac{\alpha}{2}$**, et on décide que :**

1. **Si** $t \in]-t\ ; t\ [$**, on ne peut rejeter** H_0**.**
2. **Sinon, on rejette** H_0 **avec une probabilité** α **de se tromper.**

Tests d'hypothèses

Exemple :

Soit $n = 25$, $X \sim \mathcal{N}(\mu, \sigma^2)$, $\bar{x} = 15$ **et** $s = 9$.

Peut on affirmer que la moyenne inconnue de la population est 12.

$$\textbf{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0 = 12, \\ H_1 : \mu \neq \mu_0 = 12. \end{cases}$$

On calcule :

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} = \frac{15 - 12}{\frac{9}{\sqrt{25}}} = 1.67.$$

Le ddl est $n - 1 = 24$, **donc pour** $\alpha = 5\%$, **on trouve** $t \quad = 2.07$.

Comme $t \in]-t \ ; t \ [$, **on ne peut rejeter** H_0.

Tests d'hypothèses

Cas d'un grand échantillon $n \geq 30$ **où** σ^2 **est inconnue :**

$$\textbf{Test bilatéral} : \begin{cases} H_0 : \mu = \mu_0, \\ H_1 : \mu \neq \mu_0. \end{cases}$$

On calcule :

$$u = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}.$$

On détermine z **pour la loi normale** $\mathcal{N}(0,1)$**, et on décide que :**

1. **Si** $u \in]-z\ ; z\ [$**, on ne peut rejeter** H_0**.**
2. **Sinon, on rejette** H_0 **avec une probabilité** α **de se tromper.**

Tests d'hypothèses

3) Test de conformité de la variance à une référence σ_0^2 :

$$\textbf{Test bilatéral} : \begin{cases} H_0 : \sigma^2 = \sigma_0^2, \\ H_1 : \sigma^2 \neq \sigma_0^2. \end{cases}$$

Ici on travaille avec $Y^2 \sim$ **Khi-deux à** $n-1$ **ddl. On cherche** a **et** b **:**

$$P(Y^2 \geq a) = \frac{\alpha}{2} \qquad \textbf{et} \qquad P(Y^2 \geq b) = 1 - \frac{\alpha}{2}.$$

On calcule :

$$y^2 = \frac{n-1}{\sigma_0^2} s^2.$$

1. **Si** $y^2 \in]a; b[$**, on ne peut rejeter** H_0**.**
2. **Sinon, on rejette** H_0 **avec une probabilité** α **de se tromper.**

Tests d'hypothèses

Exemple :

$$\textbf{Test bilatéral} : \begin{cases} H_0 : \sigma^2 = \sigma_0^2 = 90, \\ H_0 : \sigma^2 \neq \sigma_0^2 = 90. \end{cases}$$

Pour $n = 31$, $s^2 = 100$, **on a le ddl** $= 31 - 1 = 30$. $\alpha = 0.05$.

$\frac{\alpha}{2} = 0.025$ **donne** $a = 46.98$ **et** $1 - \frac{\alpha}{2} = 0.975$ **donne** $b = 16.80$.

$$y^2 = \frac{n-1}{\sigma_0^2} s^2 = \frac{30}{90} \times 100 = 33.34.$$

Comme $y^2 \in]a; b[$, **on ne peut rejeter** H_0.

Tests d'hypothèses

4) Test d'indépendance du khi-deux entre deux variables qualitatives :

- **Le test du khi-deux est largement utilisé pour l'étude de l'indépendance entre deux caractères qualitatifs.**
- **La présentation des résultats se fait sous forme d'un tableau de contingence à deux entrées.**
- **Chaque entrée représente les modalités d'une des variables. On détermine alors le tableau attendu sous l'hypothèse d'indépendance.**

Tests d'hypothèses :

Exemple :

Un échantillon de $n = 1000$ personnes ont été interrogées sur une question précise. On a demandé à ces personnes de préciser leur sexe. Nous voudrions savoir si la réponse Y à la question est indépendante du sexe X.

X / Y	**Favorable**	**Défavorable**	**Indécis**	**Total**
Masculin	$n_{11} = 210$	$n_{12} = 194$	$n_{13} = 91$	$n_{1\bullet} = 495$
Féminin	$n_{21} = 292$	$n_{22} = 151$	$n_{23} = 62$	$n_{2\bullet} = 505$
Total	$n_{\bullet 1} = 502$	$n_{\bullet 2} = 345$	$n_{\bullet 3} = 153$	$n = 1000$

Tests d'hypothèses

Sous l'hypothèse d'indépendance, la distribution conjointe est simplement le produit des distributions marginales :

$$f_{ij} = f_{i\bullet} f_{\bullet j}.$$

Si l'on estime f_{ij} par $\frac{n_{ij}}{n}$ et $f_{i\bullet}$ par $\frac{n_{i\bullet}}{n}$ et $f_{\bullet j}$ par $\frac{n_{\bullet j}}{n}$, on devrait donc avoir :

$$n_{ij} \approx \frac{n_{i\bullet} n_{\bullet j}}{n}.$$

L'idée est de calculer l'écart entre les deux termes : le n_{ij} observé et le n_{ij} prédit ou théorique.

Si cet écart devient trop important, on devra rejeter l'hypothèse que les variables sont indépendantes.

Tests d'hypothèses

On calcule :

$$Q = \sum_{i=1}^{k}\sum_{j=1}^{l} \frac{\left(n_{ij} - \frac{n_{i\bullet}n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet}n_{\bullet j}}{n}}$$

La statistique Q est distribuée suivant une khi-deux à $(k-1)(l-1)$ ddl où k et l désignent le nombre de valeurs des deux variables.

Test de validité du test : il faut que la fréquence théorique $\frac{n_{i\bullet}n_{\bullet j}}{n} \geq 5$ pour tous i et j.

Nous acceptons H_0 si $Q \leq q$ avec $P(Y^2 > q) = \alpha$.

Tests d'hypothèses

Dans notre exemple, pour $\alpha = 0.05$, on a le ddl est $(3-1)\times(2-1) = 2$, $q = 5.99$ **et la valeur de Q est :**

$$Q = \frac{\left(\frac{495\times502}{1000} - 210\right)^2}{\frac{495\times502}{1000}} + \frac{\left(\frac{495\times345}{1000} - 194\right)^2}{\frac{495\times345}{1000}} + \frac{\left(\frac{495\times153}{1000} - 91\right)^2}{\frac{495\times153}{1000}} +$$
$$\frac{\left(\frac{505\times502}{1000} - 292\right)^2}{\frac{505\times502}{1000}} + \frac{\left(\frac{505\times345}{1000} - 151\right)^2}{\frac{505\times345}{1000}} + \frac{\left(\frac{505\times153}{1000} - 62\right)^2}{\frac{505\times153}{1000}} = 24.15.$$

Finalement on rejette H_0 avec un risque $\alpha = 0.05$ de se tromper.

Tests d'hypothèses

5) Tests d'homogénéité dans le cas des échantillons indépendants :

Dans deux populations (P_1) et (P_2), on étudie un même caractère. On cherche à comparer les deux populations quant à ce caractère pour savoir si elles sont homogènes ou pas.

Tests d'hypothèses

Test de comparaison de deux proportions p_1 et p_2 :

Soit p_1 (resp. p_2) la proportion d'individus ayant la propriété dans (P_1) (resp. dans (P_2)). On extrait deux échantillons indépendants (E_1) et (E_2) de tailles resp. n_1 et n_2.

$$\textbf{Test bilatéral} : \begin{cases} H_0 : p_1 = p_2 = p, \\ H_1 : p_1 \neq p_2. \end{cases}$$

Dans l'échantillon (E_1) de taille n_1 on estime la proportion p_1 par $\overline{p_1}$.
Dans l'échantillon (E_2) de taille n_2 on estime la proportion p_2 par $\overline{p_2}$.
En regroupant les deux échantillons, on peut estimer p par :

$$\bar{p} = \frac{n_1\overline{p_1} + n_2\overline{p_2}}{n_1 + n_2}.$$

Tests d'hypothèses

Validité du test : $n_1\overline{p_1} \geq 5$, $n_1(1-\overline{p_1}) \geq 5$, $n_2\overline{p_2} \geq 5$ **et** $n_2(1-\overline{p_2}) \geq 5$.

On calcule :

$$u = \frac{\overline{p_1} - \overline{p_2}}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)\overline{p}(1-\overline{p})}}.$$

On détermine z **pour la** $\mathcal{N}(0,1)$ **:** $\Phi(z) = 1 - \frac{\alpha}{2}$**, et on décide que :**

1. **Si** $u \in]-z\ ; z\ [$**, on ne peut rejeter** H_0**.**
2. **Sinon, on rejette** H_0 **avec une probabilité** α **de se tromper.**

Tests d'hypothèses

Exemple :

Dans une même catégorie sociale, un échantillon de 40 hommes a fourni 8 fumeurs et un échantillon de 60 femmes a fourni 18 fumeuses.
On se demande si la proportion de fumeurs est la même pour les deux sexes :

$$\textbf{Test bilatéral} : \begin{cases} H_0 : p_1 = p_2 = p, \\ H_1 : p_1 \neq p_2. \end{cases}$$

$n_1 = 40$, $\overline{p_1} = \frac{8}{40} = 0.2$, $n_2 = 60$ **et** $\overline{p_2} = \frac{18}{60} = 0.3$.

$n_1\overline{p_1} = 8 \geq 5$, $n_1(1-\overline{p_1}) = 32 \geq 5$, $n_2\overline{p_2} = 18 \geq 5$ **et** $n_2(1-\overline{p_2}) = 42 \geq 5$.
$\bar{p} = 0.26$, $u = -1.12$ **et pour** $\alpha = 5\%$, $z = 1.96$.

Comme $u \in]-z\ ; z\ [$**, alors on ne peut rejeter** H_0 **: la proportion de fumeurs ne diffère pas significativement entre les deux sexes.**

Tests d'hypothèses

Test de comparaison de deux variances σ_1^2 et σ_2^2 :

$$\textbf{Test bilatéral} : \begin{cases} H_0 : \sigma_1^2 = \sigma_2^2, \\ H_1 : \sigma_1^2 \neq \sigma_2^2. \end{cases}$$

Dans l'échantillon (E_1) de taille n_1 (resp. l'échantillon (E_2) de taille n_2), on estime la variance σ_1^2 (resp. σ_2^2) par :

$$s_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (x_i - \overline{x_1})^2 \quad \textbf{(resp.)} \quad s_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (x_i - \overline{x_2})^2.$$

On calcule : $f = \frac{s_1^2}{s_2^2}$ telle que $f \geq 1$ sinon on permute de sorte que $f \geq 1$.

Dans la table de la loi F de Fisher Snédécor et avec le ddl $(n_1 - 1, n_2 - 1)$, on cherche f tel que $P(F \geq f) = \frac{\alpha}{2}$, et on décide que :

1. **Si $f < f$, on ne peut rejeter H_0.**
2. **Sinon, on rejette H_0 avec une probabilité α de se tromper.**

Tests d'hypothèses

Exemple :

Dans un article de la revue "Biometrica", le biologiste Latter donne la longueur (en mm) des oeufs de Coucou trouvés dans les nids de deux espèces d'oiseaux :

- dans des nids de petite taille (Roitelet) :

19,8	22,1	21,5	20,9	22,0	21,0	22,3	21,0
20,3	20,9	22,0	22,0	20,8	21,2	21,0	

- dans des nids de taille plus grande (Fauvette) :

22,0	23,9	20,9	23,8	25,0	24,0	23,8
21,7	22,8	23,1	23,5	23,0	23,0	23,1

On se demande si le Coucou adapte la taille de ses oeufs à la taille du nid.

Tests d'hypothèses

Observation sur l'échantillon (E_1) **de taille** $n_1 = 15$ **:** $\overline{x_1} = 21.25$ **et** $s_1^2 = 0.516$.

Observation sur l'échantillon (E_2) **de taille** $n_2 = 14$ **:** $\overline{x_2} = 23.11$ **et** $s_2^2 = 1.101$.

Comme $f = \frac{s_1^2}{s_2^2} < 1$, **on permute et on prend** $f' = \frac{s_2^2}{s_1^2} = 2.14 > 1$.

Le ddl de la loi F **de Fisher-Snédécor est** $(n_2 - 1, n_1 - 1) = (13, 14) = (v_1, v_2)$.

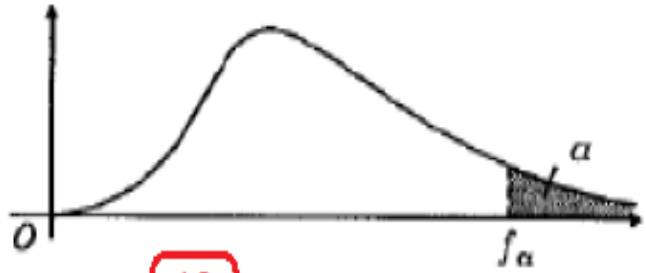
Pour $\alpha = 5\%$ **on trouve que la valeur de** f **telle que** $P(F \geq f) = \frac{\alpha}{2}$ **est compris entre 2.95 et 3.15.**

Comme $f' < f$ **, on ne peut rejeter** H_0 **et les variances des deux populations ne sont pas différentes significativement au risque** 5%.

Tests d'hypothèses

Lois de Fisher $(\alpha = 0{,}025)$

Si F est une variable aléatoire qui suit la loi de Snédécor à (ν_1, ν_2) degrés de liberté, la table donne le nombre f_α tel que $P(F \geqslant f_\alpha) = \alpha = 0{,}025$.



13

ν_2 \ ν_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	648	800	864	900	922	937	957	969	985	993	1 001	1 018
2	38,5	39,0	39,2	39,2	39,3	39,3	39,4	39,4	39,4	39,4	39,5	39,5
3	17,4	16,0	15,4	15,1	14,9	14,7	14,5	14,4	14,3	14,2	14,1	13,9
12	6,55	5,10	4,47	4,12	3,89	3,73	3,51	3,37	3,18	3,07	2,96	2,72
13	6,41	4,97	4,35	4,00	3,77	3,60	3,39	3,25	3,05	2,95	2,84	2,60
14	6,30	4,86	4,24	3,89	3,66	3,50	3,29	3,15	2,95	2,84	2,73	2,49
15	6,20	4,76	4,15	3,80	3,58	3,41	3,20	3,06	2,86	2,76	2,64	2,40

14

Tests d'hypothèses

Test de comparaison de deux moyennes μ_1 et μ_2 :

$$\textbf{Test bilatéral} : \begin{cases} H_0 : \mu_1 = \mu_2, \\ H_1 : \mu_1 \neq \mu_2. \end{cases}$$

- **Cas de grands échantillons indépendants $n_1 > 30$ et $n_2 > 30$:**

On calcule :

$$u = \frac{\overline{x_1} - \overline{x_2}}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}.$$

On détermine z pour la loi normale $\mathcal{N}(0,1)$, et on décide que :

1. **Si $u \in]-z\ ; z\ [$, on ne peut rejeter H_0.**
2. **Sinon, on rejette H_0 avec une probabilité α de se tromper.**

Tests d'hypothèses

• **Cas de petits échantillons extraits de populations gaussiennes $n_1 < 30$ et $n_2 < 30$ et tel que $\sigma = \sigma_1 = \sigma_2$:**

La variance commune σ^2 peut être estimer par :

$$s^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}.$$

On calcule :

$$t = \frac{\overline{x_1} - \overline{x_2}}{s\sqrt{(\frac{1}{n_1} + \frac{1}{n_2})}}.$$

On détermine t pour une Student à $n_1 + n_2 - 2$ ddl, et on décide que :

1. **Si $t \in]-t\ ; t\ [$, on ne peut rejeter H_0.**
2. **Sinon, on rejette H_0 avec une probabilité α de se tromper.**

Tests d'hypothèses

Exemple :

Dans un article de la revue "Biometrica", le biologiste Latter donne la longueur (en mm) des oeufs de Coucou trouvés dans les nids de deux espèces d'oiseaux :

- dans des nids de petite taille (Roitelet) :

19,8	22,1	21,5	20,9	22,0	21,0	22,3	21,0
20,3	20,9	22,0	22,0	20,8	21,2	21,0	

- dans des nids de taille plus grande (Fauvette) :

22,0	23,9	20,9	23,8	25,0	24,0	23,8
21,7	22,8	23,1	23,5	23,0	23,0	23,1

On se demande si le Coucou adapte la taille de ses oeufs à la taille du nid.

Tests d'hypothèses

Pour l'échantillon (E_1) **de taille** $n_1 = 15$ **:** $\overline{x_1} = 21.25$ **et** $s_1^2 = 0.516$.

Pour l'échantillon (E_2) **de taille** $n_2 = 14$ **:** $\overline{x_2} = 23.11$ **et** $s_2^2 = 1.101$.

On est dans le cas des petits échantillons $n_1 < 30$, $n_2 < 30$.

$s^2 = 0.798$, $t = -5.61$ **et le ddl de la loi Student est** $n_1 + n_2 - 2 = 27$.

Pour pour $\alpha = 0.05$, **on trouve** $t \quad = 2.052$.

Comme t **n'est pas dans** $]-t \ ; t \ [$, **on rejette** H_0 **avec une probabilité** α **de se tromper. La taille moyenne des oeufs de Coucou sont différentes dans les nids de Roitelet et de Fauvettes.**

Tests d'hypothèses

6) Test de normalité : test de Shapiro et Wilk :

La plupart des méthodes de test paramétriques requièrent la normalité des données. Il est donc important de disposer d'une méthode permettant de vérifier cette normalité des données. Il existe plusieurs tests pour vérifier la normalité des données observées. Nous présentons ici le test de Shapiro et Wilk pour une série d'observations d'une variable quantitative.

NB : Ce test est valable pour des petits échantillons ($n \leq 30$)**.**

Tests d'hypothèses

Exemple :

Nous avons réalisé $n = 10$ **mesures d'un alésage en (mm). On a obtenu les résultats suivants :**

$$12.124;\quad 12.230;\quad 12.327;\quad 12.242;\quad 12.466$$

$$12.215;\quad 12.026;\quad 12.359;\quad 12.215;\quad 12.387$$

On désire tester la normalité de cette série de résultats.

Tests d'hypothèses

Démarche du test de Shapiro et Wilk :

- **1) Classer les différentes valeurs de la série par ordre croissant :**

$$12.026;\quad 12.124;\quad 12.215;\quad 12.215;\quad 12.230$$

$$12.242;\quad 12.327;\quad 12.359;\quad 12.387;\quad 12.466$$

- **2) Calculer la moyenne $\bar{x}$ de la série de mesure :**

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 12.259.$$

- **3) Calculer le nombre :**

$$T^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 = 0.1514.$$

Tests d'hypothèses

- **4) Calculer les différences respectives d_i :**

$$d_1 = x_{10} - x_1 = 12.466 - 12.026 = 0.440$$

$$d_2 = x_9 - x_2 = 12.387 - 12.124 = 0.263$$

$$d_3 = x_8 - x_3 = 12.359 - 12.215 = 0.144$$

$$d_4 = x_7 - x_4 = 12.327 - 12.215 = 0.112$$

$$d_5 = x_6 - x_5 = 12.242 - 12.230 = 0.012$$

Tests d'hypothèses

- **5) A chacune de ces différences d_i, on affecte le coefficient a_i, donné par la table ci-dessus et on calcule $d_i * a_i$:**

Figure – **Valeurs des a_i :**

n / J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

Tests d'hypothèses

- **6) Calculer les nombres :**

$$d_1 * a_1 = 0.440 * 0.5739 = 0.2525$$
$$d_2 * a_2 = 0.263 * 0.3291 = 0.0865$$
$$d_3 * a_3 = 0.144 * 0.2141 = 0.0308$$
$$d_4 * a_4 = 0.112 * 0.1224 = 0.0137$$
$$d_5 * a_5 = 0.012 * 0.0399 = 0.0005$$

- **7) Calculer la valeur :**

$$b = \sum_{i=1}^{5} d_i * a_i = 0.384$$

- **8) Calculer le rapport :**

$$W = \frac{b^2}{T^2} = 0.9739$$

Tests d'hypothèses

- **9) Par exemple pour $\alpha = 0.05$, on trouve w $= 0.842$ dans la table suivante de Shapiro et Wilk.**

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

Tests d'hypothèses

- **10) Si** $W > w$ **, on accepte la normalité des donnés, sinon on rejette cette hypothèse. Dans notre exemple, on a :**
  $W = 0.9739 > w = 0.842$**, l'hypothèse de normalité est acceptée.**

Exercices

TD4

Exercice 1 :

On admet que le taux de cholestérol chez une femme suit une loi normale $\mathcal{N}(\mu, \sigma^2)$. Sur un échantillon de 10 femmes, on a obtenu les résultats suivants :

$$\sum_{i=1}^{10} x_i = 21.3 \qquad \sum_{i=1}^{10} x_i^2 = 47.49$$

- **1. Déterminer une estimation ponctuelle de la moyenne et de la variance du taux.**
- **2. Déterminer un intervalle de confiance pour la moyenne du taux au seuil 5%.**
- **Tester au seuil 5% l'hypothèse que la moyenne de la population est 2.**

Exercices

Exercice 2 :

Dans une usine du secteur de l'agroalimentaire, une machine à embouteiller est alimentée par un réservoir d'eau et par une file d'approvisionnement en bouteilles vides. Pour contrôler le bon fonctionnement de la machine. Pour une production d'une heure, on suppose que la variable aléatoire X qui à toute bouteille, prise au hasard dans cette production, associe le volume d'eau (en litres) qu'elle contient, est une variable aléatoire d'espérance μ et d'écart-type σ inconnus. On a prélevé un échantillon de 100 bouteilles, et on a obtenu un volume d'eau moyen : 1,495 l et un écart-type corrigé de 0,01.

1)- Déterminer un intervalle de confiance pour la moyenne au seuil 1%.

2)- Tester au seuil 1% si la moyenne vaut 1.5 l.

Exercices

Exercice 3 :

On sait qu'une maladie atteint 10% des individus d'une population P donnée. Un chercheur a expérimenté un traitement sur un échantillon de n individus : il a alors recensé 5% de malades.

- **1. Déterminer la valeur maximale de n qui permette au chercheur de conclure à l'efficacité du traitement au risque de 5%**
- **2. Déterminer un intervalle de confiance pour la proportion au seuil 5%.**

Exercices

Exercice 4 :

Le volume d'une pipette d'un type donné suit une loi normale $\mathcal{N}(\mu, \sigma)$. Le fabriquant annonce un écart-type $\sigma_0 = 0.2\mu$l. Pour le vérifier, on pipette 20 fois un liquide, on observe une moyenne de 10μl et un écart-type de 0.4μl.

1)- Déterminer un intervalle de confiance pour la variance au seuil 5 %.

2)- Tester au seuil 5 % si l'écart type vaut 0.2.

Exercices

Exercice 5 :

Une étude a été réalisée sur le cancer de la gorge. Pour cela, une population de 1000 personnes a été interrogée. les résultats obtenus sont donnés dans le tableau de contingences suivant :

	Atteint du cancer	Non atteint du cancer
Fumeur	344	258
Non-fumeur	160	238

- 1. Doit-on rejeter au risque 5% l'hypothèse d'indépendance des deux caractères : X=(être fumeur) et Y=(être atteint du cancer de la gorge)
- 2. Vérifier la validité du test.

Exercices

Exercice 6 :

Nous avons réalisé 10 dosages. On a obtenu les résultats suivants :

60 80 55 45 60 65 65 60 70 40

1. Utiliser le test de Shapiro et Wilk pour tester la normalité de ces données.

Exercices

Exercice 7 :

On compare les effets d'un même traitement dans deux hôpitaux différents. Dans le premier hôpital, 70 des 100 malades traités montrent des signes de guérison. Dans le deuxième hôpital, c'est le cas pour 100 des 150 malades traités.

1. **Quelle conclusion peut-on en tirer au risque de 5% ? (comparer les proportions).**

Exercices

Exercice 8 :

Sur deux groupes de même taille : 10 malades, on expérimente les effets d'un traitement destiné à diminuer la pression artérielle. On observe les résultats suivants (valeurs de la tension artérielle systolique en cm Hg). On supposera les populations gaussiennes.

Groupe 1	**15**	**18**	**17**	**20**	**21**	**18**	**17**	**15**	**19**	**16**
Groupe 2	**12**	**16**	**17**	**18**	**17**	**15**	**18**	**14**	**16**	**18**

1. **Le traitement a-t-il une action significative, au risque de 5% ?**

(comparer les variances puis comparer les moyennes).

Plan :

1. Introduction
2. Statistique descriptive univariée
3. Statistique descriptive bivariée
4. Notions de probabilités et variables aléatoires
5. Échantillonnage et estimation
6. Tests d'hypothèses
7. **Exercices de révisions et Examens**

Exercices de révisions

Exercice 1 (Variable continue et construction des classes) :

On a relevé les salaires annuels en (DH) de $n = 30$ personnes :

1860	2010	2110	2380	2600	2770	2770	2810	2920	2950
3180	3250	3250	3280	3360	4310	4320	4960	5430	5670
5710	5850	6230	6250	6960	7470	7880	8710	9440	9590

- **1. De quel type est la variable salaire ? Déterminer sa médiane. Interpréter.**
- **2. Construire le tableau statistique en adoptant des classes de même amplitude selon la règle de Sturge.**
- **3. Construire l'histogramme des fréquences.**
- **4. Déterminer la classe modale et les centres des classes.**
- **5. En déduire la moyenne, la variance et l'écart type de la variable salaire.**

Exercices de révisions

Exercice 2 (Régression linéaire) :

On considère la série double statistique suivante :

x_i	2	3	5	1	4
y_i	4	9	11	3	8

- **1. De quel type sont les variables X et Y.**
- **2. Déterminer les médianes, les moyennes et les variances de X et Y.**
- **3. Déterminer la covariance et le coefficient de corrélation entre X et Y. Donner une interprétation.**
- **4. Déterminer la droite de régression linéaire de Y en X.**

Exercices de révisions

- **5. Tracer le nuage de points et la droite de régression linéaire de Y en X.**
- **6. Vérifier que la droite de régression passe par le point $(\bar{x}, \bar{y})$.**
- **7. Établir, sur la base de ce modèle, la valeur y^* correspond à la valeur $x^* = 3,5$.**
- **8. Déterminer la variance résiduelle et le coefficient de détermination. Interpréter.**

Exercices de révisions

Exercice 3 (Loi de probabilité discrète) :

On lance deux trièdres équilibrés numérotés : 1; 2; 3; 4. **On note X la variable aléatoire qui donne le plus grand des deux numéros obtenus.**

- **1. Donner la loi de X. En déduire :** $P(X \leq 2)$, $E(X)$, $V(X)$ **et** $\sigma(X)$.

Exercices de révisions

Exercice 4 (Loi de probabilité continue) :

Soit X une variable aléatoire continue qui suit la loi de Pareto de densité : $f(x) = \frac{1_{(x>1)}}{x^2}$.

- **1. Vérifier que** $\int_{-\infty}^{+\infty} f(x)dx = 1$ **puis calculer** $E(X)$.

Exercices de révisions

Exercice 5 (Comparaisons des proportions) :
Pour traiter un certain type de tumeur, on a utilisé deux schémas thérapeutiques :
- Sur 40 malades traités avec le schéma A, on a observé la mort de 6 malades,
- Sur 60 malades traités avec le schéma B, on a observé la mort de 15 malades.

- **1. Donner une estimation ponctuelle des proportions dans les deux populations.**
- **2. Pour la population 1, donner une estimation par intervalle de confiance de la proportion au risque 1%.**
- **3. Tester au risque 1% pour la population 2 si la proportion vaut 20%.**
- **4. Comparer au risque 5% les proportions des deux populations. Peut-on dire que les schémas A et B diffèrent significativement au risque 5% ?**

Exercices de révisions

Exercice 6 (Comparaisons des moyennes) :

Sur deux groupes de même taille : 9 malades, on expérimente les effets d'un nouveau médicament. On observe les résultats suivants :

Groupe 1	**15**	**18**	**17**	**20**	**21**	**18**	**17**	**15**	**19**
Groupe 2	**12**	**16**	**17**	**18**	**17**	**15**	**18**	**14**	**16**

- **1. Donner une estimation ponctuelle des moyennes et variances dans les deux populations.**
- **2. Pour la population 1, donner une estimation par intervalle de confiance de la moyenne au risque 5%.**
- **3. Pour la population 1, donner une estimation par intervalle de confiance de la variance au risque 5%.**

Exercices de révisions

- **4. Tester au risque 5% pour la population 2 si la moyenne vaut 16.**
- **5. Tester au risque 5% pour la population 2 si la variance vaut 4.**
- **6. Comparer au risque 5% les variances des deux populations.**
- **7. Comparer au risque 5% les moyennes des deux populations.**

Exercices de révisions

Exercice 7 (Test de Shapiro et Wilk) :

Afin de tester l'hypothèse que la consommation de caféine facilite l'apprentissage, trois groupes d'étudiants se préparent à un examen : le groupe 1 boit une tasse, le groupe 2 boit 2 tasses et le groupe 3 boit 3 tasses de café. Voici leurs scores à l'examen :

Groupe 1	Groupe 2	Groupe 3
50	48	57
42	47	59
53	65	48

- **1. Utiliser le test de Shapiro et Wilk pour tester la normalité des neuf données.**

Exercices de révisions

Exercice 8 (Test d'indépendance de Khi-deux) :

Une étude a été réalisée sur le cancer de la gorge. Pour cela, une population de 1000 personnes a été interrogée. les résultats obtenus sont donnés dans le tableau de contingences suivant :

	Atteint du cancer de la gorge	Non atteint du cancer de la gorge
Fumeur	344	258
Non-fumeur	160	238

- 1. Doit-on rejeter au risque 5% l'hypothèse d'indépendance des deux caractères : X=(être fumeur) et Y=(être atteint du cancer de la gorge)
- 2. Vérifier la validité du test.

Examen (session normale 2018-2019)

Exercice 1 (2 pts=1+1) :
Soit $X \sim \mathcal{N}(\mu = 170, \sigma^2 = 64)$.

- **1. Calculer** $P(160 < X < 176)$.
- **2. Déterminer la valeur de** z **tel que** $P(170 - z < X < 170 + z) = 0,668$.

Examen (session normale 2016-2017)

Exercice 2 (9 pts=2+2+1+1+1+2) :

On considère la série double statistique suivante :

y_i	5	1	3	2	4
x_i	11	3	9	4	8

- **1. Déterminer les médianes, les moyennes et les variances de X et Y.**
- **2. Déterminer la covariance et le coefficient de corrélation entre X et Y. Donner une interprétation.**
- **3. Déterminer la droite de régression linéaire de Y en X.**
- **4. Tracer le nuage de points et la droite de régression linéaire de Y en X.**
- **5. Établir, sur la base de ce modèle, la valeur y^* correspond à la valeur $x^* = 4,5$.**
- **6. Déterminer la variance résiduelle et le coefficient de détermination. Donner une interprétation.**

Examen (session normale 2016-2017)

Exercice 3 (5 pts=1+1+2+1) :

Dans une université, on veut comparer les proportions de réussite dans la filière STU S3 sur deux années différentes :

- **Pour l'année 2014, on note 80 succès pour 120 interrogés,**
- **Pour l'année 2015, on note 70 succès pour 110 interrogés.**

- **1. Pour l'année 2014, estimer par intervalle de confiance la proportion au risque 5%.**
- **2. Pour l'année 2015, tester au risque 5% si la proportion vaut 60%.**
- **3. Comparer au risque 5% les proportions des deux années. Peut-on dire que les deux années diffèrent significativement au risque 5% ?**
- **4. Vérifier les conditions de validité de ce dernier test.**

Examen (session normale 2016-2017)

Exercice 4 (4 pts) :

Le tableau suivant présente la production laitière en litres par jours de trois races de vaches :

Race (1)	Race (2)	Race (3)
147	153	142
150	148	165
148	159	1 57

- **1. Tester au risque 5% la normalité des données.**

Examen (session normale 2016-2017)

Loi Normale N(0,1) : P(Z<z)

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,500 0	0,504 0	0,508 0	0,512 0	0,516 0	0,519 9	0,523 9	0,527 9	0,531 9	0,535 9
0,1	0,539 8	0,543 8	0,547 8	0,551 7	0,555 7	0,559 6	0,563 6	0,567 5	0,571 4	0,575 3
0,2	0,579 3	0,583 2	0,587 1	0,591 0	0,594 8	0,598 7	0,602 6	0,606 4	0,610 3	0,614 1
0,3	0,617 9	0,621 7	0,625 5	0,629 3	0,633 1	0,636 8	0,640 6	0,644 3	0,648 0	0,651 7
0,4	0,655 4	0,659 1	0,662 8	0,666 4	0,670 0	0,673 6	0,677 2	0,680 8	0,684 4	0,687 9
0,5	0,691 5	0,695 0	0,698 5	0,701 9	0,705 4	0,708 8	0,712 3	0,715 7	0,719 0	0,722 4
0,6	0,725 7	0,729 1	0,732 4	0,735 7	0,738 9	0,742 2	0,745 4	0,748 6	0,751 7	0,754 9
0,7	0,758 0	0,761 1	0,764 2	0,767 3	0,770 4	0,773 4	0,776 4	0,779 4	0,782 3	0,785 2
0,8	0,788 1	0,791 0	0,793 9	0,796 7	0,799 5	0,802 3	0,805 1	0,807 8	0,810 6	0,813 3
0,9	0,815 9	0,818 6	0,821 2	0,823 8	0,826 4	0,828 9	0,831 5	0,834 0	0,836 5	0,838 9
1,0	0,841 3	0,843 8	0,846 1	0,848 5	0,850 8	0,853 1	0,855 4	0,857 7	0,859 9	0,862 1
1,1	0,864 3	0,866 5	0,868 6	0,870 8	0,872 9	0,874 9	0,877 0	0,879 0	0,881 0	0,883 0
1,2	0,884 9	0,886 9	0,888 8	0,890 7	0,892 5	0,894 4	0,896 2	0,898 0	0,899 7	0,901 5
1,3	0,903 2	0,904 9	0,906 6	0,908 2	0,909 9	0,911 5	0,913 1	0,914 7	0,916 2	0,917 7
1,4	0,919 2	0,920 7	0,922 2	0,923 6	0,925 1	0,926 5	0,927 9	0,929 2	0,930 6	0,931 9
1,5	0,933 2	0,934 5	0,935 7	0,937 0	0,938 2	0,939 4	0,940 6	0,941 8	0,942 9	0,944 1
1,6	0,945 2	0,946 3	0,947 4	0,948 4	0,949 5	0,950 5	0,951 5	0,952 5	0,953 5	0,954 5
1,7	0,955 4	0,956 4	0,957 3	0,958 2	0,959 1	0,959 9	0,960 8	0,961 6	0,962 5	0,963 3
1,8	0,964 1	0,964 9	0,965 6	0,966 4	0,967 1	0,967 8	0,968 6	0,969 3	0,969 9	0,970 6
1,9	0,971 3	0,971 9	0,972 6	0,973 2	0,973 8	0,974 4	0,975 0	0,975 6	0,976 1	0,976 7

Examen (session de rattrapage 2016-2017)

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

Tables des valeurs des a_i

n / J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

Examen (session de rattrapage 2016-2017)

Exercice 1 (2 pts=1+1) :

Soit X une variable aléatoire de densité de probabilité : $f(x) = \frac{1_{(x>1)}}{x^2}$.

1. **Vérifier que** $\int_{-\infty}^{+\infty} f(x)dx = 1$.
2. **Calculer l'espérance** $E(X)$.

Examen (session de rattrapage 2016-2017)

Exercice 2 (9 pts=1+2+2+1+1+1+1) :

On considère la série double statistique suivante :

x_i	16	8	7	5	11	2	14	13	20	24
y_i	17	12	7	2	8	3	13	10	8	20

1. **Déterminer les médianes de X et Y. Donner une interprétation.**
2. **Déterminer les moyennes et les variances de X et Y.**
3. **Déterminer la covariance et le coefficient de corrélation entre X et Y. Donner une interprétation.**
4. **Déterminer la droite de régression linéaire de Y en X.**
5. **Tracer le nuage de points et la droite de régression linéaire de Y en X.**
6. **Établir, sur la base de ce modèle, y^* correspond à la valeur $x^* = 10$.**
7. **Déterminer la variance résiduelle et le coefficient de détermination. Donner une interprétation.**

Examen (session de rattrapage 2016-2017)

Exercice 3 (9 pts=1+1+1+1+1+2+2) :

Sur deux groupes de deux types de produits, on test un nouveau processus. On observe les résultats suivants :

Produit A	17	18	17	15	14	16	18	12	16	18
Produit B	17	15	19	16	15	18	21	18	17	20

1. **Donner une estimation ponctuelle des moyennes et variances dans les deux groupes.**
2. **Pour le groupe B, estimer par intervalle de confiance la moyenne au risque 5 %.**
3. **Pour le groupe A, estimer par intervalle de confiance la variance au risque 5 %.**

Examen (session de rattrapage 2016-2017)

- **4- Pour le groupe B, tester au risque 5 % si la moyenne vaut 16.**
- **5- Pour le groupe B, tester au risque 5 % si la variance vaut 20.**
- **6- Comparer au risque 5 % les variances des deux groupes.**

7- Pour le groupe A, tester au risque 5 % la normalité des données.

Examen (session de rattrapage 2016-2017)

Loi Student : P(T>t) = alpha

Degrés de liberté	alpha : Aire dans la queue supérieure de la distribution					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250

Examen (session de rattrapage 2016-2017)

Loi Khi-deux à v ddl : $P(Y^2>x)$

v \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103
3	0,1148	0,2158	0,3518	0,5844	6,2514	7,8147	9,3484	11,3449
4	0,2971	0,4844	0,7107	1,0636	7,7794	9,4877	11,1433	13,2767
5	0,5543	0,8312	1,1455	1,6103	9,2364	11,0705	12,8325	15,0863
6	0,8721	1,2373	1,6354	2,2041	10,6446	12,5916	14,4494	16,8119
7	1,2390	1,6899	2,1673	2,8331	12,0170	14,0671	16,0128	18,4753
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093

Examen (session de rattrapage 2016-2017)

Loi Fisher Snédécor à (v_1, v_2) ddl

$P(F \geqslant f_\alpha) = \alpha = 0{,}025$

v_2 \ v_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	648	800	864	900	922	937	957	969	985	993	1 001	1 018
2	38,5	39,0	39,2	39,2	39,3	39,3	39,4	39,4	39,4	39,4	39,5	39,5
3	17,4	16,0	15,4	15,1	14,9	14,7	14,5	14,4	14,3	14,2	14,1	13,9
4	12,2	10,6	9,98	9,60	9,36	9,20	8,98	8,84	8,66	8,56	8,46	8,26
5	10,0	8,43	7,76	7,39	7,15	6,98	6,76	6,62	6,43	6,33	6,23	6,02
6	8,81	7,26	6,60	6,23	5,99	5,82	5,60	5,46	5,27	5,17	5,07	4,85
7	8,07	6,54	5,89	5,52	5,29	5,12	4,90	4,76	4,57	4,47	4,36	4,14
8	7,57	6,06	5,42	5,05	4,82	4,65	4,43	4,30	4,10	4,00	3,89	3,67
9	7,21	5.71	5,08	4,72	4,48	4,32	4,10	3,96	3,77	3,67	3,56	3,33
10	6,94	5,46	4,83	4,47	4,24	4,07	3,85	3,72	3,52	3,42	3,31	3,08

Examen (session de rattrapage 2016-2017)

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

Tables des valeurs des a_i

n / J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

Examen (session normale 2017-2018)

Exercice 1 (3 pts=1+2) :

- **Nous supposons que l'âge auquel un enfant commence à marcher est une variable aléatoire suivant la loi normale de moyenne 13 mois et une variance 2,25 mois. Quelle est la probabilité qu'un enfant commence à marcher entre 11 et 15 mois ?**
- **Le score obtenu sur la qualité d'un produit a pour moyenne 84 et un écart-type de 35. Quelle est la probabilité d'observer sur un échantillon de taille 75 un score moyen supérieure à 90 ?**

Examen (session normale 2017-2018)

Exercice 2 (7 pts=2+2+1+2) : Dans la série statistique suivante, X représente le nombre de jours d'exposition au soleil d'une feuille et Y le nombre de stomates aérifères au millimètre carré :

X	22	26	2	4	12	18	28	30	7	10
Y	31	36	4	10	23	28	48	53	25	20

Examen (session normale 2017-2018)

- **Déterminer l'équation de la droite de regression linéaire de Y en X.**
- **Calculer les coefficients de corrélation et de détermination. Commenter les résultats.**
- **Quel nombre de stomates peut-on prévoir après 20 jours d'exposition au soleil ?**
- **Tracer le nuage de points et la droite de régression linéaire de Y en X.**

Examen (session normale 2017-2018)

Exercice 3 (4 pts=1+1+1+1) : Pour traiter un certain type de tumeur, on a utilisé deux schémas thérapeutiques :
- Sur 40 malades traités avec le schéma A, on a observé une mortalité de 6 malades.
- Sur 60 malades traités avec le schéma B, on a observé une mortalité de 15 malades.

- **Pour le schéma A, estimer par intervalle de confiance la proportion au risque 5%.**
- **Pour le schéma B, tester au risque 5% si la proportion vaut 20%.**
- **Comparer au risque 5% les proportions pour les deux schémas.**
- **Vérifier la validité du test de la question (3).**

Examen (session normale 2017-2018)

Exercice 4 (6 pts) : Pour mesurer l'influence de nourriture sur la croissance du poids des bébés, on a mesuré le poids des bébés pour quatres types de nourriture.

Type (1)	Type (2)	Type (3)	Type (4)
4	25	17	15
19	21	10	23
20	9	13	16

- **1. Tester au risque 5 % la normalité des données.**

Examen (session normale 2017-2018)

Loi Normale N(0,1) : P(Z<z)

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,500 0	0,504 0	0,508 0	0,512 0	0,516 0	0,519 9	0,523 9	0,527 9	0,531 9	0,535 9
0,1	0,539 8	0,543 8	0,547 8	0,551 7	0,555 7	0,559 6	0,563 6	0,567 5	0,571 4	0,575 3
0,2	0,579 3	0,583 2	0,587 1	0,591 0	0,594 8	0,598 7	0,602 6	0,606 4	0,610 3	0,614 1
0,3	0,617 9	0,621 7	0,625 5	0,629 3	0,633 1	0,636 8	0,640 6	0,644 3	0,648 0	0,651 7
0,4	0,655 4	0,659 1	0,662 8	0,666 4	0,670 0	0,673 6	0,677 2	0,680 8	0,684 4	0,687 9
0,5	0,691 5	0,695 0	0,698 5	0,701 9	0,705 4	0,708 8	0,712 3	0,715 7	0,719 0	0,722 4
0,6	0,725 7	0,729 1	0,732 4	0,735 7	0,738 9	0,742 2	0,745 4	0,748 6	0,751 7	0,754 9
0,7	0,758 0	0,761 1	0,764 2	0,767 3	0,770 4	0,773 4	0,776 4	0,779 4	0,782 3	0,785 2
0,8	0,788 1	0,791 0	0,793 9	0,796 7	0,799 5	0,802 3	0,805 1	0,807 8	0,810 6	0,813 3
0,9	0,815 9	0,818 6	0,821 2	0,823 8	0,826 4	0,828 9	0,831 5	0,834 0	0,836 5	0,838 9
1,0	0,841 3	0,843 8	0,846 1	0,848 5	0,850 8	0,853 1	0,855 4	0,857 7	0,859 9	0,862 1
1,1	0,864 3	0,866 5	0,868 6	0,870 8	0,872 9	0,874 9	0,877 0	0,879 0	0,881 0	0,883 0
1,2	0,884 9	0,886 9	0,888 8	0,890 7	0,892 5	0,894 4	0,896 2	0,898 0	0,899 7	0,901 5
1,3	0,903 2	0,904 9	0,906 6	0,908 2	0,909 9	0,911 5	0,913 1	0,914 7	0,916 2	0,917 7
1,4	0,919 2	0,920 7	0,922 2	0,923 6	0,925 1	0,926 5	0,927 9	0,929 2	0,930 6	0,931 9
1,5	0,933 2	0,934 5	0,935 7	0,937 0	0,938 2	0,939 4	0,940 6	0,941 8	0,942 9	0,944 1
1,6	0,945 2	0,946 3	0,947 4	0,948 4	0,949 5	0,950 5	0,951 5	0,952 5	0,953 5	0,954 5
1,7	0,955 4	0,956 4	0,957 3	0,958 2	0,959 1	0,959 9	0,960 8	0,961 6	0,962 5	0,963 3
1,8	0,964 1	0,964 9	0,965 6	0,966 4	0,967 1	0,967 8	0,968 6	0,969 3	0,969 9	0,970 6
1,9	0,971 3	0,971 9	0,972 6	0,973 2	0,973 8	0,974 4	0,975 0	0,975 6	0,976 1	0,976 7

Examen (session de rattrapage 2016-2017)

Table de Shapiro et Wilk

n	Risque 5 %	Risque 1 %
	$W_{0,05}$	$W_{0,01}$
5	0,762	0,686
6	0,788	0,713
7	0,803	0,730
8	0,818	0,749
9	0,829	0,764
10	0,842	0,781
11	0,850	0,792
12	0,859	0,805

Tables des valeurs des a_i

n / J	2	3	4	5	6	7	8	9	10
1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739
2		0.0000	0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291
3				0.0000	0.0875	0.1401	0.1743	0.1976	0.2141
4						0.0000	0.0561	0.0947	0.1224
5								0.0000	0.0399

Examen (session de rattrapage 2017-2018)

Exercice 1 (8 pts=3+1+2+2) :

Un échantillon de 48 poissons de la même espèce à fourni les poids suivants (en g) :

60	82	92	97	101	104	109	118	131	155	69	82
93	97	101	104	110	120	133	165	70	85	93	99
101	105	110	121	138	166	74	85	93	99	102	106
110	125	140	128	79	87	94	99	102	107	114	180

Examen (session de rattrapage 2017-2018)

1. **Construire le tableau statistique en adoptant quatres classes.**
2. **Tracer la fonction de répartition.**
3. **Déterminer la médiane par interpolation linéaire.**

   Utiliser les quatres classes pour calculer la moyenne, la variance et l'écart type.

Examen (session de rattrapage 2017-2018)

Exercice 2 (4 pts=3+1) :

Le tableau ci-dessus résume la présence ou l'absence d'une infection bactérienne en fonction de l'usage ou non d'une antibiothérapie ou d'un placebo :

	Antibio	Placebo
Absence	74	27
Présence	10	29

1. **Doit-on rejeter au risque 5% l'hypothèse d'indépendance des deux caractères.**
2. **Vérifier la validité du test.**

Examen (session de rattrapage 2017-2018)

Exercice 3 (8 pts=1+1+1+1+2+2) :

On a mesuré, dans deux classes différentes, après une course de 400 mètres, le pouls (en battements par minute) de sept étudiants suivants un cours d'éducation physique :

Classe 1	74	87	77	99	103	81	60
Classe 2	83	96	99	110	130	95	74

Examen (session de rattrapage 2017-2018)

1. **Pour la classe (1), estimer par intervalle de confiance la moyenne au risque 5%.**
2. **Pour la classe (1), tester au risque 5% si la moyenne vaut 80.**
3. **Pour la classe (2), estimer par intervalle de confiance la variance au risque 5%.**
4. **Pour la classe (2), tester au risque 5% si la variance vaut 330.**
5. **Comparer au risque 5% les variances des deux classes.**
6. **Comparer au risque 5% les moyennes des deux classes.**

Examen (session de rattrapage 2017-2018)

1. **Pour la classe (1), estimer par intervalle de confiance la moyenne au risque 5%.**
2. **Pour la classe (1), tester au risque 5% si la moyenne vaut 80.**
3. **Pour la classe (2), estimer par intervalle de confiance la variance au risque 5%.**
4. **Pour la classe (2), tester au risque 5% si la variance vaut 330.**
5. **Comparer au risque 5% les variances des deux classes.**
6. **Comparer au risque 5% les moyennes des deux classes.**

Examen (session de rattrapage 2017-2018)

Degrés de liberté	Loi Student : P(T>t)					
	0,20	0,10	0,05	0,025	0,01	0,005
1	1,376	3,078	6,314	12,706	31,821	63,656
2	1,061	1,886	2,920	4,303	6,965	9,925
3	0,978	1,638	2,353	3,182	4,541	5,841
4	0,941	1,533	2,132	2,776	3,747	4,604
5	0,920	1,476	2,015	2,571	3,365	4,032
6	0,906	1,440	1,943	2,447	3,143	3,707
7	0,896	1,415	1,895	2,365	2,998	3,499
8	0,889	1,397	1,860	2,306	2,896	3,355
9	0,883	1,383	1,833	2,262	2,821	3,250
10	0,879	1,372	1,812	2,228	2,764	3,169
11	0,876	1,363	1,796	2,201	2,718	3,106
12	0,873	1,356	1,782	2,179	2,681	3,055

Examen (session de rattrapage 2017-2018)

Loi Khi-deux à v ddl : $P(Y^2>x)$

v \ α	0,990	0,975	0,950	0,900	0,100	0,050	0,025	0,010
1	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349
2	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103
3	0,1148	0,2158	0,3518	0,5844	6,2514	7,8147	9,3484	11,3449
4	0,2971	0,4844	0,7107	1,0636	7,7794	9,4877	11,1433	13,2767
5	0,5543	0,8312	1,1455	1,6103	9,2364	11,0705	12,8325	15,0863
6	0,8721	1,2373	1,6354	2,2041	10,6446	12,5916	14,4494	16,8119
7	1,2390	1,6899	2,1673	2,8331	12,0170	14,0671	16,0128	18,4753
8	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902
9	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660
10	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093

Examen (session de rattrapage 2017-2018)

Loi Fisher Snédécor à (v_1, v_2) ddl

$P(F \geq f_\alpha) = \alpha = 0{,}025$

v_2 \ v_1	1	2	3	4	5	6	8	10	15	20	30	∞
1	648	800	864	900	922	937	957	969	985	993	1 001	1 018
2	38,5	39,0	39,2	39,2	39,3	39,3	39,4	39,4	39,4	39,4	39,5	39,5
3	17,4	16,0	15,4	15,1	14,9	14,7	14,5	14,4	14,3	14,2	14,1	13,9
4	12,2	10,6	9,98	9,60	9,36	9,20	8,98	8,84	8,66	8,56	8,46	8,26
5	10,0	8,43	7,76	7,39	7,15	6,98	6,76	6,62	6,43	6,33	6,23	6,02
6	8,81	7,26	6,60	6,23	5,99	5,82	5,60	5,46	5,27	5,17	5,07	4,85
7	8,07	6,54	5,89	5,52	5,29	5,12	4,90	4,76	4,57	4,47	4,36	4,14
8	7,57	6,06	5,42	5,05	4,82	4,65	4,43	4,30	4,10	4,00	3,89	3,67
9	7,21	5,71	5,08	4,72	4,48	4,32	4,10	3,96	3,77	3,67	3,56	3,33
10	6,94	5,46	4,83	4,47	4,24	4,07	3,85	3,72	3,52	3,42	3,31	3,08

Bibliographie

 Emile Amzallag et Norbert Piccioli. *Introduction à la statistique.*

 Renée Veysseyre. *Aide-mémoire : Statistique et probabilités pour l'ingénieur.*

 Yves Tillé. *Résumé du cours de statistique descriptive.*